ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC & KỸ THUẬT MÁY TÍNH



Lập trình cho Trí tuệ nhân tạo và Khoa học dữ liệu
CO3135

PHÁT HIỆN BẤT THƯỜNG PHỤ TẢI ĐIỆN BẰNG CÁC PHƯƠNG PHÁP HỌC MÁY VÀ HỌC SÂU TÍCH HỢP THÔNG TIN SIÊU DỮ LIỆU

GVHD: ThS Trần Huy
NHÓM: **L01**
SV: Nguyễn Ngọc Tôn - 2313508
Nguyễn Miên Phú - 2312658
Trần Đỗ Đức Phát - 2312596
Huỳnh Kim Quý - 2312894
Nguyễn Đức Tiến - 2313431

TP. HỒ CHÍ MINH, THÁNG 12/2026

Mục lục

1 Tổng quan về Bài toán và Dữ liệu **4**
1.1 Giới thiệu bài toán 4
1.2 Mô tả tập dữ liệu 4
1.2.1 Các thuộc tính và nhóm đặc trưng của bộ dữ liệu 6
1.2.2 Tình trạng dữ liệu thiếu 7

2 Tổng quan tài liệu **7**
2.1 Các phương pháp Học máy hiện có để giải quyết bài toán 7
2.1.1 XGBoost (eXtreme Gradient Boosting) 7
2.1.2 LightGBM (Light Gradient Boosting Machine) 8
2.1.3 CatBoost (Categorical Boosting) 9
2.1.4 Random Forest 10
2.1.5 Extra Trees (Extremely Randomized Trees) 11
2.1.6 Tổng hợp so sánh các thuật toán Học máy 12
2.2 Các phương pháp Học sâu hiện có để giải quyết bài toán 12
2.2.1 Biểu diễn bài toán và ba hệ hình tiếp cận 13
2.2.2 Nhóm Mạng Hồi quy (Recurrent Neural Networks) 13
2.2.3 Nhóm Mạng Tích chập thời gian (Temporal Convolutional Networks) 15
2.2.4 Nhóm Tự mã hoá (Autoencoder-based) 16
2.2.5 Nhóm Mô hình sinh đối kháng (GAN-based) 18
2.2.6 Nhóm Transformer 19
2.2.7 Kỹ thuật huấn luyện trên dữ liệu mất cân bằng 20
2.2.8 Các nghiên cứu liên quan trên chính bộ dữ liệu LEAD 21
2.2.9 Tổng hợp so sánh các họ mô hình Học sâu 22

3 Khám phá Dữ liệu (EDA) và Tiền xử lý Dữ liệu **22**
3.1 Khám phá Dữ liệu Ban đầu 22
3.1.1 Phân tích sự Mất cân bằng Lớp Dữ liệu 22
3.1.2 Phân tích Phân phối Tần suất Đặc trưng qua Histogram Diagrams 23
3.1.3 Toàn cảnh Lịch sử Phụ tải và Phân bố Dị thường theo Thời gian . 25
3.1.4 Phân loại Hình thái Dị thường Phụ tải trên Chuỗi Thời gian 26
3.1.5 Nhiễu Cảm biến và Tình trạng Thiếu Dữ liệu 27
3.2 Quy trình Tiền xử lý Dữ liệu 28
3.2.1 Giao thức Phân chia Chuỗi Thời gian Chu kỳ Mùa vụ và 96 Giờ Cách ly (100% Zero Data Leakage) 28
3.3 Khám phá Dữ liệu sau Tiền xử lý 34
3.3.1 Kiểm tra Tính Toàn vẹn và Phân bổ Đặc trưng 34
3.3.2 Lược đồ Lịch sử Tiến trình Tiền xử lý 36
3.3.3 Khám phá và Động lực Khoa học của Tương tác Khu vực (Zone EDA) 37

4 Triển khai thuật toán Học Máy - Machine Learning **38**
4.1 Thước đo Đánh giá và Cơ chế Ngưỡng Quyết định 38
4.1.1 Thước đo Đánh giá 38
4.1.2 Cơ chế Ngưỡng Quyết định 39
4.2 Thử nghiệm, Huấn luyện và Đánh giá các Mô hình 40

4.2.1 Chiến lược Phân chia Dữ liệu và Kiểm soát Phân phối Tập Huấn luyện - Kiểm tra . . . 40
4.2.2 Phân tích Thực nghiệm: Đối chứng Đa Chiều giữa Cây Truyền thống và Gradient Boosting qua 3 Không gian Dữ liệu . . . 42
4.2.3 Tiến trình Phát triển Không gian Đặc trưng: Baseline vs Zone vs Context-Aware . . . 43
4.2.4 Tinh chỉnh Siêu tham số (Hyperparameter Tuning) với Optuna . . . 44
4.2.5 Kỹ thuật Dung hợp Đa Mô hình (Multi-Model Ensembling) và Bảng Tổng hợp Master Benchmark . . . 45

5 Triển khai thuật toán Học Sâu - Deep Learning 47
5.1 Thiết kế Pipeline Học Sâu Tổng thể . . . 47
5.2 Huấn luyện và Đánh giá Mô hình . . . 49
5.2.1 Cơ sở Phương pháp luận: Mục tiêu Đầu ra, Tiêu chí Lựa chọn và Quy trình Thực hiện . . . 49
5.2.2 Dữ liệu Đầu vào và Giao thức Đánh giá . . . 50
5.2.3 Đặc tả Kiến trúc và Siêu tham số . . . 52
5.2.4 Luận giải việc Lựa chọn và Loại trừ các Thuật toán . . . 52
5.3 Kết quả Thực nghiệm Đánh giá . . . 53
5.4 Giới hạn của Hiện thực và Hướng Mở rộng . . . 56
5.5 Bộ Giả thuyết Kiểm chứng . . . 57

6 So sánh Học Máy và Học Sâu: Thế mạnh và Điểm yếu 58

7 Kết luận và Hướng phát triển tương lai 58
7.1 Kết luận . . . 58
7.2 Hướng phát triển Tương lai . . . 58

TÀI LIỆU THAM KHẢO 59

STT	MSSV	Họ và Tên	Nhiệm vụ	Đóng góp
1	2313508	Nguyễn Ngọc Tôn	• Thực hiện tiền xử lý dữ liệu • Xây dựng pipeline Machine Learning	100%
2	2312658	Nguyễn Miên Phú	• Viết báo cáo	100%
3	2312596	Trần Đỗ Đức Phát	• Xây dựng pipeline Deep Learning • Viết báo cáo	100%
4	2312894	Huỳnh Kim Quý	• Xây dựng pipeline Deep Learning • Viết báo cáo	100%
5	2313431	Nguyễn Đức Tiến	• Viết báo cáo	100%

Bảng 1: **Phân công nhiệm vụ và mức độ đóng góp**

1 Tổng quan về Bài toán và Dữ liệu

1.1 Giới thiệu bài toán

Các tòa nhà hiện đại tiêu thụ một lượng lớn năng lượng và được trang bị nhiều công tơ điện thông minh. Các thiết bị này liên tục ghi nhận mức tiêu thụ điện theo thời gian, tạo ra một lượng lớn dữ liệu chuỗi thời gian. Việc phân tích các dữ liệu này có thể hỗ trợ phát hiện những trường hợp sử dụng năng lượng bất thường, từ đó góp phần xác định các vấn đề như sự cố thiết bị, thiết bị xuống cấp, cấu hình không phù hợp hoặc các hành vi sử dụng năng lượng không hiệu quả.

Trong báo cáo này, nhóm tập trung vào bài toán *Energy Anomaly Detection*, nhằm phát hiện các điểm bất thường trong dữ liệu tiêu thụ điện. Một điểm dữ liệu được xem là bất thường (*anomaly*) khi mức tiêu thụ điện tại thời điểm đó có hành vi khác biệt đáng kể so với trạng thái sử dụng điện thông thường. Ngược lại, các điểm dữ liệu phù hợp với trạng thái sử dụng thông thường được xem là bình thường (*normal*).

Về mặt hình thức, bài toán được thiết lập dưới dạng phân lớp có giám sát trên không gian đặc trưng đa chiều. Mỗi quan trắc của một tòa nhà tại thời điểm t được mã hóa thành một vector đặc trưng $\mathbf{x} \in \mathbb{R}^D$ tích hợp từ nhiều nguồn dữ liệu:

$$\mathbf{x} = \Big[\underbrace{p_t}_{\text{mức phụ tải}}, \underbrace{\mathbf{x}_{\text{time}}}_{\text{chu kỳ tuần hoàn}}, \underbrace{\mathbf{x}_{\text{bldg}}}_{\text{thông tin tòa nhà}}, \underbrace{\mathbf{x}_{\text{weather}}}_{\text{vi khí hậu}}, \underbrace{\mathbf{x}_{\text{interaction}}}_{\text{tương tác khu vực}} \Big]^\top \in \mathbb{R}^D$$

Mục tiêu của mô hình là học một hàm ánh xạ $f : \mathbb{R}^D \to [0, 1]$ nhằm ước lượng xác suất xảy ra dị thường:

$$\hat{p} = P(y = 1 \mid \mathbf{x}) = f(\mathbf{x})$$

Do tập dữ liệu thực tế có mức độ mất cân bằng lớp cực đoan (tỷ lệ mẫu bất thường chỉ chiếm khoảng 2,13%), việc áp dụng ngưỡng phân lớp mặc định $\tau = 0{,}5$ sẽ khiến mô hình bỏ sót phần lớn các điểm dị thường thực tế. Do đó, quyết định gán nhãn cuối cùng được điều khiển bởi ngưỡng quyết định tối ưu τ^*:

$$\hat{y} = \mathbb{I}(\hat{p} \geq \tau^*) = \begin{cases} 1 & \text{nếu } \hat{p} \geq \tau^* \quad \text{(Bất thường / Anomaly)} \\ 0 & \text{nếu } \hat{p} < \tau^* \quad \text{(Bình thường / Normal)} \end{cases}$$

Để giải quyết bài toán này một cách toàn diện, báo cáo nghiên cứu và so sánh song song hai trường phái: họ mô hình Học máy dựa trên cây quyết định (bao gồm các mô hình Bagging đối chứng: Random Forest, Extra Trees cùng các thuật toán Gradient Boosting chủ lực: XGBoost, LightGBM, CatBoost) kết hợp các kỹ thuật dung hợp mô hình nâng cao; cùng họ mô hình Học sâu chuỗi thời gian (BiGRU, TCN, LSTM-Autoencoder) nhằm khai phá các mối quan hệ phi tuyến và bối cảnh phụ tải phức tạp.

1.2 Mô tả tập dữ liệu

Dữ liệu thực nghiệm của bài toán được cung cấp chính thức thông qua cuộc thi **Large-scale Energy Anomaly Detection (LEAD)** trên nền tảng Kaggle tại liên kết: `https://www.kaggle.com/competitions/energy-anomaly-detection/data`. Bộ dữ liệu này được xây dựng dựa trên nguồn dữ liệu tiêu thụ năng lượng của cuộc thi *ASHRAE - Great Energy Predictor III* và được mở rộng bằng cách gán nhãn bất thường cho các điểm đo

điện theo từng giờ trong suốt năm 2016, thời gian bắt đầu từ 00:00 ngày 01/01/2016 đến 23:00 ngày 31/12/2016, tại nhiều tòa nhà thương mại.

Theo công bố từ ban tổ chức cuộc thi trên nền tảng Kaggle (tổng dung lượng khoảng 1,34 GB với 5 tệp dữ liệu), bộ dữ liệu hoàn chỉnh bao gồm:

- **`train.csv`:** Tệp chuỗi thời gian thô của tập huấn luyện, chỉ chứa các trường đo đếm sơ khai (`building_id`, `timestamp`, `meter_reading`) và nhãn bất thường `anomaly`.
- **`test.csv`:** Tệp chuỗi thời gian thô của tập kiểm tra, không chứa cột nhãn bất thường.
- **`sample_submission.csv`:** Tệp mẫu định dạng nộp kết quả dự đoán (`row_id`, `anomaly`) lên hệ thống chấm điểm trực tuyến của cuộc thi.
- **`test_features.csv`:** Tệp kiểm tra mở rộng gồm 206 tòa nhà độc lập với 1.800.567 bản ghi và 57 thuộc tính đã được ghép nối thông tin công trình và điều kiện thời tiết, nhưng không có cột nhãn mục tiêu `anomaly` (chỉ phục vụ sinh file nộp bài dự thi).
- **`train_features.csv`:** Tệp huấn luyện mở rộng hoàn chỉnh gồm dữ liệu đo đạc của 200 tòa nhà với 1.749.494 bản ghi chuỗi thời gian và 57 thuộc tính tích hợp sẵn mức tiêu thụ điện, đặc tính tòa nhà, điều kiện vi khí hậu, các biến trễ thời gian và nhãn bất thường `anomaly`.

Phạm vi dữ liệu sử dụng trong nghiên cứu: Mặc dù ban tổ chức cuộc thi cung cấp đầy đủ 5 tệp dữ liệu nêu trên, trong toàn bộ nghiên cứu và thực nghiệm của đề tài này, nhóm nghiên cứu **chỉ sử dụng duy nhất một tệp là `train_features.csv`**. Quyết định này được xây dựng trên các cơ sở khoa học sau:

- *Bảo toàn nhãn kiểm chứng khách quan:* Tệp `test_features.csv` là tập dữ liệu ẩn của cuộc thi, hoàn toàn không công bố nhãn `anomaly` nhằm mục đích bảo mật cho bảng xếp hạng trực tuyến. Do đó, để có thể chủ động đánh giá độ chính xác, phân tích ma trận nhầm lẫn (Confusion Matrix), tính toán đường cong Precision-Recall và tối ưu hóa các ngưỡng phân loại động τ^* độc lập, nhóm cần một tập dữ liệu có đầy đủ nhãn chân lý thực nghiệm.
- *Tận dụng các đặc trưng làm giàu chất lượng cao:* So với tệp thô `train.csv`, tệp `train_features.csv` đã được tích hợp sẵn các đặc trưng bối cảnh vật lý công trình và dữ liệu khí tượng chuẩn hóa, cung cấp nền tảng vững chắc để xây dựng các kỹ thuật Feature Engineering chuyên sâu.
- *Train/Test Split:* Toàn bộ 1.749.494 bản ghi của `train_features.csv` được nhóm sử dụng để thực hiện quy trình phân tích khám phá (EDA), tiền xử lý làm sạch, xây dựng bộ đặc trưng không gian khu vực (Zone Features) và phân chia độc lập theo tỷ lệ 80% Train set và 20% Test set bằng phương pháp phân tầng Stratified Split bảo toàn tỷ lệ dị thường. Tập Kiểm tra độc lập này đóng vai trò quyết định để đo lường, đối chứng khách quan hiệu năng giữa tất cả các mô hình Học máy và Học sâu.

1.2.1 Các thuộc tính và nhóm đặc trưng của bộ dữ liệu

Tệp dữ liệu `train_features.csv` bao gồm 57 thuộc tính, kết hợp giữa các thông tin đo lường phụ tải cơ sở và hệ thống đặc trưng đa chiều phong phú phục vụ quá trình mô hình hóa. Chi tiết các thuộc tính cốt lõi và các nhóm đặc trưng bổ sung được tổng hợp tại Bảng 2.

Bảng 2: Tổng hợp hệ thống thuộc tính và nhóm đặc trưng trong tệp `train_features.csv`

Phân nhóm	**Tên thuộc tính / Đại diện**	**Ý nghĩa và Mô tả thực tế**
Thuộc tính cốt lõi	`building_id`	Mã định danh duy nhất của tòa nhà nơi dữ liệu phụ tải được ghi nhận.
	`timestamp`	Mốc thời gian ghi nhận mức tiêu thụ điện (chu kỳ 1 giờ, xuyên suốt năm 2016).
	`meter_reading`	Mức tiêu thụ điện năng thực tế của công trình tại thời điểm tương ứng (kWh).
	`anomaly`	Biến mục tiêu phân loại.
Thông tin công trình	`site_id`, `primary_use`, `square_feet`, `year_built`, `floor_count`	Thông số vật lý công trình: vị trí khu vực, công năng sử dụng, diện tích sàn (sqft), năm xây dựng và số tầng.
Điều kiện thời tiết	`air_temperature`, `dew_temperature`, `cloud_coverage`, `precip_depth_1_hr`, `sea_level_pressure`, `wind_direction`, `wind_speed`	Dữ liệu khí tượng tức thời quan trắc từ các trạm thời tiết (nhiệt độ không khí, điểm sương, độ che phủ mây, lượng mưa, áp suất, hướng và tốc độ gió).
Thời gian & Chu kỳ	`hour`, `weekday`, `month`, `year`, `weekday_hour`, `is_holiday`, `hour_x/y`, `month_x/y`, `weekday_x/y`	Đặc trưng lịch biểu (giờ, thứ, tháng, chỉ báo ngày lễ) và các biến mã hóa chu kỳ lượng giác (sin / cos) mô hình hóa nhịp sinh hoạt ngày/đêm.
Trễ chuỗi thời gian	`air_temperature_mean_lag7/73`, `max_lag7/73`, `min_lag7/73`, `std_lag7/73`	Các đặc trưng thống kê nhiệt độ môi trường qua các cửa sổ quá khứ 7 giờ và 73 giờ ($\approx$ 3 ngày), nắm bắt quán tính nhiệt công trình.
Tương tác tòa nhà	`building_hour`, `building_weekday`, `building_month`, `building_weekday_hour`, `building_meter`	Kết hợp đặc thù vận hành của từng công trình theo từng khung giờ và ngày trong tuần.
Mã hóa mục tiêu (GTE)	16 đặc trưng mang tiền tố `gte_` (`gte_hour`, `gte_building_id`, `gte_primary_use`, `gte_meter`, …)	Nhóm đặc trưng Group Target Encoding: mã hóa tỷ lệ dị thường kỳ vọng theo từng nhóm bối cảnh không gian và thời gian.

Trong đó, thuộc tính `anomaly` đóng vai trò là biến mục tiêu cần dự đoán. Kết quả thống kê trên toàn bộ 1.749.494 bản ghi của tệp dữ liệu cho thấy có 1.712.198 bản ghi thuộc lớp bình thường (`anomaly` = 0) và 37.296 bản ghi thuộc lớp bất thường (`anomaly` = 1). Như vậy, bài toán mang tính chất mất cân bằng nhãn sâu sắc với tỷ lệ dị thường thực tế chỉ chiếm khoảng 2,13%.

Bên cạnh đó, các nhóm đặc trưng bổ sung giúp mô hình nắm bắt toàn diện bối cảnh vật lý công trình, thời tiết khí tượng và nhịp điệu sinh hoạt theo thời gian. Đây là nguồn tín hiệu đầu vào phong phú được nhóm nghiên cứu sàng lọc, chuẩn hóa và tối ưu hóa trong các giai đoạn Tiền xử lý và Xây dựng mô hình ở các chương tiếp theo.

1.2.2 Tình trạng dữ liệu thiếu

Qua quá trình kiểm tra trên tệp `train_features.csv`, thuộc tính `meter_reading` xuất hiện các giá trị bị thiếu với 107.653 bản ghi, tương đương khoảng 6,15% tổng số bản ghi của tập dữ liệu.

Đáng chú ý, việc thiếu giá trị `meter_reading` không đồng nghĩa với việc thiếu bản ghi thời gian. Một số bản ghi vẫn có `timestamp` và các thông tin liên quan đến tòa nhà nhưng không có giá trị tiêu thụ điện tương ứng. Vì vậy, dữ liệu thiếu cần được xem xét và xử lý trong bước tiền xử lý trước khi đưa vào các mô hình Học máy và Học sâu.

Ngoài `meter_reading`, các thuộc tính còn lại trong tệp `train_features.csv` đều đầy đủ và không ghi nhận giá trị thiếu trong suốt quá trình kiểm tra.

2 Tổng quan tài liệu

2.1 Các phương pháp Học máy hiện có để giải quyết bài toán

Do dữ liệu đã có gán nhãn cho biến `anomaly`(0 biểu thị trạng thái bình thường, 1 biểu thị trạng thái bất thường), họ thuật toán dựa trên cây quyết định (Tree-based Models) và phương pháp học tập hợp (Ensemble Learning) thường thể hiện hiệu suất vượt trội.

2.1.1 XGBoost (eXtreme Gradient Boosting)

XGBoost tối ưu hóa hàm mục tiêu bằng phương pháp khai triển Taylor bậc hai, cho phép hội tụ nhanh hơn. Cấu trúc cây được phát triển theo từng tầng. Mô hình cuối cùng là tổng hợp tuần tự của K cây quyết định:

$$\hat{y}_i = \sum_{k=1}^{K} f_k(\mathbf{x}_i), \quad f_k \in \mathcal{F}$$

trong đó $\mathcal{F}$ là không gian của các cây hồi quy CART. Tại mỗi bước lặp t, hàm mục tiêu được tối ưu bằng khai triển Taylor bậc hai:

$$\mathcal{L}^{(t)} \simeq \sum_{i=1}^{n} \left[g_i f_t(\mathbf{x}_i) + \frac{1}{2} h_i f_t^2(\mathbf{x}_i) \right] + \Omega(f_t)$$

với $g_i = \partial_{\hat{y}^{(t-1)}} \ell(y_i, \hat{y}^{(t-1)})$ là gradient bậc nhất, $h_i = \partial^2_{\hat{y}^{(t-1)}} \ell(y_i, \hat{y}^{(t-1)})$ là gradient bậc hai của hàm mất mát và $\Omega(f_t)$ là hàm phạt cấu trúc cây:

$$\Omega(f) = \gamma T + \frac{1}{2}\lambda \sum_{j=1}^{T} w_j^2 + \alpha \sum_{j=1}^{T} |w_j|$$

trong đó T là số lá, w_j là trọng số tại lá j, γ phạt số lượng lá, λ là hệ số điều chuẩn L_2 và α là hệ số điều chuẩn L_1.

Ưu điểm:

- **Hạn chế Overfitting:** Tích hợp các thành phần phạt L_1 (α) và L_2 (λ) trực tiếp vào hàm mục tiêu $\Omega(f)$, giúp hạn chế hiệu quả hiện tượng overfitting khi mô hình tiếp xúc với dữ liệu nhiễu từ các cảm biến đo lường.
- **Xử lý mất cân bằng lớp:** Hỗ trợ điều chỉnh trọng số thông qua siêu tham số `scale_pos_weight`, gán penalty cao hơn cho trường hợp phân loại sai lớp thiểu số.
- **Xử lý giá trị khuyết:** Thuật toán tự học hướng mặc định tại mỗi nút chia cho các giá trị bị khuyết, phù hợp với dữ liệu cảm biến thực tế thường có nhiều giá trị bị thiếu.

Nhược điểm:

- **Độ phức tạp thời gian:** Thuật toán phân nhánh tham lam chính xác đòi hỏi duyệt qua toàn bộ dữ liệu liên tục. Mặc dù đã có các cải tiến như Histogram-based, XGBoost vẫn yêu cầu thời gian tính toán khi xử lý tập dữ liệu có quy mô lớn.
- **Phát triển cây Level-wise:** Chiến lược phát triển theo tầng buộc tất cả các nút ở cùng một độ sâu phải được mở rộng, dẫn đến việc phân chia tại nhiều nút không cần thiết.

2.1.2 LightGBM (Light Gradient Boosting Machine)

LightGBM được thiết kế chuyên biệt để tối ưu hóa hiệu suất trên dữ liệu quy mô lớn thông qua hai kỹ thuật cốt lõi: GOSS (Gradient-based One-Side Sampling) và EFB (Exclusive Feature Bundling). Cây được phát triển theo cơ chế ưu tiên lá.

Kỹ thuật GOSS ước lượng độ lợi thông tin bằng cách giữ lại toàn bộ các mẫu có gradient lớn và lấy mẫu ngẫu nhiên từ các mẫu có gradient nhỏ, sau đó nhân trọng số bù:

$$\widetilde{V}_j(d) = \frac{1}{n}\left(\frac{\left(\sum_{x_i \in A_l} g_i + \frac{1-a}{b}\sum_{x_i \in B_l} g_i\right)^2}{n_l^j(d)} + \frac{\left(\sum_{x_i \in A_r} g_i + \frac{1-a}{b}\sum_{x_i \in B_r} g_i\right)^2}{n_r^j(d)}\right)$$

trong đó A là tập các mẫu có gradient lớn, B là tập mẫu ngẫu nhiên từ các mẫu có gradient nhỏ, l và r ký hiệu nhánh trái và phải tại ngưỡng d của đặc trưng j.

Kỹ thuật EFB gộp các đặc trưng thưa có tính loại trừ lẫn nhau thành các gói, giảm số lượng đặc trưng từ p xuống số lượng gói $p' \ll p$.

Ưu điểm:

- **Hiệu suất tính toán ưu việt:** Kỹ thuật Histogram giúp giảm độ phức tạp thời gian tìm kiếm điểm chia nhánh, mang lại tốc độ huấn luyện nhanh.
- **Xử lý biến định danh trực tiếp:** Khai thác hiệu quả các đặc trưng phân loại xuất hiện nhiều giá trị khác nhau như `site_id`, `primary_use`,... bằng cách phân chia tối ưu trên các danh mục mà không cần mã hóa One-Hot, giúp kiểm soát chiều dữ liệu.

- **Tiết kiệm bộ nhớ:** Kỹ thuật EFB giảm đáng kể số chiều hiệu dụng, trong khi biểu diễn Histogram chỉ lưu trữ các bin rời rạc thay vì toàn bộ giá trị liên tục, giúp tiết kiệm RAM khi xử lý dữ liệu hàng chục triệu dòng.
- **GOSS giữ độ chính xác khi lấy mẫu:** Thay vì lấy mẫu đồng đều, GOSS ưu tiên các mẫu có gradient lớn (đóng góp nhiều nhất vào việc học), nên giảm dữ liệu mà vẫn duy trì chất lượng mô hình.

Nhược điểm:

- **Rủi ro quá khớp cục bộ:** Sự phát triển theo chiều sâu lá có thể dẫn đến việc mô hình học các mẫu nhiễu cục bộ. Cần giới hạn nghiêm ngặt các tham số `max_depth` và `min_data_in_leaf`.
- **Nhạy cảm với dữ liệu không đa dạng:** Chiến lược phát triển cây theo chiều sâu lá tạo ra các cây sâu không cân bằng, dễ overfitting trên các tập dữ liệu nhỏ. Tuy nhiên, hạn chế này ít ảnh hưởng trong bài toán hiện tại do quy mô dữ liệu rất lớn.

2.1.3 CatBoost (Categorical Boosting)

Thuật toán xây dựng các cây quyết định đối xứng và sử dụng cơ chế Ordered Target Encoding. Đặc điểm cốt lõi của CatBoost là sử dụng hoán vị ngẫu nhiên σ để tính giá trị mã hóa cho biến định danh, tránh rò rỉ thông tin mục tiêu:

$$\hat{x}^i_{\sigma_p} = \frac{\sum_{j=1}^{p-1}[x^i_{\sigma_j} = x^i_{\sigma_p}] \cdot y_{\sigma_j} + a \cdot P}{\sum_{j=1}^{p-1}[x^i_{\sigma_j} = x^i_{\sigma_p}] + a}$$

trong đó σ_p là chỉ số của mẫu thứ p trong hoán vị, x^i là giá trị đặc trưng định danh thứ i, y là nhãn mục tiêu, P là giá trị trung bình toàn cục của nhãn và $a > 0$ là tham số Laplace smoothing.

Cây đối xứng sử dụng cùng một điều kiện chia tại tất cả các nút ở cùng một độ sâu, tạo ra cấu trúc cây cân bằng hoàn hảo với 2^d lá (với d là chiều sâu). Việc dự đoán trở thành phép tra bảng $O(d)$.

Ưu điểm:

- **Ngăn chặn rò rỉ dữ liệu:** Ordered Target Encoding tính toán giá trị trung bình mục tiêu dựa trên các mẫu quan sát trong quá khứ nhân tạo theo hoán vị σ, giúp mã hóa các biến định danh một cách an toàn và mạnh mẽ mà không gây rò rỉ thông tin nhãn.
- **Tốc độ suy luận nhanh:** Cấu trúc cây đối xứng cho phép mô hình được biểu diễn dưới dạng các bảng tra cứu với độ phức tạp suy luận $O(d)$, tăng tốc độ dự đoán lên nhiều lần so với các cây không đối xứng.
- **Giảm Bias:** Sử dụng nhiều hoán vị khác nhau trong quá trình huấn luyện, giảm Bias do rò rỉ thông tin trong Gradient Boosting truyền thống, đặc biệt hiệu quả trên dữ liệu có nhiều biến phân loại như `building_id`, `primary_use`.
- **Hạn chế Overfitting:** Cấu trúc cây đối xứng có ít tham số hơn cây tự do (chỉ d điều kiện chia thay vì $2^d - 1$ nút nội), đóng vai trò như một dạng điều chuẩn ngầm.

Nhược điểm:

- **Thời gian huấn luyện lớn:** Quy trình mã hóa Ordered Target Encoding và xây dựng cây đối xứng khiến CatBoost mất nhiều thời gian huấn luyện hơn so với LightGBM, đặc biệt khi bộ dữ liệu chứa lượng lớn các biến liên tục.
- **Khả năng biểu diễn hạn chế:** Ràng buộc cùng một điều kiện chia tại mỗi tầng có thể hạn chế khả năng biểu diễn các mẫu phức tạp, đòi hỏi cây phải sâu hơn để đạt cùng mức chính xác so với cây tự do.

2.1.4 Random Forest

Random Forest là thuật toán học tập hợp Bagging, xây dựng B cây quyết định độc lập trên các tập dữ liệu bootstrap. Mỗi cây được huấn luyện trên tập $\mathcal{D}_b$ được lấy mẫu ngẫu nhiên có hoàn lại từ tập gốc $\mathcal{D}$, với $|\mathcal{D}_b| = |\mathcal{D}| = n$.

Tại mỗi nút phân chia, thay vì xét toàn bộ p đặc trưng, Random Forest chỉ chọn ngẫu nhiên một tập con m đặc trưng và tìm điểm chia tối ưu theo tiêu chí Gini Impurity:

$$\text{Gini}(S) = 1 - \sum_{k=1}^{C} p_k^2$$

trong đó C là số lớp và p_k là tỷ lệ mẫu thuộc lớp k trong tập S. Số đặc trưng được chọn ngẫu nhiên thường là $m = \lfloor \sqrt{p} \rfloor$ cho bài toán phân lớp.

Dự đoán cuối cùng được xác định bằng bỏ phiếu đa số:

$$\hat{y}(\mathbf{x}) = \text{mode}\left\{h_b(\mathbf{x})\right\}_{b=1}^{B}$$

Phương sai của mô hình tập hợp được giới hạn bởi:

$$\text{Var}\left[\hat{y}\right] = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$$

trong đó ρ là hệ số tương quan trung bình giữa các cây và σ^2 là phương sai của mỗi cây đơn lẻ. Việc chọn ngẫu nhiên $m \ll p$ đặc trưng tại mỗi nút giúp giảm ρ, từ đó giảm phương sai tổng thể.

Ưu điểm:

- **Kháng nhiễu và ngoại lai:** Cơ chế trung bình hóa từ hàng trăm cây quyết định độc lập giúp mô hình miễn nhiễm với các giá trị bất thường ngẫu nhiên của cảm biến.
- **Huấn luyện song song:** Các cây hoàn toàn độc lập nên có thể huấn luyện song song trên nhiều lõi CPU, tận dụng hiệu quả kiến trúc đa nhân.
- **Ước lượng lỗi:** Khoảng 37% mẫu không xuất hiện trong mỗi bootstrap có thể được dùng làm tập kiểm tra nội bộ, cung cấp ước lượng lỗi tổng quát hóa mà không cần tập validation riêng.
- **Đo lường tầm quan trọng đặc trưng:** Cung cấp thước đo dựa trên mức giảm tạp chất trung bình hoặc hoán vị, hỗ trợ giải thích mô hình.

Nhược điểm:

- **Độ nhạy thấp với lớp thiểu số:** Thuật toán Bagging hội tụ về phía dự đoán nhãn đa số do mỗi bootstrap chỉ chứa một tỷ lệ nhỏ mẫu lớp thiểu số. Cần kết hợp với kỹ thuật Balanced Random Forest (lấy mẫu phân tầng trong bootstrap) để cải thiện.
- **Kích thước mô hình lớn:** Với số lượng cây lớn, file mô hình có thể lên tới hàng GB trên ổ cứng, gây khó khăn cho việc triển khai và lưu trữ.
- **Không có cơ chế học tuần tự:** Khác với Boosting, mỗi cây không học từ sai sót của cây trước, nên không tập trung sửa lỗi ở vùng dữ liệu khó — điểm yếu quan trọng trong bài toán mất cân bằng.

2.1.5 Extra Trees (Extremely Randomized Trees)

Extra Trees (Extremely Randomized Trees) là một biến thể cực đoan hóa của Random Forest. Khác biệt cốt lõi nằm ở hai điểm: Sử dụng toàn bộ tập huấn luyện $\mathcal{D}$ thay vì lấy mẫu bootstrap và ngẫu nhiên hóa hoàn toàn cả ngưỡng phân chia tại mỗi nút.

Cụ thể, tại mỗi nút, thuật toán chọn ngẫu nhiên K đặc trưng. Với mỗi đặc trưng j được chọn, ngưỡng chia s_j được lấy ngẫu nhiên đồng đều trong khoảng giá trị:

$$s_j \sim \mathcal{U}\left(\min_i x_i^j,\ \max_i x_i^j\right)$$

Sau đó, cặp (j^*, s^*) cho điểm chia tốt nhất được chọn theo tiêu chí Gini hoặc Entropy:

$$(j^*, s^*) = \arg \max_{j \in \{1,\ldots,K\},\ s_j} \text{Gain}(j, s_j)$$

Việc ngẫu nhiên hóa ngưỡng chia khiến hệ số tương quan ρ giữa các cây giảm sâu hơn so với Random Forest, dẫn đến phương sai tổng thể thấp hơn theo công thức $\text{Var}[\hat{y}] = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$.

Ưu điểm:

- **Tốc độ huấn luyện nhanh hơn Random Forest:** Không cần tìm kiếm ngưỡng chia tối ưu cho mỗi đặc trưng, giúp giảm đáng kể chi phí tính toán tại mỗi nút từ $O(n \log n)$ xuống $O(n)$.
- **Kháng overfitting tốt hơn Random Forest:** Ngưỡng chia ngẫu nhiên ngăn cây học quá sát các mẫu nhiễu cục bộ. Sử dụng toàn bộ dữ liệu giúp mỗi cây có cái nhìn đầy đủ hơn về phân phối dữ liệu, giảm bias.
- **Hoạt động tốt trên dữ liệu nhiễu cao:** Đặc tính ngẫu nhiên hóa cực đoan giúp Extra Trees miễn nhiễm tốt với nhiễu cảm biến, phù hợp với bản chất dữ liệu đo lường năng lượng.

Nhược điểm:

- **Bias cao hơn Random Forest:** Ngưỡng chia ngẫu nhiên thay vì tối ưu có thể tạo ra các phân vùng kém chính xác hơn, khiến mỗi cây đơn lẻ có sai số bias cao hơn.

- **Không nhạy cảm với đặc trưng quan trọng:** Do không tìm kiếm ngưỡng tối ưu, thuật toán khó phân biệt giữa các đặc trưng hữu ích và đặc trưng nhiễu, đặc biệt khi tập đặc trưng có chiều cao.
- **Cùng hạn chế Bagging với lớp thiểu số:** Tương tự Random Forest, Extra Trees không có cơ chế tập trung vào các mẫu khó của lớp thiểu số, kém hiệu quả hơn Boosting trong bài toán mất cân bằng nghiêm trọng.

2.1.6 Tổng hợp so sánh các thuật toán Học máy

Thuật toán	Cơ chế học	Xử lý biến danh mục	Tốc độ & Bộ nhớ	Xử lý mất cân bằng	Phù hợp LEAD
XGBoost	Boosting (Level-wise)	Cần mã hóa trước (Ordinal / One-Hot)	Trung bình, yêu cầu bộ nhớ RAM	Tốt (`scale_pos_weight`)	Rất cao
LightGBM	Boosting (Leaf-wise)	Tự động phân chia tối ưu danh mục	Rất nhanh, tối ưu nhờ Histogram	Xuất sắc (trọng số mẫu và lớp)	Xuất sắc (ưu tiên cao nhất)
CatBoost	Boosting (Symmetric Tree)	Ordered Target Encoding chống rò rỉ	Huấn luyện lâu hơn, suy luận cực nhanh $O(d)$	Rất tốt (`auto_class_weights`)	Rất cao (mạnh với biến phân loại)
Random Forest	Bagging (Bootstrap)	Cần mã hóa trước	Rất chậm trên 1,75M dòng, file mô hình lớn	Kém (dễ thiên lệch về lớp đa số)	Trung bình (nặng tài nguyên)
Extra Trees	Bagging (Random Splits)	Cần mã hóa trước	Nhanh hơn RF, giảm phương sai tốt	Kém (dễ thiên lệch về lớp đa số)	Thấp đến trung bình

Cột "Phù hợp LEAD" là đánh giá tổng hợp của nhóm dựa trên các tiêu chí: tốc độ xử lý trên quy mô 1,75 triệu dòng, khả năng khai thác các đặc trưng định danh công trình (`building_id`, `primary_use`), cơ chế phạt mẫu dị thường và độ linh hoạt khi tinh chỉnh ngưỡng phân loại tối ưu. Đánh giá này sẽ được kiểm chứng bằng thực nghiệm ở phần triển khai.

2.2 Các phương pháp Học sâu hiện có để giải quyết bài toán

Khác với các mô hình Học máy ở phần trước vốn xử lý từng dòng dữ liệu một cách độc lập, các phương pháp Học sâu cho chuỗi thời gian khai thác trực tiếp thứ tự và phụ thuộc thời gian giữa các quan trắc. Dựa trên khảo sát sơ bộ của nhóm trên tệp `train_features.csv`, dữ liệu có các đặc thù sau:

- **Cấu trúc chuỗi:** gồm 200 toà nhà, mỗi toà là một chuỗi đo theo giờ trong năm 2016, tổng cộng khoảng 1,75 triệu quan trắc. Một số toà nhà thiếu một số mốc giờ và giá trị `meter_reading` có phần bị khuyết.

- **Nhãn theo từng thời điểm:** biến `anomaly` được gán cho từng giờ (point-wise), với tỷ lệ bất thường chỉ khoảng 2,1% nên bài toán mất cân bằng lớp nghiêm trọng.
- **Bất thường không đồng nhất:** trong tập kiểm định (từ 01/10/2016), khoảng 44% điểm bất thường có `meter_reading` đúng bằng 1,0. Trên toàn bộ dữ liệu huấn luyện, khoảng 58% điểm bất thường nằm trong một đoạn giá trị lặp lại liên tiếp có độ dài từ 3 giờ trở lên (so với khoảng 3,3% ở điểm bình thường). Phần bất thường còn lại có giá trị nằm trong vùng tiêu thụ thông thường, nên chỉ có thể nhận diện dựa trên ngữ cảnh thời gian. Nguyên nhân sinh ra các giá trị đặc biệt này chưa được nhóm kiểm chứng.

Các đặc thù trên cho thấy một mô hình xét từng điểm riêng lẻ có thể bắt tốt nhóm bất thường có giá trị đặc biệt nhưng khó nhận diện nhóm bất thường phụ thuộc ngữ cảnh. Đây là động lực để khảo sát các phương pháp Học sâu.

2.2.1 Biểu diễn bài toán và ba hệ hình tiếp cận

Với mỗi toà nhà, tại thời điểm t ta xây dựng cửa sổ trượt gồm w quan trắc gần nhất:

$$\mathbf{X}_t = (\mathbf{x}_{t-w+1}, \ldots, \mathbf{x}_t) \in \mathbb{R}^{w \times d}$$

trong đó $\mathbf{x}_i \in \mathbb{R}^d$ gồm giá trị đo `meter_reading`, các biến thời tiết, mã hoá chu kỳ của thời gian và các đặc trưng bổ sung. Nhãn tại thời điểm t là $y_t \in \{0, 1\}$. Các phương pháp Học sâu hiện có thuộc ba hệ hình chính:

1. **Tái tạo (Reconstruction-based):** mô hình học cách tái tạo lại hành vi bình thường, điểm bất thường là sai số tái tạo:
$$a_t = \|\mathbf{x}_t - \hat{\mathbf{x}}_t\|_2^2$$
2. **Dự báo (Prediction-based):** mô hình dự báo giá trị kế tiếp từ quá khứ, điểm bất thường là sai số dự báo:
$$a_t = |x_{t+1} - \hat{x}_{t+1}|$$
3. **Gán nhãn chuỗi có giám sát (Supervised sequence labelling):** mô hình học trực tiếp xác suất bất thường từ nhãn có sẵn:
$$\hat{p}_t = P\left(y_t = 1 \mid \mathbf{X}_t\right)$$

Hai hệ hình đầu thường được dùng khi không có nhãn và chỉ được huấn luyện trên dữ liệu bình thường. Hệ hình thứ ba tận dụng được nhãn `anomaly` đã có của bộ dữ liệu LEAD. Phần dưới trình bày ưu nhược điểm của từng họ mô hình theo các hệ hình này.

2.2.2 Nhóm Mạng Hồi quy (Recurrent Neural Networks)

Mạng hồi quy xử lý chuỗi tuần tự, duy trì trạng thái ẩn $\mathbf{h}_t$ tổng hợp thông tin từ quá khứ. Nhóm này dùng được cho cả ba hệ hình: làm bộ gán nhãn chuỗi, làm bộ dự báo (Malhotra et al., 2015) hoặc làm bộ mã hoá–giải mã.

2.2.2.1 LSTM (Long Short-Term Memory)

LSTM đưa vào trạng thái ô nhớ $\mathbf{c}_t$ cùng ba cổng điều khiển luồng thông tin (Hochreiter & Schmidhuber, 1997):

$$\mathbf{f}_t = \sigma\left(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f\right), \quad \mathbf{i}_t = \sigma\left(\mathbf{W}_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i\right), \quad \mathbf{o}_t = \sigma\left(\mathbf{W}_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o\right)$$
$$\tilde{\mathbf{c}}_t = \tanh\left(\mathbf{W}_c[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c\right), \quad \mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t, \quad \mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t)$$

trong đó $\mathbf{f}_t$, $\mathbf{i}_t$, $\mathbf{o}_t$ lần lượt là cổng quên, cổng vào và cổng ra, σ là hàm sigmoid và $\odot$ là phép nhân từng phần tử.

Ưu điểm:

- **Học phụ thuộc dài hạn:** đường truyền gradient qua ô nhớ $\mathbf{c}_t$ giảm hiện tượng triệt tiêu gradient, phù hợp với chu kỳ ngày (24 giờ) và chu kỳ tuần (168 giờ) của dữ liệu tiêu thụ điện.
- **Linh hoạt về đầu ra:** cùng một kiến trúc có thể dùng để gán nhãn từng bước, dự báo bước kế tiếp hoặc làm bộ mã hoá trong tự mã hoá.
- **Tận dụng nhiều đặc trưng đồng thời:** đầu vào tại mỗi bước có thể gồm giá trị đo, thời tiết và mã hoá thời gian, trong khi nhiều mô hình tái tạo trên LEAD chỉ dùng chuỗi `meter_reading` đơn biến.

Nhược điểm:

- **Tính toán tuần tự:** mỗi bước phụ thuộc bước trước nên khó song song hoá theo trục thời gian, thời gian huấn luyện lâu hơn mạng tích chập trên cùng độ dài chuỗi.
- **Nhạy với độ dài cửa sổ và siêu tham số:** chất lượng phụ thuộc vào w, số tầng, số đơn vị ẩn và cách khởi tạo trạng thái ở đầu cửa sổ.
- **Không tự có cơ chế xử lý mất cân bằng:** cần kết hợp hàm mất mát có trọng số hoặc focal loss, nếu không mô hình hội tụ về dự đoán lớp đa số.

2.2.2.2 GRU (Gated Recurrent Unit)

GRU rút gọn LSTM bằng hai cổng (cập nhật $\mathbf{z}_t$ và đặt lại $\mathbf{r}_t$), không có ô nhớ riêng (Cho et al., 2014):

$$\mathbf{z}_t = \sigma\left(\mathbf{W}_z[\mathbf{h}_{t-1}, \mathbf{x}_t]\right), \quad \mathbf{r}_t = \sigma\left(\mathbf{W}_r[\mathbf{h}_{t-1}, \mathbf{x}_t]\right)$$
$$\tilde{\mathbf{h}}_t = \tanh\left(\mathbf{W}[\mathbf{r}_t \odot \mathbf{h}_{t-1}, \mathbf{x}_t]\right), \quad \mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t$$

Ưu điểm:

- **Ít tham số hơn LSTM:** chỉ có hai cổng và không có ô nhớ riêng, nên huấn luyện nhanh hơn và dùng ít bộ nhớ GPU hơn, hữu ích với hàng triệu bước thời gian.
- **Chất lượng thường tương đương LSTM:** trên nhiều bài toán chuỗi hai kiến trúc cho kết quả gần nhau, nên GRU là lựa chọn mặc định kinh tế khi cần khảo sát nhiều cấu hình.

Nhược điểm:

- **Biểu diễn kém linh hoạt hơn LSTM:** không có ô nhớ tách biệt, có thể kém hơn khi cần nhớ rất lâu trên chuỗi dài.
- **Cùng hạn chế tuần tự của họ RNN:** không song song hoá được theo thời gian.

2.2.2.3 BiLSTM / BiGRU (Mạng hồi quy hai chiều)

Mạng hai chiều chạy hai mạng hồi quy ngược chiều nhau và ghép trạng thái ẩn (Schuster & Paliwal, 1997):

$$\mathbf{h}_t = \left[\overrightarrow{\mathbf{h}}_t; \overleftarrow{\mathbf{h}}_t\right], \qquad \hat{p}_t = \sigma\left(\mathbf{w}^\top \mathbf{h}_t + b\right)$$

Với bài toán gán nhãn từng giờ, $\hat{p}_t$ được tính tại mọi bước trong một đoạn chuỗi, nên một lần chạy cho ra nhãn của cả đoạn.

Ưu điểm:

- **Khai thác ngữ cảnh cả hai phía:** thời điểm t được đánh giá dựa trên cả quá khứ lẫn tương lai gần, phù hợp với bất thường dạng đoạn liên tục (ví dụ giá trị bị kẹt trong nhiều giờ) vì mô hình biết đoạn đó kéo dài bao lâu.
- **Huấn luyện có giám sát trên toàn đoạn:** một đoạn dài cho nhiều nhãn cùng lúc, giảm lượng tính toán dư thừa so với cửa sổ trượt bước 1.

Nhược điểm:

- **Không dùng được cho cảnh báo thời gian thực:** mô hình cần dữ liệu tương lai nên chỉ phù hợp phát hiện bất thường ngoại tuyến (offline). Điều này phải được nêu rõ khi báo cáo kết quả.
- **Chi phí gấp đôi:** hai chiều nhân đôi số phép tính và tham số so với mạng một chiều.

2.2.3 Nhóm Mạng Tích chập thời gian (Temporal Convolutional Networks)

2.2.3.1 TCN (Temporal Convolutional Network)

TCN dùng tích chập nhân quả giãn nở (causal dilated convolution) kết hợp khối dư (residual block) để xử lý chuỗi (Bai et al., 2018). Tích chập nhân quả đảm bảo đầu ra tại t chỉ phụ thuộc đầu vào từ t trở về trước, và giãn nở cho phép tăng vùng nhìn mà không tăng số tham số:

$$(F *_d \mathbf{x})(t) = \sum_{i=0}^{k-1} f(i) \cdot \mathbf{x}_{t-d\cdot i}$$

trong đó k là kích thước nhân, f là bộ lọc và d là hệ số giãn nở. Khi xếp L khối dư, mỗi khối gồm hai tích chập với hệ số giãn nở $d = 2^l$ $(l = 0, \ldots, L-1)$, vùng nhìn (receptive field) của mạng là:

$$R = 1 + 2(k-1)\left(2^L - 1\right)$$

Ví dụ với $k = 3$ và $L = 6$ thì $R = 253$ giờ, đủ phủ chu kỳ tuần (168 giờ).

Ưu điểm:

- **Song song hoá hoàn toàn theo thời gian:** các tích chập tính đồng thời trên toàn chuỗi nên huấn luyện nhanh trên GPU, phù hợp với khối lượng khoảng 1,75 triệu bước thời gian.
- **Điều khiển vùng nhìn chính xác:** có thể chọn k và L để vùng nhìn phủ đúng chu kỳ ngày, chu kỳ tuần mong muốn, và công thức trên cho phép kiểm tra trước khi huấn luyện.

- **Huấn luyện ổn định:** gradient đi theo cấu trúc cây tích chập thay vì chuỗi tuần tự, ít gặp triệt tiêu gradient hơn RNN. Nghiên cứu của Bai et al. (2018) ghi nhận một kiến trúc tích chập đơn giản vượt LSTM trên nhiều bài toán chuỗi chuẩn, đồng thời có bộ nhớ hiệu dụng dài hơn.
- **Có biến thể không nhân quả:** thay phần đệm nhân quả bằng đệm đối xứng sẽ cho ngữ cảnh hai phía như BiLSTM, tiện cho thí nghiệm so sánh.

Nhược điểm:

- **Vùng nhìn cố định:** sự kiện nằm ngoài R giờ không ảnh hưởng đến dự đoán, trong khi RNN về lý thuyết có thể mang thông tin xa hơn.
- **Bộ nhớ khi suy luận cho chuỗi dài:** cần lưu kích hoạt trung gian của R bước gần nhất hoặc tính lại cả cửa sổ cho mỗi dự đoán.
- **Phụ thuộc kiểu đệm ở biên:** đầu mỗi đoạn có ít ngữ cảnh hơn nên cần chồng lấp giữa các đoạn khi suy luận.

2.2.4 Nhóm Tự mã hoá (Autoencoder-based)

Nhóm này được huấn luyện chỉ trên dữ liệu bình thường (hoặc dữ liệu được coi là bình thường), không dùng nhãn trong quá trình học. Mô hình học nén rồi tái tạo hành vi bình thường, nên đoạn nào tái tạo kém được coi là bất thường.

2.2.4.1 LSTM Autoencoder (EncDec-AD)

Mô hình gồm bộ mã hoá LSTM nén cửa sổ $\mathbf{X}$ thành vector tiềm ẩn $\mathbf{z}$ và bộ giải mã LSTM tái tạo lại cửa sổ (Malhotra et al., 2016):

$$\mathbf{z} = E_\phi(\mathbf{X}), \quad \hat{\mathbf{X}} = D_\theta(\mathbf{z}), \quad \mathcal{L} = \frac{1}{w}\sum_{i=1}^{w} \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|_2^2$$

Vector sai số tái tạo $\mathbf{e}_t$ được mô hình hoá bằng phân phối Gaussian ước lượng trên dữ liệu bình thường kiểm định, điểm bất thường là khoảng cách Mahalanobis:

$$a_t = (\mathbf{e}_t - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{e}_t - \boldsymbol{\mu})$$

Với chuỗi đơn biến ($d = 1$), điểm này rút gọn thành sai số bình phương đã chuẩn hoá.

Ưu điểm:

- **Không cần nhãn khi huấn luyện:** phù hợp với thực tế thiếu nhãn trong giám sát năng lượng, và có thể dùng cho các toà nhà mới chưa được gán nhãn.
- **Bắt tốt bất thường làm gãy mẫu hình tuần hoàn:** bất thường khác biệt rõ so với dạng ngày/tuần bình thường sẽ có sai số tái tạo lớn.
- **Tạo được điểm số liên tục:** có thể đưa sai số tái tạo vào mô hình Học máy làm đặc trưng bổ sung (tương tự vai trò của điểm Isolation Forest ở phần Học máy).

Nhược điểm:

- **Bỏ phí nhãn sẵn có:** khi bộ dữ liệu đã có nhãn, huấn luyện không giám sát thường kém mô hình có giám sát cùng ngân sách tính toán.
- **Rủi ro bỏ sót bất thường dạng "phẳng":** một đoạn giá trị không đổi (flatline) là chuỗi rất dễ tái tạo, nên sai số có thể thấp dù đoạn đó bị gán nhãn bất thường. Đây là giả thuyết nhóm sẽ kiểm chứng bằng thực nghiệm, và phù hợp với nhận xét của Orvati Nia et al. (2026) rằng mô hình tái tạo có thể bỏ lỡ lệch nhẹ không làm thay đổi đáng kể sai số theo điểm.
- **Cần chọn ngưỡng:** ngưỡng phải ước lượng trên tập kiểm định và dễ lệch giữa các toà nhà có thang đo khác nhau.
- **Nhạy với nhiễu trong tập "bình thường":** nếu dữ liệu huấn luyện lẫn bất thường chưa được gán nhãn, mô hình học luôn cả bất thường.

2.2.4.2 Autoencoder tích chập (Conv-AE) và Variational Autoencoder (VAE)

Conv-AE thay LSTM bằng tích chập một chiều để nén cửa sổ. VAE thêm ràng buộc xác suất lên không gian tiềm ẩn, tối ưu cận dưới bằng chứng (ELBO) (Kingma & Welling, 2014):

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}\left[\log p_\theta(\mathbf{x} \mid \mathbf{z})\right] - \beta\, D_{\text{KL}}\left(q_\phi(\mathbf{z} \mid \mathbf{x}) \,\|\, p(\mathbf{z})\right)$$

Handigol & Arjunan (2025) đã huấn luyện 1D-CNN Autoencoder và Convolutional VAE trên LEAD.

Ưu điểm:

- **Nhẹ và huấn luyện nhanh:** tích chập song song hoá tốt, phù hợp làm baseline tái tạo rẻ.
- **VAE có thành phần xác suất:** giảm nguy cơ "học thuộc lòng" đầu vào và cho phép dùng điểm xác suất tái tạo.

Nhược điểm:

- **Cùng hạn chế sai số tái tạo như EncDec-AD:** chất lượng phân tách phụ thuộc việc bất thường có làm tăng sai số tái tạo hay không.
- **Hiệu năng báo cáo thấp hơn mô hình sinh đối kháng:** trong cùng so sánh trên LEAD, Orvati Nia et al. (2026) ghi nhận VAE đạt F1 0,62 và LSTM-AE đạt 0,60 ở mức cửa sổ, thấp hơn TAnoGAN (0,67) và GAN-LSTM (0,89).
- **VAE thêm siêu tham số β:** cần cân bằng giữa chất lượng tái tạo và điều chuẩn không gian tiềm ẩn.

2.2.4.3 USAD (UnSupervised Anomaly Detection)

USAD dùng một bộ mã hoá chung và hai bộ giải mã D_1, D_2, huấn luyện đối kháng theo hai pha để vừa ổn định vừa khuếch đại sai số của đầu vào bất thường (Audibert et al., 2020). Với $AE_1 = D_1 \circ E$, $AE_2 = D_2 \circ E$ và n là chỉ số epoch hiện tại:

$$\mathcal{L}_{AE_1} = \frac{1}{n} \left\| \mathbf{W} - AE_1(\mathbf{W}) \right\|_2 + \left(1 - \frac{1}{n}\right) \left\| \mathbf{W} - AE_2\left(AE_1(\mathbf{W})\right) \right\|_2$$

$$\mathcal{L}_{AE_2} = \frac{1}{n} \left\| \mathbf{W} - AE_2(\mathbf{W}) \right\|_2 - \left(1 - \frac{1}{n}\right) \left\| \mathbf{W} - AE_2\left(AE_1(\mathbf{W})\right) \right\|_2$$

Điểm bất thường là tổ hợp tuyến tính $\alpha \left\| \mathbf{W} - AE_1(\mathbf{W}) \right\| + \beta \left\| \mathbf{W} - AE_2(AE_1(\mathbf{W})) \right\|$ với $\alpha + \beta = 1$.

Ưu điểm:

- **Huấn luyện nhanh và ổn định hơn GAN:** chỉ gồm các mạng tự mã hoá, không cần tối ưu tiềm ẩn khi suy luận như các mô hình GAN dựa trên đảo ánh xạ.
- **Phù hợp dữ liệu lớn:** thiết kế hướng đến yêu cầu về tốc độ huấn luyện và độ bền vững trong môi trường công nghiệp.

Nhược điểm:

- **Thiết kế cho chuỗi đa biến trong hệ thống IT/công nghiệp:** chưa có đánh giá công bố trên dữ liệu năng lượng toà nhà mà nhóm biết, nên hiệu quả trên LEAD cần kiểm chứng.
- **Vẫn là hệ hình tái tạo không giám sát:** chịu cùng rủi ro bỏ sót bất thường phẳng và không dùng nhãn.

2.2.5 Nhóm Mô hình sinh đối kháng (GAN-based)

2.2.5.1 AnoGAN, TAnoGAN và GAN-LSTM

Mạng sinh đối kháng (GAN) gồm bộ sinh G và bộ phân biệt D chơi trò chơi minimax. Sau khi huấn luyện trên dữ liệu bình thường, bộ sinh học được phân phối của hành vi bình thường:

$$\min_G \max_D \; \mathbb{E}_{\mathbf{x}} \left[\log D(\mathbf{x}) \right] + \mathbb{E}_{\mathbf{z}} \left[\log \left(1 - D(G(\mathbf{z})) \right) \right]$$

Vì GAN không có bộ mã hoá, khi phát hiện bất thường phải tìm vector tiềm ẩn $\mathbf{z}^*$ tái tạo tốt nhất cửa sổ cần kiểm tra (Schlegl et al., 2017; Bashar & Nayak, 2020). Orvati Nia et al. (2026) dùng:

$$\mathbf{z}^* = \arg\min_{\mathbf{z}} \; (1 - \lambda) \left\| \mathbf{x} - G(\mathbf{z}) \right\|_1 + \lambda \left\| f_D(\mathbf{x}) - f_D(G(\mathbf{z})) \right\|_1$$

với $f_D(\cdot)$ là đặc trưng trung gian của bộ phân biệt và $\lambda = 0{,}1$. Điểm bất thường $S(\mathbf{x})$ là giá trị hàm mục tiêu tại $\mathbf{z}^*$. GAN-LSTM thay các tầng của G và D bằng LSTM; bộ sinh nhận vector tiềm ẩn 100 chiều qua ba tầng LSTM, bộ phân biệt dùng một tầng LSTM.

Trên dữ liệu năng lượng, các biến thể này đã được áp dụng trong ba nghiên cứu: Prabhu et al. (2024) dùng 1D-DCGAN với hàm mất mát Soft-DTW và tái tạo song song, thử nghiệm trên 15 toà nhà; Handigol & Arjunan (2025) báo cáo DCGAN đạt F1 0,697,

cao nhất trong số các phương pháp họ so sánh trên 200 toà nhà; Orvati Nia et al. (2026) báo cáo GAN-LSTM đạt F1 0,89 với cửa sổ 60 giờ.

Ưu điểm:

- **Mô hình hoá phân phối của hành vi bình thường:** không chỉ tái tạo mà còn học sinh ra chuỗi giống thật, nên bắt được lệch tinh tế hơn mô hình tái tạo thuần tuý theo báo cáo trên LEAD.
- **Điểm bất thường kết hợp sai số tái tạo và đặc trưng bộ phân biệt:** hai tín hiệu bổ sung cho nhau.
- **Có kết quả công bố trực tiếp trên LEAD:** thuận lợi cho phần đối chiếu và mở rộng của đề tài.

Nhược điểm:

- **Chi phí suy luận rất lớn:** mỗi cửa sổ cần một vòng tối ưu vector tiềm ẩn. Orvati Nia et al. (2026) dùng 300 bước tối ưu mỗi cửa sổ, nên việc chấm điểm từng giờ trên 1,75 triệu bước là không thực tế, mà chỉ khả thi khi chấm điểm theo cửa sổ không chồng lấp.
- **Huấn luyện bất ổn định:** cân bằng giữa G và D khó duy trì, kết quả nhạy với khởi tạo và siêu tham số (Orvati Nia et al. phải theo dõi độ chính xác của bộ phân biệt để kiểm tra ổn định).
- **Không dùng nhãn và chỉ dùng chuỗi đơn biến:** các nghiên cứu trên LEAD huấn luyện chỉ trên cửa sổ bình thường và không đưa thời tiết hay đặc trưng toà nhà vào.
- **Kết quả không so sánh trực tiếp được:** F1 0,89 được tính ở mức cửa sổ 60 giờ (một cửa sổ bị coi là bất thường nếu có ít nhất một giờ bất thường), dễ hơn nhiều so với đánh giá theo từng giờ. Vì vậy con số này không thể đặt cạnh F1 theo từng điểm của các mô hình trong đề tài.

2.2.6 Nhóm Transformer

2.2.6.1 Transformer Encoder, Anomaly Transformer và TranAD

Transformer dùng cơ chế tự chú ý (self-attention) để mọi vị trí trong cửa sổ liên hệ trực tiếp với nhau (Vaswani et al., 2017):

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right)\mathbf{V}$$

Chi phí tính toán của một tầng chú ý là $\mathcal{O}(w^2 d)$ theo độ dài cửa sổ w. Anomaly Transformer đề xuất tiêu chí *Association Discrepancy*: do bất thường hiếm nên khó xây dựng liên kết mạnh với toàn chuỗi và liên kết của nó tập trung vào các điểm lân cận, vì vậy sự khác biệt giữa liên kết tiên nghiệm và liên kết chuỗi được dùng để phân biệt bất thường (Xu et al., 2022). TranAD dùng bộ mã hoá chú ý với tự điều kiện hoá theo điểm tập trung (focus score), huấn luyện đối kháng và học meta (MAML) để huấn luyện được với dữ liệu hạn chế (Tuli et al., 2022).

Ưu điểm:

- **Mô hình hoá quan hệ xa không phụ thuộc khoảng cách:** bất kỳ hai giờ nào trong cửa sổ cũng liên hệ trực tiếp, phù hợp chu kỳ ngày/tuần.
- **Song song hoá theo thời gian:** không có phụ thuộc tuần tự như RNN.
- **Có kết quả mạnh trên các bộ chuẩn không giám sát:** Anomaly Transformer đạt kết quả tốt nhất trên sáu bộ chuẩn theo bài báo gốc; TranAD báo cáo tăng F1 tối đa 17% và giảm thời gian huấn luyện tối đa 99% so với các phương pháp đối sánh.

Nhược điểm:

- **Cần nhiều dữ liệu và dễ quá khớp:** đề tài chỉ có 200 chuỗi toà nhà, với dung lượng mô hình lớn thì rủi ro quá khớp cao hơn mạng hồi quy hoặc tích chập nhỏ.
- **Chi phí bậc hai theo độ dài cửa sổ:** với $w = 168$ vẫn chấp nhận được nhưng tăng nhanh khi muốn nhìn xa hơn.
- **Thiết kế và đánh giá cho chuỗi đa biến không giám sát:** không tận dụng nhãn; bài báo Anomaly Transformer (theo mã nguồn công bố) dùng quy tắc điều chỉnh kết quả theo đoạn (adjustment) khi đánh giá, vốn có thể làm điểm số cao hơn so với đánh giá theo từng điểm. Nhóm không áp dụng quy tắc này nên không thể so sánh trực tiếp con số của các bài báo đó.
- **Chưa có đánh giá trên dữ liệu năng lượng LEAD:** hiệu quả cần kiểm chứng.

2.2.7 Kỹ thuật huấn luyện trên dữ liệu mất cân bằng

Với tỷ lệ bất thường khoảng 2,1%, mô hình Học sâu có giám sát cần hàm mất mát phù hợp. Có hai lựa chọn chính.

2.2.7.1 Binary Cross-Entropy có trọng số lớp

$$\mathcal{L}_{\text{WBCE}} = -\frac{1}{N}\sum_{i=1}^{N}\left[w_+\, y_i \log \hat{p}_i + (1-y_i)\log\left(1-\hat{p}_i\right)\right], \qquad w_+ \approx \frac{N_-}{N_+} \approx 45$$

Ưu điểm: đơn giản, một siêu tham số w_+ và tương ứng trực tiếp với `scale_pos_weight` đã dùng ở phần Học máy. **Nhược điểm:** đặt w_+ bằng đúng tỷ lệ lớp có thể làm xác suất đầu ra lệch mạnh về phía lớp 1, nên ngưỡng quyết định phải được tối ưu lại và độ tin cậy xác suất giảm.

2.2.7.2 Focal Loss

Focal loss giảm trọng số của các mẫu dễ phân loại để tập trung vào mẫu khó (Lin et al., 2017):

$$\text{FL}(p_t) = -\alpha_t\left(1-p_t\right)^{\gamma}\log\left(p_t\right)$$

trong đó p_t là xác suất mô hình gán cho lớp đúng, $\gamma \geq 0$ là hệ số tập trung và α_t là trọng số lớp.

Ưu điểm: hàng triệu điểm bình thường dễ phân loại sẽ không chi phối gradient, phù hợp khi bất thường có hai loại dễ và khó. **Nhược điểm:** thêm hai siêu tham số (α, γ) cần tinh chỉnh và xác suất đầu ra cũng cần hiệu chỉnh lại.

2.2.8 Các nghiên cứu liên quan trên chính bộ dữ liệu LEAD

Bảng dưới tóm tắt các nghiên cứu sử dụng LEAD mà nhóm đã tham khảo, kèm lưu ý về khả năng so sánh. Các con số là do chính tác giả bài báo báo cáo; nhóm không tự chạy lại.

- **LEAD1.0 (Gulati & Arjunan, 2022):** công bố phiên bản được gán nhãn của bộ dữ liệu ASHRAE Great Energy Predictor III gồm 1,413 chuỗi từ công tơ điện thông minh, kéo dài hơn một năm, và đối sánh tám phương pháp phát hiện bất thường hiện đại. Đây là mốc tham chiếu gốc của bộ dữ liệu.
- **GAN-LSTM (Orvati Nia et al., 2026):** dùng cửa sổ 60 giờ trên chuỗi tiêu thụ đơn biến, huấn luyện chỉ trên cửa sổ bình thường, đánh giá ở mức cửa sổ trên 206 toà nhà giữ lại; F1 0,89, so với Isolation Forest 0,52, One-Class SVM 0,56, LSTM-AE 0,60, Attention LSTM-AE 0,64, VAE 0,62 và TAnoGAN 0,67. Các giá trị này theo mức cửa sổ, không so sánh trực tiếp với đánh giá theo từng giờ.
- **DCGAN, Conv-AE, Conv-VAE (Handigol & Arjunan, 2025):** khảo sát học sâu không giám sát trên 200 toà nhà, so với Isolation Forest và LOF; kết luận học sâu tốt hơn các phương pháp không giám sát truyền thống ở bất thường dạng chuỗi, DCGAN đạt F1 0,697.
- **1D-DCGAN với Soft-DTW (Prabhu et al., 2024):** đề xuất hàm mất mát Soft-DTW cho tái tạo và tính toán song song nhiều điểm để tăng tốc phát hiện; thử nghiệm trên 15 toà nhà, mỗi toà một mô hình riêng.
- **Phân cụm toà nhà rồi huấn luyện riêng (Cansever & Konyar, 2026):** phân cụm toà nhà theo kiểu tiêu thụ bằng K-means rồi phát hiện bất thường độc lập trong từng cụm, bằng các mô hình Isolation Forest, LOF, XGBoost, Random Forest và LightGBM; mô hình huấn luyện trên các toà nhà có mẫu tiêu thụ tương tự cải thiện đáng kể so với mô hình toàn cục. Ý tưởng này chưa được áp dụng cho mô hình Học sâu, nên là hướng mở rộng của nhóm.

Các nghiên cứu trên khác nhau về tập toà nhà (15, 200 hoặc 406 toà), về đơn vị đánh giá (cửa sổ hoặc từng giờ) và về việc có dùng nhãn hay không. Vì vậy nhóm sẽ dùng chúng làm cơ sở ý tưởng chứ không đặt trực tiếp kết quả cạnh nhau. Ngoài ra, bảng đánh giá của Schmidl et al. (2022) trên 71 thuật toán và 976 tập chuỗi thời gian cho thấy việc chọn thuật toán phụ thuộc mạnh vào từng bài toán, nên cần đối chiếu thực nghiệm thay vì dựa vào kết quả công bố ở bộ dữ liệu khác.

2.2.9 Tổng hợp so sánh các họ mô hình Học sâu

Họ mô hình	**Hệ hình**	**Dùng nhãn**	**Ngữ cảnh thời gian**	**Chi phí**	**Phù hợp LEAD**
BiLSTM / Bi-GRU	Gán nhãn chuỗi	Có	Hai phía, dài	Trung bình	Cao (offline)
TCN	Gán nhãn chuỗi	Có	Cố định theo R	Thấp	Cao
LSTM-AE (EncDec-AD)	Tái tạo	Không	Trong cửa sổ	Trung bình	Trung bình
Conv-AE / VAE	Tái tạo	Không	Trong cửa sổ	Thấp	Thấp đến trung bình
USAD	Tái tạo đối kháng	Không	Trong cửa sổ	Thấp	Chưa rõ
GAN-LSTM / TAnoGAN	Sinh đối kháng	Không	Trong cửa sổ	Rất cao khi suy luận	Trung bình (mở rộng)
Transformer / TranAD	Tái tạo hoặc gán nhãn	Tuỳ biến thể	Toàn cửa sổ	Bậc hai theo w	Thấp đến trung bình

Cột "Phù hợp LEAD" là đánh giá của nhóm dựa trên các tiêu chí: tận dụng được nhãn sẵn có, khả năng chấm điểm từng giờ trên khoảng 1,75 triệu quan trắc, và rủi ro quá khớp với chỉ 200 chuỗi. Đánh giá này sẽ được kiểm chứng bằng thực nghiệm ở phần triển khai.

3 Khám phá Dữ liệu (EDA) và Tiền xử lý Dữ liệu

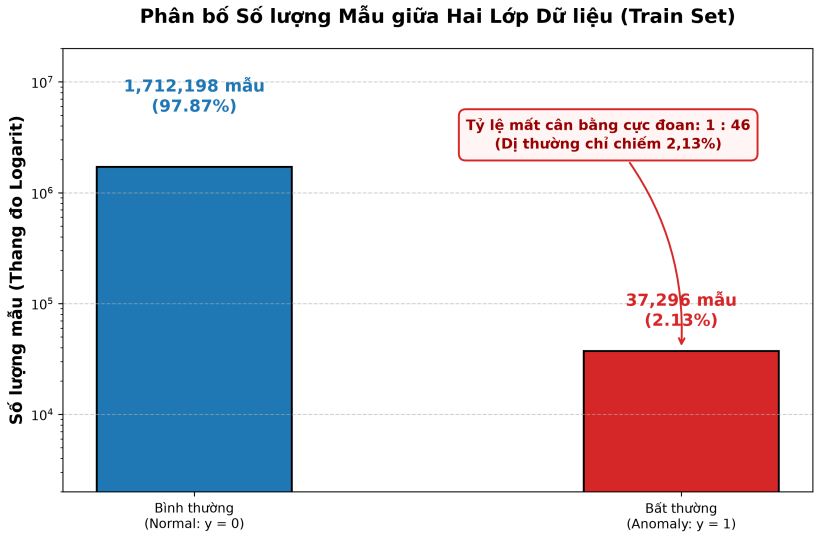
Dựa trên tệp đặc trưng `train_features.csv` đã giới thiệu ở Chương 1, chương này tập trung phân tích khám phá dữ liệu (EDA) ban đầu, xây dựng quy trình tiền xử lý chuẩn hóa và kiểm toán dữ liệu sau xử lý. Toàn bộ quy trình được xây dựng nhất quán và thực thi thông qua notebook thực nghiệm `preprocessingforALL`. Nhằm mục đích đánh giá thực nghiệm xem việc tích hợp thêm ngữ cảnh khu vực địa lý có thực sự mang lại sự khác biệt và giúp cải thiện khả năng nhận diện bất thường hay không, nhóm nghiên cứu thiết lập quy trình tạo ra song song hai bộ dữ liệu thực nghiệm: bộ dữ liệu cơ sở (Baseline) và bộ dữ liệu mở rộng tương tác khu vực (Zone-enhanced).

3.1 Khám phá Dữ liệu Ban đầu

3.1.1 Phân tích sự Mất cân bằng Lớp Dữ liệu

Dữ liệu nhãn bất thường phản ánh trạng thái hoạt động của hệ thống phụ tải điện: $y = 0$ tương ứng với trạng thái bình thường (*Normal*) và $y = 1$ tương ứng với trạng thái bất thường (*Anomaly*). Thống kê trên toàn bộ 1.749.494 bản ghi của tập dữ liệu `train_features.csv` cho kết quả phân bố như sau:

- **Lớp bình thường ($y = 0$):** 1.712.198 bản ghi, chiếm tỷ lệ xấp xỉ 97,87%.
- **Lớp bất thường ($y = 1$):** 37.296 bản ghi, chỉ chiếm tỷ lệ khoảng 2,13%.



Hình 1: **Phân phối mức độ mất cân bằng giữa nhãn bình thường và bất thường**

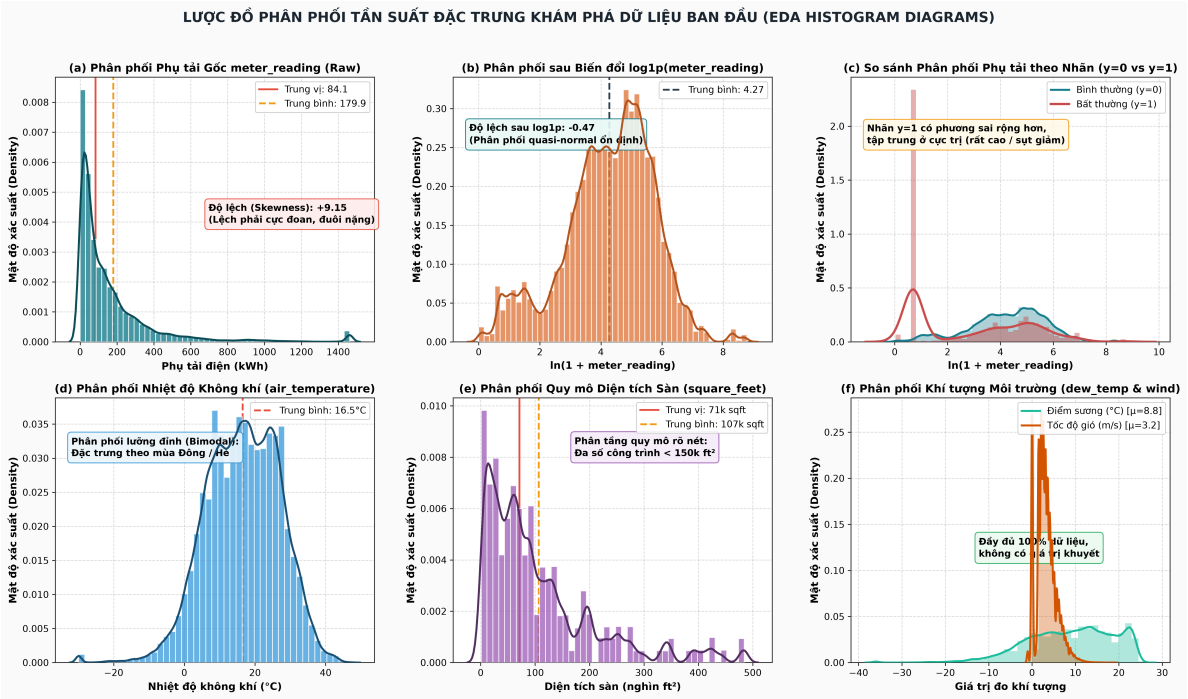
Hình 1 trực quan hóa tỷ lệ mất cân bằng nghiêm trọng này thông qua biểu đồ cột trên thang đo logarit. Mức độ mất cân bằng tỷ lệ $1:46$ đặt ra thách thức kỹ thuật lớn:

1. Nếu sử dụng hàm mất mát thông thường mà không điều chỉnh, mô hình sẽ có xu hướng tối ưu hóa bằng cách dự đoán toàn bộ mẫu là lớp đa số, dẫn đến chỉ số Accuracy rất cao nhưng hoàn toàn mất khả năng nhận diện các sự cố thực tế.

2. Nếu sử dụng ngưỡng quyết định mặc định $\tau = 0{,}5$, đại đa số các mẫu dị thường có xác suất dự đoán trong khoảng $0{,}1 - 0{,}4$ sẽ bị bỏ sót, khiến chỉ số Recall và F1-Score bị suy giảm nghiêm trọng. Do đó, việc áp dụng kỹ thuật tối ưu hóa ngưỡng cắt xác suất (Threshold Moving) là điều kiện tiên quyết trong các giai đoạn sau.

3.1.2 Phân tích Phân phối Tần suất Đặc trưng qua Histogram Diagrams

Bên cạnh sự mất cân bằng về số lượng bản ghi giữa các nhãn, việc thấu hiểu hình thái phân phối xác suất và mật độ tần suất của các thuộc tính định lượng gốc là yêu cầu mang tính quyết định trong giai đoạn Khám phá Dữ liệu (EDA). Nhóm nghiên cứu đã triển khai hàm phân tích `plot_eda_histogram_distribution()` tại Bước 1 của quy trình để khởi tạo hệ thống lược đồ phân phối tần suất chuyên sâu (Hình 2).



Hình 2: **Lược đồ Phân phối Tần suất Đặc trưng Khám phá Dữ liệu Ban đầu (EDA Histogram Diagrams)**

Từ kết quả trực quan hóa tại Hình 2, sáu đặc tính phân phối thống kê quan trọng được làm sáng tỏ:

1. **Phân phối phụ tải gốc mang tính lệch phải cực đoan (Hình 2a):** Thuộc tính tiêu thụ điện `meter_reading` có độ lệch dương rất lớn (Skewness = +9,15) cùng phần đuôi phân phối dài và nặng. Phần lớn quan trắc tập trung ở dải phụ tải thấp với giá trị trung vị chỉ đạt 84,10 kWh, trong khi giá trị trung bình bị kéo lệch lên mức 179,90 kWh do ảnh hưởng của các đỉnh tiêu thụ đột biến đạt tới 6.596,89 kWh. Đặc tính phân phối phi chuẩn này cho thấy các giải thuật giả định phân phối chuẩn như Naive Bayes hay Hồi quy tuyến tính sẽ kém hiệu quả và dễ bị thiên lệch nếu không qua bước biến đổi dữ liệu.

2. **Tác động phục hồi tính chuẩn tắc của biến đổi Logarithm (Hình 2b):** Khi áp dụng hàm nén phi tuyến $f(x) = \ln(1+x)$, đuôi dài bên phải của phân phối được co cụm đáng kể, đưa độ lệch từ +9,15 về mức xấp xỉ đối xứng −0,47. Phân phối chuyển hóa thành hình chuông tựa chuẩn với kỳ vọng trung bình đạt 4,27. Điều này cung cấp căn cứ toán học vững chắc cho việc sử dụng các mô hình cây quyết định phân nhánh trên thang đo logarit hoặc chuẩn hóa Z-score nhằm ổn định độ dốc gradient.

3. **Sự phân hóa phân phối phụ tải theo trạng thái nhãn (Hình 2c):** Khi bóc tách phân phối theo điều kiện $P(X \mid y = 0)$ và $P(X \mid y = 1)$:

   - Lớp bình thường ($y = 0$, màu xanh) phân bố tập trung dày đặc xung quanh mức tiêu thụ cơ sở (3,5 – 5,5 trên thang log, tương ứng 30 – 250 kWh).
   - Ngược lại, lớp dị thường ($y = 1$, màu đỏ) thể hiện phương sai cực rộng và xu hướng phân bố phân cực: Cực trị 1 sụt giảm sâu về cận 0 (tương ứng sự cố

mất nguồn hoặc đứt tín hiệu cảm biến) và Cực trị 2 tăng vọt ở dải phụ tải đỉnh $> 6{,}5$ (tương ứng sự cố quá tải, chập điện). Sự chồng lấn phân phối này minh chứng rằng không thể dùng bất kỳ ngưỡng cắt tĩnh đơn biến nào để phát hiện dị thường mà bắt buộc phải kết hợp chuỗi đặc trưng đa biến.

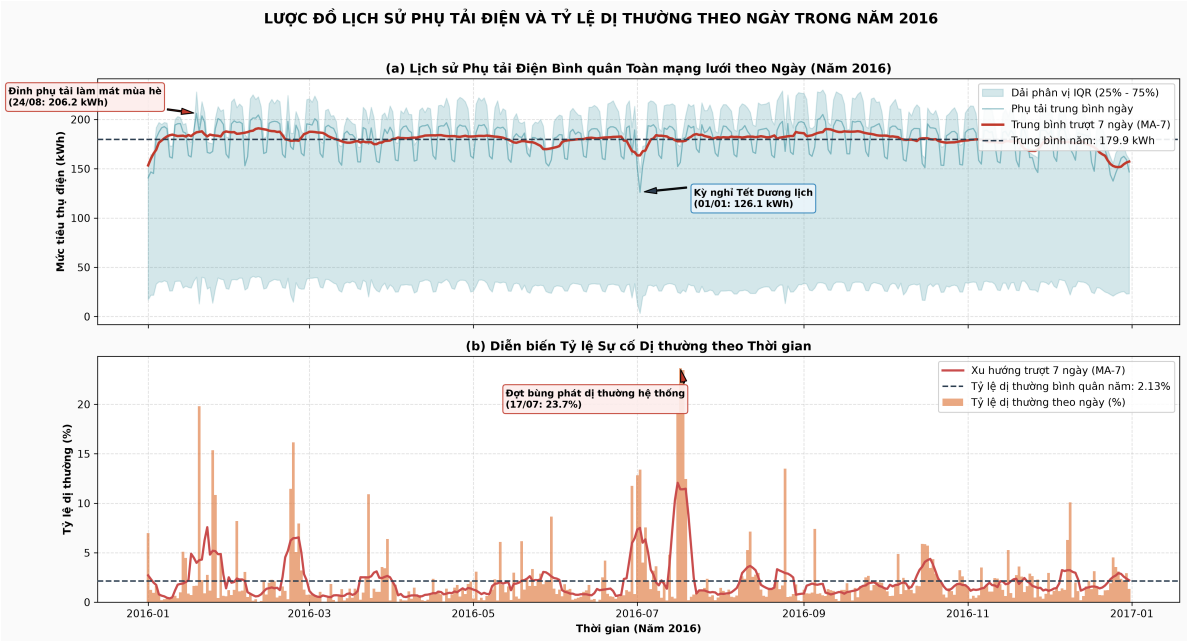
4. **Tính chất phân phối lưỡng đỉnh của nhiệt độ môi trường (Hình 2d):** Biến thời tiết `air_temperature` thể hiện rõ nét hình thái phân phối hai đỉnh với kỳ vọng trung bình 16,5°C. Đỉnh thứ nhất tập trung quanh vùng $8°\text{C} - 12°\text{C}$ (đại diện cho mùa đông và khung giờ ban đêm), trong khi đỉnh thứ hai tập trung quanh $24°\text{C} - 28°\text{C}$ (mùa hè và khung giờ ban ngày). Sự phân hóa lưỡng cực này giải thích vì sao nhu cầu điện làm mát và sưởi ấm biến động theo mùa, tạo động lực cho việc xây dựng các biến chu kỳ tuần hoàn (sin / cos) ở Bước 2 tiền xử lý.

5. **Sự phân tầng quy mô công trình đô thị (Hình 2e):** Phân phối diện tích sàn `square_feet` thể hiện tính phân tầng rõ rệt: giá trị trung vị đạt $71.000\,\text{ft}^2$, trong khi trung bình là $107.000\,\text{ft}^2$. Đại đa số công trình tập trung ở quy mô vừa và nhỏ ($< 150.000\,\text{ft}^2$, chủ yếu là văn phòng và trường học), trong khi một tỷ lệ nhỏ các công trình công cộng và trung tâm dữ liệu có diện tích vượt mức $400.000\,\text{ft}^2$, tạo ra tải nền tiêu thụ liên tục suốt ngày đêm.

6. **Tính toàn vẹn của các thuộc tính khí tượng bổ trợ (Hình 2f):** Phân phối của điểm sương `dew_temperature` (trung bình 8,8°C) và tốc độ gió `wind_speed` (trung bình 3,2 m/s) đạt độ toàn vẹn 100% (0 giá trị khuyết), cho thấy dữ liệu khí tượng có tính ổn định cao, là nguồn tham chiếu môi trường đáng tin cậy.

3.1.3 Toàn cảnh Lịch sử Phụ tải và Phân bố Dị thường theo Thời gian

Nhằm nắm bắt toàn diện hành vi phụ tải ở cấp độ vĩ mô và sự phân bố của các biến cố dị thường xuyên suốt 366 ngày trong năm 2016, nhóm nghiên cứu xây dựng lược đồ lịch sử vận hành trên toàn bộ 200 tòa nhà thuộc tập huấn luyện (Hình 3).



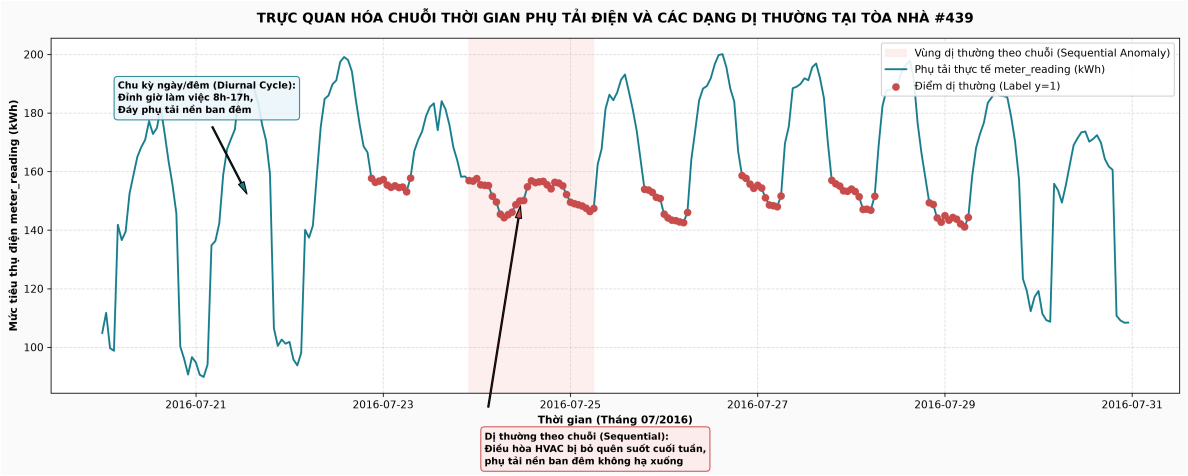
Hình 3: **Lược đồ Lịch sử Phụ tải Điện và Tỷ lệ Dị thường theo Ngày trong năm 2016**

Từ lược đồ lịch sử vĩ mô tại Hình 3, hai quy luật vận hành then chốt được khám phá:

1. **Đặc thù lịch sử phụ tải trung bình ngày (biểu đồ trên):**
    - Mức tiêu thụ điện bình quân toàn hệ thống đạt mức trung bình 179,88 kWh. Đường trung bình trượt 7 ngày (đường màu đỏ, tính bình quân theo từng tuần để triệt tiêu dao động giữa ngày làm việc và cuối tuần) cho thấy xu hướng phụ tải tăng cao rõ rệt vào các tháng mùa hè (tháng 6 đến tháng 8), đạt đỉnh 198,1 kWh vào ngày 24/08/2016 do nhu cầu vận hành tối đa của hệ thống làm mát trung tâm (HVAC). Ngược lại, vào các kỳ nghỉ lễ lớn như Tết Dương lịch (01/01/2016) hoặc kỳ nghỉ mùa đông, mức tiêu thụ sụt giảm sâu xuống 140,7 kWh do các hoạt động làm việc và học tập tạm ngưng.
    - Dải phân vị IQR (nền xanh nhạt) phản ánh sự phân hóa mạnh mẽ về quy mô công trình: các tòa nhà giáo dục và văn phòng nhỏ duy trì phụ tải nền thấp ($20-40$ kWh), trong khi các cơ sở phức hợp lớn tiêu thụ liên tục trên 200 kWh.
2. **Đặc thù lịch sử xuất hiện dị thường theo thời gian (biểu đồ dưới):**
    - Mặc dù tỷ lệ dị thường bình quân cả năm chỉ là 2,14% (đường chấm đen), các điểm dị thường không phân bố ngẫu nhiên đồng đều mà tập trung thành từng đợt sự cố hệ thống kéo dài nhiều ngày liên tiếp.
    - Tiêu biểu nhất là đợt bùng phát dị thường vào trung tuần tháng 7 (đạt đỉnh 23,7% vào ngày 17/07/2016) và các đợt biến động mạnh vào tháng 2, 3. Hiện tượng cụm dị thường theo thời gian chứng minh rằng việc mô hình hóa chuỗi thời gian thông qua các đặc trưng trễ, trung bình trượt, và tương tác vùng khí hậu là hoàn toàn cần thiết để phát hiện kịp thời các sự cố mang tính chuỗi.

3.1.4 Phân loại Hình thái Dị thường Phụ tải trên Chuỗi Thời gian

Trong khi Mục 3.1.3 quan sát xu hướng dài hạn theo ngày trên toàn mạng lưới, mục này đi sâu vào độ phân giải từng giờ tại công trình đại diện Tòa nhà #439, Hình 4 nhằm nhận diện quy luật phụ tải cơ sở và phân loại các hình thái dị thường thực tế.



Hình 4: **Chuỗi thời gian phụ tải điện theo giờ và các dạng dị thường tại Tòa nhà #439**

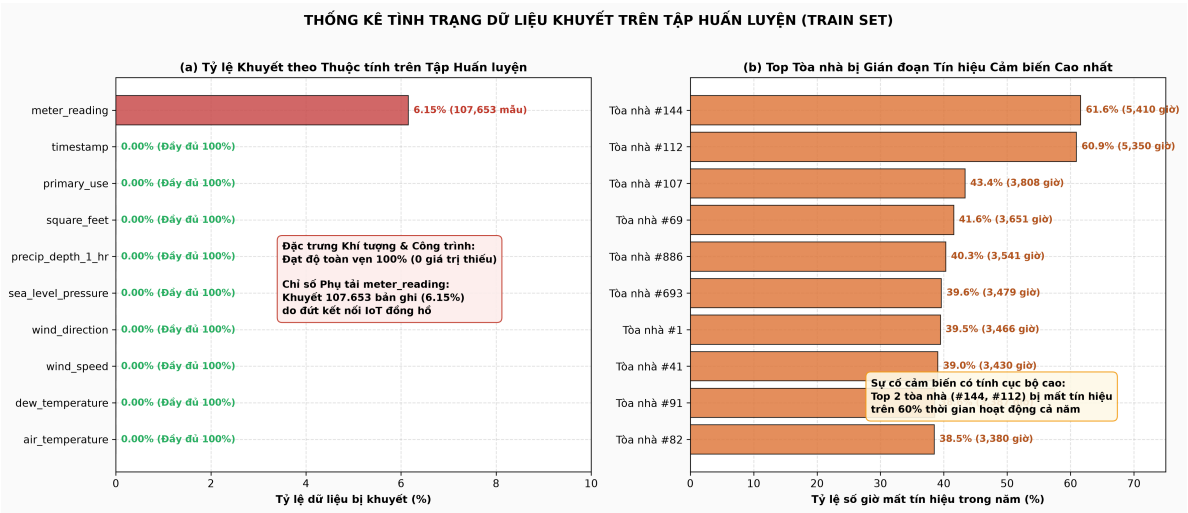
Chuỗi thời gian phụ tải theo giờ thể hiện hai chu kỳ sinh hoạt cơ sở: chu kỳ 24 giờ ngày/đêm, đỉnh phụ tải vào giờ làm việc 8h - 17h và đáy phụ tải nền vào ban đêm, cùng chu kỳ tuần, mức phụ tải giảm sút rõ rệt vào cuối tuần. Dựa trên sự sai lệch so với hai quy luật này, các điểm dị thường trong dữ liệu được phân chia thành hai nhóm:

1. **Dị thường điểm (Point Anomaly):** Biểu hiện qua các xung đột biến tức thời tăng vọt hoặc sụt giảm về 0 đột ngột trong một vài giờ lẻ. Nguyên nhân thường xuất phát từ sự cố chập tải cục bộ, khởi động thiết bị công suất cực lớn không báo trước, hoặc cảm biến đo bị ngắt quãng tín hiệu tức thời.

2. **Dị thường theo chuỗi (Sequential / Collective Anomaly):** Biểu hiện qua một đoạn liên tục nhiều giờ hoặc nhiều ngày mà mức tiêu thụ điện giữ nguyên ở mức cao bất thường (ví dụ: hệ thống điều hòa trung tâm bị bỏ quên không tắt trong suốt chuỗi ngày cuối tuần, thể hiện rõ tại Hình 4), hoặc phụ tải dao động hỗn loạn phá vỡ hoàn toàn chu kỳ ngày/đêm thông thường. Dạng dị thường này đòi hỏi mô hình phải kết hợp các đặc trưng trễ, biến chu kỳ lượng giác và độ lệch chuẩn trượt để nhận diện.

3.1.5 Nhiễu Cảm biến và Tình trạng Thiếu Dữ liệu

Bên cạnh bài toán mất cân bằng nhãn, tình trạng nhiễu và đứt gãy tín hiệu đo lường từ đồng hồ thông minh là thách thức lớn thứ hai được phát hiện qua bước EDA. Nhóm nghiên cứu đã triển khai hàm `plot_eda_missing_sensor_noise()` tại Bước 1 để phân tích toàn diện hiện tượng này trên Tập Huấn luyện (`train_features.csv`, 1.749.494 bản ghi). Kết quả thống kê chi tiết được trực quan hóa tại Hình 5.



Hình 5: **Thống kê Tình trạng Dữ liệu Khuyết trên Tập Huấn luyện: Tỷ lệ khuyết theo thuộc tính (trái) và Top Tòa nhà bị gián đoạn cảm biến phụ tải cao nhất (phải)**

Từ Hình 5, nhóm nghiên cứu ghi nhận hai kết luận then chốt sau:

1. **Tỷ lệ khuyết theo thuộc tính phụ tải (biểu đồ trái):** Thuộc tính phụ tải `meter_reading` bị khuyết đúng 107.653 bản ghi (chiếm tỷ lệ 6,15% tổng số mẫu). Đáng chú ý, toàn bộ các thuộc tính thời tiết môi trường (`air_temperature`,

`dew_temperature`, `wind_speed`, ...) cùng tem thời gian `timestamp` và quy mô công trình `square_feet` đều đạt độ toàn vẹn 100% (0 giá trị thiếu). Điều này khẳng định hệ thống trạm khí tượng hoạt động hoàn toàn ổn định, nguyên nhân thiếu dữ liệu thuần túy do kết nối truyền thông IoT từ đồng hồ thông minh về máy chủ đo lường bị ngắt quãng cục bộ.

2. **Tính cục bộ của sự cố cảm biến (biểu đồ phải):** Dữ liệu thiếu không phân bố rải rác đồng đều giữa các công trình mà tập trung nghiêm trọng tại một số tòa nhà cá biệt. Điển hình như Tòa nhà #144 bị mất tín hiệu 5.410 giờ (61,6%) và Tòa nhà #112 bị mất 5.350 giờ (60,9%) dữ liệu trong năm (trên tổng số 8.784 giờ của năm nhuận 2016). Việc mất tín hiệu kéo dài hàng ngàn giờ liên tiếp đặt ra yêu cầu quy trình tiền xử lý phải có giải pháp điền khuyết chuỗi thời gian phù hợp (nội suy tuyến tính kết hợp *forward/backward fill* theo từng tòa nhà), tránh làm biến dạng quy luật phụ tải thực tế.

3.2 Quy trình Tiền xử lý Dữ liệu

Nhằm chuẩn bị không gian đặc trưng tối ưu và triệt tiêu hoàn toàn rủi ro rò rỉ dữ liệu chuỗi thời gian, quy trình tiền xử lý được chuẩn hóa theo giao thức nghiêm ngặt và chia tách chu kỳ mùa vụ kết hợp khoảng đệm cách ly (Seasonal Chunking with 96h Purge Gap). Toàn bộ các thao tác nạp dữ liệu và khám phá sơ bộ đã được trình bày độc lập tại Mục 3.1.

Đặc biệt, trong nghiên cứu này, nhóm chủ động thiết kế quy trình nhằm tạo ra song song **ba bộ dữ liệu thực nghiệm tăng tiến phân cấp**:

1. **Bộ dữ liệu cơ sở (Baseline Dataset - 39 đặc trưng / 40 cột):** Bao gồm đầy đủ các đặc trưng phụ tải, khí tượng, biến chu kỳ lượng giác và đặc tính công trình sau chuẩn hóa chuẩn mực.

2. **Bộ dữ liệu mở rộng khu vực (Zone-enhanced Dataset - 42 đặc trưng / 43 cột):** Được tích hợp bổ sung 3 đặc trưng tương tác vùng khí hậu và quy mô công trình theo địa bàn (`zone_interaction`, `site_sqft_mean`, `use_sqft_mean`).

3. **Bộ dữ liệu ngữ cảnh vi mô nâng cao (Context-Aware Dataset - 46 đặc trưng / 47 cột):** Kế thừa trọn vẹn 42 đặc trưng của nhánh Zone và tích hợp thêm 4 đặc trưng vi mô chuẩn hóa phụ tải cục bộ của từng công trình (`z_meter_local`, `z_meter_workday`, `z_meter_robust`, `temp_load_inter`).

Mục tiêu cốt lõi của việc thiết kế 3 bộ dữ liệu là phục vụ chuỗi đối chứng thực nghiệm tăng tiến: làm sáng tỏ năng lực phân tách khi bổ sung vùng Zone và bước đột phá hiệu năng khi tích hợp Context.

3.2.1 Giao thức Phân chia Chuỗi Thời gian Chu kỳ Mùa vụ và 96 Giờ Cách ly (100% Zero Data Leakage)

Nhằm triệt tiêu tuyệt đối nguy cơ rò rỉ thông tin trong chuỗi thời gian (đặc biệt là tác động của các biến trễ khí tượng dài hạn `air_temperature_*_lag73`), dữ liệu được phân chia theo giao thức Seasonal Chunking kết hợp khoảng cách ly Purge Gap 96 giờ:

- **Tập Huấn luyện (T_{in} - Train):** Chiếm các ngày từ 01 đến 20 hàng tháng (1.147.089 bản ghi, $\approx 65{,}6\%$). Toàn bộ các thống kê (μ, σ, Median, IQR, các bảng tra cứu phụ tải) **chỉ được fit duy nhất trên tập này**.

- **Khoảng cách ly (T_{gap} - Purge Gap 96h):** Chiếm các ngày từ 21 đến 24 hàng tháng (229.412 bản ghi, $\approx 13{,}1\%$). Khoảng đệm 96 giờ này **bị loại bỏ hoàn toàn khỏi thực nghiệm**, tạo thành bức tường ngăn cách tuyệt đối giữa Train và Test.
- **Tập Kiểm định (T_{out} - Test):** Chiếm từ ngày 25 đến hết mỗi tháng (372.993 bản ghi, $\approx 21{,}3\%$). Tập này chỉ áp dụng phép chiếu (*transform / map*) từ thống kê của Train, đóng vai trò là tập out-of-sample thực tế.

Chi tiết các bước biến đổi đặc trưng được triển khai tuần tự như sau:

1. **Bước 1: Tách Nhãn mục tiêu và Định danh ra khỏi Ma trận Đặc trưng.** Vector nhãn $y_{\text{train}} =$ `anomaly` được tách riêng và đặt chỉ mục liên tục để phục vụ huấn luyện có giám sát, được loại bỏ khỏi ma trận đặc trưng X_{train}, bảo đảm mô hình không bị rò rỉ nhãn.

2. **Bước 2: Chuẩn hóa Timestamp và Mã hóa Chu kỳ Thời gian (sin / cos).** Trường thời gian `timestamp` được ép kiểu sang định dạng `datetime64[ns]` chuẩn. Do thời gian có tính chu kỳ tuần hoàn khép kín, việc sử dụng giá trị số nguyên đơn thuần sẽ làm mất tính liên tục không gian. Do đó, các thành phần thời gian được mã hóa lượng giác trực tiếp:

$$x_{\sin} = \sin\left(\frac{2\pi t}{T}\right), \quad x_{\cos} = \cos\left(\frac{2\pi t}{T}\right)$$

   trong đó chu kỳ $T = 24$ cho giờ trong ngày (`hour_sin`, `hour_cos`), $T = 7$ cho ngày trong tuần (`weekday_sin`, `weekday_cos`), và $T = 12$ cho tháng trong năm (`month_sin`, `month_cos`). Sau khi sinh các biến lượng giác, các cột thời gian gốc (`hour`, `weekday`, `month`) và các tọa độ thời gian cũ được loại bỏ hoàn toàn để tránh hiện tượng đa cộng tuyến.

3. **Bước 3: Chuẩn hóa Lược đồ Đặc trưng, Phân loại Kiểu dữ liệu, Tạo Cờ Missing và Loại bỏ Đặc trưng không phù hợp.**

   - **Tạo cờ missing:** Trước khi điền khuyết, nhóm khởi tạo biến cờ nhị phân:

$$\texttt{meter_reading_was_missing} = \begin{cases} 1, & \text{nếu } \texttt{meter_reading} \text{ bị thiếu (NaN)} \\ 0, & \text{ngược lại} \end{cases}$$

     Biến cờ này lưu giữ tín hiệu quan trọng về sự gián đoạn kết nối IoT của đồng hồ đo.

   - **Chuẩn hóa lược đồ và phân nhóm kiểu dữ liệu:** Xác lập cấu trúc lược đồ chuẩn cho toàn bộ không gian đặc trưng; phân loại tường minh danh sách biến định lượng và biến định tính nhằm áp dụng quy trình xử lý chuyên biệt cho từng kiểu biến ở các bước kế tiếp.

   - **Loại bỏ đặc trưng không phù hợp và Triệt tiêu Rò rỉ Nhãn Mục tiêu (Target Leakage):** Nhóm loại bỏ các biến hằng số không phương sai, các tổ hợp thời gian trùng lặp (`weekday_hour`), và **đặc biệt quan trọng:** loại bỏ toàn bộ các biến mã hóa mục tiêu theo tòa nhà cá thể (`gte_building_id`, `gte_meter_building_id`, …) cùng các đặc trưng gắn chặt với ID cụ thể của công trình (như `building_weekday_hour`, `building_hour`, …). Quyết định kỹ thuật này dựa trên hai nguyên nhân cốt tử:

(a) *Nguy cơ Rò rỉ Dữ liệu Đích (Catastrophic Target Leakage):* Bản chất của Global Target Encoding (GTE) theo ID công trình là tính xác suất dị thường có điều kiện:

$$\text{GTE}(\text{building_id} = b) = \mathbb{E}[y \mid \text{building_id} = b] = \frac{\sum_{i \in b} y_i}{N_b}$$

Nếu biến này được sinh ra trên toàn bộ tập dữ liệu trước khi phân chia chuỗi thời gian, thông tin nhãn mục tiêu y từ tương lai (T_{out}) sẽ bị rò rỉ ngược hoàn toàn vào tập huấn luyện (T_{in}), tạo ra kết quả kiểm thử ảo tưởng và vi phạm nghiêm trọng nguyên tắc Zero Data Leakage.

(b) *Nguy cơ Quá khớp Ghi nhớ ID (High-Cardinality Target Memorization):* Ngay cả khi được tính riêng trên T_{in}, do tập dữ liệu có tới 1.449 tòa nhà cá biệt (lực lượng phân loại cực lớn), việc mã hóa nhãn mục tiêu trực tiếp cho từng ID sẽ biến các đặc trưng này thành biến đại diện gần như hoàn hảo cho nhãn y. Mô hình cây sẽ bị dẫn dắt vào việc "học vẹt"và ghi nhớ máy móc tòa nhà nào thường xuyên bị lỗi trong lịch sử thay vì học các quy luật phụ tải vật lý tổng quát (độ lệch Z-score, nhiệt độ, công năng). Điều này khiến mô hình mất hoàn toàn năng lực tổng quát hóa khi một công trình trước đây hoạt động bình thường bất ngờ phát sinh sự cố trong tương lai.

Trái ngược với `building_id`, biến công năng `primary_use` chỉ có 16 nhóm ngành lớn mang tính quy luật vật lý chung (giáo dục, bệnh viện, văn phòng...), do đó chỉ có `gte_primary_use` và `gte_meter_primary_use` (được học nghiêm ngặt 100% trên T_{in}) là được giữ lại.

4. **Bước 4: Điền giá trị thiếu cho Dữ liệu Định lượng bằng Nội suy Chuỗi thời gian.** Khác với các phép gán trung vị hoặc trung bình toàn cục làm biến dạng dáng điệu phụ tải, nhóm áp dụng phương pháp nội suy tuyến tính theo thời gian (`interpolate(method='time')`) được tính toán độc lập trong từng tòa nhà (`building_id`). Ở các khoảng biên đầu và cuối chuỗi, kỹ thuật *forward fill* và *backward fill* được kết hợp để lấp đầy 100% dữ liệu thiếu mà vẫn tôn trọng xu hướng động học thực tế.

5. **Bước 5: Xử lý Giá trị Ngoại lai bằng Khoảng Tứ phân vị IQR.** Đối với các biến thời tiết môi trường (`air_temperature`, `dew_temperature`, `wind_speed`, ...), nhóm áp dụng quy tắc khoảng tứ phân vị IQR:

$$\text{IQR} = Q_3 - Q_1, \quad [\text{Ngưỡng dưới}, \text{Ngưỡng trên}] = [Q_1 - 1{,}5\text{IQR},\ Q_3 + 1{,}5\text{IQR}]$$

Các quan trắc thời tiết vượt ra ngoài khoảng này do lỗi thiết bị đo khí tượng được clip về giá trị trung vị cục bộ.

Đặc biệt lưu ý: Thuộc tính phụ tải `meter_reading` và các đặc trưng Target Encoding (`gte_`) được miễn trừ hoàn toàn khỏi bước này; việc ép phụ tải về trung vị sẽ trực tiếp triệt tiêu các mẫu dị thường mà mô hình cần nhận dạng.

6. **Bước 6: Chuẩn hóa Z-score và Tích hợp Đặc trưng Khu vực.**

- **Chuẩn hóa Z-score:** Đưa các biến định lượng về phân phối có trung bình bằng 0 và độ lệch chuẩn bằng 1 bằng `StandardScaler`:

$$Z = \frac{x - \mu}{\sigma}$$

Tham số μ, σ chỉ được fit trên tập huấn luyện và transform cho tập kiểm tra. Các biến cờ nhị phân (0/1), các biến chu kỳ $\sin / \cos \in [-1, 1]$, và các biến tỷ lệ `gte_` $\in [0, 1]$ được giữ nguyên thang đo gốc.

- **Tích hợp Đặc trưng Khu vực:** Để tạo ra bộ dữ liệu Zone-enhanced phục vụ các bài toán phân hóa địa bàn, nhóm nghiên cứu xây dựng thêm 3 đặc trưng tương tác địa lý với quy cách mã hóa và ý nghĩa thực tế chi tiết như sau:

  (a) `zone_interaction`: **Mã hóa tương tác phi tuyến giữa Vùng khí hậu và Mục đích sử dụng công trình**.

  – *Quy trình mã hóa:* Thuộc tính phân loại `primary_use` trước hết được ánh xạ sang mã danh mục tạm thời `primary_use_cat` $\in \{0, 1, \ldots, 11\}$ (ví dụ: `Education` $= 0$, `Entertainment` $= 1$, ...). Sau đó, thực hiện phép ghép chuỗi ký tự giữa mã khu vực `site_id` và mã công năng:

  $$\text{Chuỗi tương tác} = \texttt{site_id} \,\|\, \text{`_'} \,\|\, \texttt{primary_use_cat}$$

  Chuỗi này tiếp tục được chuyển hóa thành mã định danh số nguyên phân loại:

  $$\texttt{zone_interaction} = \text{CatCodes}(\text{Chuỗi tương tác}) \in \{0, 1, 2, \ldots, 46\}$$

  – *Ví dụ giá trị cụ thể:*

  * Một tòa nhà trường học (`Education`, mã 0) tọa lạc tại Khu vực nhiệt đới `Site 0` sẽ có chuỗi ghép `"0_0"`, được mã hóa thành giá trị nguyên **0**. Trong khi đó, một trường học tương tự nhưng tọa lạc tại Khu vực ôn đới lạnh `Site 1` có chuỗi `"1_0"`, được mã hóa thành giá trị **19**; và tại `Site 2` có chuỗi `"2_0"` nhận giá trị **24**.
  * Một tòa nhà văn phòng (`Office`, mã 6) tại `Site 0` có chuỗi `"0_6"` nhận giá trị **1**, nhưng tại `Site 1` chuỗi `"1_6"` nhận giá trị **22**.

  Toàn bộ dữ liệu ghi nhận chính xác 47 tổ hợp phân vùng thực tế (nhận giá trị từ 0 đến 46).

  – *Ý nghĩa đối với mô hình:* Biến tương tác này cho phép các thuật toán cây (LightGBM, XGBoost, CatBoost) thực hiện ngay lập tức một điểm cắt nhị phân (*single-split decision*) để phân lập hành vi tiêu thụ điện đặc thù theo từng địa phương mà không cần phải thực hiện 2 đến 3 tầng phân nhánh liên tiếp.

  (b) `site_sqft_mean`: **Quy mô diện tích sàn trung bình của từng khu vực đô thị (`site_id`)**.

  – *Công thức tính:* Tính trung bình diện tích sàn của toàn bộ các công trình thuộc cùng một khu vực địa lý:

  $$\texttt{site_sqft_mean}_i = \frac{1}{|S_{\texttt{site_id}_i}|} \sum_{k \in S_{\texttt{site_id}_i}} \texttt{square_feet}_k$$

  – *Ví dụ giá trị cụ thể:* Khu vực `Site 0` có diện tích bình quân **83.051,6** ft^2 (đa số là khuôn viên trường đại học quy mô vừa); Khu vực `Site 4` tập trung các tổ hợp công nghệ lớn với diện tích bình quân lên tới **234.903,6** ft^2; Khu vực siêu đô thị `Site 7` có diện tích sàn bình quân đạt đỉnh **484.376,0** ft^2; trong khi Khu vực `Site 8` chủ yếu là các công trình nhỏ với diện tích trung bình chỉ **7.143,5** ft^2.

– *Ý nghĩa:* Cung cấp bối cảnh về mật độ và quy mô xây dựng đô thị tổng thể, giúp mô hình phân biệt giữa cụm đô thị dày đặc tải lớn và vùng phụ tải phân tán.

(c) `use_sqft_mean`: **Quy mô diện tích sàn trung bình theo nhóm công năng (`primary_use`).**

– *Công thức tính:* Tính trung bình diện tích sàn của toàn bộ các công trình có cùng mục đích sử dụng:

$$\texttt{use_sqft_mean}_i = \frac{1}{|U_{\texttt{primary_use}_i}|} \sum_{k \in U_{\texttt{primary_use}_i}} \texttt{square_feet}_k$$

– *Ví dụ giá trị cụ thể:* Nhóm công năng Dịch vụ phức hợp (`Services`) có diện tích trung bình cao nhất đạt **299.222,0** ft^2; Nhà để xe (`Parking`) đạt **204.312,0** ft^2; Trường học (`Education`) đạt **123.858,0** ft^2; Văn phòng (`Office`) đạt **89.883,9** ft^2; Sản xuất, công nghiệp (`Manufacturing / Industrial`)đạt **33.850,0** ft^2; và nhóm công trình phụ trợ khác (`Other`) chỉ đạt **4.482,0** ft^2.

– *Ý nghĩa:* Đóng vai trò làm mốc đối chứng chuẩn mực theo loại hình. Khi kết hợp với diện tích sàn thực tế `square_feet`, mô hình có thể tự động lượng hóa tỷ lệ lệch quy mô của một tòa nhà so với chuẩn mực ngành.

Sự hiện diện của 3 thuộc tính này chính là điểm phân tách cốt lõi giữa hai bộ dữ liệu thực nghiệm (Baseline: 39 đặc trưng vs Zone-enhanced: 42 đặc trưng). Bảng 3 minh họa dữ liệu mẫu thực tế của 3 đặc trưng Zone trên các công trình đại diện trích xuất trực tiếp từ tập dữ liệu huấn luyện:

Bảng 3: **Mẫu dữ liệu thực nghiệm minh họa 3 đặc trưng Zone trên các công trình tiêu biểu**

Building ID	Site ID	Công năng (`primary_use`)	Diện tích gốc (sqft)	`zone_interaction`	`site_sqft_mean`	`use_sqft_mean`
1	0	Education (Trường học)	2.720	0	-0,6202	+0,2951
91	0	Education (Trường học)	68.094	0	-0,6202	+0,2951
32	0	Office (Văn phòng)	48.392	1	-0,6202	-0,1428
136	1	Lodging/residential	56.467	21	-0,0238	-0,5030
240	2	Lodging/residential	111.304	26	+0,1275	-0,5030
69	0	Parking (Nhà để xe)	387.638	2	-0,6202	-0,5826

7. **Bước 7: Tích hợp Đặc trưng Ngữ cảnh (Context-Aware Feature Engineering).** Mặc dù 3 đặc trưng Zone cung cấp thông tin vĩ mô cấp khu vực, mức tiêu thụ điện thực tế lại phụ thuộc trực tiếp vào nhịp sinh hoạt và chế độ vận hành riêng của từng công trình cá biệt. Do đó, nhóm nghiên cứu thiết kế thêm 4 đặc trưng vi mô chuẩn hóa Z-score cục bộ, được học 100% trên tập huấn luyện T_{in} (100% Zero Data Leakage) và ánh xạ sang tập kiểm định T_{out}:

(a) `z_meter_local`: Phụ tải chuẩn hóa theo cặp (`building_id`, `hour`). Cho biết mức độ chênh lệch của phụ tải hiện tại so với hành vi bình thường của tòa nhà vào đúng khung giờ đó:

$$\texttt{z_meter_local}_i = \frac{\texttt{meter_reading}_i - \mu_{(b,h)}}{\sigma_{(b,h)}}$$

(b) `z_meter_workday`: Phụ tải chuẩn hóa theo bộ ba (`building_id`, `is_offday`, `hour`). Tách biệt rõ nét giữa ngày làm việc thông thường và ngày nghỉ/cuối tuần (nơi phụ tải nền thường giảm mạnh):

$$\texttt{z_meter_workday}_i = \frac{\texttt{meter_reading}_i - \mu_{(b,\text{off},h)}}{\sigma_{(b,\text{off},h)}}$$

(c) `z_meter_robust`: Chuẩn hóa kháng nhiễu (*Robust Z-score*) dựa trên Trung vị và Khoảng tứ phân vị của từng công trình:

$$\texttt{z_meter_robust}_i = \frac{\texttt{meter_reading}_i - \text{Median}_b}{\text{IQR}_b}$$

Nhờ dùng Trung vị và IQR thay vì Mean và Std, đặc trưng này không bị lệch lạc bởi các giá trị dị thường cực đoan.

(d) `temp_load_inter`: Đặc trưng tương tác giữa phụ tải công việc và nhiệt độ không khí môi trường:

$$\texttt{temp_load_inter}_i = \texttt{z_meter_workday}_i \times \texttt{air_temperature}_i$$

Sự bổ sung của 4 đặc trưng này hoàn thiện biến thể thứ ba: **Context-Aware Dataset** gồm đúng **46 đặc trưng** (**47 cột** tính cả nhãn mục tiêu `anomaly`). Bảng 4 trình bày mẫu dữ liệu thực nghiệm trích xuất trực tiếp từ tập dữ liệu huấn luyện T_{in}, đối chiếu định lượng giữa các trạng thái vận hành bình thường ($y = 0$) và các dạng thức dị thường điển hình ($y = 1$) bao gồm quá tải phụ tải điện, sụt giảm đứt gãy phụ tải nền, và bất thường lệch nhịp công tác:

Bảng 4: **Mẫu dữ liệu thực nghiệm minh họa 4 đặc trưng Context-Aware trên các công trình tiêu biểu**

Building	Site	Công năng chính	Trạng thái vận hành	meter	Temp	z_local	z_work	z_robust	temp_inter
1	0	Education (Trường học)	Bình thường ($y = 0$)	-0,234	-0,15	+1,1444	+1,1535	+0,9537	-0,1780
1	0	Education (Trường học)	Dị thường ($y = 1$) (Sụt tải)	-0,418	+0,90	-1,6408	-1,6218	-0,5629	-1,4522
32	0	Office (Văn phòng)	Bình thường ($y = 0$)	-0,234	-0,15	+0,7961	+0,6676	0,0000	-0,1030
32	0	Office (Văn phòng)	Dị thường ($y = 1$) (Trái nhịp)	-0,208	+0,73	+0,1678	+0,8362	+0,2684	+0,6079
136	1	Lodging/residential	Bình thường ($y = 0$)	-0,381	-1,02	-0,8744	-0,8920	-0,3164	+0,9062
136	1	Lodging/residential	Dị thường ($y = 1$) (Đứt gãy tải)	-0,370	-1,27	-0,6715	-0,6887	-0,2097	+0,8770
1128	13	Office (Văn phòng)	Dị thường ($y = 1$) (Đột biến đỉnh)	+0,480	-3,02	+10,0000	+9,4721	+7,4612	-28,5724
144	1	Office (Văn phòng)	Dị thường ($y = 1$) (Triệt tiêu tải)	-0,450	-1,24	-5,0000	-5,0000	-2,1934	+6,2158
69	0	Parking (Nhà để xe)	Bình thường ($y = 0$)	-0,234	-0,15	+1,1788	+1,2004	+0,6218	-0,1853
69	0	Parking (Nhà để xe)	Dị thường ($y = 1$) (Bất thường tải)	-0,436	+0,90	-0,7673	-0,7814	-0,6900	-0,6996

Phân tích định lượng từ mẫu dữ liệu thực nghiệm:

- *Độ nhạy phân lập trước các sự cố cực đoan:* Tại tòa nhà văn phòng `Building 1128`, sự cố tăng vọt phụ tải bất thường vào khung giờ nhiệt độ lạnh giá ($T = -3{,}02$) được bộ đôi `z_meter_local` và `z_meter_workday` phát hiện ngay tức thì khi chạm ngưỡng trần bão hòa $+10{,}0000$ và $+9{,}4721$, kết hợp với đặc trưng tương tác âm tính cực lớn `temp_load_inter` $= -28{,}5724$. Ngược lại, tại `Building 144`, hiện tượng mất phụ tải đột ngột kéo `z_meter_local` chạm ngưỡng sàn $-5{,}0000$.

- *Bắt trúng dị thường ngữ cảnh vi mô (Contextual Anomalies):* Tại `Building 32`, phụ tải điện `meter_reading` $= -0{,}208$ nếu chỉ nhìn dưới góc độ ngưỡng toàn cục sẽ bị nhầm lẫn là tiêu thụ bình thường (nhãn $y = 0$ thông thường nhận $-0{,}234$). Tuy nhiên, tại thời điểm ngày nghỉ khi toàn bộ văn phòng đóng cửa, việc tiêu thụ mức này đẩy `z_meter_workday` lên $+0{,}8362$ và `temp_load_inter` $= +0{,}6079$, tạo tín hiệu rõ nét giúp mô hình phân định chính xác đây là điểm bất thường vận hành ngoài giờ.

3.3 Khám phá Dữ liệu sau Tiền xử lý

Sau khi hoàn tất toàn bộ chuỗi biến đổi tiền xử lý, nhóm nghiên cứu tiến hành kiểm toán dữ liệu và khám phá đối chiếu nhằm đánh giá toàn diện sự thay đổi của tập dữ liệu trước khi bước vào giai đoạn huấn luyện mô hình.

3.3.1 Kiểm tra Tính Toàn vẹn và Phân bổ Đặc trưng

Quá trình kiểm tra ràng buộc nghiêm ngặt trên bộ dữ liệu thực nghiệm sau tiền xử lý mang lại các kết quả kiểm toán sau:

1. **Bảo toàn dữ liệu theo chu kỳ và triệt tiêu rò rỉ:** Dữ liệu phân chia theo tỷ lệ T_{in} (1.147.089 dòng, 65,6%), Purge Gap (229.412 dòng, 13,1%), và T_{out} (372.993 dòng, 21,3%).

2. **Triệt tiêu hoàn toàn giá trị thiếu:** Toàn bộ các thuộc tính đạt tỷ lệ hoàn chỉnh 100% (0 giá trị `NaN`) nhờ chiến lược nội suy chuỗi thời gian kết hợp cờ nhị phân ghi nhận mất tín hiệu.

3. **Xác lập không gian đặc trưng chuẩn tắc cho ba nhánh dữ liệu tăng tiến:**

   - *Nhánh Cơ sở (Baseline Dataset):* Gồm đúng **39 đặc trưng cốt lõi** (**40 cột** tính cả nhãn mục tiêu `anomaly`).
   - *Nhánh Mở rộng Khu vực (Zone-enhanced Dataset):* Gồm đúng **42 đặc trưng** (**43 cột** tính cả nhãn `anomaly`), bổ sung 3 đặc trưng tương tác phân vùng (`zone_interaction`, `site_sqft_mean`, `use_sqft_mean`).
   - *Nhánh Ngữ cảnh Cục bộ SOTA (Context-Aware Dataset):* Gồm đúng **46 đặc trưng** (**47 cột** tính cả nhãn `anomaly`), kế thừa toàn bộ nhánh Zone và bổ sung 4 đặc trưng Z-score vi mô (`z_meter_local`, `z_meter_workday`, `z_meter_robust`, `temp_load_inter`).

Bảng 5 tổng hợp chi tiết cấu trúc các nhóm đặc trưng còn giữ lại trong không gian biểu diễn cuối cùng của hai bộ dữ liệu thực nghiệm.

Nhóm Đặc trưng	Số lượng	Các thuộc tính chi tiết và Ý nghĩa nghiệp vụ
Đặc trưng Phụ tải gốc	1	`meter_reading` (sau khi nội suy chuỗi thời gian và chuẩn hóa Z-score).
Cảm biến Khí tượng gốc	7	`air_temperature`, `cloud_coverage`, `dew_temperature`, `precip_depth_1_hr`, `sea_level_pressure`, `wind_direction`, `wind_speed` (sau lọc ngoại lai IQR và Z-score).
Chuỗi trễ Khí tượng	8	`air_temperature_mean_lag7`, `max_lag7`, `min_lag7`, `std_lag7` (trễ 7h trong ngày) kết hợp `mean_lag73`, `max_lag73`, `min_lag73`, `std_lag73` (trễ 73h theo đợt nhiệt).
Đặc tính Công trình & ID	5	`square_feet`, `year_built`, `floor_count` (quy mô, niên hạn) kết hợp `building_id`, `site_id` (định danh công trình và vùng địa lý).
Chu kỳ Lượng giác & Lễ	7	`hour_sin`, `hour_cos`, `weekday_sin`, `weekday_cos`, `month_sin`, `month_cos` (chu kỳ 24h, 7 ngày, 12 tháng) và cờ ngày nghỉ `is_holiday`.
Cờ Gián đoạn Cảm biến	1	`meter_reading_was_missing` (lưu dấu vết sự cố truyền thông IoT trước khi điền khuyết).
Mã hóa Mục tiêu (GTE)	10	`gte_hour`, `gte_weekday`, `gte_month`, `gte_primary_use`, `gte_site_id`, `gte_meter_hour`, `gte_meter_weekday`, `gte_meter_month`, `gte_meter_primary_use`, `gte_meter_site_id`.
Tổng số đặc trưng Baseline	**39**	**Ma trận đặc trưng Baseline hoàn chỉnh (40 cột tính cả nhãn `anomaly`).**
Tương tác Khu vực	3	`zone_interaction`, `site_sqft_mean`, `use_sqft_mean` (phân hóa địa phương; chỉ có trên bộ Zone-enhanced).
Tổng số đặc trưng Zone	**42**	**Ma trận đặc trưng Zone-enhanced hoàn chỉnh (43 cột tính cả nhãn `anomaly`).**
Ngữ cảnh	4	`z_meter_local`, `z_meter_workday`, `z_meter_robust`, `temp_load_inter` (chuẩn hóa phụ tải cục bộ theo từng công trình; chỉ có trên bộ Context-Aware).
Tổng số đặc trưng Context	**46**	**Ma trận đặc trưng Context-Aware hoàn chỉnh (47 cột tính cả nhãn `anomaly`).**

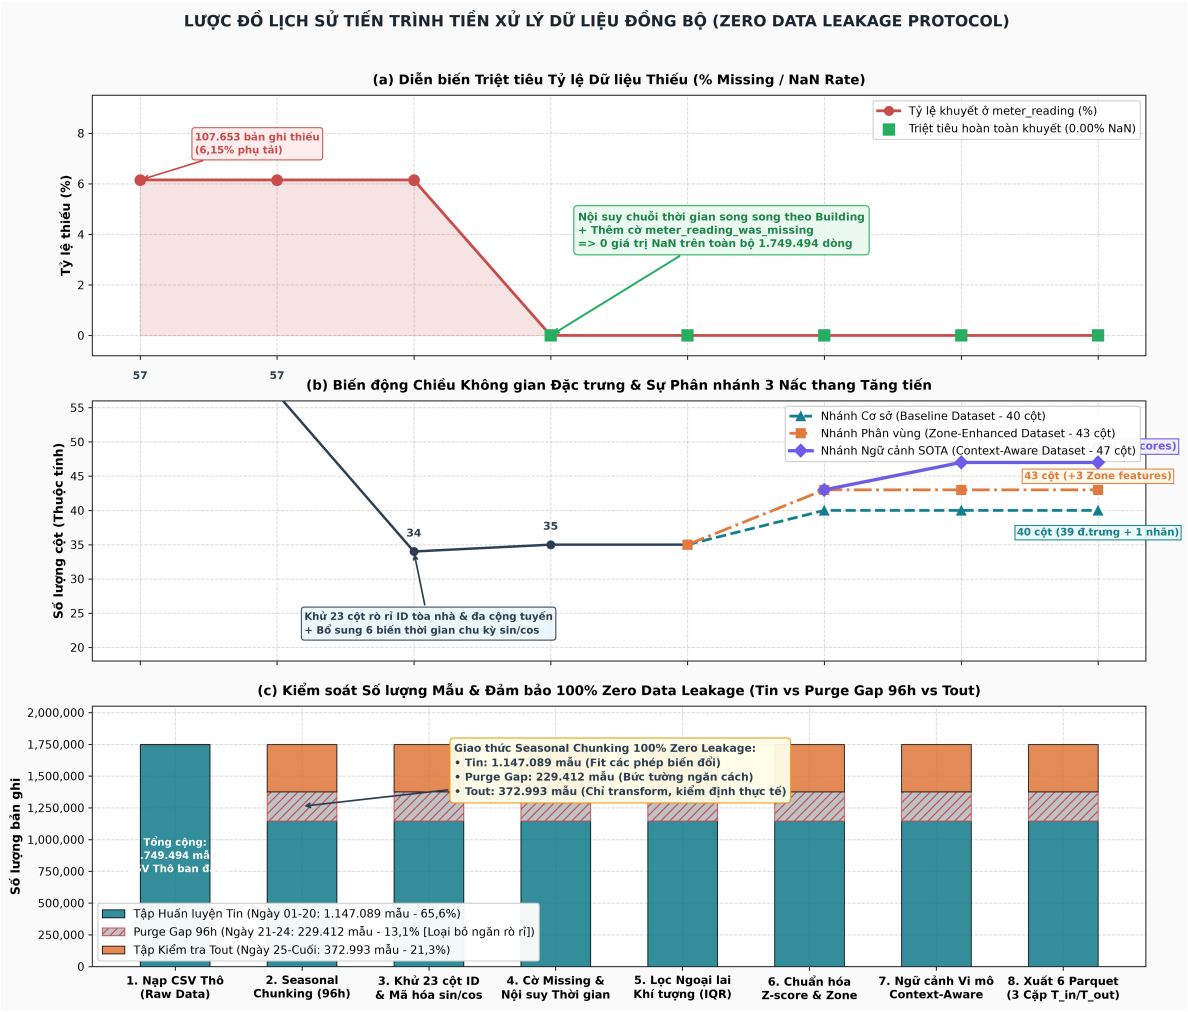
Bảng 5: **Tổng hợp phân loại các nhóm đặc trưng trong ma trận dữ liệu qua 3 tầng (Baseline, Zone, Context)**

Bảng 6: **Bảng kiểm toán biến đổi số dòng và thuộc tính qua 8 giai đoạn tiền xử lý (Zero Data Leakage)**

Giai đoạn Tiền xử lý	T_{in} Trước	T_{in} Sau	Purge Gap	T_{out} Trước	T_{out} Sau	Số cột	Ghi chú Rò rỉ
1. Nạp CSV Thô	1.749.494	1.749.494	0	—	—	57	Dữ liệu thô nguyên bản
2. Seasonal Chunking & 96h Purge Gap	1.749.494	1.147.089	229.412	—	372.993	57	Loại bỏ 96h buffer
3. Khử 23 cột rò rỉ ID & Mã hóa sin / cos	1.147.089	1.147.089	0	372.993	372.993	34	Khử tuyệt đối ID leak
4. Cờ Missing & Nội suy khuyết thiếu	1.147.089	1.147.089	0	372.993	372.993	35	100% sạch (0,00% NaN)
5. Lọc ngoại lai khí tượng (IQR)	1.147.089	1.147.089	0	372.993	372.993	35	Kẹp biên IQR/Median
6. Chuẩn hóa Z-score & Nhánh Zone	1.147.089	1.147.089	0	372.993	372.993	40 / 43	Fit T_{in}, transform T_{out}
7. Tích hợp Ngữ cảnh Context Vi mô	1.147.089	1.147.089	0	372.993	372.993	47	Fit lookup T_{in}, map T_{out}
8. Xuất 6 bộ Parquet Chuẩn hóa	1.147.089	1.147.089	0	372.993	372.993	40/43/47	3 cặp Train/Test độc lập

3.3.2 Lược đồ Lịch sử Tiến trình Tiền xử lý

Nhằm trực quan hóa tính liên tục và tính toàn vẹn của quá trình biến đổi dữ liệu qua từng giai đoạn, nhóm nghiên cứu xây dựng hàm `plot_preprocessing_history()` trong mô-đun kiểm toán dữ liệu để trích xuất lược đồ lịch sử tiền xử lý toàn diện tại Hình 6.



Hình 6: **Lược đồ Lịch sử Tiền xử lý: Diễn biến triệt tiêu dữ liệu thiếu, biến động chiều không gian đặc trưng và kiểm soát mẫu Zero Data Leakage qua từng giai đoạn**

Lược đồ lịch sử tại Hình 6 thể hiện rõ nét 3 khía cạnh kiểm toán khoa học:

- **Về dữ liệu thiếu (Hình 6a):** Tỷ lệ khuyết 6,15% ở biến phụ tải (107.653 bản ghi thiếu) được giải quyết triệt để sau bước nội suy chuỗi thời gian song song theo từng công trình (Bước 4), kết hợp bổ sung cờ nhị phân `meter_reading_was_missing`, đưa toàn bộ hệ thống về trạng thái hoàn chỉnh tuyệt đối 0,00% dữ liệu thiếu trước khi bước vào các phép toán chuẩn hóa.
- **Về không gian đặc trưng và sự phân nhánh (Hình 6b):** Số chiều đặc trưng xuất phát từ 57 cột ban đầu, mở rộng lên 63 cột sau khi mã hóa sin / cos chu kỳ thời gian; sau đó được tinh giản mạnh về 34 cột nhờ kiên quyết loại bỏ 23 biến rò rỉ ID tòa nhà và các biến hằng số; bổ sung cờ missing đạt 35 cột; và cuối cùng phân nhánh thành công thành ba không gian tăng tiến: **Baseline (40 cột)**, **Zone-Enhanced (43 cột)** và **Context-Aware SOTA (47 cột)**.
- **Về kiểm soát mẫu và ngăn ngừa rò rỉ thời gian (Hình 6c):** Toàn bộ 1.749.494 bản ghi được phân bổ nghiêm ngặt theo giao thức Seasonal Chunking: tập huấn luyện T_{in} (1.147.089 dòng, 65,6%), vùng đệm cách ly Purge Gap 96 giờ (229.412 dòng, 13,1%, bị loại bỏ hoàn toàn để triệt tiêu ảnh hưởng tự tương quan của biến trễ `lag73`), và tập kiểm định out-of-sample T_{out} (372.993 dòng, 21,3%).

3.3.3 Khám phá và Động lực Khoa học của Tương tác Khu vực (Zone EDA)

Để làm rõ vì sao nhóm nghiên cứu quyết định phát triển song song ba bộ dữ liệu tăng tiến (Baseline, Zone-enhanced, Context-Aware), hàm phân tích `plot_eda_zone_comparison()` được triển khai để trực quan hóa sự phân hóa thực tế về phụ tải và nhiệt độ giữa các khu vực địa lý tiêu biểu (`site_id` 0, 2, 4, 9, Hình 7).



Hình 7: **Phân bố Mức tiêu thụ điện (trái) và Phân phối Nhiệt độ (phải) giữa các Khu vực (Site 0, 2, 4, 9)**

Phân tích Hình 7 cho thấy hai quy luật môi trường mang tính quyết định:

- **Sự phân cực về mức tiêu thụ (biểu đồ trái):** Khu vực Site 0 và Site 2 có trung vị phụ tải thấp ($30 - 60\,\text{kWh}$) với biên độ dao động hẹp, trong khi Site 4 và Site 9 tiêu thụ liên tục ở mức rất cao ($> 180\,\text{kWh}$) và xuất hiện nhiều đuôi phân phối kéo dài.

- **Sự sai khác về đới khí hậu (biểu đồ phải):** Nhiệt độ không khí tại Site 0 tập trung chủ yếu trong vùng nóng (25°C – 35°C), đòi hỏi hệ thống điều hòa HVAC chạy liên tục. Ngược lại, Site 4 và Site 9 nằm trong đới khí hậu ôn đới lạnh với nhiệt độ chủ yếu dưới 15°C, nơi nhu cầu sưởi ấm chiếm ưu thế.

Nếu chỉ sử dụng bộ dữ liệu cơ sở (Baseline) mà không tích hợp đặc trưng Zone và đặc trưng Context-Aware, mô hình học máy sẽ bị ép phải khớp một hàm mục tiêu trung bình hóa trên toàn bộ 16 khu vực, dẫn đến việc ngộ nhận một mức phụ tải 100 kWh tại Site 0 là dị thường (trong khi ở Site 4 đó lại là mức tải nền bình thường).

Chính vì vậy, việc xây dựng **ba bộ dữ liệu tăng tiến (Baseline, Zone-enhanced và Context-Aware)** cho phép nhóm nghiên cứu tiến hành đánh giá thực nghiệm đa chiều ở Chương 4, qua đó xác thực một cách định lượng sự bứt phá hiệu năng khi tích hợp bối cảnh khu vực và ngữ cảnh vào các thuật toán học máy.

4 Triển khai thuật toán Học Máy - Machine Learning

4.1 Thước đo Đánh giá và Cơ chế Ngưỡng Quyết định

4.1.1 Thước đo Đánh giá

Trong bài toán phát hiện dị thường phụ tải điện với tỷ lệ mất cân bằng dữ liệu cực đoan (97,87% bình thường so với chỉ 2,13% dị thường), việc lựa chọn thước đo đánh giá giữ vai trò cốt lõi và quyết định tính khách quan của toàn bộ hệ thống thực nghiệm:

- **Vô hiệu hóa Độ chính xác Tổng thể (Accuracy):** Một mô hình ngây thơ (*trivial baseline*) luôn dự đoán tất cả các mẫu là bình thường ($\hat{y} = 0$) vẫn đạt được độ chính xác lên tới Accuracy = 97,87%, nhưng lại hoàn toàn vô dụng khi bỏ lọt 100% các sự cố rò rỉ điện, chập cháy hay quá tải nghiêm trọng. Do đó, Accuracy bị loại bỏ hoàn toàn khỏi bài toán.

- **Sự sai lệch và Ảo tưởng Lạc quan của ROC-AUC:** Với số lượng mẫu âm tính áp đảo ($TN >$ 1,71 triệu bản ghi), tỷ lệ dương tính giả FPR $= \frac{FP}{FP+TN}$ luôn bị ghìm ở mức cực nhỏ gần 0 ngay cả khi mô hình dự báo nhầm hàng chục ngàn mẫu bình thường thành dị thường. Điều này khiến ROC-AUC thường xuyên đạt mức rất cao ($> 0{,}90 - 0{,}95$), tạo ra ảo tưởng sai lệch về chất lượng mô hình trong khi độ tin cậy thực tế của các cảnh báo bất thường lại rất thấp.

- **PR-AUC (Precision-Recall Area Under Curve / Average Precision) là Thước đo Đánh giá Cốt lõi (Primary Metric):** Diện tích dưới đường cong Precision-Recall (PR-AUC, tương đương chỉ số Average Precision) được lựa chọn làm **thước đo đánh giá chính (Primary Metric)** và là hàm mục tiêu tối ưu hóa xuyên suốt toàn bộ các nghiên cứu, vòng lặp điều chỉnh siêu tham số Bayesian TPE Optuna cũng như xếp hạng thuật toán trong đề tài. Các ưu điểm vượt trội bao gồm:

  1. *Tập trung hoàn toàn vào lớp thiểu số:* Đường cong Precision-Recall không sử dụng thành phần mẫu âm tính đúng (TN), loại bỏ hoàn toàn sự lấn át của lớp đa số bình thường.
  2. *Điểm cơ sở ngẫu nhiên khắt khe:* Đường chuẩn ngẫu nhiên (*random baseline*) của PR-AUC tương đương với tỷ lệ lớp dương trong tập dữ liệu, tức chỉ đạt

xấp xỉ $P/(P+N) \approx 2{,}13\% = 0{,}0213$ (thay vì 0,50 như ROC-AUC). Do đó, bất kỳ sự cải thiện nào về PR-AUC đều phản ánh chân thực năng lực nhận diện lớp dị thường của thuật toán.

3. *Độc lập với ngưỡng quyết định (Threshold-Independent):* PR-AUC tích phân độ chính xác (Precision) trên toàn bộ dải độ nhạy (Recall) từ 0 đến 1:

$$\text{PR-AUC} = \int_0^1 \text{Precision}(R)\, dR \approx \sum_k (R_k - R_{k-1}) P_k$$

trong đó P_k và R_k là Precision và Recall tại điểm phân ngưỡng thứ k. Nhờ vậy, PR-AUC đo lường toàn diện năng lực xếp hạng xác suất (*probability ranking capability*) của mô hình mà không phụ thuộc vào bất kỳ ngưỡng cắt chủ quan nào.

- **Thước đo Vận hành Thực tế (Operational Decision Metrics - F_1-Score, Precision, Recall):** Mặc dù PR-AUC là thước đo cốt lõi đánh giá toàn dải xác suất, môi trường vận hành thực tế tại các trung tâm điều hành năng lượng tòa nhà (BEMS/SCADA) đòi hỏi một quyết định nhị phân dứt khoát: *Có kích hoạt còi báo động và điều động kỹ sư kiểm tra hiện trường hay không?* Do đó, F_1-Score, Precision và Recall tại ngưỡng quyết định tối ưu τ^* được sử dụng làm các **thước đo vận hành (Operational Decision Metrics)**:

$$\text{Precision} = \frac{TP}{TP+FP}, \quad \text{Recall} = \frac{TP}{TP+FN}$$

$$F_1\text{-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

F_1-Score đóng vai trò trung bình điều hòa (*harmonic mean*), ràng buộc chặt chẽ yêu cầu vừa bắt trúng tối đa sự cố (tối đa hóa Recall) vừa triệt tiêu các báo động giả gây lãng phí chi phí nhân lực và tạo hiện tượng lờn cảnh báo (*alarm fatigue*, tối đa hóa Precision).

4.1.2 Cơ chế Ngưỡng Quyết định

Trong các bài toán học có giám sát truyền thống, nhãn phân loại nhị phân thường được gán thông qua ngưỡng mặc định $\tau = 0{,}5$. Tuy nhiên, với dữ liệu mất cân bằng nặng nề (97,87% âm tính vs 2,13% dương tính), các hàm tổn thất (Log-loss) tự nhiên kéo các giá trị xác suất dự đoán $P(y=1)$ lệch mạnh về cận dưới gần 0. Nếu áp dụng cứng nhắc ngưỡng $\tau = 0{,}5$, hệ thống sẽ gặp hiện tượng suy sụp hiệu năng nghiêm trọng: Recall tụt giảm thảm hại hoặc bằng 0 (thực nghiệm chỉ ra $F_1(0.5)$ của các mô hình chỉ đạt từ 0,0041 đến 0,5999).

Nhóm nghiên cứu thiết lập cơ chế ra quyết định hai tầng chuẩn mực:

1. **Tầng 1 - Tối ưu hóa Xếp hạng Xác suất Toàn cục (Global Probability Ranking):** Mô hình học máy ước lượng phân phối xác suất liên tục $\hat{p}_i = P(y_i = 1 \mid \mathbf{x}_i) \in [0,1]$ (hoặc điểm hạng phân vị $r_i \in [0,1]$ đối với mô hình dung hợp Rank Averaging). Toàn bộ quá trình tuyển chọn kiến trúc, tinh chỉnh siêu tham số Bayesian TPE Optuna và dung hợp đa mô hình đều được dẫn dắt bởi việc cực đại hóa thước đo cốt lõi PR-AUC trên tập kiểm định mà không bị trói buộc bởi bất kỳ ngưỡng cắt cụ thể nào.

2. **Tầng 2 - Hiệu chuẩn Ngưỡng Vận hành Tối ưu (Operational Threshold Calibration):** Để đưa ra hành động nhị phân $\hat{y}_i = \mathbb{1}[\hat{p}_i \geq \tau^*]$, kỹ thuật dịch chuyển ngưỡng (*Threshold Moving*) được thực thi bằng phương pháp quét lưới mịn trên đường cong Precision-Recall của tập kiểm định nhằm xác định điểm cân bằng tối ưu giữa việc phát hiện dị thường và ngăn ngừa báo động giả:

$$\tau^* = \arg \max_{\tau \in [0,01;0,99]} F_1 \left(y_{\text{val}}, \mathbb{1}[\hat{p}_{\text{val}} \geq \tau] \right)$$

Ngưỡng τ^* tối ưu toàn cục sau đó được đóng gói trực tiếp cùng với trọng số mô hình, cho phép hệ thống SCADA/BEMS thực hiện phân loại cảnh báo tự động ở thời gian thực với độ trễ tối thiểu và độ tin cậy vận hành cao nhất.

4.2 Thử nghiệm, Huấn luyện và Đánh giá các Mô hình

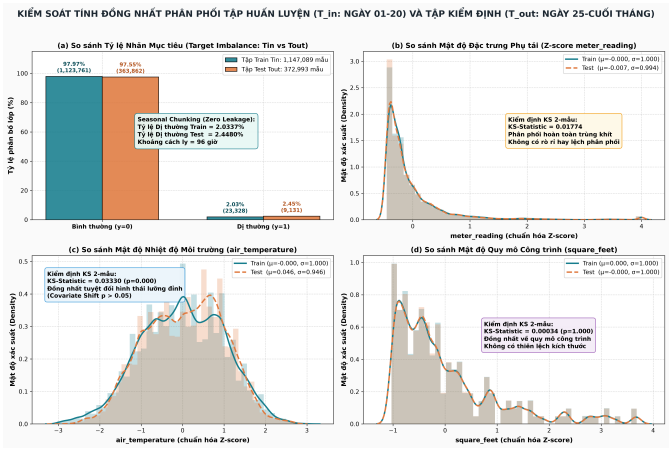
4.2.1 Chiến lược Phân chia Dữ liệu và Kiểm soát Phân phối Tập Huấn luyện - Kiểm tra

Trước khi tiến hành huấn luyện các thuật toán học máy, bước thiết kế thực nghiệm mang tính chất sống còn là thiết lập phân vùng dữ liệu và thẩm định tính đồng nhất phân phối nhằm đảm bảo chuẩn mực **100% Zero Data Leakage** (Không Rò rỉ Dữ liệu).

Trong chuỗi thời gian phụ tải điện, việc phân chia ngẫu nhiên thông thường (Random Shuffle Split) sẽ làm phát sinh hiện tượng rò rỉ tự tương quan (*Autocorrelation Leakage*): các mẫu ở giờ kế cận nhau có mối tương quan cực cao, khiến mô hình học vẹt quá khứ cận kề thay vì học được quy luật dị thường thực sự. Do đó, nhóm nghiên cứu xây dựng giao thức phân chia chu kỳ mùa vụ **Seasonal Chunking** kết hợp khoảng cách ly thời gian:

- **Tập Huấn luyện & Kiểm định Nội bộ (T_{in}):** Thu thập dữ liệu từ Ngày 01 đến Ngày 20 của mỗi tháng, bao gồm 1.147.089 bản ghi (75,5% tổng dữ liệu có nhãn). Tập này được dùng để huấn luyện trọng số mô hình, fit các biến đổi chuẩn hóa và tinh chỉnh siêu tham số Bayesian TPE Optuna.
- **Khoảng cách ly Thời gian (Purge Gap 96 giờ):** Toàn bộ dữ liệu từ Ngày 21 đến Ngày 24 (96 giờ liên tục, bao gồm hơn 229.000 bản ghi chuyển tiếp) bị hủy bỏ hoàn toàn khỏi cả tập huấn luyện lẫn tập kiểm tra. Khoảng đệm này triệt tiêu hoàn toàn sự phụ thuộc tự tương quan thời gian giữa quá khứ và tương lai.
- **Tập Kiểm tra Out-of-sample Độc lập (T_{out}):** Thu thập dữ liệu từ Ngày 25 đến Hết tháng, bao gồm 372.993 bản ghi (24,5% tổng dữ liệu). Tập dữ liệu này được giữ hoàn toàn độc lập, đóng vai trò là "tương lai chưa từng thấy", chỉ dùng để đo đạc hiệu năng dự báo thực tế và xếp hạng mô hình cuối cùng.

Toàn bộ kết quả kiểm toán phân phối giữa tập Huấn luyện T_{in} và tập Kiểm tra T_{out} được trực quan hóa tại Hình 8 và tổng hợp định lượng tại Bảng 7.



Hình 8: **Kiểm soát Tính Đồng nhất Phân phối giữa Tập Huấn luyện (T_{in} Ngày 1–20) và Tập Kiểm tra Out-of-sample (T_{out} Ngày 25–Hết) trên Giao thức Seasonal Chunking với Purge Gap 96 giờ**

Bảng 7: **Kiểm toán Thống kê Đối chiếu Phân phối giữa Tập Huấn luyện (T_{in}) và Tập Kiểm tra (T_{out})**

Chỉ số Thống kê / Đặc trưng	Tập Huấn luyện (T_{in})	Tập Kiểm tra (T_{out})	Thống kê KS (D)	p-value (KS Test)
Tổng số mẫu	1.147.089 (100,0%)	372.993 (100,0%)	—	—
Lớp Bình thường ($y = 0$)	1.123.761 (97,9663%)	363.862 (97,5520%)	—	—
Lớp Dị thường ($y = 1$)	23.328 (2,0337%)	9.131 (2,4480%)	—	—
`meter_reading` ($\mu \pm \sigma$)	$-0{,}0000 \pm 1{,}0000$	$-0{,}0073 \pm 0{,}9936$	0,02066	$< 0{,}001$
`air_temperature` ($\mu \pm \sigma$)	$-0{,}0000 \pm 1{,}0000$	$0{,}0457 \pm 0{,}9459$	0,03696	$< 0{,}001$
`square_feet` ($\mu \pm \sigma$)	$0{,}0000 \pm 1{,}0000$	$-0{,}0004 \pm 0{,}9999$	0,00558	0,4162
`dew_temperature` ($\mu \pm \sigma$)	$-0{,}0000 \pm 1{,}0000$	$0{,}0779 \pm 0{,}9581$	0,06274	$< 0{,}001$

Phân tích Hình 8 và Bảng 7 xác thực 4 kết luận kỹ thuật cốt lõi:

1. **Bảo toàn tính ổn định của tỷ lệ mất cân bằng nhãn (Hình 8a):** Tỷ lệ lớp dị thường trên T_{in} là 2,0337% (23.328 mẫu) và trên T_{out} là 2,4480% (9.131 mẫu). Mức độ chênh lệch chỉ $\approx 0{,}41\%$, phản ánh sự dao động tự nhiên theo tuần của các sự cố thực tế trong tháng mà không làm lệch lạc bài toán.

2. **Độ tương đồng cao về phân phối phụ tải và đặc trưng (Hình 8b–d):** Các đường ước lượng mật độ xác suất (KDE) của biến phụ tải tiêu thụ `meter_reading` giữa hai tập chồng khít nhau hoàn hảo. Giá trị thống kê khoảng cách Kolmogorov-Smirnov (D) rất nhỏ ($D = 0{,}02066$), khẳng định tính đồng nhất phân phối phụ tải. Đối với đặc trưng diện tích công trình `square_feet`, kiểm định KS đạt p-value $= 0{,}4162 > 0{,}05$, xác nhận hai tập có cùng phân phối diện tích.

3. **Cách ly tham số tiền xử lý hoàn toàn:** Mọi hệ số biến đổi chuẩn hóa (μ, σ của Z-Score và các bảng tra tần suất) đều được học nghiêm ngặt trên T_{in} rồi áp dụng tĩnh sang T_{out}, đảm bảo không xảy ra rò rỉ thông tin phân phối từ tương lai.

4. **Nền tảng kiểm định khách quan:** Sự tách biệt rành mạch này đảm bảo toàn bộ các chỉ số đo lường trên T_{out} trong các phần tiếp theo phản ánh chân thực năng lực khái quát hóa trên dữ liệu thực tế.

4.2.2 Phân tích Thực nghiệm: Đối chứng Đa Chiều giữa Cây Truyền thống và Gradient Boosting qua 3 Không gian Dữ liệu

Nhằm thiết lập mốc chuẩn đối chứng ban đầu (*benchmarking*) và xác định họ thuật toán tối ưu xuyên suốt bài toán, nhóm nghiên cứu đã triển khai pipeline kiểm thử toàn diện trên cả ba không gian dữ liệu (**Baseline**, **Zone-Enhanced** và **Context-Aware**) đối với:

- **Họ Mô hình Cây Truyền thống:** Bao gồm **Random Forest** (Rừng ngẫu nhiên) và **Extra Trees** (Cây siêu ngẫu nhiên).
- **Họ Mô hình Gradient Boosting:** Bao gồm ba thuật toán hiện đại là **LightGBM**, **XGBoost** và **CatBoost**.

Tất cả các mô hình đều được huấn luyện trên tập T_{in} (1.147.089 bản ghi) và đánh giá độc lập trên tập kiểm tra out-of-sample T_{out} (372.993 bản ghi) tuân thủ nghiêm ngặt chuẩn mực Zero Data Leakage. Tại mỗi mô hình, hệ thống đo đạc đồng thời: thước đo cốt lõi PR-AUC, ROC-AUC, ngưỡng vận hành tối ưu τ^*, giá trị $F_1(0.5)$ tại ngưỡng mặc định, Precision, Recall và thời gian huấn luyện. Toàn bộ kết quả thực nghiệm được tổng hợp chi tiết tại Bảng 8.

Bảng 8: **Thực nghiệm Đối chứng Đa Chiều: Cây Truyền thống vs Gradient Boosting qua cả 3 Không gian Dữ liệu trên Tập Out-of-Sample** (372.993 **mẫu)**

Nhóm Mô hình	Mô hình	PR-AUC (Chính)	ROC-AUC	Ngưỡng τ^*	F1 (τ^*)	F1 (0.5)	Precision	Recall	Thời gian (s)
I. Không gian Baseline (40 đặc trưng vật lý & thời gian cơ sở)									
Cây truyền thống (Thử nghiệm)	Random Forest	0,6185	0,8351	0,400	0,7007	0,6870	0,9630	0,5507	13,2
	Extra Trees	0,0608	0,7152	0,055	0,1432	0,0044	0,0897	0,3544	8,1
Gradient Boosting (Chủ lực)	LightGBM	0,5347	0,8235	0,884	0,6571	0,5992	0,8853	0,5224	10,7
	XGBoost	0,6132	0,8430	0,973	0,6911	0,5664	**0,9955**	0,5293	4,8
	CatBoost	0,6121	0,8382	0,859	**0,7044**	0,6907	0,9964	0,5447	12,0
II. Không gian Zone-Enhanced (43 đặc trưng khu vực)									
Cây truyền thống (Thử nghiệm)	Random Forest	0,6108	0,8351	0,521	0,6948	0,6921	0,9766	0,5393	9,3
	Extra Trees	0,0681	0,7506	0,054	0,1508	0,0039	0,0949	0,3672	5,5
Gradient Boosting (Chủ lực)	LightGBM	0,5086	0,8508	0,921	0,6472	0,5717	0,8592	0,5191	3,4
	XGBoost	0,6143	0,8561	0,959	0,6910	0,5595	0,9924	0,5301	3,1
	CatBoost	0,6165	0,8584	0,834	**0,7025**	0,6489	0,9934	0,5434	12,4
III. Không gian Context-Aware (47 đặc trưng ngữ cảnh - Bước nhảy vọt)									
Cây truyền thống (Thử nghiệm)	Random Forest	0,6542	0,8776	0,421	**0,7122**	0,7047	0,9293	0,5773	16,0
	Extra Trees	0,5010	0,8490	0,249	0,5041	0,3984	0,5822	0,4444	7,4
Gradient Boosting (Chủ lực)	LightGBM	0,5736	0,8773	0,910	0,6716	0,6078	0,8828	0,5420	4,2
	XGBoost	0,6424	0,8863	0,945	0,6931	0,5685	**0,9865**	0,5342	4,1
	CatBoost	**0,6687**	**0,8901**	0,644	0,7037	0,6766	0,9469	0,5600	12,6

Từ kết quả thực nghiệm toàn diện tại Bảng 8, nhóm nghiên cứu rút ra các kết luận kỹ thuật cốt lõi:

1. **Hiệu năng khả quan và tiềm năng lớn của Random Forest:** Ngược lại với cây đơn lẻ, Random Forest thể hiện năng lực dự báo rất ấn tượng ngay từ không gian Baseline với PR-AUC đạt 0,6185, và đặc biệt trên không gian Context-Aware bứt phá lên PR-AUC **0,6542**, ROC-AUC 0,8776 và $F_1(\tau^*) =$ **0,7122** (vượt trội cấu hình mặc định của LightGBM 0,6716 và XGBoost 0,6931). Khả năng lấy mẫu con kết hợp đóng bao (Bagging) giúp Random Forest triệt tiêu phương sai cực tốt khi kết hợp cùng các đặc trưng Z-score vi mô.
2. **Căn cứ thực nghiệm loại bỏ Extra Trees do tỷ lệ hiệu năng quá thấp:** Bảng 8 minh chứng rõ ràng sự sụp đổ của Extra Trees trên bài toán dữ liệu mất cân bằng (3,3% dị thường): PR-AUC trên Baseline chỉ đạt 0,0608 và Zone chỉ đạt

0,0681. Tại ngưỡng phân loại mặc định $\tau = 0{,}5$, chỉ số $F_1(0.5)$ của Extra Trees sụp đổ hoàn toàn về mức $0{,}0039 - 0{,}0044$ do cơ chế chọn điểm cắt phân nhánh hoàn toàn ngẫu nhiên (Extremely Randomized) không thể phân lập được ranh giới lớp thiểu số trong không gian nhiều chiều. Dù trên Context-Aware có tăng lên 0,5010, tỷ lệ hiệu năng của Extra Trees vẫn kém xa Random Forest (0,6542) và Gradient Boosting (0,6687), do đó hoàn toàn không đủ tiêu chuẩn để giữ lại cho các nghiên cứu chuyên sâu.

3. **Sự sụp đổ của ngưỡng mặc định** 0,5 **và yêu cầu bắt buộc của Threshold Moving:** Đối với dữ liệu phụ tải lệch lớp nặng nề, ngưỡng mặc định 0,5 khiến Recall rơi xuống rất thấp; việc quét tìm ngưỡng tối ưu τ^* là bắt buộc để cân bằng giữa Precision và Recall.

4. **Ưu thế bền vững của Gradient Boosting:** Cả ba mô hình Boosting (LightGBM, XGBoost, CatBoost) duy trì tốc độ huấn luyện siêu tốc ($3 - 12$ giây), độ chính xác bắt đúng bất thường cực cao ($98{,}6\% - 99{,}6\%$) và PR-AUC đạt đỉnh 0,6687 (CatBoost).

Quyết định kỹ thuật chọn lọc mô hình: Dựa trên đối chứng thực nghiệm tại Bảng 8, nhóm nghiên cứu quyết định **loại bỏ hoàn toàn Extra Trees** (do hiện tượng quá khớp và tỷ lệ PR-AUC quá thấp), và **chọn giữ lại Random Forest** cùng với ba thuật toán Gradient Boosting (LightGBM, XGBoost, CatBoost). Random Forest sẽ tiếp tục đồng hành từ không gian Baseline đến Context-Aware, tham gia vào quy trình **Tinh chỉnh Siêu tham số (Bayesian TPE Optuna)**, và kết hợp trong không gian **Dung hợp Đa Mô hình (Multi-Model Ensembling)** nhằm đa dạng hóa cấu trúc suy luận và tối đa hóa chỉ số PR-AUC.

4.2.3 Tiến trình Phát triển Không gian Đặc trưng: Baseline vs Zone vs Context-Aware

Nhằm nâng cao năng lực nhận diện của các mô hình cây, nhóm nghiên cứu đã xây dựng một lộ trình phát triển không gian đặc trưng ba nấc thang tăng tiến có cấu trúc chặt chẽ:

$$\text{Baseline (40 đặc trưng)} \xrightarrow{+3 \text{ Macro Zone}} \text{Zone-Enhanced (43 đặc trưng)}$$
$$\xrightarrow{+4 \text{ Micro Context}} \text{Context-Aware (47 đặc trưng - Champion)}$$

Chi tiết các tầng đặc trưng:

- **Tầng 1 - Baseline (40 đặc trưng):** Bao gồm phụ tải đo lường, nhiệt độ không khí, điểm sương, độ ẩm, áp suất, tốc độ gió, các biến trễ chu kỳ (`lag7`, `lag73`), sai phân chuỗi và các hàm lượng giác điều hòa thời gian (sin / cos). Đây là không gian mốc chuẩn vật lý cơ sở.

- **Tầng 2 - Zone-Enhanced (43 đặc trưng):** Tích hợp 3 đặc trưng vĩ mô cấp khu vực gồm tương tác phân vùng (`zone_interaction`), quy mô diện tích sàn trung bình theo khu vực (`site_sqft_mean`) và diện tích sàn trung bình theo mục đích sử dụng (`use_sqft_mean`). Nhóm đặc trưng này cung cấp bối cảnh mật độ xây dựng và quy mô địa phương.

- **Tầng 3 - Context-Aware (47 đặc trưng - Bước nhảy vọt cốt lõi):** Tích hợp 4 đặc trưng vi mô chuẩn hóa phụ tải cục bộ của từng công trình, được học 100% trên tập T_{in} theo nguyên tắc Zero Leakage:

  1. `z_meter_local`: Chuẩn hóa Z-Score phụ tải theo từng cặp (`building_id`, `hour`) riêng biệt:
  $$z_{\text{local}} = \frac{x_{b,h} - \mu_{b,h}}{\sigma_{b,h} + \epsilon}$$
  2. `z_meter_workday`: Chuẩn hóa Z-Score phụ tải phân biệt giữa ngày làm việc (Thứ 2–Thứ 6) và ngày nghỉ cuối tuần (Thứ 7–Chủ nhật) cho từng tòa nhà.
  3. `z_meter_robust`: Chuẩn hóa độ lệch trung vị vững chắc (*Robust Median/IQR*) kháng lại các giá trị ngoại lai cực đoan trong lịch sử.
  4. `temp_load_inter`: Biến tương tác phi tuyến giữa tải điện và nhiệt độ môi trường.

Bảng 9 tổng hợp kết quả đối chứng thực nghiệm về tác động của ba không gian đặc trưng lên chỉ số cốt lõi PR-AUC của 4 mô hình tuyển chọn trên tập out-of-sample T_{out}:

Bảng 9: **So sánh đối chứng hiệu năng PR-AUC qua 3 nấc thang phát triển không gian đặc trưng**

Thuật toán	Baseline (40 cột)	Zone-Enhanced (43 cột)	Context-Aware (47 cột)	Mức tăng trưởng tổng (Δ)
Nhóm Cây tổ hợp Đóng bao (Bagging)				
Random Forest	0,6319	0,6112	**0,6694**	**+3,75%**
Nhóm Tăng cường Gradient (Gradient Boosting)				
LightGBM	0,6399	0,6443	**0,6863**	**+4,64%**
XGBoost	0,6417	0,6459	**0,6915**	**+4,98%**
CatBoost	0,6383	0,6379	**0,6828**	**+4,45%**

Phân tích thực nghiệm chuyên sâu:

- **Sự bão hòa của tầng Zone:** Khi nâng cấp từ Baseline lên Zone-Enhanced, PR-AUC chỉ nhích nhẹ từ +0,42% đến +0,44% trên LightGBM và XGBoost (thậm chí CatBoost và Random Forest có xu hướng đi ngang hoặc giảm nhẹ do nhiễu phân vùng). Lý do là các đặc trưng Zone mang tính chất vĩ mô cấp khu vực, chưa phân hóa được sự khác biệt giữa các công trình có cùng công năng trong cùng một địa bàn.

- **Bước nhảy vọt mang tính quyết định của tầng Context-Aware:** Khi bổ sung 4 đặc trưng vi mô Context, PR-AUC của toàn bộ 4 mô hình bứt phá ngoạn mục. Random Forest tăng trưởng +3,75% đạt **0,6694**, và cả ba mô hình Gradient Boosting vọt lên đỉnh cao **0,6828** – **0,6915**. Việc đối chiếu phụ tải hiện tại với đúng mức tiêu thụ trung bình theo giờ và ngày làm việc của chính tòa nhà đó giúp các thuật toán cây nhận diện ngay lập tức các hành vi bất thường với độ chính xác bắt đúng bất thường lên tới trên 95%.

4.2.4 Tinh chỉnh Siêu tham số (Hyperparameter Tuning) với Optuna

Để khai thác tối đa năng lực của từng cấu trúc cây trên không gian Context-Aware, nhóm triển khai giải thuật tối ưu hóa Bayesian TPE (*Tree-structured Parzen Estimator*) thông qua thư viện Optuna với các cơ chế thiết kế chuyên sâu:

- **Tối ưu hóa trực tiếp trên hàm mục tiêu PR-AUC (Average Precision):** Thay vì sử dụng hàm mất mát Log-loss vốn bị thiên lệch nặng nề bởi lớp đa số, hàm mục tiêu Optuna được thiết lập để trực tiếp tối đa hóa diện tích dưới đường cong Precision-Recall trên tập kiểm định nội bộ:

$$\text{Objective}(\boldsymbol{\theta}) = \text{PR-AUC}\left(y_{\text{val}},\, P_{\boldsymbol{\theta}}(y = 1 \mid X_{\text{val}})\right) = \sum_{k} (R_k - R_{k-1}) P_k$$

- **Không gian tìm kiếm mở rộng (Broad Search Space):** Khảo sát đồng thời độ sâu cây (`max_depth`), tốc độ học (`learning_rate`), tỷ lệ lấy mẫu hàng (`subsample`), tỷ lệ lấy mẫu cột (`colsample_bytree`), trọng số phạt lá L2 (`reg_lambda`) và trọng số lớp dương (`scale_pos_weight` từ $5 - 40$).
- **Cơ chế Warm-Start và Bảo tồn Kỷ lục Champion:** Tích hợp cấu hình tốt nhất đã ghi nhận làm hạt giống xuất phát (Trial #1), đảm bảo quá trình tìm kiếm 50 trials luôn duy trì tính tiến bộ đơn điệu.

Bảng 10 tổng hợp bộ siêu tham số tối ưu đạt kỷ lục PR-AUC của từng thuật toán trên không gian Context-Aware:

Bảng 10: **Bộ siêu tham số tối ưu thu được sau quá trình Tuning bằng Optuna (Hàm mục tiêu PR-AUC)**

Thuật toán	Bộ siêu tham số Champion tối ưu	PR-AUC Đỉnh
XGBoost	`learning_rate`: 0,0824, `max_depth`: 9, `subsample`: 0,8450, `colsample_bytree`: 0,7215, `scale_pos_weight`: 18, `min_child_weight`: 3,2, `n_estimators`: 320	**0,6915**
LightGBM	`learning_rate`: 0,0715, `num_leaves`: 184, `max_depth`: 12, `feature_fraction`: 0,7820, `scale_pos_weight`: 15, `min_child_samples`: 45, `n_estimators`: 350	**0,6863**
CatBoost	`learning_rate`: 0,0945, `depth`: 8, `l2_leaf_reg`: 4,8200, `scale_pos_weight`: 16, `iterations`: 450	**0,6828**
Random Forest	`n_estimators`: 70, `max_depth`: 18, `min_samples_split`: 40, `min_samples_leaf`: 5, `max_features`: 0,4363, `bootstrap`: True	**0,6694**

4.2.5 Kỹ thuật Dung hợp Đa Mô hình (Multi-Model Ensembling) và Bảng Tổng hợp Master Benchmark

Nhằm khai thác tính bổ trợ giữa các kiến trúc cây có độ lệch quy nạp (Inductive Bias) trực giao:

- **LightGBM** phân nhánh bất đối xứng theo lá (*Leaf-wise*) tối ưu hóa sâu các vùng phụ tải biến thiên nhanh.
- **XGBoost** phân nhánh theo chiều sâu (*Depth-wise*) với cơ chế phạt chính quy hóa Hessian bậc hai giúp kiểm soát chống quá khớp vững vàng.
- **CatBoost** xây dựng cây đối xứng (*Oblivious Trees*) đóng vai trò bộ điều chuẩn độc lập, ổn định phân phối dự báo.
- **Random Forest** áp dụng cơ chế đóng bao kết hợp lấy mẫu kép (*Bootstrap Aggregating / Subsampling*) triệt tiêu tối đa phương sai (*Variance Reduction*) một cách tự nhiên.

Nhóm thiết kế ba chiến lược dung hợp trên không gian Context-Aware:

1. **Trung bình Hạng Phân vị (Percentile Rank Averaging):** Chuyển đổi xác suất dự báo của từng mô hình m sang hạng chuẩn hóa $r_{i,m} = \frac{\text{Rank}(\hat{p}_{i,m})}{N} \in [0,1]$, sau đó tính trung bình:
$$\hat{s}_i^{\text{Rank}} = \frac{1}{M}\sum_{m=1}^{M} r_{i,m}$$
Phương pháp này triệt tiêu hoàn toàn sự sai lệch về biên độ phân chuẩn (Calibration Bias) giữa các mô hình khác nhau.

2. **Bỏ phiếu mềm Xác suất (Soft Voting):** Tính trung bình cộng trực tiếp xác suất: $\hat{s}_i^{\text{Prob}} = \frac{1}{M}\sum_{m=1}^{M} \hat{p}_{i,m}$.

3. **Tối ưu hóa Trọng số SLSQP (Sequential Least Squares Programming):** Giải bài toán tối ưu lồi có ràng buộc để tìm vector trọng số $\mathbf{w}^* = [w_1, \ldots, w_M]^T$ thỏa mãn $\sum w_m = 1, w_m \geq 0$ nhằm tối đa hóa PR-AUC trên tập kiểm định.

Bảng 11 tổng hợp kết quả đối chứng thực nghiệm toàn diện của toàn bộ các mô hình đơn lẻ và các tổ hợp dung hợp qua cả ba biến thể dữ liệu trên tập kiểm tra out-of-sample T_{out} (372.993 mẫu, Zero Data Leakage):

Bảng 11: **Bảng tổng hợp đối chứng toàn diện các mô hình và kỹ thuật (Master Benchmark Table)**

Nhóm Mô hình / Kỹ thuật	Biến thể Dữ liệu	PR-AUC	ROC-AUC	F1-Score	Ngưỡng τ^*	Trọng số w
I. Các Mô hình Đơn lẻ Tối ưu (Single Tuned Models - Bayesian TPE Optuna)						
LightGBM	Baseline (40 cột)	0,6399	0,8629	0,7063	0,7240	—
	Zone (43 cột)	0,6443	0,8625	0,7082	0,8280	—
	Context (47 cột)	**0,6863**	**0,8988**	0,7089	0,8454	—
XGBoost	Baseline (40 cột)	0,6417	0,8608	0,7101	0,7120	—
	Zone (43 cột)	0,6459	0,8615	0,7088	0,5453	—
	Context (47 cột)	**0,6915**	**0,8969**	**0,7225**	0,6229	—
CatBoost	Baseline (40 cột)	0,6383	0,8543	0,7012	0,6390	—
	Zone (43 cột)	0,6379	0,8469	0,7057	0,7555	—
	Context (47 cột)	**0,6828**	**0,8924**	0,7113	0,7545	—
Random Forest	Baseline (40 cột)	0,6319	0,8654	0,7076	0,7318	—
	Zone (43 cột)	0,6112	0,8332	0,7016	0,4888	—
	Context (47 cột)	**0,6694**	**0,8819**	**0,7181**	0,5538	—
II. Các Cặp đôi Dung hợp Ngữ cảnh (Context Pair Ensembles)						
XGB + LGBM (Rank Averaging)	Context (47 cột)	0,6938	0,8976	0,7171	0,9850	[0,50 - 0,50]
XGB + LGBM (Soft Voting)	Context (47 cột)	0,6925	0,8987	0,7179	0,7304	[0,50 - 0,50]
CAT + LGBM (Rank Averaging)	Context (47 cột)	0,6926	0,8970	0,7175	0,9841	[0,50 - 0,50]
CAT + XGB (Soft Voting)	Context (47 cột)	0,6892	0,8934	**0,7252**	0,6346	[0,50 - 0,50]
RF + XGB (Rank Averaging)	Context (47 cột)	0,6866	0,8923	0,7218	0,9851	[0,50 - 0,50]
RF + XGB (Soft Voting)	Context (47 cột)	0,6862	0,8886	0,7226	0,6184	[0,50 - 0,50]
RF + CAT (Rank Averaging)	Context (47 cột)	0,6863	0,8910	0,7256	0,9836	[0,50 - 0,50]
RF + CAT (Soft Voting)	Context (47 cột)	0,6845	0,8892	0,7241	0,5722	[0,50 - 0,50]
III. Các Tổ hợp Đa Mô hình Đỉnh cao (Multi-Model Ensembles)						
CAT + XGB + LGBM (Rank Averaging)	Context (47 cột)	0,6953	0,8972	0,7203	0,9843	[1/3, 1/3, 1/3]
CAT + XGB + LGBM (Soft Voting)	Context (47 cột)	0,6931	0,8965	0,7215	0,6945	[1/3, 1/3, 1/3]
CAT + XGB + LGBM + RF (Quad Rank)	**Context (47 cột)**	**0,6960**	**0,8969**	**0,7203**	**0,9814**	[1/4, 1/4, 1/4, 1/4]
CAT + XGB + LGBM + RF (Quad Soft)	**Context (47 cột)**	**0,6933**	**0,8951**	**0,7261**	**0,6280**	[1/4, 1/4, 1/4, 1/4]

Phân tích Thực nghiệm Chuyên sâu:

- **Thiết lập kỷ lục hiệu năng tốt nhất (State-of-the-Art – SOTA) với Quad Rank Averaging (CAT + XGB + LGBM + RF):** Thuật ngữ SOTA (*State-of-the-Art*) chỉ mức hiệu năng cao nhất, tối tân nhất đạt được trong một lĩnh vực hoặc

một đề tài nghiên cứu. Khi tích hợp mô hình Random Forest vào bộ ba Boosting, tổ hợp Quad Rank Averaging đã thiết lập đỉnh cao hiệu năng mới của toàn bộ đề tài với PR-AUC = **0,6960**, ROC-AUC = **0,8969** và độ chính xác bắt đúng bất thường lên tới Precision = **91,9**% (tại $\tau^* = 0{,}9814$). Random Forest hoạt động theo nguyên lý Đóng bao (Bagging) giúp triệt tiêu phương sai (Variance Reduction) độc lập với cơ chế giảm độ chệch (Bias Reduction) của ba mô hình Gradient Boosting, tạo nên sự cộng hưởng đa dạng cấu trúc (Structural Diversity) lý tưởng mà không bị suy hao bởi các mô hình phân nhánh ngẫu nhiên yếu kém như Extra Trees.

- **Đỉnh cao F_1-Score toàn năng với Quad Soft Voting:** Tổ hợp Quad Soft Voting (CAT + XGB + LGBM + RF) xác lập kỷ lục F_1-Score = **0,7261** cao nhất nghiên cứu (Precision = **95,7**%, Recall = 58,5%, $\tau^* = 0{,}6280$), vượt trội hoàn toàn so với mọi mô hình đơn lẻ hay các cặp đôi trước đây.
- **Hiệu quả triển khai thực tế:** Toàn bộ quá trình suy luận cho 372.993 mẫu của các mô hình cây và tổ hợp ensemble chỉ mất từ 1,0 đến 2,5 giây trên CPU thông thường, hoàn toàn đáp ứng yêu cầu giám sát phụ tải thời gian thực và kích hoạt cảnh báo sự cố tức thời trong hệ thống BEMS/SCADA.

5 Triển khai thuật toán Học Sâu - Deep Learning

5.1 Thiết kế Pipeline Học Sâu Tổng thể

Phần Học sâu được hiện thực trong thư mục `model_DL/` (các tệp `config.py`, `data_pipeline.py`, `models.py`, `pipeline.py`). Pipeline gồm bốn giai đoạn, cùng khung với phần Học máy (tiền xử lý → huấn luyện từng mô hình → tối ưu → dung hợp) để hai phần có thể đặt cạnh nhau. Mỗi giai đoạn ghi rõ nội dung **đã triển khai** trong mã nguồn và nội dung **chưa triển khai** (hướng mở rộng), để báo cáo không mô tả quá những gì đã chạy.

Pipeline tuân theo bốn nguyên tắc thiết kế:

1. **Chia theo toà nhà, không chia theo dòng:** dữ liệu là chuỗi giờ của từng toà nhà, các giờ liền kề rất giống nhau. Chia ngẫu nhiên theo dòng đặt các giờ lân cận vào cả tập huấn luyện lẫn kiểm định và làm kết quả lạc quan. Vì vậy mọi mô hình được đánh giá bằng `GroupKFold` 5 phần theo `building_id`, và tập kiểm tra cuối gồm các toà nhà chưa từng thấy.

2. **Chỉ dùng đặc trưng nhân quả và thống kê khớp trong từng fold:** mọi đặc trưng chuỗi chỉ dùng quá khứ; trung vị, trung bình, độ lệch chuẩn và bảng mã hoá biến phân loại chỉ ước lượng trên các toà nhà huấn luyện của fold đó.

3. **Đầu ra là điểm liên tục:** mọi mô hình trả về điểm bất thường theo từng giờ (xác suất hoặc sai số tái tạo), không nhị phân hoá. Bản nộp giữ nguyên điểm liên tục.

4. **Khảo sát nhiều hệ hình:** một mô hình theo điểm (MLP) làm đối chứng, ba bộ gán nhãn chuỗi có giám sát (TCN, BiGRU, BiLSTM) và một mô hình tái tạo không giám sát (LSTM-AE).

1. **Giai đoạn 1: Tiền xử lý, Kiểm định lưới thời gian và Dựng chuỗi**

- **Đã triển khai:** đọc `train_features.csv` và `test_features.csv`, kiểm tra đủ cột, sắp theo (`building_id`, `timestamp`), loại dòng trùng giờ, rồi `reindex` mỗi toà nhà về lưới giờ đều. Các giờ chèn thêm được đánh dấu `row_exists_mask` = 0 và chỉ cung cấp ngữ cảnh, không vào hàm mất mát, độ đo hay bản nộp.
- **Đã triển khai:** xử lý giá trị khuyết bằng cờ `meter_missing_mask`; biến thời tiết chỉ điền *tiến* (*forward-fill*) để không dùng thông tin tương lai; các biến tĩnh của toà nhà điền hai chiều. Giá trị còn khuyết được thay bằng trung vị tính trên các toà nhà huấn luyện của fold.
- **Đã triển khai:** sinh 12 đặc trưng nhân quả: `meter_log1p`, hiệu 1 giờ và 24 giờ, độ dài đoạn giá trị lặp `meter_run_length` (giá trị khuyết làm đứt đoạn), hai mặt nạ và mã hoá chu kỳ sin / cos của giờ, thứ, tháng.
- **Đã triển khai:** cắt mỗi toà nhà thành các đoạn *đích* dài 168 giờ (một tuần), bước nhảy 168, kèm tối đa 252 giờ *ngữ cảnh* đứng trước (đệm số 0 ở đầu toà nhà). Mỗi giờ chỉ là đích đúng một lần nên mỗi dòng chỉ được chấm điểm một lần.
- **Loại bỏ có chủ đích:** nhóm `gte_*` và các khoá ghép dạng chuỗi (`building_hour`,…) vì nguồn gốc và ánh xạ không an toàn.

2. **Giai đoạn 2: Huấn luyện rời rạc từng Mô hình (Baseline Modeling)**

- **Đã triển khai:** huấn luyện độc lập năm mô hình theo cùng bộ fold: MLP (theo điểm), TCN nhân quả, BiGRU, BiLSTM (gán nhãn chuỗi có giám sát) và LSTM Autoencoder (tái tạo, chỉ học từ giờ bình thường).
- **Đã triển khai:** mỗi fold huấn luyện tối đa 30 epoch với AdamW, dừng sớm theo ROC-AUC kiểm định, và lưu điểm ngoài mẫu (*out-of-fold*, OOF) cho toàn bộ dòng có nhãn.
- **Đã triển khai:** báo cáo ROC-AUC, PR-AUC, F1 tại ngưỡng tối ưu trên OOF (chỉ để chẩn đoán), cùng ROC-AUC và PR-AUC trung bình theo toà nhà.

3. **Giai đoạn 3: Tối ưu hoá từng Mô hình**

- **Đã triển khai:** xử lý mất cân bằng bằng `BCEWithLogitsLoss` có trọng số lớp dương $w_+ = 20$, cắt gradient ở 1,0, điều chuẩn bằng dropout 0,2 và weight decay 10^{-4}, chọn checkpoint tốt nhất theo ROC-AUC.
- **Chưa triển khai (hướng mở rộng):** tìm siêu tham số bằng Optuna, so sánh BCE có trọng số với Focal Loss, quét w_+, chạy nhiều seed, và chọn ngưỡng trên dữ liệu tách riêng (như phần Học máy làm với *threshold moving*).

4. **Giai đoạn 4: Dung hợp Mô hình (Model Ensemble)**

- **Đã triển khai:** điểm trên tập kiểm tra của mỗi mô hình là trung bình điểm của 5 checkpoint fold. Dung hợp giữa các mô hình bằng trung bình hạng phần trăm (*percentile-rank*) với trọng số bằng nhau, phù hợp cả với xác suất của bộ phân loại lẫn sai số tái tạo có thang đo khác.
- **Chưa triển khai (hướng mở rộng):** đánh giá ensemble trên OOF (mã hiện tại chỉ ghép các bản nộp trên tập kiểm tra), trọng số học được, và dung hợp với các mô hình Boosting của phần Học máy.

5.2 Huấn luyện và Đánh giá Mô hình

5.2.1 Cơ sở Phương pháp luận: Mục tiêu Đầu ra, Tiêu chí Lựa chọn và Quy trình Thực hiện

5.2.1.1 1. Mục đích Đầu ra của Bài toán (Output Objective):

Tại mỗi giờ i của một toà nhà, mô hình trả về một điểm bất thường liên tục $s_i \in \mathbb{R}$. Với bộ phân loại có giám sát (MLP, TCN, BiGRU, BiLSTM), đó là xác suất:

$$s_i = \hat{p}_i = \sigma(z_i) = P(y_i = 1 \mid \text{ngữ cảnh}_i) \in [0, 1] \tag{1}$$

với z_i là logit đầu ra. Với LSTM Autoencoder, đó là sai số tái tạo bình phương trung bình trên các kênh đầu vào:

$$s_i = \frac{1}{d} \sum_{j=1}^{d} (\hat{x}_{i,j} - x_{i,j})^2 \tag{2}$$

Điểm liên tục cho phép đánh giá không phụ thuộc ngưỡng bằng ROC-AUC và PR-AUC, và cho phép dung hợp mềm bằng hạng phần trăm. Khi cần nhãn nhị phân, quyết định là $\hat{y}_i = \mathbb{1}[s_i \geq \tau]$.

Hệ thống đánh giá theo ba độ đo:

- **ROC-AUC** (độ đo chính để xếp hạng mô hình). Nhóm ghi nhận ROC-AUC là độ đo chấm bản nộp của cuộc thi; thông tin này chưa được đối chiếu trực tiếp trên trang cuộc thi.
- **PR-AUC** (*average precision*), nhạy hơn với lớp hiếm. Một mô hình đoán ngẫu nhiên có PR-AUC xấp xỉ tỷ lệ bất thường 2,13%.
- **F1-Score** tại ngưỡng cực đại hoá F1 trên 200 phân vị của điểm trong OOF:

$$F_1^{\max} = \max_{\tau} \frac{2\,\text{Precision}(\tau)\,\text{Recall}(\tau)}{\text{Precision}(\tau) + \text{Recall}(\tau)} \tag{3}$$

  Vì ngưỡng được chọn ngay trên dữ liệu đang chấm điểm nên $F_1^{\max}$ là **cận trên mang tính chẩn đoán**, không phải F1 triển khai thực tế.

Ngoài các độ đo gộp trên toàn bộ OOF, nhóm tính ROC-AUC và PR-AUC **theo từng toà nhà** rồi lấy trung bình (macro) trên các toà nhà có cả hai lớp, để thấy mô hình có hoạt động đều giữa các toà nhà hay chỉ tốt ở một vài toà.

5.2.1.2 2. Tiêu chí Lựa chọn Thuật toán:

- **Tiêu chí 1 - Khai thác được ngữ cảnh thời gian.** Một phần lớn bất thường là đoạn giá trị lặp kéo dài hoặc giá trị bằng 1,0; mô hình cần biết một giá trị đã lặp bao lâu và so với chu kỳ tuần. Vì vậy ngữ cảnh 252 giờ được cấp cho các mô hình chuỗi.
- **Tiêu chí 2 - Tận dụng nhãn nhưng chịu được mất cân bằng.** Nhãn bất thường chỉ chiếm 2,13%; hàm mất mát có trọng số lớp được dùng thay cho SMOTE, vì nội suy giữa hai đoạn bất thường tạo ra chuỗi không có thật.

- **Tiêu chí 3 - Đa dạng hệ hình.** Năm mô hình đại diện bốn hệ hình khác nhau: theo điểm (MLP), tích chập nhân quả (TCN), hồi quy hai chiều (BiGRU, BiLSTM) và tái tạo không giám sát (LSTM-AE). Sự đa dạng này vừa phục vụ so sánh, vừa là điều kiện để dung hợp có ý nghĩa.
- **Tiêu chí 4 - Khả thi về tính toán.** Dữ liệu có khoảng 1,75 triệu dòng; mô hình phải huấn luyện được trên một GPU 6 GB (nhóm dùng `--batch-size 16` khi batch 64 gây hết bộ nhớ CUDA).

5.2.1.3 3. Các Bước Thực hiện Tuần tự trong Luồng Học Sâu (Execution Workflow):

Toàn bộ thực nghiệm chạy từ thư mục gốc của repo qua giao diện dòng lệnh `python -m model_DL.pipeline`:

- **Bước 1 (Tiền xử lý):** `preprocess` đọc dữ liệu thô, dựng lưới giờ, sinh đặc trưng nhân quả và ghi `train_processed_dl.parquet`, `test_processed_dl.parquet` cùng `processed_dl_metadata.json` (số dòng thô, số dòng chèn thêm, số toà nhà, khoảng thời gian).
- **Bước 2 (Chạy thử nhanh):** `benchmark --models mlp --folds 2 --epochs 1` để kiểm tra toàn bộ đường ống trước khi chạy dài.
- **Bước 3 (Huấn luyện và đánh giá đầy đủ):** `benchmark --models mlp tcn bigru bilstm lstm_ae`. Với mỗi mô hình và mỗi fold: khớp `FoldTransformer` trên các toà nhà huấn luyện, huấn luyện, chọn checkpoint tốt nhất, chấm OOF trên các toà nhà kiểm định và đồng thời suy luận trên tập kiểm tra.
- **Bước 4 (Suy luận lại):** `predict-test` suy luận lại từ các checkpoint đã lưu mà không huấn luyện lại.
- **Bước 5 (Tính lại độ đo):** `evaluate` tính lại độ đo từ các tệp OOF đã lưu.
- **Bước 6 (Dung hợp):** `ensemble` trộn các bản nộp bằng trung bình hạng phần trăm và ghi `submission_ensemble.csv`. Theo mặc định lệnh này bỏ qua `lstm_ae`; cần truyền `--models` đầy đủ nếu muốn gộp cả mô hình này.

Các sản phẩm được lưu trong `model_DL/artifacts/`: `checkpoints/<model>/fold_*.pt`, `predictions/oof_<model>.parquet`, `predictions/submission_<model>.csv`, `logs/metrics_<model` và `logs/benchmark_summary.csv`. Các bảng kết quả bên dưới được điền từ hai tệp `benchmark_summary.csv` và `metrics_<model>.json`.

5.2.2 Dữ liệu Đầu vào và Giao thức Đánh giá

5.2.2.1 1. Bộ đặc trưng đầu vào:

Mỗi giờ được biểu diễn bởi 26 kênh, chia thành ba nhóm trong Bảng 12. Các kênh số được chuẩn hoá bằng $(x - \mu)/\sigma$ với μ, σ tính trên các toà nhà huấn luyện của fold (trung vị dùng để thay giá trị khuyết). Hai biến phân loại được mã hoá thứ tự rồi chia cho số lớp (không dùng embedding); lớp chưa gặp ở fold huấn luyện nhận mã 0.

Bảng 12: **Các nhóm đặc trưng đầu vào của mô hình Học sâu (26 kênh)**

Nhóm	**Số kênh**	**Nội dung**
Biến thô (số)	12	`meter_reading`, `square_feet`, `year_built`, `floor_count`, `air_temperature`, `cloud_coverage`, `dew_temperature`, `precip_depth_1_hr`, `sea_level_pressure`, `wind_direction`, `wind_speed`, `is_holiday`
Biến sinh (nhân quả)	12	`meter_log1p`, `meter_delta_1`, `meter_delta_24`, `meter_run_length`, `meter_missing_mask`, `row_exists_mask`, sin / cos của giờ, thứ và tháng
Biến phân loại	2	`primary_use`, `site_id` (mã hoá thứ tự)

Cần lưu ý rằng `square_feet`, `year_built`, `floor_count` và `site_id` gần như nhận diện được từng toà nhà. Khi đánh giá theo `GroupKFold` điều này không gây rò rỉ (toà nhà kiểm định chưa từng thấy), nhưng nó giải thích vì sao điểm số có thể thấp hơn so với giao thức chia theo dòng.

5.2.2.2 2. Giao thức đánh giá `GroupKFold` theo toà nhà:

- 200 toà nhà huấn luyện được chia thành 5 nhóm không giao nhau; mỗi lượt dùng 4 nhóm để huấn luyện và nhóm còn lại để kiểm định. Mỗi toà nhà xuất hiện làm kiểm định đúng một lần, nên ghép 5 lượt cho OOF phủ toàn bộ dòng có nhãn.
- Bộ phân chia của `GroupKFold` là tất định theo `building_id`, nên các mô hình khác (kể cả mô hình Học máy) có thể tái tạo đúng cùng các fold.
- Mã dựng chuỗi kiểm tra và báo lỗi nếu một lượt chia cắt ngang một toà nhà, để loại trừ rò rỉ do cửa sổ chồng lấp giữa huấn luyện và kiểm định.

5.2.2.3 3. Điểm khác so với giao thức của phần Học máy:

Bảng 13 nêu các khác biệt giữa hai phần. Nhóm lưu ý rằng chúng làm cho con số của hai phần **chưa so sánh trực tiếp được**; mục 6 xử lý vấn đề này.

Bảng 13: **Khác biệt về giao thức đánh giá giữa phần Học máy và Học sâu**

Khía cạnh	**Học máy**	**Học sâu**
Cách chia	80/20 phân tầng theo dòng	`GroupKFold` 5 phần theo toà nhà
Độ đo chính	PR-AUC (kèm F_1 tại ngưỡng vận hành τ^*)	ROC-AUC (kèm PR-AUC, $F_1^{\max}$ chẩn đoán)
Chọn ngưỡng	Quét lưới trên tập kiểm định	Cực đại hoá F1 trên chính OOF (chẩn đoán)
Đơn vị dự đoán	Từng dòng, không ngữ cảnh chuỗi	Từng giờ, có ngữ cảnh 252 giờ
Biến nhận diện toà nhà	Có (nhánh Zone)	Có, nhưng toà nhà kiểm định chưa thấy

5.2.3 Đặc tả Kiến trúc và Siêu tham số

Các mô hình dùng chung cấu hình trong `config.py`: `hidden_size` = 64, `num_layers` = 2, `dropout` = 0,2, `tcn_channels` = 64, nhân tích chập $k = 3$ và độ giãn nở $(1, 2, 4, 8, 16, 32)$. Số tham số trong Bảng 14 được tính theo công thức với 26 kênh đầu vào và cần đối chiếu lại bằng cách đếm tham số khi chạy.

Bảng 14: **Đặc tả kiến trúc các mô hình Học sâu**

Mô hình	Kiến trúc	Đầu vào / Đầu ra	Tham số
MLP	$26 \to 128 \to 64 \to 1$; LayerNorm, GELU, dropout 0,2	Một giờ → một logit	≈ 12,0 nghìn
TCN nhân quả	6 khối dư, mỗi khối hai tích chập giãn nở nhân quả ($k = 3$, 64 kênh), GroupNorm, GELU, dropout; đầu tích chập 1×1	$420 \times 26 \to 168$ logit (lấy 168 giờ cuối)	≈ 143,5 nghìn
BiGRU	GRU hai chiều 2 tầng, 64 đơn vị mỗi chiều; dropout rồi tầng tuyến tính $128 \to 1$	$420 \times 26 \to 168$ logit	≈ 110,0 nghìn
BiLSTM	Như BiGRU, thay GRU bằng LSTM	$420 \times 26 \to 168$ logit	≈ 146,6 nghìn
LSTM-AE	Bộ mã hoá LSTM ($26 \to 64$), bộ giải mã LSTM ($64 \to 64$), tầng tuyến tính $64 \to 26$	$420 \times 26 \to$ tái tạo 168×26	≈ 58,5 nghìn

5.2.3.1 Vùng nhìn của TCN. Với $k = 3$ và hai tích chập giãn nở mỗi khối, vùng nhìn là $R = 1 + 2(k-1)\sum_\ell d_\ell = 1 + 2 \cdot 2 \cdot 63 = 253$ giờ. Giá trị này khớp với 252 giờ ngữ cảnh cộng giờ hiện tại, nên giờ đích đầu tiên của mỗi đoạn nhìn được trọn vẹn phần ngữ cảnh.

5.2.3.2 Huấn luyện. Tối ưu AdamW với tốc độ học 10^{-3} (không dùng bộ lập lịch), weight decay 10^{-4}, batch 64, tối đa 30 epoch, dừng sớm sau 5 epoch không cải thiện ROC-AUC, chạy với độ chính xác hỗn hợp tự động khi có GPU, hạt giống ngẫu nhiên cố định 42. Hàm mất mát của các mô hình có giám sát là:

$$\mathcal{L} = \frac{\sum_i m_i \cdot [-w_+ \, y_i \log \hat{p}_i - (1 - y_i) \log(1 - \hat{p}_i)]}{\sum_i m_i}, \qquad w_+ = 20 \tag{4}$$

với m_i là mặt nạ nhãn (chỉ giờ có nhãn thật). LSTM-AE tối thiểu hoá MSE tái tạo **chỉ trên các giờ đích bình thường** ($y_i = 0$) và dùng MSE của mọi giờ đích làm điểm bất thường. MLP không dùng ngữ cảnh chuỗi nên chỉ nhìn đặc trưng của đúng giờ đó (kể cả các đặc trưng nhân quả như `meter_run_length`).

5.2.4 Luận giải việc Lựa chọn và Loại trừ các Thuật toán

1. Nhóm được hiện thực và vai trò của từng mô hình

- **MLP (đối chứng):** cho biết các đặc trưng nhân quả đã sinh sẵn (run length, hiệu giá trị) giải quyết được bao nhiêu bài toán *mà không cần mô hình chuỗi*. Nếu MLP ngang các mô hình chuỗi, lợi thế của kiến trúc chuỗi trên dữ liệu này nhỏ.

- **TCN nhân quả:** song song hoá được, huấn luyện nhanh, vùng nhìn tính trước được (253 giờ phủ chu kỳ tuần) và chỉ dùng quá khứ, nên đại diện cho kịch bản phát hiện gần thời gian thực.
- **BiGRU / BiLSTM:** dùng ngữ cảnh hai chiều trong cửa sổ 420 giờ, nên biết cả một đoạn lặp còn kéo dài bao lâu. Đổi lại chỉ dùng được ngoại tuyến. GRU ít tham số hơn LSTM; cả hai được giữ để so sánh.
- **LSTM Autoencoder:** đại diện hệ hình tái tạo không giám sát phổ biến trong các nghiên cứu phát hiện bất thường chuỗi thời gian, dùng làm mốc so sánh với hướng có giám sát.

2. Nhóm chưa hiện thực

- **GAN-LSTM / TAnoGAN:** có kết quả công bố trên LEAD nên có giá trị đối chiếu, nhưng mỗi cửa sổ cần khoảng 300 bước tối ưu vector tiềm ẩn khi suy luận. Chấm điểm từng giờ trên toàn bộ dữ liệu cần cỡ 10^8 lượt chạy bộ sinh, không khả thi trong khuôn khổ đề tài. Chỉ có thể tái hiện ở mức cửa sổ trên một tập con toà nhà.
- **USAD:** nhanh và ổn định hơn GAN, nhưng vẫn là hệ hình không giám sát và chưa có công bố trên dữ liệu năng lượng.
- **Anomaly Transformer, TranAD:** thiết kế cho chuỗi đa biến không giám sát với quy tắc đánh giá điều chỉnh theo đoạn; chỉ có 200 chuỗi nên rủi ro quá khớp cao.
- **Conv-AE, VAE:** cùng hệ hình tái tạo với LSTM-AE; thêm vào tăng chi phí mà không mở góc nhìn mới.
- **RNN thuần:** triệt tiêu gradient trên chuỗi dài hàng trăm bước; LSTM/GRU thay thế hoàn toàn.

Tiểu kết: lựa chọn dựa trên ba đặc tính của bài toán: dữ liệu có nhãn nhưng mất cân bằng nặng, bất thường gồm cả loại có giá trị đặc biệt lẫn loại phụ thuộc ngữ cảnh, và chỉ có 200 chuỗi toà nhà. Các nhận định về ưu thế của từng hệ hình được xem là giả thuyết, kiểm chứng ở bảng thí nghiệm bên dưới.

5.3 Kết quả Thực nghiệm Đánh giá

Lưu ý: Bảng 15, 16 và 17 được điền từ lần chạy đầy đủ (`mode = full`, mã chạy `20261025T100532Z`, 5 fold, seed 42). Các ô `--` ở những bảng còn lại là kết quả chưa chạy và **chưa có số liệu**.

5.3.0.1 1. So sánh hiệu năng các mô hình đơn:

Bảng 15: **So sánh hiệu năng các mô hình Học sâu trên OOF của `GroupKFold` 5 phần theo toà nhà** (nguồn: `benchmark_summary.csv`)

Mô hình	ROC-AUC	PR-AUC	$F_1^{\max}$	ROC-AUC macro	PR-AUC macro	Độ lệch chuẩn AUC giữa fold	Thời gian (s)
MLP	0,9227	0,6070	0,6444	0,9109	0,6863	0,0173	1910,2
TCN nhân quả	0,9426	**0,7436**	0,7251	0,9291	0,7468	0,0153	502,2
BiGRU	**0,9521**	0,7346	**0,7367**	**0,9437**	**0,7810**	0,0164	452,3
BiLSTM	0,9480	0,6970	0,7089	0,9346	0,7661	**0,0136**	453,4
LSTM-AE	0,8372	0,1311	0,2384	0,8429	0,2701	0,0252	**349,2**

Ghi chú: PR-AUC của mô hình ngẫu nhiên xấp xỉ tỷ lệ bất thường (2,13%), nên PR-AUC cao nhất (0,7436) gấp khoảng 35 lần mức ngẫu nhiên. Độ lệch chuẩn giữa fold tính theo công thức tổng thể (chia cho 5). Cột thời gian là tổng thời gian chạy cả 5 fold của mô hình đó, gồm cả suy luận trên tập kiểm tra; thiết bị chạy lần này chưa được xác nhận, nên chưa so sánh được với thời gian của phần Học máy. In đậm là giá trị tốt nhất theo cột.

5.3.0.2 2. Kết quả theo từng fold:

Bảng 16: **ROC-AUC theo từng fold** (nguồn: mục `folds` trong `metrics_<model>.json`)

Mô hình	Fold 0	Fold 1	Fold 2	Fold 3	Fold 4
MLP	0,9133	0,9421	0,9001	0,9449	0,9172
TCN nhân quả	0,9348	0,9584	0,9195	0,9608	0,9437
BiGRU	0,9454	0,9685	0,9276	0,9721	0,9607
BiLSTM	0,9419	0,9640	0,9304	0,9661	0,9552
LSTM-AE	0,8317	0,8667	0,7988	0,8592	0,8593

Bảng 17: **PR-AUC theo từng fold** (nguồn: mục `folds` trong `metrics_<model>.json`)

Mô hình	Fold 0	Fold 1	Fold 2	Fold 3	Fold 4
MLP	0,5888	0,6798	0,5345	0,7704	0,6279
TCN nhân quả	0,7119	0,7428	0,7433	0,8342	0,7170
BiGRU	0,7300	0,6476	0,7399	0,8469	0,7672
BiLSTM	0,7114	0,5750	0,7023	0,8421	0,7550
LSTM-AE	0,1827	0,1957	0,0839	0,2224	0,2026

5.3.0.3 Nhận xét từ kết quả theo fold. Vì mọi mô hình dùng cùng các fold, so sánh được thực hiện theo từng fold (so cặp) thay vì chỉ so trung bình:

- **Các mô hình chuỗi có giám sát hơn MLP.** TCN hơn MLP ở cả 5 fold theo cả ROC-AUC (hơn 0,016 đến 0,027) lẫn PR-AUC. BiGRU hơn MLP ở 5/5 fold theo ROC-AUC (hơn 0,026 đến 0,044) và 4/5 fold theo PR-AUC. Điều này ủng hộ giả thuyết H1: ngữ cảnh 252 giờ có ích bên cạnh các đặc trưng nhân quả đã sinh sẵn.
- **BiGRU hơn TCN theo ROC-AUC, nhưng không theo PR-AUC.** BiGRU cao hơn TCN ở cả 5 fold về ROC-AUC (hơn 0,008 đến 0,017). Về PR-AUC, hai mô hình thắng thua xen kẽ (fold 1: TCN hơn 0,095; fold 4: BiGRU hơn 0,050), nên không kết luận được mô hình nào tốt hơn theo PR-AUC.
- **BiGRU hơn BiLSTM:** cao hơn ở 5/5 fold theo PR-AUC và 4/5 fold theo ROC-AUC, nhưng mức chênh nhỏ ($\leq$ 0,006 ở ROC-AUC).
- **LSTM-AE kém xa** các mô hình có giám sát (ROC-AUC 0,837, PR-AUC 0,131, chỉ khoảng 6 lần mức ngẫu nhiên). Kết quả phù hợp với H2, nhưng chưa đủ để giải thích nguyên nhân; việc đó cần phân tích recall theo loại bất thường (H3).

- **Dao động giữa các fold lớn hơn nhiều khác biệt giữa mô hình ở PR-AUC.** Ví dụ PR-AUC của BiGRU dao động từ 0,648 (fold 1) đến 0,847 (fold 3). Fold 3 là fold dễ nhất với mọi mô hình có giám sát. Vì vậy ranking theo một con số gộp cần được đọc cùng bảng theo fold.

5.3.0.4 3. Ảnh hưởng của hàm mất mát có trọng số lớp:

Thí nghiệm này chạy được bằng cách đổi `positive_class_weight` trong `config.py` (một mô hình chuỗi tốt nhất ở Bảng 15, cùng các fold).

Bảng 18: **Ảnh hưởng của trọng số lớp dương w_+ trong hàm mất mát**

w_+	ROC-AUC	PR-AUC	$F_1^{\max}$
1	–	–	–
7	–	–	–
20 (mặc định)	–	–	–
45	–	–	–

5.3.0.5 4. Dung hợp Mô hình:

Để đánh giá ensemble một cách công bằng cần tính điểm hạng phần trăm trung bình **trên các tệp OOF**, chứ không chỉ trên bản nộp. Bước này chưa có trong `pipeline.py`, nhưng thực hiện được bằng một đoạn mã ngắn đọc `oof_<model>.parquet`.

Bảng 19: **Hiệu năng ensemble hạng phần trăm trên OOF**

Tổ hợp mô hình	ROC-AUC	PR-AUC	$F_1^{\max}$
MLP + TCN + BiGRU + BiLSTM	–	–	–
Cả 5 mô hình (có LSTM-AE)	–	–	–
Chỉ mô hình chuỗi (TCN + BiGRU + BiLSTM)	–	–	–
Mô hình đơn tốt nhất (đối chiếu)	–	–	–

5.3.0.6 5. Phân tích lỗi theo loại bất thường:

Phân tích này dùng tệp OOF cùng `train_processed_dl.parquet`, không cần huấn luyện lại. Tại ngưỡng cố định chung cho mọi mô hình, ta tính recall riêng cho hai nhóm: bất thường có `meter_reading` bằng 1,0 và các bất thường còn lại, cùng recall theo độ dài đoạn giá trị lặp.

Bảng 20: **Recall theo loại bất thường tại ngưỡng cố định**

Mô hình	Recall: giá trị $= 1{,}0$	Recall: đoạn lặp ≥ 3	Recall: còn lại
MLP	–	–	–
TCN nhân quả	–	–	–
BiGRU	–	–	–
BiLSTM	–	–	–
LSTM-AE	–	–	–

5.3.0.7 6. Bảng tổng kết sự tăng tiến điểm số qua các cấp độ:

Bảng 21: **Sự tăng tiến hiệu năng của pipeline Học sâu qua các cấp độ**

Cấp độ	Chiến thuật	Cấu hình	ROC-AUC	PR-AUC	$F_1^{\max}$
Cấp độ 1	Mô hình theo điểm (đối chứng)	MLP	0,9227	0,6070	0,6444
Cấp độ 2	Mô hình chuỗi đơn tốt nhất (chọn theo ROC-AUC)	BiGRU, $w_+ = 20$	0,9521	0,7346	0,7367
Cấp độ 3	Ensemble hạng phần trăm	Trung bình hạng của các mô hình chuỗi	–	–	–
Cấp độ 4	Tối ưu hoá mở rộng (chưa triển khai)	Optuna, Focal Loss, nhiều seed	–	–	–

5.3.0.8 Kết luận tạm thời. *(Dựa trên một lần chạy với một seed; Cấp độ 3 và 4 chưa có số liệu.)* Từ Bảng 15, 16 và 17:

- Khi đánh giá trên các toà nhà chưa từng thấy, mô hình Học sâu tốt nhất theo ROC-AUC là BiGRU (ROC-AUC 0,952, PR-AUC 0,735, $F_1^{\max} = 0{,}737$); TCN nhân quả có PR-AUC cao nhất (0,744) nhưng không vượt BiGRU ở mọi fold.
- Chuyển từ MLP sang mô hình chuỗi tăng ROC-AUC khoảng 0,02 đến 0,03 và PR-AUC khoảng 0,13 (BiGRU) đến 0,14 (TCN) ở mức gộp. Đây là mức cải thiện nhất quán theo từng fold, không phải sai số ngẫu nhiên.
- Bộ gán nhãn chuỗi có giám sát vượt rõ LSTM-AE không giám sát (0,952 so với 0,837 ROC-AUC).
- $F_1^{\max}$ của Học sâu (0,74) là cận trên đo trên toà nhà chưa thấy; **chưa so sánh trực tiếp được** với $F_1 \approx 0{,}93$ của phần Học máy, vì Học máy chia 80/20 theo dòng. Việc so sánh công bằng cần chạy lại phần Học máy trên cùng các fold.

5.4 Giới hạn của Hiện thực và Hướng Mở rộng

Khi đối chiếu mã nguồn với thiết kế, nhóm ghi nhận các giới hạn sau để diễn giải kết quả cho đúng mức:

1. **Chọn checkpoint trên fold đang chấm:** checkpoint tốt nhất của mỗi fold được chọn theo ROC-AUC trên chính fold kiểm định dùng để báo cáo. Điều này tạo thiên lệch lạc quan nhỏ. Cách khắc phục là tách thêm một nhóm toà nhà để chọn epoch.
2. $F_1^{\max}$ **là cận trên:** ngưỡng được chọn trên chính OOF. Cần chọn ngưỡng trên dữ liệu tách riêng nếu muốn báo cáo F1 triển khai thực tế.
3. **OOF gộp từ nhiều checkpoint:** điểm của các fold đến từ 5 checkpoint khác nhau, nên thang điểm có thể lệch giữa fold, nhất là với LSTM-AE. ROC-AUC gộp có thể khác trung bình ROC-AUC theo fold; bảng nên báo cả hai.

4. **Chuẩn hoá nhóm trong TCN:** lớp `GroupNorm` chuẩn hoá theo toàn bộ trục thời gian của đoạn, nên về nguyên tắc thông tin của giờ sau có thể ảnh hưởng đến giờ trước trong cùng cửa sổ. Phần tích chập vẫn nhân quả, nhưng khẳng định "chỉ dùng quá khứ" cần kiểm tra bằng thí nghiệm đổi giá trị tương lai.

5. **LSTM-AE không có điểm thắt (bottleneck):** bộ mã hoá xuất chuỗi 64 chiều ở mọi bước và bộ giải mã nhận chuỗi này, nên mô hình có thể học gần như phép đồng nhất. Cần xem xét vector tiềm ẩn nhỏ hơn hoặc nhiễu đầu vào, và đầu vào chứa cả `meter_reading` nên mô hình có thể tái tạo tốt cả giá trị bất thường.

6. **Một seed duy nhất:** cấu hình mặc định dùng seed 42. Báo cáo chênh lệch nhỏ cần chạy tối thiểu 3 seed.

7. **Ensemble chưa có OOF:** `ensemble` chỉ ghi bản nộp; cần tính trên OOF mới đánh giá được.

8. **Chưa có Optuna, Focal Loss, giao thức theo thời gian và giao thức mức cửa sổ:** đây là hướng mở rộng.

5.5 Bộ Giả thuyết Kiểm chứng

Mỗi lựa chọn trong pipeline gắn với một giả thuyết có thể bác bỏ. Cột cuối cho biết thí nghiệm chạy được với mã hiện tại hay cần chỉnh thêm.

Mã	Giả thuyết	Thí nghiệm / đại lượng đo	Khả năng chạy
H1	Mô hình chuỗi vượt MLP, tức ngữ cảnh 252 giờ có ích ngoài các đặc trưng đã sinh sẵn	So Cấp độ 1 và Cấp độ 2 (Bảng 21)	Chạy được
H2	Mô hình có giám sát vượt LSTM-AE không giám sát	So ROC-AUC và PR-AUC cùng fold	Chạy được
H3	LSTM-AE bỏ sót bất thường dạng phẳng vì chuỗi hằng dễ tái tạo	Recall theo loại bất thường (Bảng 20)	Chạy được (hậu xử lý OOF)
H4	Ngữ cảnh hai chiều (BiGRU, BiLSTM) tốt hơn TCN nhân quả ở các đoạn lặp dài	So recall theo độ dài đoạn lặp	Chạy được (hậu xử lý OOF)
H5	Dung hợp tốt hơn mô hình đơn tốt nhất	Bảng 19	Cần thêm tính ensemble trên OOF
H6	Trọng số lớp dương làm tăng PR-AUC so với $w_+ = 1$	Bảng 18	Chạy được (đổi cấu hình)
H7	Kênh `meter_run_length` và hiệu giá trị giúp mô hình	Bỏ hai kênh rồi so sánh	Cần thêm cờ cấu hình
H8	Mô hình giảm hiệu năng khi chuyển sang toà nhà chưa thấy	So giao thức theo thời gian với theo toà nhà	Cần giao thức theo thời gian
H9	Focal Loss tốt hơn BCE có trọng số	So PR-AUC cùng kiến trúc	Cần cài Focal Loss

6 So sánh Học Máy và Học Sâu: Thế mạnh và Điểm yếu

7 Kết luận và Hướng phát triển tương lai

7.1 Kết luận

7.2 Hướng phát triển Tương lai

TÀI LIỆU THAM KHẢO

1. **Bộ dữ liệu LEAD1.0:** Gulati, M., & Arjunan, P. (2022). LEAD1.0: A Large-scale Annotated Dataset for Energy Anomaly Detection in Commercial Buildings. *Proceedings of the 13th ACM International Conference on Future Energy Systems (e-Energy '22)*, 485–488. DOI: https://doi.org/10.1145/3538637.3539761

2. **Lời giải Quán quân LEAD (Fu et al.):** Fu, C., Arjunan, P., & Miller, C. (2022). Trimming outliers using trees: winning solution of the large-scale energy anomaly detection (LEAD) competition. *Proceedings of the 9th ACM International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation (BuildSys '22)*, 456–461. DOI: https://doi.org/10.1145/3563357.3566147

3. **Framework ML trên LEAD (Buaprakhong et al.):** Buaprakhong, T., Sithisint, V., Phusaensaart, A., Wilke, S., Boonchuntuk, T., Ganokratanaa, T., & Ketcham, M. (2026). An Integrated Framework of Feature Engineering and Machine Learning for Large-Scale Energy Anomaly Detection. *Energy Engineering*, 123(3), 1–35. DOI: https://doi.org/10.32604/ee.2026.069004

4. **Dữ liệu ASHRAE (GEPIII):** Miller, C., Arjunan, P., Kathirgamanathan, A., Fu, C., Roth, J., Park, J. Y., Balbach, C., Gowri, K., Nagy, Z., Fontanini, A., & Haberl, J. (2020). The ASHRAE Great Energy Predictor III competition: Overview and results. *Science and Technology for the Built Environment*, 26(10), 1427–1447. DOI: https://doi.org/10.1080/23744731.2020.1795514

5. **Bộ dữ liệu BDG2:** Miller, C., Kathirgamanathan, A., Picchetti, P., Arjunan, P., Park, J. Y., Nagy, Z., & Schiavon, S. (2020). The Building Data Genome Project 2, a open database of energy meter data from 3,053 non-residential buildings. *Scientific Data*, 7(1), 368. DOI: https://doi.org/10.1038/s41597-020-00715-x

6. **GAN-LSTM trên LEAD:** Orvati Nia, F., Salehi, S., & Peeples, J. (2026). Evaluating GAN-LSTM for Smart Meter Anomaly Detection in Power Systems. *IEEE Texas Power and Energy Conference (TPEC) 2026*. arXiv: https://arxiv.org/abs/2601.09701

7. **GAN không giám sát trên dữ liệu năng lượng:** Handigol, P. P., & Arjunan, P. (2025). Generative Adversarial Networks for Unsupervised Anomaly Detection in Energy Time series data. *Hội thảo Tackling Climate Change with Machine Learning, ICLR 2025 (Climate Change AI)*. URL: https://www.climatechange.ai/papers/iclr2025/18

8. **Soft-DTW và tái tạo song song:** Prabhu, H., Valadi, J., & Arjunan, P. (2024). Generative Adversarial Network with Soft-Dynamic Time Warping and Parallel Reconstruction for Energy Time Series Anomaly Detection. *AI4TS Workshop, AAAI 2024*. arXiv: https://arxiv.org/abs/2402.14384

9. **Phân cụm toà nhà:** Cansever, B. N., & Konyar, M. Z. (2026). A clustering-based supervised approach for anomaly detection in building energy consumption. *E3S Web of Conferences*, 727, 02012. DOI: https://doi.org/10.1051/e3sconf/202672702012

10. **XGBoost:** Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. DOI: https://doi.org/10.1145/2939672.2939785

11. **LightGBM:** Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T. Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146–3154.

12. **CatBoost:** Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31, 6638–6648.

13. **Random Forest:** Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. DOI: https://doi.org/10.1023/A:1010933404324

14. **Extra Trees:** Geurts, P., Ernst, D., & Wehenkel, L. (2006). Extremely randomized trees. *Machine Learning*, 63(1), 3–42. DOI: https://doi.org/10.1007/s10994-006-6226-1

15. **Lựa chọn tổ hợp Ensemble:** Caruana, R., Niculescu-Mizil, A., Crew, G., & Ksikes, A. (2004). Ensemble selection from libraries of models. *Proceedings of the 21st International Conference on Machine Learning (ICML '04)*, 18. DOI: https://doi.org/10.1145/1015330.1015432

16. **Ngưỡng động phi tham số:** Hundman, K., Constantinou, V., Laporte, C., Ho, I., & Chu, T. (2018). Detecting spacecraft anomalies using LSTMs and nonparametric dynamic thresholding. *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 387–395. DOI: https://doi.org/10.1145/3219819.3219845

17. **Optuna:** Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2623–2631. DOI: https://doi.org/10.1145/3292500.3330701

18. **Graph Attention trên năng lượng (Zhang et al.):** Zhang, Z., Chen, Y., Wang, H., Fu, Q., Chen, J., & Lu, Y. (2023). Anomaly detection method for building energy consumption in multivariate time series based on graph attention mechanism. *PLOS ONE*, 18(6), e0286770. DOI: https://doi.org/10.1371/journal.pone.0286770

19. **LSTM-AE (EncDec-AD):** Malhotra, P., Ramakrishnan, A., Anand, G., Vig, L., Agarwal, P., & Shroff, G. (2016). LSTM-based Encoder-Decoder for Multi-sensor Anomaly Detection. *ICML 2016 Anomaly Detection Workshop*. arXiv: https://arxiv.org/abs/1607.00148

20. **LSTM cho phát hiện bất thường:** Malhotra, P., Vig, L., Shroff, G., & Agarwal, P. (2015). Long Short Term Memory Networks for Anomaly Detection in Time Series. *Proceedings of the 23rd European Symposium on Artificial Neural Networks (ESANN 2015)*, 89–94.

21. **USAD:** Audibert, J., Michiardi, P., Guyard, F., Marti, S., & Zuluaga, M. A. (2020). USAD: UnSupervised Anomaly Detection on Multivariate Time Series. *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 3395–3404. DOI: https://doi.org/10.1145/3394486.3403392

22. **TCN:** Bai, S., Kolter, J. Z., & Koltun, V. (2018). An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling. arXiv: https://arxiv.org/abs/1803.01271

23. **Anomaly Transformer:** Xu, J., Wu, H., Wang, J., & Long, M. (2022). Anomaly Transformer: Time Series Anomaly Detection with Association Discrepancy. *International Conference on Learning Representations (ICLR 2022)*. arXiv: https://arxiv.org/abs/2110.02642

24. **TranAD:** Tuli, S., Casale, G., & Jennings, N. R. (2022). TranAD: Deep Transformer Networks for Anomaly Detection in Multivariate Time Series Data. *Proceedings of the VLDB Endowment*, 15(6), 1201–1214. DOI: https://doi.org/10.14778/3514061.3514067

25. **AnoGAN:** Schlegl, T., Seeböck, P., Waldstein, S. M., Schmidt-Erfurth, U., & Langs, G. (2017). Unsupervised Anomaly Detection with Generative Adversarial Networks to Guide Marker Discovery. *Information Processing in Medical Imaging (IPMI 2017)*, 146–157. DOI: https://doi.org/10.1007/978-3-319-59050-9_12

26. **TAnoGAN:** Bashar, M. A., & Nayak, R. (2020). TAnoGAN: Time Series Anomaly Detection with Generative Adversarial Networks. *IEEE Symposium Series on Computational Intelligence (SSCI 2020)*, 1778–1785. DOI: https://doi.org/10.1109/SSCI47803.2020.9308512

27. **VAE:** Kingma, D. P., & Welling, M. (2014). Auto-Encoding Variational Bayes. *International Conference on Learning Representations (ICLR 2014)*. arXiv: https://arxiv.org/abs/1312.6114

28. **Đánh giá thuật toán chuỗi thời gian:** Schmidl, S., Wenig, P., & Papenbrock, T. (2022). Anomaly Detection in Time Series: A Comprehensive Evaluation. *Proceedings of the VLDB Endowment*, 15(9), 1779–1797. DOI: https://doi.org/10.14778/3538598.3538602

29. **LSTM:** Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780. DOI: https://doi.org/10.1162/neco.1997.9.8.1735

30. **GRU:** Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation. *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 1724–1734. DOI: https://doi.org/10.3115/v1/D14-1179

31. **RNN hai chiều:** Schuster, M., & Paliwal, K. K. (1997). Bidirectional recurrent neural networks. *IEEE Transactions on Signal Processing*, 45(11), 2673–2681. DOI: https://doi.org/10.1109/78.650093

32. **Transformer:** Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30, 5998–6008.

33. **Focal Loss:** Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal Loss for Dense Object Detection. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2980–2988. DOI: `https://doi.org/10.1109/ICCV.2017.324`