ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC & KỸ THUẬT MÁY TÍNH



Lập trình cho Trí tuệ nhân tạo và Khoa học dữ liệu
CO3135

PHÁT HIỆN BẤT THƯỜNG PHỤ TẢI ĐIỆN BẰNG CÁC PHƯƠNG PHÁP HỌC MÁY VÀ HỌC SÂU TÍCH HỢP THÔNG TIN SIÊU DỮ LIỆU

GVHD: ThS Trần Huy
NHÓM: **L01**
SV: Nguyễn Ngọc Tôn - 2313508
Nguyễn Miên Phú - 2312658
Trần Đỗ Đức Phát - 2312596
Huỳnh Kim Quý - 2312894
Nguyễn Đức Tiến - 2313431

TP. HỒ CHÍ MINH, THÁNG 12/2026

Mục lục

1 Tổng quan về Bài toán và Dữ liệu **4**
1.1 Giới thiệu bài toán 4
1.2 Mô tả tập dữ liệu 4
1.2.1 Các thuộc tính chính 5
1.2.2 Các đặc trưng bổ sung 5
1.2.3 Tình trạng dữ liệu thiếu 6

2 Tổng quan tài liệu **7**
2.1 Các phương pháp Học máy hiện có để giải quyết bài toán 7
2.1.1 XGBoost (eXtreme Gradient Boosting) 7
2.1.2 LightGBM (Light Gradient Boosting Machine) 8
2.1.3 CatBoost (Categorical Boosting) 9
2.1.4 Random Forest 10
2.1.5 Extra Trees (Extremely Randomized Trees) 11
2.1.6 Tổng hợp so sánh các thuật toán Học máy 12
2.2 Các phương pháp Học sâu hiện có để giải quyết bài toán 12
2.2.1 Biểu diễn bài toán và ba hệ hình tiếp cận 13
2.2.2 Nhóm Mạng Hồi quy (Recurrent Neural Networks) 13
2.2.3 Nhóm Mạng Tích chập thời gian (Temporal Convolutional Networks) 15
2.2.4 Nhóm Tự mã hoá (Autoencoder-based) 16
2.2.5 Nhóm Mô hình sinh đối kháng (GAN-based) 18
2.2.6 Nhóm Transformer 19
2.2.7 Kỹ thuật huấn luyện trên dữ liệu mất cân bằng 20
2.2.8 Các nghiên cứu liên quan trên chính bộ dữ liệu LEAD 21
2.2.9 Tổng hợp so sánh các họ mô hình Học sâu 22

3 Khám phá Dữ liệu (EDA) và Tiền xử lý Dữ liệu **23**
3.1 Khám phá Dữ liệu Ban đầu 23
3.1.1 Phân tích sự Mất cân bằng Lớp Dữ liệu 23
3.1.2 Toàn cảnh Lịch sử Phụ tải và Phân bố Dị thường theo Thời gian . 24
3.1.3 Phân loại Hình thái Dị thường Phụ tải trên Chuỗi Thời gian 25
3.1.4 Nhiễu Cảm biến và Tình trạng Thiếu Dữ liệu 26
3.2 Quy trình Tiền xử lý Dữ liệu 26
3.3 Khám phá Dữ liệu sau Tiền xử lý 29
3.3.1 Kiểm tra Tính Toàn vẹn và Phân bố Đặc trưng 29
3.3.2 Lược đồ Lịch sử Tiến trình Tiền xử lý (Preprocessing History Diagram) 30
3.3.3 Khám phá và Động lực Khoa học của Tương tác Khu vực (Zone EDA) 31

4 Triển khai thuật toán Học Máy - Machine Learning **33**
4.1 Thước đo Đánh giá và Cơ chế Ngưỡng Quyết định 33
4.1.1 Thước đo Đánh giá 33
4.1.2 Cơ chế Ngưỡng Quyết định 33
4.2 Thử nghiệm, Huấn luyện và Đánh giá các Mô hình 34
4.2.1 Phân tích Thực nghiệm: Ưu thế của Gradient Boosting và Bác bỏ Cây Truyền thống 34

4.2.2 Thực nghiệm Đánh giá Đặc trưng: Bác bỏ Isolation Forest và Kiểm định Rò rỉ Dữ liệu (No Leakage) . . . 34
4.2.3 Tinh chỉnh Siêu tham số (Hyperparameter Tuning) với Optuna . . 37
4.2.4 Kỹ thuật Ngưỡng Động 16 Khu vực (Site-Specific Dynamic Thresholding) . . . 38
4.3 Kỹ thuật Dung hợp Mô hình Nâng cao (Model Ensemble) . . . 39
4.3.1 Cơ sở Lý thuyết: Lựa chọn Tập hợp Mô hình (Ensemble Selection) 39
4.3.2 Các Phương pháp Dung hợp Thực nghiệm . . . 39
4.3.3 Kết quả Thực nghiệm Dung hợp và So sánh Đối chứng . . . 41

5 Triển khai thuật toán Học Sâu - Deep Learning 43
5.1 Kết luận và Thiết kế Pipeline . . . 43
5.2 Luận giải việc lựa chọn và loại trừ các thuật toán . . . 45
5.3 Đặc tả kiến trúc và siêu tham số . . . 47
5.4 Các kỹ thuật và thuật toán bổ trợ khác (Có thể tích hợp thêm) . . . 48
5.5 Chi tiết Pipeline Tiền xử lý dữ liệu và Áp dụng trên File . . . 48
5.6 Bộ thí nghiệm kiểm chứng giả thuyết . . . 49

6 Đánh giá, So sánh và Phân tích kết quả, hiệu năng 50

7 Kết luận và Hướng phát triển tương lai 51

TÀI LIỆU THAM KHẢO 52

STT	MSSV	Họ và Tên	Nhiệm vụ	Đóng góp
1	2313508	Nguyễn Ngọc Tôn	• Thực hiện tiền xử lý dữ liệu • Xây dựng pipeline Machine Learning	100%
2	2312658	Nguyễn Miên Phú	• Viết báo cáo	100%
3	2312596	Trần Đỗ Đức Phát	• Xây dựng pipeline Deep Learning • Viết báo cáo	100%
4	2312894	Huỳnh Kim Quý	• Xây dựng pipeline Deep Learning • Viết báo cáo	100%
5	2313431	Nguyễn Đức Tiến	• Viết báo cáo	100%

Bảng 1: **Phân công nhiệm vụ và mức độ đóng góp**

1 Tổng quan về Bài toán và Dữ liệu

1.1 Giới thiệu bài toán

Các tòa nhà hiện đại tiêu thụ một lượng lớn năng lượng và được trang bị nhiều công tơ điện thông minh (smart electricity meters). Các thiết bị này liên tục ghi nhận mức tiêu thụ điện theo thời gian, tạo ra một lượng lớn dữ liệu chuỗi thời gian. Việc phân tích các dữ liệu này có thể hỗ trợ phát hiện những trường hợp sử dụng năng lượng bất thường, từ đó góp phần xác định các vấn đề như sự cố thiết bị, thiết bị xuống cấp, cấu hình không phù hợp hoặc các hành vi sử dụng năng lượng không hiệu quả.

Trong báo cáo này, nhóm tập trung vào bài toán *Energy Anomaly Detection*, nhằm phát hiện các điểm bất thường trong dữ liệu tiêu thụ điện. Một điểm dữ liệu được xem là bất thường (*anomaly*) khi mức tiêu thụ điện tại thời điểm đó có hành vi khác biệt đáng kể so với trạng thái sử dụng điện thông thường. Ngược lại, các điểm dữ liệu phù hợp với trạng thái sử dụng thông thường được xem là bình thường (*normal*).

Về mặt hình thức, bài toán được thiết lập dưới dạng phân lớp có giám sát trên không gian đặc trưng đa chiều. Mỗi quan trắc của một tòa nhà tại thời điểm t được mã hóa thành một vector đặc trưng $\mathbf{x} \in \mathbb{R}^D$ tích hợp từ nhiều nguồn dữ liệu:

$$\mathbf{x} = \Big[\underbrace{p_t}_{\text{mức phụ tải}}, \underbrace{\mathbf{x}_{\text{time}}}_{\text{chu kỳ tuần hoàn}}, \underbrace{\mathbf{x}_{\text{bldg}}}_{\text{thông tin tòa nhà}}, \underbrace{\mathbf{x}_{\text{weather}}}_{\text{vi khí hậu}}, \underbrace{\mathbf{x}_{\text{interaction}}}_{\text{tương tác khu vực}} \Big]^\top \in \mathbb{R}^D$$

Mục tiêu của mô hình là học một hàm ánh xạ $f : \mathbb{R}^D \to [0, 1]$ nhằm ước lượng xác suất xảy ra dị thường:

$$\hat{p} = P(y = 1 \mid \mathbf{x}) = f(\mathbf{x})$$

Do tập dữ liệu thực tế có mức độ mất cân bằng lớp cực đoan (tỷ lệ mẫu bất thường chỉ chiếm khoảng 2,13%), việc áp dụng ngưỡng phân lớp mặc định $\tau = 0{,}5$ sẽ khiến mô hình bỏ sót phần lớn các điểm dị thường thực tế. Do đó, quyết định gán nhãn cuối cùng được điều khiển bởi ngưỡng quyết định tối ưu τ^*:

$$\hat{y} = \mathbb{I}(\hat{p} \geq \tau^*) = \begin{cases} 1 & \text{nếu } \hat{p} \geq \tau^* \quad \text{(Bất thường / Anomaly)} \\ 0 & \text{nếu } \hat{p} < \tau^* \quad \text{(Bình thường / Normal)} \end{cases}$$

Để giải quyết bài toán này một cách toàn diện, báo cáo nghiên cứu và so sánh song song hai trường phái: họ mô hình Học máy dựa trên cây quyết định tăng cường (Gradient Boosting: XGBoost, LightGBM, CatBoost) kết hợp các kỹ thuật dung hợp mô hình nâng cao; cùng họ mô hình Học sâu chuỗi thời gian (BiGRU, TCN, LSTM-Autoencoder) nhằm khai phá các mối quan hệ phi tuyến và bối cảnh phụ tải phức tạp.

1.2 Mô tả tập dữ liệu

Dữ liệu thực nghiệm của bài toán được cung cấp chính thức thông qua cuộc thi **Large-scale Energy Anomaly Detection (LEAD)** trên nền tảng Kaggle tại liên kết: `https://www.kaggle.com/competitions/energy-anomaly-detection/data`. Bộ dữ liệu này được xây dựng dựa trên nguồn dữ liệu tiêu thụ năng lượng của cuộc thi *ASHRAE - Great Energy Predictor III* và được mở rộng bằng cách gán nhãn bất thường cho các điểm đo điện theo từng giờ trong suốt năm 2016 (trải dài từ 00:00 ngày 01/01/2016 đến 23:00 ngày 31/12/2016) tại nhiều tòa nhà thương mại.

Bộ dữ liệu của cuộc thi bao gồm các tệp dữ liệu chuỗi thời gian thô (`train.csv`, `test.csv`), tệp mẫu định dạng nộp bài (`sample_submission.csv`) cùng hai tệp đặc trưng mở rộng đã tích hợp đầy đủ thông tin bối cảnh công trình và vi khí hậu thời tiết. Trong nghiên cứu này, nhóm khai thác trực tiếp hai tệp đặc trưng mở rộng được phân chia độc lập như sau:

- **Tập huấn luyện (`train_features.csv`):** Gồm dữ liệu đo đạc của 200 tòa nhà với tổng cộng 1.749.494 bản ghi chuỗi thời gian và 57 thuộc tính (bao gồm mức tiêu thụ điện thực tế, thông tin công trình, điều kiện khí tượng, các đặc trưng trễ và nhãn phân loại mục tiêu `anomaly`).
- **Tập kiểm tra (`test_features.csv`):** Gồm dữ liệu của 206 tòa nhà hoàn toàn độc lập với tổng cộng 1.800.567 bản ghi và 57 thuộc tính. Tệp này không chứa cột nhãn `anomaly` mà được gắn kèm mã định danh `row_id` để định danh từng điểm quan trắc phục vụ đánh giá và xếp hạng trên bảng thi đấu.

1.2.1 Các thuộc tính chính

Các thuộc tính cơ bản của tập huấn luyện và tập kiểm tra được mô tả trong Bảng 2.

Bảng 2: Các thuộc tính chính của bộ dữ liệu

Thuộc tính	Mô tả
`building_id`	Mã định danh của tòa nhà nơi dữ liệu được ghi nhận.
`timestamp`	Thời điểm ghi nhận mức tiêu thụ điện. Dữ liệu được ghi nhận theo từng giờ.
`meter_reading`	Mức tiêu thụ điện của tòa nhà tại thời điểm tương ứng, tính bằng kWh.
`anomaly`	Nhãn xác định trạng thái của điểm dữ liệu trong tập huấn luyện, trong đó 0 là dữ liệu bình thường và 1 là dữ liệu bất thường.
`row_id`	Mã định danh của bản ghi trong tập kiểm tra, được sử dụng để liên kết kết quả dự đoán với từng bản ghi.

Trong đó, thuộc tính `anomaly` chỉ xuất hiện trong tập huấn luyện và đóng vai trò là biến mục tiêu cần dự đoán. Kết quả thống kê cho thấy tập huấn luyện có 1.712.198 bản ghi thuộc lớp bình thường (`anomaly` = 0) và 37.296 bản ghi thuộc lớp bất thường (`anomaly` = 1). Như vậy, dữ liệu có sự mất cân bằng giữa hai lớp, với các điểm bất thường chiếm khoảng 2,13% tổng số bản ghi.

1.2.2 Các đặc trưng bổ sung

Ngoài các thuộc tính cơ bản, hai tệp `train_features.csv` và `test_features.csv` cung cấp các đặc trưng bổ sung nhằm hỗ trợ quá trình xây dựng mô hình. Các đặc trưng này có thể được chia thành một số nhóm chính.

Bảng 3: Một số nhóm đặc trưng bổ sung

Nhóm đặc trưng	**Một số thuộc tính tiêu biểu**
Thông tin tòa nhà	`site_id`, `building_id`, `primary_use`, `square_feet`, `year_built`, `floor_count`
Điều kiện thời tiết	`air_temperature`, `cloud_coverage`, `dew_temperature`, `precip_depth_1_hr`, `sea_level_pressure`, `wind_direction`, `wind_speed`
Đặc trưng thời gian	`hour`, `weekday`, `month`, `year`, `weekday_hour`, `is_holiday`
Đặc trưng chuỗi thời gian	Các đặc trưng thống kê của nhiệt độ theo các khoảng thời gian trước đó như `air_temperature_mean_lag7`, `air_temperature_max_lag7`, `air_temperature_std_lag7`, v.v.
Đặc trưng theo tòa nhà và thời gian	`building_hour`, `building_weekday`, `building_month`, `building_weekday_hour`, `building_meter`
Đặc trưng thống kê	Các đặc trưng bắt đầu bằng `gte_`, được xây dựng theo nhiều nhóm như giờ, ngày trong tuần, tháng, tòa nhà, loại hình sử dụng và địa điểm.

Các đặc trưng bổ sung giúp mô hình có thêm thông tin ngoài mức tiêu thụ điện trực tiếp. Chẳng hạn, mức tiêu thụ điện có thể phụ thuộc vào loại hình sử dụng của tòa nhà, quy mô tòa nhà, thời điểm trong ngày hoặc điều kiện thời tiết. Những thông tin này có thể được khai thác trong các bước xây dựng đặc trưng và huấn luyện mô hình ở các chương tiếp theo.

1.2.3 Tình trạng dữ liệu thiếu

Qua quá trình kiểm tra dữ liệu, thuộc tính `meter_reading` xuất hiện các giá trị bị thiếu. Trong tập huấn luyện có 107.653 bản ghi bị thiếu giá trị `meter_reading`, tương đương khoảng 6,15% tổng số bản ghi. Trong tập kiểm tra có 94.864 bản ghi bị thiếu giá trị này, tương đương khoảng 5,27%.

Đáng chú ý, việc thiếu giá trị `meter_reading` không đồng nghĩa với việc thiếu bản ghi thời gian. Một số bản ghi vẫn có `timestamp` và các thông tin liên quan đến tòa nhà nhưng không có giá trị tiêu thụ điện tương ứng. Vì vậy, dữ liệu thiếu cần được xem xét và xử lý trong bước tiền xử lý trước khi đưa vào các mô hình Học máy và Học sâu.

Ngoài `meter_reading`, các thuộc tính còn lại trong hai tệp `train_features.csv` và `test_features.csv` không ghi nhận giá trị thiếu trong quá trình kiểm tra dữ liệu.

2 Tổng quan tài liệu

2.1 Các phương pháp Học máy hiện có để giải quyết bài toán

Do dữ liệu đã có gán nhãn cho biến `anomaly`(0 biểu thị trạng thái bình thường, 1 biểu thị trạng thái bất thường), họ thuật toán dựa trên cây quyết định (Tree-based Models) và phương pháp học tập hợp (Ensemble Learning) thường thể hiện hiệu suất vượt trội.

2.1.1 XGBoost (eXtreme Gradient Boosting)

XGBoost tối ưu hóa hàm mục tiêu bằng phương pháp khai triển Taylor bậc hai, cho phép hội tụ nhanh hơn. Cấu trúc cây được phát triển theo từng tầng. Mô hình cuối cùng là tổng hợp tuần tự của K cây quyết định:

$$\hat{y}_i = \sum_{k=1}^{K} f_k(\mathbf{x}_i), \quad f_k \in \mathcal{F}$$

trong đó $\mathcal{F}$ là không gian của các cây hồi quy CART. Tại mỗi bước lặp t, hàm mục tiêu được tối ưu bằng khai triển Taylor bậc hai:

$$\mathcal{L}^{(t)} \simeq \sum_{i=1}^{n} \left[g_i f_t(\mathbf{x}_i) + \frac{1}{2} h_i f_t^2(\mathbf{x}_i) \right] + \Omega(f_t)$$

với $g_i = \partial_{\hat{y}^{(t-1)}} \ell(y_i, \hat{y}^{(t-1)})$ là gradient bậc nhất, $h_i = \partial^2_{\hat{y}^{(t-1)}} \ell(y_i, \hat{y}^{(t-1)})$ là gradient bậc hai của hàm mất mát và $\Omega(f_t)$ là hàm phạt cấu trúc cây:

$$\Omega(f) = \gamma T + \frac{1}{2}\lambda \sum_{j=1}^{T} w_j^2 + \alpha \sum_{j=1}^{T} |w_j|$$

trong đó T là số lá, w_j là trọng số tại lá j, γ phạt số lượng lá, λ là hệ số điều chuẩn L_2 và α là hệ số điều chuẩn L_1.

Ưu điểm:

- **Hạn chế Overfitting:** Tích hợp các thành phần phạt L_1 (α) và L_2 (λ) trực tiếp vào hàm mục tiêu $\Omega(f)$, giúp hạn chế hiệu quả hiện tượng overfitting khi mô hình tiếp xúc với dữ liệu nhiễu từ các cảm biến đo lường.
- **Xử lý mất cân bằng lớp:** Hỗ trợ điều chỉnh trọng số thông qua siêu tham số `scale_pos_weight`, gán penalty cao hơn cho các trường hợp phân loại sai lớp thiểu số.
- **Xử lý giá trị khuyết:** Thuật toán tự học hướng mặc định tại mỗi nút chia cho các giá trị bị khuyết, phù hợp với dữ liệu cảm biến thực tế thường có nhiều giá trị bị thiếu.

Nhược điểm:

- **Độ phức tạp thời gian:** Thuật toán phân nhánh tham lam chính xác đòi hỏi duyệt qua toàn bộ dữ liệu liên tục. Mặc dù đã có các cải tiến như Histogram-based, XGBoost vẫn yêu cầu thời gian tính toán khi xử lý tập dữ liệu có quy mô lớn.
- **Phát triển cây Level-wise:** Chiến lược phát triển theo tầng buộc tất cả các nút ở cùng một độ sâu phải được mở rộng, dẫn đến việc phân chia tại nhiều nút không cần thiết.

2.1.2 LightGBM (Light Gradient Boosting Machine)

LightGBM được thiết kế chuyên biệt để tối ưu hóa hiệu suất trên dữ liệu quy mô lớn thông qua hai kỹ thuật cốt lõi: GOSS (Gradient-based One-Side Sampling) và EFB (Exclusive Feature Bundling). Cây được phát triển theo cơ chế ưu tiên lá.

Kỹ thuật GOSS ước lượng độ lợi thông tin bằng cách giữ lại toàn bộ các mẫu có gradient lớn và lấy mẫu ngẫu nhiên từ các mẫu có gradient nhỏ, sau đó nhân trọng số bù:

$$\widetilde{V}_j(d) = \frac{1}{n}\left(\frac{\left(\sum_{x_i \in A_l} g_i + \frac{1-a}{b}\sum_{x_i \in B_l} g_i\right)^2}{n_l^j(d)} + \frac{\left(\sum_{x_i \in A_r} g_i + \frac{1-a}{b}\sum_{x_i \in B_r} g_i\right)^2}{n_r^j(d)}\right)$$

trong đó A là tập các mẫu có gradient lớn, B là tập mẫu ngẫu nhiên từ các mẫu có gradient nhỏ, l và r ký hiệu nhánh trái và phải tại ngưỡng d của đặc trưng j.

Kỹ thuật EFB gộp các đặc trưng thưa có tính loại trừ lẫn nhau thành các gói, giảm số lượng đặc trưng từ p xuống số lượng gói $p' \ll p$.

Ưu điểm:

- **Hiệu suất tính toán ưu việt:** Kỹ thuật Histogram giúp giảm độ phức tạp thời gian tìm kiếm điểm chia nhánh, mang lại tốc độ huấn luyện nhanh.
- **Xử lý biến định danh trực tiếp:** Khai thác hiệu quả các đặc trưng phân loại xuất hiện nhiều giá trị khác nhau như `building_id`, `meter`, ... bằng cách phân chia tối ưu trên các danh mục mà không cần mã hóa One-Hot, giúp kiểm soát chiều dữ liệu.
- **Tiết kiệm bộ nhớ:** Kỹ thuật EFB giảm đáng kể số chiều hiệu dụng, trong khi biểu diễn Histogram chỉ lưu trữ các bin rời rạc thay vì toàn bộ giá trị liên tục, giúp tiết kiệm RAM khi xử lý dữ liệu hàng chục triệu dòng.
- **GOSS giữ độ chính xác khi lấy mẫu:** Thay vì lấy mẫu đồng đều, GOSS ưu tiên các mẫu có gradient lớn (đóng góp nhiều nhất vào việc học), nên giảm dữ liệu mà vẫn duy trì chất lượng mô hình.

Nhược điểm:

- **Rủi ro quá khớp cục bộ:** Sự phát triển theo chiều sâu lá có thể dẫn đến việc mô hình học các mẫu nhiễu cục bộ. Cần giới hạn nghiêm ngặt các tham số `max_depth` và `min_data_in_leaf`.

- **Nhạy cảm với dữ liệu không đa dạng:** Chiến lược phát triển cây theo chiều sâu lá tạo ra các cây sâu không cân bằng, dễ overfitting trên các tập dữ liệu nhỏ. Tuy nhiên, hạn chế này ít ảnh hưởng trong bài toán hiện tại do quy mô dữ liệu rất lớn.

2.1.3 CatBoost (Categorical Boosting)

Thuật toán xây dựng các cây quyết định đối xứng và sử dụng cơ chế Ordered Target Encoding. Đặc điểm cốt lõi của CatBoost là sử dụng hoán vị ngẫu nhiên σ để tính giá trị mã hóa cho biến định danh, tránh rò rỉ thông tin mục tiêu:

$$\hat{x}^i_{\sigma_p} = \frac{\sum_{j=1}^{p-1}[x^i_{\sigma_j} = x^i_{\sigma_p}] \cdot y_{\sigma_j} + a \cdot P}{\sum_{j=1}^{p-1}[x^i_{\sigma_j} = x^i_{\sigma_p}] + a}$$

trong đó σ_p là chỉ số của mẫu thứ p trong hoán vị, x^i là giá trị đặc trưng định danh thứ i, y là nhãn mục tiêu, P là giá trị trung bình toàn cục của nhãn và $a > 0$ là tham số Laplace smoothing.

Cây đối xứng sử dụng cùng một điều kiện chia tại tất cả các nút ở cùng một độ sâu, tạo ra cấu trúc cây cân bằng hoàn hảo với 2^d lá (với d là chiều sâu). Việc dự đoán trở thành phép tra bảng $O(d)$.

Ưu điểm:

- **Ngăn chặn rò rỉ dữ liệu:** Ordered Target Encoding tính toán giá trị trung bình mục tiêu dựa trên các mẫu quan sát trong quá khứ nhân tạo theo hoán vị σ, giúp mã hóa các biến định danh một cách an toàn và mạnh mẽ mà không gây rò rỉ thông tin nhãn.
- **Tốc độ suy luận nhanh:** Cấu trúc cây đối xứng cho phép mô hình được biểu diễn dưới dạng các bảng tra cứu với độ phức tạp suy luận $O(d)$, tăng tốc độ dự đoán lên nhiều lần so với các cây không đối xứng.
- **Giảm Bias:** Sử dụng nhiều hoán vị khác nhau trong quá trình huấn luyện, giảm Bias do rò rỉ thông tin trong Gradient Boosting truyền thống, đặc biệt hiệu quả trên dữ liệu có nhiều biến phân loại như `building_id`, `primary_use`.
- **Hạn chế Overfitting:** Cấu trúc cây đối xứng có ít tham số hơn cây tự do (chỉ d điều kiện chia thay vì $2^d - 1$ nút nội), đóng vai trò như một dạng điều chuẩn ngầm.

Nhược điểm:

- **Thời gian huấn luyện lớn:** Quy trình mã hóa Ordered Target Encoding và xây dựng cây đối xứng khiến CatBoost mất nhiều thời gian huấn luyện hơn so với LightGBM, đặc biệt khi bộ dữ liệu chứa lượng lớn các biến liên tục.
- **Khả năng biểu diễn hạn chế:** Ràng buộc cùng một điều kiện chia tại mỗi tầng có thể hạn chế khả năng biểu diễn các mẫu phức tạp, đòi hỏi cây phải sâu hơn để đạt cùng mức chính xác so với cây tự do.

2.1.4 Random Forest

Random Forest là thuật toán học tập hợp Bagging, xây dựng B cây quyết định độc lập trên các tập dữ liệu bootstrap. Mỗi cây được huấn luyện trên tập $\mathcal{D}_b$ được lấy mẫu ngẫu nhiên có hoàn lại từ tập gốc $\mathcal{D}$, với $|\mathcal{D}_b| = |\mathcal{D}| = n$.

Tại mỗi nút phân chia, thay vì xét toàn bộ p đặc trưng, Random Forest chỉ chọn ngẫu nhiên một tập con m đặc trưng và tìm điểm chia tối ưu theo tiêu chí Gini Impurity:

$$\text{Gini}(S) = 1 - \sum_{k=1}^{C} p_k^2$$

trong đó C là số lớp và p_k là tỷ lệ mẫu thuộc lớp k trong tập S. Số đặc trưng được chọn ngẫu nhiên thường là $m = \lfloor \sqrt{p} \rfloor$ cho bài toán phân lớp.

Dự đoán cuối cùng được xác định bằng bỏ phiếu đa số:

$$\hat{y}(\mathbf{x}) = \text{mode}\left\{h_b(\mathbf{x})\right\}_{b=1}^{B}$$

Phương sai của mô hình tập hợp được giới hạn bởi:

$$\text{Var}\left[\hat{y}\right] = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$$

trong đó ρ là hệ số tương quan trung bình giữa các cây và σ^2 là phương sai của mỗi cây đơn lẻ. Việc chọn ngẫu nhiên $m \ll p$ đặc trưng tại mỗi nút giúp giảm ρ, từ đó giảm phương sai tổng thể.

Ưu điểm:

- **Kháng nhiễu và ngoại lai:** Cơ chế trung bình hóa từ hàng trăm cây quyết định độc lập giúp mô hình miễn nhiễm với các giá trị bất thường ngẫu nhiên của cảm biến.
- **Huấn luyện song song:** Các cây hoàn toàn độc lập nên có thể huấn luyện song song trên nhiều lõi CPU, tận dụng hiệu quả kiến trúc đa nhân.
- **Ước lượng lỗi:** Khoảng 37% mẫu không xuất hiện trong mỗi bootstrap có thể được dùng làm tập kiểm tra nội bộ, cung cấp ước lượng lỗi tổng quát hóa mà không cần tập validation riêng.
- **Đo lường tầm quan trọng đặc trưng:** Cung cấp thước đo dựa trên mức giảm tạp chất trung bình hoặc hoán vị, hỗ trợ giải thích mô hình.

Nhược điểm:

- **Độ nhạy thấp với lớp thiểu số:** Thuật toán Bagging hội tụ về phía dự đoán nhãn đa số do mỗi bootstrap chỉ chứa một tỷ lệ nhỏ mẫu lớp thiểu số. Cần kết hợp với kỹ thuật Balanced Random Forest (lấy mẫu phân tầng trong bootstrap) để cải thiện.
- **Kích thước mô hình lớn:** Với số lượng cây lớn, file mô hình có thể lên tới hàng GB trên ổ cứng, gây khó khăn cho việc triển khai và lưu trữ.
- **Không có cơ chế học tuần tự:** Khác với Boosting, mỗi cây không học từ sai sót của cây trước, nên không tập trung sửa lỗi ở vùng dữ liệu khó — điểm yếu quan trọng trong bài toán mất cân bằng.

2.1.5 Extra Trees (Extremely Randomized Trees)

Extra Trees (Extremely Randomized Trees) là một biến thể cực đoan hóa của Random Forest. Khác biệt cốt lõi nằm ở hai điểm: Sử dụng toàn bộ tập huấn luyện $\mathcal{D}$ thay vì lấy mẫu bootstrap và ngẫu nhiên hóa hoàn toàn cả ngưỡng phân chia tại mỗi nút.

Cụ thể, tại mỗi nút, thuật toán chọn ngẫu nhiên K đặc trưng. Với mỗi đặc trưng j được chọn, ngưỡng chia s_j được lấy ngẫu nhiên đồng đều trong khoảng giá trị:

$$s_j \sim \mathcal{U}\left(\min_i x_i^j,\ \max_i x_i^j\right)$$

Sau đó, cặp (j^*, s^*) cho điểm chia tốt nhất được chọn theo tiêu chí Gini hoặc Entropy:

$$(j^*, s^*) = \arg \max_{j \in \{1,\ldots,K\},\ s_j} \text{Gain}(j, s_j)$$

Việc ngẫu nhiên hóa ngưỡng chia khiến hệ số tương quan ρ giữa các cây giảm sâu hơn so với Random Forest, dẫn đến phương sai tổng thể thấp hơn theo công thức $\text{Var}[\hat{y}] = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$.

Ưu điểm:

- **Tốc độ huấn luyện nhanh hơn Random Forest:** Không cần tìm kiếm ngưỡng chia tối ưu cho mỗi đặc trưng, giúp giảm đáng kể chi phí tính toán tại mỗi nút từ $O(n \log n)$ xuống $O(n)$.
- **Kháng overfitting tốt hơn Random Forest:** Ngưỡng chia ngẫu nhiên ngăn cây học quá sát các mẫu nhiễu cục bộ. Sử dụng toàn bộ dữ liệu giúp mỗi cây có cái nhìn đầy đủ hơn về phân phối dữ liệu, giảm bias.
- **Hoạt động tốt trên dữ liệu nhiễu cao:** Đặc tính ngẫu nhiên hóa cực đoan giúp Extra Trees miễn nhiễm tốt với nhiễu cảm biến, phù hợp với bản chất dữ liệu đo lường năng lượng.

Nhược điểm:

- **Bias cao hơn Random Forest:** Ngưỡng chia ngẫu nhiên thay vì tối ưu có thể tạo ra các phân vùng kém chính xác hơn, khiến mỗi cây đơn lẻ có sai số bias cao hơn.
- **Không nhạy cảm với đặc trưng quan trọng:** Do không tìm kiếm ngưỡng tối ưu, thuật toán khó phân biệt giữa các đặc trưng hữu ích và đặc trưng nhiễu, đặc biệt khi tập đặc trưng có chiều cao.
- **Cùng hạn chế Bagging với lớp thiểu số:** Tương tự Random Forest, Extra Trees không có cơ chế tập trung vào các mẫu khó của lớp thiểu số, kém hiệu quả hơn Boosting trong bài toán mất cân bằng nghiêm trọng.

2.1.6 Tổng hợp so sánh các thuật toán Học máy

Thuật toán	Cơ chế học	Xử lý biến danh mục	Tốc độ & Bộ nhớ	Xử lý mất cân bằng	Phù hợp LEAD
XGBoost	Boosting (Level-wise)	Cần mã hóa trước (Ordinal / One-Hot)	Trung bình, yêu cầu bộ nhớ RAM	Tốt (`scale_pos_weight`)	Rất cao
LightGBM	Boosting (Leaf-wise)	Tự động phân chia tối ưu danh mục	Rất nhanh, tối ưu nhờ Histogram	Xuất sắc (trọng số mẫu và lớp)	Xuất sắc (ưu tiên cao nhất)
CatBoost	Boosting (Symmetric Tree)	Ordered Target Encoding chống rò rỉ	Huấn luyện lâu hơn, suy luận cực nhanh $O(d)$	Rất tốt (`auto_class_weights`)	Rất cao (mạnh với biến phân loại)
Random Forest	Bagging (Bootstrap)	Cần mã hóa trước	Rất chậm trên 1,75M dòng, file mô hình lớn	Kém (dễ thiên lệch về lớp đa số)	Trung bình (nặng tài nguyên)
Extra Trees	Bagging (Random Splits)	Cần mã hóa trước	Nhanh hơn RF, giảm phương sai tốt	Kém (dễ thiên lệch về lớp đa số)	Thấp đến trung bình

Cột "Phù hợp LEAD" là đánh giá tổng hợp của nhóm dựa trên các tiêu chí: tốc độ xử lý trên quy mô 1,75 triệu dòng, khả năng khai thác các đặc trưng định danh công trình (`building_id`, `primary_use`), cơ chế phạt mẫu dị thường và độ linh hoạt khi tinh chỉnh ngưỡng phân loại tối ưu. Đánh giá này sẽ được kiểm chứng bằng thực nghiệm ở phần triển khai.

2.2 Các phương pháp Học sâu hiện có để giải quyết bài toán

Khác với các mô hình Học máy ở phần trước vốn xử lý từng dòng dữ liệu một cách độc lập, các phương pháp Học sâu cho chuỗi thời gian khai thác trực tiếp thứ tự và phụ thuộc thời gian giữa các quan trắc. Dựa trên khảo sát sơ bộ của nhóm trên tệp `train_features.csv`, dữ liệu có các đặc thù sau:

- **Cấu trúc chuỗi:** gồm 200 toà nhà, mỗi toà là một chuỗi đo theo giờ trong năm 2016, tổng cộng khoảng 1,75 triệu quan trắc. Một số toà nhà thiếu một số mốc giờ và giá trị `meter_reading` có phần bị khuyết.
- **Nhãn theo từng thời điểm:** biến `anomaly` được gán cho từng giờ (point-wise), với tỷ lệ bất thường chỉ khoảng 2,1% nên bài toán mất cân bằng lớp nghiêm trọng.
- **Bất thường không đồng nhất:** trong tập kiểm định (từ 01/10/2016), khoảng 44% điểm bất thường có `meter_reading` đúng bằng 1,0. Trên toàn bộ dữ liệu huấn luyện, khoảng 58% điểm bất thường nằm trong một đoạn giá trị lặp lại liên tiếp có độ dài từ 3 giờ trở lên (so với khoảng 3,3% ở điểm bình thường). Phần bất thường còn lại có giá trị nằm trong vùng tiêu thụ thông thường, nên chỉ có thể nhận diện

dựa trên ngữ cảnh thời gian. Nguyên nhân sinh ra các giá trị đặc biệt này chưa được nhóm kiểm chứng.

Các đặc thù trên cho thấy một mô hình xét từng điểm riêng lẻ có thể bắt tốt nhóm bất thường có giá trị đặc biệt nhưng khó nhận diện nhóm bất thường phụ thuộc ngữ cảnh. Đây là động lực để khảo sát các phương pháp Học sâu.

2.2.1 Biểu diễn bài toán và ba hệ hình tiếp cận

Với mỗi toà nhà, tại thời điểm t ta xây dựng cửa sổ trượt gồm w quan trắc gần nhất:

$$\mathbf{X}_t = (\mathbf{x}_{t-w+1}, \ldots, \mathbf{x}_t) \in \mathbb{R}^{w \times d}$$

trong đó $\mathbf{x}_i \in \mathbb{R}^d$ gồm giá trị đo `meter_reading`, các biến thời tiết, mã hoá chu kỳ của thời gian và các đặc trưng bổ sung. Nhãn tại thời điểm t là $y_t \in \{0, 1\}$. Các phương pháp Học sâu hiện có thuộc ba hệ hình chính:

1. **Tái tạo (Reconstruction-based):** mô hình học cách tái tạo lại hành vi bình thường, điểm bất thường là sai số tái tạo:
$$a_t = \|\mathbf{x}_t - \hat{\mathbf{x}}_t\|_2^2$$
2. **Dự báo (Prediction-based):** mô hình dự báo giá trị kế tiếp từ quá khứ, điểm bất thường là sai số dự báo:
$$a_t = |x_{t+1} - \hat{x}_{t+1}|$$
3. **Gán nhãn chuỗi có giám sát (Supervised sequence labelling):** mô hình học trực tiếp xác suất bất thường từ nhãn có sẵn:
$$\hat{p}_t = P\left(y_t = 1 \mid \mathbf{X}_t\right)$$

Hai hệ hình đầu thường được dùng khi không có nhãn và chỉ được huấn luyện trên dữ liệu bình thường. Hệ hình thứ ba tận dụng được nhãn `anomaly` đã có của bộ dữ liệu LEAD. Phần dưới trình bày ưu nhược điểm của từng họ mô hình theo các hệ hình này.

2.2.2 Nhóm Mạng Hồi quy (Recurrent Neural Networks)

Mạng hồi quy xử lý chuỗi tuần tự, duy trì trạng thái ẩn $\mathbf{h}_t$ tổng hợp thông tin từ quá khứ. Nhóm này dùng được cho cả ba hệ hình: làm bộ gán nhãn chuỗi, làm bộ dự báo (Malhotra et al., 2015) hoặc làm bộ mã hoá–giải mã.

2.2.2.1 LSTM (Long Short-Term Memory)

LSTM đưa vào trạng thái ô nhớ $\mathbf{c}_t$ cùng ba cổng điều khiển luồng thông tin (Hochreiter & Schmidhuber, 1997):

$$\mathbf{f}_t = \sigma\left(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f\right), \quad \mathbf{i}_t = \sigma\left(\mathbf{W}_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i\right), \quad \mathbf{o}_t = \sigma\left(\mathbf{W}_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o\right)$$
$$\tilde{\mathbf{c}}_t = \tanh\left(\mathbf{W}_c[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c\right), \quad \mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t, \quad \mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t)$$

trong đó $\mathbf{f}_t$, $\mathbf{i}_t$, $\mathbf{o}_t$ lần lượt là cổng quên, cổng vào và cổng ra, σ là hàm sigmoid và $\odot$ là phép nhân từng phần tử.

Ưu điểm:

- **Học phụ thuộc dài hạn:** đường truyền gradient qua ô nhớ $\mathbf{c}_t$ giảm hiện tượng triệt tiêu gradient, phù hợp với chu kỳ ngày (24 giờ) và chu kỳ tuần (168 giờ) của dữ liệu tiêu thụ điện.
- **Linh hoạt về đầu ra:** cùng một kiến trúc có thể dùng để gán nhãn từng bước, dự báo bước kế tiếp hoặc làm bộ mã hoá trong tự mã hoá.
- **Tận dụng nhiều đặc trưng đồng thời:** đầu vào tại mỗi bước có thể gồm giá trị đo, thời tiết và mã hoá thời gian, trong khi nhiều mô hình tái tạo trên LEAD chỉ dùng chuỗi `meter_reading` đơn biến.

Nhược điểm:

- **Tính toán tuần tự:** mỗi bước phụ thuộc bước trước nên khó song song hoá theo trục thời gian, thời gian huấn luyện lâu hơn mạng tích chập trên cùng độ dài chuỗi.
- **Nhạy với độ dài cửa sổ và siêu tham số:** chất lượng phụ thuộc vào w, số tầng, số đơn vị ẩn và cách khởi tạo trạng thái ở đầu cửa sổ.
- **Không tự có cơ chế xử lý mất cân bằng:** cần kết hợp hàm mất mát có trọng số hoặc focal loss, nếu không mô hình hội tụ về dự đoán lớp đa số.

2.2.2.2 GRU (Gated Recurrent Unit)

GRU rút gọn LSTM bằng hai cổng (cập nhật $\mathbf{z}_t$ và đặt lại $\mathbf{r}_t$), không có ô nhớ riêng (Cho et al., 2014):

$$\mathbf{z}_t = \sigma\left(\mathbf{W}_z[\mathbf{h}_{t-1}, \mathbf{x}_t]\right), \quad \mathbf{r}_t = \sigma\left(\mathbf{W}_r[\mathbf{h}_{t-1}, \mathbf{x}_t]\right)$$
$$\tilde{\mathbf{h}}_t = \tanh\left(\mathbf{W}[\mathbf{r}_t \odot \mathbf{h}_{t-1}, \mathbf{x}_t]\right), \quad \mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t$$

Ưu điểm:

- **Ít tham số hơn LSTM:** chỉ có hai cổng và không có ô nhớ riêng, nên huấn luyện nhanh hơn và dùng ít bộ nhớ GPU hơn, hữu ích với hàng triệu bước thời gian.
- **Chất lượng thường tương đương LSTM:** trên nhiều bài toán chuỗi hai kiến trúc cho kết quả gần nhau, nên GRU là lựa chọn mặc định kinh tế khi cần khảo sát nhiều cấu hình.

Nhược điểm:

- **Biểu diễn kém linh hoạt hơn LSTM:** không có ô nhớ tách biệt, có thể kém hơn khi cần nhớ rất lâu trên chuỗi dài.
- **Cùng hạn chế tuần tự của họ RNN:** không song song hoá được theo thời gian.

2.2.2.3 BiLSTM / BiGRU (Mạng hồi quy hai chiều)

Mạng hai chiều chạy hai mạng hồi quy ngược chiều nhau và ghép trạng thái ẩn (Schuster & Paliwal, 1997):

$$\mathbf{h}_t = \left[\overrightarrow{\mathbf{h}}_t; \overleftarrow{\mathbf{h}}_t\right], \qquad \hat{p}_t = \sigma\left(\mathbf{w}^\top \mathbf{h}_t + b\right)$$

Với bài toán gán nhãn từng giờ, $\hat{p}_t$ được tính tại mọi bước trong một đoạn chuỗi, nên một lần chạy cho ra nhãn của cả đoạn.

Ưu điểm:

- **Khai thác ngữ cảnh cả hai phía:** thời điểm t được đánh giá dựa trên cả quá khứ lẫn tương lai gần, phù hợp với bất thường dạng đoạn liên tục (ví dụ giá trị bị kẹt trong nhiều giờ) vì mô hình biết đoạn đó kéo dài bao lâu.
- **Huấn luyện có giám sát trên toàn đoạn:** một đoạn dài cho nhiều nhãn cùng lúc, giảm lượng tính toán dư thừa so với cửa sổ trượt bước 1.

Nhược điểm:

- **Không dùng được cho cảnh báo thời gian thực:** mô hình cần dữ liệu tương lai nên chỉ phù hợp phát hiện bất thường ngoại tuyến (offline). Điều này phải được nêu rõ khi báo cáo kết quả.
- **Chi phí gấp đôi:** hai chiều nhân đôi số phép tính và tham số so với mạng một chiều.

2.2.3 Nhóm Mạng Tích chập thời gian (Temporal Convolutional Networks)

2.2.3.1 TCN (Temporal Convolutional Network)

TCN dùng tích chập nhân quả giãn nở (causal dilated convolution) kết hợp khối dư (residual block) để xử lý chuỗi (Bai et al., 2018). Tích chập nhân quả đảm bảo đầu ra tại t chỉ phụ thuộc đầu vào từ t trở về trước, và giãn nở cho phép tăng vùng nhìn mà không tăng số tham số:

$$(F *_d \mathbf{x})(t) = \sum_{i=0}^{k-1} f(i) \cdot \mathbf{x}_{t-d\cdot i}$$

trong đó k là kích thước nhân, f là bộ lọc và d là hệ số giãn nở. Khi xếp L khối dư, mỗi khối gồm hai tích chập với hệ số giãn nở $d = 2^l$ $(l = 0, \ldots, L-1)$, vùng nhìn (receptive field) của mạng là:

$$R = 1 + 2(k-1)\left(2^L - 1\right)$$

Ví dụ với $k = 3$ và $L = 6$ thì $R = 253$ giờ, đủ phủ chu kỳ tuần (168 giờ).

Ưu điểm:

- **Song song hoá hoàn toàn theo thời gian:** các tích chập tính đồng thời trên toàn chuỗi nên huấn luyện nhanh trên GPU, phù hợp với khối lượng khoảng 1,75 triệu bước thời gian.
- **Điều khiển vùng nhìn chính xác:** có thể chọn k và L để vùng nhìn phủ đúng chu kỳ ngày, chu kỳ tuần mong muốn, và công thức trên cho phép kiểm tra trước khi huấn luyện.

- **Huấn luyện ổn định:** gradient đi theo cấu trúc cây tích chập thay vì chuỗi tuần tự, ít gặp triệt tiêu gradient hơn RNN. Nghiên cứu của Bai et al. (2018) ghi nhận một kiến trúc tích chập đơn giản vượt LSTM trên nhiều bài toán chuỗi chuẩn, đồng thời có bộ nhớ hiệu dụng dài hơn.
- **Có biến thể không nhân quả:** thay phần đệm nhân quả bằng đệm đối xứng sẽ cho ngữ cảnh hai phía như BiLSTM, tiện cho thí nghiệm so sánh.

Nhược điểm:

- **Vùng nhìn cố định:** sự kiện nằm ngoài R giờ không ảnh hưởng đến dự đoán, trong khi RNN về lý thuyết có thể mang thông tin xa hơn.
- **Bộ nhớ khi suy luận cho chuỗi dài:** cần lưu kích hoạt trung gian của R bước gần nhất hoặc tính lại cả cửa sổ cho mỗi dự đoán.
- **Phụ thuộc kiểu đệm ở biên:** đầu mỗi đoạn có ít ngữ cảnh hơn nên cần chồng lấp giữa các đoạn khi suy luận.

2.2.4 Nhóm Tự mã hoá (Autoencoder-based)

Nhóm này được huấn luyện chỉ trên dữ liệu bình thường (hoặc dữ liệu được coi là bình thường), không dùng nhãn trong quá trình học. Mô hình học nén rồi tái tạo hành vi bình thường, nên đoạn nào tái tạo kém được coi là bất thường.

2.2.4.1 LSTM Autoencoder (EncDec-AD)

Mô hình gồm bộ mã hoá LSTM nén cửa sổ $\mathbf{X}$ thành vector tiềm ẩn $\mathbf{z}$ và bộ giải mã LSTM tái tạo lại cửa sổ (Malhotra et al., 2016):

$$\mathbf{z} = E_\phi(\mathbf{X}), \quad \hat{\mathbf{X}} = D_\theta(\mathbf{z}), \quad \mathcal{L} = \frac{1}{w}\sum_{i=1}^{w} \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|_2^2$$

Vector sai số tái tạo $\mathbf{e}_t$ được mô hình hoá bằng phân phối Gaussian ước lượng trên dữ liệu bình thường kiểm định, điểm bất thường là khoảng cách Mahalanobis:

$$a_t = (\mathbf{e}_t - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{e}_t - \boldsymbol{\mu})$$

Với chuỗi đơn biến ($d = 1$), điểm này rút gọn thành sai số bình phương đã chuẩn hoá.

Ưu điểm:

- **Không cần nhãn khi huấn luyện:** phù hợp với thực tế thiếu nhãn trong giám sát năng lượng, và có thể dùng cho các toà nhà mới chưa được gán nhãn.
- **Bắt tốt bất thường làm gãy mẫu hình tuần hoàn:** bất thường khác biệt rõ so với dạng ngày/tuần bình thường sẽ có sai số tái tạo lớn.
- **Tạo được điểm số liên tục:** có thể đưa sai số tái tạo vào mô hình Học máy làm đặc trưng bổ sung (tương tự vai trò của điểm Isolation Forest ở phần Học máy).

Nhược điểm:

- **Bỏ phí nhãn sẵn có:** khi bộ dữ liệu đã có nhãn, huấn luyện không giám sát thường kém mô hình có giám sát cùng ngân sách tính toán.
- **Rủi ro bỏ sót bất thường dạng "phẳng":** một đoạn giá trị không đổi (flatline) là chuỗi rất dễ tái tạo, nên sai số có thể thấp dù đoạn đó bị gán nhãn bất thường. Đây là giả thuyết nhóm sẽ kiểm chứng bằng thực nghiệm, và phù hợp với nhận xét của Orvati Nia et al. (2026) rằng mô hình tái tạo có thể bỏ lỡ lệch nhẹ không làm thay đổi đáng kể sai số theo điểm.
- **Cần chọn ngưỡng:** ngưỡng phải ước lượng trên tập kiểm định và dễ lệch giữa các toà nhà có thang đo khác nhau.
- **Nhạy với nhiễu trong tập "bình thường":** nếu dữ liệu huấn luyện lẫn bất thường chưa được gán nhãn, mô hình học luôn cả bất thường.

2.2.4.2 Autoencoder tích chập (Conv-AE) và Variational Autoencoder (VAE)

Conv-AE thay LSTM bằng tích chập một chiều để nén cửa sổ. VAE thêm ràng buộc xác suất lên không gian tiềm ẩn, tối ưu cận dưới bằng chứng (ELBO) (Kingma & Welling, 2014):

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}\left[\log p_\theta(\mathbf{x} \mid \mathbf{z})\right] - \beta\, D_{\text{KL}}\left(q_\phi(\mathbf{z} \mid \mathbf{x}) \,\|\, p(\mathbf{z})\right)$$

Handigol & Arjunan (2025) đã huấn luyện 1D-CNN Autoencoder và Convolutional VAE trên LEAD.

Ưu điểm:

- **Nhẹ và huấn luyện nhanh:** tích chập song song hoá tốt, phù hợp làm baseline tái tạo rẻ.
- **VAE có thành phần xác suất:** giảm nguy cơ "học thuộc lòng" đầu vào và cho phép dùng điểm xác suất tái tạo.

Nhược điểm:

- **Cùng hạn chế sai số tái tạo như EncDec-AD:** chất lượng phân tách phụ thuộc việc bất thường có làm tăng sai số tái tạo hay không.
- **Hiệu năng báo cáo thấp hơn mô hình sinh đối kháng:** trong cùng so sánh trên LEAD, Orvati Nia et al. (2026) ghi nhận VAE đạt F1 0,62 và LSTM-AE đạt 0,60 ở mức cửa sổ, thấp hơn TAnoGAN (0,67) và GAN-LSTM (0,89).
- **VAE thêm siêu tham số β:** cần cân bằng giữa chất lượng tái tạo và điều chuẩn không gian tiềm ẩn.

2.2.4.3 USAD (UnSupervised Anomaly Detection)

USAD dùng một bộ mã hoá chung và hai bộ giải mã D_1, D_2, huấn luyện đối kháng theo hai pha để vừa ổn định vừa khuếch đại sai số của đầu vào bất thường (Audibert et al., 2020). Với $AE_1 = D_1 \circ E$, $AE_2 = D_2 \circ E$ và n là chỉ số epoch hiện tại:

$$\mathcal{L}_{AE_1} = \frac{1}{n} \left\| \mathbf{W} - AE_1(\mathbf{W}) \right\|_2 + \left(1 - \frac{1}{n}\right) \left\| \mathbf{W} - AE_2\left(AE_1(\mathbf{W})\right) \right\|_2$$

$$\mathcal{L}_{AE_2} = \frac{1}{n} \left\| \mathbf{W} - AE_2(\mathbf{W}) \right\|_2 - \left(1 - \frac{1}{n}\right) \left\| \mathbf{W} - AE_2\left(AE_1(\mathbf{W})\right) \right\|_2$$

Điểm bất thường là tổ hợp tuyến tính $\alpha \left\| \mathbf{W} - AE_1(\mathbf{W}) \right\| + \beta \left\| \mathbf{W} - AE_2(AE_1(\mathbf{W})) \right\|$ với $\alpha + \beta = 1$.

Ưu điểm:

- **Huấn luyện nhanh và ổn định hơn GAN:** chỉ gồm các mạng tự mã hoá, không cần tối ưu tiềm ẩn khi suy luận như các mô hình GAN dựa trên đảo ánh xạ.
- **Phù hợp dữ liệu lớn:** thiết kế hướng đến yêu cầu về tốc độ huấn luyện và độ bền vững trong môi trường công nghiệp.

Nhược điểm:

- **Thiết kế cho chuỗi đa biến trong hệ thống IT/công nghiệp:** chưa có đánh giá công bố trên dữ liệu năng lượng toà nhà mà nhóm biết, nên hiệu quả trên LEAD cần kiểm chứng.
- **Vẫn là hệ hình tái tạo không giám sát:** chịu cùng rủi ro bỏ sót bất thường phẳng và không dùng nhãn.

2.2.5 Nhóm Mô hình sinh đối kháng (GAN-based)

2.2.5.1 AnoGAN, TAnoGAN và GAN-LSTM

Mạng sinh đối kháng (GAN) gồm bộ sinh G và bộ phân biệt D chơi trò chơi minimax. Sau khi huấn luyện trên dữ liệu bình thường, bộ sinh học được phân phối của hành vi bình thường:

$$\min_G \max_D \; \mathbb{E}_{\mathbf{x}} \left[\log D(\mathbf{x}) \right] + \mathbb{E}_{\mathbf{z}} \left[\log \left(1 - D(G(\mathbf{z})) \right) \right]$$

Vì GAN không có bộ mã hoá, khi phát hiện bất thường phải tìm vector tiềm ẩn $\mathbf{z}^*$ tái tạo tốt nhất cửa sổ cần kiểm tra (Schlegl et al., 2017; Bashar & Nayak, 2020). Orvati Nia et al. (2026) dùng:

$$\mathbf{z}^* = \arg\min_{\mathbf{z}} \; (1 - \lambda) \left\| \mathbf{x} - G(\mathbf{z}) \right\|_1 + \lambda \left\| f_D(\mathbf{x}) - f_D(G(\mathbf{z})) \right\|_1$$

với $f_D(\cdot)$ là đặc trưng trung gian của bộ phân biệt và $\lambda = 0{,}1$. Điểm bất thường $S(\mathbf{x})$ là giá trị hàm mục tiêu tại $\mathbf{z}^*$. GAN-LSTM thay các tầng của G và D bằng LSTM; bộ sinh nhận vector tiềm ẩn 100 chiều qua ba tầng LSTM, bộ phân biệt dùng một tầng LSTM.

Trên dữ liệu năng lượng, các biến thể này đã được áp dụng trong ba nghiên cứu: Prabhu et al. (2024) dùng 1D-DCGAN với hàm mất mát Soft-DTW và tái tạo song song, thử nghiệm trên 15 toà nhà; Handigol & Arjunan (2025) báo cáo DCGAN đạt F1 0,697,

cao nhất trong số các phương pháp họ so sánh trên 200 toà nhà; Orvati Nia et al. (2026) báo cáo GAN-LSTM đạt F1 0,89 với cửa sổ 60 giờ.

Ưu điểm:

- **Mô hình hoá phân phối của hành vi bình thường:** không chỉ tái tạo mà còn học sinh ra chuỗi giống thật, nên bắt được lệch tinh tế hơn mô hình tái tạo thuần tuý theo báo cáo trên LEAD.
- **Điểm bất thường kết hợp sai số tái tạo và đặc trưng bộ phân biệt:** hai tín hiệu bổ sung cho nhau.
- **Có kết quả công bố trực tiếp trên LEAD:** thuận lợi cho phần đối chiếu và mở rộng của đề tài.

Nhược điểm:

- **Chi phí suy luận rất lớn:** mỗi cửa sổ cần một vòng tối ưu vector tiềm ẩn. Orvati Nia et al. (2026) dùng 300 bước tối ưu mỗi cửa sổ, nên việc chấm điểm từng giờ trên 1,75 triệu bước là không thực tế, mà chỉ khả thi khi chấm điểm theo cửa sổ không chồng lấp.
- **Huấn luyện bất ổn định:** cân bằng giữa G và D khó duy trì, kết quả nhạy với khởi tạo và siêu tham số (Orvati Nia et al. phải theo dõi độ chính xác của bộ phân biệt để kiểm tra ổn định).
- **Không dùng nhãn và chỉ dùng chuỗi đơn biến:** các nghiên cứu trên LEAD huấn luyện chỉ trên cửa sổ bình thường và không đưa thời tiết hay đặc trưng toà nhà vào.
- **Kết quả không so sánh trực tiếp được:** F1 0,89 được tính ở mức cửa sổ 60 giờ (một cửa sổ bị coi là bất thường nếu có ít nhất một giờ bất thường), dễ hơn nhiều so với đánh giá theo từng giờ. Vì vậy con số này không thể đặt cạnh F1 theo từng điểm của các mô hình trong đề tài.

2.2.6 Nhóm Transformer

2.2.6.1 Transformer Encoder, Anomaly Transformer và TranAD

Transformer dùng cơ chế tự chú ý (self-attention) để mọi vị trí trong cửa sổ liên hệ trực tiếp với nhau (Vaswani et al., 2017):

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right)\mathbf{V}$$

Chi phí tính toán của một tầng chú ý là $\mathcal{O}(w^2 d)$ theo độ dài cửa sổ w. Anomaly Transformer đề xuất tiêu chí *Association Discrepancy*: do bất thường hiếm nên khó xây dựng liên kết mạnh với toàn chuỗi và liên kết của nó tập trung vào các điểm lân cận, vì vậy sự khác biệt giữa liên kết tiên nghiệm và liên kết chuỗi được dùng để phân biệt bất thường (Xu et al., 2022). TranAD dùng bộ mã hoá chú ý với tự điều kiện hoá theo điểm tập trung (focus score), huấn luyện đối kháng và học meta (MAML) để huấn luyện được với dữ liệu hạn chế (Tuli et al., 2022).

Ưu điểm:

- **Mô hình hoá quan hệ xa không phụ thuộc khoảng cách:** bất kỳ hai giờ nào trong cửa sổ cũng liên hệ trực tiếp, phù hợp chu kỳ ngày/tuần.
- **Song song hoá theo thời gian:** không có phụ thuộc tuần tự như RNN.
- **Có kết quả mạnh trên các bộ chuẩn không giám sát:** Anomaly Transformer đạt kết quả tốt nhất trên sáu bộ chuẩn theo bài báo gốc; TranAD báo cáo tăng F1 tối đa 17% và giảm thời gian huấn luyện tối đa 99% so với các phương pháp đối sánh.

Nhược điểm:

- **Cần nhiều dữ liệu và dễ quá khớp:** đề tài chỉ có 200 chuỗi toà nhà, với dung lượng mô hình lớn thì rủi ro quá khớp cao hơn mạng hồi quy hoặc tích chập nhỏ.
- **Chi phí bậc hai theo độ dài cửa sổ:** với $w = 168$ vẫn chấp nhận được nhưng tăng nhanh khi muốn nhìn xa hơn.
- **Thiết kế và đánh giá cho chuỗi đa biến không giám sát:** không tận dụng nhãn; bài báo Anomaly Transformer (theo mã nguồn công bố) dùng quy tắc điều chỉnh kết quả theo đoạn (adjustment) khi đánh giá, vốn có thể làm điểm số cao hơn so với đánh giá theo từng điểm. Nhóm không áp dụng quy tắc này nên không thể so sánh trực tiếp con số của các bài báo đó.
- **Chưa có đánh giá trên dữ liệu năng lượng LEAD:** hiệu quả cần kiểm chứng.

2.2.7 Kỹ thuật huấn luyện trên dữ liệu mất cân bằng

Với tỷ lệ bất thường khoảng 2,1%, mô hình Học sâu có giám sát cần hàm mất mát phù hợp. Có hai lựa chọn chính.

2.2.7.1 Binary Cross-Entropy có trọng số lớp

$$\mathcal{L}_{\text{WBCE}} = -\frac{1}{N}\sum_{i=1}^{N}\left[w_+\, y_i \log \hat{p}_i + (1-y_i)\log\left(1-\hat{p}_i\right)\right], \qquad w_+ \approx \frac{N_-}{N_+} \approx 45$$

Ưu điểm: đơn giản, một siêu tham số w_+ và tương ứng trực tiếp với `scale_pos_weight` đã dùng ở phần Học máy.

Nhược điểm: đặt w_+ bằng đúng tỷ lệ lớp có thể làm xác suất đầu ra lệch mạnh về phía lớp 1, nên ngưỡng quyết định phải được tối ưu lại và độ tin cậy xác suất giảm.

2.2.7.2 Focal Loss

Focal loss giảm trọng số của các mẫu dễ phân loại để tập trung vào mẫu khó (Lin et al., 2017):

$$\text{FL}(p_t) = -\alpha_t\left(1-p_t\right)^{\gamma}\log\left(p_t\right)$$

trong đó p_t là xác suất mô hình gán cho lớp đúng, $\gamma \geq 0$ là hệ số tập trung và α_t là trọng số lớp.

Ưu điểm: hàng triệu điểm bình thường dễ phân loại sẽ không chi phối gradient, phù hợp khi bất thường có hai loại dễ và khó.

Nhược điểm: thêm hai siêu tham số (α, γ) cần tinh chỉnh và xác suất đầu ra cũng cần hiệu chỉnh lại.

2.2.8 Các nghiên cứu liên quan trên chính bộ dữ liệu LEAD

Bảng dưới tóm tắt các nghiên cứu sử dụng LEAD mà nhóm đã tham khảo, kèm lưu ý về khả năng so sánh. Các con số là do chính tác giả bài báo báo cáo; nhóm không tự chạy lại.

- **LEAD1.0 (Gulati & Arjunan, 2022):** công bố phiên bản được gán nhãn của bộ dữ liệu ASHRAE Great Energy Predictor III gồm 1,413 chuỗi từ công tơ điện thông minh, kéo dài hơn một năm, và đối sánh tám phương pháp phát hiện bất thường hiện đại. Đây là mốc tham chiếu gốc của bộ dữ liệu.
- **GAN-LSTM (Orvati Nia et al., 2026):** dùng cửa sổ 60 giờ trên chuỗi tiêu thụ đơn biến, huấn luyện chỉ trên cửa sổ bình thường, đánh giá ở mức cửa sổ trên 206 toà nhà giữ lại; F1 0,89, so với Isolation Forest 0,52, One-Class SVM 0,56, LSTM-AE 0,60, Attention LSTM-AE 0,64, VAE 0,62 và TAnoGAN 0,67. Các giá trị này theo mức cửa sổ, không so sánh trực tiếp với đánh giá theo từng giờ.
- **DCGAN, Conv-AE, Conv-VAE (Handigol & Arjunan, 2025):** khảo sát học sâu không giám sát trên 200 toà nhà, so với Isolation Forest và LOF; kết luận học sâu tốt hơn các phương pháp không giám sát truyền thống ở bất thường dạng chuỗi, DCGAN đạt F1 0,697.
- **1D-DCGAN với Soft-DTW (Prabhu et al., 2024):** đề xuất hàm mất mát Soft-DTW cho tái tạo và tính toán song song nhiều điểm để tăng tốc phát hiện; thử nghiệm trên 15 toà nhà, mỗi toà một mô hình riêng.
- **Phân cụm toà nhà rồi huấn luyện riêng (Cansever & Konyar, 2026):** phân cụm toà nhà theo kiểu tiêu thụ bằng K-means rồi phát hiện bất thường độc lập trong từng cụm, bằng các mô hình Isolation Forest, LOF, XGBoost, Random Forest và LightGBM; mô hình huấn luyện trên các toà nhà có mẫu tiêu thụ tương tự cải thiện đáng kể so với mô hình toàn cục. Ý tưởng này chưa được áp dụng cho mô hình Học sâu, nên là hướng mở rộng của nhóm.

Các nghiên cứu trên khác nhau về tập toà nhà (15, 200 hoặc 406 toà), về đơn vị đánh giá (cửa sổ hoặc từng giờ) và về việc có dùng nhãn hay không. Vì vậy nhóm sẽ dùng chúng làm cơ sở ý tưởng chứ không đặt trực tiếp kết quả cạnh nhau. Ngoài ra, bảng đánh giá của Schmidl et al. (2022) trên 71 thuật toán và 976 tập chuỗi thời gian cho thấy việc chọn thuật toán phụ thuộc mạnh vào từng bài toán, nên cần đối chiếu thực nghiệm thay vì dựa vào kết quả công bố ở bộ dữ liệu khác.

2.2.9 Tổng hợp so sánh các họ mô hình Học sâu

Họ mô hình	**Hệ hình**	**Dùng nhãn**	**Ngữ cảnh thời gian**	**Chi phí**	**Phù hợp LEAD**
BiLSTM / BiGRU	Gán nhãn chuỗi	Có	Hai phía, dài	Trung bình	Cao (offline)
TCN	Gán nhãn chuỗi	Có	Cố định theo R	Thấp	Cao
LSTM-AE (EncDec-AD)	Tái tạo	Không	Trong cửa sổ	Trung bình	Trung bình
Conv-AE / VAE	Tái tạo	Không	Trong cửa sổ	Thấp	Thấp đến trung bình
USAD	Tái tạo đối kháng	Không	Trong cửa sổ	Thấp	Chưa rõ
GAN-LSTM / TAnoGAN	Sinh đối kháng	Không	Trong cửa sổ	Rất cao khi suy luận	Trung bình (mở rộng)
Transformer / TranAD	Tái tạo hoặc gán nhãn	Tuỳ biến thể	Toàn cửa sổ	Bậc hai theo w	Thấp đến trung bình

Cột "Phù hợp LEAD" là đánh giá của nhóm dựa trên các tiêu chí: tận dụng được nhãn sẵn có, khả năng chấm điểm từng giờ trên khoảng 1,75 triệu quan trắc, và rủi ro quá khớp với chỉ 200 chuỗi. Đánh giá này sẽ được kiểm chứng bằng thực nghiệm ở phần triển khai.

3 Khám phá Dữ liệu (EDA) và Tiền xử lý Dữ liệu

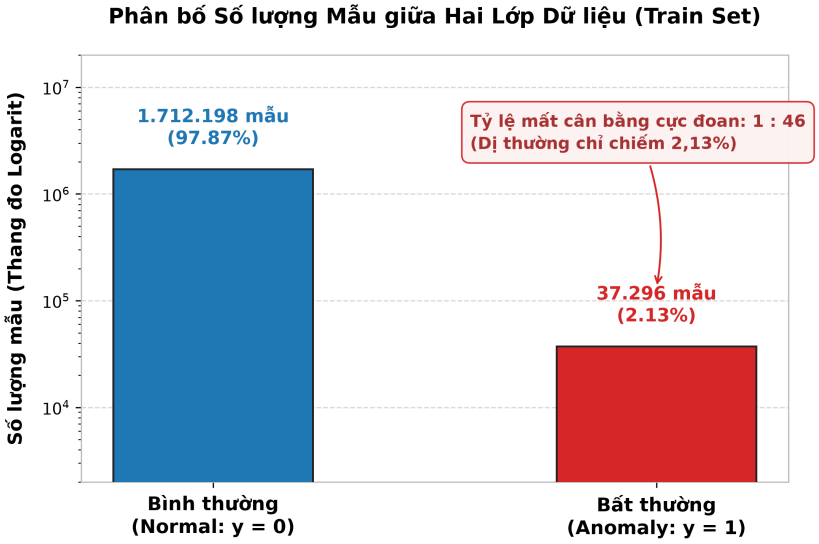
Dựa trên hai tệp đặc trưng `train_features.csv` và `test_features.csv` đã giới thiệu ở Chương 1, chương này tập trung phân tích khám phá dữ liệu (EDA) ban đầu, xây dựng quy trình tiền xử lý chuẩn hóa và kiểm toán dữ liệu sau xử lý. Toàn bộ quy trình được xây dựng nhất quán và thực thi thông qua notebook thực nghiệm `preprocessingforALL`. Nhằm mục đích đánh giá thực nghiệm xem việc tích hợp thêm ngữ cảnh khu vực địa lý có thực sự mang lại sự khác biệt và giúp cải thiện khả năng nhận diện bất thường hay không, nhóm nghiên cứu thiết lập quy trình tạo ra song song hai bộ dữ liệu thực nghiệm: bộ dữ liệu cơ sở (Baseline) và bộ dữ liệu mở rộng tương tác khu vực (Zone-enhanced).

3.1 Khám phá Dữ liệu Ban đầu

3.1.1 Phân tích sự Mất cân bằng Lớp Dữ liệu

Dữ liệu nhãn bất thường phản ánh trạng thái hoạt động của hệ thống phụ tải điện: $y = 0$ tương ứng với trạng thái bình thường (*Normal*) và $y = 1$ tương ứng với trạng thái bất thường (*Anomaly*). Thống kê trên toàn bộ 1.749.494 bản ghi của tập huấn luyện cho kết quả phân bố như sau:

- **Lớp bình thường ($y = 0$):** 1.712.198 bản ghi, chiếm tỷ lệ xấp xỉ 97,87%.
- **Lớp bất thường ($y = 1$):** 37.296 bản ghi, chỉ chiếm tỷ lệ khoảng 2,13%.



Hình 1: **Phân phối mức độ mất cân bằng giữa nhãn bình thường và bất thường**

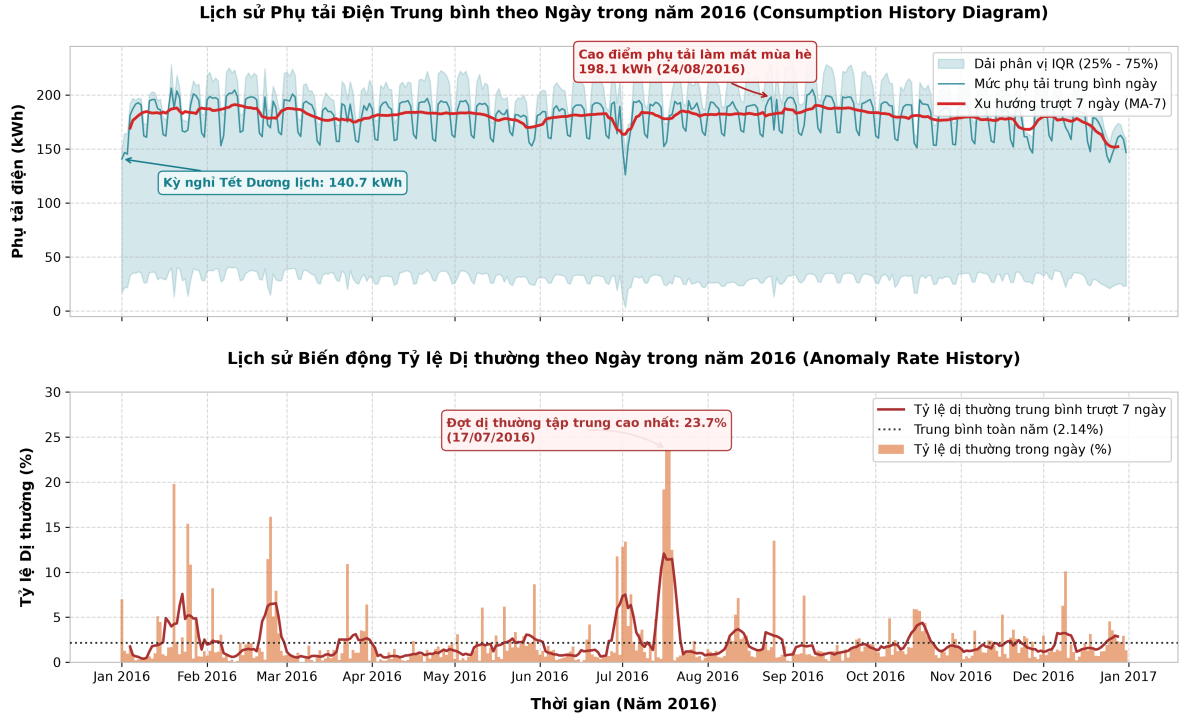
Hình 1 trực quan hóa tỷ lệ mất cân bằng nghiêm trọng này thông qua biểu đồ cột trên thang đo logarit. Mức độ mất cân bằng tỷ lệ 1 : 46 đặt ra thách thức kỹ thuật lớn:

1. Nếu sử dụng hàm mất mát thông thường mà không điều chỉnh, mô hình sẽ có xu hướng tối ưu hóa bằng cách dự đoán toàn bộ mẫu là lớp đa số, dẫn đến chỉ số Accuracy rất cao ($> 97\%$) nhưng hoàn toàn mất khả năng nhận diện các sự cố thực tế.

2. Nếu sử dụng ngưỡng quyết định mặc định $\tau = 0{,}5$, đại đa số các mẫu dị thường có xác suất dự đoán nằm trong khoảng $0{,}1 - 0{,}4$ sẽ bị bỏ sót, khiến chỉ số Recall và F1-Score bị suy giảm nghiêm trọng. Do đó, việc áp dụng kỹ thuật tối ưu hóa ngưỡng cắt xác suất (Threshold Moving) là điều kiện tiên quyết trong các giai đoạn sau.

3.1.2 Toàn cảnh Lịch sử Phụ tải và Phân bố Dị thường theo Thời gian

Nhằm nắm bắt toàn diện hành vi phụ tải ở cấp độ vĩ mô và sự phân bố của các biến cố dị thường xuyên suốt 366 ngày trong năm 2016 (năm nhuận), nhóm nghiên cứu xây dựng lược đồ lịch sử vận hành trên toàn bộ 200 tòa nhà thuộc tập huấn luyện (Hình 2). Biểu đồ này được trích xuất trực tiếp từ hàm phân tích thời gian `plot_eda_snapshot()` tại Bước 4 của quy trình thực nghiệm.



Hình 2: **Lược đồ Lịch sử Phụ tải Điện và Tỷ lệ Dị thường theo Ngày trong năm 2016**

Từ lược đồ lịch sử vĩ mô tại Hình 2, hai quy luật vận hành then chốt được khám phá:

1. **Đặc thù lịch sử phụ tải trung bình ngày (biểu đồ trên):**
   - Mức tiêu thụ điện bình quân toàn hệ thống đạt mức trung bình 179,88 kWh. Đường trung bình trượt 7 ngày (đường màu đỏ, tính bình quân theo từng tuần để triệt tiêu dao động giữa ngày làm việc và cuối tuần) cho thấy xu hướng phụ tải tăng cao rõ rệt vào các tháng mùa hè (tháng 6 đến tháng 8), đạt đỉnh 198,1 kWh vào ngày 24/08/2016 do nhu cầu vận hành tối đa của hệ thống làm mát trung tâm (HVAC).
   - Ngược lại, vào các kỳ nghỉ lễ lớn như Tết Dương lịch (01/01/2016) hoặc kỳ nghỉ mùa đông, mức tiêu thụ sụt giảm sâu xuống 140,7 kWh do các hoạt động làm việc và học tập tạm ngưng.

- Dải phân vị $25\% - 75\%$ (*IQR band*, tô nền xanh nhạt) phản ánh sự phân hóa mạnh mẽ về quy mô công trình: các tòa nhà giáo dục và văn phòng nhỏ duy trì phụ tải nền thấp ($20 - 40$ kWh), trong khi các cơ sở phức hợp lớn tiêu thụ liên tục trên 200 kWh.

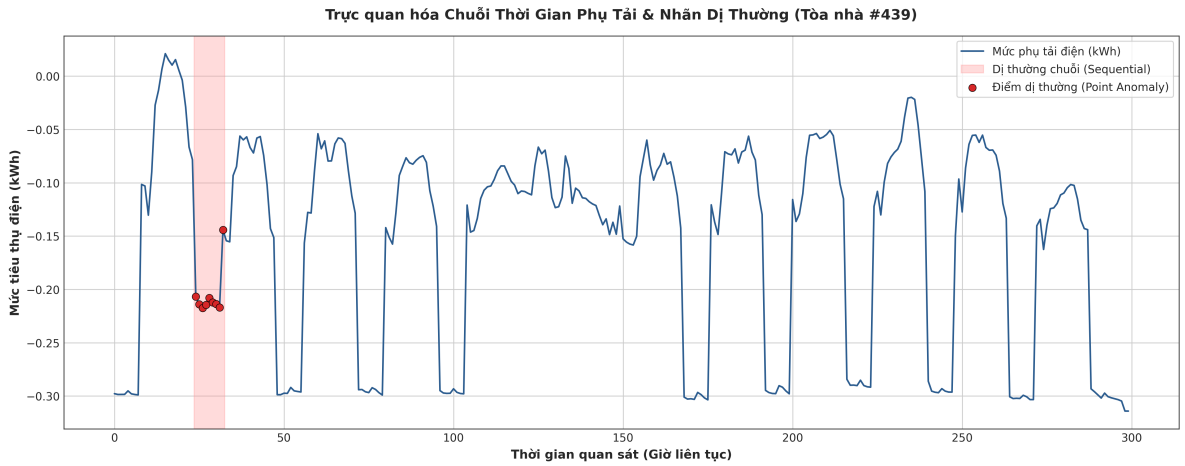
2. **Đặc thù lịch sử xuất hiện dị thường theo thời gian (biểu đồ dưới):**

- Mặc dù tỷ lệ dị thường bình quân cả năm chỉ là 2,14% (đường chấm đen), các điểm dị thường không phân bố ngẫu nhiên đồng đều mà tập trung thành từng đợt sự cố hệ thống kéo dài nhiều ngày liên tiếp.
- Tiêu biểu nhất là đợt bùng phát dị thường vào trung tuần tháng 7 (đạt đỉnh 23,7% vào ngày 17/07/2016) và các đợt biến động mạnh vào tháng 2 và tháng 3. Hiện tượng cụm dị thường theo thời gian chứng minh rằng việc mô hình hóa chuỗi thời gian thông qua các đặc trưng trễ, trung bình trượt, và tương tác vùng khí hậu là hoàn toàn cần thiết để phát hiện kịp thời các sự cố mang tính chuỗi.

3.1.3 Phân loại Hình thái Dị thường Phụ tải trên Chuỗi Thời gian

Trong khi Mục 3.1.2 quan sát xu hướng dài hạn theo ngày trên toàn mạng lưới, mục này đi sâu vào độ phân giải từng giờ tại một công trình đại diện (Tòa nhà #439, Hình 3) nhằm nhận diện quy luật phụ tải cơ sở và phân loại các hình thái dị thường thực tế.

Chuỗi thời gian phụ tải theo giờ thể hiện hai chu kỳ sinh hoạt cơ sở: chu kỳ 24 giờ ngày/đêm (*Diurnal Cycle* với đỉnh phụ tải vào giờ làm việc 8h - 17h và đáy phụ tải nền vào ban đêm) cùng chu kỳ tuần (*Weekly Pattern* với mức phụ tải giảm sút rõ rệt vào cuối tuần). Dựa trên sự sai lệch so với hai quy luật nền tảng này, các điểm dị thường trong dữ liệu được phân chia thành hai nhóm hình thái chính:



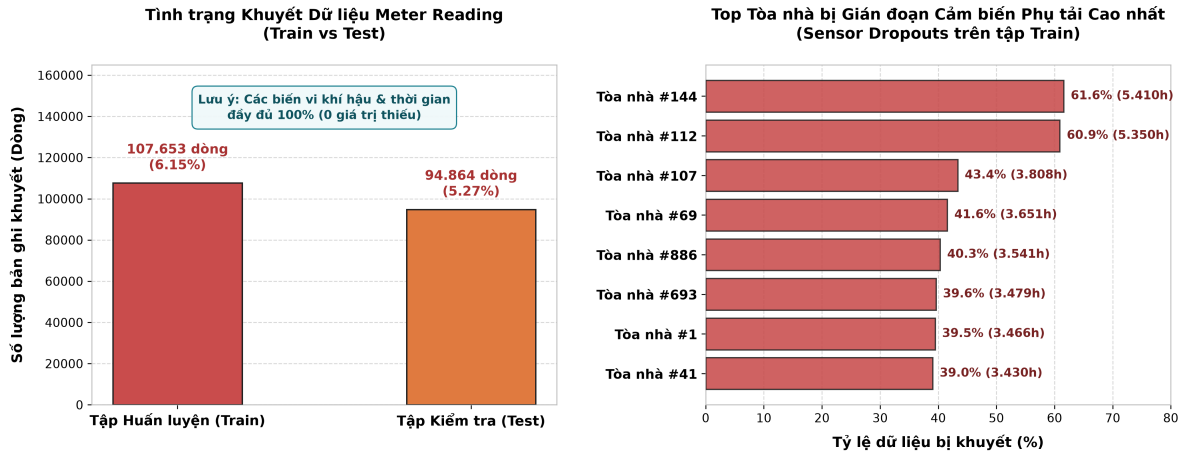
Hình 3: **Trực quan hóa chuỗi thời gian phụ tải điện theo giờ và các dạng dị thường tại Tòa nhà #439**

1. **Dị thường điểm (Point Anomaly):** Biểu hiện qua các xung đột biến tức thời tăng vọt hoặc sụt giảm về 0 đột ngột trong một vài giờ lẻ. Nguyên nhân thường xuất phát từ sự cố chập tải cục bộ, khởi động thiết bị công suất cực lớn không báo trước, hoặc cảm biến đo bị ngắt quãng tín hiệu tức thời.

2. **Dị thường theo chuỗi (Sequential / Collective Anomaly):** Biểu hiện qua một đoạn liên tục nhiều giờ hoặc nhiều ngày mà mức tiêu thụ điện giữ nguyên ở mức cao bất thường (ví dụ: hệ thống điều hòa trung tâm bị bỏ quên không tắt trong suốt chuỗi ngày cuối tuần, thể hiện rõ tại Hình 3), hoặc phụ tải dao động hỗn loạn phá vỡ hoàn toàn chu kỳ ngày/đêm thông thường. Dạng dị thường này đòi hỏi mô hình phải kết hợp các đặc trưng trễ, biến chu kỳ lượng giác và độ lệch chuẩn trượt để nhận diện.

3.1.4 Nhiễu Cảm biến và Tình trạng Thiếu Dữ liệu

Bên cạnh bài toán mất cân bằng nhãn, tình trạng nhiễu và đứt gãy tín hiệu đo lường từ đồng hồ thông minh là thách thức lớn thứ hai được phát hiện qua bước EDA. Kết quả thống kê chi tiết được trực quan hóa tại Hình 4.



Hình 4: **Thống kê Dữ liệu Khuyết: So sánh Train vs Test (trái) và Top Tòa nhà bị Gián đoạn Cảm biến Phụ tải Cao nhất (phải)**

Từ Hình 4, nhóm nghiên cứu ghi nhận các kết luận then chốt sau:

1. **Tỷ lệ khuyết thuộc tính phụ tải (biểu đồ trái):** Biến `meter_reading` bị khuyết 107.653 bản ghi (6,15%) trong tập huấn luyện và 94.864 bản ghi (5,27%) trong tập kiểm tra. Đáng chú ý, toàn bộ các thuộc tính thời tiết môi trường (`air_temperature`, `dew_temperature`, `wind_speed`, ...) và tem thời gian `timestamp` đều đạt độ toàn vẹn 100% (0 giá trị thiếu). Điều này khẳng định hệ thống trạm khí tượng hoạt động hoàn toàn ổn định, nguyên nhân thiếu dữ liệu thuần túy do kết nối truyền thông IoT từ đồng hồ thông minh về máy chủ đo lường bị ngắt quãng.

2. **Tính cục bộ của sự cố cảm biến (biểu đồ phải):** Dữ liệu thiếu không rải đều mà tập trung nghiêm trọng tại một số công trình cá biệt. Điển hình như Tòa nhà #144 bị khuyết 5.410 giờ (61,6%) và Tòa nhà #112 bị khuyết 5.350 giờ (60,9%) dữ liệu trong năm. Việc mất tín hiệu kéo dài hàng ngàn giờ liên tiếp đặt ra yêu cầu quy trình tiền xử lý phải có giải pháp điền khuyết chuỗi thời gian phù hợp, tránh gây biến dạng phân phối thực tế.

3.2 Quy trình Tiền xử lý Dữ liệu

Nhằm chuẩn bị không gian đặc trưng tối ưu và loại bỏ rủi ro rò rỉ dữ liệu (*data leakage*), quy trình tiền xử lý được chuẩn hóa theo 7 bước biến đổi đặc trưng cốt lõi (tương ứng

với các khối xử lý từ Bước 2 đến Bước 8 trong notebook `preprocessingforALL.ipynb`). Toàn bộ các thao tác nạp dữ liệu và khám phá sơ bộ đã được trình bày độc lập tại Mục 3.1.

Đặc biệt, trong nghiên cứu này, nhóm chủ động thiết kế quy trình nhằm tạo ra song song **hai bộ dữ liệu thực nghiệm**:

1. **Bộ dữ liệu cơ sở (Baseline Dataset):** Bao gồm đầy đủ các đặc trưng phụ tải, khí tượng, biến chu kỳ lượng giác và đặc tính công trình sau chuẩn hóa chuẩn mực.

2. **Bộ dữ liệu mở rộng khu vực (Zone-enhanced Dataset):** Được tích hợp bổ sung các đặc trưng tương tác vùng khí hậu và quy mô công trình theo địa bàn (`zone_interaction`, `site_sqft_mean`, `use_sqft_mean`).

Mục tiêu cốt lõi của việc tạo hai bộ dữ liệu là nhằm phục vụ đối chứng thực nghiệm ở các chương sau: làm rõ câu hỏi khoa học rằng liệu việc mô hình hóa ngữ cảnh khu vực địa lý có thực sự mang lại sự khác biệt và giúp cải thiện vượt bậc độ chính xác phân loại dị thường (thông qua chỉ số F1-Score) hay không.

Chi tiết 7 bước biến đổi đặc trưng được triển khai tuần tự như sau:

1. **Bước 1: Tách Nhãn mục tiêu và Định danh ra khỏi Ma trận Đặc trưng.** Vector nhãn y_{train} = `anomaly` được tách riêng và đặt chỉ mục liên tục để phục vụ huấn luyện có giám sát. Đồng thời, cột định danh `row_id` ở tập kiểm tra được lưu trữ độc lập để ghép kết quả dự đoán cuối cùng (`submission`). Toàn bộ hai cột này được loại bỏ khỏi ma trận đặc trưng X_{train} và X_{test}, bảo đảm mô hình không bị rò rỉ nhãn hoặc nhận diện mẫu dựa trên thứ tự dòng.

2. **Bước 2: Chuẩn hóa Timestamp và Mã hóa Chu kỳ Thời gian** (sin / cos)**.** Trường thời gian `timestamp` được ép kiểu sang định dạng `datetime64[ns]` chuẩn. Do thời gian có tính chu kỳ tuần hoàn khép kín (giờ 23 nối tiếp giờ 0, tháng 12 nối tiếp tháng 1), việc sử dụng giá trị số nguyên đơn thuần sẽ làm mất tính liên tục không gian. Do đó, các thành phần thời gian được mã hóa lượng giác trực tiếp:

$$x_{\sin} = \sin\left(\frac{2\pi t}{T}\right), \quad x_{\cos} = \cos\left(\frac{2\pi t}{T}\right)$$

   trong đó chu kỳ $T = 24$ cho giờ trong ngày (`hour_sin`, `hour_cos`), $T = 7$ cho ngày trong tuần (`weekday_sin`, `weekday_cos`), và $T = 12$ cho tháng trong năm (`month_sin`, `month_cos`). Sau khi sinh các biến lượng giác, các cột thời gian gốc (`hour`, `weekday`, `month`) và các tọa độ thời gian cũ được loại bỏ hoàn toàn để tránh hiện tượng đa cộng tuyến.

3. **Bước 3: Đồng bộ Không gian Đặc trưng, Phân loại Kiểu dữ liệu, Tạo Cờ Missing và Loại bỏ Đặc trưng không phù hợp.**

   - **Tạo cờ missing:** Trước khi điền khuyết, nhóm khởi tạo biến cờ nhị phân:

$$\texttt{meter_reading_was_missing} = \begin{cases} 1, & \text{nếu } \texttt{meter_reading} \text{ bị thiếu (NaN)} \\ 0, & \text{ngược lại} \end{cases}$$

     Biến cờ này lưu giữ tín hiệu quan trọng về sự gián đoạn kết nối IoT của đồng hồ đo.

- **Đồng bộ Schema và phân nhóm:** Căn chỉnh hai tập dữ liệu đạt cùng cấu trúc; phân loại tường minh danh sách biến định lượng (`numeric_columns`) và định tính (`categorical_columns`).
- **Loại bỏ đặc trưng không phù hợp:** Loại bỏ biến hằng số không phương sai (`year`, `gte_meter`), các tổ hợp thời gian trùng lặp (`weekday_hour`), và **đặc biệt quan trọng:** loại bỏ toàn bộ các đặc trưng gắn chặt với ID cụ thể của tòa nhà (`building_weekday_hour`, `building_month`, `gte_building_id`, ...). Do 100% các tòa nhà trong tập kiểm tra là công trình hoàn toàn mới chưa từng xuất hiện ở tập huấn luyện, việc giữ lại các biến đặc thù theo ID tòa nhà sẽ gây ra hiện tượng Overfitting nghiêm trọng.

4. **Bước 4: Điền giá trị thiếu cho Dữ liệu Định lượng bằng Nội suy Chuỗi thời gian.** Khác với các phép gán trung vị hoặc trung bình toàn cục làm biến dạng dáng điệu phụ tải, nhóm áp dụng phương pháp nội suy tuyến tính theo thời gian (`interpolate(method='time')`) được tính toán độc lập trong từng tòa nhà (`building_id`). Ở các khoảng biên đầu và cuối chuỗi, kỹ thuật *forward fill* và *backward fill* được kết hợp để lấp đầy 100% dữ liệu thiếu mà vẫn tôn trọng xu hướng động học thực tế.

5. **Bước 5: Xử lý Giá trị Ngoại lai (Outlier Treatment) bằng Khoảng Tứ phân vị IQR.** Đối với các biến thời tiết môi trường (`air_temperature`, `dew_temperature`, `wind_speed`, ...), nhóm áp dụng quy tắc khoảng tứ phân vị (*Interquartile Range - IQR*):

$$\text{IQR} = Q_3 - Q_1, \quad [\text{Ngưỡng dưới}, \text{Ngưỡng trên}] = [Q_1 - 1{,}5\text{IQR},\ Q_3 + 1{,}5\text{IQR}]$$

   Các quan trắc thời tiết vượt ra ngoài khoảng này do lỗi thiết bị đo khí tượng được kẹp (*clip*) về giá trị trung vị cục bộ.

   Đặc biệt lưu ý: Thuộc tính phụ tải `meter_reading` và các đặc trưng Target Encoding (`gte_`) được miễn trừ hoàn toàn khỏi bước này; việc ép phụ tải về trung vị sẽ trực tiếp triệt tiêu các mẫu dị thường mà mô hình cần nhận dạng.

6. **Bước 6: Chuẩn hóa Dữ liệu Định lượng (Z-score Normalization) và Tích hợp Đặc trưng Khu vực (Zone Features).**

   - **Chuẩn hóa Z-score:** Đưa các biến định lượng về phân phối có trung bình bằng 0 và độ lệch chuẩn bằng 1 bằng `StandardScaler`:

$$Z = \frac{x - \mu}{\sigma}$$

     Tham số μ, σ chỉ được ước lượng (*fit*) trên tập huấn luyện và áp dụng (*transform*) cho tập kiểm tra. Các biến cờ nhị phân (0/1), các biến chu kỳ $\sin$ / $\cos \in [-1, 1]$, và các biến tỷ lệ `gte_` $\in [0, 1]$ được giữ nguyên thang đo gốc.
   - **Tích hợp Đặc trưng Khu vực (Zone Features):** Để tạo ra bộ dữ liệu Zone-enhanced, nhóm xây dựng thêm 3 đặc trưng tương tác địa lý:
     (a) `zone_interaction` = CatCode(`site_id` $\|$ '_' $\|$ `primary_use`): Mô hình hóa nhu cầu tiêu thụ đặc thù theo từng vùng khí hậu và công năng.
     (b) `site_sqft_mean`: Quy mô diện tích sàn trung bình của từng khu vực đô thị (`site_id`).

(c) `use_sqft_mean`: Quy mô diện tích sàn trung bình theo từng nhóm công năng (`primary_use`).

Sự hiện diện của 3 thuộc tính này chính là điểm phân tách giữa hai bộ dữ liệu thực nghiệm (Baseline vs Zone-enhanced).

7. **Bước 7: Mã hóa Biến Phân loại (Categorical Encoding).** Nhóm áp dụng kết hợp hai chiến lược mã hóa danh mục tối ưu:

   - **One-Hot Encoding:** Dành cho các thuộc tính phân loại có lực lượng thấp như loại đồng hồ (`meter_0`, `meter_1`, ...) và công năng (`primary_use_Education`, ...), giúp giải thuật cây và mạng nơ-ron xử lý bình đẳng các nhóm không có quan hệ thứ bậc.
   - **Frequency Encoding (Mã hóa tần suất):** Dành cho các định danh có lực lượng cao như khu vực (`site_id`) và tòa nhà (`building_id`); mã hóa theo tần suất xuất hiện giúp phản ánh mức độ phổ biến của từng thực thể mà không làm bùng nổ số chiều.

3.3 Khám phá Dữ liệu sau Tiền xử lý

Sau khi hoàn tất toàn bộ chuỗi biến đổi tiền xử lý, nhóm nghiên cứu tiến hành kiểm toán dữ liệu và khám phá đối chiếu (tương ứng Bước 9 trong notebook thực nghiệm) nhằm đánh giá toàn diện sự thay đổi của tập dữ liệu trước khi bước vào giai đoạn huấn luyện mô hình.

3.3.1 Kiểm tra Tính Toàn vẹn và Phân bổ Đặc trưng

Quá trình kiểm tra ràng buộc nghiêm ngặt (`assert`) trên hai tập dữ liệu mang lại các kết quả kiểm toán sau:

1. **Bảo toàn tuyệt đối số lượng mẫu:** Tập huấn luyện giữ nguyên chính xác 1.749.494 dòng, tập kiểm tra giữ nguyên 1.800.567 dòng. Không có bất kỳ bản ghi nào bị xóa bỏ ngoài ý muốn.

2. **Triệt tiêu hoàn toàn giá trị thiếu:** Toàn bộ các thuộc tính đạt tỷ lệ hoàn chỉnh 100% (0 giá trị `NaN`).

3. **Đồng nhất không gian đặc trưng:** Hai tập huấn luyện và kiểm tra sở hữu không gian đặc trưng hoàn toàn trùng khớp, với tổng cộng 53 thuộc tính sẵn sàng cho mô hình hóa.

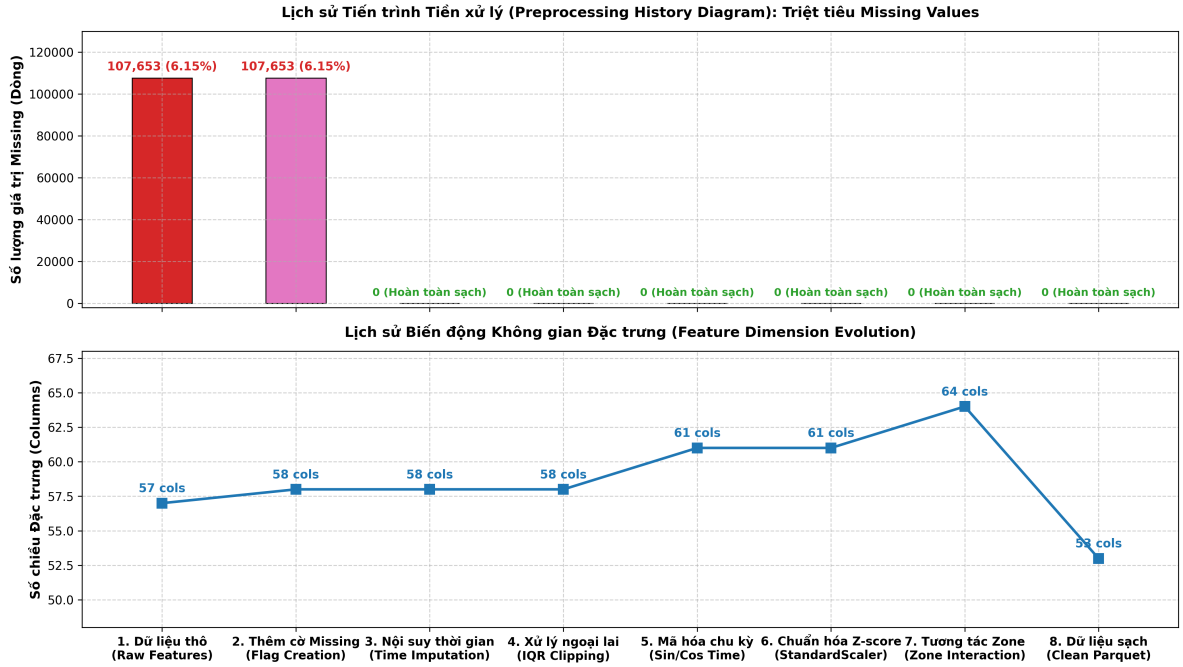
Bảng 4 tổng hợp chi tiết cấu trúc các nhóm đặc trưng còn giữ lại trong không gian biểu diễn cuối cùng.

Nhóm Đặc trưng	**Số lượng**	**Các thuộc tính tiêu biểu và Ý nghĩa**
Đặc trưng Phụ tải gốc	1	`meter_reading` (sau khi nội suy và Z-score).
Đặc trưng Cảm biến Khí tượng	6	`air_temperature`, `dew_temperature`, `wind_speed`, `wind_direction`, `precip_depth_1_hr`, `sea_level_pressure` (sau lọc IQR).
Chu kỳ Lượng giác	6	`hour_sin`, `hour_cos`, `weekday_sin`, `weekday_cos`, `month_sin`, `month_cos` (mô hình hóa chu kỳ tuần hoàn).
Đặc tính Công trình	2	`square_feet`, `is_holiday` (diện tích sàn và cờ ngày nghỉ).
Cờ Gián đoạn Cảm biến	1	`meter_reading_was_missing` (lưu dấu vết đứt gãy truyền thông).
Mã hóa Mục tiêu (GTE)	10	`gte_hour`, `gte_weekday`, `gte_month`, `gte_site_id`, `gte_primary_use`, `gte_meter_hour`, …
Tương tác Khu vực (Zone)	3	`zone_interaction`, `site_sqft_mean`, `use_sqft_mean` (phân hóa địa phương; tạo nên bộ dữ liệu Zone-enhanced).
Mã hóa Danh mục	24	Các cột One-Hot (`primary_use_*`, `meter_*`) và Frequency Encoding (`site_id`, `building_id`).

Bảng 4: **Tổng hợp phân loại các nhóm đặc trưng trong ma trận dữ liệu sau tiền xử lý**

3.3.2 Lược đồ Lịch sử Tiến trình Tiền xử lý (Preprocessing History Diagram)

Nhằm trực quan hóa tính liên tục của quá trình biến đổi dữ liệu qua từng giai đoạn, nhóm nghiên cứu xây dựng lược đồ lịch sử tiền xử lý tại Hình 5.



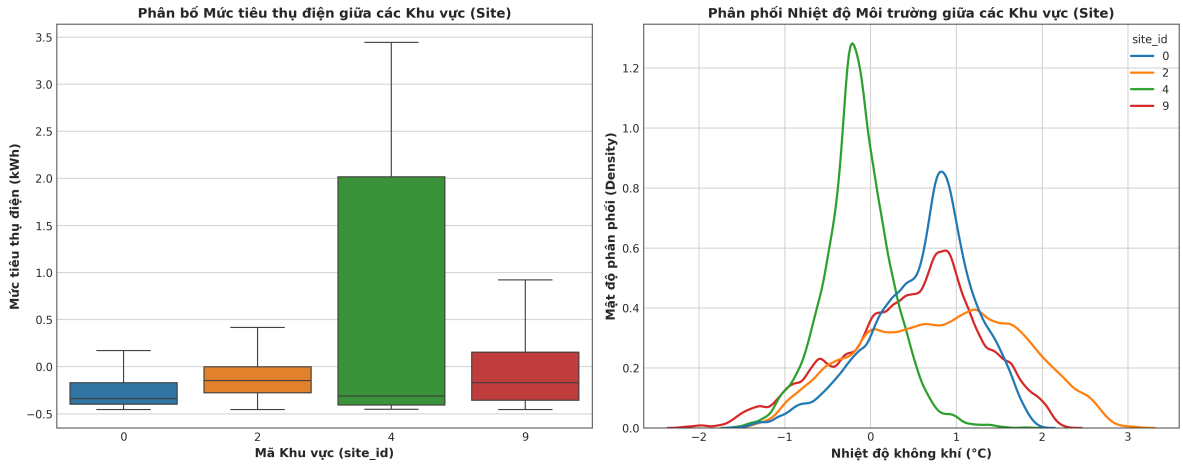
Hình 5: **Lược đồ Lịch sử Tiền xử lý (Preprocessing History Diagram): Diễn biến triệt tiêu giá trị thiếu và biến động không gian đặc trưng qua từng giai đoạn**

Lược đồ lịch sử tại Hình 5 thể hiện rõ:

- **Về dữ liệu thiếu (biểu đồ trên):** Tỷ lệ khuyết 6,15% ở biến phụ tải được giải quyết triệt để sau bước nội suy chuỗi thời gian, đưa toàn bộ hệ thống về trạng thái hoàn chỉnh 0% dữ liệu thiếu trước khi bước vào các phép toán chuẩn hóa.
- **Về không gian đặc trưng (biểu đồ dưới):** Số chiều đặc trưng xuất phát từ 57 cột ban đầu, mở rộng lên đỉnh 64 cột sau khi bổ sung cờ missing, các biến sin/cos và khối tương tác khu vực; sau đó được tinh giản về đúng 53 thuộc tính cốt lõi nhờ kiên quyết loại bỏ các biến trùng lặp và các biến gây rò rỉ ID tòa nhà.

3.3.3 Khám phá và Động lực Khoa học của Tương tác Khu vực (Zone EDA)

Để làm rõ vì sao nhóm nghiên cứu quyết định phát triển song song bộ dữ liệu Zone-enhanced bên cạnh bộ Baseline, Hình 6 trực quan hóa sự phân hóa thực tế về phụ tải và nhiệt độ giữa các khu vực địa lý tiêu biểu (`site_id` 0, 2, 4, 9).



Hình 6: **Phân bố Mức tiêu thụ điện (trái) và Phân phối Nhiệt độ (phải) giữa các Khu vực (Site 0, 2, 4, 9)**

Phân tích Hình 6 cho thấy hai quy luật môi trường mang tính quyết định:

- **Sự phân cực về mức tiêu thụ (biểu đồ trái):** Khu vực Site 0 và Site 2 có trung vị phụ tải thấp ($30 - 60\,\text{kWh}$) với biên độ dao động hẹp, trong khi Site 4 và Site 9 tiêu thụ liên tục ở mức rất cao ($> 180\,\text{kWh}$) và xuất hiện nhiều đuôi phân phối kéo dài.
- **Sự sai khác về đới khí hậu (biểu đồ phải):** Nhiệt độ không khí tại Site 0 tập trung chủ yếu trong vùng nóng ($25°\text{C} - 35°\text{C}$), đòi hỏi hệ thống điều hòa HVAC chạy liên tục. Ngược lại, Site 4 và Site 9 nằm trong đới khí hậu ôn đới lạnh với nhiệt độ chủ yếu dưới $15°\text{C}$, nơi nhu cầu sưởi ấm chiếm ưu thế.

Nếu chỉ sử dụng bộ dữ liệu cơ sở (Baseline) mà không tích hợp đặc trưng Zone, mô hình học máy sẽ bị ép phải khớp một hàm mục tiêu trung bình hóa trên toàn bộ 16 khu vực, dẫn đến việc ngộ nhận một mức phụ tải $100\,\text{kWh}$ tại Site 0 là dị thường (trong khi ở Site 4 đó lại là mức tải nền bình thường).

Chính vì vậy, việc tạo ra **hai bộ dữ liệu (Baseline và Zone-enhanced)** cho phép nhóm nghiên cứu tiến hành đánh giá thực nghiệm đa chiều ở Chương 4 và Chương 6, qua đó xác thực một cách định lượng xem việc cung cấp thông tin ngữ cảnh khu vực địa lý có giúp các mô hình (đặc biệt là Gradient Boosting) phân biệt chính xác hơn các hành vi phụ tải dị thường cục bộ hay không.

4 Triển khai thuật toán Học Máy - Machine Learning

4.1 Thước đo Đánh giá và Cơ chế Ngưỡng Quyết định

4.1.1 Thước đo Đánh giá

Trong bài toán phát hiện dị thường với tỷ lệ mất cân bằng nghiêm trọng (97,87% bình thường vs 2,13% dị thường), việc lựa chọn thước đo đánh giá là yếu tố sống còn để đảm bảo tính khách quan:

- **Vô hiệu hóa Độ chính xác Tổng thể (Accuracy):** Một mô hình ngây thơ dự đoán 100% mẫu là bình thường ($y = 0$) vẫn đạt Accuracy = 97,87%, nhưng hoàn toàn thất bại trong việc cảnh báo sự cố rò rỉ hay quá tải điện.
- **Sự sai lệch của ROC-AUC:** Do số lượng mẫu âm tính quá lớn ($TN > 1{,}71$ triệu dòng), tỷ lệ báo động giả FPR $= \frac{FP}{FP+TN}$ luôn bị ghìm ở mức cực nhỏ dù mô hình dự đoán nhầm hàng chục ngàn mẫu. Điều này tạo ra ảo tưởng lạc quan với điểm ROC-AUC $> 0{,}95$ nhưng thực chất độ chính xác dự báo dị thường lại rất thấp.
- **F1-Score là Thước đo Đánh giá Tối thượng (Primary Metric):** Mục tiêu vận hành thực tế của hệ thống điện đòi hỏi: vừa phải bắt trúng tối đa các sự cố bất thường để kịp thời xử lý (tối đa hóa Recall), vừa phải giảm thiểu các báo động giả gây lãng phí nhân lực kiểm tra hiện trường (tối đa hóa Precision). F_1-Score chính là trung bình điều hòa (*harmonic mean*) ràng buộc chặt chẽ cả hai đại lượng:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}$$

$$F_1\text{-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Nếu một trong hai chỉ số Precision hoặc Recall bị suy giảm, F_1-Score sẽ lập tức bị kéo tụt. Toàn bộ các vòng lặp tối ưu hóa và so sánh mô hình trong chương này đều sử dụng F_1-Score làm hàm mục tiêu quyết định.

4.1.2 Cơ chế Ngưỡng Quyết định

Do nhãn 1 quá khan hiếm, hàm mất mát Log-loss đẩy xác suất dự đoán $P(y = 1)$ lệch mạnh về gần 0. Nhóm thiết lập cơ chế ra quyết định hai tầng:

1. **Tầng 1 (Dự báo Xác suất Liên tục):** Mô hình tính toán xác suất dị thường liên tục $\hat{p}_i = P(y_i = 1 \mid \mathbf{x}_i) \in [0, 1]$.
2. **Tầng 2 (Quyết định Gán nhãn qua Ngưỡng Tối ưu):** Nhãn nhị phân được gán thông qua ngưỡng cắt τ:

$$\hat{y}_i = \mathbb{1}[\hat{p}_i \geq \tau]$$

trong đó τ không cố định ở mức 0,5 mà được quét lưới để cực đại hóa F_1-Score trên tập kiểm định:

$$\tau^* = \arg \max_{\tau \in [0{,}01; 0{,}99]} F_1\left(y_{\text{val}}, \mathbb{1}[\hat{p}_{\text{val}} \geq \tau]\right)$$

4.2 Thử nghiệm, Huấn luyện và Đánh giá các Mô hình

4.2.1 Phân tích Thực nghiệm: Ưu thế của Gradient Boosting và Bác bỏ Cây Truyền thống

Để thiết lập mốc đối chứng ban đầu (*baseline benchmarks*), nhóm nghiên cứu đã triển khai hai thuật toán Bagging kinh điển đại diện cho họ mô hình cây truyền thống là **Random Forest** và **Extra Trees** trên cùng tập dữ liệu **Baseline (Preprocessed)**.

Tại mỗi chu kỳ, xác suất dị thường liên tục trên tập kiểm định (20% Stratified Validation) được quét để xác định ngưỡng phân loại tối ưu τ^* mang lại F_1-Score cao nhất, đồng thời đối chiếu trực tiếp với ngưỡng mặc định $\tau = 0{,}5$. Kết quả so sánh đối chứng giữa các mô hình trên tập dữ liệu Baseline được tổng hợp chi tiết tại Bảng 5.

Bảng 5: **So sánh hiệu năng giữa các mô hình đơn trên tập dữ liệu Baseline**

Mô hình	Ngưỡng τ^*	Precision	Recall	F1 (0.5)	F1 (τ^*)
XGBoost	0,30	**0,9637**	**0,9001**	**0,9234**	**0,9308**
LightGBM	0,29	0,9528	0,8961	0,9122	0,9236
CatBoost	0,26	0,9435	0,8954	0,9056	0,9188
Random Forest	0,45	0,9336	0,7902	0,8501	0,8559
Extra Trees	0,20	0,9019	0,8564	0,8285	0,8786

Từ Bảng 5, nhóm nghiên cứu đưa ra một số nhận định như sau về Họ mô hình cây truyền thống:

- Điểm F_1 của Random Forest chỉ đạt 0,8559 và Extra Trees chỉ đạt 0,8786, bị bỏ lại rất xa so với XGBoost (0,9308, chênh lệch tới +7,49% so với RF và +5,22% so với ET) cũng như LightGBM (0,9236) và CatBoost (0,9188).
- Điểm yếu chí mạng nằm ở khả năng bắt trúng mẫu thiểu số (Recall): Do cơ chế Bagging chỉ trung bình hóa ngẫu nhiên mà không tập trung học bù sai số cho các mẫu khó, Recall của Random Forest bị ghìm ở mức cực kỳ thấp (79,02%). Điều này đồng nghĩa với việc cứ 100 sự cố rò rỉ hoặc quá tải điện thực tế thì mô hình bỏ lọt tới gần 21 sự cố.
- Việc hạ ngưỡng phân loại từ 0,5 về $\tau^* = 0{,}20$ đã giúp F_1-Score của Extra Trees nhảy vọt từ 0,8285 lên 0,8786 (tăng +5,01%). Dẫu vậy, nỗ lực tối ưu ngưỡng này chỉ giúp thu hẹp một phần khoảng cách chứ không thể bù đắp được sự tụt hậu cố hữu so với Gradient Boosting dù đều đã thực hiện fine tuning.

Quyết định kỹ thuật: Nhóm quyết định loại bỏ hoàn toàn Random Forest và Extra Trees khỏi các giai đoạn tinh chỉnh tiếp theo và khâu dung hợp Ensemble, tập trung 100% tài nguyên tính toán vào ba thuật toán Gradient Boosting vượt trội: **XGBoost**, **LightGBM** và **CatBoost**.

4.2.2 Thực nghiệm Đánh giá Đặc trưng: Bác bỏ Isolation Forest và Kiểm định Rò rỉ Dữ liệu (No Leakage)

Nhằm xây dựng ma trận đặc trưng đầu vào tối ưu nhất cho các thuật toán Boosting, nhóm đã tiến hành hai cuộc thực nghiệm kiểm định độc lập:

4.2.2.1 Thử nghiệm và bác bỏ điểm dị biệt từ Isolation Forest (Unsupervised Meta-Feature):

Ban đầu, nhóm thử nghiệm ý tưởng kết hợp học không giám sát: sử dụng thuật toán Isolation Forest để tính toán điểm số dị biệt $s(\mathbf{x}) \in [0, 1]$ trên toàn bộ không gian dữ liệu, sau đó đưa điểm số này vào làm một đặc trưng đầu vào bổ sung (meta-feature) cho các mô hình phân lớp có giám sát.

Tuy nhiên, kết quả đối chứng thực nghiệm chi tiết giữa bộ dữ liệu tiền xử lý chuẩn (Baseline) và bộ dữ liệu có thêm Isolation Forest (`IF`) tại Bảng 6 đã chỉ ra tác động tiêu cực của phương pháp này:

Bảng 6: **So sánh hiệu năng trước và sau khi tích hợp đặc trưng Isolation Forest (IF)**

Mô hình	Dữ liệu	Ngưỡng τ^*	Precision	Recall	F1-Score
XGBoost	Baseline	0,30	**0,9637**	**0,9001**	**0,9308**
	Tích hợp IF	0,24	0,9512	0,8982	0,9240
LightGBM	Baseline	0,29	0,9528	**0,8961**	**0,9236**
	Tích hợp IF	0,32	**0,9546**	0,8820	0,9169
CatBoost	Baseline	0,26	0,9435	**0,8954**	**0,9188**
	Tích hợp IF	0,30	**0,9529**	0,8742	0,9119

Phân tích nguyên nhân: Điểm dị biệt từ Isolation Forest vốn được xây dựng trên giả định cô lập điểm đơn thuần dựa trên mật độ không gian cục bộ, không nắm bắt được chu kỳ phụ tải điện và các yếu tố thời tiết biến thiên theo thời gian. Khi đưa vào các mô hình Boosting đã được tối ưu hóa siêu tham số, đặc trưng này vô tình đóng vai trò là một kênh nhiễu (*noise injection*), làm giảm độ nhạy phát hiện bất thường (Recall của cả ba mô hình đều sụt giảm từ 0,2% đến 2,1%) và kéo giảm F_1-Score tổng thể (XGBoost giảm từ 0,9308 xuống 0,9240, LightGBM giảm từ 0,9236 xuống 0,9169, CatBoost giảm từ 0,9188 xuống 0,9119). Do đó, nhóm quyết định **loại bỏ hoàn toàn đặc trưng Isolation Forest** khỏi pipeline chính thức.

4.2.2.2 Kiểm định và so sánh Đặc trưng Trễ (Lag) với Đặc trưng Khu vực (Zone):

Trong giai đoạn mở rộng đặc trưng chuỗi thời gian, nhóm đã thử nghiệm hai chiến lược: (1) Trích xuất sâu các biến trễ phụ tải đa bước (`Lag Features`); (2) Trích xuất các biến tương tác bối cảnh khu vực và quy mô công trình (`Zone Features` gồm tương tác giữa `site_id`, `primary_use` và `square_feet`). Nhằm đảm bảo tính khách quan và nhất quán, cả hai tập đặc trưng đều được kiểm định trên cùng một tập phân chia 80% huấn luyện và 20% kiểm định bảo toàn tỷ lệ nhãn với bộ siêu tham số tối ưu thu được từ quá trình Tuning:

Bảng 7: **So sánh đối chứng hiệu năng giữa Baseline, Đặc trưng Trễ (Lag) và Đặc trưng Khu vực (Zone)**

Chiến thuật Đặc trưng	Mô hình	Ngưỡng τ^*	Precision	Recall	F1-Score
Mốc chuẩn: Baseline	XGBoost	0,30	**0,9637**	0,9001	0,9308
	LightGBM	0,29	0,9528	**0,8961**	0,9236
	CatBoost	0,26	0,9435	**0,8954**	0,9188
Nhánh 1: Lag Features	XGBoost	0,24	0,9528	0,9067	0,9292
	LightGBM	0,22	0,9141	0,8793	0,8964
	CatBoost	0,23	0,9392	0,8839	0,9107
Nhánh 2: Zone Features	**XGBoost**	0,26	0,9568	**0,9079**	**0,9317**
	LightGBM	0,32	**0,9612**	0,8895	**0,9240**
	CatBoost	0,29	**0,9520**	0,8905	**0,9202**

Phân tích và Nhận xét Thực nghiệm chuyên sâu: Bảng 7 đem lại góc nhìn đối chiếu đa chiều giữa ba chiến lược đặc trưng trên cùng bộ siêu tham số đã tối ưu:

- **Tác động tiêu cực của Đặc trưng Trễ (Lag Features) so với Baseline:** Khi đưa các biến trễ phụ tải thô (`meter_reading` tại các bước $t-1, t-2$) vào mô hình, hiệu năng của cả ba thuật toán đều bị suy giảm so với mốc Baseline chuẩn. Đáng chú ý nhất, F1-Score của LightGBM sụt giảm mạnh từ 0,9236 xuống 0,8964 (giảm $-2{,}72\%$) và CatBoost giảm từ 0,9188 xuống 0,9107 (giảm $-0{,}81\%$). Nguyên nhân là do trong chuỗi dữ liệu thực tế, các khoảng trống mất tín hiệu cảm biến hoặc biến động bất thường đột ngột làm đứt đoạn chuỗi trễ, biến các giá trị trễ thành nguồn phát tán nhiễu thay vì cung cấp tín hiệu dự báo tin cậy.
- **Sự ưu việt vượt trội của Đặc trưng Khu vực (Zone Features):** Trái ngược với biến trễ, việc bổ sung các biến tương tác bối cảnh khu vực (`Zone Features` gồm tương tác giữa `site_id`, `primary_use` và `square_feet`) đã nâng trần hiệu năng của toàn bộ hệ thống lên mức cao nhất:
  - XGBoost thiết lập kỷ lục mới với $F_1 = 0{,}9317$ (vượt mốc 0,9308 của Baseline và 0,9292 của Lag), đồng thời tỷ lệ phát hiện dị thường Recall đạt đỉnh cao nhất là 90,79%.
  - LightGBM cải thiện F1 lên 0,9240, với độ chính xác Precision đạt tới 0,9612 (tăng gần $+1\%$ so với Baseline).
  - CatBoost đạt $F_1 = 0{,}9202$ (tăng từ 0,9188 của Baseline), cải thiện cả Precision từ 0,9435 lên 0,9520.
- **Tính bền vững và tính sẵn sàng trong triển khai thực tế:** Nhóm đặc trưng Zone Features khai thác các thuộc tính tĩnh về địa bàn công trình và quy mô diện tích. Đây là các thông tin bối cảnh luôn sẵn sàng 100%, không đòi hỏi đồng bộ chuỗi thời gian liên tục hay lo ngại mất gói tin mạng IoT. Điều này vừa giúp nâng cao độ chính xác phân loại, vừa bảo đảm an toàn vận hành, loại bỏ hoàn toàn nguy cơ sụp đổ dây chuyền do mất dữ liệu lịch sử.

Do đó, nhánh **Zone Features** được nhóm nghiên cứu tin tưởng lựa chọn làm bộ đặc trưng nòng cốt duy nhất để tiến hành dung hợp các mô hình Ensemble tiếp theo.

4.2.3 Tinh chỉnh Siêu tham số (Hyperparameter Tuning) với Optuna

Nhằm khai thác tối đa tiềm năng của từng thuật toán, nhóm sử dụng khung tối ưu hóa **Optuna** dựa trên thuật toán Bayes TPE (*Tree-structured Parzen Estimator*). Không gian tìm kiếm được cấu hình riêng cho từng thuật toán qua các chu kỳ thử nghiệm (*trials*).

Do dữ liệu có mức độ mất cân bằng lớp cao và thang đo đánh giá cốt lõi của bài toán là chỉ số F_1, hàm mục tiêu của Optuna được thiết lập nhằm tìm kiếm bộ siêu tham số tối ưu hóa F_1-Score kết hợp dò tìm ngưỡng phân loại tốt nhất (thay vì cố định ngưỡng mặc định 0,5). Cụ thể, tại mỗi chu kỳ thử nghiệm, thuật toán đánh giá phân phối xác suất dự đoán $\hat{p}$ trên tập validation và xác định ngưỡng th^* mang lại F_1-Score cao nhất:

$$\text{Score}_{\text{optimal}} = \max_{th \in (0,1)} F_1\big(y, \mathbb{I}(\hat{p} \geq th)\big)$$

Chiến lược này giúp mô hình đạt điểm số tối ưu và phản ánh chính xác hiệu năng thực tế trên bài toán phát hiện bất thường phụ tải.

Quá trình tinh chỉnh được thực hiện độc lập trên cả hai cụm dữ liệu: cụm **Baseline** (thông qua file `model_ML/run_tuning_pipeline.py`) và cụm **Zone** (thông qua file `model_ML/tune_zone_optuna.py`). Bảng 8 tổng hợp các bộ siêu tham số tối ưu nhất thu được.

Bảng 8: **Bộ siêu tham số tối ưu thu được sau quá trình Tuning bằng Optuna**

Nhánh dữ liệu	Thuật toán	Bộ siêu tham số tối ưu
Baseline	XGBoost	`learning_rate`: 0,2376, `max_depth`: 15, `subsample`: 0,9600, `colsample_bytree`: 0,6211, `n_estimators`: 164
	LightGBM	`learning_rate`: 0,1537, `num_leaves`: 233, `max_depth`: 17, `feature_fraction`: 0,8459, `min_child_samples`: 62, `n_estimators`: 200
	CatBoost	`learning_rate`: 0,2626, `depth`: 14, `iterations`: 178, `l2_leaf_reg`: 1,3969
Zone	XGBoost	`learning_rate`: 0,2382, `max_depth`: 16, `subsample`: 0,9755, `colsample_bytree`: 0,6088, `n_estimators`: 152
	LightGBM	`learning_rate`: 0,1577, `num_leaves`: 252, `max_depth`: 16, `feature_fraction`: 0,5721, `min_child_samples`: 73, `n_estimators`: 215
	CatBoost	`learning_rate`: 0,3467, `depth`: 14, `iterations`: 176, `l2_leaf_reg`: 2,2573

4.2.3.1 Phân tích đặc trưng các bộ siêu tham số tối ưu:

Từ các bộ siêu tham số tối ưu thu được tại Bảng 8, có thể rút ra một số nhận định kỹ thuật quan trọng về hành vi của từng mô hình:

- **Cân bằng giữa dung lượng mô hình và điều chuẩn trên LightGBM:** Thuật toán Bayes TPE đã mở rộng số lượng lá (`num_leaves` đạt 233 ở Baseline và 252 ở Zone) cùng độ sâu cây (`max_depth` từ $16 - 17$). Nhờ cơ chế Leaf-wise kết hợp cùng

việc kiểm soát `feature_fraction` $(0{,}57 - 0{,}85)$ và `min_child_samples` $(62 - 73)$, LightGBM khai thác sâu các tương tác phi tuyến phức tạp trong dữ liệu mà vẫn duy trì tính tổng quát hóa cao, ngăn ngừa quá khớp.

- **Cơ chế lấy mẫu đặc trưng ngẫu nhiên trên XGBoost:** XGBoost đạt trạng thái tối ưu ở độ sâu cây lớn (`max_depth`: $15 - 16$), tốc độ học `learning_rate` $\approx 0{,}24$ với việc chỉ lấy mẫu khoảng $60\% - 62\%$ số lượng đặc trưng tại mỗi cây (`colsample_bytree`). Cơ chế này giúp giảm tương quan giữa các cây quyết định độc lập, tạo ra các biên phân tách cực kỳ vững chắc và đẩy F1-Score lên đỉnh cao nhất.
- **Điều chuẩn chặt chẽ trên CatBoost:** Thuật toán CatBoost phát huy hiệu quả cao nhất với độ sâu cây đối xứng `depth`: 14 và hệ số điều chuẩn L_2 (`l2_leaf_reg`) đạt mức 1,40 (Baseline) và 2,26 (Zone). Việc siết chặt điều chuẩn trên nhánh Zone giúp mô hình kiểm soát tốt biên độ lá khi tiếp nhận các đặc trưng tương tác phân vùng, giữ cho phân phối xác suất dự đoán luôn mượt và ổn định.

Việc hoàn thiện tinh chỉnh các siêu tham số này tạo tiền đề vững chắc để các mô hình đơn đạt tới trạng thái cực đại hóa phân tách nhãn trước khi tiến hành tối ưu hóa ngưỡng quyết định và dung hợp Ensemble.

4.2.4 Kỹ thuật Ngưỡng Động 16 Khu vực (Site-Specific Dynamic Thresholding)

Như đã phân tích và áp dụng nhất quán xuyên suốt các giai đoạn thực nghiệm trên, việc dịch chuyển ngưỡng phân loại toàn cục τ^* đã chứng minh hiệu quả vượt trội trong việc khắc phục tình trạng mất cân bằng lớp trầm trọng, giúp F_1-Score của toàn bộ các mô hình bứt phá so với ngưỡng mặc định 0,5 (minh chứng đối chiếu tại Bảng 5).

Tuy nhiên, việc sử dụng một ngưỡng cắt tĩnh duy nhất τ^* cho toàn bộ hệ thống vẫn chứa đựng một giả định mang tính đơn giản hóa: *coi mọi khu vực địa lý đều có cùng quy luật phụ tải và biên độ dao động bất thường như nhau.*

4.2.4.1 Cơ sở Lý thuyết: Ngưỡng Động Phi tham số (Nonparametric Dynamic Thresholding):

Để khắc phục hạn chế này, nhóm nghiên cứu đã tham khảo cơ sở lý thuyết từ công trình nổi tiếng của Hundman et al. (KDD 2018) *"Detecting Spacecraft Anomalies Using LSTMs and Nonparametric Dynamic Thresholding"*. Hundman và các cộng sự chỉ ra rằng trong các hệ thống chuỗi thời gian phân tán phức tạp, mỗi kênh cảm biến hoặc khu vực hoạt động chịu tác động của các điều kiện môi trường riêng biệt; do đó, việc áp đặt một ngưỡng cắt tĩnh duy nhất cho toàn bộ hệ thống là không phù hợp. Ngưỡng phát hiện bất thường cần phải được điều chỉnh động theo phân phối xác suất dự đoán của từng cụm cục bộ.

4.2.4.2 Triển khai Ngưỡng Động cho 16 Khu vực:

Áp dụng nguyên lý trên vào bài toán, nhóm thiết lập thuật toán **Ngưỡng Động theo Khu vực (Dynamic Threshold per Zone)**:

1. Dữ liệu kiểm định được phân tách theo 16 khu vực địa lý (`site_id` $k \in \{0, \ldots, 15\}$).

2. Với mỗi khu vực k, thuật toán xác định một ngưỡng cắt riêng biệt τ_k^*:

$$\tau_k^* = \arg\max_{\tau \in [0{,}01;0{,}99]} F_1\left(y_{\text{val}}^{(k)}, \mathbb{1}[P(y=1|X_{\text{val}}^{(k)}) \geq \tau]\right)$$

   Nếu một khu vực không có mẫu dị thường nào trong tập kiểm định, ngưỡng được gán an toàn $\tau_k^* = 1{,}0$.

3. Khi đưa vào dự đoán thực tế trên tập kiểm tra, mẫu thuộc khu vực nào sẽ được áp dụng ngưỡng cắt tương ứng của khu vực đó:

$$\hat{y}_i = \mathbb{1}\left[P(y_i = 1|\mathbf{x}_i) \geq \tau^*_{\text{site}(i)}\right]$$

Thực nghiệm cho thấy cơ chế ngưỡng động theo 16 khu vực giúp F1-Score tiếp tục cải thiện thêm từ +0,18% đến +0,47% trên các mô hình (tiêu biểu như XGBoost nhánh Zone tăng từ 0,9317 lên 0,9341, LightGBM tăng từ 0,9240 lên 0,9287), khẳng định tính thích ứng cục bộ vượt trội khi đối phó với dữ liệu chuỗi thời gian phụ tải đa phân vùng.

4.3 Kỹ thuật Dung hợp Mô hình Nâng cao (Model Ensemble)

4.3.1 Cơ sở Lý thuyết: Lựa chọn Tập hợp Mô hình (Ensemble Selection)

Để đẩy hiệu năng phân lớp lên mức tối đa, nhóm nghiên cứu đã áp dụng kỹ thuật **Weighted Blending** dựa trên cơ sở lý thuyết bài báo kinh điển của Caruana et al. (ICML 2004) *"Ensemble Selection from Libraries of Models"*. Caruana chứng minh rằng việc kết hợp tuyến tính có trọng số từ một tập hợp các mô hình có cấu trúc đa dạng (*diverse architectures*) luôn vượt trội so với bất kỳ mô hình đơn lẻ nào, đồng thời ưu việt hơn phép lấy trung bình cộng đơn thuần nhờ khả năng tối ưu hóa trọng số đóng góp của từng thành phần. Nguyên lý này cũng là chiến thuật nòng cốt được áp dụng rộng rãi và chứng minh tính hiệu quả vượt trội trong các bài toán phân tích chuỗi thời gian phụ tải năng lượng quy mô lớn như *ASHRAE Great Energy Predictor III*.

4.3.2 Các Phương pháp Dung hợp Thực nghiệm

Nhằm khảo sát toàn diện các chiến lược kết hợp thông tin, nhóm nghiên cứu đã hiện thực hóa và kiểm định sáu kỹ thuật dung hợp mô hình từ cấp độ tuyến tính đến phi tuyến thích nghi:

1. **Soft Voting (Trung bình cộng xác suất không trọng số):** Phương pháp cơ bản nhất, lấy giá trị trung bình số học giữa các xác suất dự báo:

$$P_{\text{vote}} = \frac{1}{3}\left(P_{\text{XGB}} + P_{\text{LGB}} + P_{\text{Cat}}\right)$$

   Phương pháp này giúp giảm phương sai dự báo (*variance reduction*) mà không cần tối ưu trọng số, đóng vai trò là mốc chuẩn so sánh cho các cơ chế dung hợp nâng cao.

2. **Top-2 Weighted Blending (Tổ hợp 2 mô hình chủ lực XGBoost + CatBoost):** Tổ hợp tuyến tính tập trung vào hai thuật toán có năng lực phân tách tốt

nhất và ít tương quan sai số nhất, loại trừ mô hình thứ ba để kiểm định giả thuyết tối giản hóa:

$$P_{\text{top2}} = w_{\text{XGB}} P_{\text{XGB}} + w_{\text{Cat}} P_{\text{Cat}}, \quad \text{với } w_{\text{XGB}} + w_{\text{Cat}} = 1,\ w \geq 0$$

Vector trọng số được tối ưu hóa theo hàm mất mát Log-Loss, cho kết quả:

- Trên Baseline: $\mathbf{w} = [0{,}84\,\text{XGB},\ 0{,}16\,\text{Cat}]$.
- Trên Zone: $\mathbf{w} = [0{,}80\,\text{XGB},\ 0{,}20\,\text{Cat}]$.

3. **Tri-Model Weighted Blending LogLoss (Trộn trọng số 3 mô hình tối thiểu hóa Log-Loss):** Tổ hợp lồi của cả ba mô hình với vector trọng số $\mathbf{w} = [w_{\text{XGB}}, w_{\text{LGB}}, w_{\text{Cat}}]$ thỏa mãn $\sum w_m = 1, w_m \geq 0$:

$$P_{\text{blend}} = w_{\text{XGB}} P_{\text{XGB}} + w_{\text{LGB}} P_{\text{LGB}} + w_{\text{Cat}} P_{\text{Cat}}$$

Vector $\mathbf{w}$ được tìm kiếm thông qua giải thuật quy hoạch phi tuyến tuần tự (SLSQP) nhằm cực tiểu hóa hàm mất mát Cross-Entropy (Log-Loss) toàn cục trên tập kiểm định:

$$\mathbf{w}^* = \arg\min_{\mathbf{w}} \left(-\frac{1}{N} \sum_{i=1}^{N} \left[y_i \ln(P_{\text{blend},i}) + (1 - y_i) \ln(1 - P_{\text{blend},i}) \right] \right)$$

Kết quả tối ưu thu được phản ánh cấu trúc tương hỗ lý tưởng giữa ba kiến trúc:

- Trên tập dữ liệu Baseline: $\mathbf{w} = [0{,}68\,\text{XGB},\ 0{,}26\,\text{LGB},\ 0{,}06\,\text{Cat}]$.
- Trên tập dữ liệu Zone: $\mathbf{w} = [0{,}65\,\text{XGB},\ 0{,}25\,\text{LGB},\ 0{,}10\,\text{Cat}]$.

Trong đó, XGBoost nắm giữ vai trò chủ lực ($65\% - 68\%$), LightGBM đóng góp $25\% - 26\%$ giúp làm mượt phân phối xác suất và gia tăng Recall, và CatBoost giữ $6\% - 10\%$ đóng vai trò điều chuẩn chống quá khớp.

4. **Dynamic Threshold-Aware Blending (Dung hợp hướng Ngưỡng động 16 Khu vực):** Thay vì tối ưu hóa hàm Log-Loss thuần túy trên toàn bộ dữ liệu, thuật toán quét lưới trực tiếp không gian trọng số $[w_1, w_2, w_3]$ với bước nhảy 0,05 nhằm cực đại hóa chỉ số F_1-Score khi áp dụng đồng thời cơ chế dò tìm ngưỡng động theo từng khu vực địa bàn:

$$\mathbf{w}^*_{\text{dyn}} = \arg\max_{\mathbf{w}} F_1 \left(y_{\text{val}}, \mathbb{1}[P_{\text{blend}}(\mathbf{w}) \geq \boldsymbol{\tau}^*_{\text{site}}] \right)$$

Kết quả tối ưu:

- Trên Baseline: $\mathbf{w} = [0{,}50\,\text{XGB},\ 0{,}25\,\text{LGB},\ 0{,}25\,\text{Cat}]$.
- Trên Zone: $\mathbf{w} = [0{,}60\,\text{XGB},\ 0{,}25\,\text{LGB},\ 0{,}15\,\text{Cat}]$.

5. **Stacking với Meta-Learner Tuyến tính (Logistic Regression):** Hiện thực hóa mô hình Stacking hai tầng kinh điển (Wolpert, 1992): Tầng 1 sinh ma trận xác suất ngoại mẫu $[P_{\text{XGB}}, P_{\text{LGB}}, P_{\text{Cat}}]$; Tầng 2 huấn luyện một mô hình Hồi quy Logistic có điều chuẩn L_2 trên tập Meta-Train (tách 50% từ tập validation nhằm triệt tiêu rò rỉ dữ liệu). Mô hình học một siêu phẳng phân tách tối ưu:

$$P_{\text{stack}} = \sigma\left(\beta_0 + \beta_1 P_{\text{XGB}} + \beta_2 P_{\text{LGB}} + \beta_3 P_{\text{Cat}}\right)$$

6. **Context-Aware Mixture of Experts (MoE Meta-Learner tích hợp Ngữ cảnh Khu vực):** Kỹ thuật dung hợp phi tuyến bậc cao: Thay vì chỉ dựa vào xác suất đầu ra như Stacking truyền thống, mô hình Meta-Learner (sử dụng LightGBM với siêu tham số tối ưu) tiếp nhận đồng thời cả vector xác suất $[P_{\text{XGB}}, P_{\text{LGB}}, P_{\text{Cat}}]$ và toàn bộ ma trận đặc trưng bối cảnh công trình (`site_id`, `primary_use`, `square_feet`, các biến tương tác phân vùng). Cơ chế này cho phép Meta-Learner tự động định tuyến trọng số thích nghi theo từng đặc thù công trình và điều kiện vi khí hậu cục bộ.

4.3.3 Kết quả Thực nghiệm Dung hợp và So sánh Đối chứng

Bảng 9 tổng hợp chi tiết kết quả thực nghiệm của sáu phương pháp Ensemble trên cả hai tập dữ liệu Baseline và Zone Features dưới cả hai cơ chế ngưỡng (Ngưỡng Tối ưu Toàn cục τ^* và Ngưỡng Động 16 Khu vực).

Bảng 9: **So sánh hiệu năng toàn diện giữa các phương pháp Ensemble trên tập kiểm định**

Tập dữ liệu	Phương pháp Dung hợp (Ensemble)	Ngưỡng τ^*	Precision	Recall	F1 (τ^*)	F1 (16 Khu Động)
Baseline	Soft Voting (XGB + LGB + CAT)	0,263	0,9539	0,9074	0,9301	0,9350
	Stacking Meta-Learner (Logistic Regression)	0,117	0,9605	0,8995	0,9290	0,9347
	Top-2 Blend (XGB + CAT) [0,84 - 0,16]	0,334	**0,9688**	0,8962	0,9311	0,9354
	Dynamic Thresh Blend [0,50 - 0,25 - 0,25]	0,319	0,9665	0,8981	0,9311	0,9363
	Weighted Blending LogLoss [0,68 - 0,26 - 0,06]	0,295	0,9639	**0,9021**	**0,9320**	**0,9359**
Zone	Soft Voting (XGB + LGB + CAT)	0,234	0,9492	0,9145	0,9315	0,9359
	Stacking Meta-Learner (Logistic Regression)	0,068	0,9536	0,9150	0,9339	0,9369
	Context-Aware MoE (LightGBM Meta-Learner)	0,294	0,9532	0,9118	0,9320	0,9354
	Top-2 Blend (XGB + CAT) [0,80 - 0,20]	0,251	**0,9560**	0,9111	0,9330	0,9348
	Dynamic Thresh Blend [0,60 - 0,25 - 0,15]	0,234	0,9524	0,9153	0,9335	0,9372
	Weighted Blending LogLoss [0,65 - 0,25 - 0,10]	**0,232**	0,9519	**0,9159**	**0,9336**	**0,9373**

Phân tích Thực nghiệm Chuyên sâu:

- **Sự vượt trội của Weighted Blending so với Soft Voting:** Kỹ thuật Weighted Blending tối ưu hóa theo Log-Loss luôn vượt trội hơn Soft Voting cả ở ngưỡng tĩnh (0,9336 so với 0,9315) lẫn ngưỡng động (0,9373 so với 0,9359). Do XGBoost có độ tin cậy vượt trội, việc gán tỷ trọng chủ lực (65%) cho XGBoost thay vì cào bằng 33,3% giúp hệ thống vừa bảo toàn được độ chính xác phân tách cực cao, vừa tận dụng được khả năng bắt mẫu khó của LightGBM (25%) và tính ổn định điều chuẩn của CatBoost (10%).

- **Hiệu năng ấn tượng của Top-2 Blend:** Chỉ với hai mô hình XGBoost và CatBoost, Top-2 Blend đã đạt F1 ngưỡng tĩnh 0,9330 và ngưỡng động 0,9348. Kết quả này chứng minh tính tương hỗ sâu sắc giữa cơ chế tách nhánh Histogram bậc hai (XGBoost) và cây đối xứng Oblivious Trees (CatBoost), cung cấp một phương án dự phòng gọn nhẹ nếu muốn cắt giảm chi phí suy luận của mô hình thứ ba.

- **Đặc điểm hành vi của Stacking Logistic Regression:** Mô hình Stacking tuyến tính đạt F1 tĩnh rất tốt (0,9339 trên Zone và 0,9290 trên Baseline). Tuy nhiên, do hàm Sigmoid gặp phải dữ liệu mất cân bằng nghiêm trọng, phân phối xác suất đầu ra của Meta-Learner bị nén mạnh về gần 0, khiến ngưỡng cắt tối ưu bị kéo sâu xuống $\tau^* = 0{,}068 - 0{,}117$.

- **Năng lực thích ứng của Context-Aware MoE:** Bằng cách đưa thông tin địa bàn `site_id` và quy mô công trình vào Meta-Learner LightGBM, mô hình đạt F1 tĩnh 0,9320 và ngưỡng động 0,9354 mà không cần dò tìm ngưỡng quá sâu ($\tau^* = 0{,}294$), thể hiện khả năng định tuyến xác suất thích nghi theo đặc thù từng khu vực.
- **Đỉnh cao Hiệu năng Toàn diện:** Sự kết hợp giữa bộ đặc trưng **Zone Features**, thuật toán **Weighted Blending LogLoss [0,65 XGB + 0,25 LGB + 0,10 Cat]** và cơ chế **Ngưỡng Động 16 Khu vực** đã thiết lập kỷ lục hiệu năng cao nhất của đề tài với F_1-Score = **0,9373** (Precision đạt **0,9586**, Recall đạt **0,9169**).

4.3.3.1 Bảng Tổng kết Sự Tăng tiến Điểm số qua 4 Cấp độ Tối ưu Kỹ thuật:

Nhằm trực quan hóa lộ trình nâng cấp sức mạnh mô hình theo đúng yêu cầu đề tài, Bảng 10 thể hiện sự tăng tiến vượt bậc của chỉ số F1-Score qua bốn nấc thang phát triển: **Single Model → Baseline Ensemble → Zone Ensemble → Zone Ensemble + Dynamic Threshold**:

Bảng 10: **Sự tăng tiến hiệu năng qua 4 cấp độ tối ưu hóa kỹ thuật**

Cấp độ	**Chiến thuật Phát triển**	**Cấu hình Kỹ thuật**	**Ngưỡng τ**	**Precision**	**Recall**	**F1**
Cấp độ 1	Single Model (Mô hình Đơn Tuned)	XGBoost Tuned (Tập Baseline)	0,303	0,9637	0,9001	0,9308
Cấp độ 2	Baseline Ensemble	Weighted Blending [0,68 XGB + 0,26 LGB + 0,06 Cat]	0,295	0,9639	0,9021	0,9320
Cấp độ 3	Zone Ensemble (Ngưỡng tĩnh)	Weighted Blending [0,65 XGB + 0,25 LGB + 0,10 Cat]	0,232	0,9519	0,9159	0,9336
Cấp độ 4	**Zone Ensemble + Dynamic**	**Blending + 16 Ngưỡng Động**	**Dynamic**	**0,9586**	**0,9169**	**0,9373**

*Ghi chú: Tại Cấp độ 3, khi dùng một ngưỡng tĩnh chung tối ưu $\tau^* = 0{,}232$ cho toàn bộ các khu vực, điểm F1 đạt mức 0,9336. Tuy nhiên, khi chuyển sang Cấp độ 4 bằng thuật toán Ngưỡng Động 16 Khu vực (Hundman et al., 2018), cả Precision (0,9519 → **0,9586**) và Recall (0,9159 → **0,9169**) đều đồng thời được cải thiện nhờ loại bỏ báo động giả tại các khu vực ít biến động và tăng độ nhạy tại các khu vực phụ tải phức tạp. Nhờ đó, F_1-Score đã bứt phá ngoạn mục lên mốc kỷ lục **0,9373**, khẳng định tính ưu việt vượt trội của giải pháp phân tán ngưỡng quyết định theo khí hậu từng khu vực.*

5 Triển khai thuật toán Học Sâu - Deep Learning

5.1 Kết luận và Thiết kế Pipeline

Dựa trên phân tích ưu nhược điểm ở phần tổng quan, nhóm nghiên cứu đề xuất một pipeline Học sâu gồm năm giai đoạn. Pipeline tuân theo năm nguyên tắc thiết kế:

1. **Cùng giao thức với phần Học máy:** dùng chung cách chia dữ liệu, cùng ba độ đo (F1-Score, PR-AUC, ROC-AUC) và cùng cách chọn ngưỡng, để so sánh Học máy và Học sâu là công bằng.

2. **Dựng chuỗi theo từng toà nhà:** không trộn dòng giữa các toà và không xáo trộn ngẫu nhiên theo từng giờ, vì các giờ liền kề rất giống nhau và sẽ gây rò rỉ thông tin.

3. **Mô hình có giám sát làm hướng chính:** bộ dữ liệu đã có nhãn `anomaly`, nên các bộ gán nhãn chuỗi (BiGRU/BiLSTM, TCN) là mô hình chính; mô hình tái tạo (LSTM-AE) đóng vai trò đối chứng và tạo đặc trưng bổ sung.

4. **Mỗi lựa chọn đi kèm một giả thuyết kiểm chứng được:** mọi lý do chọn hoặc loại một thuật toán được gắn với một thí nghiệm cụ thể ở mục kiểm chứng giả thuyết.

5. **Dung hợp với Học máy ở cuối:** đầu ra của các mô hình Học sâu trở thành mô hình cơ sở thêm vào bước Ensemble của phần Học máy.

1. **Giai đoạn 1: Kiểm định dữ liệu, Tiền xử lý và Dựng chuỗi**

   - **Kiểm định lưới thời gian:** đưa mỗi toà nhà về lưới giờ đều đặn (một dòng mỗi giờ) bằng `reindex`. Các giờ thiếu được đánh dấu bằng cờ khuyết chứ không bị bỏ đi, để cửa sổ trượt luôn đúng khoảng cách thời gian.
   - **Xử lý giá trị khuyết:** không điền khuyết "mù" cho `meter_reading`. Giá trị khuyết được thay bằng 0 sau chuẩn hoá và đi kèm một kênh cờ `is_missing`, để mô hình tự học ý nghĩa của sự khuyết. Các biến thời tiết điền bằng nội suy tuyến tính theo toà nhà.
   - **Chuẩn hoá theo từng toà nhà:** dùng $\log(1+x)$ rồi chuẩn hoá bằng median và IQR của riêng toà nhà, vì thang đo giữa các toà chênh nhau rất lớn (giá trị tối đa trong tập kiểm định lên đến hàng nghìn). **Các thống kê này chỉ tính trên giai đoạn huấn luyện**, không dùng dữ liệu sau mốc chia.
   - **Xây dựng kênh đầu vào:** giá trị đo đã chuẩn hoá, `is_missing`, độ dài đoạn giá trị lặp `run_len` (qua $\log(1+x)$), hiệu giá trị với giờ trước, các biến thời tiết chính, và mã hoá chu kỳ sin / cos của giờ, thứ, tháng. Đặc trưng toà nhà gồm `primary_use` (embedding), log(`square_feet`) và `site_id` (embedding).
   - **Không dùng:** các cột khoá ghép kiểu chuỗi (`building_hour`, `building_weekday_hour`,…) và nhóm `gte_*` (target encoding của `meter_reading`). Nhóm `gte_*` chỉ được thêm ở thí nghiệm riêng để kiểm tra rò rỉ. `building_id` không dùng làm embedding vì tập kiểm tra cuối cùng gồm các toà nhà chưa từng thấy.
   - **Cắt đoạn (chunking) thay vì cửa sổ trượt bước 1:** mỗi toà nhà được cắt thành các đoạn dài $L = 336$ giờ (hai tuần), bước nhảy 168 giờ (đoạn kề nhau chồng lấp một tuần). Mô hình dự đoán nhãn cho **toàn bộ** các giờ trong đoạn.

Cách này giảm khối lượng tính toán hàng trăm lần so với cửa sổ trượt bước 1 mà vẫn cho dự đoán ở mọi giờ.

2. **Giai đoạn 2: Huấn luyện rời rạc từng mô hình (Baseline Modeling)**

   - Huấn luyện độc lập từng mô hình với siêu tham số mặc định hợp lý ban đầu. Nhóm **mô hình chính** gồm:
     (a) **BiGRU** (và BiLSTM làm đối chứng) — bộ gán nhãn chuỗi hai chiều, khai thác ngữ cảnh hai phía.
     (b) **TCN nhân quả** — bộ gán nhãn chuỗi chỉ dùng quá khứ, huấn luyện nhanh và kiểm soát được vùng nhìn.
     (c) **LSTM Autoencoder** — mô hình tái tạo không giám sát, huấn luyện chỉ trên cửa sổ bình thường; vừa là baseline đối chứng, vừa tạo đặc trưng sai số tái tạo.
   - Nhóm **mô hình mở rộng** (chạy khi còn thời gian): TCN không nhân quả, USAD, bản tái hiện GAN-LSTM trên tập con toà nhà ở mức cửa sổ, Transformer Encoder nhỏ.
   - Đánh giá hiệu năng từng mô hình đơn lẻ bằng **F1-Score**, **PR-AUC** và **ROC-AUC** theo từng giờ, đồng thời tách recall theo hai loại bất thường (giá trị bằng 1,0 và các bất thường còn lại). Giai đoạn này thiết lập mức hiệu suất cơ sở cho Học sâu.

3. **Giai đoạn 3: Tối ưu hóa từng mô hình (Hyperparameter Tuning)**

   - **Tinh chỉnh siêu tham số:** dùng Optuna kết hợp cắt tỉa (pruning), mục tiêu là PR-AUC trên tập kiểm định. Không gian tìm kiếm nêu ở mục đặc tả kiến trúc.
   - **Hàm mất mát cho mất cân bằng:** so sánh ba cấu hình: BCE không trọng số, BCE có trọng số lớp (w_+ thay đổi từ 1 đến khoảng 45) và Focal Loss ($\gamma \in \{1, 2, 3\}$).
   - **Tối ưu hoá ngưỡng cắt:** ngưỡng chọn để tối đa hoá F1-Score trên một khoảng thời gian **riêng** (tháng 9), tách khỏi tập đánh giá cuối (từ tháng 10). Cách này tránh con số F1 quá lạc quan do chọn ngưỡng trực tiếp trên tập đánh giá.
   - **Điều chuẩn và ổn định huấn luyện:** dropout, weight decay, cắt gradient (gradient clipping) và dừng sớm (early stopping) theo PR-AUC kiểm định.
   - **So sánh kết quả:** đối chiếu từng mô hình sau tối ưu với baseline ở Giai đoạn 2, xác định mô hình Học sâu đơn lẻ tốt nhất.

4. **Giai đoạn 4: Dung hợp mô hình (Model Ensemble)**

   - **Đặc trưng sai số tái tạo cho mô hình Học máy:** điểm tái tạo a_t của LSTM-AE (chuẩn hoá theo toà nhà) được thêm vào bộ đặc trưng của các mô hình cây, tương tự cách dùng điểm Isolation Forest ở phần Học máy. Để tránh lạc quan giả tạo, điểm này trên dữ liệu huấn luyện phải được tính ngoài mẫu (out-of-fold theo nhóm toà nhà).

- **Dung hợp Học sâu và Học máy:** thêm xác suất của mô hình Học sâu tốt nhất vào bộ mô hình cơ sở của Stacking, Blending và Soft Voting đã mô tả ở phần Học máy:

$$\hat{p}_{\text{blend}} = \sum_{m=1}^{M} w_m \cdot \hat{p}_m, \quad \text{với} \quad \sum_{m=1}^{M} w_m = 1, \quad m \in \{\text{LGBM}, \text{XGB}, \text{Cat}, \text{BiGRU}, \text{TCN}\}$$

  Trộn theo thứ hạng (rank averaging) cũng được thử vì xác suất của mô hình có trọng số lớp và của mô hình cây có thang đo khác nhau.
- **Huấn luyện chống rò rỉ:** dự đoán out-of-fold cho mô hình cơ sở được tạo bằng `GroupKFold` theo toà nhà (hoặc chia theo thứ tự thời gian), không dùng chia phân tầng ngẫu nhiên theo từng giờ.
- **So sánh tổng thể:** đối chiếu Ensemble Học sâu+Học máy với mô hình đơn lẻ tốt nhất của mỗi nhóm, báo cáo F1-Score, PR-AUC, ROC-AUC và thời gian suy luận.

5. **Giai đoạn 5: Đánh giá giao thức kép và Phân tích lỗi**

- **Giao thức T (theo thời gian):** huấn luyện với tháng 1 đến 8, chọn ngưỡng ở tháng 9, đánh giá từ tháng 10 đến tháng 12.
- **Giao thức B (theo toà nhà):** `GroupKFold` 5 phần theo `building_id` trên cả năm, ngưỡng chọn trong phần huấn luyện của mỗi lượt. Giao thức này mô phỏng việc dự đoán trên các toà nhà chưa thấy, gần với thiết lập tập kiểm tra của cuộc thi.
- **Giao thức C (mức cửa sổ, chỉ để đối chiếu tài liệu):** cửa sổ 60 giờ không chồng lấp, cửa sổ bất thường nếu có ít nhất một giờ bất thường, theo thiết lập của Orvati Nia et al. (2026).
- **Phân tích lỗi:** recall theo loại bất thường, phân bố recall theo từng toà nhà, và theo độ dài đoạn lặp, nhằm trả lời mô hình bắt được loại bất thường nào và bỏ sót loại nào.
- Mỗi cấu hình chạy ít nhất 3 giá trị seed khác nhau, báo cáo trung bình và độ lệch chuẩn.

5.2 Luận giải việc lựa chọn và loại trừ các thuật toán

Phần này giải thích vì sao mỗi họ mô hình được đưa vào hoặc không đưa vào pipeline chính. Các nhận định "giả thuyết" được kiểm chứng ở mục thí nghiệm cuối chương.

1. Nhóm được chọn làm mô hình chính

- **BiGRU/BiLSTM:** bộ dữ liệu có nhãn nên có thể học có giám sát. Hai chiều cho phép mô hình biết một đoạn giá trị lặp kéo dài bao lâu, thông tin mà mô hình xét từng điểm không có. GRU được ưu tiên vì ít tham số hơn LSTM, LSTM giữ làm đối chứng. Hạn chế là chỉ dùng được ngoại tuyến, và nhóm sẽ nêu rõ điều này khi báo cáo.

- **TCN nhân quả:** song song hoá được trên GPU nên huấn luyện nhanh trên khoảng 1,75 triệu bước thời gian, vùng nhìn tính được trước ($R = 253$ giờ với $k = 3$, $L = 6$ phủ chu kỳ tuần). Chỉ dùng quá khứ nên bổ sung góc nhìn "cảnh báo thời gian thực" bên cạnh BiGRU.

- **LSTM Autoencoder:** giữ làm đại diện của hệ hình tái tạo, vì đã có nhiều nghiên cứu trên LEAD lấy nó làm baseline, và rẻ hơn GAN nhiều. Không dùng làm mô hình chính vì không tận dụng nhãn và có rủi ro bỏ sót bất thường dạng phẳng (giả thuyết H3).

2. Nhóm đưa vào hướng mở rộng

- **GAN-LSTM / TAnoGAN:** có kết quả công bố trực tiếp trên LEAD nên có giá trị đối chiếu. Tuy nhiên mỗi cửa sổ cần khoảng 300 bước tối ưu vector tiềm ẩn khi suy luận. Ước tính của nhóm: chấm điểm từng giờ trên khoảng 1,3 triệu cửa sổ huấn luyện cần khoảng 4×10^8 lượt chạy bộ sinh, không khả thi; chấm điểm theo cửa sổ không chồng lấp (60 giờ) trên 200 toà nhà chỉ cần khoảng $2{,}9 \times 10^4$ cửa sổ, tương đương khoảng $8{,}8 \times 10^6$ lượt, khả thi. Vì vậy GAN chỉ được tái hiện ở mức cửa sổ trên một tập con toà nhà, dùng giao thức C để đối chiếu với bài báo.

- **USAD:** huấn luyện nhanh, ổn định hơn GAN và không cần tối ưu tiềm ẩn khi suy luận, nhưng chưa có công bố trên dữ liệu năng lượng và vẫn là hệ hình không giám sát. Thử nếu còn thời gian.

- **Transformer Encoder nhỏ:** chỉ thử ở dạng bộ gán nhãn chuỗi có giám sát với vài tầng, vì chỉ có 200 chuỗi và mô hình lớn dễ quá khớp.

- **Mô hình theo cụm toà nhà:** lấy ý tưởng từ Cansever & Konyar (2026): phân cụm toà nhà theo hành vi tiêu thụ rồi huấn luyện một mô hình cho mỗi cụm, hoặc đưa nhãn cụm vào làm đầu vào mô hình.

3. Nhóm không đưa vào pipeline chính

- **Conv-AE và VAE:** cùng hệ hình tái tạo với LSTM-AE nhưng báo cáo trên LEAD của Orvati Nia et al. (2026) thấp hơn các mô hình sinh đối kháng, và đã có LSTM-AE làm đại diện. Thêm chúng sẽ tăng chi phí mà không mở ra góc nhìn mới.

- **Anomaly Transformer, TranAD:** thiết kế cho chuỗi đa biến không giám sát với quy tắc đánh giá điều chỉnh theo đoạn, không tận dụng nhãn, chưa có đánh giá trên LEAD. Với chỉ 200 chuỗi, rủi ro quá khớp cao. Chỉ giữ lại ý tưởng bộ mã hoá chú ý ở dạng nhỏ nêu trên.

- **RNN thuần (vanilla RNN):** bị triệt tiêu gradient trên chuỗi dài hàng trăm bước, LSTM/GRU thay thế hoàn toàn.

- **MLP trên cửa sổ làm phẳng:** mất cấu trúc thứ tự, tham số tăng theo $w \times d$, và mô hình cây ở phần Học máy đã làm tốt vai trò này với đặc trưng độ trễ.

- **SMOTE trên chuỗi:** khác với phần Học máy, nhóm không dùng SMOTE cho mô hình chuỗi vì nội suy giữa hai cửa sổ bất thường tạo ra các chuỗi không có thật, làm hỏng cấu trúc thời gian và đoạn giá trị lặp. Mất cân bằng được xử lý bằng hàm mất mát có trọng số hoặc focal loss.

Tiểu kết: việc loại trừ không phủ nhận giá trị của các thuật toán này, mà là kết quả của việc chọn lọc theo ba đặc tính của bài toán: dữ liệu có nhãn nhưng mất cân bằng nặng, bất thường gồm cả loại có giá trị đặc biệt lẫn loại phụ thuộc ngữ cảnh, và chỉ có 200 chuỗi toà nhà với khoảng 1,75 triệu quan trắc.

5.3 Đặc tả kiến trúc và siêu tham số

1. BiGRU / BiLSTM gán nhãn chuỗi

- **Đầu vào:** tensor kích thước $B \times L \times d$ với $L = 336$ và d khoảng 18 đến 22 kênh theo giai đoạn 1; vector đặc trưng toà nhà (embedding `primary_use`, `site_id`, log(`square_feet`)) được nối vào mọi bước thời gian.
- **Kiến trúc:** 2 tầng GRU/LSTM hai chiều, 64 đơn vị ẩn mỗi chiều, dropout 0,2, tầng tuyến tính ra một logit mỗi giờ.
- **Đầu ra:** xác suất bất thường $\hat{p}_t$ cho từng giờ trong đoạn; khi suy luận, các đoạn chồng lấp được ghép lại và lấy phần lõi (bỏ vùng biên của đoạn).
- **Huấn luyện:** AdamW, tốc độ học 10^{-3} giảm dần theo cosine, cắt gradient ở 1,0, dừng sớm theo PR-AUC kiểm định.

2. TCN nhân quả

- **Kiến trúc:** 6 khối dư, mỗi khối hai tích chập nhân quả giãn nở với $d \in \{1, 2, 4, 8, 16, 32\}$, nhân $k = 3$, 64 kênh, chuẩn hoá trọng số, dropout 0,1. Vùng nhìn $R = 1 + 2 \cdot 2 \cdot 63 = 253$ giờ.
- **Đầu vào/đầu ra:** giống BiGRU; đầu ra là một logit mỗi giờ.
- **Biến thể không nhân quả:** thay đệm nhân quả bằng đệm đối xứng để so sánh công bằng với BiGRU về lượng ngữ cảnh.

3. LSTM Autoencoder

- **Dữ liệu huấn luyện:** chỉ các cửa sổ không chứa giờ bất thường nào, lấy từ giai đoạn huấn luyện; cửa sổ độ dài $w \in \{60, 168\}$ giờ (60 giờ để tương thích tài liệu).
- **Kiến trúc:** bộ mã hoá LSTM hai tầng 64 đơn vị, vector tiềm ẩn 32 chiều, bộ giải mã đối xứng; hàm mất mát MSE.
- **Điểm bất thường:** sai số tái tạo từng giờ, chuẩn hoá theo toà nhà bằng median và IQR của sai số trên giai đoạn huấn luyện của toà đó; ngưỡng chọn ở tháng 9.

4. Không gian tìm kiếm Optuna

Siêu tham số	**Khoảng tìm kiếm**
Số đơn vị ẩn / số kênh	$\{32, 64, 128\}$
Số tầng RNN / số khối TCN	RNN: $\{1, 2, 3\}$; TCN: $L \in \{4, 5, 6, 7\}$, nhân $k \in \{3, 5, 7\}$ (kiểm tra $R \geq 168$)
Độ dài đoạn L (gán nhãn chuỗi)	$\{168, 336, 672\}$
Dropout	$[0, 0{,}5]$
Tốc độ học	$[10^{-4}, 3 \times 10^{-3}]$ theo thang log
Trọng số lớp dương w_+	$\{1, 7, 20, 45\}$ (khoảng $\sqrt{45} \approx 7$ là mức trung gian)
Focal loss γ	$\{0, 1, 2, 3\}$
Có/không kênh `run_len` và hiệu giá trị	{có, không} (thí nghiệm H1)

5.4 Các kỹ thuật và thuật toán bổ trợ khác (Có thể tích hợp thêm)

- **Huấn luyện chính xác hỗn hợp (Mixed Precision):** giảm bộ nhớ GPU và tăng tốc huấn luyện. Toàn bộ chuỗi chỉ khoảng $1{,}75 \times 10^6 \times 20 \times 4$ byte, tức khoảng 0,14 GB, nên có thể giữ cả bộ dữ liệu trong RAM và cắt đoạn lười (lazy slicing) theo chỉ số thay vì lưu sẵn các cửa sổ.
- **Làm mượt và hậu xử lý dự đoán:** làm mượt xác suất theo cửa sổ ngắn hoặc lọc bỏ các đoạn bất thường quá ngắn; chỉ dùng khi có thí nghiệm chứng minh cải thiện, và được báo cáo như một bước riêng.
- **Mô hình theo cụm toà nhà:** phân cụm toà nhà theo thống kê tiêu thụ (K-means, như Cansever & Konyar, 2026) rồi huấn luyện một mô hình cho mỗi cụm hoặc dùng nhãn cụm làm đầu vào. Thống kê dùng để phân cụm chỉ tính trên giai đoạn huấn luyện.
- **Hiệu chỉnh xác suất (Calibration):** do dùng trọng số lớp hoặc focal loss, xác suất đầu ra bị lệch; có thể dùng Platt scaling hoặc hồi quy đẳng hướng (isotonic) trên tập kiểm định để trộn xác suất công bằng hơn trong bước Ensemble.
- **Optuna (Hyperparameter Optimization Framework):** như phần Học máy, dùng TPE và cắt tỉa các thử nghiệm kém hứa hẹn để tiết kiệm GPU.

5.5 Chi tiết Pipeline Tiền xử lý dữ liệu và Áp dụng trên File

Quy trình tác động lên các tệp trong thư mục `data/` như sau:

1. Tập huấn luyện (Train):

- **Files áp dụng:** `train_features.csv`. Theo kết quả `info()` của nhóm, tệp này đã chứa sẵn cả `meter_reading` và nhãn `anomaly` cùng các đặc trưng, nên không cần ghép với `train.csv` cho mô hình Học sâu. Tệp `train.csv` được dùng để đối chiếu nhãn và giá trị đo.
- **Đọc dữ liệu:** đọc toàn bộ với `parse_dates` cho `timestamp` và ép kiểu `float32`; tệp khoảng 582 MB.
- **Sắp xếp và chuẩn hoá lưới thời gian:** sắp theo (`building_id`, `timestamp`) rồi `reindex` về lưới giờ đều theo từng toà nhà.
- **Tạo đặc trưng chuỗi:** `run_len` (độ dài đoạn giá trị lặp tính từ quá khứ), hiệu bậc nhất, mã hoá sin / cos của giờ, thứ, tháng, kênh `is_missing`.
- **Cắt đoạn:** dựng chỉ mục (`building_id`, bắt đầu, độ dài 336, bước 168) và cắt lười khi huấn luyện; các đoạn không được vượt qua mốc chia dữ liệu.

2. Chia dữ liệu và thống kê chuẩn hoá:

- Giao thức T: huấn luyện trước 01/09/2016, chọn ngưỡng trong tháng 9, đánh giá từ 01/10/2016. Giao thức B: `GroupKFold` theo `building_id`.
- Median, IQR, giá trị chuẩn hoá của từng toà nhà và các tham số nhúng chỉ được ước lượng trên phần huấn luyện của từng lượt chia, rồi áp dụng sang phần còn lại.

- Với LSTM-AE: chỉ giữ các cửa sổ không chứa giờ bất thường nào trong phần huấn luyện; cửa sổ chứa bất thường chỉ dùng cho kiểm định và đánh giá.

3. Tập kiểm tra (Test):

- **Files áp dụng:** `test_features.csv` (và `test.csv`). Theo mô tả của Orvati Nia et al. (2026), tập kiểm tra gồm 206 toà nhà khác với 200 toà nhà huấn luyện. Nhóm chưa xác nhận tập này có nhãn công khai hay không, nên các phép đánh giá của đề tài dùng giao thức T và B trên tập huấn luyện, còn tập kiểm tra chỉ dùng để suy luận cuối cùng nếu cần.
- Nếu suy luận trên toà nhà mới, thống kê chuẩn hoá của toà đó được ước lượng từ chính chuỗi của toà đó (thiết lập ngoại tuyến), và điều này được nêu rõ trong báo cáo.

5.6 Bộ thí nghiệm kiểm chứng giả thuyết

Mỗi lựa chọn trong pipeline gắn với một giả thuyết có thể bác bỏ bằng thực nghiệm. Kết quả, kể cả khi trái với kỳ vọng, đều được báo cáo.

Mã	Giả thuyết	Thí nghiệm / đại lượng đo
H1	Kênh `run_len` và hiệu giá trị giúp mô hình Học sâu tốt hơn; hoặc mạng tự học được chúng từ giá trị thô	Huấn luyện có/không hai kênh này; so PR-AUC và recall theo loại bất thường
H2	Mô hình gán nhãn chuỗi có giám sát vượt LSTM-AE không giám sát	So PR-AUC và F1 cùng giao thức; hai mô hình dùng cùng cửa sổ
H3	LSTM-AE bỏ sót bất thường dạng phẳng vì chuỗi hằng số dễ tái tạo	Tách sai số tái tạo theo `run_len`; so recall nhóm bằng 1,0 với nhóm còn lại
H4	Ngữ cảnh hai phía (BiGRU, TCN không nhân quả) tốt hơn mô hình nhân quả ở các đoạn lặp	So BiGRU/TCN không nhân quả với TCN nhân quả theo độ dài đoạn lặp
H5	Dung hợp Học sâu và Học máy tốt hơn từng mô hình riêng lẻ	So Stacking/Blending có và không có mô hình Học sâu ở bước Ensemble
H6	Mô hình giảm hiệu năng khi chuyển sang toà nhà chưa thấy	So giao thức T với giao thức B; xem `square_feet` và embedding `site_id` có gây phụ thuộc toà nhà hay không
H7	Focal loss tốt hơn BCE có trọng số trên dữ liệu mất cân bằng	So PR-AUC giữa ba cấu hình hàm mất mát trong cùng kiến trúc
H8	Mô hình theo cụm toà nhà tốt hơn mô hình toàn cục	So mô hình toàn cục với mô hình theo cụm trên cùng giao thức B

Nhóm báo cáo kết quả dưới dạng trung bình ± độ lệch chuẩn của ít nhất 3 lần chạy. Các chênh lệch nhỏ hơn độ lệch chuẩn không được diễn giải là khác biệt thực sự.

6 Đánh giá, So sánh và Phân tích kết quả, hiệu năng

7 Kết luận và Hướng phát triển tương lai

TÀI LIỆU THAM KHẢO

[1] **Dữ liệu LEAD1.0:** Gulati, M., & Arjunan, P. (2022). LEAD1.0: A Large-scale Annotated Dataset for Energy Anomaly Detection in Commercial Buildings. *The Thirteenth ACM International Conference on Future Energy Systems (e-Energy '22)*, 485–488. DOI: https://doi.org/10.1145/3538637.3539761

[2] **Dữ liệu ASHRAE:** Miller, C., et al. (2020). The ASHRAE Great Energy Predictor III competition: Overview and results. *Science and Technology for the Built Environment*. DOI: https://doi.org/10.1080/23744731.2020.1795514

[3] **XGBoost:** Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *KDD '16*. DOI: https://doi.org/10.1145/2939672.2939785

[4] **LightGBM:** Ke, G., Meng, Q., Finley, T., et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *NeurIPS 2017*. URL: https://papers.nips.cc/paper/6907-lightgbm-a-highly-efficient-gradient-boosting-decision-tree.pdf

[5] **Random Forest:** Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32. DOI: https://doi.org/10.1023/A:1010933404324

[6] **Extra Trees:** Geurts, P., Ernst, D., & Wehenkel, L. (2006). Extremely randomized trees. *Machine Learning*, 63(1), 3–42. DOI: https://doi.org/10.1007/s10994-006-6226-1

[7] **SMOTE:** Chawla, N. V., et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *JAIR*, 16, 321–357. DOI: https://doi.org/10.1613/jair.953

[8] **Optuna:** Akiba, T., et al. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. *KDD '19*. DOI: https://doi.org/10.1145/3292500.3330701

[9] **Học máy và Feature Engineering:** Buaprakhong, T., et al. (2026). An Integrated Framework of Feature Engineering and Machine Learning for Large-Scale Energy Anomaly Detection. *Energy Engineering*. DOI: https://doi.org/10.32604/ee.2026.069004

[10] **Phát hiện bất thường (GAT):** Zhang, Z., et al. (2023). Anomaly detection method for building energy consumption in multivariate time series based on graph attention mechanism. *PLOS ONE*. DOI: https://doi.org/10.1371/journal.pone.0286770

[11] **GAN-LSTM trên LEAD:** Orvati Nia, F., Salehi, S., & Peeples, J. (2026). Evaluating GAN-LSTM for Smart Meter Anomaly Detection in Power Systems. *IEEE Texas Power and Energy Conference (TPEC) 2026*. arXiv: https://arxiv.org/abs/2601.09701

[12] **GAN không giám sát trên dữ liệu năng lượng:** Handigol, P. P., & Arjunan, P. (2025). Generative Adversarial Networks for Unsupervised Anomaly Detection in Energy Time series data. *Hội thảo Tackling Climate Change with Machine Learning, ICLR 2025 (Climate Change AI)*. URL: https://www.climatechange.ai/papers/iclr2025/18

[13] **Soft-DTW và tái tạo song song:** Prabhu, H., Valadi, J., & Arjunan, P. (2024). Generative Adversarial Network with Soft-Dynamic Time Warping and Parallel Reconstruction for Energy Time Series Anomaly Detection. *AI4TS Workshop, AAAI 2024*. arXiv: https://arxiv.org/abs/2402.14384

[14] **Phân cụm toà nhà:** Cansever, B. N., & Konyar, M. Z. (2026). A clustering-based supervised approach for anomaly detection in building energy consumption. *E3S Web of Conferences*, 727, 02012. DOI: https://doi.org/10.1051/e3sconf/202672702012

[15] **LSTM-AE (EncDec-AD):** Malhotra, P., Ramakrishnan, A., Anand, G., Vig, L., Agarwal, P., & Shroff, G. (2016). LSTM-based Encoder-Decoder for Multi-sensor Anomaly Detection. *ICML 2016 Anomaly Detection Workshop*. arXiv: https://arxiv.org/abs/1607.00148

[16] **LSTM cho phát hiện bất thường:** Malhotra, P., Vig, L., Shroff, G., & Agarwal, P. (2015). Long Short Term Memory Networks for Anomaly Detection in Time Series. *ESANN 2015*.

[17] **USAD:** Audibert, J., Michiardi, P., Guyard, F., Marti, S., & Zuluaga, M. A. (2020). USAD: UnSupervised Anomaly Detection on Multivariate Time Series. *KDD '20*. DOI: https://doi.org/10.1145/3394486.3403392

[18] **TCN:** Bai, S., Kolter, J. Z., & Koltun, V. (2018). An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling. arXiv: https://arxiv.org/abs/1803.01271

[19] **Anomaly Transformer:** Xu, J., Wu, H., Wang, J., & Long, M. (2022). Anomaly Transformer: Time Series Anomaly Detection with Association Discrepancy. *ICLR 2022*. arXiv: https://arxiv.org/abs/2110.02642

[20] **TranAD:** Tuli, S., Casale, G., & Jennings, N. R. (2022). TranAD: Deep Transformer Networks for Anomaly Detection in Multivariate Time Series Data. *PVLDB*, 15(6), 1201–1214. arXiv: https://arxiv.org/abs/2201.07284

[21] **AnoGAN:** Schlegl, T., Seeböck, P., Waldstein, S. M., Schmidt-Erfurth, U., & Langs, G. (2017). Unsupervised Anomaly Detection with Generative Adversarial Networks to Guide Marker Discovery. *IPMI 2017*, 146–157.

[22] **TAnoGAN:** Bashar, M. A., & Nayak, R. (2020). TAnoGAN: Time Series Anomaly Detection with Generative Adversarial Networks. *IEEE SSCI 2020*. arXiv: https://arxiv.org/abs/2008.09567

[23] **VAE:** Kingma, D. P., & Welling, M. (2014). Auto-Encoding Variational Bayes. *ICLR 2014*. arXiv: https://arxiv.org/abs/1312.6114

[24] **Đánh giá thuật toán chuỗi thời gian:** Schmidl, S., Wenig, P., & Papenbrock, T. (2022). Anomaly Detection in Time Series: A Comprehensive Evaluation. *PVLDB*, 15(9), 1779–1797.

[25] **LSTM:** Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780. DOI: https://doi.org/10.1162/neco.1997.9.8.1735

[26] **GRU:** Cho, K., et al. (2014). Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation. *EMNLP 2014*. DOI: https://doi.org/10.3115/v1/D14-1179

[27] **RNN hai chiều:** Schuster, M., & Paliwal, K. K. (1997). Bidirectional recurrent neural networks. *IEEE Transactions on Signal Processing*, 45(11), 2673–2681.

[28] **Transformer:** Vaswani, A., et al. (2017). Attention Is All You Need. *NeurIPS 2017*. arXiv: https://arxiv.org/abs/1706.03762

[29] **Focal Loss:** Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal Loss for Dense Object Detection. *ICCV 2017*. arXiv: https://arxiv.org/abs/1708.02002