ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC & KỸ THUẬT MÁY TÍNH



Lập trình cho Trí tuệ nhân tạo và Khoa học dữ liệu
CO3135

PHÁT HIỆN BẤT THƯỜNG PHỤ TẢI ĐIỆN BẰNG CÁC PHƯƠNG PHÁP HỌC MÁY VÀ HỌC SÂU TÍCH HỢP THÔNG TIN SIÊU DỮ LIỆU

GVHD: ThS. Trần Huy
NHÓM: **L01**
SINH VIÊN: Nguyễn Ngọc Tôn - 2313508
Nguyễn Miên Phú - 2312658
Trần Đỗ Đức Phát - 2312596
Huỳnh Kim Quý - 2312894
Nguyễn Đức Tiến - 2313431

TP. HỒ CHÍ MINH, THÁNG 12/2026

Mục lục

1 Tổng quan về Bài toán và Dữ liệu **4**
1.1 Giới thiệu bài toán 4
1.2 Mô tả tập dữ liệu 4

2 Tổng quan tài liệu **7**
2.1 Các phương pháp Học máy hiện có để giải quyết bài toán 7
2.1.1 XGBoost (eXtreme Gradient Boosting) 7
2.1.2 LightGBM (Light Gradient Boosting Machine) 8
2.1.3 CatBoost (Categorical Boosting) 9
2.1.4 HistGradientBoosting (Histogram-based Gradient Boosting) 10
2.1.5 Tổng hợp So sánh Bộ tứ Thuật toán Gradient Boosting Chủ lực . . 10
2.2 Các phương pháp Học sâu hiện có để giải quyết bài toán 10
2.2.1 Biểu diễn bài toán và ba hệ hình tiếp cận 11
2.2.2 Nhóm Mạng Hồi quy (Recurrent Neural Networks) 11
2.2.3 Nhóm Mạng Tích chập thời gian (Temporal Convolutional Networks) 13
2.2.4 Nhóm Tự mã hoá (Autoencoder-based) 14
2.2.5 Nhóm Mô hình sinh đối kháng (GAN-based) 16
2.2.6 Nhóm Transformer 17
2.3 Các kỹ thuật bổ trợ hiện có để giải quyết bài toán 18
2.3.1 Kỹ thuật tương tác giữa địa điểm và công năng 18
2.3.2 Chuẩn hóa phụ tải theo ngữ cảnh 19
2.3.3 Đặc trưng biến thiên phụ tải trong bộ dữ liệu Expanded 20
2.3.4 Kỹ thuật phân cụm hành vi phụ tải 22
2.3.5 Hàm mất mát entropy chéo nhị phân có trọng số 22
2.3.6 Hàm mất mát tập trung 23
2.3.7 Mạng tích chập thời gian kết hợp bộ tự mã hóa TCN 23
2.3.8 Cơ chế tự chú ý trong mô hình chuỗi 24
2.3.9 Hàm mất mát căn chỉnh thời gian mềm khả vi Soft-DTW 25
2.3.10 Mô hình chuỗi có điều kiện theo siêu dữ liệu 25
2.3.11 Mô hình sinh đối kháng kết hợp mạng LSTM 26
2.3.12 Mạng sinh đối kháng tích chập sâu một chiều 27
2.3.13 Kỹ thuật tái tạo song song nhiều điểm 28

3 Tiền xử lý và Khám phá Dữ liệu **28**
3.1 Khám phá Dữ liệu Ban đầu 29
3.1.1 Phân tích sự Mất cân bằng Lớp Dữ liệu 29
3.1.2 Phân tích Phân phối Tần suất Đặc trưng 29
3.1.3 Toàn cảnh Lịch sử Phụ tải và Phân bố Dị thường theo Thời gian . 30
3.1.4 Quan sát Nhãn Bất thường trên Chuỗi Thời gian 31
3.1.5 Tình trạng Thiếu Dữ liệu 32
3.2 Quy trình Tiền xử lý Dữ liệu 32
3.2.1 Giao thức Phân chia Chuỗi Thời gian Chu kỳ Mùa vụ và 96 Giờ Cách ly 33
3.3 Khám phá Dữ liệu sau Tiền xử lý 39
3.3.1 Kiểm tra Tính Toàn vẹn và Phân bổ Đặc trưng 39
3.3.2 Lược đồ Lịch sử Tiến trình Tiền xử lý 41
3.3.3 Khám phá Tương tác Khu vực 42

3.3.4 Khảo sát các Đặc trưng Ngữ cảnh 42
3.3.5 Phân tích Khám phá Dữ liệu Chuyên sâu trên Không gian Mở rộng 43

4 Triển khai Học máy 46
4.1 Thước đo Đánh giá và Cơ chế Ngưỡng Quyết định 46
4.1.1 Thước đo Đánh giá 46
4.1.2 Cơ chế Ngưỡng Quyết định 47
4.2 Thử nghiệm, Huấn luyện và Đánh giá các Mô hình 47
4.2.1 Chiến lược Phân chia Dữ liệu và Kiểm soát Phân phối Tập Huấn luyện - Kiểm tra 47
4.2.2 Phân tích Thực nghiệm: Đối chứng Bộ tứ Gradient Boosting qua 3 Không gian Dữ liệu 48
4.2.3 Tối ưu hóa Siêu tham số bằng Optuna 49
4.2.4 Kỹ thuật Dung hợp Đa Mô hình (Multi-Model Ensembling) 50
4.2.5 Đối chứng các mốc dung hợp trên Expanded 51
4.3 Đánh giá Isolation Forest và K-Means trên Không gian Expanded 52

5 Triển khai Học Sâu 53
5.1 Thiết kế Pipeline Học Sâu Tổng thể 53
5.2 Huấn luyện và Đánh giá Mô hình 55
5.2.1 Cơ sở Phương pháp luận: Mục tiêu Đầu ra, Tiêu chí Lựa chọn và Quy trình Thực hiện 55
5.2.2 Dữ liệu Đầu vào và Giao thức Đánh giá 57
5.2.3 Đặc tả Kiến trúc và Siêu tham số 58
5.2.4 Luận giải việc Lựa chọn và Loại trừ các Thuật toán 59
5.3 Kết quả Thực nghiệm Đánh giá 60
5.4 Giới hạn của Hiện thực và Hướng Mở rộng 65
5.5 Bộ Giả thuyết Kiểm chứng 66

6 So sánh Học Máy và Học Sâu: Thế mạnh và Điểm yếu 67

7 Kết luận và Hướng phát triển tương lai 67
7.1 Kết luận 67
7.2 Hướng phát triển Tương lai 67

TÀI LIỆU THAM KHẢO 68

STT	MSSV	Họ và Tên	Nhiệm vụ	Đóng góp
1	2313508	Nguyễn Ngọc Tôn	• Tiền xử lý dữ liệu • Triển khai Machine Learning • Viết báo cáo Phần 2.1, 2.3, 3, 4	100%
2	2312658	Nguyễn Miên Phú	• Viết báo cáo Phần 3, 4	100%
3	2312596	Trần Đỗ Đức Phát	• Triển khai Deep Learning • Viết báo cáo Phần 2.2, 2.3, 5	100%
4	2312894	Huỳnh Kim Quý	• Triển khai Deep Learning • Viết báo cáo Phần 2.2, 2.3, 5	100%
5	2313431	Nguyễn Đức Tiến	• Viết báo cáo Phần 1	100%

Bảng 1: **Phân công nhiệm vụ và mức độ đóng góp**

1 Tổng quan về Bài toán và Dữ liệu

1.1 Giới thiệu bài toán

Các tòa nhà hiện đại tiêu thụ một lượng lớn năng lượng và được trang bị nhiều công tơ điện thông minh. Các thiết bị này liên tục ghi nhận mức tiêu thụ điện theo thời gian, tạo ra một lượng lớn dữ liệu chuỗi thời gian. Việc phân tích các dữ liệu này có thể hỗ trợ phát hiện những trường hợp sử dụng năng lượng bất thường, từ đó góp phần xác định các vấn đề như sự cố thiết bị, thiết bị xuống cấp, cấu hình không phù hợp hoặc các hành vi sử dụng năng lượng không hiệu quả.

Trong báo cáo này, nhóm tập trung vào bài toán *Energy Anomaly Detection*, nhằm phát hiện các điểm bất thường trong dữ liệu tiêu thụ điện. Một điểm dữ liệu được xem là bất thường (*anomaly*) khi mức tiêu thụ điện tại thời điểm đó khác biệt đáng kể so với trạng thái sử dụng điện thông thường, ngược lại được xem là bình thường (*normal*).

Về mặt hình thức, bài toán được thiết lập dưới dạng phân lớp có giám sát trên không gian đặc trưng đa chiều. Mỗi quan trắc của một tòa nhà tại thời điểm t được mã hóa thành một vector đặc trưng $\mathbf{x} \in \mathbb{R}^D$ tích hợp đa tầng từ nhiều nguồn dữ liệu:

$$\mathbf{x} = \Big[\underbrace{m_t}_{\text{mức phụ tải}}, \underbrace{\mathbf{x}_{\text{time}}}_{\text{chu kỳ tuần hoàn}}, \underbrace{\mathbf{x}_{\text{bldg}}}_{\text{thông tin tòa nhà}}, \underbrace{\mathbf{x}_{\text{weather}}}_{\text{khí hậu}}, \underbrace{\mathbf{x}_{\text{zone}}}_{\text{tương tác vùng}}, \underbrace{\mathbf{x}_{\text{context}}}_{\text{ngữ cảnh vi mô}}, \underbrace{\mathbf{x}_{\text{lag}}, \mathbf{x}_{\text{diff}}, \mathbf{x}_{\text{ratio}}, \text{flatline}, \text{stl_residual}}_{\text{động học chuỗi thời gian \& phân rã mùa vụ STL}} \Big]^{\top} \in \mathbb{R}^D$$

Mục tiêu của các mô hình là học một hàm ánh xạ phân lớp $f : \mathbb{R}^D \to \{0, 1\}$ nhằm trực tiếp gán nhãn quyết định nhị phân cho từng quan trắc:

$$\hat{y} = f(\mathbf{x}) \in \{0, 1\}$$

trong đó $\hat{y} = 1$ tương ứng với trạng thái bất thường (*Anomaly*) và $\hat{y} = 0$ tương ứng với trạng thái bình thường (*Normal*).

Để giải quyết bài toán này, nhóm tiến hành nghiên cứu, huấn luyện mô hình trên cả hai lĩnh vực Machine Learning và Deep Learning, đồng thời so sánh nhằm tìm ra được ưu, nhược điểm trong cách giải quyết bài toán của chúng, kết hợp các kỹ thuật xử lý nâng cao để cải thiện chất lượng của mô hình.

1.2 Mô tả tập dữ liệu

Dữ liệu thực nghiệm của bài toán được cung cấp chính thức thông qua cuộc thi **Large-scale Energy Anomaly Detection (LEAD)** trên nền tảng Kaggle tại liên kết: `https://www.kaggle.com/competitions/energy-anomaly-detection/data`. Bộ dữ liệu này được xây dựng dựa trên nguồn dữ liệu tiêu thụ năng lượng của cuộc thi *ASHRAE - Great Energy Predictor III* và được mở rộng bằng cách gán nhãn bất thường cho các điểm đo điện theo từng giờ trong suốt năm 2016, thời gian bắt đầu từ 00:00 ngày 01/01/2016 đến 23:00 ngày 31/12/2016, tại nhiều tòa nhà thương mại.

Theo công bố từ ban tổ chức cuộc thi trên nền tảng Kaggle với tổng dung lượng khoảng 1,34 GB, bộ dữ liệu hoàn chỉnh bao gồm 5 tệp dữ liệu:

- **`train.csv`:** Tệp chuỗi thời gian thô của tập huấn luyện, chỉ chứa các trường `building_id`, `timestamp`, `meter_reading` và nhãn bất thường `anomaly`.

- **`test.csv`:** Tệp chuỗi thời gian thô của tập kiểm tra, không chứa cột nhãn `anomaly`.
- **`sample_submission.csv`:** Tệp mẫu định dạng nộp kết quả dự đoán bao gồm 2 cột `row_id` và `anomaly` lên hệ thống chấm điểm trực tuyến của cuộc thi.
- **`test_features.csv`:** Tệp kiểm tra mở rộng gồm 206 tòa nhà độc lập với 1.800.567 bản ghi và 57 thuộc tính đã được ghép nối thông tin công trình và điều kiện thời tiết, nhưng không có cột nhãn mục tiêu `anomaly`.
- **`train_features.csv`:** Tệp huấn luyện mở rộng hoàn chỉnh gồm dữ liệu đo đạc của 200 tòa nhà với 1.749.494 bản ghi chuỗi thời gian và 57 thuộc tính tích hợp sẵn mức tiêu thụ điện, đặc tính tòa nhà, điều kiện khí hậu, các biến trễ thời gian và nhãn bất thường `anomaly`.

Phạm vi dữ liệu sử dụng trong nghiên cứu: Mặc dù ban tổ chức cuộc thi cung cấp đầy đủ 5 tệp dữ liệu nêu trên, trong toàn bộ nghiên cứu và thực nghiệm của báo cáo này, nhóm chỉ sử dụng duy nhất một tệp là `train_features.csv`. Lý do:

- *Bảo toàn nhãn kiểm chứng khách quan:* Tệp `test_features.csv` là tập dữ liệu ẩn của cuộc thi, hoàn toàn không công bố nhãn `anomaly` nhằm mục đích bảo mật cho bảng xếp hạng trực tuyến. Do đó, để có thể chủ động đánh giá chất lượng mô hình, nhóm cần một tập dữ liệu có đầy đủ nhãn `anomaly`.
- *Tận dụng các đặc trưng làm giàu chất lượng cao:* So với tệp thô `train.csv`, tệp `train_features.csv` đã được tích hợp sẵn các đặc trưng bối cảnh vật lý công trình và dữ liệu khí tượng chuẩn hóa, cung cấp nền tảng vững chắc để xây dựng các kỹ thuật Feature Engineering chuyên sâu.

Tệp dữ liệu `train_features.csv` bao gồm 57 thuộc tính, kết hợp giữa các thông tin đo lường phụ tải cơ sở và hệ thống đặc trưng đa chiều phong phú phục vụ quá trình mô hình hóa. Chi tiết các thuộc tính cốt lõi và các nhóm đặc trưng bổ sung được tổng hợp tại Bảng 2.

Bảng 2: Tổng hợp hệ thống thuộc tính và nhóm đặc trưng trong tệp `train_features.csv`

Phân nhóm	**Tên thuộc tính / Đại diện**	**Ý nghĩa và Mô tả thực tế**
Thuộc tính cốt lõi	`building_id`	Mã định danh duy nhất của tòa nhà nơi dữ liệu phụ tải được ghi nhận.
	`timestamp`	Mốc thời gian ghi nhận mức tiêu thụ điện (chu kỳ 1 giờ, xuyên suốt năm 2016).
	`meter_reading`	Mức tiêu thụ điện năng thực tế của công trình tại thời điểm tương ứng (kWh).
	`anomaly`	Biến mục tiêu phân loại.
Thông tin công trình	`site_id`, `primary_use`, `square_feet`, `year_built`, `floor_count`	Thông số vật lý công trình: vị trí khu vực, công năng sử dụng, diện tích sàn (sqft), năm xây dựng và số tầng.
Điều kiện thời tiết	`air_temperature`, `dew_temperature`, `cloud_coverage`, `precip_depth_1_hr`, `sea_level_pressure`, `wind_direction`, `wind_speed`	Dữ liệu khí tượng tức thời quan trắc từ các trạm thời tiết (nhiệt độ không khí, điểm sương, độ che phủ mây, lượng mưa, áp suất, hướng và tốc độ gió).
Thời gian & Chu kỳ	`hour`, `weekday`, `month`, `year`, `weekday_hour`, `is_holiday`, `hour_x/y`, `month_x/y`, `weekday_x/y`	Đặc trưng lịch biểu (giờ, thứ, tháng, chỉ báo ngày lễ) và các biến mã hóa chu kỳ lượng giác (sin / cos) mô hình hóa nhịp sinh hoạt ngày/đêm.
Trễ chuỗi thời gian	`air_temperature -_mean_lag7/73`, `max_lag7/73`, `min_lag7/73`, `std_lag7/73`	Các đặc trưng thống kê nhiệt độ môi trường qua các cửa sổ quá khứ 7 giờ và 73 giờ ($\approx$ 3 ngày), nắm bắt quán tính nhiệt công trình.
Tương tác tòa nhà	`building_hour`, `building_weekday`, `building_month`, `building_weekday_hour`, `building_meter`	Kết hợp đặc thù vận hành của từng công trình theo từng khung giờ và ngày trong tuần.
Mã hóa mục tiêu (GTE)	16 đặc trưng mang tiền tố `gte_` (`gte_hour`, `gte_building_id`, `gte_primary_use`, `gte_meter`, …)	Nhóm đặc trưng Group Target Encoding: mã hóa tỷ lệ dị thường kỳ vọng theo từng nhóm bối cảnh không gian và thời gian.

Trong đó, thuộc tính `anomaly` đóng vai trò là biến mục tiêu cần dự đoán. Kết quả thống kê trên toàn bộ 1.749.494 bản ghi của tệp dữ liệu cho thấy có 1.712.198 bản ghi thuộc lớp bình thường (`anomaly` = 0) và 37.296 bản ghi thuộc lớp bất thường (`anomaly` = 1). Như vậy, bài toán mang tính chất mất cân bằng nhãn sâu sắc với tỷ lệ dị thường thực tế chỉ chiếm khoảng 2,13%.

Bên cạnh đó, các nhóm đặc trưng bổ sung giúp mô hình nắm bắt toàn diện bối cảnh vật lý công trình, thời tiết khí tượng và nhịp điệu sinh hoạt theo thời gian. Đây là nguồn tín hiệu đầu vào phong phú được nhóm nghiên cứu sàng lọc, chuẩn hóa và tối ưu hóa trong các giai đoạn Tiền xử lý và Xây dựng mô hình ở các chương tiếp theo.

Qua quá trình kiểm tra trên tệp `train_features.csv`, thuộc tính `meter_reading` xuất hiện các giá trị bị thiếu với 107.653 bản ghi, tương đương khoảng 6,15% tổng số bản ghi của tập dữ liệu. Vì vậy, dữ liệu thiếu cần được xem xét và xử lý trong bước tiền xử

lý trước khi đưa vào các mô hình Học máy và Học sâu. Ngoài `meter_reading`, các thuộc tính còn lại trong tệp `train_features.csv` đều đầy đủ và không ghi nhận giá trị thiếu trong suốt quá trình kiểm tra.

2 Tổng quan tài liệu

2.1 Các phương pháp Học máy hiện có để giải quyết bài toán

Do dữ liệu sử dụng trong nghiên cứu đã có gán nhãn cho biến `anomaly` (0 biểu thị trạng thái bình thường, 1 biểu thị trạng thái bất thường), bài toán được xây dựng dưới dạng phân loại nhị phân có giám sát. Các phương pháp học máy tiếp cận được trình bày trong mục này là các phương pháp tiêu biểu và được sử dụng trong lời giải quán quân cuộc thi LEAD của Fu et al. [2].

2.1.1 XGBoost (eXtreme Gradient Boosting)

XGBoost [10] tối ưu hóa hàm mục tiêu bằng phương pháp khai triển Taylor bậc hai, cho phép hội tụ nhanh hơn. Cấu trúc cây được phát triển theo từng tầng. Mô hình cuối cùng là tổng hợp tuần tự của K cây quyết định:

$$\hat{y}_i = \sum_{k=1}^{K} f_k(\mathbf{x}_i), \quad f_k \in \mathcal{F}$$

trong đó $\mathcal{F}$ là không gian của các cây hồi quy CART. Tại mỗi bước lặp t, hàm mục tiêu được tối ưu bằng khai triển Taylor bậc hai:

$$\mathcal{L}^{(t)} \simeq \sum_{i=1}^{n} \left[g_i f_t(\mathbf{x}_i) + \frac{1}{2} h_i f_t^2(\mathbf{x}_i) \right] + \Omega(f_t)$$

với $g_i = \partial_{\hat{y}^{(t-1)}} \ell(y_i, \hat{y}^{(t-1)})$ là gradient bậc nhất, $h_i = \partial^2_{\hat{y}^{(t-1)}} \ell(y_i, \hat{y}^{(t-1)})$ là gradient bậc hai của hàm mất mát và $\Omega(f_t)$ là hàm phạt cấu trúc cây:

$$\Omega(f) = \gamma T + \frac{1}{2}\lambda \sum_{j=1}^{T} w_j^2 + \alpha \sum_{j=1}^{T} |w_j|$$

trong đó T là số lá, w_j là trọng số tại lá j, γ phạt số lượng lá, λ là hệ số điều chuẩn L_2 và α là hệ số điều chuẩn L_1.

Ưu điểm:

- **Hạn chế Overfitting:** Tích hợp các thành phần phạt L_1 (α) và L_2 (λ) trực tiếp vào hàm mục tiêu $\Omega(f)$, giúp hạn chế hiệu quả hiện tượng overfitting khi mô hình tiếp xúc với dữ liệu nhiễu từ các cảm biến đo lường.
- **Xử lý mất cân bằng lớp:** Hỗ trợ điều chỉnh trọng số thông qua siêu tham số `scale_pos_weight`, gán penalty cao hơn cho trường hợp phân loại sai lớp thiểu số.

- **Xử lý giá trị khuyết:** Thuật toán tự học hướng mặc định tại mỗi nút chia cho các giá trị bị khuyết, phù hợp với dữ liệu cảm biến thực tế thường có nhiều giá trị bị thiếu.

Nhược điểm:

- **Độ phức tạp thời gian:** Thuật toán phân nhánh tham lam chính xác đòi hỏi duyệt qua toàn bộ dữ liệu liên tục. Mặc dù đã có các cải tiến như Histogram-based, XGBoost vẫn yêu cầu thời gian tính toán khi xử lý tập dữ liệu có quy mô lớn.
- **Phát triển cây Level-wise:** Chiến lược phát triển theo tầng buộc tất cả các nút ở cùng một độ sâu phải được mở rộng, dẫn đến việc phân chia tại nhiều nút không cần thiết.

2.1.2 LightGBM (Light Gradient Boosting Machine)

LightGBM [11] được thiết kế chuyên biệt để tối ưu hóa hiệu suất trên dữ liệu quy mô lớn thông qua hai kỹ thuật cốt lõi: GOSS (Gradient-based One-Side Sampling) và EFB (Exclusive Feature Bundling). Cây được phát triển theo cơ chế ưu tiên lá.

Kỹ thuật GOSS ước lượng độ lợi thông tin bằng cách giữ lại toàn bộ các mẫu có gradient lớn và lấy mẫu ngẫu nhiên từ các mẫu có gradient nhỏ, sau đó nhân trọng số bù:

$$\widetilde{V}_j(d) = \frac{1}{n}\left(\frac{\left(\sum_{x_i\in A_l} g_i + \frac{1-a}{b}\sum_{x_i\in B_l} g_i\right)^2}{n_l^j(d)} + \frac{\left(\sum_{x_i\in A_r} g_i + \frac{1-a}{b}\sum_{x_i\in B_r} g_i\right)^2}{n_r^j(d)}\right)$$

trong đó A là tập các mẫu có gradient lớn, B là tập mẫu ngẫu nhiên từ các mẫu có gradient nhỏ, l và r ký hiệu nhánh trái và phải tại ngưỡng d của đặc trưng j.

Kỹ thuật EFB gộp các đặc trưng thưa có tính loại trừ lẫn nhau thành các gói, giảm số lượng đặc trưng từ p xuống số lượng gói $p' \ll p$.

Ưu điểm:

- **Hiệu suất tính toán ưu việt:** Kỹ thuật Histogram giúp giảm độ phức tạp thời gian tìm kiếm điểm chia nhánh, mang lại tốc độ huấn luyện nhanh.
- **Xử lý biến định danh trực tiếp:** Khai thác hiệu quả các đặc trưng phân loại xuất hiện nhiều giá trị khác nhau như `site_id`, `primary_use`,... bằng cách phân chia tối ưu trên các danh mục mà không cần mã hóa One-Hot, giúp kiểm soát chiều dữ liệu.
- **Tiết kiệm bộ nhớ:** Kỹ thuật EFB giảm đáng kể số chiều hiệu dụng, trong khi biểu diễn Histogram chỉ lưu trữ các bin rời rạc thay vì toàn bộ giá trị liên tục, giúp tiết kiệm RAM khi xử lý dữ liệu hàng chục triệu dòng.
- **GOSS giữ độ chính xác khi lấy mẫu:** Thay vì lấy mẫu đồng đều, GOSS ưu tiên các mẫu có gradient lớn (đóng góp nhiều nhất vào việc học), nên giảm dữ liệu mà vẫn duy trì chất lượng mô hình.

Nhược điểm:

- **Rủi ro quá khớp cục bộ:** Sự phát triển theo chiều sâu lá có thể dẫn đến việc mô hình học các mẫu nhiễu cục bộ. Cần giới hạn nghiêm ngặt các tham số `max_depth` và `min_data_in_leaf`.
- **Nhạy cảm với dữ liệu không đa dạng:** Chiến lược phát triển cây theo chiều sâu lá tạo ra các cây sâu không cân bằng, dễ overfitting trên các tập dữ liệu nhỏ. Tuy nhiên, hạn chế này ít ảnh hưởng trong bài toán hiện tại do quy mô dữ liệu rất lớn.

2.1.3 CatBoost (Categorical Boosting)

Thuật toán CatBoost [12] xây dựng các cây quyết định đối xứng và sử dụng cơ chế Ordered Target Encoding. Đặc điểm cốt lõi của CatBoost là sử dụng hoán vị ngẫu nhiên σ để tính giá trị mã hóa cho biến định danh, tránh rò rỉ thông tin mục tiêu:

$$\hat{x}^i_{\sigma_p} = \frac{\sum_{j=1}^{p-1}[x^i_{\sigma_j} = x^i_{\sigma_p}] \cdot y_{\sigma_j} + a \cdot P}{\sum_{j=1}^{p-1}[x^i_{\sigma_j} = x^i_{\sigma_p}] + a}$$

trong đó σ_p là chỉ số của mẫu thứ p trong hoán vị, x^i là giá trị đặc trưng định danh thứ i, y là nhãn mục tiêu, P là giá trị trung bình toàn cục của nhãn và $a > 0$ là tham số Laplace smoothing.

Cây đối xứng sử dụng cùng một điều kiện chia tại tất cả các nút ở cùng một độ sâu, tạo ra cấu trúc cây cân bằng hoàn hảo với 2^d lá (với d là chiều sâu). Việc dự đoán trở thành phép tra bảng $O(d)$.

Ưu điểm:

- **Ngăn chặn rò rỉ dữ liệu:** Ordered Target Encoding tính toán giá trị trung bình mục tiêu dựa trên các mẫu quan sát trong quá khứ nhân tạo theo hoán vị σ, giúp mã hóa các biến định danh một cách an toàn và mạnh mẽ mà không gây rò rỉ thông tin nhãn.
- **Tốc độ suy luận nhanh:** Cấu trúc cây đối xứng cho phép mô hình được biểu diễn dưới dạng các bảng tra cứu với độ phức tạp suy luận $O(d)$, tăng tốc độ dự đoán lên nhiều lần so với các cây không đối xứng.
- **Giảm Bias:** Sử dụng nhiều hoán vị khác nhau trong quá trình huấn luyện, giảm Bias do rò rỉ thông tin trong Gradient Boosting truyền thống, đặc biệt hiệu quả trên dữ liệu có nhiều biến phân loại như `building_id`, `primary_use`.
- **Hạn chế Overfitting:** Cấu trúc cây đối xứng có ít tham số hơn cây tự do (chỉ d điều kiện chia thay vì $2^d - 1$ nút nội), đóng vai trò như một dạng điều chuẩn ngầm.

Nhược điểm:

- **Thời gian huấn luyện lớn:** Quy trình mã hóa Ordered Target Encoding và xây dựng cây đối xứng khiến CatBoost mất nhiều thời gian huấn luyện hơn so với LightGBM, đặc biệt khi bộ dữ liệu chứa lượng lớn các biến liên tục.
- **Khả năng biểu diễn hạn chế:** Ràng buộc cùng một điều kiện chia tại mỗi tầng có thể hạn chế khả năng biểu diễn các mẫu phức tạp, đòi hỏi cây phải sâu hơn để đạt cùng mức chính xác so với cây tự do.

2.1.4 HistGradientBoosting (Histogram-based Gradient Boosting)

HistGradientBoosting [13] là phiên bản tăng cường độ dốc hiện đại trong Scikit-learn, lấy cảm hứng từ kỹ thuật của LightGBM nhằm tối ưu tốc độ tính toán và bộ nhớ khi làm việc với tập dữ liệu quy mô lớn ($N > 10^6$ mẫu).

Cốt lõi của thuật toán là kỹ thuật Binning các giá trị liên tục được ánh xạ vào $K = 256$ thùng số nguyên 8-bit, với thùng thứ 255 dành riêng để xử lý tự nhiên dữ liệu khuyết. Nhờ việc cộng dồn gradient vào histogram và áp dụng phép trừ histogram, chi phí tìm điểm cắt tối ưu tại mỗi nút chỉ còn $O(K)$, hoàn toàn không phụ thuộc kích thước tập dữ liệu N.

Ưu điểm:

- **Tốc độ cao và tối ưu RAM:** Sử dụng định dạng `uint8` kết hợp đa luồng giúp tăng tốc huấn luyện vượt trội so với các thuật toán phân nhánh chính xác.
- **Xử lý trực tiếp giá trị thiếu và Dừng sớm:** Không cần tiền xử lý điền khuyết, tích hợp sẵn cơ chế Early Stopping để phòng chống quá khớp.

Nhược điểm:

- **Mất độ phân giải cục bộ:** Việc rời rạc hóa đặc trưng có thể làm mờ các biến động giá trị cực nhỏ.
- **Tùy biến mất cân bằng lớp:** Không có tham số trực tiếp như `scale_pos_weight` mà cần tinh chỉnh thông qua trọng số mẫu `sample_weight`.

2.1.5 Tổng hợp So sánh Bộ tứ Thuật toán Gradient Boosting Chủ lực

Bảng 3 tổng hợp các đặc tính kỹ thuật cốt lõi của bốn mô hình Gradient Boosting chủ lực được nghiên cứu:

Bảng 3: **So sánh Tổng hợp Bộ tứ Thuật toán Gradient Boosting trong Bài toán Phát hiện Bất thường**

Thuật toán	Chiến lược Phát triển Cây	Xử lý Biến Danh mục	Xử lý Dữ liệu Khuyết	Cơ chế Tối ưu Tốc độ	Thế mạnh Nổi bật
XGBoost	Theo tầng (*Depth-wise*)	One-Hot / Target Encoding	Tự học hướng đi mặc định	Khai triển Taylor bậc hai	Kháng quá khớp cực tốt (L_1, L_2)
LightGBM	Theo lá (*Leaf-wise*)	Phân chia tối ưu danh mục	Bỏ qua hoặc gán nhánh riêng	Histogram + GOSS + EFB	Tốc độ huấn luyện siêu tốc
CatBoost	Cây đối xứng (*Oblivious*)	Ordered Target Encoding	Gán giá trị biên nhỏ/lớn nhất	Tra bảng $O(d)$ + Hoán vị	Xử lý biến phân loại chống rò rỉ
HistGradientBoosting	Theo lá / Histogram	Hỗ trợ phân nhóm tự nhiên	Gán thùng chuyên biệt (Bin 255)	Rời rạc hóa `uint8` + Trừ Histogram	Chuẩn tắc Scikit-learn, nhẹ bộ nhớ

2.2 Các phương pháp Học sâu hiện có để giải quyết bài toán

Khác với các mô hình Học máy ở phần trước vốn xử lý từng dòng dữ liệu một cách độc lập, các phương pháp Học sâu cho chuỗi thời gian khai thác trực tiếp thứ tự và phụ thuộc thời gian giữa các quan trắc. Dựa trên khảo sát sơ bộ của nhóm trên tệp `train_features.csv`, dữ liệu có các đặc thù sau:

- **Cấu trúc chuỗi:** Gồm 200 toà nhà, mỗi toà là một chuỗi đo theo giờ trong năm 2016, tổng cộng khoảng 1,75 triệu quan trắc. Một số toà nhà thiếu một số mốc giờ và giá trị `meter_reading` có phần bị khuyết.
- **Nhãn theo từng thời điểm:** Biến `anomaly` được gán cho từng point-wise, với tỷ lệ bất thường chỉ khoảng 2,1% nên bài toán mất cân bằng lớp nghiêm trọng.

- **Bất thường không đồng nhất:** Trong tập kiểm định (từ 01/10/2016), khoảng 44% điểm bất thường có `meter_reading` đúng bằng 1,0. Trên toàn bộ dữ liệu huấn luyện, khoảng 58% điểm bất thường nằm trong một đoạn giá trị lặp lại liên tiếp có độ dài từ 3 giờ trở lên (so với khoảng 3,3% ở điểm bình thường). Phần bất thường còn lại có giá trị nằm trong vùng tiêu thụ thông thường, nên chỉ có thể nhận diện dựa trên ngữ cảnh thời gian. Nguyên nhân sinh ra các giá trị đặc biệt này chưa được nhóm kiểm chứng.

Các đặc thù trên cho thấy một mô hình xét từng điểm riêng lẻ có thể bắt tốt nhóm bất thường có giá trị đặc biệt nhưng khó nhận diện nhóm bất thường phụ thuộc ngữ cảnh. Đây là động lực để khảo sát các phương pháp Học sâu.

2.2.1 Biểu diễn bài toán và ba hệ hình tiếp cận

Với mỗi toà nhà, tại thời điểm t ta xây dựng cửa sổ trượt gồm w quan trắc gần nhất:

$$\mathbf{X}_t = (\mathbf{x}_{t-w+1}, \ldots, \mathbf{x}_t) \in \mathbb{R}^{w \times d}$$

trong đó $\mathbf{x}_i \in \mathbb{R}^d$ gồm giá trị đo `meter_reading`, các biến thời tiết, mã hoá chu kỳ của thời gian và các đặc trưng bổ sung. Nhãn tại thời điểm t là $y_t \in \{0, 1\}$. Các phương pháp Học sâu hiện có thuộc ba hệ hình chính:

1. **Tái tạo (Reconstruction-based):** Mô hình học cách tái tạo lại hành vi bình thường, điểm bất thường là sai số tái tạo:

$$a_t = \|\mathbf{x}_t - \hat{\mathbf{x}}_t\|_2^2$$

2. **Dự báo (Prediction-based):** Mô hình dự báo giá trị kế tiếp từ quá khứ, điểm bất thường là sai số dự báo:

$$a_t = |x_{t+1} - \hat{x}_{t+1}|$$

3. **Gán nhãn chuỗi có giám sát (Supervised sequence labelling):** Mô hình học trực tiếp xác suất bất thường từ nhãn có sẵn:

$$\hat{p}_t = P\left(y_t = 1 \mid \mathbf{X}_t\right)$$

Hai hệ hình đầu thường được dùng khi không có nhãn và chỉ được huấn luyện trên dữ liệu bình thường. Hệ hình thứ ba tận dụng được nhãn `anomaly` đã có của bộ dữ liệu LEAD. Phần dưới trình bày ưu nhược điểm của từng họ mô hình theo các hệ hình này.

2.2.2 Nhóm Mạng Hồi quy (Recurrent Neural Networks)

Mạng hồi quy xử lý chuỗi tuần tự, duy trì trạng thái ẩn $\mathbf{h}_t$ tổng hợp thông tin từ quá khứ. Nhóm này dùng được cho cả ba hệ hình: làm bộ gán nhãn chuỗi, làm bộ dự báo (Malhotra et al., 2015) hoặc làm bộ mã hoá–giải mã.

2.2.2.1 LSTM (Long Short-Term Memory)

LSTM đưa vào trạng thái ô nhớ $\mathbf{c}_t$ cùng ba cổng điều khiển luồng thông tin (Hochreiter & Schmidhuber [33], Malhotra et al. [22]):

$$\mathbf{f}_t = \sigma\left(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f\right), \quad \mathbf{i}_t = \sigma\left(\mathbf{W}_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i\right), \quad \mathbf{o}_t = \sigma\left(\mathbf{W}_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o\right)$$
$$\tilde{\mathbf{c}}_t = \tanh\left(\mathbf{W}_c[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c\right), \quad \mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t, \quad \mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t)$$

trong đó $\mathbf{f}_t$, $\mathbf{i}_t$, $\mathbf{o}_t$ lần lượt là cổng quên, cổng vào và cổng ra, σ là hàm sigmoid và $\odot$ là phép nhân từng phần tử.

Ưu điểm:

- **Học phụ thuộc dài hạn:** Đường truyền gradient qua ô nhớ $\mathbf{c}_t$ giảm hiện tượng triệt tiêu gradient, phù hợp với chu kỳ ngày (24 giờ) và chu kỳ tuần (168 giờ) của dữ liệu tiêu thụ điện.
- **Linh hoạt về đầu ra:** Cùng một kiến trúc có thể dùng để gán nhãn từng bước, dự báo bước kế tiếp hoặc làm bộ mã hoá trong tự mã hoá.
- **Tận dụng nhiều đặc trưng đồng thời:** Đầu vào tại mỗi bước có thể gồm giá trị đo, thời tiết và mã hoá thời gian, trong khi nhiều mô hình tái tạo trên LEAD chỉ dùng chuỗi `meter_reading` đơn biến.

Nhược điểm:

- **Tính toán tuần tự:** Mỗi bước phụ thuộc bước trước nên khó song song hoá theo trục thời gian, thời gian huấn luyện lâu hơn mạng tích chập trên cùng độ dài chuỗi.
- **Nhạy với độ dài cửa sổ và siêu tham số:** Chất lượng phụ thuộc vào w, số tầng, số đơn vị ẩn và cách khởi tạo trạng thái ở đầu cửa sổ.
- **Không tự có cơ chế xử lý mất cân bằng:** Cần kết hợp hàm mất mát có trọng số hoặc focal loss, nếu không mô hình hội tụ về dự đoán lớp đa số.

2.2.2.2 GRU (Gated Recurrent Unit)

GRU rút gọn LSTM bằng hai cổng (cập nhật $\mathbf{z}_t$ và đặt lại $\mathbf{r}_t$), không có ô nhớ riêng (Cho et al. [34]):

$$\mathbf{z}_t = \sigma\left(\mathbf{W}_z[\mathbf{h}_{t-1}, \mathbf{x}_t]\right), \quad \mathbf{r}_t = \sigma\left(\mathbf{W}_r[\mathbf{h}_{t-1}, \mathbf{x}_t]\right)$$
$$\tilde{\mathbf{h}}_t = \tanh\left(\mathbf{W}[\mathbf{r}_t \odot \mathbf{h}_{t-1}, \mathbf{x}_t]\right), \quad \mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t$$

Ưu điểm:

- **Ít tham số hơn LSTM:** Chỉ có hai cổng và không có ô nhớ riêng, nên huấn luyện nhanh hơn và dùng ít bộ nhớ GPU hơn, hữu ích với hàng triệu bước thời gian.
- **Chất lượng thường tương đương LSTM:** Trên nhiều bài toán chuỗi hai kiến trúc cho kết quả gần nhau, nên GRU là lựa chọn mặc định kinh tế khi cần khảo sát nhiều cấu hình.

Nhược điểm:

- **Biểu diễn kém linh hoạt hơn LSTM:** Không có ô nhớ tách biệt, có thể kém hơn khi cần nhớ rất lâu trên chuỗi dài.
- **Cùng hạn chế tuần tự của họ RNN:** Không song song hoá được theo thời gian.

2.2.2.3 BiLSTM / BiGRU (Mạng hồi quy hai chiều)

Mạng hai chiều chạy hai mạng hồi quy ngược chiều nhau và ghép trạng thái ẩn (Schuster & Paliwal [35]):

$$\mathbf{h}_t = \left[\overrightarrow{\mathbf{h}}_t, \overleftarrow{\mathbf{h}}_t\right], \qquad \hat{p}_t = \sigma\left(\mathbf{w}^\top \mathbf{h}_t + b\right)$$

Với bài toán gán nhãn từng giờ, $\hat{p}_t$ được tính tại mọi bước trong một đoạn chuỗi, nên một lần chạy cho ra nhãn của cả đoạn.

Ưu điểm:

- **Khai thác ngữ cảnh cả hai phía:** Thời điểm t được đánh giá dựa trên cả quá khứ lẫn tương lai gần, phù hợp với bất thường dạng đoạn liên tục (ví dụ giá trị bị kẹt trong nhiều giờ) vì mô hình biết đoạn đó kéo dài bao lâu.
- **Huấn luyện có giám sát trên toàn đoạn:** Một đoạn dài cho nhiều nhãn cùng lúc, giảm lượng tính toán dư thừa so với cửa sổ trượt bước 1.

Nhược điểm:

- **Không dùng được cho cảnh báo thời gian thực:** Mô hình cần dữ liệu tương lai nên chỉ phù hợp phát hiện bất thường ngoại tuyến. Điều này phải được nêu rõ khi báo cáo kết quả.
- **Chi phí gấp đôi:** Hai chiều nhân đôi số phép tính và tham số so với mạng một chiều.

2.2.3 Nhóm Mạng Tích chập thời gian (Temporal Convolutional Networks)

2.2.3.1 TCN (Temporal Convolutional Network)

TCN dùng tích chập nhân quả giãn nở (causal dilated convolution) kết hợp khối dư (residual block) để xử lý chuỗi (Bai et al. [24]). Tích chập nhân quả đảm bảo đầu ra tại t chỉ phụ thuộc đầu vào từ t trở về trước, và giãn nở cho phép tăng vùng nhìn mà không tăng số tham số:

$$(F *_d \mathbf{x})(t) = \sum_{i=0}^{k-1} f(i) \cdot \mathbf{x}_{t-d\cdot i}$$

trong đó k là kích thước nhân, f là bộ lọc và d là hệ số giãn nở. Khi xếp L khối dư, mỗi khối gồm hai tích chập với hệ số giãn nở $d = 2^l$ $(l = 0, \ldots, L-1)$, vùng nhìn của mạng là:

$$R = 1 + 2(k-1)\left(2^L - 1\right)$$

Ví dụ với $k = 3$ và $L = 6$ thì $R = 253$ giờ, đủ phủ chu kỳ tuần (168 giờ).

Ưu điểm:

- **Song song hoá hoàn toàn theo thời gian:** Các tích chập tính đồng thời trên toàn chuỗi nên huấn luyện nhanh trên GPU, phù hợp với khối lượng khoảng 1,75 triệu bước thời gian.
- **Điều khiển vùng nhìn chính xác:** Có thể chọn k và L để vùng nhìn phủ đúng chu kỳ ngày, chu kỳ tuần mong muốn, và công thức trên cho phép kiểm tra trước khi huấn luyện.

- **Huấn luyện ổn định:** Gradient đi theo cấu trúc cây tích chập thay vì chuỗi tuần tự, ít gặp triệt tiêu gradient hơn RNN. Nghiên cứu của Bai et al. (2018) ghi nhận một kiến trúc tích chập đơn giản vượt LSTM trên nhiều bài toán chuỗi chuẩn, đồng thời có bộ nhớ hiệu dụng dài hơn.
- **Có biến thể không nhân quả:** Thay phần đệm nhân quả bằng đệm đối xứng sẽ cho ngữ cảnh hai phía như BiLSTM, tiện cho thí nghiệm so sánh.

Nhược điểm:

- **Vùng nhìn cố định:** Sự kiện nằm ngoài R giờ không ảnh hưởng đến dự đoán, trong khi RNN về lý thuyết có thể mang thông tin xa hơn.
- **Bộ nhớ khi suy luận cho chuỗi dài:** Cần lưu kích hoạt trung gian của R bước gần nhất hoặc tính lại cả cửa sổ cho mỗi dự đoán.
- **Phụ thuộc kiểu đệm ở biên:** Đầu mỗi đoạn có ít ngữ cảnh hơn nên cần chồng lấp giữa các đoạn khi suy luận.

2.2.4 Nhóm Tự mã hoá (Autoencoder-based)

Nhóm này được huấn luyện chỉ trên dữ liệu bình thường (hoặc dữ liệu được coi là bình thường), không dùng nhãn trong quá trình học. Mô hình học nén rồi tái tạo hành vi bình thường, nên đoạn nào tái tạo kém được coi là bất thường.

2.2.4.1 LSTM Autoencoder (EncDec-AD)

Mô hình gồm bộ mã hoá LSTM nén cửa sổ $\mathbf{X}$ thành vector tiềm ẩn $\mathbf{z}$ và bộ giải mã LSTM tái tạo lại cửa sổ (Malhotra et al. [21]):

$$\mathbf{z} = E_\phi(\mathbf{X}), \quad \hat{\mathbf{X}} = D_\theta(\mathbf{z}), \quad \mathcal{L} = \frac{1}{w}\sum_{i=1}^{w} \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|_2^2$$

Vector sai số tái tạo $\mathbf{e}_t$ được mô hình hoá bằng phân phối Gaussian ước lượng trên dữ liệu bình thường kiểm định, điểm bất thường là khoảng cách Mahalanobis:

$$a_t = (\mathbf{e}_t - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{e}_t - \boldsymbol{\mu})$$

Với chuỗi đơn biến ($d = 1$), điểm này rút gọn thành sai số bình phương đã chuẩn hoá.

Ưu điểm:

- **Không cần nhãn khi huấn luyện:** Phù hợp với thực tế thiếu nhãn trong giám sát năng lượng, và có thể dùng cho các toà nhà mới chưa được gán nhãn.
- **Bắt tốt bất thường làm gãy mẫu hình tuần hoàn:** Bất thường khác biệt rõ so với dạng ngày/tuần bình thường sẽ có sai số tái tạo lớn.
- **Tạo được điểm số liên tục:** Có thể đưa sai số tái tạo vào mô hình Học máy làm đặc trưng bổ sung.

Nhược điểm:

- **Bỏ phí nhãn sẵn có:** Khi bộ dữ liệu đã có nhãn, huấn luyện không giám sát thường kém mô hình có giám sát cùng ngân sách tính toán.
- **Rủi ro bỏ sót bất thường dạng "phẳng":** Một đoạn giá trị không đổi là chuỗi rất dễ tái tạo, nên sai số có thể thấp dù đoạn đó bị gán nhãn bất thường. Đây là giả thuyết nhóm sẽ kiểm chứng bằng thực nghiệm, và phù hợp với nhận xét của Orvati Nia et al. (2026) rằng mô hình tái tạo có thể bỏ lỡ lệch nhẹ không làm thay đổi đáng kể sai số theo điểm.
- **Cần chọn ngưỡng:** Ngưỡng phải ước lượng trên tập kiểm định và dễ lệch giữa các toà nhà có thang đo khác nhau.
- **Nhạy với nhiễu trong tập "bình thường":** Nếu dữ liệu huấn luyện lẫn bất thường chưa được gán nhãn, mô hình học luôn cả bất thường.

2.2.4.2 Autoencoder tích chập (Conv-AE) và Variational Autoencoder (VAE)

Conv-AE thay LSTM bằng tích chập một chiều để nén cửa sổ. VAE thêm ràng buộc xác suất lên không gian tiềm ẩn, tối ưu cận dưới bằng chứng (ELBO) (Kingma & Welling [29]):

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}\left[\log p_\theta(\mathbf{x} \mid \mathbf{z})\right] - \beta\, D_{\text{KL}}\left(q_\phi(\mathbf{z} \mid \mathbf{x}) \,\|\, p(\mathbf{z})\right)$$

Handigol & Arjunan [7] đã huấn luyện 1D-CNN Autoencoder và Convolutional VAE trên LEAD.

Ưu điểm:

- **Nhẹ và huấn luyện nhanh:** Tích chập song song hoá tốt, phù hợp làm baseline tái tạo rẻ.
- **VAE có thành phần xác suất:** Giảm nguy cơ "học thuộc lòng" đầu vào và cho phép dùng điểm xác suất tái tạo.

Nhược điểm:

- **Cùng hạn chế sai số tái tạo như EncDec-AD:** Chất lượng phân tách phụ thuộc việc bất thường có làm tăng sai số tái tạo hay không.
- **Hiệu năng báo cáo thấp hơn mô hình sinh đối kháng:** Trong cùng so sánh trên LEAD, Orvati Nia et al. (2026) ghi nhận VAE đạt F1 0,62 và LSTM-AE đạt 0,60 ở mức cửa sổ, thấp hơn TAnoGAN (0,67) và GAN-LSTM (0,89).
- **VAE thêm siêu tham số β:** Cần cân bằng giữa chất lượng tái tạo và điều chuẩn không gian tiềm ẩn.

2.2.4.3 USAD (UnSupervised Anomaly Detection)

USAD dùng một bộ mã hoá chung và hai bộ giải mã D_1, D_2, huấn luyện đối kháng theo hai pha để vừa ổn định vừa khuếch đại sai số của đầu vào bất thường (Audibert et al. [23]). Với $AE_1 = D_1 \circ E$, $AE_2 = D_2 \circ E$ và n là chỉ số epoch hiện tại:

$$\mathcal{L}_{AE_1} = \frac{1}{n} \left\| \mathbf{W} - AE_1(\mathbf{W}) \right\|_2 + \left(1 - \frac{1}{n}\right) \left\| \mathbf{W} - AE_2\left(AE_1(\mathbf{W})\right) \right\|_2$$

$$\mathcal{L}_{AE_2} = \frac{1}{n} \left\| \mathbf{W} - AE_2(\mathbf{W}) \right\|_2 - \left(1 - \frac{1}{n}\right) \left\| \mathbf{W} - AE_2\left(AE_1(\mathbf{W})\right) \right\|_2$$

Điểm bất thường là tổ hợp tuyến tính $\alpha \left\| \mathbf{W} - AE_1(\mathbf{W}) \right\| + \beta \left\| \mathbf{W} - AE_2(AE_1(\mathbf{W})) \right\|$ với $\alpha + \beta = 1$.

Ưu điểm:

- **Huấn luyện nhanh và ổn định hơn GAN:** Chỉ gồm các mạng tự mã hoá, không cần tối ưu tiềm ẩn khi suy luận như các mô hình GAN dựa trên đảo ánh xạ.
- **Phù hợp dữ liệu lớn:** Thiết kế hướng đến yêu cầu về tốc độ huấn luyện và độ bền vững trong môi trường công nghiệp.

Nhược điểm:

- **Thiết kế cho chuỗi đa biến trong hệ thống IT/công nghiệp:** Chưa có đánh giá công bố trên dữ liệu năng lượng toà nhà mà nhóm biết, nên hiệu quả trên LEAD cần kiểm chứng.
- **Vẫn là hệ hình tái tạo không giám sát:** Chịu cùng rủi ro bỏ sót bất thường phẳng và không dùng nhãn.

2.2.5 Nhóm Mô hình sinh đối kháng (GAN-based)

2.2.5.1 AnoGAN, TAnoGAN và GAN-LSTM

Mạng sinh đối kháng (GAN) gồm bộ sinh G và bộ phân biệt D chơi trò chơi minimax. Sau khi huấn luyện trên dữ liệu bình thường, bộ sinh học được phân phối của hành vi bình thường:

$$\min_G \max_D \; \mathbb{E}_{\mathbf{x}} \left[\log D(\mathbf{x})\right] + \mathbb{E}_{\mathbf{z}} \left[\log\left(1 - D(G(\mathbf{z}))\right)\right]$$

Vì GAN không có bộ mã hoá, khi phát hiện bất thường phải tìm vector tiềm ẩn $\mathbf{z}^*$ tái tạo tốt nhất cửa sổ cần kiểm tra (Schlegl et al. [27], Bashar & Nayak [28]). Orvati Nia et al. [6] dùng:

$$\mathbf{z}^* = \arg\min_{\mathbf{z}} \; (1 - \lambda) \left\| \mathbf{x} - G(\mathbf{z}) \right\|_1 + \lambda \left\| f_D(\mathbf{x}) - f_D(G(\mathbf{z})) \right\|_1$$

với $f_D(\cdot)$ là đặc trưng trung gian của bộ phân biệt và $\lambda = 0{,}1$. Điểm bất thường $S(\mathbf{x})$ là giá trị hàm mục tiêu tại $\mathbf{z}^*$. GAN-LSTM thay các tầng của G và D bằng LSTM. Bộ sinh nhận vector tiềm ẩn 100 chiều qua ba tầng LSTM, bộ phân biệt dùng một tầng LSTM.

Trên dữ liệu năng lượng, các biến thể này đã được áp dụng trong ba nghiên cứu: Prabhu et al. [8] dùng 1D-DCGAN với hàm mất mát Soft-DTW và tái tạo song song, Handigol & Arjunan [7] khảo sát DCGAN trên 200 toà nhà, Orvati Nia et al. [6] áp dụng

GAN-LSTM với cửa sổ 60 giờ.

Ưu điểm:

- **Mô hình hoá phân phối của hành vi bình thường:** Không chỉ tái tạo mà còn học sinh ra chuỗi giống thật, nên bắt được lệch tinh tế hơn mô hình tái tạo thuần tuý theo báo cáo trên LEAD.
- **Điểm bất thường kết hợp sai số tái tạo và đặc trưng bộ phân biệt:** Hai tín hiệu bổ sung cho nhau.
- **Có kết quả công bố trực tiếp trên LEAD:** Thuận lợi cho phần đối chiếu và mở rộng của đề tài.

Nhược điểm:

- **Chi phí suy luận rất lớn:** Mỗi cửa sổ cần một vòng tối ưu vector tiềm ẩn. Orvati Nia et al. (2026) dùng 300 bước tối ưu mỗi cửa sổ, nên việc chấm điểm từng giờ trên 1,75 triệu bước là không thực tế, mà chỉ khả thi khi chấm điểm theo cửa sổ không chồng lấp.
- **Huấn luyện bất ổn định:** Cân bằng giữa G và D khó duy trì, kết quả nhạy với khởi tạo và siêu tham số (Orvati Nia et al. phải theo dõi độ chính xác của bộ phân biệt để kiểm tra ổn định).
- **Không dùng nhãn và chỉ dùng chuỗi đơn biến:** Các nghiên cứu trên LEAD huấn luyện chỉ trên cửa sổ bình thường và không đưa thời tiết hay đặc trưng toà nhà vào.
- **Kết quả không so sánh trực tiếp được:** F1 0,89 được tính ở mức cửa sổ 60 giờ (một cửa sổ bị coi là bất thường nếu có ít nhất một giờ bất thường), dễ hơn nhiều so với đánh giá theo từng giờ. Vì vậy con số này không thể đặt cạnh F1 theo từng điểm của các mô hình trong đề tài.

2.2.6 Nhóm Transformer

2.2.6.1 Transformer Encoder, Anomaly Transformer và TranAD

Transformer dùng cơ chế tự chú ý (self-attention) để mọi vị trí trong cửa sổ liên hệ trực tiếp với nhau [36]:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right)\mathbf{V}$$

Chi phí tính toán của một tầng chú ý là $\mathcal{O}(w^2 d)$ theo độ dài cửa sổ w. Trong bài toán phát hiện dị thường chuỗi thời gian, Anomaly Transformer [25] đề xuất tiêu chí *Association Discrepancy*: do bất thường hiếm nên khó xây dựng liên kết mạnh với toàn chuỗi và liên kết của nó tập trung vào các điểm lân cận, vì vậy sự khác biệt giữa liên kết tiên nghiệm và liên kết chuỗi được dùng để phân biệt bất thường. TranAD [26] sử dụng kiến trúc bộ mã hoá chú ý với cơ chế tự điều kiện hoá theo điểm tập trung (focus score), kết hợp huấn luyện đối kháng hai giai đoạn và học meta (MAML) để duy trì tính khái quát hoá tốt ngay cả khi lượng dữ liệu chuỗi có nhãn bị hạn chế.

Ưu điểm:

- **Mô hình hoá quan hệ xa không phụ thuộc khoảng cách:** Bất kỳ hai giờ nào trong cửa sổ cũng liên hệ trực tiếp, phù hợp chu kỳ ngày/tuần.
- **Song song hoá theo thời gian:** Không có phụ thuộc tuần tự như RNN.
- **Có kết quả mạnh trên các bộ chuẩn không giám sát:** Anomaly Transformer đạt kết quả tốt nhất trên sáu bộ chuẩn theo bài báo gốc. TranAD báo cáo tăng F1 tối đa 17% và giảm thời gian huấn luyện tối đa 99% so với các phương pháp đối sánh.

Nhược điểm:

- **Cần nhiều dữ liệu và dễ quá khớp:** Đề tài chỉ có 200 chuỗi toà nhà, với dung lượng mô hình lớn thì rủi ro quá khớp cao hơn mạng hồi quy hoặc tích chập nhỏ.
- **Chi phí bậc hai theo độ dài cửa sổ:** Với $w = 168$ vẫn chấp nhận được nhưng tăng nhanh khi muốn nhìn xa hơn.
- **Thiết kế và đánh giá cho chuỗi đa biến không giám sát:** Không tận dụng nhãn. Bài báo Anomaly Transformer (theo mã nguồn công bố) dùng quy tắc điều chỉnh kết quả theo đoạn (adjustment) khi đánh giá, vốn có thể làm điểm số cao hơn so với đánh giá theo từng điểm. Nhóm không áp dụng quy tắc này nên không thể so sánh trực tiếp con số của các bài báo đó.
- **Chưa có đánh giá trên dữ liệu năng lượng LEAD:** Hiệu quả cần kiểm chứng.

2.3 Các kỹ thuật bổ trợ hiện có để giải quyết bài toán

Trong bài toán phát hiện bất thường phụ tải điện, hiệu quả mô hình không chỉ phụ thuộc vào thuật toán mà còn chịu ảnh hưởng bởi cách biểu diễn dữ liệu. Hành vi tiêu thụ có thể khác nhau theo từng khu vực và loại công trình; bên cạnh đó, nhãn bất thường thường ít hơn nhiều so với nhãn bình thường, còn các biến động phụ tải lại gắn liền với diễn biến theo thời gian. Vì vậy, mục này giới thiệu một số kỹ thuật bổ trợ đã được nghiên cứu, gồm xây dựng đặc trưng theo bối cảnh, phân cụm phụ tải, điều chỉnh hàm mất mát và mô hình hóa chuỗi thời gian. Với mỗi kỹ thuật, phần này trình bày nguyên lý, điểm mạnh và những hạn chế cần cân nhắc khi áp dụng.

2.3.1 Kỹ thuật tương tác giữa địa điểm và công năng

Trong dữ liệu công trình, phụ tải có thể khác nhau theo vị trí địa lý, điều kiện thời tiết và công năng sử dụng của tòa nhà [5, 4]. Trong bộ dữ liệu ASHRAE GEPIII, `site_id` nhận diện địa điểm thu thập dữ liệu và có dữ liệu thời tiết tương ứng; đây không phải một phân loại vùng khí hậu ASHRAE. Vì vậy, khi xây dựng mô hình, có thể xem xét kết hợp thông tin địa điểm với `primary_use` để biểu diễn bối cảnh của từng nhóm công trình.

Một cách tạo đặc trưng tương tác là mã hóa mỗi cặp địa điểm $S \in \mathcal{S}$ và công năng $U \in \mathcal{U}$ thành một danh mục:

$$\texttt{zone_interaction} = \phi(S, U) \in \{0, 1, \ldots, |\mathcal{S} \times \mathcal{U}| - 1\}$$

Ngoài ra, có thể bổ sung diện tích sàn trung bình của các tòa nhà trong cùng địa điểm hoặc cùng nhóm công năng:

$$\bar{A}_S = \mathbb{E}_{\mathbf{x}\in\mathcal{D}_S}[\texttt{square_feet}], \qquad \bar{A}_U = \mathbb{E}_{\mathbf{x}\in\mathcal{D}_U}[\texttt{square_feet}]$$

Các thống kê diện tích cần được tính trên tập huấn luyện rồi mới áp dụng cho tập kiểm định và tập kiểm tra. Fu và cộng sự [2] nhấn mạnh vai trò của đặc trưng biểu diễn mức thay đổi phụ tải; Buaprakhong và cộng sự [3] khảo sát các đặc trưng thời gian, môi trường và biến đổi giá trị. Các kết quả này là cơ sở tham khảo chung, không chứng minh rằng riêng phép mã hóa cặp địa điểm–công năng luôn cải thiện khả năng tổng quát hóa.

Ưu điểm:

- **Biểu diễn sự khác biệt theo bối cảnh:** Có thể giúp mô hình phân biệt phụ tải của các nhóm công trình có vị trí hoặc công năng khác nhau.
- **Hỗ trợ mô hình hóa tương tác:** Đặc trưng kết hợp có thể giúp một số mô hình biểu diễn quan hệ giữa địa điểm và công năng trực tiếp hơn; hiệu quả phụ thuộc vào cách mã hóa và thuật toán.
- **Khả năng áp dụng cho công trình mới:** Đặc trưng dựa trên siêu dữ liệu có thể hữu ích khi dự đoán cho công trình chưa xuất hiện trong tập huấn luyện, nhưng không tự bảo đảm khả năng tổng quát hóa, nhất là khi địa điểm hoặc công năng mới chưa có trong dữ liệu.

Nhược điểm:

- **Làm tăng độ thưa của biến danh mục:** Phép nhân tổ hợp $\mathcal{S} \times \mathcal{U}$ tạo ra nhiều cặp giá trị có rất ít mẫu quan sát trong thực tế (ví dụ loại công năng hiếm tại một địa bàn nhỏ), dễ gây nhiễu cho mô hình nếu phân vùng dữ liệu không đồng đều.
- **Chỉ nắm bắt thông tin tĩnh:** Kỹ thuật này cung cấp bối cảnh địa lý và công năng ở mức vĩ mô nhưng không theo dõi được các dao động phụ tải vi mô ngắn hạn theo từng giờ của riêng công trình đó.

2.3.2 Chuẩn hóa phụ tải theo ngữ cảnh

Orvati Nia và cộng sự [6] chuẩn hóa phụ tải theo từng công trình trong thiết lập phát hiện bất thường của họ. Trong đề tài này, phụ tải được biểu diễn tương đối so với mức tiêu thụ quen thuộc của từng công trình để tạo bốn biến ngữ cảnh:

1. `z_meter_local`: độ lệch của phụ tải so với trung bình và độ lệch chuẩn của cùng công trình tại cùng giờ:

$$z_{\text{local}}(t) = \frac{x_t - \mu_{b,h}}{\sigma_{b,h}},$$

trong đó b là công trình, h là giờ trong ngày, còn $\mu_{b,h}$ và $\sigma_{b,h}$ được tính từ tập huấn luyện.

2. `z_meter_workday`: độ lệch phụ tải so với trung bình và độ lệch chuẩn của cùng công trình, cùng giờ và cùng nhóm ngày làm việc/ngày nghỉ:

$$z_{\text{workday}}(t) = \frac{x_t - \mu_{b,d,h}}{\sigma_{b,d,h}},$$

trong đó d phân biệt ngày làm việc với ngày nghỉ. Nếu nhóm tương ứng không có thống kê, quy trình dùng thống kê cùng giờ của công trình.

3. `z_meter_robust`: độ lệch phụ tải so với trung vị của công trình, chia cho khoảng tứ phân vị của công trình:

$$z_{\text{robust}}(t) = \frac{x_t - \text{median}_b}{\text{IQR}_b}.$$

4. `temp_load_inter`: tích giữa biến phụ tải đã chuẩn hóa theo nhóm ngày và nhiệt độ không khí:

$$\texttt{temp_load_inter}(t) = z_{\text{workday}}(t) \times \texttt{air_temperature}(t).$$

Các thống kê được tính từ dữ liệu huấn luyện rồi dùng để chuẩn hóa phụ tải; độ lệch chuẩn quá nhỏ được thay bằng giá trị dự phòng, khoảng tứ phân vị được chặn dưới ở mức 0,1, và ba biến chuẩn hóa được giới hạn trong đoạn $[-5, 10]$.

Ưu điểm:

- **So sánh phụ tải theo thói quen riêng:** Biểu diễn tương đối giúp nhận ra mức tiêu thụ khác thường của một công trình ngay cả khi giá trị tuyệt đối vẫn nằm trong khoảng phổ biến của toàn bộ dữ liệu.
- **Bổ sung bối cảnh thời gian và thời tiết:** Chuẩn hóa theo giờ, loại ngày và kết hợp với nhiệt độ cung cấp thêm ngữ cảnh để phân biệt các mức phụ tải có ý nghĩa khác nhau.

Nhược điểm:

- **Phụ thuộc chất lượng thống kê lịch sử:** Lịch sử quá ngắn hoặc chứa nhiều bất thường có thể làm sai lệch trung bình, độ lệch chuẩn, trung vị và khoảng tứ phân vị dùng để chuẩn hóa.
- **Khó áp dụng cho công trình mới:** Khi chưa có đủ dữ liệu huấn luyện của công trình, các thống kê riêng theo công trình chưa đáng tin cậy hoặc chưa thể tính.

2.3.3 Đặc trưng biến thiên phụ tải trong bộ dữ liệu Expanded

Trong lời giải quán quân LEAD, Fu và cộng sự [2] bổ sung đặc trưng biến thiên phụ tải dưới hai dạng: sai phân $X(t) - X(t-s)$ và tỉ số $(X(t)+1)/(X(t-s)+1)$, khảo sát các độ trễ từ 1 đến 168 bước thời gian. Nghiên cứu ghi nhận cả hai dạng đều hữu ích cho dự đoán. Theo hướng xử lý này, nhóm sử dụng sai phân và tỉ số tại độ trễ một và hai giờ, đồng thời bổ sung các biến trễ, bộ đếm đoạn phụ tải gần như không đổi và độ lệch so với chu kỳ ngày:

1. `meter_lag_1h` và `meter_lag_2h`: phụ tải ghi nhận trước đó một và hai giờ. Đây là các giá trị đầu vào để biểu diễn ngữ cảnh trễ:

$$\texttt{meter_lag_k}_t = m_{t-k}, \qquad k \in \{1, 2\}.$$

2. `meter_diff_1h` và `meter_diff_2h`: mức chênh lệch phụ tải hiện tại so với một và hai giờ trước:

$$\texttt{meter_diff_k}_t = m_t - m_{t-k}, \qquad k \in \{1, 2\}.$$

3. `meter_ratio_1h` và `meter_ratio_2h`: tỷ số giữa phụ tải hiện tại và phụ tải trễ, cộng thêm 1 ở tử và mẫu theo cách triển khai:

$$\texttt{meter_ratio_k}_t = \frac{m_t + 1}{m_{t-k} + 1}, \qquad k \in \{1, 2\}.$$

4. `flatline_duration`: số giờ liên tiếp phụ tải gần như không đổi; một bước được xem là không đổi khi $|m_t - m_{t-1}| \leq 10^{-4}$. Bộ đếm được khởi động lại khi điều kiện này không còn thỏa mãn hoặc khi gặp giá trị thiếu.

5. `stl_residual`: chênh lệch giữa phụ tải hiện tại và trung vị của phụ tải tại cùng giờ trong bảy ngày trước đó:

$$\texttt{stl_residual}_t = m_t - \text{median}\{m_{t-24d} \mid d = 1, \ldots, 7\}.$$

Fu và cộng sự cũng chỉ ra rằng sai phân bằng không có thể biểu thị bất thường dạng phụ tải phẳng; nhóm dùng ý tưởng này để tạo `flatline_duration` [2]. Riêng `stl_residual` là phần nhóm tự xây dựng: lấy phụ tải hiện tại trừ trung vị phụ tải tại cùng giờ trong bảy ngày trước đó. Tên biến được giữ theo mã nguồn, nhưng phép tính này không phải phân rã STL cổ điển. Các biến trễ được tính theo từng công trình và chỉ sử dụng phụ tải tại thời điểm hiện tại hoặc trước đó.

Ưu điểm:

- **Mô tả biến động ngắn hạn:** Các độ trễ, sai phân và tỉ số biểu diễn mức và chiều thay đổi phụ tải, hữu ích khi cần nhận diện bước nhảy hoặc sụt giảm đột ngột.
- **Nhận biết đoạn phụ tải phẳng và sai lệch theo ngày:** `flatline_duration` thể hiện thời gian kéo dài của các giá trị gần như không đổi; `stl_residual` thể hiện độ lệch so với phụ tải tại cùng giờ trong các ngày trước.

Nhược điểm:

- **Phụ thuộc tính liên tục của chuỗi:** Giá trị trễ không có sẵn ở đầu chuỗi hoặc sau khoảng thiếu; cách xử lý các giá trị này có thể ảnh hưởng đến tín hiệu của mô hình.
- **Nhạy với ngưỡng và mẫu số:** Ngưỡng cố định 10^{-4} của bộ đếm đoạn phẳng có thể không phù hợp với mọi thang đo, còn tỉ số có thể nhạy khi mẫu số gần bằng 0.
- **Cần đủ lịch sử cho đối chiếu chu kỳ:** Phần dư theo ngày kém tin cậy khi chưa có đủ các quan sát của cùng giờ trong bảy ngày trước.

2.3.4 Kỹ thuật phân cụm hành vi phụ tải

Kỹ thuật phân cụm nhóm các tòa nhà theo đặc trưng tiêu thụ thay vì chỉ dựa vào nhãn công năng. Một cách biểu diễn có thể dùng là véc-tơ $\mathbf{v}_i \in \mathbb{R}^D$, chẳng hạn véc-tơ 168 chiều gồm phụ tải trung bình theo từng giờ trong tuần; đây là ví dụ về biểu diễn, không phải khẳng định rằng mọi nghiên cứu đều dùng véc-tơ này. K-Means [16] là một thuật toán thường dùng, với hàm mục tiêu:

$$\mathcal{J} = \sum_{k=1}^{K} \sum_{\mathbf{v}_i \in \mathcal{C}_k} \|\mathbf{v}_i - \boldsymbol{\mu}_k\|_2^2$$

với $\boldsymbol{\mu}_k$ là véc-tơ trọng tâm của cụm $\mathcal{C}_k$. Cansever và Konyar [9] phân cụm các tòa nhà bằng K-Means dựa trên đặc trưng thống kê cấp công trình, sau đó đánh giá các mô hình phát hiện bất thường riêng theo cụm. Trong triển khai khác, mã cụm cũng có thể được dùng như một đặc trưng bổ trợ.

Ưu điểm:

- **Tách các nhóm hành vi khác nhau:** Có thể giúp mô hình hóa riêng các nhóm có hình thái phụ tải khác nhau, nếu các đặc trưng và số cụm được lựa chọn phù hợp.
- **Bổ sung cho nhãn công năng:** Phân cụm dựa trên dữ liệu tiêu thụ có thể phản ánh khác biệt vận hành giữa các công trình cùng loại công năng, nhưng kết quả phụ thuộc vào chất lượng dữ liệu và biểu diễn đầu vào.

Nhược điểm:

- **Nhạy cảm với việc chọn số cụm K:** Chất lượng phân cụm phụ thuộc lớn vào việc định cỡ tham số K và độ đo khoảng cách; khoảng cách Euclidean thông thường nhạy cảm với hiện tượng lệch pha thời gian.

2.3.5 Hàm mất mát entropy chéo nhị phân có trọng số

Nhằm xử lý sự mất cân bằng giữa số lượng quan trắc bình thường và bất thường, hàm mất mát entropy chéo nhị phân có trọng số gán hệ số phạt w_+ cao hơn cho các trường hợp phân loại sai lớp bất thường:

$$\mathcal{L}_{\text{WBCE}} = -\frac{1}{N} \sum_{i=1}^{N} \left[w_+ \, y_i \log \hat{p}_i + (1 - y_i) \log (1 - \hat{p}_i) \right]$$

với $\hat{p}_i$ là xác suất dự đoán và $y_i \in \{0, 1\}$. Với từng quan sát, đạo hàm theo logit z_i lần lượt là $\hat{p}_i$ khi $y_i = 0$ và $-w_+(1 - \hat{p}_i)$ khi $y_i = 1$; nếu xét hàm mất mát trung bình trên N quan sát thì các đạo hàm này có thêm hệ số $1/N$.

Ưu điểm:

- **Đơn giản và dễ tích hợp:** Chỉ cần một siêu tham số duy nhất w_+; các thư viện Học máy thường cung cấp tham số tương ứng như `scale_pos_weight` trong XGBoost [10], LightGBM [11], CatBoost [12], hoặc `pos_weight` trong các thư viện Học sâu.

- **Cải thiện khả năng phát hiện lớp bất thường:** Có thể hạn chế việc mô hình dự đoán gần như toàn bộ mẫu thuộc lớp đa số bình thường.

Nhược điểm:

- **Làm lệch xác suất dự đoán:** Đặt w_+ quá lớn có thể đẩy điểm số dự đoán về phía lớp bất thường, làm giảm độ tin cậy của xác suất và khiến cần điều chỉnh ngưỡng phân loại.
- **Tăng cảnh báo nhầm:** Trọng số phạt lớp bất thường quá cao có thể khiến mô hình gán nhầm nhiều biến động phụ tải bình thường thành bất thường, làm giảm độ chính xác của các dự đoán bất thường.

2.3.6 Hàm mất mát tập trung

Lin và cộng sự [37] đề xuất hàm mất mát tập trung cho bài toán phát hiện vật thể nhằm giảm ảnh hưởng của các mẫu dễ trong dữ liệu mất cân bằng. Hàm này bổ sung một thừa số suy giảm động $(1 - p_t)^\gamma$ vào hàm mất mát entropy chéo:

$$\mathrm{FL}(p_t) = -\alpha_t \left(1 - p_t\right)^\gamma \log\left(p_t\right)$$

trong đó p_t là xác suất mô hình gán cho lớp đúng, α_t là hệ số cân bằng lớp và $\gamma \geq 0$ điều khiển mức độ tập trung vào các mẫu khó. Có thể thử áp dụng hàm mất mát này cho dữ liệu dị thường mất cân bằng, nhưng hiệu quả cần được kiểm chứng trên tập kiểm định của bài toán cụ thể.

Ưu điểm:

- **Giảm ảnh hưởng của mẫu dễ:** Khi một mẫu bình thường được phân loại đúng với độ tin cậy cao ($p_t \to 1$), thành phần $(1-p_t)^\gamma$ giảm dần về 0, hạn chế ảnh hưởng áp đảo của số lượng lớn mẫu bình thường trong quá trình học.
- **Tập trung vào các trường hợp biên khó:** Mô hình tự động hướng năng lực tối ưu vào các mẫu có độ mơ hồ cao hoặc nằm sát ranh giới quyết định giữa bình thường và bất thường.

Nhược điểm:

- **Thêm siêu tham số cần tinh chỉnh:** Cần lựa chọn các tham số (α, γ), làm tăng không gian tìm kiếm siêu tham số.
- **Khó diễn giải xác suất đầu ra:** Điểm số dự đoán có thể khó được diễn giải trực tiếp như xác suất thực nếu chưa qua bước hiệu chuẩn.

2.3.7 Mạng tích chập thời gian kết hợp bộ tự mã hóa TCN

TCN-AE là một cách kết hợp bộ mã hóa-giải mã với mạng tích chập thời gian TCN. TCN sử dụng các phép tích chập nhân quả và giãn cách để mở rộng vùng tiếp nhận theo thời gian [24]; nút thắt cổ chai là một lựa chọn thiết kế của autoencoder, không phải thành phần bắt buộc của mọi TCN. Điểm dị thường có thể được xác định bằng sai số

tái tạo, như cách tiếp cận CNN autoencoder được khảo sát cùng các mô hình GAN trong công trình của Handigol và Arjunan [7]; công trình này không trực tiếp đánh giá kiến trúc TCN-AE.

Ưu điểm:

- **Huấn luyện song song vượt trội:** Không bị ràng buộc tính toán tuần tự theo từng bước thời gian như LSTM/GRU, tận dụng tối đa kiến trúc xử lý song song của GPU.
- **Vùng tiếp nhận mở rộng linh hoạt:** Một lịch giãn cách thường dùng là $d = 2^l$; lựa chọn này mở rộng vùng tiếp nhận mà không cần tăng tương ứng kích thước bộ lọc, nhưng không tự bảo đảm kiểm soát đạo hàm.
- **Trích xuất mẫu cục bộ:** Các bộ lọc tích chập có thể học đặc trưng cục bộ như bước nhảy tải hoặc đoạn giá trị không đổi; hiệu quả phụ thuộc vào kiến trúc và dữ liệu huấn luyện.

Nhược điểm:

- **Nguy cơ tái tạo cả dữ liệu bất thường:** Nếu nút thắt cổ chai không đủ hẹp hoặc mô hình quá mạnh, bộ tự mã hóa có thể học cách tái tạo cả những đoạn dữ liệu bất thường.
- **Yêu cầu bộ nhớ GPU cao khi chuỗi dài:** Các phép toán tích chập nhiều kênh trên kích thước batch lớn đòi hỏi dung lượng VRAM đáng kể.

2.3.8 Cơ chế tự chú ý trong mô hình chuỗi

Cơ chế tự chú ý trong Transformer [36] tính toán mức độ liên hệ giữa các vị trí trong chuỗi thông qua các phép chiếu truy vấn, khóa và giá trị. Biểu thức dưới đây mô tả phép chú ý tích vô hướng có co giãn cho một đầu chú ý; cơ chế chú ý đa đầu kết hợp nhiều đầu như vậy. Đây là cơ chế tổng quát có thể được xem xét cho dữ liệu chuỗi, không phải mô tả kiến trúc GAN-LSTM của Orvati Nia và cộng sự hay cơ chế chú ý trên đồ thị của Zhang và cộng sự:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right)\mathbf{V}$$

Ưu điểm:

- **Mô hình hóa quan hệ giữa các thời điểm:** Cơ chế chú ý cho phép tính tương tác trực tiếp giữa các vị trí trong cửa sổ, kể cả khi chúng cách xa nhau; hiệu quả thực tế còn phụ thuộc vào biểu diễn và cách huấn luyện mô hình.
- **Cung cấp thông tin về trọng số chú ý:** Ma trận chú ý thể hiện các trọng số được tính trong mô hình, nhưng không nên mặc nhiên xem các trọng số này là lời giải thích đầy đủ hoặc có tính nhân quả cho dự đoán.

Nhược điểm:

- **Độ phức tạp tính toán bậc hai:** Chi phí tính toán và bộ nhớ tăng theo hàm bậc hai $O(w^2)$ theo chiều dài cửa sổ trượt w, gây trở ngại khi cần mở rộng cửa sổ ngữ cảnh rất dài.

- **Dễ quá khớp trên dữ liệu ít đa dạng:** Mạng chú ý đòi hỏi lượng dữ liệu chuỗi phong phú để học ma trận tương quan ổn định, dễ bị quá khớp nếu số lượng công trình huấn luyện hạn chế.

2.3.9 Hàm mất mát căn chỉnh thời gian mềm khả vi Soft-DTW

Soft-DTW [31] là phiên bản làm trơn, có thể lấy đạo hàm của phép căn chỉnh thời gian động. Trong bài toán phát hiện bất thường chuỗi năng lượng, Prabhu và cộng sự [8] sử dụng Soft-DTW làm hàm mất mát tái tạo cho DCGAN 1D và báo cáo kết quả tốt hơn khoảng cách Euclid trong thiết lập thí nghiệm của họ; kết quả đó không đồng nghĩa Soft-DTW luôn thay thế sai số bình phương trung bình hiệu quả hơn trên mọi dữ liệu:

$$\text{Soft-DTW}_\gamma(\mathbf{x}, \hat{\mathbf{x}}) = \text{soft-min}_\gamma \left(\{ \langle \mathbf{A}_\pi, \boldsymbol{\Delta}(\mathbf{x}, \hat{\mathbf{x}}) \rangle \}_{\pi \in \mathcal{A}} \right)$$

với $\boldsymbol{\Delta}$ là ma trận khoảng cách giữa các điểm, $\mathcal{A}$ là tập đường căn chỉnh và $\text{soft-min}_\gamma(a) = -\gamma \log \sum \exp(-a_i/\gamma)$ là phép lấy cực tiểu mềm có thể tính đạo hàm.

Ưu điểm:

- **Dung nạp một số sai lệch căn chỉnh thời gian:** Phép căn chỉnh đàn hồi có thể giảm mức phạt đối với các chuỗi có hình dạng tương tự nhưng lệch pha; cần giới hạn căn chỉnh phù hợp để không bỏ qua độ trễ mang ý nghĩa bất thường.
- **Có thể tính đạo hàm:** Phiên bản làm trơn cho phép tính đạo hàm và dùng làm hàm mất mát trong quá trình tối ưu mô hình.

Nhược điểm:

- **Chi phí tính toán lớn:** Thuật toán quy hoạch động có độ phức tạp thời gian và không gian là $O(w^2)$, khiến tốc độ huấn luyện trên tập dữ liệu hàng triệu bước thời gian chậm hơn nhiều lần so với sai số bình phương trung bình thông thường.
- **Nguy cơ bỏ sót bất thường độ trễ:** Nếu bài toán thực tế yêu cầu phát hiện sự cố chậm giờ bật tải, cơ chế co dãn của Soft-DTW có thể vô tình xem sự chậm trễ này là hành vi bình thường.

2.3.10 Mô hình chuỗi có điều kiện theo siêu dữ liệu

Một hướng mô hình hóa có điều kiện là kết hợp siêu dữ liệu tĩnh của công trình (chẳng hạn địa điểm, công năng hoặc nhãn cụm) với biểu diễn chuỗi. Với biến danh mục Z, có thể ánh xạ thành véc-tơ nhúng $\mathbf{e} = \mathbf{E}[Z] \in \mathbb{R}^d$ rồi điều biến biểu diễn ẩn bằng FiLM [32]:

$$\mathbf{h}'_t = \boldsymbol{\gamma}(\mathbf{e}) \odot \mathbf{h}_t + \boldsymbol{\beta}(\mathbf{e})$$

trong đó $\mathbf{h}_t$ là trạng thái biểu diễn chuỗi và $\boldsymbol{\gamma}, \boldsymbol{\beta}$ là các mạng chiếu tuyến tính điều biến độ lợi và độ lệch.

Ưu điểm:

- **Biểu diễn có điều kiện theo siêu dữ liệu:** Có thể giúp mạng điều chỉnh biểu diễn chuỗi theo thông tin công trình; cơ chế này không tự động xác định ngưỡng phân loại.
- **Học biểu diễn nhúng:** Véc-tơ nhúng được học trong quá trình huấn luyện, nhưng không bảo đảm rằng khoảng cách giữa các véc-tơ phản ánh đúng mức độ tương đồng ngữ nghĩa của các địa điểm.

Nhược điểm:

- **Tăng số lượng tham số mô hình:** Thêm các bảng tra cứu nhúng và mạng điều biến FiLM làm tăng số lượng tham số; cần dùng các biện pháp điều chuẩn như bỏ ngẫu nhiên kết nối hoặc suy giảm trọng số để hạn chế ghi nhớ dữ liệu huấn luyện.
- **Phụ thuộc vào siêu dữ liệu:** Cần có các trường ngữ cảnh được dùng khi huấn luyện tại thời điểm suy luận; thiếu hoặc gặp giá trị danh mục mới có thể làm giảm chất lượng dự đoán.

2.3.11 Mô hình sinh đối kháng kết hợp mạng LSTM

Orvati Nia và cộng sự [6] đánh giá một mô hình GAN-LSTM trên các cửa sổ phụ tải LEAD dài 60 giờ, huấn luyện bằng các cửa sổ bình thường và so sánh với các phương pháp đối chứng. Ở mức khái quát, cấu trúc GAN gồm:

- **Mạng tạo sinh** G**:** Sử dụng các tầng tế bào nhớ LSTM để ánh xạ từ không gian véc-tơ tiềm ẩn $\mathbf{z} \sim p_z$ thành một cửa sổ phụ tải điện nhân tạo $\hat{\mathbf{x}} = G(\mathbf{z}) \in \mathbb{R}^W$.
- **Mạng phân biệt** D**:** Nhận một cửa sổ chuỗi phụ tải thực tế $\mathbf{x}$ hoặc chuỗi do mạng tạo sinh tạo ra $\hat{\mathbf{x}}$, rồi dùng các tầng LSTM kết hợp tầng tuyến tính để ước lượng xác suất chuỗi thuộc phân phối dữ liệu chuẩn $D(\mathbf{x}) \in [0, 1]$.

Với dạng GAN chuẩn, mục tiêu cực tiểu–cực đại có thể viết như sau:

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}}[\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z}[\log(1 - D(G(\mathbf{z})))]$$

Trong thiết lập của Orvati Nia và cộng sự, mô hình chỉ được huấn luyện trên các cửa sổ bình thường. Khi suy luận, điểm bất thường ở mức cửa sổ kết hợp sai số tái tạo với sai khác giữa các đặc trưng ẩn của mạng phân biệt:

$$\mathcal{S}(\mathbf{x}) = \lambda \, \mathcal{L}_{\text{rec}}(\mathbf{x}, G(\mathbf{z}^*)) + (1 - \lambda) \, \mathcal{L}_{\text{feat}}(f_D(\mathbf{x}), f_D(G(\mathbf{z}^*)))$$

trong đó $\mathbf{z}^*$ là véc-tơ tiềm ẩn được tìm bằng tối ưu hóa tại thời điểm suy luận, f_D là biểu diễn trung gian của mạng phân biệt, còn $\mathcal{L}_{\text{rec}}$ và $\mathcal{L}_{\text{feat}}$ lần lượt là các thành phần sai số tái tạo và sai khác đặc trưng. Nghiên cứu này đánh giá ở mức cửa sổ; không nên diễn giải điểm số đó thành nhãn bất thường cho từng giờ nếu chưa có bước ánh xạ riêng.

Ưu điểm:

- **Học biểu diễn phụ tải bình thường không cần nhãn:** Tận dụng tối đa lượng lớn dữ liệu vận hành chuẩn, không phụ thuộc vào nhãn bất thường vốn rất khan hiếm trong thực tế.

- **Nắm bắt quan hệ động học đa bước:** Cơ chế cổng nhớ của LSTM duy trì tính liên tục và hình thái tuần hoàn của chuỗi phụ tải trong suốt chiều dài cửa sổ.
- **Đánh giá theo ngữ cảnh nhiều giờ:** Điểm số cửa sổ sử dụng thông tin của nhiều thời điểm, nhưng việc gộp nhãn theo cửa sổ có thể làm giảm khả năng xác định chính xác thời điểm bắt đầu của bất thường.

Nhược điểm:

- **Khó khăn trong cân bằng đối kháng:** Dễ gặp hiện tượng suy giảm đa dạng đầu ra hoặc mất cân bằng đạo hàm cập nhật giữa mạng tạo sinh và mạng phân biệt trong quá trình tối ưu.
- **Độ trễ và suy giảm phân giải thời gian:** Đánh giá bất thường theo cửa sổ chỉ phát hiện được khoảng thời gian xảy ra biến cố, khó định vị chính xác thời điểm giờ bắt đầu nếu không kết hợp thêm cơ chế phân giải ngược.
- **Chi phí suy luận trượt cửa sổ cao:** Việc trượt cửa sổ liên tục qua chuỗi dữ liệu dài ngày đòi hỏi chi phí tính toán đáng kể.

2.3.12 Mạng sinh đối kháng tích chập sâu một chiều

Handigol và Arjunan [7] khảo sát DCGAN một chiều cho phát hiện bất thường trên chuỗi năng lượng, đồng thời so sánh với mạng tích chập tự mã hóa và mạng tự mã hóa biến phân tích chập. Ở mức khái quát, DCGAN dùng các mạng tích chập một chiều để xử lý cửa sổ chuỗi:

- **Mạng tạo sinh:** Tạo chuỗi phụ tải từ biểu diễn tiềm ẩn.
- **Mạng phân biệt:** Phân biệt chuỗi thực với chuỗi được tạo ra trong quá trình huấn luyện đối kháng.

Trong thiết lập được báo cáo, điểm bất thường dựa trên sai số tái tạo:

$$\mathcal{S}(\mathbf{x}) = \mathcal{L}_{\text{rec}}(\mathbf{x}, \hat{\mathbf{x}})$$

trong đó $\hat{\mathbf{x}}$ là chuỗi tái tạo. Không nên đồng nhất điểm số này với cơ chế so khớp đặc trưng của mạng phân biệt nếu không chỉ rõ đó là một biến thể khác.

Ưu điểm:

- **Khả năng song song hóa cao:** Các phép toán tích chập 1D không có phụ thuộc tuần hoàn theo thời gian, tận dụng tối đa năng lực xử lý song song của GPU, tăng tốc độ huấn luyện so với mô hình hồi quy.
- **Nhạy với hình thái sóng phụ tải:** Các bộ lọc tích chập cục bộ có thể nhận diện các dạng bất thường như gai tải đột ngột, méo đỉnh phụ tải hoặc đoạn giá trị không đổi.
- **Trích xuất đặc trưng nhiều quy mô:** Các tầng tích chập có vùng tiếp nhận tăng dần giúp nắm bắt đồng thời dao động vi mô lẫn chu kỳ ngày/tuần.

Nhược điểm:

- **Hiện tượng tạo mẫu tuần hoàn giả:** Nếu kiến trúc dùng tích chập chuyển vị, việc lựa chọn kích thước bộ lọc và bước nhảy không phù hợp có thể tạo ra cấu trúc giả trong chuỗi sinh.
- **Hạn chế trong duy trì phụ thuộc xa:** Trường tiếp nhận phụ thuộc trực tiếp vào số tầng tích chập; việc mở rộng vùng quan sát đòi hỏi tăng mạnh độ sâu mạng, làm tăng kích thước tham số.

2.3.13 Kỹ thuật tái tạo song song nhiều điểm

Trong AnoGAN [27] và cách tiếp cận của Prabhu và cộng sự [8], giai đoạn suy luận tìm véc-tơ tiềm ẩn sao cho đầu ra của mạng tạo sinh tái tạo gần với chuỗi quan sát:

$$\mathbf{z}^* = \arg\min_{\mathbf{z}} \mathcal{L}_{\text{rec}}(\mathbf{x}, G(\mathbf{z}))$$

Việc tối ưu lặp này có thể tốn thời gian nếu xử lý từng cửa sổ riêng lẻ.

Prabhu và cộng sự [8] tăng tốc bằng cách thực hiện song song việc tái tạo nhiều điểm hoặc cửa sổ trong quá trình tối ưu. Phương pháp này vẫn cập nhật véc-tơ tiềm ẩn bằng đạo hàm; bài báo không thay thế bước đó bằng một mạng ánh xạ E và không loại bỏ hoàn toàn các vòng lặp tối ưu hóa tại thời điểm suy luận. Điểm bất thường kết hợp sai số tái tạo với thông tin từ phân phối tiên nghiệm của không gian tiềm ẩn.

Ưu điểm:

- **Tăng thông lượng xử lý:** Tối ưu nhiều điểm hoặc cửa sổ theo lô có thể tận dụng tính toán song song trên GPU và giảm chi phí xử lý tuần tự.
- **Giữ bước tối ưu hóa tiềm ẩn:** Phương pháp vẫn thực hiện tối ưu hóa tại thời điểm suy luận; mức tăng tốc phụ thuộc kích thước lô, phần cứng và số bước tối ưu.

Nhược điểm:

- **Vẫn tốn chi phí tối ưu hóa:** Tối ưu nhiều cửa sổ đồng thời vẫn cần lặp cập nhật đạo hàm và có thể tiêu tốn nhiều bộ nhớ GPU.
- **Phụ thuộc vào chất lượng tái tạo:** Điểm số vẫn bị ảnh hưởng bởi khả năng biểu diễn của mạng tạo sinh và cách thiết lập hàm mất mát.

Các hướng tiếp cận trên cho thấy có thể bổ sung thông tin cho mô hình từ bối cảnh công trình, hình thái phụ tải, mức mất cân bằng giữa các lớp và diễn biến theo thời gian. Việc lựa chọn kỹ thuật cần cân nhắc mục tiêu phát hiện, đặc điểm dữ liệu và giới hạn của từng cách làm.

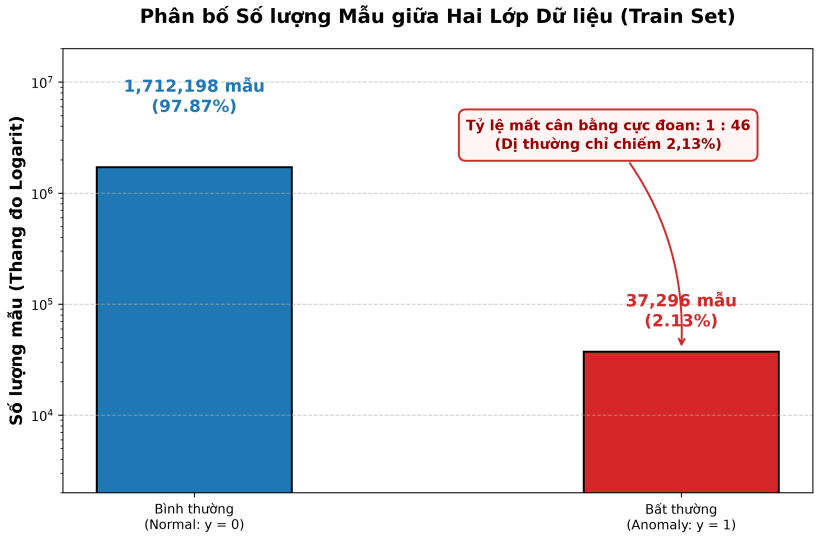
3 Tiền xử lý và Khám phá Dữ liệu

Dựa trên tệp `train_features.csv` đã giới thiệu ở Chương 1, chương này trình bày khám phá dữ liệu EDA ban đầu, sau đó là quy trình tiền xử lý và cuối cùng là khám phá và kiểm toán dữ liệu sau khi đã tiền xử lý.

3.1 Khám phá Dữ liệu Ban đầu

3.1.1 Phân tích sự Mất cân bằng Lớp Dữ liệu

Dữ liệu nhãn bất thường phản ánh trạng thái hoạt động của hệ thống phụ tải điện: $y = 0$ tương ứng với trạng thái bình thường và $y = 1$ tương ứng với trạng thái bất thường. Trong 1.749.494 bản ghi của `train_features.csv`, có 1.712.198 bản ghi bình thường (97,87%) và 37.296 bản ghi bất thường (2,13%), tương đương khoảng một mẫu bất thường trên 46 mẫu.

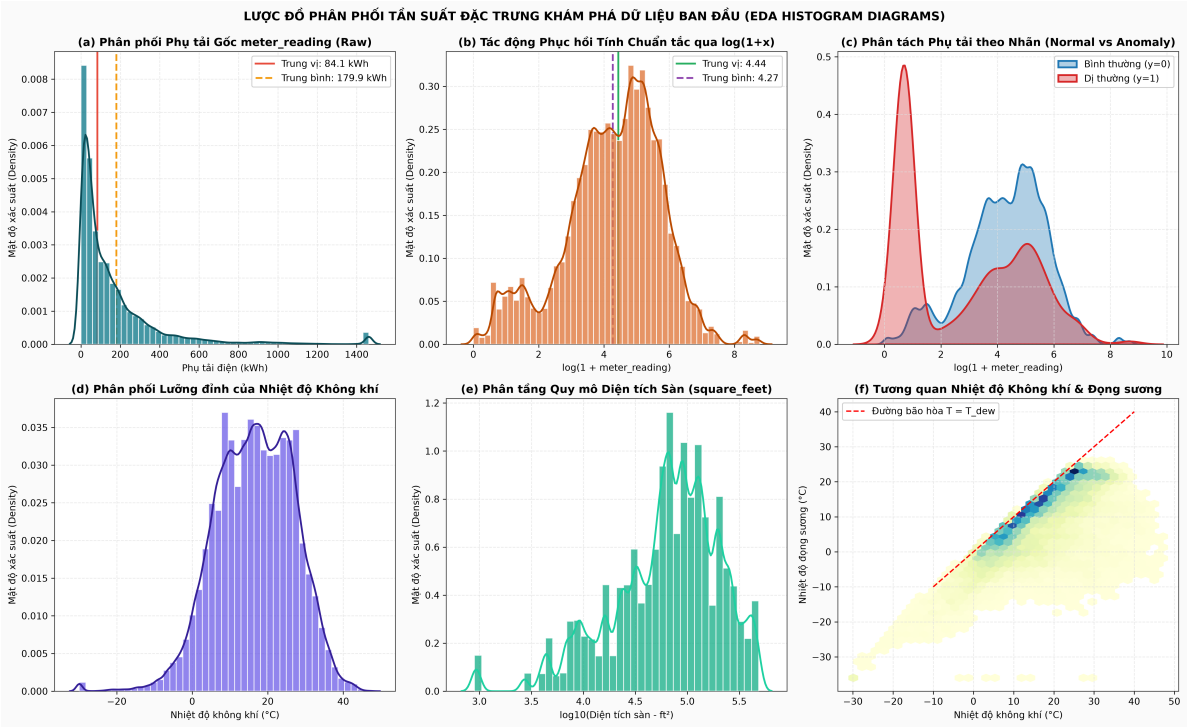


Hình 1: Phân phối mức độ mất cân bằng giữa nhãn bình thường và bất thường

Với tỷ lệ lớp xấp xỉ 1 : 46, bộ dự đoán luôn chọn lớp bình thường vẫn đạt Accuracy khoảng 97,87% trong khi bỏ sót toàn bộ mẫu bất thường. Vì vậy, PR-AUC phù hợp làm thước đo chính, Precision, Recall và F1-Score bổ sung góc nhìn về hiệu quả phát hiện tại ngưỡng phân loại.

3.1.2 Phân tích Phân phối Tần suất Đặc trưng

Bên cạnh phân bố nhãn, Hình 2 minh họa phân phối của một số thuộc tính đầu vào và phụ tải theo nhãn trên mẫu ngẫu nhiên tối đa 300.000 bản ghi.



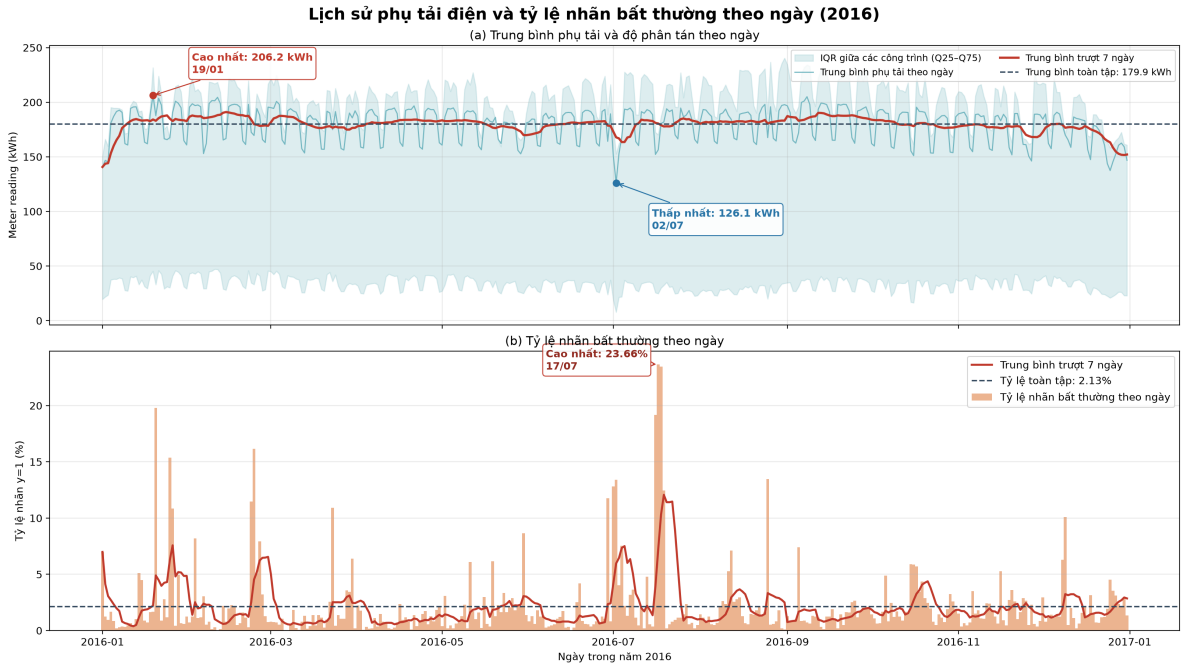
Hình 2: Lược đồ Phân phối Tần suất Đặc trưng Khám phá Dữ liệu Ban đầu

Phân phối `meter_reading` lệch phải rõ rệt: trên các quan sát không khuyết, trung bình là 179,90 kWh, cao hơn trung vị 84,10 kWh, giá trị lớn nhất đạt 6.596,89 kWh và độ lệch là +9,15. Hình dùng $\ln(1+x)$ và giới hạn trục đến phân vị 99 để thể hiện rõ phần lớn quan sát. Theo nhãn, lớp bất thường tập trung nhiều hơn ở vùng phụ tải thấp. Hai phân phối vẫn chồng lấn đáng kể, nên phụ tải tức thời riêng lẻ chưa tách biệt rõ hai lớp.

Các thuộc tính khác cũng có độ phân tán đáng kể: nhiệt độ không khí có các vùng mật độ cao khoảng 8–12°C và 24–28°C, diện tích công trình trải rộng trên nhiều bậc độ lớn ngay cả khi biểu diễn theo thang $\log_{10}$. Nhiệt độ không khí và điểm sương biến thiên cùng chiều. Các quan sát này cho thấy quy mô công trình và điều kiện môi trường là những bối cảnh cần xét cùng phụ tải.

3.1.3 Toàn cảnh Lịch sử Phụ tải và Phân bố Dị thường theo Thời gian

Nhằm nắm bắt toàn diện hành vi phụ tải ở cấp độ vĩ mô và sự phân bố của các biến cố dị thường xuyên suốt 366 ngày trong năm 2016, nhóm nghiên cứu xây dựng lược đồ lịch sử vận hành trên toàn bộ 200 tòa nhà thuộc tập huấn luyện (Hình 3).

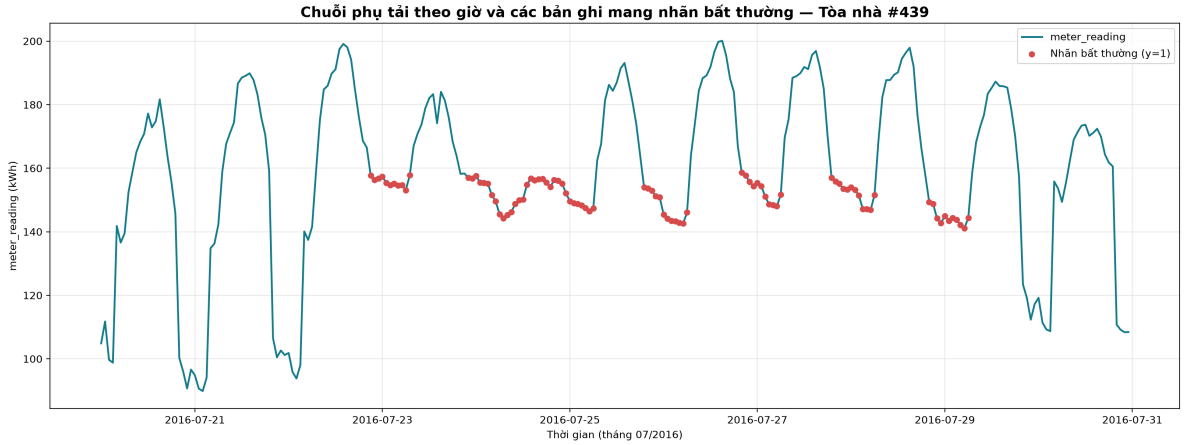


Hình 3: Lược đồ Lịch sử Phụ tải Điện và Tỷ lệ Dị thường theo Ngày trong năm 2016

Hình 3 cho thấy trung bình phụ tải theo ngày thay đổi trong năm: đạt 206,2 kWh vào 19/01 và giảm còn 126,1 kWh vào 02/07, đường MA-7 làm rõ xu hướng ngắn hạn, còn dải IQR phản ánh khác biệt giữa các công trình. Tỷ lệ bất thường toàn tập là 2,13% và biến động theo ngày, đạt đỉnh 23,66% vào 17/07, một số ngày có tỷ lệ cao xuất hiện gần nhau. Các biến động này cho thấy dữ liệu có cấu trúc thời gian, do đó việc chia tập cần giữ trật tự thời gian.

3.1.4 Quan sát Nhãn Bất thường trên Chuỗi Thời gian

Hình 4 minh họa phụ tải theo giờ và các bản ghi mang nhãn bất thường tại Tòa nhà #439 trong tháng 7/2016.



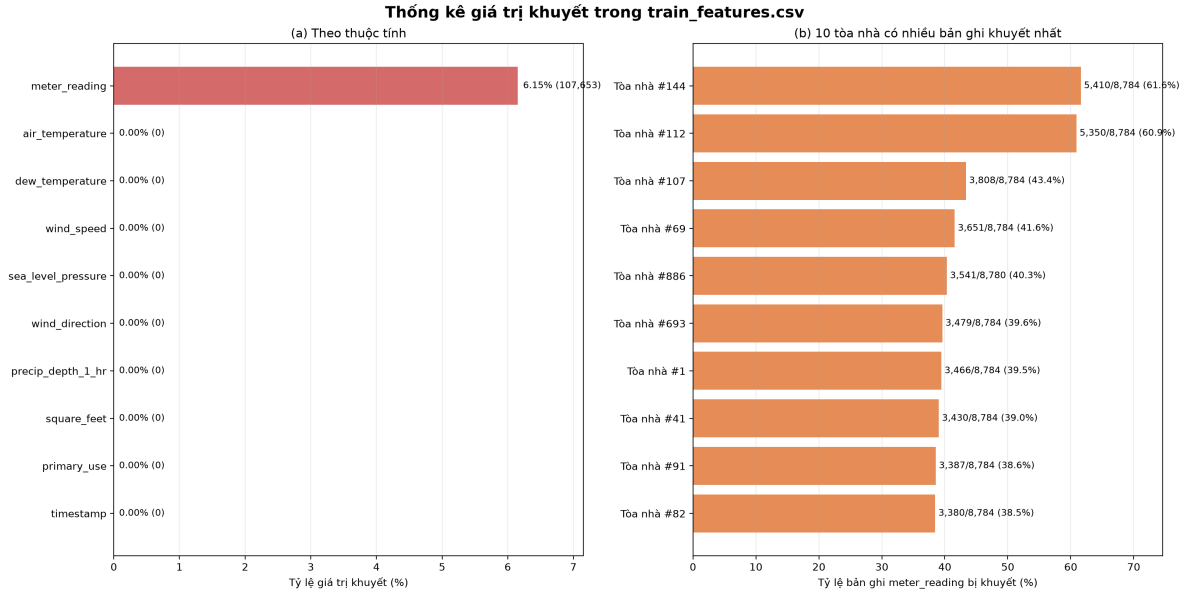
Hình 4: Chuỗi thời gian phụ tải điện theo giờ và các bản ghi mang nhãn bất thường tại Tòa nhà #439

Trong cửa sổ minh họa, phụ tải dao động theo ngày và các nhãn $y = 1$ tập trung thành

một số đoạn liên tiếp. Chuỗi này cho thấy các biến động phụ tải và nhãn bất thường có thể được khảo sát theo diễn tiến thời gian trong từng công trình.

3.1.5 Tình trạng Thiếu Dữ liệu

Bên cạnh mất cân bằng nhãn, dữ liệu có các giá trị phụ tải bị khuyết. Hình 5 tổng hợp tỷ lệ khuyết theo thuộc tính và số bản ghi phụ tải khuyết tại một số công trình trong tập huấn luyện (`train_features.csv`, 1.749.494 bản ghi).



Hình 5: Thống kê giá trị khuyết trên tập huấn luyện: tỷ lệ khuyết theo thuộc tính (trái) và 10 tòa nhà có nhiều bản ghi phụ tải khuyết nhất (phải)

Trong các thuộc tính được khảo sát, giá trị khuyết tập trung ở `meter_reading`: có 107.653 dòng (6,15%), các thuộc tính thời tiết và công trình trong hình không có giá trị khuyết. Mức thiếu tập trung rõ ở một số công trình: tòa nhà #144 có 5.410/8.784 dòng bị khuyết (61,6%), tòa nhà #112 có 5.350/8.784 (60,9%). Vì vậy, pipeline giữ cờ ghi nhận vị trí thiếu trước khi điền giá trị.

3.2 Quy trình Tiền xử lý Dữ liệu

Pipeline tạo bốn bộ dữ liệu trên cùng các mẫu và cách chia tập: Baseline gồm 39 đặc trưng, Zone-Enhanced bổ sung 3 đặc trưng khu vực, Context-Aware bổ sung 4 đặc trưng ngữ cảnh, Expanded Champion bổ sung 8 đặc trưng chuỗi thời gian và STL.

Quy trình tiền xử lý bắt đầu bằng việc chia dữ liệu theo thời gian, sau đó chỉ học các tham số biến đổi trên tập huấn luyện.

Quy trình xuất bốn bộ dữ liệu tăng tiến:

1. **Baseline:** 39 đặc trưng nền, 40 cột tính cả nhãn.
2. **Zone-Enhanced:** Kế thừa Baseline và bổ sung 3 đặc trưng khu vực, tổng cộng 42 đặc trưng.
3. **Context-Aware:** Kế thừa Zone-Enhanced và bổ sung 4 đặc trưng ngữ cảnh, tổng cộng 46 đặc trưng.

4. **Expanded Champion:** Kế thừa Context-Aware và bổ sung 8 đặc trưng chuỗi thời gian, tổng cộng 54 đặc trưng.

Các bộ dữ liệu lần lượt bổ sung đặc trưng khu vực, ngữ cảnh và chuỗi thời gian để phục vụ đối chiếu thực nghiệm.

3.2.1 Giao thức Phân chia Chuỗi Thời gian Chu kỳ Mùa vụ và 96 Giờ Cách ly

Để hạn chế rò rỉ thông tin trong chuỗi thời gian, dữ liệu được chia theo ngày trong tháng và chừa khoảng cách ly 96 giờ. Các biến trễ khí tượng dài hạn như `air_temperature_*_lag73` được tính đến khi thiết kế khoảng cách này:

- **Tập huấn luyện (T_{in}):** Gồm ngày 01–20 hàng tháng (1.147.089 bản ghi, ≈ 65,6%). Các thống kê và bảng tra cứu chỉ được tính trên tập này.
- **Khoảng cách ly (T_{gap}):** Gồm ngày 21–24 (229.412 bản ghi, ≈ 13,1%) và được loại khỏi thực nghiệm.
- **Tập kiểm định (T_{out}):** Gồm ngày 25 đến cuối tháng (372.993 bản ghi, ≈ 21,3%). Tập này chỉ áp dụng các phép biến đổi đã khớp trên tập huấn luyện.

Chi tiết các bước biến đổi đặc trưng được triển khai tuần tự như sau:

1. **Bước 1:** Tách nhãn mục tiêu và định danh ra khỏi ma trận đặc trưng. Vector nhãn $y_{\text{train}} = \texttt{anomaly}$ được tách riêng và đặt chỉ mục liên tục để phục vụ huấn luyện có giám sát, được loại bỏ khỏi ma trận đặc trưng X_{train}, bảo đảm mô hình không bị rò rỉ nhãn.

2. **Bước 2:** Chuẩn hóa thời gian và mã hóa chu kỳ sin / cos. Trường thời gian `timestamp` được ép kiểu sang định dạng `datetime64[ns]` chuẩn. Do thời gian có tính chu kỳ tuần hoàn khép kín, việc sử dụng giá trị số nguyên đơn thuần sẽ làm mất tính liên tục không gian. Do đó, các thành phần thời gian được mã hóa lượng giác trực tiếp:

$$x_{\sin} = \sin\left(\frac{2\pi t}{T}\right), \quad x_{\cos} = \cos\left(\frac{2\pi t}{T}\right)$$

   trong đó chu kỳ $T = 24$ cho giờ trong ngày (`hour_sin`, `hour_cos`), $T = 7$ cho ngày trong tuần (`weekday_sin`, `weekday_cos`), và $T = 12$ cho tháng trong năm (`month_sin`, `month_cos`). Sau khi sinh các biến lượng giác, các cột thời gian gốc (`hour`, `weekday`, `month`) và các tọa độ thời gian cũ được loại bỏ hoàn toàn để tránh hiện tượng đa cộng tuyến.

3. **Bước 3:** Chuẩn hóa lược đồ, phân loại kiểu dữ liệu, tạo cờ khuyết và loại bỏ đặc trưng không phù hợp.

   - **Tạo cờ missing:** Trước khi điền khuyết, nhóm khởi tạo biến cờ nhị phân:

$$\texttt{meter_reading_was_missing} = \begin{cases} 1, & \text{nếu } \texttt{meter_reading} \text{ bị thiếu} \\ 0, & \text{ngược lại} \end{cases}$$

     Biến cờ này lưu giữ tín hiệu quan trọng về sự gián đoạn kết nối IoT của đồng hồ đo.

- **Chuẩn hóa lược đồ và phân nhóm kiểu dữ liệu:** Xác lập cấu trúc lược đồ chuẩn cho toàn bộ không gian đặc trưng, phân loại tường minh danh sách biến định lượng và biến định tính nhằm áp dụng quy trình xử lý chuyên biệt cho từng kiểu biến ở các bước kế tiếp.
- **Loại bỏ đặc trưng không phù hợp và Triệt tiêu Rò rỉ Nhãn Mục tiêu :** Nhóm loại bỏ các biến hằng số không phương sai, các tổ hợp thời gian trùng lặp (`weekday_hour`), và đặc biệt quan trọng: loại bỏ toàn bộ các biến mã hóa mục tiêu theo tòa nhà cá thể (`gte_building_id`, `gte_meter_building_id`, …) cùng các đặc trưng gắn chặt với ID cụ thể của công trình (như `building_weekday_hour`, `building_hour`, …). Quyết định kỹ thuật này dựa trên hai nguyên nhân cốt tử:
  (a) *Nguy cơ Rò rỉ Dữ liệu Đích :* Bản chất của Global Target Encoding theo ID công trình là tính xác suất dị thường có điều kiện:

$$\text{GTE}(\text{building_id} = b) = \mathbb{E}[y \mid \text{building_id} = b] = \frac{\sum_{i \in b} y_i}{N_b}$$

  Nếu biến này được sinh ra trên toàn bộ tập dữ liệu trước khi phân chia chuỗi thời gian, thông tin nhãn mục tiêu y từ tương lai (T_{out}) sẽ bị rò rỉ ngược hoàn toàn vào tập huấn luyện (T_{in}), tạo ra kết quả kiểm thử ảo tưởng và gây rò rỉ dữ liệu.
  (b) *Nguy cơ Quá khớp Ghi nhớ ID :* Ngay cả khi được tính riêng trên T_{in}, do tập dữ liệu có tới 1.449 tòa nhà cá biệt (lực lượng phân loại cực lớn), việc mã hóa nhãn mục tiêu trực tiếp cho từng ID sẽ biến các đặc trưng này thành biến đại diện gần như hoàn hảo cho nhãn y. Mô hình cây sẽ bị dẫn dắt vào việc "học vẹt"và ghi nhớ máy móc tòa nhà nào thường xuyên bị lỗi trong lịch sử thay vì học các quy luật phụ tải vật lý tổng quát (độ lệch Z-score, nhiệt độ, công năng). Điều này khiến mô hình mất hoàn toàn năng lực tổng quát hóa khi một công trình trước đây hoạt động bình thường bất ngờ phát sinh sự cố trong tương lai.

  Trái ngược với `building_id`, biến công năng `primary_use` chỉ có 16 nhóm ngành lớn mang tính quy luật vật lý chung (giáo dục, bệnh viện, văn phòng...), do đó chỉ có `gte_primary_use` và `gte_meter_primary_use` (được học nghiêm ngặt 100% trên T_{in}) là được giữ lại.

4. **Bước 4:** Xử lý giá trị thiếu và giữ dấu vết thiếu dữ liệu. Cờ `meter_reading_was_missing` được tạo từ dữ liệu gốc trước khi điền khuyết, nên vẫn phân biệt được quan sát thật với giá trị được ước lượng. Với các cột số, pipeline nội suy tuyến tính theo thứ tự dòng trong từng `building_id`, giới hạn tối đa 12 giá trị thiếu liên tiếp theo mỗi hướng (`limit=12`, `limit_direction='both'`). Giá trị còn thiếu sau nội suy được điền bằng trung vị của từng cột, tính trên tập huấn luyện rồi áp dụng cho cả train và test. Vì việc chia tập theo các đoạn thời gian không liên tục nhưng nội suy chỉ nhóm theo tòa nhà, phép nội suy hiện tại có thể nối qua khoảng thời gian bị loại khỏi tập, do đó không nên diễn giải mọi giá trị đã điền là quan trắc thực hay khẳng định phép điền luôn bảo toàn động học phụ tải. Tỷ lệ thiếu bằng 0 sau tiền xử lý (nếu được kiểm tra) chỉ phản ánh ma trận đầu vào đã được điền, không có nghĩa dữ liệu gốc đầy đủ.

5. **Bước 5:** Xử lý giá trị ngoại lai bằng khoảng tứ phân vị IQR. Đối với các biến thời tiết môi trường (`air_temperature`, `dew_temperature`, `wind_speed`, …), nhóm áp dụng quy tắc khoảng tứ phân vị IQR:

$$\text{IQR} = Q_3 - Q_1, \quad [\text{Ngưỡng dưới}, \text{Ngưỡng trên}] = [Q_1 - 1{,}5\text{IQR},\ Q_3 + 1{,}5\text{IQR}]$$

Các quan trắc thời tiết vượt ra ngoài khoảng này do lỗi thiết bị đo khí tượng được clip về giá trị trung vị cục bộ.

Đặc biệt lưu ý: Thuộc tính phụ tải `meter_reading` và các đặc trưng Target Encoding (`gte_`) được miễn trừ hoàn toàn khỏi bước này, việc ép phụ tải về trung vị sẽ trực tiếp triệt tiêu các mẫu dị thường mà mô hình cần nhận dạng.

6. **Bước 6:** Chuẩn hóa Z-score và tích hợp đặc trưng khu vực.

- **Chuẩn hóa Z-score:** Đưa các biến định lượng về phân phối có trung bình bằng 0 và độ lệch chuẩn bằng 1 bằng `StandardScaler`:

$$Z = \frac{x - \mu}{\sigma}$$

Tham số μ, σ chỉ được fit trên tập huấn luyện và transform cho tập kiểm tra. Các biến cờ nhị phân (0/1), các biến chu kỳ $\sin / \cos \in [-1, 1]$, và các biến tỷ lệ `gte_` $\in [0, 1]$ được giữ nguyên thang đo gốc.

- **Tích hợp Đặc trưng Khu vực:** Để tạo ra bộ dữ liệu Zone-enhanced phục vụ các bài toán phân hóa địa bàn, nhóm nghiên cứu xây dựng thêm 3 đặc trưng tương tác địa lý với quy cách mã hóa và ý nghĩa thực tế chi tiết như sau:

(a) `zone_interaction`: Mã hóa tương tác phi tuyến giữa Vùng khí hậu và Mục đích sử dụng công trình.

– *Quy trình mã hóa:* Thuộc tính phân loại `primary_use` trước hết được ánh xạ sang mã danh mục tạm thời `primary_use_cat` $\in \{0, 1, \ldots, 11\}$ (ví dụ: `Education` = 0, `Entertainment` = 1, …). Sau đó, thực hiện phép ghép chuỗi ký tự giữa mã khu vực `site_id` và mã công năng:

$$\text{Chuỗi tương tác} = \texttt{site_id} \,\|\, \text{`_'} \,\|\, \texttt{primary_use_cat}$$

Chuỗi này tiếp tục được chuyển hóa thành mã định danh số nguyên phân loại:

$$\texttt{zone_interaction} = \text{CatCodes}(\text{Chuỗi tương tác}) \in \{0, 1, 2, \ldots, 46\}$$

– *Ví dụ giá trị cụ thể:*

∗ Một tòa nhà trường học (`Education`, mã 0) tọa lạc tại Khu vực nhiệt đới `Site 0` sẽ có chuỗi ghép `"0_0"`, được mã hóa thành giá trị nguyên **0**. Trong khi đó, một trường học tương tự nhưng tọa lạc tại Khu vực ôn đới lạnh `Site 1` có chuỗi `"1_0"`, được mã hóa thành giá trị **19**, và tại `Site 2` có chuỗi `"2_0"` nhận giá trị **24**.

∗ Một tòa nhà văn phòng (`Office`, mã 6) tại `Site 0` có chuỗi `"0_6"` nhận giá trị **1**, nhưng tại `Site 1` chuỗi `"1_6"` nhận giá trị **22**.

Toàn bộ dữ liệu ghi nhận chính xác 47 tổ hợp phân vùng thực tế (nhận giá trị từ 0 đến 46).

– *Ý nghĩa đối với mô hình:* Biến tương tác này cho phép các thuật toán cây thực hiện ngay lập tức một điểm cắt nhị phân (*single-split decision*) để phân lập hành vi tiêu thụ điện đặc thù theo từng địa phương mà không cần phải thực hiện 2 đến 3 tầng phân nhánh liên tiếp.

(b) `site_sqft_mean`: Quy mô diện tích sàn trung bình của từng khu vực đô thị (`site_id`).

– *Công thức tính:* Tính trung bình diện tích sàn của toàn bộ các công trình thuộc cùng một khu vực địa lý:

$$\texttt{site_sqft_mean}_i = \frac{1}{|S_{\texttt{site_id}_i}|} \sum_{k \in S_{\texttt{site_id}_i}} \texttt{square_feet}_k$$

– *Ví dụ giá trị cụ thể:* Khu vực `Site 0` có diện tích bình quân **83.051,6** ft^2 (đa số là khuôn viên trường đại học quy mô vừa), Khu vực `Site 4` tập trung các tổ hợp công nghệ lớn với diện tích bình quân lên tới **234.903,6** ft^2, Khu vực siêu đô thị `Site 7` có diện tích sàn bình quân đạt đỉnh **484.376,0** ft^2, trong khi Khu vực `Site 8` chủ yếu là các công trình nhỏ với diện tích trung bình chỉ **7.143,5** ft^2.

– *Ý nghĩa:* Cung cấp bối cảnh về mật độ và quy mô xây dựng đô thị tổng thể, giúp mô hình phân biệt giữa cụm đô thị dày đặc tải lớn và vùng phụ tải phân tán.

(c) `use_sqft_mean`: Quy mô diện tích sàn trung bình theo nhóm công năng (`primary_use`).

– *Công thức tính:* Tính trung bình diện tích sàn của toàn bộ các công trình có cùng mục đích sử dụng:

$$\texttt{use_sqft_mean}_i = \frac{1}{|U_{\texttt{primary_use}_i}|} \sum_{k \in U_{\texttt{primary_use}_i}} \texttt{square_feet}_k$$

– *Ví dụ giá trị cụ thể:* Nhóm công năng Dịch vụ phức hợp (`Services`) có diện tích trung bình cao nhất đạt **299.222,0** ft^2, Nhà để xe (`Parking`) đạt **204.312,0** ft^2, Trường học (`Education`) đạt **123.858,0** ft^2, Văn phòng (`Office`) đạt **89.883,9** ft^2, Sản xuất, công nghiệp (`Manufacturing / Industrial`)đạt **33.850,0** ft^2, và nhóm công trình phụ trợ khác (`Other`) chỉ đạt **4.482,0** ft^2.

– *Ý nghĩa:* Đóng vai trò làm mốc đối chứng chuẩn mực theo loại hình. Khi kết hợp với diện tích sàn thực tế `square_feet`, mô hình có thể tự động lượng hóa tỷ lệ lệch quy mô của một tòa nhà so với chuẩn mực ngành.

Ba thuộc tính này tạo nên khác biệt giữa Baseline với 39 đặc trưng và Zone-Enhanced với 42 đặc trưng. Bảng 4 minh họa giá trị của ba đặc trưng khu vực trên các công trình đại diện trong tập huấn luyện:

Bảng 4: Mẫu dữ liệu thực nghiệm minh họa 3 đặc trưng Zone trên các công trình tiêu biểu

Building ID	Site ID	Công năng (`primary_use`)	Diện tích gốc	`zone_interaction`	`site_sqft_mean`	`use_sqft_mean`
1	0	Education (Trường học)	2.720	0	-0,6202	+0,2951
91	0	Education (Trường học)	68.094	0	-0,6202	+0,2951
32	0	Office (Văn phòng)	48.392	1	-0,6202	-0,1428
136	1	Lodging/residential	56.467	21	-0,0238	-0,5030
240	2	Lodging/residential	111.304	26	+0,1275	-0,5030
69	0	Parking (Nhà để xe)	387.638	2	-0,6202	-0,5826

7. **Bước 7:** Tích hợp đặc trưng ngữ cảnh. Mặc dù 3 đặc trưng Zone cung cấp thông tin vĩ mô cấp khu vực, mức tiêu thụ điện thực tế lại phụ thuộc trực tiếp vào nhịp sinh hoạt và chế độ vận hành riêng của từng công trình cá biệt. Do đó, nhóm nghiên cứu thiết kế thêm 4 đặc trưng vi mô chuẩn hóa Z-score cục bộ, được học 100% trên tập huấn luyện T_{in} và ánh xạ sang tập kiểm định T_{out}:

   (a) `z_meter_local`: Phụ tải chuẩn hóa theo cặp (`building_id`, `hour`). Cho biết mức độ chênh lệch của phụ tải hiện tại so với hành vi bình thường của tòa nhà vào đúng khung giờ đó:

$$\texttt{z_meter_local}_i = \frac{\texttt{meter_reading}_i - \mu_{(b,h)}}{\sigma_{(b,h)}}$$

   (b) `z_meter_workday`: Phụ tải chuẩn hóa theo bộ ba (`building_id`, `is_offday`, `hour`). Tách biệt rõ nét giữa ngày làm việc thông thường và ngày nghỉ/cuối tuần (nơi phụ tải nền thường giảm mạnh):

$$\texttt{z_meter_workday}_i = \frac{\texttt{meter_reading}_i - \mu_{(b,\text{off},h)}}{\sigma_{(b,\text{off},h)}}$$

   (c) `z_meter_robust`: Chuẩn hóa kháng nhiễu bằng Z-score bền vững, dựa trên trung vị và khoảng tứ phân vị của từng công trình:

$$\texttt{z_meter_robust}_i = \frac{\texttt{meter_reading}_i - \text{Median}_b}{\text{IQR}_b}$$

   Nhờ dùng trung vị và IQR thay vì trung bình và độ lệch chuẩn, đặc trưng này ít bị ảnh hưởng bởi các giá trị dị thường cực đoan.

   (d) `temp_load_inter`: Đặc trưng tương tác giữa phụ tải công việc và nhiệt độ không khí môi trường:

$$\texttt{temp_load_inter}_i = \texttt{z_meter_workday}_i \times \texttt{air_temperature}_i$$

   Bốn đặc trưng này tạo thành bộ Context-Aware gồm 46 đặc trưng, 47 cột tính cả nhãn `anomaly`. Bảng 5 đối chiếu các giá trị của chúng giữa trạng thái bình thường ($y = 0$) và một số dạng dị thường ($y = 1$) trong tập huấn luyện T_{in}:

Bảng 5: Mẫu dữ liệu thực nghiệm minh họa 4 đặc trưng Context-Aware trên các công trình tiêu biểu

Building	Site	Công năng chính	Trạng thái vận hành	meter	Temp	z_local	z_work	z_robust	temp_inter
1	0	Education (Trường học)	Bình thường ($y = 0$)	-0,234	-0,15	+1,1444	+1,1535	+0,9537	-0,1780
1	0	Education (Trường học)	Dị thường ($y = 1$) (Sụt tải)	-0,418	+0,90	-1,6408	-1,6218	-0,5629	-1,4522
32	0	Office (Văn phòng)	Bình thường ($y = 0$)	-0,234	-0,15	+0,7961	+0,6676	0,0000	-0,1030
32	0	Office (Văn phòng)	Dị thường ($y = 1$) (Trái nhịp)	-0,208	+0,73	+0,1678	+0,8362	+0,2684	+0,6079
136	1	Lodging/residential	Bình thường ($y = 0$)	-0,381	-1,02	-0,8744	-0,8920	-0,3164	+0,9062
136	1	Lodging/residential	Dị thường ($y = 1$) (Đứt gãy tải)	-0,370	-1,27	-0,6715	-0,6887	-0,2097	+0,8770
1128	13	Office (Văn phòng)	Dị thường ($y = 1$) (Đột biến đỉnh)	+0,480	-3,02	+10,0000	+9,4721	+7,4612	-28,5724
144	1	Office (Văn phòng)	Dị thường ($y = 1$) (Triệt tiêu tải)	-0,450	-1,24	-5,0000	-5,0000	-2,1934	+6,2158
69	0	Parking (Nhà để xe)	Bình thường ($y = 0$)	-0,234	-0,15	+1,1788	+1,2004	+0,6218	-0,1853
69	0	Parking (Nhà để xe)	Dị thường ($y = 1$) (Bất thường tải)	-0,436	+0,90	-0,7673	-0,7814	-0,6900	-0,6996

Phân tích định lượng từ mẫu dữ liệu thực nghiệm:

- *Độ nhạy phân lập trước các sự cố cực đoan:* Tại tòa nhà văn phòng `Building 1128`, sự cố tăng vọt phụ tải bất thường vào khung giờ nhiệt độ lạnh giá ($T = -3{,}02$) được bộ đôi `z_meter_local` và `z_meter_workday` phát hiện ngay tức thì khi chạm ngưỡng trần bão hòa $+10{,}0000$ và $+9{,}4721$, kết hợp với đặc trưng tương tác âm tính cực lớn `temp_load_inter` $= -28{,}5724$. Ngược lại, tại `Building 144`, hiện tượng mất phụ tải đột ngột kéo `z_meter_local` chạm ngưỡng sàn $-5{,}0000$.
- *Bắt trúng dị thường ngữ cảnh vi mô :* Tại `Building 32`, phụ tải điện `meter_reading` $= -0{,}208$ nếu chỉ nhìn dưới góc độ ngưỡng toàn cục sẽ bị nhầm lẫn là tiêu thụ bình thường (nhãn $y = 0$ thông thường nhận $-0{,}234$). Tuy nhiên, tại thời điểm ngày nghỉ khi toàn bộ văn phòng đóng cửa, việc tiêu thụ mức này đẩy `z_meter_workday` lên $+0{,}8362$ và `temp_load_inter` $= +0{,}6079$, tạo tín hiệu rõ nét giúp mô hình phân định chính xác đây là điểm bất thường vận hành ngoài giờ.

8. **Bước 8:** Mở rộng đặc trưng chuỗi thời gian và phần dư STL. Context-Aware (47 cột) đã bổ sung ngữ cảnh theo giờ và ngày làm việc, nhưng các đặc trưng này chưa biểu diễn trực tiếp biến động tức thời, thời lượng cảm biến đứng yên hay sai lệch so với chu kỳ ngày. Vì vậy, nhóm tích hợp thêm 8 đặc trưng Expanded vào quy trình lõi `preprocessingforALL.py`. Để tránh rò rỉ nhìn trước tương lai (*Look-ahead Bias*), dữ liệu được gắn chỉ số gốc $idx_{\text{orig}} \in [0, N-1]$, sau đó sắp xếp theo [building_id, timestamp]. Mọi phép trễ và sai phân chỉ sử dụng các quan trắc trước đó của cùng công trình.

   (a) **Độ trễ phụ tải:** Ghi nhận mức phụ tải ở một và hai giờ trước để cung cấp các mốc gần cho phép so sánh:

   $$\text{meter_lag_1h}_t = m_{t-1}, \qquad \text{meter_lag_2h}_t = m_{t-2}.$$

   (b) **Sai phân phụ tải:** Đo mức thay đổi tuyệt đối trong một và hai giờ, giúp mô hình nhận diện các cú nhảy bất thường:

   $$\text{meter_diff_1h}_t = m_t - m_{t-1}, \qquad \text{meter_diff_2h}_t = m_t - m_{t-2}.$$

   (c) **Tỉ số phụ tải:** Chuẩn hóa biến động tương đối bằng hằng số $\epsilon = 1{,}0$, giảm phụ thuộc vào quy mô tải nền và làm nổi bật các lần tăng tải đột ngột:

   $$\text{meter_ratio_1h}_t = \frac{m_t + 1{,}0}{m_{t-1} + 1{,}0}, \qquad \text{meter_ratio_2h}_t = \frac{m_t + 1{,}0}{m_{t-2} + 1{,}0}.$$

(d) **Thời lượng cảm biến treo:** Khi giá trị đo gần như không đổi ($|m_t - m_{t-1}| \leq 10^{-4}$), bộ đếm tích lũy số giờ liên tiếp duy trì trạng thái này, qua đó cung cấp dấu hiệu về sự cố cảm biến hoặc truyền thông:

$$\text{flatline_duration}_t = \sum_{k=0}^{K-1} \mathbb{I}\left[|m_{t-k} - m_{t-k-1}| \leq 10^{-4}\right],$$

trong đó K là số giờ liên tiếp được xét.

(e) **Phần dư chu kỳ mùa vụ STL:** So sánh phụ tải hiện tại với trung vị của cùng khung giờ trong bảy ngày trước. Trung vị giảm ảnh hưởng của các ngày có dị thường trong giá trị tham chiếu:

$$\text{stl_residual}_t = m_t - \text{Median}\left(\{m_{t-24d} \mid d \in \{1,2,3,4,5,6,7\}\}\right).$$

Sau khi tạo đặc trưng, tám cột mới được ánh xạ về chỉ số gốc idx_{orig} để giữ nguyên thứ tự dòng ban đầu.

3.3 Khám phá Dữ liệu sau Tiền xử lý

Sau khi hoàn tất toàn bộ chuỗi biến đổi tiền xử lý, nhóm nghiên cứu tiến hành kiểm toán dữ liệu và khám phá đối chiếu nhằm đánh giá toàn diện sự thay đổi của tập dữ liệu trước khi bước vào giai đoạn huấn luyện mô hình.

3.3.1 Kiểm tra Tính Toàn vẹn và Phân bổ Đặc trưng

Sau khi tiền xử lý, dữ liệu gồm 1.147.089 dòng T_{in} (65,6%), 229.412 dòng Purge Gap (13,1%) và 372.993 dòng T_{out} (21,3%). Cờ missing được tạo trước khi nội suy có giới hạn và điền phần còn lại bằng trung vị train, vì vậy, việc không còn `NaN` trong đầu vào không có nghĩa là đã khôi phục được phép đo gốc. Trên cùng cách chia dữ liệu, bốn nhánh tăng dần từ Baseline (39 đặc trưng) qua Zone-Enhanced (42), Context-Aware (46) đến Expanded Champion (54), tạo cơ sở để so sánh đóng góp của các nhóm đặc trưng bổ sung ở Chương 4.

Bảng 6 tổng hợp các nhóm đặc trưng trong bốn bộ dữ liệu thực nghiệm.

Nhóm Đặc trưng	Số lượng	Các thuộc tính chi tiết và Ý nghĩa nghiệp vụ
Đặc trưng Phụ tải gốc	1	`meter_reading` (sau nội suy có giới hạn, điền phần còn thiếu bằng trung vị train và chuẩn hóa Z-score, cờ missing được giữ riêng).
Cảm biến Khí tượng gốc	7	`air_temperature`, `cloud_coverage`, `dew_temperature`, `precip_depth_1_hr`, `sea_level_pressure`, `wind_direction`, `wind_speed` (sau lọc ngoại lai IQR và Z-score).
Chuỗi trễ Khí tượng	8	`air_temperature_mean_lag7`, `max_lag7`, `min_lag7`, `std_lag7` (trễ 7h trong ngày) kết hợp `mean_lag73`, `max_lag73`, `min_lag73`, `std_lag73` (trễ 73h theo đợt nhiệt).
Đặc tính Công trình & ID	5	`square_feet`, `year_built`, `floor_count` (quy mô, niên hạn) kết hợp `building_id`, `site_id` (định danh công trình và vùng địa lý).
Chu kỳ Lượng giác & Lễ	7	`hour_sin`, `hour_cos`, `weekday_sin`, `weekday_cos`, `month_sin`, `month_cos` (chu kỳ 24h, 7 ngày, 12 tháng) và cờ ngày nghỉ `is_holiday`.
Cờ Gián đoạn Cảm biến	1	`meter_reading_was_missing` (lưu dấu vết sự cố truyền thông IoT trước khi điền khuyết).
Mã hóa Mục tiêu	10	`gte_hour`, `gte_weekday`, `gte_month`, `gte_primary_use`, `gte_site_id`, `gte_meter_hour`, `gte_meter_weekday`, `gte_meter_month`, `gte_meter_primary_use`, `gte_meter_site_id`.
Tổng số đặc trưng Baseline	39	Ma trận gồm 40 cột tính cả nhãn `anomaly`.
Tương tác Khu vực	3	`zone_interaction`, `site_sqft_mean`, `use_sqft_mean`, bổ sung vào Zone-Enhanced.
Tổng số đặc trưng Zone-Enhanced	42	Ma trận gồm 43 cột tính cả nhãn `anomaly`.
Ngữ cảnh	4	`z_meter_local`, `z_meter_workday`, `z_meter_robust`, `temp_load_inter`, bổ sung vào Context-Aware.
Tổng số đặc trưng Context-Aware	46	Ma trận đặc trưng gồm 47 cột tính cả nhãn `anomaly`.
Đặc trưng chuỗi thời gian	8	`meter_lag_1h`, `meter_lag_2h`, `meter_diff_1h`, `meter_diff_2h`, `meter_ratio_1h`, `meter_ratio_2h`, `flatline_duration`, `stl_residual`.
Tổng số đặc trưng Expanded Champion	54	Ma trận đặc trưng gồm 55 cột tính cả nhãn `anomaly`.

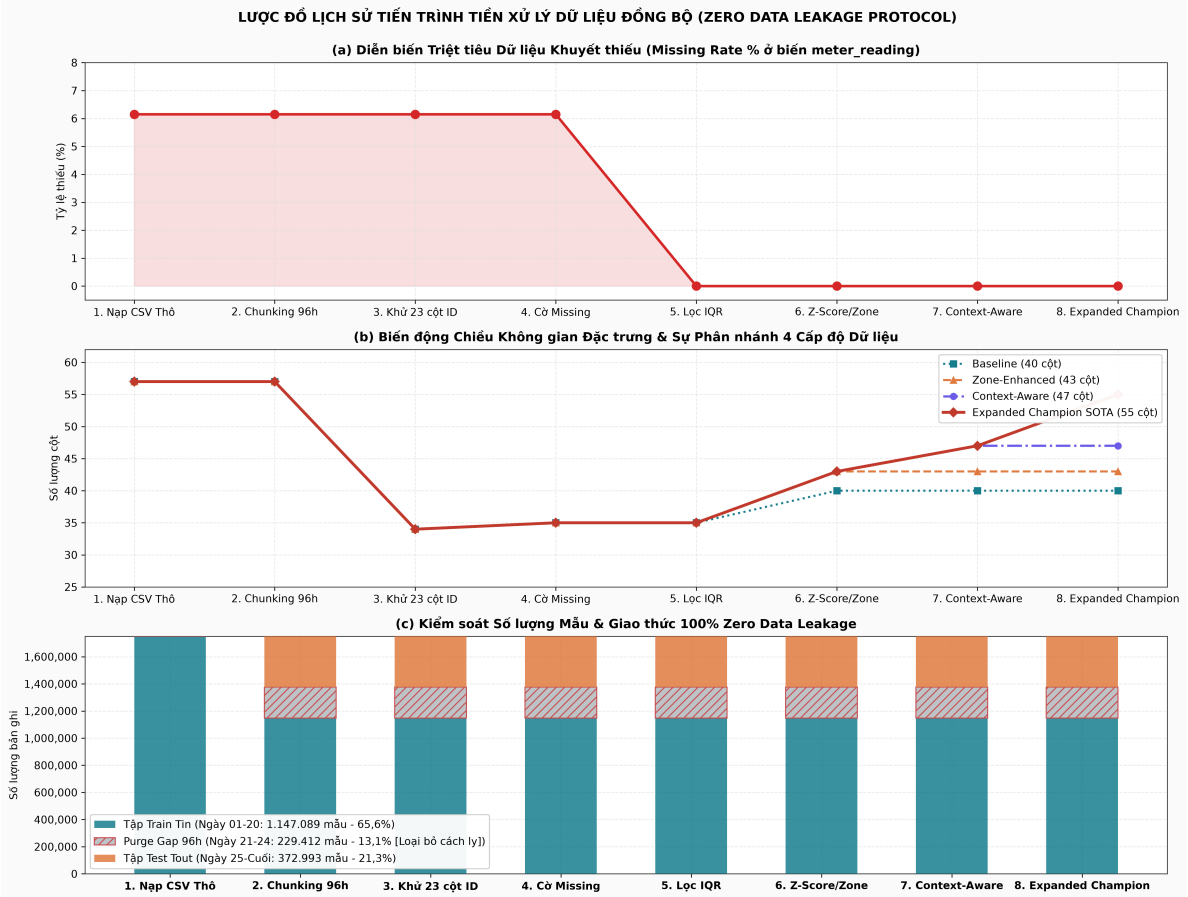
Bảng 6: Tổng hợp các nhóm đặc trưng trong bốn bộ dữ liệu

Bảng 7: Bảng kiểm toán biến đổi số dòng và thuộc tính qua 8 giai đoạn tiền xử lý

Giai đoạn Tiền xử lý	T_{in} Trước	T_{in} Sau	Purge Gap	T_{out} Trước	T_{out} Sau	Số cột	Ghi chú Rò rỉ
1. Nạp CSV Thô	1.749.494	1.749.494	0	—	—	57	Dữ liệu thô nguyên bản
2. Seasonal Chunking & 96h Purge Gap	1.749.494	1.147.089	229.412	—	372.993	57	Loại bỏ 96h buffer
3. Khử 23 cột rò rỉ ID & Mã hóa sin / cos	1.147.089	1.147.089	0	372.993	372.993	34	Khử tuyệt đối ID leak
4. Cờ Missing & Điền khuyết	1.147.089	1.147.089	0	372.993	372.993	35	Nội suy giới hạn 12 dòng, phần còn lại điền median train
5. Lọc ngoại lai khí tượng	1.147.089	1.147.089	0	372.993	372.993	35	Kẹp biên IQR/Median
6. Chuẩn hóa Z-score & Nhánh Zone	1.147.089	1.147.089	0	372.993	372.993	40 / 43	Fit T_{in}, transform T_{out}
7. Tích hợp Ngữ cảnh Context Vi mô	1.147.089	1.147.089	0	372.993	372.993	47	Fit lookup T_{in}, map T_{out}
8. Xuất 8 tệp Parquet	1.147.089	1.147.089	0	372.993	372.993	40/43/47/55	4 cặp huấn luyện/kiểm định

3.3.2 Lược đồ Lịch sử Tiến trình Tiền xử lý

Hình 6 tóm tắt các thay đổi chính của dữ liệu qua các giai đoạn tiền xử lý: tỷ lệ thiếu của `meter_reading`, số cột trong từng nhánh đặc trưng và số lượng mẫu được giữ lại hoặc loại bỏ.

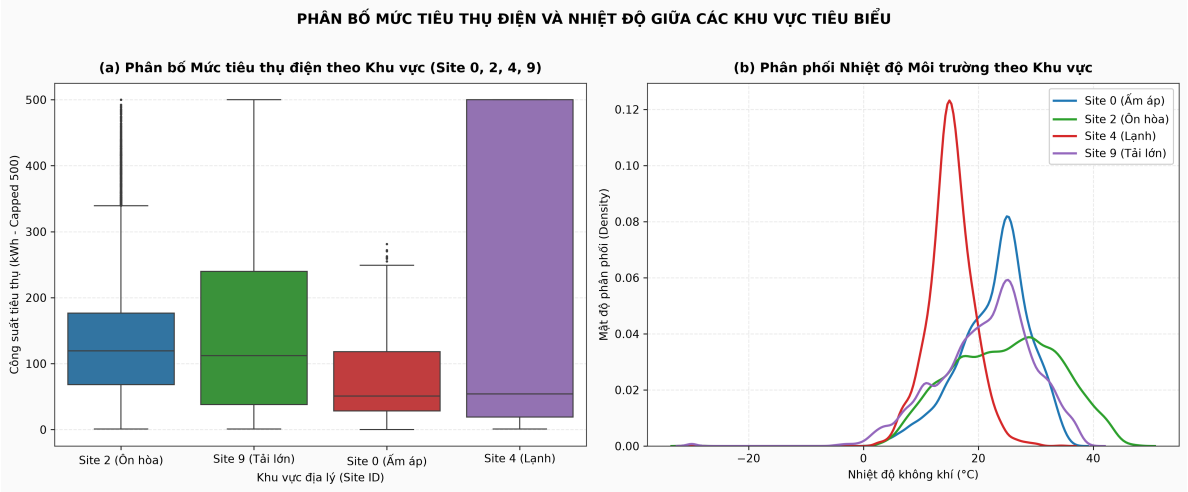


Hình 6: Tóm tắt tỷ lệ thiếu, số cột đặc trưng và số lượng mẫu qua các giai đoạn tiền xử lý

Hình 6 cho thấy dữ liệu gốc có 107.653 giá trị `meter_reading` bị thiếu (6,15%), số cột tăng từ 40 ở Baseline lên 43, 47 và 55 ở các nhánh mở rộng. Trong 1.749.494 dòng, 1.147.089 dòng được dùng làm T_{in}, 229.412 dòng nằm trong Purge Gap và 372.993 dòng làm T_{out}. Parquet Baseline train không còn NaN, cờ `meter_reading_was_missing` vẫn đánh dấu 76.237 dòng có phép đo gốc bị khuyết. Quy trình do đó hoàn thiện ma trận đầu vào đồng thời giữ lại thông tin về các phép đo bị thiếu.

3.3.3 Khám phá Tương tác Khu vực

Hình 7 trực quan hóa phân bố phụ tải và nhiệt độ tại bốn khu vực tiêu biểu (`site_id` 0, 2, 4, 9), làm rõ khác biệt giữa các site trước khi xây dựng nhóm đặc trưng Zone.



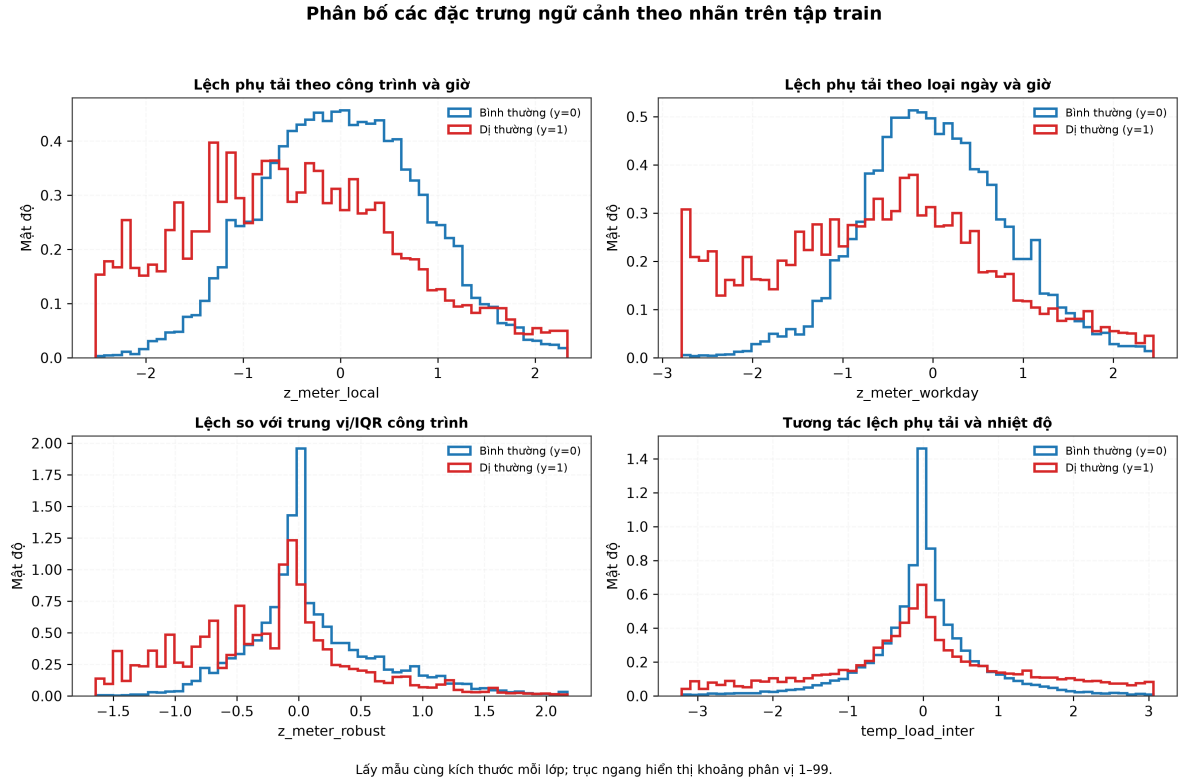
Hình 7: Phân bố Mức tiêu thụ điện (trái) và Phân phối Nhiệt độ (phải) giữa các Khu vực (Site 0, 2, 4, 9)

Hình 7 cho thấy mức và độ phân tán phụ tải, cùng phân bố nhiệt độ, khác nhau giữa bốn site được minh họa. Các đặc trưng khu vực được bổ sung để biểu diễn bối cảnh này, mức đóng góp dự đoán của chúng được kiểm tra trong thực nghiệm ở Chương 4.

Bốn bộ dữ liệu Baseline, Zone-Enhanced, Context-Aware và Expanded Champion được sử dụng trong các thực nghiệm ở Chương 4 để so sánh đóng góp của các nhóm đặc trưng được bổ sung.

3.3.4 Khảo sát các Đặc trưng Ngữ cảnh

Bộ Context-Aware bổ sung bốn biến mô tả phụ tải so với mức tham chiếu riêng của từng công trình. `z_meter_local` chuẩn hóa `meter_reading` theo trung bình và độ lệch chuẩn của từng cặp công trình–giờ, `z_meter_workday` dùng tham chiếu theo công trình, giờ và trạng thái ngày thường/cuối tuần, đồng thời dùng tham chiếu theo giờ nếu nhóm tương ứng không có dữ liệu. `z_meter_robust` biểu diễn độ lệch so với trung vị của công trình, chia cho khoảng tứ phân vị (IQR). Các thống kê tham chiếu được tính trên tập train, ba biến chuẩn hóa được giới hạn trong khoảng $[-5, 10]$. Biến `temp_load_inter` là tích của `z_meter_workday` với `air_temperature` sau chuẩn hóa.

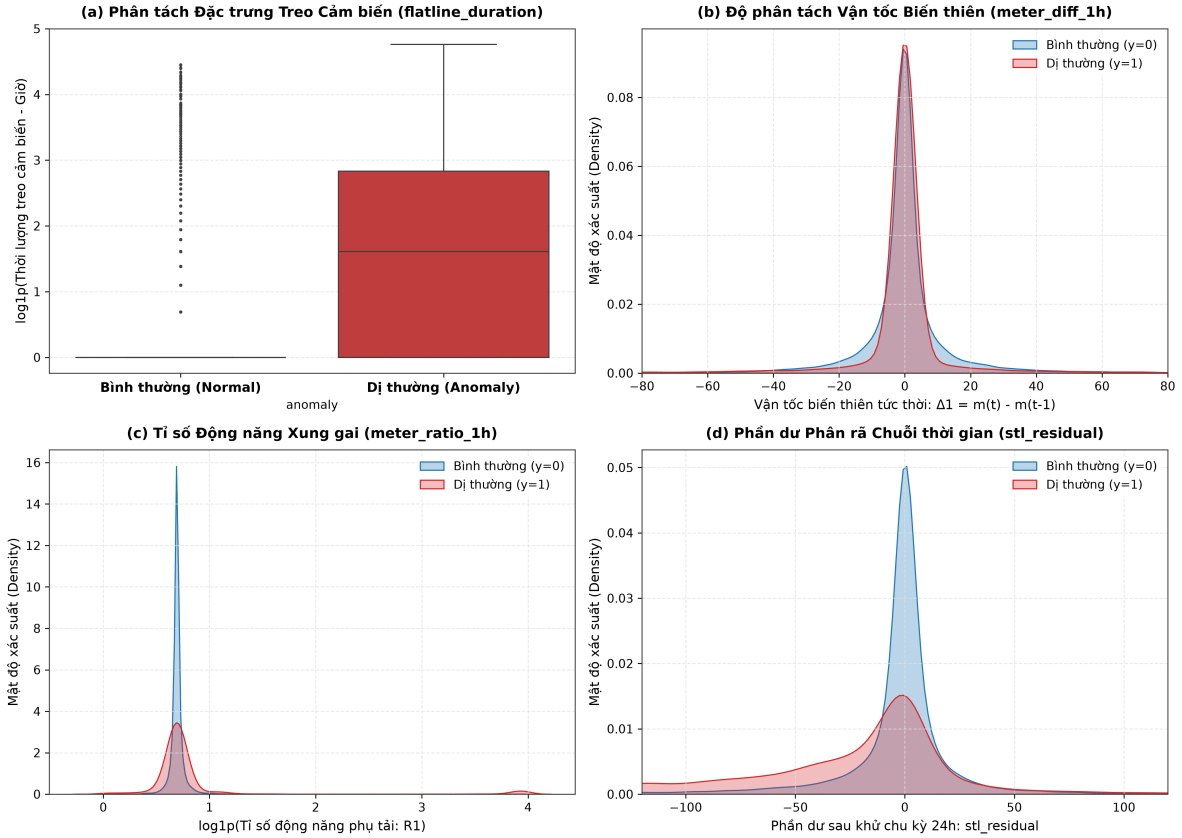


Hình 8: Phân bố các đặc trưng Context-Aware theo nhãn trên tập train, mỗi lớp được lấy mẫu cùng kích thước và trục hoành hiển thị khoảng phân vị 1–99

Hình 8 cho thấy ba biến chuẩn hóa phụ tải có trung vị thấp hơn ở nhóm bất thường: `z_meter_local` là $-1{,}1265$ so với $0{,}0039$, `z_meter_workday` là $-1{,}1821$ so với $-0{,}0153$, và `z_meter_robust` là $-0{,}3982$ so với $0{,}0000$. Với `temp_load_inter`, trung vị hai nhóm gần nhau ($-0{,}0097$ và $0{,}0023$), còn độ phân tán ở nhóm bất thường lớn hơn. Các biến chuẩn hóa thể hiện vị trí phụ tải so với mức tham chiếu riêng của công trình, hiệu quả dự đoán được đánh giá bằng thực nghiệm ở Chương 4.

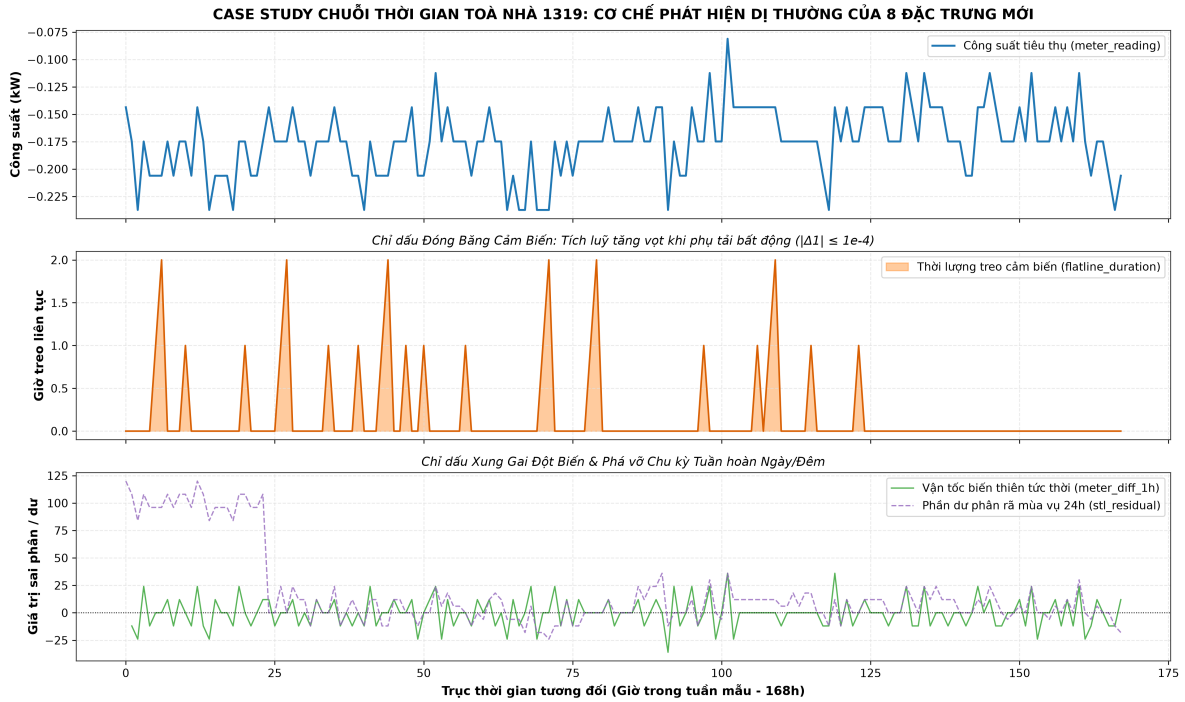
3.3.5 Phân tích Khám phá Dữ liệu Chuyên sâu trên Không gian Mở rộng

Các biểu đồ dưới đây khảo sát phân bố đặc trưng mở rộng theo nhãn và một ví dụ chuỗi thời gian cụ thể.



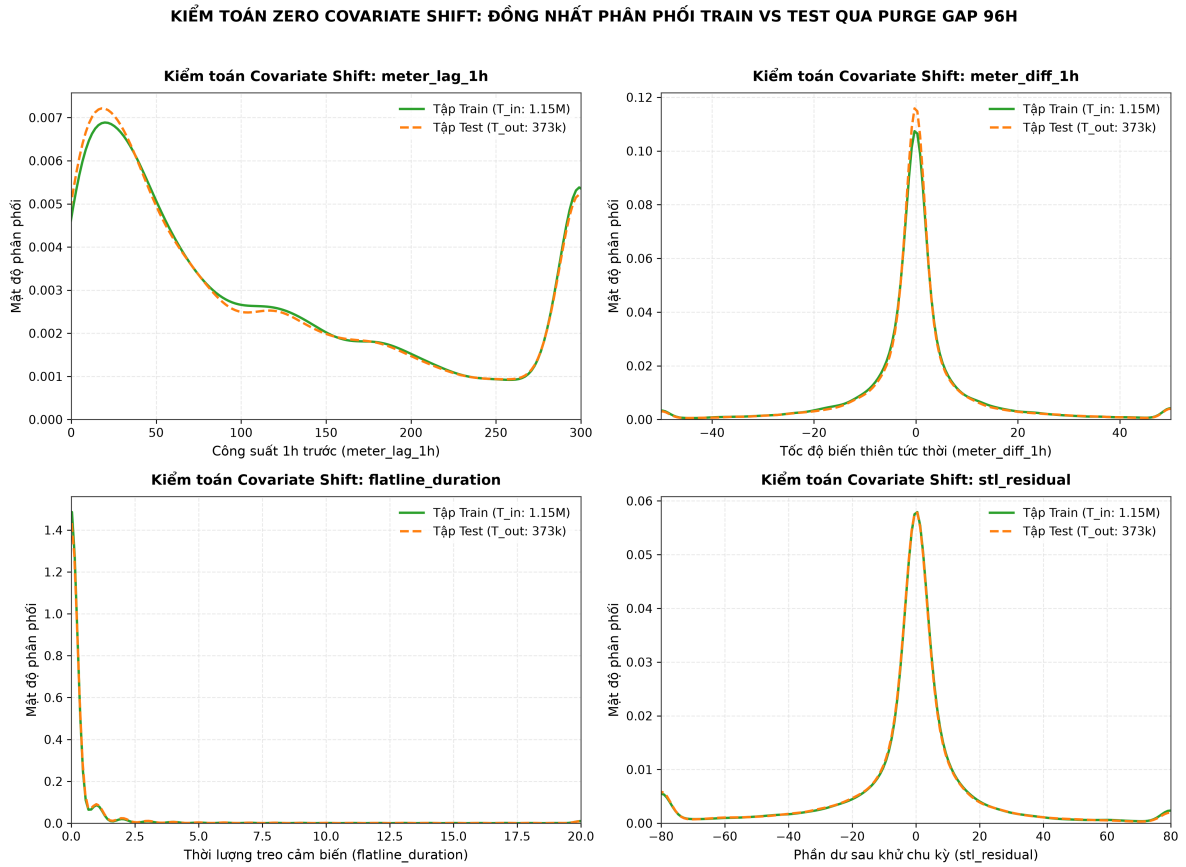
Hình 9: Phân tích tám đặc trưng mở rộng: phân phối của lớp bình thường và lớp dị thường

Hình 9 cho thấy `meter_diff_1h` ở lớp bất thường phân tán rộng hơn, tức một số mẫu mang nhãn này đi kèm biến động phụ tải lớn giữa hai giờ liên tiếp. `flatline_duration` mô tả thời lượng phụ tải gần như không đổi, còn `stl_residual` biểu diễn độ lệch so với mức tham chiếu trễ. Ba đặc trưng này bổ sung thông tin về biến động ngắn hạn và trạng thái chuỗi.



Hình 10: Nghiên cứu Điển hình 168 Giờ Liên tục: Diễn biến Phụ tải Thực tế, Phản ứng Tức thời của STL Residual và Bộ đếm Flatline Duration trước Sự kiện Bất thường

Trong cửa sổ 168 giờ tại Hình 10, một số thời điểm mang nhãn bất thường trùng với biến động phụ tải, `stl_residual` thể hiện độ lệch với mức tham chiếu, còn `flatline_duration` đánh dấu các đoạn phụ tải gần như không đổi. Hình cho thấy các đặc trưng chuỗi ghi nhận những dạng biến động khác nhau.



Hình 11: Kiểm toán Độ lệch Phân phối giữa Tập Train (T_{in}) và Test (T_{out}) qua Khoảng Cách ly Purge Gap 96 Giờ

Các đường mật độ của T_{in} (ngày 01–20) và T_{out} (ngày 25–cuối tháng) chồng lấp gần như hoàn toàn trên cả bốn đặc trưng được minh họa. Phân phối hai tập nhìn chung tương đồng.

4 Triển khai Học máy

4.1 Thước đo Đánh giá và Cơ chế Ngưỡng Quyết định

4.1.1 Thước đo Đánh giá

Do lớp dị thường chỉ chiếm khoảng 2,13%, bộ phân loại luôn dự đoán lớp bình thường vẫn đạt Accuracy cao trong khi bỏ sót toàn bộ dị thường. PR-AUC vì thế được chọn làm thước đo chính để đánh giá khả năng xếp hạng lớp dương trên toàn dải ngưỡng, mức cơ sở ngẫu nhiên xấp xỉ 0,0213. Khi chuyển điểm số thành cảnh báo, Precision đo tỷ lệ cảnh báo đúng, Recall đo tỷ lệ dị thường được phát hiện, còn F_1 tổng hợp hai đại lượng. ROC-AUC được báo cáo bổ sung, trên dữ liệu mất cân bằng, chỉ số này không cho biết trực tiếp chất lượng phát hiện lớp hiếm.

$$\text{Precision} = \frac{TP}{TP + FP}, \qquad \text{Recall} = \frac{TP}{TP + FN}$$

$$F_1\text{-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

4.1.2 Cơ chế Ngưỡng Quyết định

Ngưỡng 0,5 không mặc nhiên phù hợp vì các mô hình và phương pháp dung hợp tạo ra điểm số trên những thang khác nhau. Về nguyên tắc, chọn τ^* bằng cách tối đa hóa F_1 trên validation để cân bằng Precision và Recall, sau đó giữ cố định ngưỡng khi đánh giá trên test:

$$\tau^* = \arg\max_{\tau} F_1\left(y_{\text{val}}, \mathbb{1}[\hat{s}_{\text{val}} \geq \tau]\right)$$

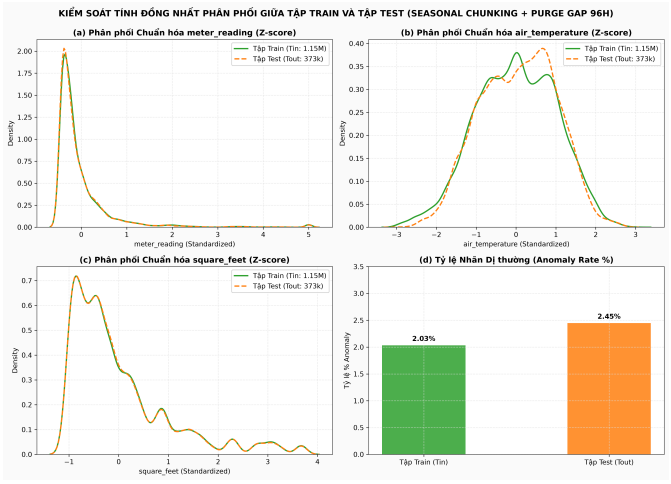
Trong `pipeline_ml.py`, các bảng benchmark chính tính ngưỡng từ nhãn và điểm số của T_{out}, phần tối ưu trọng số SLSQP và trọng số theo PR-AUC cũng sử dụng nhãn test. Vì vậy, F1, Precision, Recall và ngưỡng ở các bảng này là kết quả hậu nghiệm trên test, PR-AUC của ensemble có trọng số học từ test cũng không phải ước lượng độc lập. Các số liệu này cần được đánh giá lại sau khi cố định ngưỡng và trọng số bằng validation.

4.2 Thử nghiệm, Huấn luyện và Đánh giá các Mô hình

4.2.1 Chiến lược Phân chia Dữ liệu và Kiểm soát Phân phối Tập Huấn luyện - Kiểm tra

Chia ngẫu nhiên có thể đặt các giờ gần nhau của cùng chuỗi vào cả train lẫn test, khiến đánh giá không phản ánh tốt việc dự đoán trên giai đoạn thời gian tách biệt. Vì vậy, dữ liệu được chia theo ngày trong tháng: ngày 01–20 làm T_{in} (1.147.089 mẫu), ngày 21–24 làm Purge Gap (229.412 mẫu), và ngày 25 đến cuối tháng làm T_{out} (372.993 mẫu). Khoảng gap tạo khoảng cách thời gian giữa hai tập, các phép biến đổi được fit trên T_{in} rồi áp dụng cho T_{out}.

Hình 12 và Bảng 8 đối chiếu phân phối của hai tập.



Hình 12: **Kiểm soát Tính Đồng nhất Phân phối giữa Tập Huấn luyện (T_{in} Ngày 1–20) và Tập Kiểm tra Out-of-sample (T_{out} Ngày 25–Hết) trên Giao thức Seasonal Chunking với Purge Gap 96 giờ**

Bảng 8: **Kiểm toán Thống kê Đối chiếu Phân phối giữa Tập Huấn luyện (T_{in}) và Tập Kiểm tra (T_{out})**

Chỉ số Thống kê / Đặc trưng	Tập Huấn luyện (T_{in})	Tập Kiểm tra (T_{out})	Thống kê KS (D)	p-value (KS Test)
Tổng số mẫu	1.147.089 (100,0%)	372.993 (100,0%)	—	—
Lớp Bình thường ($y = 0$)	1.123.761 (97,9663%)	363.862 (97,5520%)	—	—
Lớp Dị thường ($y = 1$)	23.328 (2,0337%)	9.131 (2,4480%)	—	—
`meter_reading` ($\mu \pm \sigma$)	$-0{,}0000 \pm 1{,}0000$	$-0{,}0073 \pm 0{,}9936$	0,02066	$< 0{,}001$
`air_temperature` ($\mu \pm \sigma$)	$-0{,}0000 \pm 1{,}0000$	$0{,}0457 \pm 0{,}9459$	0,03696	$< 0{,}001$
`square_feet` ($\mu \pm \sigma$)	$0{,}0000 \pm 1{,}0000$	$-0{,}0004 \pm 0{,}9999$	0,00558	0,4162
`dew_temperature` ($\mu \pm \sigma$)	$-0{,}0000 \pm 1{,}0000$	$0{,}0779 \pm 0{,}9581$	0,06274	$< 0{,}001$

Tỷ lệ dị thường ở T_{in} và T_{out} lần lượt là 2,0337% và 2,4480%, chênh 0,4143 điểm phần trăm. Các thống kê KS D nằm trong khoảng 0,00558–0,06274, cho thấy mức sai khác phân phối nhỏ trên các biến được kiểm tra, riêng `square_feet` có $D = 0{,}00558$ và $p = 0{,}4162$. Với cỡ mẫu lớn, một số biến có $p < 0{,}001$ trong khi độ lớn D vẫn thấp. Nhìn chung, hai tập có phân phối khá gần nhau. Các phép biến đổi được fit trên T_{in} rồi áp dụng cho T_{out}.

4.2.2 Phân tích Thực nghiệm: Đối chứng Bộ tứ Gradient Boosting qua 3 Không gian Dữ liệu

Bốn mô hình Gradient Boosting được so sánh trên Baseline, Zone-Enhanced và Context-Aware. Chúng được huấn luyện trên T_{in} và đánh giá trên T_{out}, kết quả gồm PR-AUC, ROC-AUC, các chỉ số tại ngưỡng và thời gian huấn luyện (Bảng 9).

Bảng 9: **Thực nghiệm Đối chứng Đa Chiều: Bộ tứ Gradient Boosting qua cả 3 Không gian Dữ liệu trên Tập Out-of-Sample (372.993 mẫu)**

Thuật toán Boosting	PR-AUC (Chính)	ROC-AUC	Ngưỡng τ^*	F1 (τ^*)	F1 (0.5)	Precision	Recall	Thời gian (s)
I. Không gian Baseline (39 đặc trưng vật lý & thời gian cơ sở)								
LightGBM	0,6210	0,8557	0,968	0,6836	0,6197	**0,9983**	0,5198	12,4
XGBoost	**0,6350**	**0,8558**	0,819	**0,7028**	0,6742	0,9616	**0,5537**	8,6
CatBoost	0,6223	0,8446	0,829	0,6954	0,6372	0,9909	0,5356	7,7
HistGradientBoosting	0,6056	0,8438	0,958	0,6766	0,4012	0,9829	0,5158	14,7
II. Không gian Zone-Enhanced (42 đặc trưng khu vực)								
LightGBM	0,6238	0,8621	0,800	0,6899	0,6421	0,9389	0,5453	36,1
XGBoost	**0,6363**	**0,8644**	0,918	**0,7031**	0,6812	0,9850	0,5466	8,1
CatBoost	0,6181	0,8423	0,880	0,6923	0,5793	**0,9908**	0,5320	8,6
HistGradientBoosting	0,6086	0,8486	0,970	0,6815	0,4120	0,9970	0,5177	15,9
III. Không gian Context-Aware (46 đặc trưng ngữ cảnh - Bước nhảy vọt)								
LightGBM	0,6750	0,8931	0,879	**0,7081**	0,6521	**0,9752**	0,5559	16,1
XGBoost	**0,6810**	**0,8957**	0,848	0,7066	0,6841	0,9626	**0,5582**	8,4
CatBoost	0,6691	0,8953	0,800	0,6960	0,6420	0,9549	0,5476	8,4
HistGradientBoosting	0,6671	0,8904	0,957	0,6975	0,4236	0,9613	0,5473	15,4

XGBoost dẫn đầu PR-AUC ở cả ba không gian, nhưng mức thay đổi theo nhóm đặc trưng khác nhau. Khi bổ sung ba đặc trưng Zone, PR-AUC thay đổi nhẹ: XGBoost tăng từ 0,6350 lên 0,6363, LightGBM tăng từ 0,6210 lên 0,6238, HistGradientBoosting tăng từ 0,6056 lên 0,6086, còn CatBoost giảm từ 0,6223 xuống 0,6181. ROC-AUC tăng ở XGBoost, LightGBM và HistGradientBoosting, trong khi giảm nhẹ ở CatBoost. Nhóm Zone gồm `zone_interaction`, `site_sqft_mean` và `use_sqft_mean`. Hai biến mean gán cho mỗi mẫu diện tích trung bình theo `site_id` và theo `primary_use`, còn biến tương tác là tích của hai giá trị này. Vì vậy, chúng mô tả quy mô điển hình của khu vực và công năng chứ không phản ánh trực tiếp diện tích hay chế độ vận hành riêng của từng công trình. Baseline đã có `site_id`, `primary_use`, `square_feet` và các mã hóa mục tiêu liên quan, nên một phần thông tin của ba biến Zone có thể đã được mô hình suy ra từ đặc

trưng hiện hữu. Việc tổng hợp theo nhóm còn làm mất khác biệt giữa các công trình cùng site hoặc cùng công năng. Đây là lý do cụ thể khiến các đặc trưng Zone chỉ bổ sung ít tín hiệu mới và mức tăng PR-AUC nhỏ. Với CatBoost, phần thông tin mới có thể không đủ bù cho nhiễu hoặc sự trùng lặp từ các giá trị trung bình theo nhóm, làm thứ tự một số mẫu dị thường kém chính xác hơn và PR-AUC giảm. Đây là cách giải thích phù hợp với cách tạo biến và kết quả quan sát, không phải kết luận nhân quả đã được kiểm chứng riêng.

Mức cải thiện rõ nhất xuất hiện khi chuyển từ Zone-Enhanced sang Context-Aware. PR-AUC tăng lần lượt 0,0447 ở XGBoost, 0,0512 ở LightGBM, 0,0510 ở CatBoost và 0,0585 ở HistGradientBoosting. ROC-AUC cũng tăng ở cả bốn mô hình. Bốn đặc trưng mới gồm các độ lệch chuẩn hóa phụ tải theo công trình, theo ngày làm việc và theo thước đo robust, cùng tương tác giữa phụ tải tương đối ngày làm việc với nhiệt độ. Các biến này biểu diễn trực tiếp mức bất thường của phụ tải so với nhịp riêng của công trình và bổ sung thông tin về điều kiện môi trường. Nhờ đó, mô hình có thể nhận ra những điểm có giá trị đo chưa hẳn cực đoan trên toàn bộ dữ liệu nhưng lệch đáng kể so với mức vận hành thường thấy của chính công trình. Việc cả bốn thuật toán cùng cải thiện, với PR-AUC Context-Aware nằm trong khoảng 0,6671–0,6810, cho thấy nhóm đặc trưng ngữ cảnh đóng góp tín hiệu nhất quán hơn nhóm Zone trong thực nghiệm này.

4.2.3 Tối ưu hóa Siêu tham số bằng Optuna

Các siêu tham số của những mô hình được báo cáo trong chương này đều đã được tinh chỉnh bằng Optuna. Sampler TPE đề xuất cấu hình dựa trên kết quả các lượt thử trước. PR-AUC trên validation là mục tiêu tối ưu, phù hợp với dữ liệu mất cân bằng và yêu cầu xếp hạng lớp dị thường. Không gian tìm kiếm bao gồm các tham số như độ sâu hoặc số lá, tốc độ học, lấy mẫu, chính quy hóa và trọng số lớp. Bảng dưới chỉ liệt kê cấu hình tham khảo trên Expanded, không lặp lại các cấu hình của những không gian đặc trưng đã trình bày trước đó.

Bảng 10: **Cấu hình siêu tham số tham khảo sau khi tuning bằng Optuna trên Expanded (54 đặc trưng)**

Thuật toán	Cấu hình siêu tham số	PR-AUC Test	F_1-Score
XGBoost	`n_estimators`: 350, `max_depth`: 10, `learning_rate`: 0,0382, `subsample`: 0,6067, `colsample_bytree`: 0,6137, `min_child_weight`: 4, `gamma`: 0,0181, `reg_alpha`: 0,0081, `reg_lambda`: 0,5349	**0,8432**	0,8358
LightGBM	`n_estimators`: 200, `num_leaves`: 126, `max_depth`: 10, `learning_rate`: 0,0433, `subsample`: 0,7055, `colsample_bytree`: 0,7146, `min_child_samples`: 104, `reg_alpha`: 0,0030, `reg_lambda`: 1,6470	0,8384	0,8366
CatBoost	`iterations`: 300, `depth`: 9, `learning_rate`: 0,0430, `l2_leaf_reg`: 2,0192, `random_strength`: 0,0132	0,8376	**0,8409**
HistGradientBoosting	`max_iter`: 350, `max_leaf_nodes`: 37, `max_depth`: 6, `learning_rate`: 0,0550, `min_samples_leaf`: 56, `l2_regularization`: 1,9011	0,8380	0,8358

Trên Expanded, XGBoost có PR-AUC cao nhất (0,8432), còn CatBoost có F_1 cao nhất (0,8409). PR-AUC phản ánh xếp hạng dị thường trên toàn dải ngưỡng, trong khi F_1 phụ thuộc ngưỡng quyết định, vì vậy thứ hạng hai chỉ số không nhất thiết trùng nhau. Cả bốn bộ siêu tham số được giữ cho các so sánh tiếp theo để phân biệt tác động của thuật toán với tác động của đặc trưng. PR-AUC và F_1 ở bảng là số đo test của benchmark hiện tại, do pipeline benchmark chọn ngưỡng trên test, F_1 chưa phải ước lượng ngoài mẫu độc lập.

4.2.4 Kỹ thuật Dung hợp Đa Mô hình (Multi-Model Ensembling)

Dung hợp kết hợp điểm dự đoán từ nhiều mô hình. Gọi $p_m(x)$ là xác suất dị thường do mô hình thứ m dự đoán, $r_m(x)$ là thứ hạng phân vị của xác suất đó trong tập đánh giá, M là số mô hình và N là số mẫu đánh giá. Các phương pháp được khảo sát và công thức tương ứng như sau.

4.2.4.1 Soft Voting với trọng số đều. Lấy trung bình xác suất dự đoán. Với các tổ hợp hai, ba hoặc bốn mô hình, trọng số đều lần lượt là 1/2, 1/3 hoặc 1/4:

$$s_{\text{soft}}(x) = \frac{1}{M}\sum_{m=1}^{M} p_m(x).$$

Phương pháp này giữ lại độ lớn xác suất nên nhạy với khác biệt về thang điểm và hiệu chỉnh xác suất giữa các mô hình.

4.2.4.2 Rank Averaging với trọng số đều. Đầu tiên chuyển xác suất của từng mô hình thành thứ hạng phân vị, sau đó lấy trung bình các thứ hạng:

$$r_m(x) = \frac{\text{rank}(p_m(x))}{N}, \qquad s_{\text{rank}}(x) = \frac{1}{M}\sum_{m=1}^{M} r_m(x).$$

Phương pháp này bỏ qua độ lớn xác suất, tập trung vào thứ tự ưu tiên các mẫu và giảm ảnh hưởng của việc các mô hình sử dụng thang xác suất khác nhau.

4.2.4.3 Weighted Soft Voting theo PR-AUC. Gán trọng số cho xác suất của từng mô hình theo PR-AUC độc lập của mô hình đó:

$$w_m^{\text{AP}} = \frac{\text{AP}_m}{\sum_{j=1}^{M}\text{AP}_j}, \qquad s_{\text{weighted soft}}(x) = \sum_{m=1}^{M} w_m^{\text{AP}} p_m(x).$$

Mô hình có PR-AUC cao hơn sẽ có ảnh hưởng lớn hơn đến điểm tổng hợp. Trong pipeline hiện tại, các AP_m được tính trên nhãn test nên kết quả này mang tính thăm dò.

4.2.4.4 Rank Weighted theo PR-AUC. Dùng cùng trọng số PR-AUC nhưng áp dụng lên thứ hạng phân vị thay vì xác suất:

$$s_{\text{rank weighted}}(x) = \sum_{m=1}^{M} w_m^{\text{AP}} r_m(x).$$

Phương pháp giữ thứ tự của từng mô hình và ưu tiên thứ hạng từ mô hình có PR-AUC cao hơn.

4.2.4.5 SLSQP Rank Averaging. Tìm trọng số không âm có tổng bằng một để tối đa PR-AUC của tổ hợp thứ hạng:

$$\mathbf{w}^* = \arg\max_{\mathbf{w}} \text{AP}\left(y, \sum_{m=1}^{M} w_m r_m\right), \qquad w_m \geq 0, \quad \sum_{m=1}^{M} w_m = 1.$$

Trong mã benchmark, phép tối ưu dùng một mẫu con tối đa 50.000 dòng lấy từ test, vì vậy trọng số SLSQP và kết quả đánh giá tương ứng không phải ước lượng ngoài mẫu độc lập.

4.2.4.6 Geometric Mean. Kết hợp xác suất bằng trung bình nhân. Một xác suất rất thấp từ một mô hình sẽ kéo giảm điểm tổng hợp:

$$s_{\text{geo}}(x) = \left(\prod_{m=1}^{M} \tilde{p}_m(x) \right)^{1/M}, \qquad \tilde{p}_m(x) = \min(1, \max(p_m(x), \epsilon)).$$

Việc chặn xác suất dưới bởi ϵ tránh lấy log của không trong triển khai tương đương.

4.2.4.7 Harmonic Mean. Trung bình điều hòa cũng nhấn mạnh sự đồng thuận, với điểm tổng hợp thấp khi một hoặc nhiều mô hình dự đoán xác suất thấp:

$$s_{\text{harm}}(x) = \frac{M}{\sum_{m=1}^{M} 1/\tilde{p}_m(x)}, \qquad \tilde{p}_m(x) = \min(1, \max(p_m(x), \epsilon)).$$

4.2.4.8 Min Voting. Lấy xác suất nhỏ nhất trong các mô hình. Cấu hình này là mốc bảo thủ vì điểm dị thường chỉ cao khi các mô hình cùng cho điểm cao:

$$s_{\min}(x) = \min_{1 \le m \le M} p_m(x).$$

4.2.4.9 Max Voting. Lấy xác suất lớn nhất trong các mô hình. Cấu hình này là mốc nhạy vì một mô hình dự đoán cao cũng có thể làm điểm tổng hợp tăng:

$$s_{\max}(x) = \max_{1 \le m \le M} p_m(x).$$

4.2.5 Đối chứng các mốc dung hợp trên Expanded

Để so sánh các kỹ thuật đã nêu trên cùng không gian đặc trưng, Bảng 11 giữ lại bốn mô hình gốc và cấu hình có PR-AUC cao nhất trong từng kỹ thuật dung hợp. Đây là bảng tóm tắt các mốc dẫn đầu trong 24 cấu hình đã khảo sát trên T_{out} của Expanded.

Bảng 11: **Bốn Mô hình Gốc và Các Phương pháp Dung hợp Dẫn đầu theo PR-AUC trên Expanded**

Hạng	Mô hình / phương pháp	Kỹ thuật	PR-AUC	ROC-AUC	F_1	Precision	Recall
1	Quad Geometric Mean	Geometric Mean	**0,8458**	**0,9541**	0,8432	94,12%	76,38%
2	Quad Harmonic Mean	Harmonic Mean	**0,8457**	0,9537	0,8416	93,92%	76,25%
3	Pair Soft Voting (XGB + CAT)	Soft Voting	**0,8457**	0,9531	0,8441	94,78%	76,09%
4	Quad Equal Rank (Champion)	Rank Averaging	0,8452	**0,9540**	0,8419	93,73%	**76,42%**
5	Quad Weighted Rank	Rank Weighted	0,8452	0,9540	0,8420	93,75%	76,41%
6	Quad SLSQP Rank	Rank SLSQP	0,8452	0,9540	0,8419	93,74%	76,41%
7	Quad Weighted Soft Voting	Soft Voting Weighted	0,8449	0,9540	**0,8441**	94,76%	76,10%
8	Quad Min Probability	Min Voting	0,8439	0,9526	0,8380	94,02%	75,59%
9	XGBoost (Expanded)	Mô hình đơn	0,8432	0,9531	0,8358	93,35%	75,67%
10	Quad Max Probability	Max Voting	0,8409	0,9522	0,8438	94,69%	76,10%
11	LightGBM (Expanded)	Mô hình đơn	0,8384	0,9534	0,8366	93,60%	75,63%
12	HistGradientBoosting (Expanded)	Mô hình đơn	0,8380	0,9530	0,8358	95,74%	74,15%
13	CatBoost (Expanded)	Mô hình đơn	0,8376	0,9482	0,8409	93,93%	76,11%

Trên Expanded, Quad Geometric Mean đứng đầu PR-AUC với 0,8458, cao hơn XGBoost đơn 0,0026. Quad Harmonic Mean và Pair Soft Voting cùng đạt 0,8457, chỉ thấp hơn mốc đầu 0,0001, còn các cấu hình Rank Averaging và có trọng số đạt 0,8452. Như

vậy, nhiều kiểu gộp cho kết quả xếp hạng gần nhau, và mức tăng PR-AUC so với mô hình đơn tốt nhất là nhỏ, không phải một bước nhảy lớn. Cả bốn mô hình gốc đều có PR-AUC thấp hơn các cấu hình dung hợp đứng đầu, cho thấy trên Expanded việc kết hợp có thể khai thác khác biệt giữa dự đoán của các mô hình, dù bảng này chưa chứng minh từng mô hình đóng góp độc lập.

Xét điểm vận hành, Pair Soft Voting và Quad Weighted Soft Voting cùng đạt $F_1 =$ 0,8441, cao nhất trong bảng. Quad Equal Rank có Recall lớn nhất (76,42%), còn Quad Geometric Mean có ROC-AUC cao nhất (0,9541). Vì các chỉ số này phản ánh các khía cạnh khác nhau, không có một kỹ thuật duy nhất đứng đầu trên mọi tiêu chí. Các giá trị PR-AUC và thứ hạng ở đây được chọn, báo cáo trên cùng tập test, còn ngưỡng tối ưu F1 cũng dựa trên test, nên xem đây là đối chứng thăm dò. Muốn kết luận chính thức về lợi ích của dung hợp cần chọn kỹ thuật, trọng số và ngưỡng bằng validation rồi đánh giá một lần trên test độc lập.

4.3 Đánh giá Isolation Forest và K-Means trên Không gian Expanded

Không gian Expanded gồm 54 đặc trưng, trong đó có các biến bối cảnh và đặc trưng động học chuỗi thời gian/STL. K-Means tạo hồ sơ công trình từ trung bình và độ lệch chuẩn của các đặc trưng số Expanded (loại `building_id`) rồi mã hóa cụm one-hot. K được chọn trong khoảng 2–12 theo PR-AUC validation của XGBoost với bộ siêu tham số Expanded, $K = 12$ đạt cao nhất (0,8014), thấp hơn XGBoost Expanded cơ sở validation 0,0002. Isolation Forest được fit trên toàn bộ đặc trưng Expanded, loại `building_id`, điểm dị thường được đưa vào các mô hình có giám sát như một đặc trưng.

XGBoost, CatBoost, LightGBM và HistGradientBoosting đều dùng bộ siêu tham số Expanded đã tuning. Mỗi mô hình được so sánh ở bốn cấu hình: đặc trưng gốc, thêm điểm IF, thêm cụm K-Means, và thêm cả hai. Mười lăm phần trăm cuối của T_{in} được dành làm validation để chọn ngưỡng F_1, sau đó mô hình được huấn luyện lại trên toàn bộ T_{in} và đánh giá trên T_{out}. Bảng 12 tập trung vào hiệu quả của các đặc trưng bổ sung trong từng mô hình có giám sát, Isolation Forest độc lập không đưa vào bảng này.

Bảng 12: **So sánh các Đặc trưng Isolation Forest và K-Means trên Expanded**

Mô hình / cấu hình	**PR-AUC**	**ΔPR-AUC**	**ROC-AUC**	F_1	**Precision**	**Recall**
XGBoost (Expanded)	0,8432	0,0000	0,9531	0,8341	0,9099	0,7700
XGBoost + `iforest_score`	0,8426	-0,0006	0,9521	0,8362	0,9265	0,7620
XGBoost + K-Means	0,8430	-0,0001	0,9526	0,8324	0,9248	0,7568
XGBoost + IF + K-Means	0,8434	+0,0003	0,9527	0,8358	0,9223	0,7641
CatBoost (Expanded)	0,8376	0,0000	0,9482	0,8399	0,9435	0,7568
CatBoost + `iforest_score`	0,8349	-0,0027	0,9470	0,8353	0,9468	0,7472
CatBoost + K-Means	0,8366	-0,0010	0,9484	0,8367	0,9338	0,7580
CatBoost + IF + K-Means	0,8366	-0,0010	0,9486	0,8411	0,9365	0,7633
LightGBM (Expanded)	0,8384	0,0000	0,9534	0,8282	0,8869	0,7767
LightGBM + `iforest_score`	0,8443	+0,0058	0,9545	0,8399	0,9587	0,7473
LightGBM + K-Means	0,8433	+0,0049	0,9531	0,8436	0,9404	0,7650
LightGBM + IF + K-Means	0,8420	+0,0035	0,9525	0,8378	0,9202	0,7690
HistGradientBoosting (Expanded)	0,8380	0,0000	0,9530	0,8331	0,9254	0,7576
HistGradientBoosting + `iforest_score`	0,8393	+0,0014	0,9537	0,8344	0,9271	0,7585
HistGradientBoosting + K-Means	0,8409	+0,0030	0,9532	0,8374	0,9350	0,7583
HistGradientBoosting + IF + K-Means	0,8388	+0,0008	0,9532	0,8354	0,9297	0,7585

PR-AUC cho thấy hai đặc trưng bổ sung không tạo hiệu quả đồng nhất giữa các

mô hình. LightGBM hưởng lợi rõ nhất: thêm IF tăng PR-AUC 0,0058 lên 0,8443, còn K-Means tăng 0,0049 lên 0,8433. Với IF, LightGBM đồng thời tăng Precision từ 0,8869 lên 0,9587 và giảm Recall từ 0,7767 xuống 0,7473, tức cải thiện thứ hạng đi kèm điểm vận hành thận trọng hơn. HistGradientBoosting cũng tăng PR-AUC 0,0014 với IF và 0,0030 với K-Means. Với XGBoost, mỗi đặc trưng riêng lẻ làm PR-AUC giảm nhẹ, còn tổ hợp tăng rất ít, 0,0003. Cả ba biến thể đều làm PR-AUC CatBoost giảm từ 0,8376 xuống mức 0,8349–0,8366. Một cách giải thích phù hợp với kết quả là điểm IF và hồ sơ cụm cung cấp thêm tín hiệu cho LightGBM và HistGradientBoosting, còn với XGBoost và CatBoost chúng có thể trùng lặp với tín hiệu đã học hoặc thêm nhiễu, nhưng bảng này chưa đủ để khẳng định cơ chế nhân quả. Các mức thay đổi của F_1 cũng phụ thuộc ngưỡng, nên cần đọc cùng Precision và Recall. Kết quả ủng hộ việc đánh giá đặc trưng bổ sung theo từng mô hình thay vì giả định một kỹ thuật có lợi đồng đều.

5 Triển khai Học Sâu

5.1 Thiết kế Pipeline Học Sâu Tổng thể

Phần Học sâu được hiện thực trong thư mục `model_DL/` (các tệp `config.py`, `models.py`, `prepare_chunked_data.py`, `chunked_data.py`, `chunked_pipeline.py`). Pipeline gồm bốn giai đoạn, cùng khung với phần Học máy (tiền xử lý → huấn luyện từng mô hình → tối ưu → dung hợp) để hai phần có thể đặt cạnh nhau. Khác với phiên bản đầu của pipeline (dựng lại lưới giờ từ dữ liệu thô), phiên bản cuối **dùng chung ba bộ dữ liệu đã chia theo mùa vụ của phần Học máy** (Baseline, Zone, Context; Chương 3) và chỉ gắn thêm cột `timestamp`, nên mọi mô hình Học sâu và Học máy được chấm trên cùng 372.993 dòng ngoài mẫu T_{out}. Mỗi giai đoạn ghi rõ nội dung **đã triển khai** trong mã nguồn và nội dung **chưa triển khai** (hướng mở rộng), để báo cáo không mô tả quá những gì đã chạy.

Pipeline tuân theo bốn nguyên tắc thiết kế:

1. **Hai lớp đánh giá tách biệt:** (i) trong T_{in} (ngày 1–20 hằng tháng), mọi mô hình được kiểm định bằng `GroupKFold` 5 phần theo `building_id`, vì các giờ liền kề của cùng một toà nhà rất giống nhau và chia ngẫu nhiên theo dòng sẽ làm kết quả lạc quan; (ii) T_{out} (ngày 25 đến hết tháng, cách T_{in} khoảng đệm 96 giờ) chỉ dùng để chấm điểm cuối, không dùng để huấn luyện, chọn checkpoint hay chọn ngưỡng. Lưu ý T_{out} chứa cùng 200 toà nhà với T_{in} nhưng ở các ngày sau, nên đây là phép kiểm tra **theo thời gian**, không phải toà nhà chưa từng thấy.

2. **Chỉ dùng đặc trưng đã tiền xử lý không rò rỉ và chuẩn hoá lại trong từng fold:** đặc trưng chunked đã được khớp thống kê trên T_{in}; thêm vào đó, trung vị, trung bình và độ lệch chuẩn của mỗi kênh được ước lượng lại trên các toà nhà huấn luyện của fold đó.

3. **Đầu ra là điểm liên tục:** mọi mô hình trả về điểm bất thường theo từng giờ (xác suất hoặc sai số tái tạo), không nhị phân hoá; ngưỡng chỉ được áp dụng khi tính F1.

4. **Khảo sát nhiều hệ hình:** một mô hình theo điểm (MLP) làm đối chứng, ba bộ gán nhãn chuỗi có giám sát (TCN, BiGRU, BiLSTM) và một mô hình tái tạo không giám sát (LSTM-AE), mỗi mô hình chạy trên cả ba biến thể dữ liệu.

1. **Giai đoạn 1: Chuẩn bị dữ liệu chunked, Kiểm định và Dựng chuỗi**

   - **Đã triển khai:** `prepare_chunked_data.py` đọc `train_features.csv` chỉ để lấy `timestamp`, kiểm tra thứ tự dòng khớp với `building_id`, `anomaly` và sáu đặc trưng thời gian, rồi ghi sáu tệp `*_chunked_{baseline,zone,context}_timestamp.parq` vào `data/processed_DL/`. Mọi cột và giá trị gốc được giữ nguyên (chỉ thêm một cột); mã băm SHA-256 và số dòng được ghi trong `chunked_timestamp_metadata.json` và được kiểm tra lại mỗi lần nạp.
   - **Đã triển khai:** `chunked_data.py` kiểm tra số dòng và số cột khớp bản kê, không có giá trị rỗng ở `building_id`, `timestamp`, `anomaly`, không trùng cặp (toà nhà, giờ), nhãn nhị phân, mọi giá trị số hữu hạn, và các dòng train chỉ rơi vào ngày ≤ 20, test chỉ vào ngày ≥ 25.
   - **Đã triển khai:** cắt mỗi toà nhà thành các đoạn *đích* dài 168 giờ (một tuần), bước nhảy 168, kèm tối đa 252 giờ *ngữ cảnh* đứng trước. Ngữ cảnh **không vượt qua chỗ đứt giờ**: vì T_{in} và T_{out} là các khối ngày trong từng tháng, chuỗi của mỗi toà nhà gồm nhiều đoạn liên tục, và cửa sổ được đặt lại ở mỗi chỗ đứt (đệm số 0 ở đầu cửa sổ). Mỗi giờ là đích đúng một lần nên mỗi dòng được chấm điểm một lần; mã kiểm tra và báo lỗi nếu có dòng bị bỏ sót hoặc lặp.
   - **Loại bỏ có chủ đích:** `building_id`, `timestamp`, nhãn, và nhóm `gte_*` vì nguồn gốc và ánh xạ chưa được xác minh an toàn. `site_id` được giữ làm biến phân loại.

2. **Giai đoạn 2: Huấn luyện rời rạc từng Mô hình (Baseline Modeling)**

   - **Đã triển khai:** huấn luyện độc lập năm mô hình trên từng biến thể dữ liệu, theo cùng bộ fold: MLP (theo điểm), TCN nhân quả, BiGRU, BiLSTM (gán nhãn chuỗi có giám sát) và LSTM Autoencoder (tái tạo, chỉ học từ giờ bình thường).
   - **Đã triển khai:** mỗi fold huấn luyện với AdamW, dừng sớm sau 5 epoch không cải thiện, và **chọn checkpoint theo Average Precision (AP) trên fold kiểm định**. Điểm ngoài mẫu (*out-of-fold*, OOF) được ghép từ 5 fold, đồng thời mỗi checkpoint chấm luôn T_{out}.
   - **Đã triển khai:** báo cáo AP, ROC-AUC, F1 tại ngưỡng chọn trên OOF, cùng AP và ROC-AUC trung bình theo toà nhà, cho cả OOF và T_{out}.

3. **Giai đoạn 3: Tối ưu hoá từng Mô hình**

   - **Đã triển khai:** xử lý mất cân bằng bằng `BCEWithLogitsLoss` có trọng số lớp dương $w_+ = 20$, cắt gradient ở 1,0, điều chuẩn bằng dropout 0,2 và weight decay 10^{-4}, chọn checkpoint theo AP kiểm định.
   - **Đã triển khai:** ngưỡng F1 được chọn trên điểm OOF của T_{in} (200 phân vị) rồi **áp nguyên cho T_{out}**, nên F1 trên T_{out} là ước lượng không dùng nhãn của tập kiểm tra để chọn ngưỡng.
   - **Chưa triển khai (hướng mở rộng):** tìm siêu tham số bằng Optuna, so sánh BCE có trọng số với Focal Loss, quét w_+, chạy nhiều seed.

4. **Giai đoạn 4: Dung hợp Mô hình (Model Ensemble)**

- **Đã triển khai:** điểm trên T_{out} của mỗi mô hình là trung bình điểm của 5 checkpoint fold. Dung hợp giữa các mô hình bằng trung bình hạng phần trăm (*percentile-rank*) với trọng số bằng nhau, phù hợp cả với xác suất của bộ phân loại lẫn sai số tái tạo có thang đo khác. Phép tính này được thực hiện bằng một đoạn mã hậu xử lý trên các tệp `oof_<model>.parquet` và `holdout_<model>.parquet`; lệnh `chunked_pipeline` hiện chưa có bước dung hợp.
- **Chưa triển khai (hướng mở rộng):** trọng số học được và dung hợp với các mô hình Boosting của phần Học máy.

5.2 Huấn luyện và Đánh giá Mô hình

5.2.1 Cơ sở Phương pháp luận: Mục tiêu Đầu ra, Tiêu chí Lựa chọn và Quy trình Thực hiện

5.2.1.1 1. Mục đích Đầu ra của Bài toán (Output Objective):

Tại mỗi giờ i của một toà nhà, mô hình trả về một điểm bất thường liên tục $s_i \in \mathbb{R}$. Với bộ phân loại có giám sát (MLP, TCN, BiGRU, BiLSTM), đó là xác suất:

$$s_i = \hat{p}_i = \sigma(z_i) = P(y_i = 1 \mid \text{ngữ cảnh}_i) \in [0, 1] \tag{1}$$

với z_i là logit đầu ra. Với LSTM Autoencoder, đó là sai số tái tạo bình phương trung bình trên các kênh đầu vào:

$$s_i = \frac{1}{d} \sum_{j=1}^{d} (\hat{x}_{i,j} - x_{i,j})^2 \tag{2}$$

trong đó d là số kênh đầu vào của biến thể đang xét (28, 31 hoặc 35). Điểm liên tục cho phép đánh giá không phụ thuộc ngưỡng bằng AP và ROC-AUC, và cho phép dung hợp mềm bằng hạng phần trăm. Khi cần nhãn nhị phân, quyết định là $\hat{y}_i = \mathbb{1}[s_i \geq \tau]$.

Hệ thống đánh giá theo ba độ đo:

- **PR-AUC** (*average precision*, AP; cùng định nghĩa `average_precision_score` của `scikit-learn` như phần Học máy), độ đo chính vì nhạy với lớp hiếm. Một mô hình đoán ngẫu nhiên có AP xấp xỉ tỷ lệ bất thường: 2,03% trên T_{in} và 2,45% trên T_{out}.
- **ROC-AUC**, độ đo xếp hạng không phụ thuộc ngưỡng và tỷ lệ lớp.
- **F1-Score** tại ngưỡng cực đại hoá F1 trên 200 phân vị của điểm trong OOF:

$$\tau^* = \arg\max_{\tau} \frac{2\,\text{Precision}(\tau)\,\text{Recall}(\tau)}{\text{Precision}(\tau) + \text{Recall}(\tau)}, \qquad F_1^{\max} = F_1^{\text{OOF}}(\tau^*) \tag{3}$$

  Trên OOF, $F_1^{\max}$ là **cận trên mang tính chẩn đoán** vì ngưỡng được chọn ngay trên dữ liệu đang chấm điểm. Trên T_{out}, nhóm báo cáo $F_1(\tau^*)$ với đúng τ^* lấy từ OOF, không điều chỉnh theo nhãn của T_{out}, nên đây là ước lượng F1 gần với triển khai thực tế.

Ngoài các độ đo gộp, nhóm tính AP và ROC-AUC **theo từng toà nhà** rồi lấy trung bình (macro) trên các toà nhà có cả hai lớp (198 toà ở OOF, 189 toà ở T_{out}), để thấy mô hình có hoạt động đều giữa các toà nhà hay chỉ tốt ở một vài toà.

5.2.1.2 2. Tiêu chí Lựa chọn Thuật toán:

- **Tiêu chí 1 - Khai thác được ngữ cảnh thời gian.** Nhiều bất thường chỉ nhận ra khi đặt giá trị đo trong mức tải thông thường của toà nhà theo giờ, thứ trong tuần và các giờ lân cận; ngữ cảnh 252 giờ (hơn một tuần) được cấp cho các mô hình chuỗi để chúng so sánh với chu kỳ tuần.
- **Tiêu chí 2 - Tận dụng nhãn nhưng chịu được mất cân bằng.** Nhãn bất thường chỉ chiếm khoảng 2–2,5%; hàm mất mát có trọng số lớp được dùng thay cho SMOTE, vì nội suy giữa hai đoạn bất thường tạo ra chuỗi không có thật.
- **Tiêu chí 3 - Đa dạng hệ hình.** Năm mô hình đại diện bốn hệ hình khác nhau: theo điểm (MLP), tích chập nhân quả (TCN), hồi quy hai chiều (BiGRU, BiLSTM) và tái tạo không giám sát (LSTM-AE). Sự đa dạng này vừa phục vụ so sánh, vừa là điều kiện để dung hợp có ý nghĩa.
- **Tiêu chí 4 - Khả thi về tính toán.** Mỗi lần chạy đầy đủ gồm 3 biến thể × 5 mô hình × 5 fold, trên khoảng 1,15 triệu dòng huấn luyện; mô hình phải huấn luyện được trên GPU phổ thông (nhóm dùng batch 16 cho các mô hình chuỗi và batch 1024 cho MLP).

5.2.1.3 3. Các Bước Thực hiện Tuần tự trong Luồng Học Sâu (Execution Workflow):

Toàn bộ thực nghiệm chạy từ thư mục gốc của repo:

- **Bước 1 (Gắn thời gian):** `python -m model_DL.prepare_chunked_data` tạo sáu tệp parquet có `timestamp` và `chunked_timestamp_metadata.json`. Tệp đầu ra không bao giờ bị ghi đè.
- **Bước 2 (Chạy thử nhanh):** `python -m model_DL.chunked_pipeline train --smoke` (chọn 8 toà nhà, 2 fold, 1 epoch) để kiểm tra toàn bộ đường ống trước khi chạy dài.
- **Bước 3 (Huấn luyện và đánh giá đầy đủ):** `python -m model_DL.chunked_pipeline train` chạy 3 biến thể × 5 mô hình × 5 fold. Với mỗi mô hình và mỗi fold: khớp `FoldTransformer` trên các toà nhà huấn luyện, huấn luyện, chọn checkpoint theo AP, chấm OOF trên các toà nhà kiểm định và đồng thời chấm T_{out}.
- **Bước 4 (Tiếp tục khi bị gián đoạn):** thêm `--run-id <id> --resume`; các fold đã hoàn tất được dùng lại từ bộ nhớ đệm (`fold_<n>_<model>.npz`) sau khi kiểm tra độ phủ và giá trị hữu hạn. Mọi tệp (checkpoint, lịch sử epoch, dự đoán, bảng tổng kết) được ghi nguyên tử (ghi vào tệp tạm rồi đổi tên) và hệ điều hành bị chặn tự ngủ trong lúc chạy.
- **Bước 5 (Tính lại độ đo):** `python -m model_DL.chunked_pipeline evaluate --run-id <id>` tính lại độ đo từ các tệp OOF và T_{out} đã lưu.

Các sản phẩm của mỗi lần chạy nằm trong `model_DL/artifacts/chunked/<run-id>/`: `run_config.json`, `summary.csv`, và với mỗi biến thể: `variant_config.json`, `checkpoints/<model>/f` `logs/history_<model>_fold_<n>.csv`, `logs/metrics_<model>.json`, `predictions/oof_<model>.pa` và `predictions/holdout_<model>.parquet`. Các bảng kết quả bên dưới được điền từ `summary.csv`, `metrics_<model>.json` và hai tệp dự đoán nói trên của lần chạy `full_local_20261028`.

5.2.2 Dữ liệu Đầu vào và Giao thức Đánh giá

5.2.2.1 1. Bộ đặc trưng đầu vào:

Mô hình nhận ba biến thể dữ liệu lồng nhau (Bảng 13); số kênh đầu vào là số đặc trưng số cộng một kênh cho `site_id`, tức 28, 31 và 35 kênh. Các kênh số được chuẩn hoá lại bằng $(x - \mu)/\sigma$ với μ, σ tính trên các toà nhà huấn luyện của fold (trung vị dùng để thay giá trị khuyết). Biến phân loại `site_id` được mã hoá thứ tự rồi chia cho số lớp (không dùng embedding); lớp chưa gặp ở fold huấn luyện nhận mã 0.

Bảng 13: **Các nhóm đặc trưng đầu vào của mô hình Học sâu theo ba biến thể**

Nhóm	**Số kênh**	**Nội dung**
Cơ sở (Baseline)	27	`meter_reading`, `square_feet`, `year_built`, `floor_count`, 7 biến thời tiết (`air_temperature`, `cloud_coverage`, `dew_temperature`, `precip_depth_1_hr`, `sea_level_pressure`, `wind_direction`, `wind_speed`), 8 thống kê trễ của nhiệt độ (`air_temperature_{mean,max,min,std}_lag7` và `lag73`), `is_holiday`, sin / cos của giờ, thứ, tháng, `meter_reading_was_missing`
Zone (thêm vào Baseline)	+3	`zone_interaction`, `site_sqft_mean`, `use_sqft_mean`
Context (thêm vào Zone)	+4	`z_meter_local`, `z_meter_workday`, `z_meter_robust`, `temp_load_inter`
Biến phân loại	+1	`site_id` (mã hoá thứ tự)
Tổng số kênh đầu vào	Baseline 28 | Zone 31 | Context 35	

Cần lưu ý ba điểm. (i) `square_feet`, `year_built`, `floor_count` và `site_id` gần như nhận diện được từng toà nhà; khi kiểm định bằng `GroupKFold` điều này không gây rò rỉ (toà nhà kiểm định chưa từng thấy), nhưng T_{out} chứa chính các toà nhà đã huấn luyện, nên trên T_{out} các kênh này giúp mô hình nhận ra từng toà. (ii) Bốn đặc trưng ngữ cảnh z của biến thể Context được tính từ thống kê theo toà nhà–giờ khớp trên toàn bộ T_{in} *trước* khi chia fold, nên kết quả OOF của biến thể này chỉ mang tính thăm dò; số liệu trên T_{out} không bị ảnh hưởng. (iii) Các nhóm `gte_*` bị loại khỏi đầu vào.

5.2.2.2 2. Giao thức đánh giá `GroupKFold` theo toà nhà trên T_{in}:

- 200 toà nhà của T_{in} (1.147.089 dòng) được chia thành 5 nhóm không giao nhau; mỗi lượt dùng 4 nhóm để huấn luyện và nhóm còn lại để kiểm định. Mỗi toà nhà xuất hiện làm kiểm định đúng một lần, nên ghép 5 lượt cho OOF phủ toàn bộ dòng của T_{in}.
- Bộ phân chia của `GroupKFold` là tất định theo `building_id`, nên các mô hình khác (kể cả mô hình Học máy) có thể tái tạo đúng cùng các fold.
- Mã dựng chuỗi kiểm tra và báo lỗi nếu một lượt chia cắt ngang một toà nhà, để loại trừ rò rỉ do cửa sổ chồng lấp giữa huấn luyện và kiểm định; mỗi fold bắt buộc có cả hai lớp ở cả tập huấn luyện lẫn kiểm định.

- T_{out} (372.993 dòng) được chấm bằng trung bình điểm của 5 checkpoint fold; T_{out} không tham gia huấn luyện, chọn checkpoint hay chọn ngưỡng.

5.2.2.3 3. Điểm khác so với giao thức của phần Học máy:

Hai phần giờ dùng cùng các dòng, cùng nhãn và cùng giá trị đặc trưng đã chuẩn hoá, và cùng chấm trên T_{out}, nên PR-AUC và ROC-AUC trên T_{out} đặt cạnh nhau được. Bảng 14 nêu các khác biệt còn lại. Điều quan trọng là phần Học máy tinh chỉnh siêu tham số và chọn ngưỡng **trực tiếp trên T_{out}** (hàm mục tiêu Optuna trong `pipeline_master_unified.py` là PR-AUC trên T_{out}), nên các số của Học máy là **cận trên**, đặc biệt F1, precision và recall của hai phần không so sánh trực tiếp được; phía Học sâu không dùng nhãn T_{out} ở bất kỳ bước nào trước khi chấm.

Bảng 14: **Khác biệt về giao thức đánh giá giữa phần Học máy và Học sâu**

Khía cạnh	**Học máy**	**Học sâu**
Dữ liệu	Ba bộ chunked (Baseline, Zone, Context)	Cùng ba bộ, thêm cột `timestamp`
Tập chấm điểm cuối	T_{out}, 372.993 dòng	T_{out}, 372.993 dòng
Chọn mô hình / siêu tham số	Optuna tối đa hoá PR-AUC **trên T_{out}**	Checkpoint theo AP trên fold kiểm định của `GroupKFold` 5 phần theo toà nhà trong T_{in}
Chọn ngưỡng	Cực đại hoá F1 trên T_{out} (cận trên)	Cực đại hoá F1 trên OOF của T_{in}, áp nguyên cho T_{out}
Độ đo chính	PR-AUC (kèm ROC-AUC, F1)	AP (cùng định nghĩa, kèm ROC-AUC, F1)
Đơn vị dự đoán	Từng dòng, không ngữ cảnh chuỗi	Từng giờ, có ngữ cảnh tối đa 252 giờ trong cùng đoạn liên tục
Điểm trên T_{out}	Một mô hình huấn luyện trên toàn T_{in}	Trung bình 5 checkpoint fold
Biến nhận diện toà nhà	Có	Có (và T_{out} dùng lại đúng các toà nhà đó)

5.2.3 Đặc tả Kiến trúc và Siêu tham số

Các mô hình dùng chung cấu hình trong `config.py`: `hidden_size` $= 64$, `num_layers` $= 2$, `dropout` $= 0{,}2$, `tcn_channels` $= 64$, nhân tích chập $k = 3$ và độ giãn nở $(1, 2, 4, 8, 16, 32)$. Số tham số trong Bảng 15 được đếm trực tiếp từ các mô hình được xây dựng bởi `build_model` với số kênh đầu vào $C = 28$, 31 và 35; số tham số chỉ thay đổi theo C qua lớp đầu vào.

Bảng 15: **Đặc tả kiến trúc các mô hình Học sâu** (C = số kênh đầu vào)

Mô hình	Kiến trúc	Đầu vào / Đầu ra	Baseline	Zone	Context
MLP	$C \to 128 \to 64 \to 1$; LayerNorm, GELU, dropout 0,2	Một giờ → một logit	12.289	12.673	13.185
TCN nhân quả	6 khối dư, mỗi khối hai tích chập giãn nở nhân quả ($k = 3$, 64 kênh), GroupNorm, GELU, dropout; đầu tích chập 1×1	$420 \times C \to 168$ logit (lấy 168 giờ cuối)	144.001	144.769	145.793
BiGRU	GRU hai chiều 2 tầng, 64 đơn vị mỗi chiều; dropout rồi tầng tuyến tính $128 \to 1$	$420 \times C \to 168$ logit	110.721	111.873	113.409
BiLSTM	Như BiGRU, thay GRU bằng LSTM	$420 \times C \to 168$ logit	147.585	149.121	151.169
LSTM-AE	Bộ mã hoá LSTM ($C \to 64$), bộ giải mã LSTM ($64 \to 64$), tầng tuyến tính $64 \to C$	$420 \times C \to$ tái tạo $168 \times C$	59.164	60.127	61.411

5.2.3.1 Vùng nhìn của TCN. Với $k = 3$ và hai tích chập giãn nở mỗi khối, vùng nhìn là $R = 1 + 2(k-1)\sum_\ell d_\ell = 1 + 2 \cdot 2 \cdot 63 = 253$ giờ. Giá trị này khớp với 252 giờ ngữ cảnh cộng giờ hiện tại, nên giờ đích đầu tiên của mỗi đoạn nhìn được trọn vẹn phần ngữ cảnh (khi đoạn liên tục đủ dài).

5.2.3.2 Huấn luyện. Tối ưu AdamW với tốc độ học 10^{-3} (không dùng bộ lập lịch), weight decay 10^{-4}, batch 1024 cho MLP và 16 cho các mô hình chuỗi, dừng sớm sau 5 epoch không cải thiện AP kiểm định, chạy với độ chính xác hỗn hợp tự động khi có GPU, hạt giống ngẫu nhiên $42 +$ chỉ số fold. Số epoch tối đa của lần chạy chính thức là 10; lần chạy được khởi động với trần 30 epoch rồi hạ xuống 10 khi tiếp tục (`--resume`), và các fold đã hoàn tất trước đó giữ nguyên checkpoint của chúng. Vì vậy một số fold của MLP trên biến thể Baseline chọn epoch tốt nhất ở các epoch 13–20 (lớn hơn 10). Hàm mất mát của các mô hình có giám sát là:

$$\mathcal{L} = \frac{\sum_i m_i \cdot [-w_+ \, y_i \log \hat{p}_i - (1 - y_i) \log(1 - \hat{p}_i)]}{\sum_i m_i}, \qquad w_+ = 20 \tag{4}$$

với m_i là mặt nạ của các giờ đích hợp lệ (ở các đoạn đích ngắn, phần đệm bị loại). LSTM-AE tối thiểu hoá MSE tái tạo **chỉ trên các giờ đích bình thường** ($y_i = 0$) và dùng MSE của mọi giờ đích làm điểm bất thường. MLP không dùng ngữ cảnh chuỗi nên chỉ nhìn đặc trưng của đúng giờ đó (kể cả các đặc trưng ngữ cảnh z của biến thể Context).

5.2.4 Luận giải việc Lựa chọn và Loại trừ các Thuật toán

1. Nhóm được hiện thực và vai trò của từng mô hình

- **MLP (đối chứng):** cho biết các đặc trưng đã sinh sẵn (nhất là các đặc trưng ngữ cảnh z) giải quyết được bao nhiêu bài toán *mà không cần mô hình chuỗi*. Nếu MLP ngang các mô hình chuỗi, lợi thế của kiến trúc chuỗi trên dữ liệu này nhỏ.
- **TCN nhân quả:** song song hoá được, huấn luyện nhanh, vùng nhìn tính trước được (253 giờ phủ chu kỳ tuần) và chỉ dùng quá khứ, nên đại diện cho kịch bản phát hiện gần thời gian thực.

- **BiGRU / BiLSTM:** dùng ngữ cảnh hai chiều trong cửa sổ 420 giờ, nên biết cả những giờ sau giờ đang xét trong cùng cửa sổ. Đổi lại chỉ dùng được ngoại tuyến. GRU ít tham số hơn LSTM; cả hai được giữ để so sánh.
- **LSTM Autoencoder:** đại diện hệ hình tái tạo không giám sát phổ biến trong các nghiên cứu phát hiện bất thường chuỗi thời gian, dùng làm mốc so sánh với hướng có giám sát.

2. Nhóm chưa hiện thực

- **GAN-LSTM / TAnoGAN:** có kết quả công bố trên LEAD nên có giá trị đối chiếu, nhưng mỗi cửa sổ cần khoảng 300 bước tối ưu vector tiềm ẩn khi suy luận. Chấm điểm từng giờ trên toàn bộ dữ liệu cần cỡ 10^8 lượt chạy bộ sinh, không khả thi trong khuôn khổ đề tài. Chỉ có thể tái hiện ở mức cửa sổ trên một tập con toà nhà.
- **USAD:** nhanh và ổn định hơn GAN, nhưng vẫn là hệ hình không giám sát và chưa có công bố trên dữ liệu năng lượng.
- **Anomaly Transformer, TranAD:** thiết kế cho chuỗi đa biến không giám sát với quy tắc đánh giá điều chỉnh theo đoạn; chỉ có 200 chuỗi nên rủi ro quá khớp cao.
- **Conv-AE, VAE:** cùng hệ hình tái tạo với LSTM-AE; thêm vào tăng chi phí mà không mở góc nhìn mới.
- **RNN thuần:** triệt tiêu gradient trên chuỗi dài hàng trăm bước; LSTM/GRU thay thế hoàn toàn.

Tiểu kết: lựa chọn dựa trên ba đặc tính của bài toán: dữ liệu có nhãn nhưng mất cân bằng nặng, bất thường gồm cả loại có giá trị đặc biệt lẫn loại phụ thuộc ngữ cảnh, và chỉ có 200 chuỗi toà nhà. Các nhận định về ưu thế của từng hệ hình được xem là giả thuyết, kiểm chứng ở bảng thí nghiệm bên dưới.

5.3 Kết quả Thực nghiệm Đánh giá

Lưu ý: Bảng 16, 17, 18, 20 và 22 được điền từ lần chạy đầy đủ `full_local_20261028` (`status = complete`, thiết bị `cuda`, 3 biến thể × 5 mô hình × 5 fold, seed 42). Thời gian chạy từng mô hình không được ghi lại trong các tệp kết quả nên báo cáo không nêu. Các ô `--` ở những bảng còn lại (Bảng 19 và 21) là thí nghiệm chưa chạy và **chưa có số liệu**.

5.3.0.1 1. So sánh hiệu năng các mô hình đơn:

Bảng 16: **So sánh hiệu năng các mô hình Học sâu trên OOF của T_{in} và trên T_{out}** (nguồn: `summary.csv`, `metrics_<model>.json`; F_1 trên T_{out} dùng ngưỡng τ^* chọn trên OOF; AP macro tính theo toà nhà)

		OOF (T_{in})			Ngoài mẫu T_{out}			
Biến thể	**Mô hình**	**AP**	**ROC-AUC**	$F_1^{\max}$	**AP**	**ROC-AUC**	$F_1(\tau^*)$	**AP macro**
Baseline	MLP	0,5757	0,8792	0,5977	0,4204	0,8192	0,4345	0,4059
Baseline	TCN nhân quả	**0,6154**	0,8751	**0,6385**	0,4576	0,8341	0,3587	0,4583
Baseline	BiGRU	0,5906	0,8762	0,6206	**0,5154**	**0,8699**	**0,4456**	**0,5246**
Baseline	BiLSTM	0,5724	0,8704	0,6074	0,4008	0,8511	0,2802	0,4559
Baseline	LSTM-AE	0,0234	0,5163	0,0460	0,0362	0,5819	0,0759	0,0548
Zone	MLP	0,5461	0,8639	0,5736	0,3960	0,8098	0,4094	0,3799
Zone	TCN nhân quả	**0,6167**	0,8791	**0,6468**	0,4915	0,8362	**0,4192**	0,4672
Zone	BiGRU	0,5736	0,8761	0,6091	**0,5152**	**0,8789**	0,4025	**0,5268**
Zone	BiLSTM	0,5612	0,8637	0,5951	0,4088	0,8511	0,2662	0,4586
Zone	LSTM-AE	0,0232	0,5380	0,0454	0,0335	0,5775	0,0663	0,0575
Context	MLP	0,5930	0,8996	0,5982	0,5305	0,8752	0,5329	0,4941
Context	TCN nhân quả	**0,6889**	0,9138	**0,6989**	0,6677	0,9233	0,6497	0,6392
Context	BiGRU	0,6774	**0,9233**	0,6782	**0,7535**	**0,9646**	**0,6794**	**0,7358**
Context	BiLSTM	0,6553	0,9098	0,6708	0,7402	0,9552	0,6639	0,7226
Context	LSTM-AE	0,0404	0,6491	0,0948	0,1107	0,8063	0,2284	0,2075

Ghi chú: một mô hình ngẫu nhiên có AP xấp xỉ 2,45% trên T_{out}, nên AP cao nhất (0,7535, BiGRU trên Context) gấp khoảng 31 lần mức ngẫu nhiên, còn LSTM-AE tốt nhất (0,1107) chỉ gấp khoảng 4,5 lần. In đậm là giá trị tốt nhất trong từng biến thể theo cột. Với OOF của biến thể Context cần nhớ lưu ý (ii) ở mục dữ liệu đầu vào. Điểm trên T_{out} là trung bình của 5 checkpoint; điểm AP trung bình của từng checkpoint riêng lẻ trên T_{out} (Context) là 0,716 (BiGRU), 0,676 (BiLSTM) và 0,641 (TCN), tức việc lấy trung bình fold cộng thêm khoảng 0,03 đến 0,06 AP.

5.3.0.2 2. Kết quả theo từng fold (biến thể Context):

Bảng 17: **ROC-AUC theo từng fold kiểm định, biến thể Context** (nguồn: mục `folds` trong `metrics_<model>.json`)

Mô hình	**Fold 0**	**Fold 1**	**Fold 2**	**Fold 3**	**Fold 4**
MLP	0,9319	0,8939	0,8854	0,9174	0,8727
TCN nhân quả	0,9328	0,8962	0,9239	0,9337	0,8845
BiGRU	0,9389	0,9124	0,9468	0,9651	0,9048
BiLSTM	0,9180	0,8912	0,9218	0,9528	0,8979
LSTM-AE	0,7204	0,6852	0,6831	0,7544	0,6929

Bảng 18: **AP theo từng fold kiểm định, biến thể Context** (nguồn: mục `folds` trong `metrics_<model>.json`)

Mô hình	Fold 0	Fold 1	Fold 2	Fold 3	Fold 4
MLP	0,6950	0,5661	0,5795	0,5770	0,5810
TCN nhân quả	0,7715	0,6208	0,7082	0,7024	0,6507
BiGRU	0,7746	0,6107	0,7316	0,7227	0,6189
BiLSTM	0,7436	0,5887	0,6863	0,6504	0,6210
LSTM-AE	0,0842	0,0544	0,0874	0,1081	0,0477

5.3.0.3 Nhận xét từ kết quả theo fold.

Vì mọi mô hình dùng cùng các fold, so sánh được thực hiện theo từng fold (so cặp) thay vì chỉ so trung bình:

- **Các mô hình chuỗi có giám sát hơn MLP.** TCN và BiGRU hơn MLP ở cả 5/5 fold theo cả ROC-AUC (TCN hơn từ 0,001 đến 0,039; BiGRU hơn từ 0,007 đến 0,061) lẫn AP. Điều này ủng hộ giả thuyết H1: ngữ cảnh 252 giờ có ích bên cạnh các đặc trưng ngữ cảnh z đã sinh sẵn. Trên T_{out}, khoảng cách còn rõ hơn: AP của MLP là 0,531, của BiGRU là 0,754.
- **BiGRU hơn TCN theo ROC-AUC, nhưng không chắc theo AP.** BiGRU cao hơn TCN ở cả 5/5 fold về ROC-AUC (hơn 0,006 đến 0,031). Về AP, BiGRU hơn ở 3/5 fold (fold 1: TCN hơn 0,010; fold 4: TCN hơn 0,032), và xếp hạng đảo chiều giữa OOF (TCN 0,689 so với BiGRU 0,677) và T_{out} (BiGRU 0,754 so với TCN 0,668), nên không kết luận được mô hình nào tốt hơn theo AP chỉ từ OOF.
- **BiGRU hơn BiLSTM:** cao hơn ở 5/5 fold theo ROC-AUC (hơn 0,007 đến 0,025) và 4/5 fold theo AP (fold 4 thua 0,002); trên T_{out} hai mô hình sít sao (AP 0,754 so với 0,740).
- **LSTM-AE kém xa** các mô hình có giám sát ở mọi biến thể (AP trên T_{out} từ 0,034 đến 0,111; ROC-AUC OOF trên Baseline và Zone gần 0,5, tức gần như ngẫu nhiên). Kết quả phù hợp với H2; việc giải thích nguyên nhân cần phân tích recall theo loại bất thường (H3).
- **Dao động giữa các fold lớn hơn nhiều khác biệt giữa mô hình ở AP.** Ví dụ AP của BiGRU dao động từ 0,611 (fold 1) đến 0,775 (fold 0). Vì vậy ranking theo một con số gộp cần được đọc cùng bảng theo fold. Kết quả theo fold của hai biến thể Baseline và Zone nằm trong `metrics_<model>.json` tương ứng, với độ biến thiên tương tự.
- **Tác dụng của đặc trưng ngữ cảnh.** Chuyển từ Baseline sang Context nâng AP của BiGRU trên T_{out} từ 0,515 lên 0,754 và ROC-AUC từ 0,870 lên 0,965, trong khi biến thể Zone gần như không đổi so với Baseline (AP 0,515 và 0,515). Mức tăng này có phần do đặc trưng z thông tin hơn trên T_{out} so với trên T_{in} (xem mục giới hạn).

5.3.0.4 3. Ảnh hưởng của hàm mất mát có trọng số lớp:

Thí nghiệm này chạy được bằng cách đổi `positive_class_weight` trong `config.py` (một mô hình chuỗi tốt nhất ở Bảng 16, biến thể Context, cùng các fold). **Chưa chạy trong lần thực nghiệm này.**

Bảng 19: **Ảnh hưởng của trọng số lớp dương w_+ trong hàm mất mát**

w_+	**ROC-AUC**	**AP**	$F_1^{\max}$
1	–	–	–
7	–	–	–
20 (mặc định)	–	–	–
45	–	–	–

5.3.0.5 4. Dung hợp Mô hình:

Điểm hạng phần trăm trung bình được tính trên các tệp OOF và T_{out} đã lưu, với trọng số bằng nhau; hạng của T_{out} được tính trong nội bộ T_{out}.

Bảng 20: **Hiệu năng ensemble hạng phần trăm trên OOF và T_{out}**

Biến thể	**Tổ hợp mô hình**	**OOF AP**	**OOF ROC-AUC**	**T_{out} AP**	**T_{out} ROC-AUC**
Baseline	MLP + TCN + BiGRU + BiLSTM	0,6213	0,8906	0,4541	0,8684
Baseline	Cả 5 mô hình (có LSTM-AE)	0,2862	0,8782	0,2578	0,8594
Baseline	TCN + BiGRU + BiLSTM	0,6173	0,8834	0,4535	0,8648
Baseline	Mô hình đơn tốt nhất (đối chiếu)	0,6154	0,8792	0,5154	0,8699
Zone	MLP + TCN + BiGRU + BiLSTM	0,6146	0,8868	0,4517	0,8699
Zone	Cả 5 mô hình (có LSTM-AE)	0,2854	0,8771	0,2551	0,8566
Zone	TCN + BiGRU + BiLSTM	0,6170	0,8834	0,4701	0,8696
Zone	Mô hình đơn tốt nhất (đối chiếu)	0,6167	0,8791	0,5152	0,8789
Context	MLP + TCN + BiGRU + BiLSTM	0,6852	0,9267	0,6534	0,9455
Context	Cả 5 mô hình (có LSTM-AE)	0,4682	0,9205	0,5971	0,9407
Context	TCN + BiGRU + BiLSTM	**0,7025**	**0,9267**	0,7150	0,9560
Context	BiGRU + BiLSTM	0,6832	0,9214	**0,7574**	0,9628
Context	Mô hình đơn tốt nhất (đối chiếu)	0,6889	0,9233	0,7535	**0,9646**

Ghi chú: "Mô hình đơn tốt nhất" lấy AP và ROC-AUC cao nhất trong số các mô hình đơn có giám sát của Bảng 16 (hai chỉ số có thể đến từ hai mô hình khác nhau). Ensemble chỉ hơn mô hình đơn khi các thành viên đều mạnh và cùng thang: trên OOF của Context, TCN + BiGRU + BiLSTM đạt AP 0,7025 so với 0,6889 của TCN. Thêm LSTM-AE làm AP rơi mạnh (OOF 0,2862 trên Baseline, 0,4682 trên Context), vì điểm hạng của một mô hình gần ngẫu nhiên làm nhiễu điểm của các mô hình tốt. Trên T_{out} của Context, BiGRU + BiLSTM chỉ hơn BiGRU đơn khoảng 0,004 AP, đủ nhỏ để chưa kết luận H5 chỉ từ một seed.

5.3.0.6 5. Phân tích lỗi theo loại bất thường:

Phân tích này dùng các tệp OOF cùng dữ liệu chunked, không cần huấn luyện lại. Tại ngưỡng cố định chung cho mọi mô hình, ta tính recall riêng cho hai nhóm: bất thường có `meter_reading` nhận giá trị đặc biệt (ví dụ 1,0 ở thang gốc) và các bất thường còn lại, cùng recall theo độ dài đoạn giá trị lặp. Vì `meter_reading` trong dữ liệu chunked đã được chuẩn hoá, việc xác định các nhóm này cần ánh xạ ngược về thang gốc; **chưa thực hiện trong lần thực nghiệm này**.

Bảng 21: **Recall theo loại bất thường tại ngưỡng cố định**

Mô hình	Recall: giá trị đặc biệt	Recall: đoạn lặp ≥ 3	Recall: còn lại
MLP	–	–	–
TCN nhân quả	–	–	–
BiGRU	–	–	–
BiLSTM	–	–	–
LSTM-AE	–	–	–

5.3.0.7 6. Bảng tổng kết sự tăng tiến điểm số qua các cấp độ (biến thể Context, trên T_{out}):

Bảng 22: **Sự tăng tiến hiệu năng của pipeline Học sâu qua các cấp độ** (biến thể Context, T_{out}; F_1 tại ngưỡng τ^* chọn trên OOF)

Cấp độ	Chiến thuật	Cấu hình	ROC-AUC	AP	F_1
Cấp độ 0	Biến thể Baseline, mô hình chuỗi tốt nhất	BiGRU, $w_+ = 20$	0,8699	0,5154	0,4456
Cấp độ 1	Mô hình theo điểm (đối chứng)	MLP, Context	0,8752	0,5305	0,5329
Cấp độ 2	Mô hình chuỗi đơn tốt nhất (chọn theo AP trên T_{out})	BiGRU, Context, $w_+ = 20$	0,9646	0,7535	0,6794
Cấp độ 3	Ensemble hạng phần trăm	BiGRU + BiLSTM, Context	0,9628	0,7574	–
Cấp độ 4	Tối ưu hoá mở rộng (chưa triển khai)	Optuna, Focal Loss, nhiều seed	–	–	–

5.3.0.8 Kết luận tạm thời.

(Dựa trên một lần chạy với một seed; Cấp độ 4 chưa có số liệu; F_1 của ensemble chưa tính.) Từ Bảng 16, 17, 18 và 20:

- Trên T_{out}, mô hình Học sâu tốt nhất là BiGRU trên biến thể Context (AP 0,754, ROC-AUC 0,965, $F_1 = 0{,}679$ tại ngưỡng chọn trên OOF); BiLSTM đứng sát (0,740 AP) và TCN thấp hơn (0,668 AP) dù xếp đầu trên OOF.
- Trên Baseline và Zone, mọi mô hình Học sâu có AP trên T_{out} chỉ từ 0,40 đến 0,52; mức tăng lớn đến từ đặc trưng ngữ cảnh z của Context chứ không từ kiến trúc, và các đặc trưng z này đúng là mạnh hơn trên T_{out} (xem giới hạn 7).
- Chuyển từ MLP sang mô hình chuỗi trên Context tăng AP khoảng 0,14 (TCN) đến 0,22 (BiGRU) và ROC-AUC khoảng 0,05 đến 0,09 trên T_{out}; trên OOF mức cải thiện nhất quán ở cả 5/5 fold. Đây không phải sai số ngẫu nhiên.
- Bộ gán nhãn chuỗi có giám sát vượt rõ LSTM-AE không giám sát (0,965 so với 0,806 ROC-AUC trên T_{out} ở Context).

- T_{out} cùng tập với phần Học máy, nên AP và ROC-AUC so sánh được: trên Context, BiGRU (AP 0,754, ROC-AUC 0,965) cao hơn ensemble Học máy tốt nhất (PR-AUC 0,695, ROC-AUC 0,897); trên Baseline và Zone, Học máy cao hơn (PR-AUC khoảng 0,64 so với 0,52). Các số của Học máy là cận trên vì được tinh chỉnh và chọn ngưỡng trên chính T_{out}, còn F_1, precision và recall của hai phần chưa so sánh trực tiếp được.

5.4 Giới hạn của Hiện thực và Hướng Mở rộng

Khi đối chiếu mã nguồn với thiết kế, nhóm ghi nhận các giới hạn sau để diễn giải kết quả cho đúng mức:

1. **Chọn checkpoint trên fold đang chấm (OOF):** checkpoint tốt nhất của mỗi fold được chọn theo AP trên chính fold kiểm định dùng để báo cáo OOF, tạo thiên lệch lạc quan nhỏ ở các cột OOF. Các cột T_{out} không chịu thiên lệch này vì T_{out} không tham gia chọn checkpoint.

2. $F_1^{\max}$ **trên OOF là cận trên:** ngưỡng được chọn trên chính OOF; $F_1(\tau^*)$ trên T_{out} dùng ngưỡng đó và là ước lượng gần với thực tế, nhưng ngưỡng chọn trên T_{in} có thể lệch khi tỷ lệ bất thường của T_{out} khác (2,45% so với 2,03%).

3. **OOF gộp từ nhiều checkpoint:** điểm của các fold đến từ 5 checkpoint khác nhau, nên thang điểm có thể lệch giữa fold, nhất là với LSTM-AE. AP và ROC-AUC gộp có thể khác trung bình theo fold; bảng nên báo cả hai.

4. **Chuẩn hoá nhóm trong TCN:** lớp `GroupNorm` chuẩn hoá theo toàn bộ trục thời gian của đoạn, nên về nguyên tắc thông tin của giờ sau có thể ảnh hưởng đến giờ trước trong cùng cửa sổ. Phần tích chập vẫn nhân quả, nhưng khẳng định "chỉ dùng quá khứ" cần kiểm tra bằng thí nghiệm đổi giá trị tương lai.

5. **LSTM-AE không có điểm thắt (bottleneck):** bộ mã hoá xuất chuỗi 64 chiều ở mọi bước và bộ giải mã nhận chuỗi này, nên mô hình có thể học gần như phép đồng nhất. Đầu vào chứa cả `meter_reading` nên mô hình có thể tái tạo tốt cả giá trị bất thường. Cần xem xét vector tiềm ẩn nhỏ hơn hoặc nhiễu đầu vào.

6. **Một seed duy nhất và trần epoch không đồng nhất:** cấu hình dùng seed 42 (cộng chỉ số fold). Báo cáo chênh lệch nhỏ cần chạy tối thiểu 3 seed. Ngoài ra lần chạy được khởi động với trần 30 epoch rồi hạ xuống 10 khi tiếp tục, nên một số fold của MLP trên Baseline huấn luyện lâu hơn các fold còn lại.

7. **Phân phối đặc trưng ngữ cảnh** z **khác nhau giữa** T_{in} **và** T_{out}**:** AP của riêng `z_meter_local` là 0,209 trên T_{in} nhưng 0,370 trên T_{out} (tương tự với `z_meter_workday`: 0,228 và 0,364), nên AP của Học sâu trên Context cao hơn ở T_{out} so với OOF (Bi-GRU: 0,754 so với 0,677). Nhóm cho rằng nguyên nhân là các thống kê theo toà nhà–giờ được khớp trên T_{in} bao gồm cả chính các dòng đó và các điểm bất thường, làm điểm z của bất thường bị co lại trên T_{in} nhưng không bị co trên T_{out}; đây là giả thuyết, chưa được kiểm chứng riêng. Tỷ lệ bất thường cao hơn của T_{out} cũng góp phần nâng AP. Ảnh hưởng này áp dụng cho cả Học máy.

8. **Ensemble chưa tích hợp vào pipeline:** dung hợp được tính bằng đoạn mã hậu xử lý trên tệp dự đoán; chưa có lệnh trong `chunked_pipeline`, chưa có trọng số học được, và chưa dung hợp với mô hình Boosting.

9. **Chưa có Optuna, Focal Loss và giao thức mức cửa sổ:** đây là hướng mở rộng. Các thí nghiệm theo trọng số lớp (Bảng 19) và theo loại bất thường (Bảng 21) cũng chưa chạy.

5.5 Bộ Giả thuyết Kiểm chứng

Mỗi lựa chọn trong pipeline gắn với một giả thuyết có thể bác bỏ. Cột cuối cho biết thí nghiệm đã chạy, chạy được với mã hiện tại, hay cần chỉnh thêm.

Mã	**Giả thuyết**	**Thí nghiệm / đại lượng đo**	**Trạng thái**
H1	Mô hình chuỗi vượt MLP, tức ngữ cảnh 252 giờ có ích ngoài các đặc trưng đã sinh sẵn	So Cấp độ 1 và Cấp độ 2 (Bảng 22) và theo fold (Bảng 17, 18)	Đã chạy; được ủng hộ (5/5 fold)
H2	Mô hình có giám sát vượt LSTM-AE không giám sát	So AP và ROC-AUC cùng fold	Đã chạy; được ủng hộ
H3	LSTM-AE bỏ sót bất thường dạng phẳng vì chuỗi hằng dễ tái tạo	Recall theo loại bất thường (Bảng 21)	Chạy được (hậu xử lý OOF, cần ánh xạ ngược thang gốc)
H4	Ngữ cảnh hai chiều (BiGRU, BiLSTM) tốt hơn TCN nhân quả ở các đoạn lặp dài	So recall theo độ dài đoạn lặp	Chạy được (hậu xử lý OOF)
H5	Dung hợp tốt hơn mô hình đơn tốt nhất	Bảng 20	Đã chạy; ủng hộ một phần (hơn trên OOF, chênh nhỏ trên T_{out}, hại khi thêm LSTM-AE)
H6	Trọng số lớp dương làm tăng AP so với $w_+ = 1$	Bảng 19	Chạy được (đổi cấu hình)
H7	Các đặc trưng ngữ cảnh z của biến thể Context giúp mô hình	So biến thể Context với Zone và Baseline (Bảng 16)	Đã chạy; được ủng hộ (BiGRU: AP 0,515 → 0,754)
H8	Mô hình giảm hiệu năng khi chuyển sang giai đoạn sau (hoặc toà nhà chưa thấy)	So OOF theo toà nhà với T_{out} theo thời gian	Đã chạy một phần; Baseline/Zone giảm (AP 0,59 → 0,52), Context không giảm (xem giới hạn 7)
H9	Focal Loss tốt hơn BCE có trọng số	So AP cùng kiến trúc	Cần cài Focal Loss

6 So sánh Học Máy và Học Sâu: Thế mạnh và Điểm yếu

7 Kết luận và Hướng phát triển tương lai

7.1 Kết luận

7.2 Hướng phát triển Tương lai

Tài liệu

[1] **Bộ dữ liệu LEAD1.0 (Đối chiếu Mục 2.3.14):** Gulati, M., & Arjunan, P. (2022). LEAD1.0: A Large-scale Annotated Dataset for Energy Anomaly Detection in Commercial Buildings. *Proceedings of the 13th ACM International Conference on Future Energy Systems (e-Energy '22)*, 485–488. DOI: https://doi.org/10.1145/3538637.3539761

[2] **Lời giải Quán quân LEAD – Fu et al. (Đối chiếu Mục 2.3.1, Mục 2.3.2):** Fu, C., Arjunan, P., & Miller, C. (2022). Trimming outliers using trees: winning solution of the large-scale energy anomaly detection (LEAD) competition. *Proceedings of the 9th ACM International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation (BuildSys '22)*, 456–461. DOI: https://doi.org/10.1145/3563357.3566147

[3] **Khung xử lý ML trên LEAD – Buaprakhong et al. (Đối chiếu Mục 2.3.1, Mục 2.3.2, Mục 2.3.9):** Buaprakhong, T., Sithisint, V., Phusaensaart, A., Wilke, S., Boonchuntuk, T., Ganokratanaa, T., & Ketcham, M. (2026). An Integrated Framework of Feature Engineering and Machine Learning for Large-Scale Energy Anomaly Detection. *Energy Engineering*, 123(3), 1–35. DOI: https://doi.org/10.32604/ee.2026.069004

[4] **Dữ liệu ASHRAE GEPIII – Miller et al. (Đối chiếu Mục 2.3.1):** Miller, C., Arjunan, P., Kathirgamanathan, A., Fu, C., Roth, J., Park, J. Y., Balbach, C., Gowri, K., Nagy, Z., Fontanini, A., & Haberl, J. (2020). The ASHRAE Great Energy Predictor III competition: Overview and results. *Science and Technology for the Built Environment*, 26(10), 1427–1447. DOI: https://doi.org/10.1080/23744731.2020.1795514

[5] **Bộ dữ liệu BDG2 – Miller et al. (Đối chiếu Mục 2.3.1, Mục 3):** Miller, C., Kathirgamanathan, A., Picchetti, P., Arjunan, P., Park, J. Y., Nagy, Z., & Schiavon, S. (2020). The Building Data Genome Project 2, a open database of energy meter data from 3,053 non-residential buildings. *Scientific Data*, 7(1), 368. DOI: https://doi.org/10.1038/s41597-020-00715-x

[6] **Mô hình GAN-LSTM trên LEAD – Orvati Nia et al. (Đối chiếu Mục 2.2.4, Mục 2.3.7, Mục 2.3.10):** Orvati Nia, F., Salehi, S., & Peeples, J. (2026). Evaluating GAN-LSTM for Smart Meter Anomaly Detection in Power Systems. *IEEE Texas Power and Energy Conference (TPEC) 2026*. arXiv: https://arxiv.org/abs/2601.09701

[7] **Mô hình GAN và Tích chập không giám sát – Handigol & Arjunan (Đối chiếu Mục 2.2.3, Mục 2.3.6, Mục 2.3.11):** Handigol, P. P., & Arjunan, P. (2025). Generative Adversarial Networks for Unsupervised Anomaly Detection in Energy Time series data. *Hội thảo Tackling Climate Change with Machine Learning, ICLR 2025 (Climate Change AI)*. URL: https://www.climatechange.ai/papers/iclr2025/18

[8] **Soft-DTW và Tái tạo Song song – Prabhu et al. (Đối chiếu Mục 2.3.8, Mục 2.3.12):** Prabhu, H., Valadi, J., & Arjunan, P. (2024). Generative Adversarial Network with Soft-Dynamic Time Warping and Parallel Reconstruction for Energy

Time Series Anomaly Detection. *AI4TS Workshop, AAAI 2024*. arXiv: https://arxiv.org/abs/2402.14384

[9] **Phân cụm Tòa nhà và Học có Giám sát – Cansever & Konyar (Đối chiếu Mục 2.1, Mục 2.3.3, Mục 2.3.13):** Cansever, B. N., & Konyar, M. Z. (2026). A clustering-based supervised approach for anomaly detection in building energy consumption. *E3S Web of Conferences*, 727, 02012. DOI: https://doi.org/10.1051/e3sconf/202672702012

[10] **Mô hình XGBoost (Đối chiếu Mục 2.1.1, Mục 2.3.4, Mục 2.3.13):** Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. DOI: https://doi.org/10.1145/2939672.2939785

[11] **Mô hình LightGBM (Đối chiếu Mục 2.1.1, Mục 2.3.4, Mục 2.3.13):** Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T. Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146–3154.

[12] **Mô hình CatBoost (Đối chiếu Mục 2.1.1, Mục 2.3.4):** Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31, 6638–6648.

[13] **Mô hình HistGradientBoosting (Đối chiếu Mục 2.1.4):** Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[14] **Mô hình Isolation Forest (Đối chiếu Mục 2.1.3, Mục 2.3.13, Mục 2.3.14):** Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation Forest. *Proceedings of the 8th IEEE International Conference on Data Mining (ICDM '08)*, 413–422. DOI: https://doi.org/10.1109/ICDM.2008.17

[15] **Mô hình Local Outlier Factor – LOF (Đối chiếu Mục 2.1.3, Mục 2.3.14):** Breunig, M. M., Kriegel, H.-P., Ng, R. T., & Sander, J. (2000). LOF: Identifying density-based local outliers. *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, 93–104. DOI: https://doi.org/10.1145/342009.335388

[16] **Thuật toán Phân cụm K-Means (Đối chiếu Mục 2.3.3, Mục 2.3.13):** MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 1(14), 281–297.

[17] **Kỹ thuật Lựa chọn Tổ hợp Ensemble (Đối chiếu Mục 2.1):** Caruana, R., Niculescu-Mizil, A., Crew, G., & Ksikes, A. (2004). Ensemble selection from libraries of models. *Proceedings of the 21st International Conference on Machine Learning (ICML '04)*, 18. DOI: https://doi.org/10.1145/1015330.1015432

[18] **Kỹ thuật Ngưỡng động Phi tham số (Đối chiếu Mục 2.3.2):** Hundman, K., Constantinou, V., Laporte, C., Ho, I., & Chu, T. (2018). Detecting spacecraft anomalies using LSTMs and nonparametric dynamic thresholding. *Proceedings of*

the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 387–395. DOI: https://doi.org/10.1145/3219819.3219845

[19] **Nền tảng Tối ưu Siêu tham số Optuna:** Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2623–2631. DOI: https://doi.org/10.1145/3292500.3330701

[20] **Cơ chế Graph Attention trên Dữ liệu Năng lượng – Zhang et al. (Đối chiếu Mục 2.3.7):** Zhang, Z., Chen, Y., Wang, H., Fu, Q., Chen, J., & Lu, Y. (2023). Anomaly detection method for building energy consumption in multivariate time series based on graph attention mechanism. *PLOS ONE*, 18(6), e0286770. DOI: https://doi.org/10.1371/journal.pone.0286770

[21] **Mô hình LSTM Autoencoder (Đối chiếu Mục 2.2.3):** Malhotra, P., Ramakrishnan, A., Anand, G., Vig, L., Agarwal, P., & Shroff, G. (2016). LSTM-based Encoder-Decoder for Multi-sensor Anomaly Detection. *ICML 2016 Anomaly Detection Workshop*. arXiv: https://arxiv.org/abs/1607.00148

[22] **Mạng LSTM cho Phát hiện Bất thường (Đối chiếu Mục 2.2.1):** Malhotra, P., Vig, L., Shroff, G., & Agarwal, P. (2015). Long Short Term Memory Networks for Anomaly Detection in Time Series. *Proceedings of the 23rd European Symposium on Artificial Neural Networks (ESANN 2015)*, 89–94.

[23] **Mô hình USAD (Đối chiếu Mục 2.2.4):** Audibert, J., Michiardi, P., Guyard, F., Marti, S., & Zuluaga, M. A. (2020). USAD: UnSupervised Anomaly Detection on Multivariate Time Series. *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 3395–3404. DOI: https://doi.org/10.1145/3394486.3403392

[24] **Mạng Tích chập Thời gian TCN (Đối chiếu Mục 2.2.2, Mục 2.3.6):** Bai, S., Kolter, J. Z., & Koltun, V. (2018). An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling. arXiv: https://arxiv.org/abs/1803.01271

[25] **Mô hình Anomaly Transformer (Đối chiếu Mục 2.2.5):** Xu, J., Wu, H., Wang, J., & Long, M. (2022). Anomaly Transformer: Time Series Anomaly Detection with Association Discrepancy. *International Conference on Learning Representations (ICLR 2022)*. arXiv: https://arxiv.org/abs/2110.02642

[26] **Mô hình TranAD (Đối chiếu Mục 2.2.5):** Tuli, S., Casale, G., & Jennings, N. R. (2022). TranAD: Deep Transformer Networks for Anomaly Detection in Multivariate Time Series Data. *Proceedings of the VLDB Endowment*, 15(6), 1201–1214. DOI: https://doi.org/10.14778/3514061.3514067

[27] **Mô hình AnoGAN (Đối chiếu Mục 2.2.4, Mục 2.3.12):** Schlegl, T., Seeböck, P., Waldstein, S. M., Schmidt-Erfurth, U., & Langs, G. (2017). Unsupervised Anomaly Detection with Generative Adversarial Networks to Guide Marker Discovery. *Information Processing in Medical Imaging (IPMI 2017)*, 146–157. DOI: https://doi.org/10.1007/978-3-319-59050-9_12

[28] **Mô hình TAnoGAN (Đối chiếu Mục 2.2.4):** Bashar, M. A., & Nayak, R. (2020). TAnoGAN: Time Series Anomaly Detection with Generative Adversarial Networks. *IEEE Symposium Series on Computational Intelligence (SSCI 2020)*, 1778–1785. DOI: https://doi.org/10.1109/SSCI47803.2020.9308512

[29] **Mô hình Variational Autoencoder – VAE (Đối chiếu Mục 2.2.3):** Kingma, D. P., & Welling, M. (2014). Auto-Encoding Variational Bayes. *International Conference on Learning Representations (ICLR 2014)*. arXiv: https://arxiv.org/abs/1312.6114

[30] **Khảo sát Đánh giá Thuật toán Chuỗi Thời gian – Schmidl et al. (Đối chiếu Mục 2.3.14):** Schmidl, S., Wenig, P., & Papenbrock, T. (2022). Anomaly Detection in Time Series: A Comprehensive Evaluation. *Proceedings of the VLDB Endowment*, 15(9), 1779–1797. DOI: https://doi.org/10.14778/3538598.3538602

[31] **Hàm mất mát Soft-DTW (Đối chiếu Mục 2.3.8, Mục 2.3.12):** Cuturi, M., & Blondel, M. (2017). Soft-DTW: a Differentiable Loss Function for Time-Series. *Proceedings of the 34th International Conference on Machine Learning (ICML '17)*, 894–903.

[32] **Cơ chế Điều biến Tuyến tính Đặc trưng FiLM (Đối chiếu Mục 2.3.9):** Perez, E., Strub, F., de Vries, H., Courville, A., & Bengio, Y. (2018). FiLM: Visual Reasoning with a General Conditioning Layer. *Proceedings of the AAAI Conference on Artificial Intelligence*, 32(1), 3942–3951. DOI: https://doi.org/10.1609/aaai.v32i1.11671

[33] **Kiến trúc Mạng LSTM (Đối chiếu Mục 2.2.1):** Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780. DOI: https://doi.org/10.1162/neco.1997.9.8.1735

[34] **Kiến trúc Mạng GRU (Đối chiếu Mục 2.2.1):** Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation. *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 1724–1734. DOI: https://doi.org/10.3115/v1/D14-1179

[35] **Kiến trúc Mạng RNN Hai chiều (Đối chiếu Mục 2.2.1):** Schuster, M., & Paliwal, K. K. (1997). Bidirectional recurrent neural networks. *IEEE Transactions on Signal Processing*, 45(11), 2673–2681. DOI: https://doi.org/10.1109/78.650093

[36] **Kiến trúc Transformer (Đối chiếu Mục 2.2.5, Mục 2.3.7):** Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30, 5998–6008.

[37] **Hàm mất mát Focal Loss (Đối chiếu Mục 2.3.5):** Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal Loss for Dense Object Detection. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2980–2988. DOI: https://doi.org/10.1109/ICCV.2017.324