ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC & KỸ THUẬT MÁY TÍNH



Lập trình cho Trí tuệ nhân tạo và Khoa học dữ liệu
CO3135

PHÁT HIỆN BẤT THƯỜNG PHỤ TẢI ĐIỆN BẰNG CÁC PHƯƠNG PHÁP HỌC MÁY VÀ HỌC SÂU TRÊN DỮ LIỆU ĐA CHIỀU

GVHD: ThS. Trần Huy
NHÓM: **L01**
SINH VIÊN: Nguyễn Ngọc Tôn - 2313508
Nguyễn Miên Phú - 2312658
Trần Đỗ Đức Phát - 2312596
Huỳnh Kim Quý - 2312894
Nguyễn Đức Tiến - 2313431

TP. HỒ CHÍ MINH, THÁNG 12/2026

Mục lục

1 Tổng quan về Bài toán và Dữ liệu **4**
1.1 Giới thiệu bài toán 4
1.2 Mô tả tập dữ liệu 4

2 Tổng quan tài liệu **7**
2.1 Các phương pháp Học máy hiện có để giải quyết bài toán 7
2.1.1 Mô hình XGBoost 7
2.1.2 Mô hình LightGBM 8
2.1.3 Mô hình CatBoost 8
2.1.4 Mô hình HistGradientBoosting 9
2.2 Các phương pháp Học sâu hiện có để giải quyết bài toán 10
2.2.1 Biểu diễn bài toán và ba hệ hình tiếp cận 10
2.2.2 Mạng thần kinh hồi quy 11
2.2.3 Mạng tích chập thời gian 12
2.2.4 Họ mô hình tự mã hóa 12
2.2.5 Họ mô hình sinh đối kháng 14
2.2.6 Họ mô hình Transformer 14
2.3 Các kỹ thuật bổ trợ hiện có để giải quyết bài toán 15
2.3.1 Kỹ thuật tương tác giữa địa điểm và công năng 15
2.3.2 Chuẩn hóa phụ tải theo ngữ cảnh 15
2.3.3 Đặc trưng động học chuỗi thời gian và thành phần phân rã 16
2.3.4 Kỹ thuật phân cụm hành vi phụ tải 17
2.3.5 Hàm mất mát entropy chéo có trọng số 18
2.3.6 Hàm mất mát Focal Loss 18
2.3.7 Mạng tích chập thời gian kết hợp bộ tự mã hóa TCN 18
2.3.8 Cơ chế tự chú ý trong mô hình chuỗi 19
2.3.9 Hàm mất mát căn chỉnh thời gian mềm khả vi Soft-DTW 19
2.3.10 Mô hình chuỗi có điều kiện theo siêu dữ liệu 19
2.3.11 Mô hình sinh đối kháng kết hợp mạng LSTM 20
2.3.12 Mô hình sinh đối kháng tích chập một chiều 20
2.3.13 Kỹ thuật tái tạo song song nhiều điểm 20

3 Tiền xử lý và Khám phá Dữ liệu **21**
3.1 Khám phá Dữ liệu Ban đầu 21
3.1.1 Phân tích sự Mất cân bằng Lớp Dữ liệu 21
3.1.2 Phân tích Phân phối Tần suất Đặc trưng 22
3.1.3 Toàn cảnh Lịch sử Phụ tải và Phân bố Dị thường theo Thời gian . 22
3.1.4 Quan sát Nhãn Bất thường trên Chuỗi Thời gian 23
3.1.5 Tình trạng Thiếu Dữ liệu 24
3.2 Quy trình Tiền xử lý Dữ liệu 24
3.2.1 Giao thức Phân chia Chuỗi Thời gian Chu kỳ Mùa vụ và 96 Giờ Cách ly 25
3.3 Khám phá Dữ liệu sau Tiền xử lý 30
3.3.1 Kiểm tra Tính Toàn vẹn và Phân bổ Đặc trưng 30
3.3.2 Lược đồ Lịch sử Tiến trình Tiền xử lý 32
3.3.3 Khám phá Tương tác Khu vực 32
3.3.4 Khảo sát các Đặc trưng Ngữ cảnh 33

3.3.5 Phân tích Khám phá Dữ liệu Chuyên sâu trên Không gian Mở rộng 34

4 Triển khai Học máy 36
4.1 Thước đo Đánh giá và Cơ chế Ngưỡng Quyết định . . . 36
4.1.1 Thước đo Đánh giá . . . 36
4.1.2 Cơ chế Ngưỡng Quyết định . . . 36
4.2 Thử nghiệm, Huấn luyện và Đánh giá các Mô hình . . . 37
4.2.1 Chiến lược Phân chia Dữ liệu và Kiểm soát Phân phối Tập Huấn luyện - Kiểm tra . . . 37
4.2.2 Phân tích Thực nghiệm: Đối chứng Bộ tứ Gradient Boosting qua 3 Không gian Dữ liệu . . . 38
4.2.3 Tối ưu hóa Siêu tham số bằng Optuna trên Không gian Expanded . 39
4.2.4 Kỹ thuật Dung hợp Đa Mô hình . . . 41
4.2.5 Đối chứng các Kỹ thuật Dung hợp Đa Mô hình trên Không gian Expanded . . . 42
4.3 Khảo sát Mở rộng: Đánh giá Tác động của Isolation Forest và Phân cụm K-Means . . . 44

5 Triển khai Học sâu 47
5.1 Kiến trúc Pipeline Học Sâu Tổng thể . . . 47
5.2 Thiết kế Phương pháp luận và Giao thức Thực nghiệm . . . 48
5.2.1 Mục tiêu Đầu ra và Thước đo Đánh giá . . . 48
5.2.2 Tiêu chí Lựa chọn và Đa dạng hóa Thuật toán . . . 49
5.2.3 Quy trình Thực thi Thực nghiệm Chuẩn hóa . . . 49
5.2.4 Dữ liệu Đầu vào và Giao thức Kiểm định theo Công trình . . . 50
5.2.5 Đặc tả Kiến trúc Mạng Nơ-ron và Hàm Mất mát . . . 52
5.2.6 Luận giải Lựa chọn và Loại trừ Thuật toán . . . 53
5.3 Kết quả Thực nghiệm và Phân tích Cơ chế Nơ-ron . . . 54
5.3.1 Hiệu năng các Mô hình Đơn lẻ và Động học Kiến trúc . . . 54
5.3.2 Cơ sở Dẫn xuất Toán học của Trọng số Lớp Dương . . . 56
5.3.3 Dung hợp Đa Kiến trúc Chuỗi Thời gian . . . 57
5.3.4 Phân tích Hình thái Bắt lỗi theo Dạng Dị thường . . . 57
5.3.5 Tăng tiến Hiệu năng qua các Cấp độ của Phân hệ Học Sâu . . . 58
5.4 Bộ Giả thuyết Kiểm chứng . . . 58

6 Đánh giá, So sánh và Phân tích Kết quả Hiệu năng 59

7 Kết luận và Hướng phát triển Tương lai 59
7.1 Kết luận Toàn diện Đề tài . . . 59
7.2 Các Giới hạn Cốt lõi của Nghiên cứu . . . 59
7.3 Hướng phát triển Tương lai . . . 59

TÀI LIỆU THAM KHẢO 60

STT	MSSV	Họ và Tên	Nhiệm vụ	Đóng góp
1	2313508	Nguyễn Ngọc Tôn	• Tiền xử lý dữ liệu • Triển khai Học máy • Viết báo cáo Phần 2.1, 2.3, 3, 4	100%
2	2312658	Nguyễn Miên Phú	• Viết báo cáo Phần 3, 4	100%
3	2312596	Trần Đỗ Đức Phát	• Triển khai Học sâu • Viết báo cáo Phần 2.2, 2.3, 5	100%
4	2312894	Huỳnh Kim Quý	• Triển khai Học sâu • Viết báo cáo Phần 2.2, 2.3, 5	100%
5	2313431	Nguyễn Đức Tiến	• Viết báo cáo Phần 1	100%

Bảng 1: **Phân công nhiệm vụ và mức độ đóng góp**

1 Tổng quan về Bài toán và Dữ liệu

1.1 Giới thiệu bài toán

Các tòa nhà hiện đại tiêu thụ một lượng lớn năng lượng và được trang bị nhiều công tơ điện thông minh. Các thiết bị này liên tục ghi nhận mức tiêu thụ điện theo thời gian, tạo ra một lượng lớn dữ liệu chuỗi thời gian. Việc phân tích các dữ liệu này có thể hỗ trợ phát hiện những trường hợp sử dụng năng lượng bất thường, từ đó góp phần xác định các vấn đề như sự cố thiết bị, thiết bị xuống cấp, cấu hình không phù hợp hoặc các hành vi sử dụng năng lượng không hiệu quả.

Trong báo cáo này, nhóm tập trung vào bài toán phát hiện dị thường trong dữ liệu tiêu thụ điện năng, nhằm phát hiện kịp thời các hành vi phụ tải khác biệt hoặc đột biến. Một điểm dữ liệu được xem là bất thường khi mức tiêu thụ điện tại thời điểm đó khác biệt đáng kể so với trạng thái vận hành thông thường, ngược lại được phân loại là trạng thái bình thường.

Về mặt hình thức, bài toán được thiết lập dưới dạng phân lớp có giám sát trên không gian đặc trưng đa chiều. Mỗi quan trắc của một tòa nhà tại thời điểm t được mã hóa thành một vector đặc trưng $\mathbf{x} \in \mathbb{R}^D$ tích hợp đa tầng từ nhiều nguồn dữ liệu:

$$\mathbf{x} = \Big[\underbrace{m_t}_{\text{mức phụ tải}}, \underbrace{\mathbf{x}_{\text{time}}}_{\text{chu kỳ tuần hoàn}}, \underbrace{\mathbf{x}_{\text{bldg}}}_{\text{thông tin tòa nhà}}, \underbrace{\mathbf{x}_{\text{weather}}}_{\text{khí hậu}}, \underbrace{\mathbf{x}_{\text{zone}}}_{\text{tương tác vùng}}, \underbrace{\mathbf{x}_{\text{context}}}_{\text{ngữ cảnh vi mô}}, \underbrace{\mathbf{x}_{\text{lag}}, \mathbf{x}_{\text{diff}}, \mathbf{x}_{\text{ratio}}, \text{flatline}, \text{stl_residual}}_{\text{động học chuỗi thời gian \& phân rã mùa vụ STL}} \Big]^{\top} \in \mathbb{R}^D$$

Mục tiêu của các mô hình là học một hàm ánh xạ phân lớp $f : \mathbb{R}^D \to \{0, 1\}$ nhằm trực tiếp gán nhãn quyết định nhị phân cho từng quan trắc:

$$\hat{y} = f(\mathbf{x}) \in \{0, 1\}$$

trong đó $\hat{y} = 1$ tương ứng với trạng thái bất thường và $\hat{y} = 0$ tương ứng với trạng thái bình thường.

Để giải quyết bài toán này, đề tài tiến hành nghiên cứu, xây dựng và huấn luyện mô hình trên cả hai nhánh tiếp cận học máy truyền thống và học sâu, đồng thời so sánh đối chứng toàn diện nhằm tìm ra giải pháp tối ưu cho việc giám sát phụ tải thực tế, kết hợp các kỹ thuật xử lý nâng cao để nâng cao độ chính xác dự báo.

1.2 Mô tả tập dữ liệu

Dữ liệu thực nghiệm của đề tài được thu thập từ cuộc thi phát hiện bất thường năng lượng quy mô lớn LEAD trên nền tảng Kaggle tại liên kết `https://www.kaggle.com/competitions/energy-anomaly-detection/data`. Bộ dữ liệu này được kế thừa và phát triển từ nguồn dữ liệu phụ tải của cuộc thi ASHRAE, trong đó các điểm đo điện theo từng giờ tại các tòa nhà thương mại trong suốt năm 2016 (từ 00:00 ngày 01/01/2016 đến 23:00 ngày 31/12/2016) đã được gán nhãn bất thường.

Theo công bố từ ban tổ chức cuộc thi trên nền tảng Kaggle với tổng dung lượng khoảng 1,34 GB, bộ dữ liệu hoàn chỉnh bao gồm 5 tệp thành phần phục vụ các giai đoạn phát triển và đánh giá mô hình. Trong đó, hai tệp chuỗi thời gian thô gồm **`train.csv`** (chỉ lưu các trường cơ sở `building_id`, `timestamp`, `meter_reading` và nhãn `anomaly`) và **`test.csv`**

(cấu trúc tương tự tập train thô nhưng khuyết cột nhãn). Tệp **sample_submission.csv** đóng vai trò là biểu mẫu định dạng kết quả nộp bài gồm hai cột `row_id` và `anomaly` để hệ thống Kaggle chấm điểm trực tuyến. Bên cạnh dữ liệu thô, ban tổ chức cung cấp hai tệp mở rộng đã được ghép nối thông tin công trình và điều kiện thời tiết: **test_features.csv** bao gồm dữ liệu của 206 tòa nhà độc lập với 1.800.567 bản ghi và 57 thuộc tính (không có cột nhãn mục tiêu), và **train_features.csv** gồm dữ liệu đo đạc của 200 tòa nhà với 1.749.494 bản ghi chuỗi thời gian cùng 57 thuộc tính tích hợp sẵn mức phụ tải, đặc tính vật lý công trình, điều kiện khí hậu, các biến trễ nhiệt độ và nhãn bất thường `anomaly`.

Về phạm vi dữ liệu sử dụng trong nghiên cứu, mặc dù ban tổ chức cuộc thi cung cấp đầy đủ cả 5 tệp dữ liệu nêu trên, trong toàn bộ quy trình thực nghiệm của đề tài, nhóm quyết định chỉ sử dụng duy nhất tệp **train_features.csv**. Quyết định này xuất phát từ hai nguyên nhân kỹ thuật then chốt. Thứ nhất, tệp `test_features.csv` là tập kiểm tra ẩn được ban tổ chức ẩn cột nhãn nhằm bảo mật bảng xếp hạng trực tuyến; do đó, để chủ động thiết lập giao thức kiểm thử khách quan và đo lường chính xác các chỉ số hiệu năng như PR-AUC, F1-Score và ma trận nhầm lẫn, đề tài bắt buộc phải sử dụng tập dữ liệu có đầy đủ nhãn kiểm chứng thực tế. Thứ hai, so với tệp thô `train.csv`, tệp `train_features.csv` đã được tiền xử lý ghép nối sẵn các thuộc tính bối cảnh vật lý công trình và dữ liệu khí tượng chuẩn hóa, tạo nền tảng vững chắc cho việc phát triển các nhóm đặc trưng không gian và động học chuỗi thời gian chuyên sâu ở các giai đoạn sau.

Tệp dữ liệu `train_features.csv` bao gồm 57 thuộc tính, kết hợp giữa các thông tin đo lường phụ tải cơ sở và hệ thống đặc trưng đa chiều phong phú phục vụ quá trình mô hình hóa. Chi tiết các thuộc tính cốt lõi và các nhóm đặc trưng bổ sung được tổng hợp tại Bảng 2.

Bảng 2: Tổng hợp hệ thống thuộc tính và nhóm đặc trưng trong tệp `train_features.csv`

Phân nhóm	**Tên thuộc tính / Đại diện**	**Ý nghĩa và Mô tả thực tế**
Thuộc tính cốt lõi	`building_id`	Mã định danh duy nhất của tòa nhà nơi dữ liệu phụ tải được ghi nhận.
	`timestamp`	Mốc thời gian ghi nhận mức tiêu thụ điện (chu kỳ 1 giờ, xuyên suốt năm 2016).
	`meter_reading`	Mức tiêu thụ điện năng thực tế của công trình tại thời điểm tương ứng (kWh).
	`anomaly`	Biến mục tiêu phân loại nhị phân (0: bình thường, 1: bất thường).
Thông tin công trình	`site_id`, `primary_use`, `square_feet`, `year_built`, `floor_count`	Thông số vật lý công trình: vị trí khu vực, công năng sử dụng, diện tích sàn (sqft), năm xây dựng và số tầng.
Điều kiện thời tiết	`air_temperature`, `dew_temperature`, `cloud_coverage`, `precip_depth_1_hr`, `sea_level_pressure`, `wind_direction`, `wind_speed`	Dữ liệu khí tượng tức thời quan trắc từ các trạm thời tiết: nhiệt độ không khí, điểm sương, độ che phủ mây, lượng mưa, áp suất, hướng và tốc độ gió.
Thời gian & Chu kỳ	`hour`, `weekday`, `month`, `year`, `weekday_hour`, `is_holiday`, `hour_x/y`, `month_x/y`, `weekday_x/y`	Đặc trưng lịch biểu gồm giờ, thứ, tháng, chỉ báo ngày lễ và các biến mã hóa chu kỳ lượng giác (sin / cos) mô hình hóa nhịp sinh hoạt ngày đêm.
Trễ chuỗi thời gian	`air_temperature_mean_lag7/73`, `max_lag7/73`, `min_lag7/73`, `std_lag7/73`	Các đặc trưng thống kê nhiệt độ môi trường qua các cửa sổ quá khứ 7 giờ và 73 giờ (khoảng 3 ngày), nắm bắt quán tính nhiệt công trình.
Tương tác tòa nhà	`building_hour`, `building_weekday`, `building_month`, `building_weekday_hour`, `building_meter`	Kết hợp đặc thù vận hành của từng công trình theo từng khung giờ và ngày trong tuần.
Mã hóa mục tiêu	16 đặc trưng tiền tố `gte_` như `gte_hour`, `gte_site_id`, `gte_primary_use`, `gte_meter`…	Kỹ thuật mã hóa mục tiêu theo nhóm: ước lượng tỷ lệ dị thường kỳ vọng theo từng nhóm bối cảnh không gian và thời gian.

Trong đó, thuộc tính `anomaly` đóng vai trò là biến mục tiêu cần dự đoán. Kết quả thống kê trên toàn bộ 1.749.494 bản ghi của tệp dữ liệu cho thấy có 1.712.198 bản ghi thuộc lớp bình thường (`anomaly` = 0) và 37.296 bản ghi thuộc lớp bất thường (`anomaly` = 1). Như vậy, bài toán mang tính chất mất cân bằng nhãn sâu sắc với tỷ lệ dị thường thực tế chỉ chiếm khoảng 2,13%.

Bên cạnh đó, các nhóm đặc trưng bổ sung giúp mô hình nắm bắt toàn diện bối cảnh vật lý công trình, thời tiết khí tượng và nhịp điệu sinh hoạt theo thời gian. Đây là nguồn tín hiệu đầu vào phong phú được nhóm nghiên cứu sàng lọc, chuẩn hóa và tối ưu hóa trong các giai đoạn tiền xử lý và xây dựng mô hình ở các chương tiếp theo.

Qua quá trình kiểm tra trên tệp `train_features.csv`, thuộc tính `meter_reading` xuất hiện các giá trị bị thiếu với 107.653 bản ghi, tương đương khoảng 6,15% tổng số bản ghi của tập dữ liệu. Vì vậy, dữ liệu thiếu cần được xem xét và xử lý trong bước tiền xử

lý trước khi đưa vào các mô hình học máy và học sâu. Ngoài `meter_reading`, các thuộc tính còn lại trong tệp `train_features.csv` đều đầy đủ và không ghi nhận giá trị thiếu trong suốt quá trình kiểm tra.

2 Tổng quan tài liệu

2.1 Các phương pháp Học máy hiện có để giải quyết bài toán

Do dữ liệu sử dụng trong nghiên cứu đã có sẵn nhãn cho biến `anomaly` (0 biểu thị trạng thái bình thường, 1 biểu thị trạng thái bất thường), bài toán được thiết lập dưới dạng phân loại nhị phân có giám sát. Các phương pháp học máy tiếp cận được trình bày trong mục này là các thuật toán tăng cường độ dốc trên cây quyết định tiêu biểu, từng được khai thác hiệu quả trong lời giải quán quân cuộc thi LEAD của nhóm tác giả Fu và cộng sự [2].

2.1.1 Mô hình XGBoost

Mô hình XGBoost [10] tối ưu hóa hàm mục tiêu bằng phương pháp khai triển Taylor bậc hai, cho phép quá trình học hội tụ nhanh chóng. Cấu trúc cây được phát triển tuần tự theo từng tầng, trong đó mô hình dự báo cuối cùng là tổng hợp của K cây quyết định:

$$\hat{y}_i = \sum_{k=1}^{K} f_k(\mathbf{x}_i), \quad f_k \in \mathcal{F}$$

trong đó $\mathcal{F}$ là không gian của các cây hồi quy phân loại. Tại mỗi bước lặp t, hàm mục tiêu được xấp xỉ hóa qua khai triển Taylor bậc hai:

$$\mathcal{L}^{(t)} \simeq \sum_{i=1}^{n} \left[g_i f_t(\mathbf{x}_i) + \frac{1}{2} h_i f_t^2(\mathbf{x}_i) \right] + \Omega(f_t)$$

với $g_i = \partial_{\hat{y}^{(t-1)}} \ell(y_i, \hat{y}^{(t-1)})$ là độ dốc bậc nhất, $h_i = \partial^2_{\hat{y}^{(t-1)}} \ell(y_i, \hat{y}^{(t-1)})$ là độ dốc bậc hai của hàm mất mát, và $\Omega(f_t)$ là hàm phạt độ phức tạp cấu trúc cây:

$$\Omega(f) = \gamma T + \frac{1}{2}\lambda \sum_{j=1}^{T} w_j^2 + \alpha \sum_{j=1}^{T} |w_j|$$

trong đó T là số lượng lá, w_j là trọng số tại nút lá thứ j, γ đại diện cho hệ số phạt số lượng lá, λ là hệ số điều chuẩn L_2 và α là hệ số điều chuẩn L_1.

Về mặt ưu điểm, XGBoost tích hợp trực tiếp các thành phần điều chuẩn L_1 và L_2 vào hàm mục tiêu, giúp hạn chế hiệu quả hiện tượng quá khớp khi mô hình tiếp xúc với dữ liệu phụ tải có nhiều nhiễu cảm biến. Thuật toán hỗ trợ xử lý mất cân bằng lớp thông qua siêu tham số điều chỉnh trọng số mẫu, gán mức phạt cao hơn đối với các lỗi phân loại sai lớp bất thường. Đồng thời, mô hình có khả năng tự học hướng đi mặc định tại mỗi nút rẽ nhánh đối với các giá trị bị khuyết, đáp ứng tốt đặc thù dữ liệu đo đạc thực tế.

Ngược lại, nhược điểm chính của XGBoost nằm ở độ phức tạp tính toán lớn. Do thuật toán phân nhánh tham lam chính xác đòi hỏi phải duyệt qua toàn bộ dữ liệu liên tục, thời gian huấn luyện mô hình kéo dài khi đối mặt với tập dữ liệu quy mô hàng triệu bản ghi. Bên cạnh đó, chiến lược phát triển cây theo từng tầng buộc mọi nút ở cùng độ sâu đều phải mở rộng, dễ dẫn đến việc phân chia không cần thiết tại các nhánh ít thông tin.

2.1.2 Mô hình LightGBM

Mô hình LightGBM [11] được tối ưu hóa chuyên biệt về tốc độ tính toán và hiệu suất sử dụng bộ nhớ trên dữ liệu quy mô lớn thông qua hai kỹ thuật nền tảng: lấy mẫu một phía theo độ dốc GOSS và gộp đặc trưng loại trừ lẫn nhau EFB. Cây quyết định trong LightGBM được phát triển theo chiến lược ưu tiên nút lá có độ lợi thông tin lớn nhất.

Kỹ thuật GOSS ước lượng độ lợi thông tin bằng cách giữ lại toàn bộ các mẫu có độ dốc lớn và lấy mẫu ngẫu nhiên một tỷ lệ nhỏ từ các mẫu có độ dốc nhỏ, sau đó nhân hệ số bù trọng số nhằm bảo toàn phân phối dữ liệu:

$$\widetilde{V}_j(d) = \frac{1}{n}\left(\frac{\left(\sum_{x_i \in A_l} g_i + \frac{1-a}{b}\sum_{x_i \in B_l} g_i\right)^2}{n_l^j(d)} + \frac{\left(\sum_{x_i \in A_r} g_i + \frac{1-a}{b}\sum_{x_i \in B_r} g_i\right)^2}{n_r^j(d)}\right)$$

trong đó A là tập các mẫu có độ dốc lớn, B là tập mẫu ngẫu nhiên từ nhóm có độ dốc nhỏ, l và r tương ứng với nhánh trái và nhánh phải tại ngưỡng chia d của đặc trưng j. Song song với đó, kỹ thuật EFB gộp các đặc trưng thưa có tính loại trừ lẫn nhau thành các bó đặc trưng kết hợp, giảm mạnh số chiều dữ liệu từ p xuống còn $p' \ll p$.

Ưu điểm nổi bật của LightGBM là tốc độ huấn luyện vượt trội và khả năng tiết kiệm tài nguyên bộ nhớ. Nhờ việc rời rạc hóa các giá trị liên tục thành các thùng biểu đồ histogram rời rạc, chi phí tìm kiếm điểm chia nhánh giảm đi đáng kể. Mô hình hỗ trợ phân chia trực tiếp trên các biến định danh nhiều nhóm mà không cần mã hóa One-Hot, giúp kiểm soát chiều không gian dữ liệu hiệu quả. Cơ chế GOSS duy trì độ chính xác cao nhờ ưu tiên giữ lại các mẫu khó học nhất.

Tuy nhiên, LightGBM tiềm ẩn rủi ro quá khớp cục bộ do chiến lược mở rộng cây theo nút lá có xu hướng tạo ra các cây sâu bất đối xứng. Nếu không giới hạn nghiêm ngặt độ sâu tối đa và số lượng mẫu tối thiểu trong mỗi lá, mô hình có thể học thuộc lòng các mẫu nhiễu cục bộ trong dữ liệu.

2.1.3 Mô hình CatBoost

Mô hình CatBoost [12] xây dựng các cây quyết định đối xứng và ứng dụng cơ chế mã hóa mục tiêu có thứ tự. Thuật toán sử dụng một hoán vị ngẫu nhiên σ của tập dữ liệu để tính toán giá trị mã hóa cho các biến định danh dựa trên các quan trắc xuất hiện trước đó, qua đó triệt tiêu triệt để hiện tượng rò rỉ nhãn mục tiêu:

$$\hat{x}^i_{\sigma_p} = \frac{\sum_{j=1}^{p-1}[x^i_{\sigma_j} = x^i_{\sigma_p}] \cdot y_{\sigma_j} + a \cdot P}{\sum_{j=1}^{p-1}[x^i_{\sigma_j} = x^i_{\sigma_p}] + a}$$

trong đó σ_p là chỉ số của mẫu thứ p trong hoán vị, x^i là giá trị của đặc trưng định danh thứ i, y là nhãn mục tiêu, P là giá trị kỳ vọng toàn cục của nhãn và $a > 0$ là hệ số làm trơn Laplace.

Cây quyết định đối xứng trong CatBoost áp dụng cùng một điều kiện phân chia trên toàn bộ các nút ở cùng một độ sâu, tạo ra cấu trúc cây hoàn toàn cân bằng với 2^d nút lá (với d là độ sâu cây). Khi suy luận, cấu trúc này cho phép chuyển đổi cây thành bảng tra cứu nhị phân với độ phức tạp cực thấp $O(d)$.

Về ưu điểm, cơ chế mã hóa mục tiêu có thứ tự giúp CatBoost xử lý an toàn các biến định danh có lực lượng phân loại lớn mà không gây rò rỉ thông tin nhãn. Cấu trúc cây đối xứng đóng vai trò như một cơ chế điều chuẩn ngầm giúp hạn chế quá khớp, đồng thời tăng tốc độ suy luận dự đoán lên gấp nhiều lần so với các cây bất đối xứng.

Nhược điểm của CatBoost là thời gian huấn luyện kéo dài do chi phí tính toán nhiều hoán vị ngẫu nhiên và mã hóa mục tiêu liên tục, đặc biệt trên các bộ dữ liệu có nhiều biến thực liên tục. Ngoài ra, việc áp đặt cùng một ngưỡng chia cho toàn bộ các nút trong một tầng có thể làm giảm tính linh hoạt của mô hình khi mô tả các mẫu hình phi tuyến tính phức tạp.

2.1.4 Mô hình HistGradientBoosting

Mô hình HistGradientBoosting [13] là phiên bản tăng cường độ dốc hiện đại được tích hợp trong thư viện Scikit-learn, áp dụng cơ chế phân thùng giá trị liên tục nhằm tối ưu hóa chi phí tính toán trên tập dữ liệu lớn ($N > 10^6$ mẫu).

Cốt lõi của thuật toán là kỹ thuật phân thùng số nguyên 8-bit, trong đó toàn bộ dải giá trị liên tục của đặc trưng j được ánh xạ vào $B = 256$ thùng rời rạc ($b \in \{0, 1, \ldots, 255\}$):

$$b_i = \text{bin}(x_{i,j}) = \sum_{k=1}^{B-1} \mathbb{I}(x_{i,j} > q_k)$$

trong đó $\{q_1, q_2, \ldots, q_{B-1}\}$ là các điểm phân vị thực nghiệm được ước lượng trước trên tập huấn luyện, và thùng thứ 255 được quy ước dành riêng để đại diện cho dữ liệu bị khuyết.

Tại mỗi nút của cây quyết định, thay vì duyệt qua toàn bộ n mẫu quan sát, thuật toán tích lũy độ dốc bậc nhất g_i và độ dốc bậc hai h_i vào biểu đồ histogram theo từng thùng:

$$G_k = \sum_{i \in I,\, b_i = k} g_i, \qquad H_k = \sum_{i \in I,\, b_i = k} h_i$$

với I là tập chỉ số các mẫu tại nút hiện tại, $g_i = \partial_{\hat{y}^{(t-1)}} \ell(y_i, \hat{y}^{(t-1)})$ và $h_i = \partial^2_{\hat{y}^{(t-1)}} \ell(y_i, \hat{y}^{(t-1)})$. Trong bài toán phân loại nhị phân với hàm mất mát Logistic, độ dốc có dạng $g_i = p_i - y_i$ và $h_i = p_i(1 - p_i)$ với $p_i = \sigma(\hat{y}_i^{(t-1)})$.

Độ lợi phân chia $\Delta\mathcal{L}(s)$ khi tách nút tại ngưỡng thùng $s \in \{0, 1, \ldots, B-2\}$ được tính toán trực tiếp từ các tổng tích lũy của biểu đồ histogram:

$$\Delta\mathcal{L}(s) = \frac{1}{2}\left[\frac{\left(\sum_{k \le s} G_k\right)^2}{\sum_{k \le s} H_k + \lambda} + \frac{\left(\sum_{k > s} G_k\right)^2}{\sum_{k > s} H_k + \lambda} - \frac{\left(\sum_k G_k\right)^2}{\sum_k H_k + \lambda}\right] - \gamma$$

trong đó λ là hệ số điều chuẩn L_2 (`l2_regularization`) nhằm kiểm soát độ lớn trọng số nút lá, và γ là ngưỡng cải thiện tối thiểu (`min_impurity_decrease`).

Đặc biệt, nhằm tăng tốc quá trình xây dựng cây, thuật toán áp dụng cơ chế trừ biểu đồ histogram. Biểu đồ của nút con bên phải được suy diễn trực tiếp từ nút cha và nút con bên trái mà không cần quét lại dữ liệu:

$$G_{k,\text{phải}} = G_{k,\text{cha}} - G_{k,\text{trái}}, \qquad H_{k,\text{phải}} = H_{k,\text{cha}} - H_{k,\text{trái}}$$

Nhờ đó, độ phức tạp tìm kiếm điểm chia nhánh tối ưu tại mỗi nút chỉ còn phụ thuộc tuyến tính vào số lượng thùng $O(B)$, hoàn toàn độc lập với quy mô kích thước mẫu N.

Ưu điểm chính của mô hình là tốc độ xử lý nhanh, chiếm dụng ít bộ nhớ RAM nhờ tối ưu hóa định dạng số nguyên 8-bit kết hợp xử lý đa luồng, hỗ trợ cơ chế dừng sớm để phòng chống quá khớp và tự động xử lý giá trị khuyết mà không cần bước điền khuyết thủ công.

Dù vậy, việc rời rạc hóa các giá trị liên tục thành 256 thùng có thể làm mất đi độ phân giải chi tiết của các biến động phụ tải vi mô. Ngoài ra, mô hình chưa hỗ trợ tham số trực tiếp cho tỷ lệ mất cân bằng nhãn mà đòi hỏi người dùng phải cấu hình thủ công thông qua vector trọng số mẫu.

2.2 Các phương pháp Học sâu hiện có để giải quyết bài toán

Khác với các mô hình học máy truyền thống vốn tiếp cận từng bản ghi dữ liệu một cách độc lập, các phương pháp học sâu dành cho chuỗi thời gian có khả năng khai thác trực tiếp thứ tự thời gian và mối tương quan phụ thuộc giữa các bước quan trắc liên tiếp. Dựa trên quá trình khảo sát thực nghiệm trên tệp dữ liệu `train_features.csv`, chuỗi phụ tải điện năng mang những đặc trưng cốt lõi sau:

Dữ liệu khảo sát bao gồm 200 tòa nhà, trong đó mỗi công trình là một chuỗi đo đạc phụ tải theo từng giờ xuyên suốt năm 2016 với quy mô gần 1,75 triệu bước quan trắc. Biến mục tiêu `anomaly` được gán nhãn cho từng thời điểm riêng lẻ với tỷ lệ dị thường chỉ chiếm khoảng 2,1%, đặt ra thách thức mất cân bằng nhãn sâu sắc. Đáng chú ý, các dạng bất thường trong tập dữ liệu có tính chất không đồng nhất: nhiều điểm bất thường xuất hiện dưới dạng chuỗi giá trị đóng băng liên tục kéo dài từ 3 giờ trở lên, trong khi một bộ phận khác lại có giá trị tiêu thụ nằm hoàn toàn trong ngưỡng phụ tải thông thường và chỉ có thể phát hiện dựa trên ngữ cảnh lịch sử thời gian.

Các đặc thù trên cho thấy những mô hình đánh giá điểm dữ liệu cô lập khó có thể bao quát toàn diện các dạng dị thường phụ thuộc bối cảnh vận hành. Đây chính là tiền đề thôi thúc việc khảo sát và ứng dụng các kiến trúc mạng học sâu chuyên sâu.

2.2.1 Biểu diễn bài toán và ba hệ hình tiếp cận

Với mỗi công trình, tại thời điểm quan sát t, dữ liệu đầu vào được tổ chức thành một cửa sổ trượt gồm w quan trắc gần nhất trong quá khứ:

$$\mathbf{X}_t = (\mathbf{x}_{t-w+1}, \ldots, \mathbf{x}_t) \in \mathbb{R}^{w \times d}$$

trong đó vector $\mathbf{x}_i \in \mathbb{R}^d$ bao gồm giá trị tiêu thụ điện thực tế `meter_reading`, các thuộc tính khí tượng quan trắc, mã hóa chu kỳ lịch biểu và các biến bối cảnh bổ trợ. Nhãn quyết định tại thời điểm t là $y_t \in \{0, 1\}$. Các phương pháp học sâu hiện nay chủ yếu vận hành dựa trên ba hệ hình tiếp cận chính:

Thứ nhất là hệ hình tái tạo dữ liệu, trong đó mô hình học cách khôi phục lại hành vi phụ tải ở trạng thái bình thường; điểm bất thường được xác định dựa trên độ lớn của sai số tái tạo:

$$a_t = \|\mathbf{x}_t - \hat{\mathbf{x}}_t\|_2^2$$

Thứ hai là hệ hình dự báo chuỗi thời gian, trong đó mạng học sâu dự đoán mức phụ tải ở bước kế tiếp dựa trên chuỗi lịch sử quá khứ; độ sai lệch giữa giá trị đo thực tế và giá trị dự báo phản ánh mức độ dị thường:

$$a_t = |x_{t+1} - \hat{x}_{t+1}|$$

Thứ ba là hệ hình gán nhãn chuỗi có giám sát, trong đó mô hình trực tiếp học hàm ánh xạ xác suất xuất hiện bất thường dựa trên nhãn mục tiêu sẵn có của tập dữ liệu:

$$\hat{p}_t = P\left(y_t = 1 \mid \mathbf{X}_t\right)$$

Hai hệ hình đầu tiên thường được triển khai trong bối cảnh học không giám sát khi thiếu nhãn dị thường. Trong khi đó, hệ hình thứ ba cho phép tận dụng trọn vẹn nhãn kiểm chứng của bộ dữ liệu phục vụ huấn luyện tối ưu hóa trực tiếp.

2.2.2 Mạng thần kinh hồi quy

Mạng thần kinh hồi quy xử lý chuỗi dữ liệu theo cơ chế tuần tự từng bước, liên tục duy trì và cập nhật trạng thái ẩn $\mathbf{h}_t$ nhằm tổng hợp thông tin tích lũy từ quá khứ. Kiến trúc này có thể thích ứng linh hoạt với cả ba hệ hình nêu trên.

2.2.2.1 Mô hình mạng LSTM Mạng LSTM giải quyết hiện tượng triệt tiêu độ dốc trên chuỗi dài bằng cách đưa vào trạng thái ô nhớ $\mathbf{c}_t$ cùng ba cơ chế cổng kiểm soát thông tin (Hochreiter và Schmidhuber [33], Malhotra và cộng sự [22]):

$$\mathbf{f}_t = \sigma\left(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f\right), \quad \mathbf{i}_t = \sigma\left(\mathbf{W}_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i\right), \quad \mathbf{o}_t = \sigma\left(\mathbf{W}_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o\right)$$
$$\tilde{\mathbf{c}}_t = \tanh\left(\mathbf{W}_c[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c\right), \quad \mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t, \quad \mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t)$$

trong đó $\mathbf{f}_t$, $\mathbf{i}_t$, $\mathbf{o}_t$ lần lượt là cổng quên, cổng vào và cổng ra, σ là hàm kích hoạt phi tuyến tính sigmoid và $\odot$ đại diện cho phép nhân Hadamard từng phần tử.

Ưu điểm nổi bật của LSTM là khả năng ghi nhớ sự phụ thuộc dài hạn qua kênh ô nhớ, rất phù hợp để học chu kỳ phụ tải ngày (24 giờ) và chu kỳ tuần (168 giờ) của các công trình. Kiến trúc hỗ trợ đầu vào đa biến phong phú, kết hợp đồng thời phụ tải, nhiệt độ và lịch biểu để ra quyết định gán nhãn từng bước hoặc dự báo.

Dù vậy, nhược điểm cốt lõi của LSTM là tính toán tuần tự không thể song song hóa theo trục thời gian, dẫn đến thời gian huấn luyện kéo dài khi tập dữ liệu có hàng triệu bước thời gian. Mô hình khá nhạy cảm với độ dài cửa sổ w và các siêu tham số mạng, đồng thời đòi hỏi phải tích hợp thêm các hàm mất mát có trọng số để tránh nguy cơ dự đoán thiên lệch về lớp đa số bình thường.

2.2.2.2 Mô hình mạng GRU Kiến trúc GRU rút gọn mạng LSTM bằng cách tinh giản cơ cấu xuống còn hai cổng điều khiển là cổng cập nhật $\mathbf{z}_t$ và cổng đặt lại $\mathbf{r}_t$, đồng thời tích hợp trực tiếp trạng thái nhớ vào vector ẩn $\mathbf{h}_t$ (Cho và cộng sự [34]):

$$\mathbf{z}_t = \sigma\left(\mathbf{W}_z[\mathbf{h}_{t-1}, \mathbf{x}_t]\right), \quad \mathbf{r}_t = \sigma\left(\mathbf{W}_r[\mathbf{h}_{t-1}, \mathbf{x}_t]\right)$$
$$\tilde{\mathbf{h}}_t = \tanh\left(\mathbf{W}[\mathbf{r}_t \odot \mathbf{h}_{t-1}, \mathbf{x}_t]\right), \quad \mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t$$

Ưu điểm của GRU là số lượng tham số ít hơn đáng kể so với LSTM, giúp giảm thiểu hiện tượng quá khớp, đẩy nhanh tốc độ hội tụ và giảm dung lượng bộ nhớ GPU mà vẫn duy trì hiệu năng tương đương trên nhiều bài toán chuỗi thời gian.

Tuy nhiên, do loại bỏ ô nhớ tách biệt, GRU có năng lực biểu diễn kém linh hoạt hơn khi cần duy trì các ngữ cảnh lịch sử cực dài. Ngoài ra, GRU vẫn chia sẻ hạn chế tính toán tuần tự chung của dòng mạng hồi quy.

2.2.2.3 Mô hình hồi quy hai chiều BiLSTM và BiGRU Mạng hồi quy hai chiều vận hành đồng thời hai luồng tính toán độc lập xuôi và ngược theo trục thời gian, sau đó ghép nối các trạng thái ẩn để tổng hợp toàn diện bối cảnh hai phía (Schuster và Paliwal [35]):

$$\mathbf{h}_t = \left[\overrightarrow{\mathbf{h}}_t, \overleftarrow{\mathbf{h}}_t\right], \qquad \hat{p}_t = \sigma\left(\mathbf{w}^\top \mathbf{h}_t + b\right)$$

Ưu điểm chính của kiến trúc hai chiều là khả năng khai thác đồng thời cả bối cảnh quá khứ lẫn tương lai gần tại mỗi mốc thời gian t. Điều này đặc biệt giá trị đối với các dạng bất thường đóng băng cảm biến hoặc sụt áp kéo dài, giúp mô hình định vị chính xác độ dài đoạn lỗi. Khi huấn luyện trên toàn đoạn chuỗi, mạng có thể gán nhãn cho nhiều bước cùng lúc, tiết kiệm chi phí trượt cửa sổ từng bước.

Mặt khác, nhược điểm lớn nhất là kiến trúc hai chiều đòi hỏi thông tin của các bước tiếp theo, do đó không thể ứng dụng trong chế độ giám sát cảnh báo thời gian thực mà chỉ phù hợp cho việc rà soát và kiểm toán dữ liệu ngoại tuyến. Bên cạnh đó, việc nhân đôi luồng hồi quy làm tăng gấp đôi số lượng tham số và chi phí tính toán.

2.2.3 Mạng tích chập thời gian

2.2.3.1 Kiến trúc TCN Mạng TCN áp dụng các phép tích chập nhân quả giãn nở kết hợp khối phần dư để xử lý chuỗi thời gian (Bai và cộng sự [24]). Cơ chế tích chập nhân quả đảm bảo đầu ra tại thời điểm t chỉ phụ thuộc vào các quan trắc từ t trở về trước, trong khi hệ số giãn nở d cho phép mở rộng cấp số nhân vùng tiếp nhận mà không làm gia tăng số lượng trọng số:

$$(F *_d \mathbf{x})(t) = \sum_{i=0}^{k-1} f(i) \cdot \mathbf{x}_{t-d \cdot i}$$

trong đó k là kích thước bộ lọc, f là hàm trọng số nhân tích chập và d là hệ số giãn nở. Khi xếp chồng L khối phần dư với hệ số giãn nở lũy thừa cơ số 2 ($d = 2^l$, $l = 0, \ldots, L-1$), vùng tiếp nhận hiệu dụng của mạng được tính theo công thức:

$$R = 1 + 2(k-1)\left(2^L - 1\right)$$

Chẳng hạn với cấu hình $k = 3$ và $L = 6$, vùng tiếp nhận $R = 253$ giờ, hoàn toàn bao quát trọn vẹn chu kỳ tuần 168 giờ của phụ tải.

Ưu điểm nổi bật của TCN là khả năng song song hóa hoàn toàn theo trục thời gian, tận dụng triệt để kiến trúc xử lý của GPU để đẩy nhanh tốc độ huấn luyện trên quy mô hàng triệu bản ghi. Vùng nhìn được kiểm soát toán học chặt chẽ qua công thức cấu hình, và đường truyền phần dư giúp quá trình truyền độ dốc ổn định hơn nhiều so với mạng hồi quy.

Nhược điểm của TCN là vùng tiếp nhận bị cố định bởi cấu hình (k, L), không thể tiếp nhận thông tin từ các sự kiện nằm ngoài phạm vi R giờ. Khi suy luận trên các chuỗi rất dài, mô hình đòi hỏi dung lượng bộ nhớ lớn để lưu trữ các kích hoạt trung gian hoặc phải tính toán lặp lại từng đoạn.

2.2.4 Họ mô hình tự mã hóa

Họ mô hình này được huấn luyện chỉ dựa trên dữ liệu phụ tải bình thường nhằm học cách nén và tái tạo phân phối vận hành chuẩn. Bất kỳ quan trắc nào có sai số tái tạo vượt ngưỡng quy định đều bị coi là bất thường.

2.2.4.1 Mô hình tự mã hóa LSTM Mô hình tự mã hóa LSTM bao gồm một bộ mã hóa LSTM nén cửa sổ đầu vào $\mathbf{X}$ thành vector tiềm ẩn $\mathbf{z}$ và một bộ giải mã LSTM tái tạo lại chuỗi ban đầu (Malhotra và cộng sự [21]):

$$\mathbf{z} = E_\phi(\mathbf{X}), \quad \hat{\mathbf{X}} = D_\theta(\mathbf{z}), \quad \mathcal{L} = \frac{1}{w}\sum_{i=1}^{w} \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|_2^2$$

Vector sai số tái tạo $\mathbf{e}_t$ được mô hình hóa qua phân phối Gaussian nhiều chiều trên tập kiểm định, từ đó điểm bất thường được tính dựa trên khoảng cách Mahalanobis:

$$a_t = (\mathbf{e}_t - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{e}_t - \boldsymbol{\mu})$$

Ưu điểm của mô hình là không đòi hỏi nhãn bất thường trong quá trình huấn luyện, rất phù hợp triển khai cho các tòa nhà mới đưa vào vận hành. Mô hình phát hiện nhạy bén các dạng bất thường phá vỡ tính tuần hoàn của phụ tải và tạo ra chỉ số sai số liên tục có thể sử dụng làm đặc trưng bổ trợ.

Tuy nhiên, phương pháp này bỏ phí nguồn nhãn giám sát sẵn có của tập dữ liệu, khiến độ chính xác thường thấp hơn mô hình có giám sát. Đặc biệt, mô hình rất dễ bỏ sót các bất thường dạng phụ tải phẳng do chuỗi giá trị hằng số rất dễ tái tạo với sai số cực nhỏ. Ngoài ra, việc xác định ngưỡng quyết định phân loại trên khoảng cách Mahalanobis khá nhạy cảm và dễ bị sai lệch khi phân phối phụ tải giữa các công trình có sự chênh lệch lớn.

2.2.4.2 Mô hình tự mã hóa tích chập và tự mã hóa biến phân VAE Mô hình tự mã hóa tích chập thay thế các tầng hồi quy bằng các lớp tích chập một chiều để tăng tốc độ nén. Trong khi đó, mạng tự mã hóa biến phân VAE áp đặt ràng buộc phân phối xác suất tiên nghiệm lên không gian tiềm ẩn, tối ưu hóa cận dưới biến phân ELBO (Kingma và Welling [29]):

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} [\log p_\theta(\mathbf{x} \mid \mathbf{z})] - \beta \, D_{\text{KL}} (q_\phi(\mathbf{z} \mid \mathbf{x}) \,\|\, p(\mathbf{z}))$$

Các kiến trúc này từng được Handigol và Arjunan [7] khảo sát trên tập dữ liệu phụ tải LEAD.

Ưu điểm của nhóm này là cấu trúc gọn nhẹ, huấn luyện nhanh nhờ tính toán tích chập song song. Thành phần ngẫu nhiên trong VAE giúp không gian tiềm ẩn liên tục hơn, hạn chế hiện tượng học vẹt dữ liệu. Dù vậy, mô hình vẫn chịu chung hạn chế về việc bỏ sót bất thường phụ tải phẳng, và kết quả thực nghiệm được công bố cho thấy hiệu năng F1 của VAE và Conv-AE thường thấp hơn các kiến trúc đối kháng chuyên sâu.

2.2.4.3 Mô hình USAD Mô hình USAD kết hợp một bộ mã hóa chung với hai bộ giải mã đối kháng D_1 và D_2, vận hành qua hai pha huấn luyện nhằm vừa đảm bảo tính ổn định vừa khuếch đại sai số tái tạo đối với các mẫu bất thường (Audibert và cộng sự [23]). Với $AE_1 = D_1 \circ E$, $AE_2 = D_2 \circ E$ và n là chỉ số chu kỳ huấn luyện hiện tại:

$$\mathcal{L}_{AE_1} = \frac{1}{n} \|\mathbf{W} - AE_1(\mathbf{W})\|_2 + \left(1 - \frac{1}{n}\right) \|\mathbf{W} - AE_2 (AE_1(\mathbf{W}))\|_2$$

$$\mathcal{L}_{AE_2} = \frac{1}{n} \|\mathbf{W} - AE_2(\mathbf{W})\|_2 - \left(1 - \frac{1}{n}\right) \|\mathbf{W} - AE_2 (AE_1(\mathbf{W}))\|_2$$

Điểm bất thường là tổ hợp tuyến tính $\alpha \|\mathbf{W} - AE_1(\mathbf{W})\| + \beta \|\mathbf{W} - AE_2(AE_1(\mathbf{W}))\|$ với $\alpha + \beta = 1$.

Ưu điểm của USAD là quá trình huấn luyện ổn định và nhanh hơn nhiều so với các mô hình GAN truyền thống nhờ tránh được việc tối ưu hóa vector tiềm ẩn khi suy luận. Tuy nhiên, mô hình vẫn thuộc hệ hình học không giám sát dựa trên sai số tái tạo, nên không khai thác được nhãn mục tiêu và chưa có nhiều công bố thực nghiệm đối chứng trực tiếp trên bài toán phụ tải năng lượng công trình.

2.2.5 Họ mô hình sinh đối kháng

Mạng sinh đối kháng bao gồm mạng tạo sinh G và mạng phân biệt D tham gia vào trò chơi đối kháng minimax. Sau khi huấn luyện trên dữ liệu bình thường, mạng tạo sinh học được phân phối của hành vi phụ tải chuẩn:

$$\min_G \max_D \ \mathbb{E}_{\mathbf{x}} \left[\log D(\mathbf{x})\right] + \mathbb{E}_{\mathbf{z}} \left[\log \left(1 - D(G(\mathbf{z}))\right)\right]$$

Do không có sẵn bộ mã hóa ngược, quá trình phát hiện bất thường đòi hỏi phải tìm kiếm vector tiềm ẩn tối ưu $\mathbf{z}^*$ nhằm tái tạo sát nhất cửa sổ chuỗi đang kiểm tra (Schlegl và cộng sự [27], Bashar và Nayak [28]). Nghiên cứu của Orvati Nia và cộng sự [6] sử dụng hàm mục tiêu tối ưu hóa:

$$\mathbf{z}^* = \arg\min_{\mathbf{z}} \ (1 - \lambda) \left\|\mathbf{x} - G(\mathbf{z})\right\|_1 + \lambda \left\|f_D(\mathbf{x}) - f_D(G(\mathbf{z}))\right\|_1$$

với $f_D(\cdot)$ là biểu diễn đặc trưng trung gian của mạng phân biệt và $\lambda = 0{,}1$. Điểm bất thường được xác định từ giá trị hàm mục tiêu tại $\mathbf{z}^*$. Kiến trúc GAN-LSTM thay thế các tầng nơ-ron bằng các khối LSTM nhiều tầng để tăng cường năng lực mô hình hóa chuỗi.

Ưu điểm nổi bật của mô hình sinh đối kháng là khả năng học xấp xỉ phân phối xác suất thực tế của chuỗi phụ tải thay vì chỉ tối thiểu hóa sai số điểm ảnh, kết hợp hiệu quả giữa sai số tái tạo và đặc trưng phân biệt. Dù vậy, nhược điểm lớn nhất là chi phí suy luận khổng lồ do mỗi cửa sổ trượt đều đòi hỏi hàng trăm bước tối ưu hóa lặp để tìm vector tiềm ẩn, khiến việc chấm điểm từng giờ trên hàng triệu mẫu là bất khả thi trong thực tế vận hành. Quá trình huấn luyện mạng GAN cũng rất dễ mất ổn định hoặc gặp hiện tượng sụp đổ mốt sinh.

2.2.6 Họ mô hình Transformer

Kiến trúc Transformer áp dụng cơ chế tự chú ý cho phép mọi vị trí thời gian trong cửa sổ trượt liên kết và tương tác trực tiếp với nhau mà không phụ thuộc khoảng cách bước (Vaswani và cộng sự [36]):

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right)\mathbf{V}$$

Độ phức tạp tính toán của mỗi tầng tự chú ý là $\mathcal{O}(w^2 d)$ theo độ dài cửa sổ w. Trong lĩnh vực phát hiện bất thường chuỗi thời gian, mô hình Anomaly Transformer [25] đề xuất tiêu chí phân kỳ liên kết dựa trên nhận định rằng các điểm dị thường hiếm khi thiết lập được tương quan mạnh với toàn bộ chuỗi mà chỉ tập trung vào lân cận gần. Bên cạnh đó, mô hình TranAD [26] kết hợp cơ chế tự chú ý với huấn luyện đối kháng hai giai đoạn và kỹ thuật meta-learning để tăng cường khả năng tổng quát hóa trên chuỗi dữ liệu.

Ưu điểm vượt trội của Transformer là khả năng song song hóa hoàn toàn quá trình huấn luyện và mô hình hóa trực tiếp các mối liên hệ xa trên chu kỳ ngày và tuần. Mô hình đạt hiệu năng rất cao trên các tập dữ liệu chuẩn mực nhờ năng lực biểu diễn phong phú.

Ngược lại, nhược điểm của Transformer là chi phí tính toán và bộ nhớ GPU tăng theo hàm bậc hai theo chiều dài cửa sổ trượt, đồng thời số lượng tham số khổng lồ khiến mô hình rất dễ gặp quá khớp khi số lượng công trình huấn luyện bị giới hạn. Hơn nữa, hầu hết các biến thể Transformer công bố đều được thiết kế cho bài toán chuỗi đa biến không giám sát và áp dụng cơ chế hiệu chỉnh điểm số theo đoạn, vốn không phản ánh đúng thách thức phân lớp từng giờ có giám sát của bài toán hiện tại.

2.3 Các kỹ thuật bổ trợ hiện có để giải quyết bài toán

Trong bài toán phát hiện bất thường phụ tải điện, hiệu quả của mô hình không chỉ phụ thuộc vào thuật toán học máy hay học sâu cốt lõi mà còn chịu ảnh hưởng mang tính quyết định bởi cách thức biểu diễn dữ liệu và các kỹ thuật xử lý chuyên biệt. Hành vi tiêu thụ điện năng luôn gắn chặt với bối cảnh vật lý công trình, điều kiện khí tượng khu vực, tính chu kỳ sinh hoạt theo thời gian và hiện tượng mất cân bằng nhãn sâu sắc. Do đó, mục này tiến hành tổng quan các kỹ thuật bổ trợ hiện có trong tài liệu nghiên cứu, bao gồm kỹ thuật tương tác không gian vĩ mô, chuẩn hóa phụ tải theo ngữ cảnh, trích xuất động học chuỗi thời gian, phân cụm hành vi phụ tải, các hàm mất mát tùy biến và các cơ chế mô hình hóa nâng cao.

2.3.1 Kỹ thuật tương tác giữa địa điểm và công năng

Trong dữ liệu quản lý công trình, phụ tải tiêu thụ có sự phân hóa rõ rệt theo vị trí địa lý, điều kiện khí hậu và công năng sử dụng đặc thù của từng tòa nhà [5, 4]. Trong bộ dữ liệu ASHRAE, thuộc tính `site_id` định danh khu vực thu thập dữ liệu đi kèm trạm thời tiết tương ứng, trong khi `primary_use` đại diện cho loại hình công năng hoạt động.

Để nắm bắt quy mô vận hành ở cấp độ vĩ mô, các kỹ thuật kỹ nghệ đặc trưng thường trích xuất diện tích sàn trung bình của các tòa nhà theo từng phân vùng địa lý và theo từng nhóm công năng:

$$\bar{A}_S = \mathbb{E}_{\mathbf{x}\in\mathcal{D}_S}[\texttt{square_feet}], \qquad \bar{A}_U = \mathbb{E}_{\mathbf{x}\in\mathcal{D}_U}[\texttt{square_feet}]$$

Trên cơ sở hai đại lượng thống kê này, đặc trưng tương tác không gian vĩ mô được xác định thông qua tích số giữa hai cấp độ diện tích trung bình:

$$\texttt{zone_interaction} = \bar{A}_S \times \bar{A}_U$$

Nhằm tuân thủ nguyên tắc không rò rỉ dữ liệu, các giá trị kỳ vọng diện tích $\bar{A}_S$ và $\bar{A}_U$ bắt buộc phải được tính toán hoàn toàn trên tập dữ liệu huấn luyện, sau đó ánh xạ sang tập kiểm định và tập kiểm tra Out-of-sample.

Ưu điểm của kỹ thuật này là cung cấp cho các thuật toán phân lớp một thước đo định lượng về quy mô tương đối của công trình trong mối tương quan giữa khu vực và công năng sử dụng, hỗ trợ mô hình nhận diện các cụm phụ tải đặc thù mà không làm gia tăng số chiều phân loại. Đối với các công trình mới, thông tin siêu dữ liệu này giúp mô hình duy trì khả năng suy diễn khái quát hóa tốt hơn.

Tuy nhiên, nhược điểm là biến tương tác liên tục có độ phân tán giá trị rất lớn, đòi hỏi các thuật toán nhạy cảm với thang đo phải trải qua bước chuẩn hóa phù hợp. Ngoài ra, đây là các đặc trưng tĩnh ở cấp độ vĩ mô, do đó không thể nắm bắt được các biến động phụ tải vi mô tức thời theo từng khung giờ trong ngày của riêng từng tòa nhà.

2.3.2 Chuẩn hóa phụ tải theo ngữ cảnh

Lấy cảm hứng từ phương pháp chuẩn hóa phụ tải theo từng công trình của Orvati Nia và cộng sự [6], phụ tải được biểu diễn tương đối so với mức tiêu thụ quen thuộc của chính công trình đó nhằm tạo ra bốn biến ngữ cảnh vi mô:

1. Biến `z_meter_local` biểu diễn độ lệch chuẩn hóa của phụ tải so với mức tiêu thụ trung bình và độ lệch chuẩn của cùng công trình tại cùng khung giờ:

$$z_{\text{local}}(t) = \frac{x_t - \mu_{b,h}}{\sigma_{b,h}}$$

trong đó b đại diện cho mã công trình, h là giờ trong ngày, còn $\mu_{b,h}$ và $\sigma_{b,h}$ được ước lượng từ tập huấn luyện.

2. Biến `z_meter_workday` đo lường độ lệch phụ tải tương đối theo cùng công trình, cùng khung giờ và phân biệt rõ ngày làm việc với ngày nghỉ:

$$z_{\text{workday}}(t) = \frac{x_t - \mu_{b,d,h}}{\sigma_{b,d,h}}$$

với d là chỉ báo phân biệt ngày làm việc và ngày cuối tuần/ngày lễ.

3. Biến `z_meter_robust` áp dụng kỹ thuật chuẩn hóa bền vững dựa trên khoảng tứ phân vị nhằm triệt tiêu ảnh hưởng của các giá trị ngoại lai cực trị:

$$z_{\text{robust}}(t) = \frac{x_t - \text{median}_b}{\text{IQR}_b}$$

4. Biến `temp_load_inter` mô hình hóa sự tương tác trực tiếp giữa mức độ lệch phụ tải theo loại ngày và nhiệt độ môi trường xung quanh:

$$\texttt{temp_load_inter}(t) = z_{\text{workday}}(t) \times \texttt{air_temperature}(t)$$

Ưu điểm nổi bật của phương pháp chuẩn hóa theo ngữ cảnh là giúp mô hình phát hiện được các điểm tiêu thụ bất thường của một tòa nhà ngay cả khi giá trị công suất tuyệt đối vẫn nằm hoàn toàn trong dải biến thiên thông thường của toàn bộ quần thể dữ liệu. Sự kết hợp giữa thời gian biểu và nhiệt độ môi trường cung cấp bối cảnh vận hành chân thực để phân biệt giữa nhu cầu sử dụng đột biến do thời tiết với các sự cố bất thường thực sự.

Dù vậy, nhược điểm là kỹ thuật này phụ thuộc chặt chẽ vào độ tin cậy của chuỗi thống kê lịch sử. Nếu giai đoạn đo đạc cơ sở chứa quá nhiều dữ liệu lỗi hoặc độ dài quan trắc không đủ lớn, các giá trị kỳ vọng sẽ bị sai lệch. Hơn nữa, phương pháp này khó có thể áp dụng ngay cho các tòa nhà hoàn toàn mới khi chưa tích lũy đủ dữ liệu vận hành lịch sử.

2.3.3 Đặc trưng động học chuỗi thời gian và thành phần phân rã

Trong giải pháp vô địch cuộc thi LEAD, Fu và cộng sự [2] đã chứng minh vai trò quyết định của các đặc trưng động học chuỗi thời gian dưới dạng biến trễ, sai phân bậc một bậc hai và tỷ số biến thiên phụ tải. Dựa trên cơ sở đó, hệ thống tám đặc trưng động học mở rộng được thiết lập bao gồm:

1. Các biến trễ vi mô `meter_lag_1h` và `meter_lag_2h` phản ánh mức tiêu thụ điện năng tại một và hai bước thời gian trước đó:

$$\texttt{meter_lag_k}_t = m_{t-k}, \qquad k \in \{1, 2\}$$

2. Các biến sai phân vận tốc `meter_diff_1h` và `meter_diff_2h` đo lường tốc độ thay đổi tức thời của phụ tải:

$$\texttt{meter_diff_k}_t = m_t - m_{t-k}, \qquad k \in \{1, 2\}$$

3. Các biến tỷ số động năng `meter_ratio_1h` và `meter_ratio_2h` nắm bắt biên độ gia tăng công suất tương đối:

$$\texttt{meter_ratio_k}_t = \frac{m_t + 1}{m_{t-k} + 1}, \qquad k \in \{1, 2\}$$

4. Biến thời lượng đóng băng `flatline_duration` đếm số giờ liên tiếp mà mức tiêu thụ điện của công trình gần như không đổi ($|m_t - m_{t-1}| \leq 10^{-4}$), hỗ trợ nhận diện các sự cố cảm biến bị treo hoặc lỗi truyền thông.

5. Biến thành phần phân rã `stl_residual` đo lường độ sai lệch giữa phụ tải hiện tại so với trung vị của cùng khung giờ trong bảy ngày trước đó:

$$\texttt{stl_residual}_t = m_t - \text{median}\{m_{t-24d} \mid d = 1, \ldots, 7\}$$

Ưu điểm lớn nhất của nhóm đặc trưng này là cung cấp tín hiệu trực tiếp về chiều hướng và tốc độ biến thiên phụ tải, cho phép các mô hình phát hiện tức thì các cú sốc tải hoặc sụt áp đột ngột. Cơ chế đếm đoạn phẳng giải quyết triệt để bài toán nhận diện cảm biến đóng băng, trong khi thành phần phần dư chu kỳ giúp loại bỏ nhịp điệu sinh hoạt 24 giờ để làm nổi bật dị thường.

Ngược lại, nhược điểm là các biến trễ đòi hỏi tính liên tục nghiêm ngặt của chuỗi thời gian. Tại các mốc khởi đầu chuỗi hoặc sau các khoảng trống dữ liệu bị mất kết nối, giá trị trễ sẽ bị khuyết và cần chiến lược điền bù dự phòng an toàn. Ngoài ra, ngưỡng phát hiện đoạn phẳng đòi hỏi phải được tinh chỉnh phù hợp với độ phân giải của từng loại công tơ đo đạc.

2.3.4 Kỹ thuật phân cụm hành vi phụ tải

Kỹ thuật phân cụm nhóm các tòa nhà dựa trên hình thái tiêu thụ thực tế thay vì phụ thuộc hoàn toàn vào nhãn công năng danh nghĩa. Mỗi tòa nhà có thể được biểu diễn bằng một vector đặc trưng hồ sơ phụ tải $\mathbf{v}_i \in \mathbb{R}^D$, chẳng hạn vector 168 chiều mô tả công suất tiêu thụ trung bình qua từng giờ trong tuần. Thuật toán K-Means [16] tối ưu hóa hàm mục tiêu phân cụm theo khoảng cách:

$$\mathcal{J} = \sum_{k=1}^{K} \sum_{\mathbf{v}_i \in \mathcal{C}_k} \|\mathbf{v}_i - \boldsymbol{\mu}_k\|_2^2$$

với $\boldsymbol{\mu}_k$ là vector trọng tâm của cụm thứ k. Phương pháp này từng được Cansever và Konyar [9] ứng dụng để chia nhóm công trình trước khi huấn luyện các mô hình phát hiện dị thường chuyên biệt.

Về ưu điểm, phân cụm hồ sơ tiêu thụ giúp phân tách các nhóm công trình có hình thái phụ tải tương đồng, phản ánh trung thực thực tế vận hành vượt ra ngoài ranh giới phân loại công năng ban đầu. Nhãn cụm có thể tích hợp trực tiếp vào mô hình như một đặc trưng bổ trợ giá trị.

Tuy vậy, nhược điểm là kết quả phân cụm rất nhạy cảm với việc lựa chọn số lượng cụm K và độ đo khoảng cách. Khoảng cách Euclidean thông thường dễ bị ảnh hưởng bởi hiện tượng lệch pha thời gian hoặc chênh lệch quy mô công suất giữa các tòa nhà lớn và nhỏ.

2.3.5 Hàm mất mát entropy chéo có trọng số

Nhằm xử lý trực tiếp tình trạng mất cân bằng lớp nghiêm trọng trong bài toán phát hiện dị thường, hàm mất mát entropy chéo có trọng số gán hệ số phạt w_+ cao hơn cho các sai sót phân loại trên lớp bất thường:

$$\mathcal{L}_{\text{WBCE}} = -\frac{1}{N}\sum_{i=1}^{N}\left[w_+\, y_i \log \hat{p}_i + (1-y_i)\log\left(1-\hat{p}_i\right)\right]$$

với $\hat{p}_i$ là xác suất dự đoán và $y_i \in \{0,1\}$. Hệ số này tương ứng với tham số điều chỉnh tỷ lệ mẫu dương trong các thư viện học máy và học sâu phổ biến.

Ưu điểm của kỹ thuật là tính đơn giản, dễ triển khai và có thể tích hợp trực tiếp vào quá trình tối ưu hóa đạo hàm của mô hình mà không cần can thiệp lấy mẫu lại dữ liệu, từ đó ngăn chặn hiện tượng mô hình hội tụ về giải pháp tầm thường là dự đoán toàn bộ mẫu thuộc lớp bình thường.

Mặc dù vậy, việc áp đặt trọng số phạt quá cao có thể làm méo mó xác suất dự đoán thực tế, khiến mô hình phản ứng quá nhạy với các biến động phụ tải nhẹ và làm gia tăng đáng kể số lượng cảnh báo giả, đòi hỏi phải tiến hành dò tìm lại ngưỡng phân loại tối ưu.

2.3.6 Hàm mất mát Focal Loss

Hàm mất mát Focal Loss được Lin và cộng sự [37] phát triển nhằm giải quyết triệt để sự áp đảo của các mẫu dễ học trong bài toán mất cân bằng nhãn. Bằng cách bổ sung thừa số suy giảm động $(1-p_t)^\gamma$, hàm mất mát tự động triệt tiêu đóng góp đạo hàm từ các mẫu mà mô hình đã phân loại tự tin:

$$\text{FL}(p_t) = -\alpha_t\left(1-p_t\right)^\gamma \log\left(p_t\right)$$

trong đó p_t là xác suất mô hình gán cho lớp chính xác, α_t là hệ số cân bằng nhãn và $\gamma \geq 0$ là tham số điều biến mức độ tập trung vào các mẫu khó.

Ưu điểm nổi bật của Focal Loss là tập trung tối đa tài nguyên học của mô hình vào các trường hợp biên khó phân định, hạn chế tình trạng hàm mất mát bị chi phối bởi hàng triệu quan trắc bình thường dễ nhận biết.

Nhược điểm là hàm đưa thêm hai siêu tham số (α, γ) vào không gian tìm kiếm, đòi hỏi chi phí tinh chỉnh bổ sung. Ngoài ra, điểm số đầu ra của mô hình sau khi tối ưu với Focal Loss không còn mang ý nghĩa xác suất hiệu chuẩn thực tế và cần qua bước cân chỉnh nếu muốn sử dụng làm xác suất tin cậy.

2.3.7 Mạng tích chập thời gian kết hợp bộ tự mã hóa TCN

Kiến trúc TCN kết hợp bộ tự mã hóa ứng dụng các phép tích chập nhân quả giãn cách trong cả nhánh mã hóa và giải mã nhằm học cách khôi phục chuỗi thời gian thông qua một nút thắt cổ chai đại diện [24, 7]. Điểm số bất thường được xác định dựa trên mức độ sai số tái tạo giữa chuỗi thực tế và chuỗi khôi phục.

Ưu điểm của mô hình là tốc độ huấn luyện vượt bậc nhờ khả năng song song hóa hoàn toàn của phép toán tích chập một chiều trên GPU, kết hợp cùng vùng tiếp nhận mở rộng lũy thừa giúp bao quát toàn diện các chu kỳ phụ tải ngày và tuần.

Tuy nhiên, nhược điểm là nếu không gian nút thắt cổ chai không được thiết kế đủ hẹp, mạng có thể học tái tạo cả các đoạn phụ tải bất thường. Bên cạnh đó, các phép toán tích chập nhiều kênh trên kích thước lô lớn đòi hỏi dung lượng bộ nhớ GPU đáng kể.

2.3.8 Cơ chế tự chú ý trong mô hình chuỗi

Cơ chế tự chú ý trong kiến trúc Transformer [36] cho phép tính toán trực tiếp trọng số tương quan giữa mọi cặp thời điểm trong chuỗi phụ tải thông qua các phép chiếu ma trận truy vấn, khóa và giá trị:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right)\mathbf{V}$$

Ưu điểm chính của cơ chế tự chú ý là khả năng mô hình hóa sự phụ thuộc xa mà không bị suy giảm thông tin theo bước truyền như mạng hồi quy, cho phép liên kết trực tiếp giữa các thời điểm cách nhau nhiều ngày trong cùng một chu kỳ vận hành. Ma trận chú ý đồng thời cung cấp khả năng trực quan hóa mức độ quan trọng của các mốc thời gian lịch sử đối với dự đoán hiện tại.

Dù vậy, nhược điểm là chi phí tính toán và bộ nhớ tăng theo hàm bậc hai $O(w^2)$ theo chiều dài cửa sổ trượt, gây hạn chế lớn khi muốn mở rộng phạm vi ngữ cảnh. Hơn nữa, cơ chế này đòi hỏi lượng dữ liệu chuỗi rất lớn để tối ưu hóa ổn định, dễ rơi vào trạng thái quá khớp khi tập dữ liệu bị giới hạn về số lượng công trình.

2.3.9 Hàm mất mát căn chỉnh thời gian mềm khả vi Soft-DTW

Kỹ thuật Soft-DTW [31] là phiên bản làm trơn khả vi của thuật toán căn chỉnh thời gian động cổ điển, từng được Prabhu và cộng sự [8] sử dụng làm hàm mất mát tái tạo cho mô hình phát hiện dị thường chuỗi năng lượng:

$$\text{Soft-DTW}_\gamma(\mathbf{x}, \hat{\mathbf{x}}) = \text{soft-min}_\gamma\left(\{\langle \mathbf{A}_\pi, \boldsymbol{\Delta}(\mathbf{x}, \hat{\mathbf{x}})\rangle\}_{\pi \in \mathcal{A}}\right)$$

với $\boldsymbol{\Delta}$ là ma trận khoảng cách giữa các điểm chuỗi, $\mathcal{A}$ là tập hợp các đường căn chỉnh hợp lệ và phép lấy cực tiểu mềm soft-min_γ cho phép tính toán đạo hàm phục vụ lan truyền ngược.

Ưu điểm của Soft-DTW là khả năng dung nạp các sai lệch lệch pha thời gian nhỏ trong nhịp phụ tải, giúp mô hình không phạt nặng các biến động tiêu thụ bình thường chỉ bị trễ giờ nhẹ so với lịch biểu thông thường.

Ngược lại, nhược điểm là thuật toán quy hoạch động có độ phức tạp tính toán bậc hai $O(w^2)$, làm chậm đáng kể quá trình huấn luyện mô hình. Đặc biệt, nếu sự cố bất thường trong thực tế chính là việc chậm giờ đóng cắt thiết bị, cơ chế co dãn đàn hồi của Soft-DTW có thể vô tình xem sự cố này là hành vi bình thường và bỏ sót lỗi.

2.3.10 Mô hình chuỗi có điều kiện theo siêu dữ liệu

Hướng tiếp cận có điều kiện kết hợp các thuộc tính siêu dữ liệu tĩnh như vị trí khu vực, loại hình công năng hoặc nhãn cụm hành vi vào không gian biểu diễn ẩn của mạng chuỗi thông qua cơ chế điều biến tuyến tính FiLM [32]:

$$\mathbf{h}'_t = \boldsymbol{\gamma}(\mathbf{e}) \odot \mathbf{h}_t + \boldsymbol{\beta}(\mathbf{e})$$

trong đó $\mathbf{e}$ là vector nhúng của siêu dữ liệu, $\mathbf{h}_t$ là trạng thái ẩn của chuỗi thời gian, còn $\boldsymbol{\gamma}$ và $\boldsymbol{\beta}$ là các mạng biến đổi tuyến tính điều khiển hệ số co giãn và độ lệch.

Ưu điểm của kỹ thuật là giúp mạng thích ứng linh hoạt các trạng thái biểu diễn chuỗi theo bối cảnh vật lý cụ thể của từng công trình, nâng cao khả năng khái quát hóa khi áp dụng mô hình chung cho nhiều nhóm tòa nhà khác nhau.

Tuy nhiên, việc tích hợp thêm các ma trận nhúng và mạng điều biến làm gia tăng số lượng tham số, đòi hỏi các biện pháp điều chuẩn chặt chẽ để phòng chống quá khớp. Hơn nữa, mô hình phụ thuộc nghiêm ngặt vào tính sẵn sàng của siêu dữ liệu tại thời điểm suy luận.

2.3.11 Mô hình sinh đối kháng kết hợp mạng LSTM

Mô hình GAN-LSTM kết hợp mạng sinh đối kháng với các tầng hồi quy LSTM nhằm học phân phối của chuỗi phụ tải bình thường trên các cửa sổ thời gian kéo dài (Orvati Nia và cộng sự [6]). Khi suy luận, điểm bất thường kết hợp giữa sai số tái tạo và độ lệch đặc trưng phân biệt:

$$\mathcal{S}(\mathbf{x}) = \lambda\, \mathcal{L}_{\text{rec}}(\mathbf{x}, G(\mathbf{z}^*)) + (1-\lambda)\, \mathcal{L}_{\text{feat}}(f_D(\mathbf{x}), f_D(G(\mathbf{z}^*)))$$

trong đó $\mathbf{z}^*$ là vector tiềm ẩn tối ưu được tìm kiếm tại thời điểm suy luận và f_D là biểu diễn đặc trưng trung gian của mạng phân biệt.

Ưu điểm của phương pháp là học được phân phối chuẩn xác của chuỗi thời gian mà không phụ thuộc vào nhãn bất thường, đồng thời tận dụng bộ nhớ LSTM để duy trì hình thái tuần hoàn của phụ tải qua nhiều khung giờ.

Mặt khác, nhược điểm lớn là quá trình tối ưu hóa vector tiềm ẩn khi suy luận đòi hỏi hàng trăm vòng lặp tính toán cho mỗi cửa sổ, tạo ra nút thắt cổ chai nghiêm trọng về tốc độ xử lý khi áp dụng cho các hệ thống giám sát quy mô lớn. Việc đánh giá theo cửa sổ gộp cũng làm giảm độ chính xác định vị thời điểm phát sinh bất thường.

2.3.12 Mô hình sinh đối kháng tích chập một chiều

Kiến trúc DCGAN một chiều sử dụng các tầng tích chập sâu để xử lý cửa sổ phụ tải điện năng (Handigol và Arjunan [7]). Mạng tạo sinh sinh ra chuỗi nhân tạo từ vector ngẫu nhiên, trong khi mạng phân biệt đối kháng đánh giá tính chân thực của chuỗi đo đạc. Điểm bất thường được suy luận trực tiếp từ sai số tái tạo:

$$\mathcal{S}(\mathbf{x}) = \mathcal{L}_{\text{rec}}(\mathbf{x}, \hat{\mathbf{x}})$$

Ưu điểm nổi bật là tốc độ tính toán song song nhanh hơn đáng kể so với các mô hình GAN dựa trên LSTM, cùng khả năng trích xuất nhạy bén các đặc trưng hình thái sóng cục bộ như gai tải đột biến hoặc các khoảng giá trị đóng băng.

Dù vậy, việc sử dụng các tầng tích chập chuyển vị có thể gây ra hiện tượng méo chuỗi hoặc sinh mẫu tuần hoàn giả nếu không thiết lập cẩn trọng kích thước bộ lọc. Ngoài ra, khả năng duy trì sự phụ thuộc dài hạn của mạng tích chập bị giới hạn bởi độ sâu của các tầng tích chập.

2.3.13 Kỹ thuật tái tạo song song nhiều điểm

Để giải quyết nút thắt cổ chai về tốc độ của mô hình AnoGAN [27], kỹ thuật tái tạo song song thực hiện tối ưu hóa đồng thời nhiều cửa sổ quan sát theo lô trên bộ xử lý đồ họa GPU (Prabhu và cộng sự [8]):

$$\mathbf{z}^* = \arg\min_{\mathbf{z}} \mathcal{L}_{\text{rec}}(\mathbf{x}, G(\mathbf{z}))$$

Ưu điểm của kỹ thuật là tận dụng năng lực xử lý đa luồng của phần cứng để tăng thông lượng suy luận, giảm thiểu thời gian chờ đợi khi phải rà soát các tệp dữ liệu lớn.

Tuy nhiên, bản chất của phương pháp vẫn đòi hỏi các bước cập nhật độ dốc lặp đi lặp lại tại thời điểm suy luận, do đó mức độ tiêu tốn bộ nhớ GPU vẫn còn tương đối cao và tốc độ chưa thể so sánh trực tiếp với các mô hình phân lớp xuôi chiều một lượt.

Tổng thể các kỹ thuật bổ trợ trên cung cấp một hệ thống giải pháp đa tầng từ cấp độ không gian vĩ mô, ngữ cảnh vi mô cho đến động học chuỗi thời gian, tạo nền tảng lý thuyết vững chắc để nhóm nghiên cứu xây dựng và tối ưu hóa các không gian dữ liệu thực nghiệm trong các chương tiếp theo.

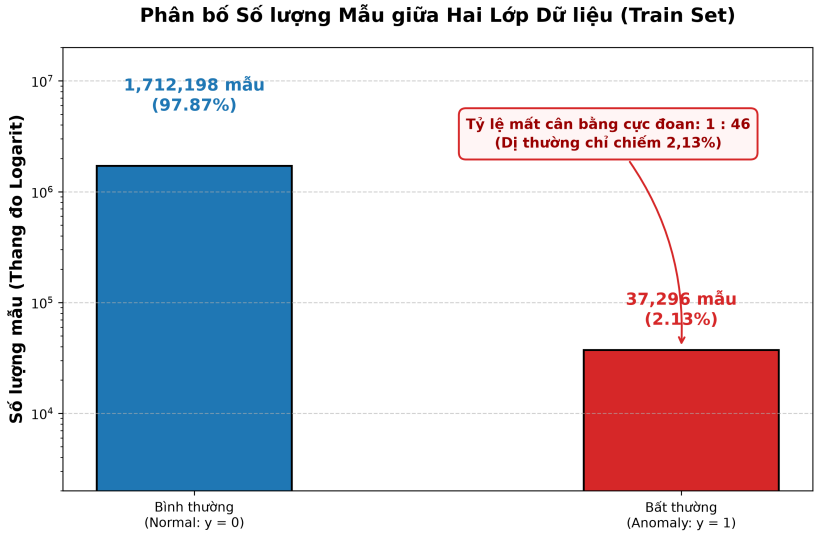
3 Tiền xử lý và Khám phá Dữ liệu

Dựa trên tệp `train_features.csv` đã giới thiệu ở Chương 1, chương này trình bày khám phá dữ liệu ban đầu, tiếp theo là quy trình tiền xử lý dữ liệu tăng tiến qua bốn không gian đặc trưng và cuối cùng là khám phá và kiểm toán dữ liệu sau khi đã hoàn tất quy trình tiền xử lý.

3.1 Khám phá Dữ liệu Ban đầu

3.1.1 Phân tích sự Mất cân bằng Lớp Dữ liệu

Dữ liệu nhãn bất thường phản ánh trạng thái hoạt động của hệ thống phụ tải điện: $y = 0$ tương ứng với trạng thái bình thường và $y = 1$ tương ứng với trạng thái bất thường. Trong 1.749.494 bản ghi của `train_features.csv`, có 1.712.198 bản ghi bình thường (97,87%) và 37.296 bản ghi bất thường (2,13%), tương đương khoảng một mẫu bất thường trên 46 mẫu quan trắc.

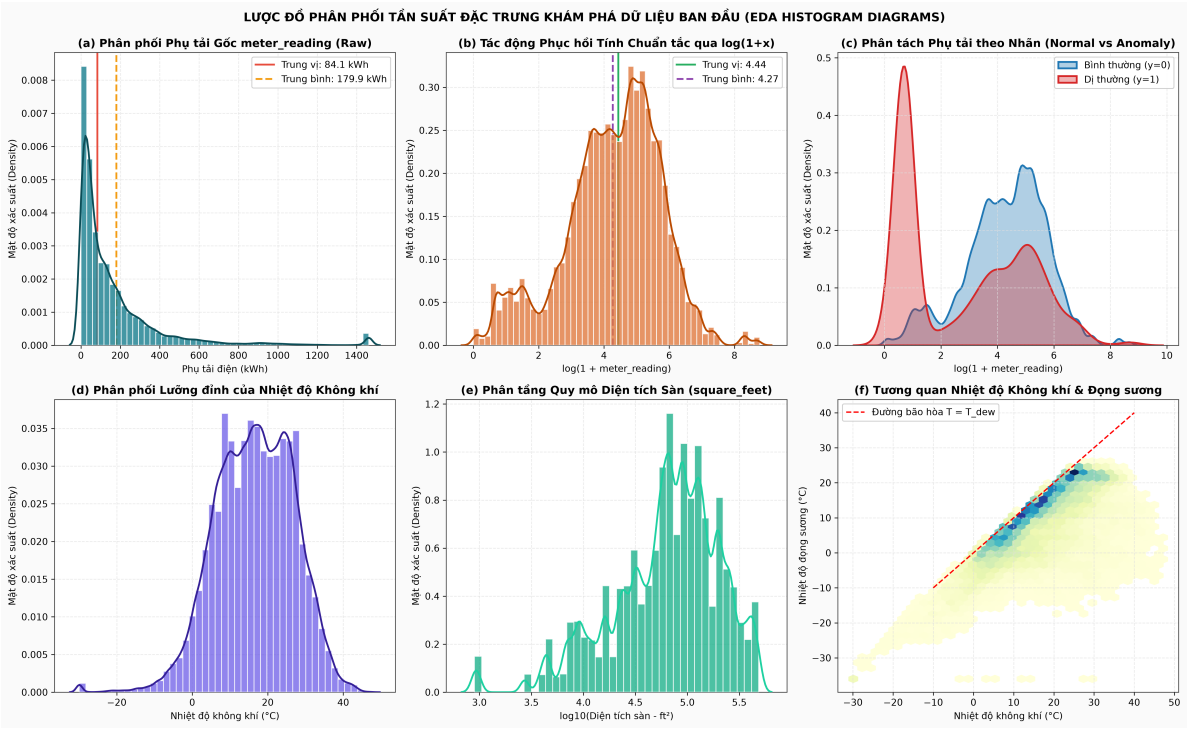


Hình 1: Phân phối mức độ mất cân bằng giữa nhãn bình thường và bất thường

Với tỷ lệ lớp xấp xỉ 1 : 46, một bộ dự đoán tầm thường luôn chọn nhãn bình thường vẫn đạt độ chính xác Accuracy khoảng 97,87% nhưng lại bỏ sót toàn bộ các sự cố bất thường thực tế. Do đó, chỉ số diện tích dưới đường cong PR-AUC là thước đo chính xác và phù hợp nhất để đánh giá toàn diện mô hình, trong khi Precision, Recall và F1-Score đóng vai trò bổ sung góc nhìn hiệu năng tại từng ngưỡng quyết định phân loại cụ thể.

3.1.2 Phân tích Phân phối Tần suất Đặc trưng

Bên cạnh phân bố nhãn, Hình 2 minh họa phân phối của một số thuộc tính đầu vào và phụ tải theo nhãn trên mẫu ngẫu nhiên tối đa 300.000 bản ghi.



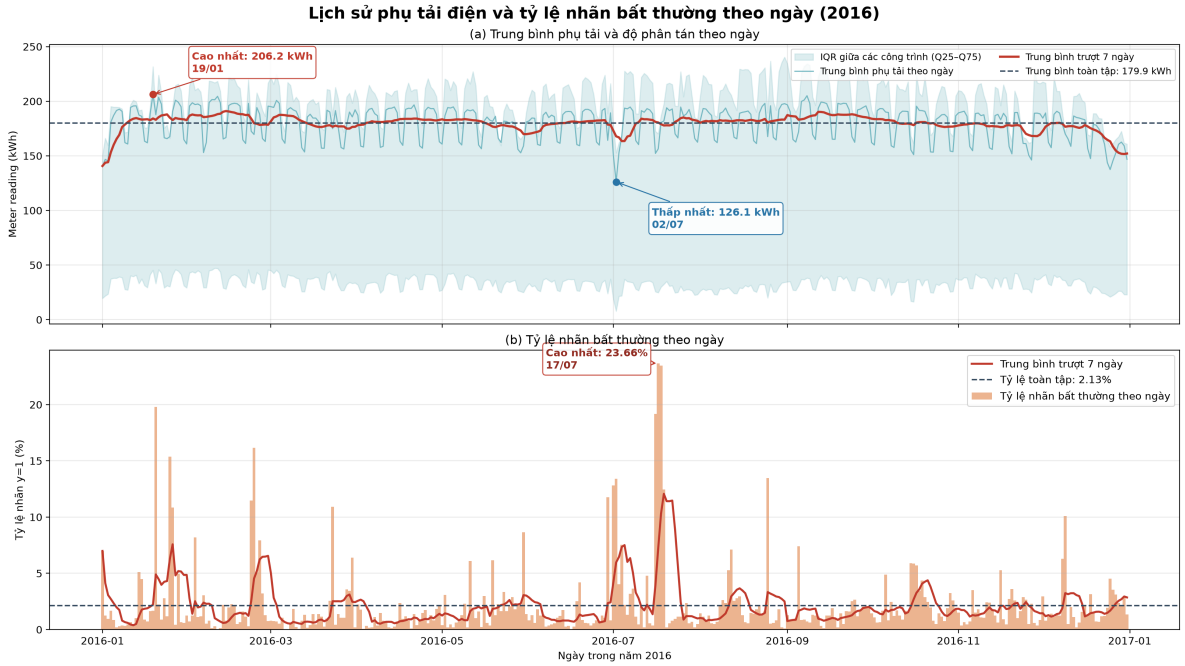
Hình 2: Lược đồ Phân phối Tần suất Đặc trưng Khám phá Dữ liệu Ban đầu

Phân phối mức tiêu thụ điện `meter_reading` có hiện tượng lệch phải rõ rệt: trên các quan sát không khuyết, giá trị trung bình là 179,90 kWh, cao hơn nhiều so với trung vị 84,10 kWh, trong khi giá trị lớn nhất đạt tới 6.596,89 kWh và hệ số độ lệch là +9,15. Đồ thị sử dụng phép biến đổi $\ln(1+x)$ và giới hạn trục đến phân vị 99 để thể hiện rõ nét phần lớn quan sát. Xét theo nhãn mục tiêu, lớp bất thường có xu hướng tập trung nhiều hơn ở vùng phụ tải thấp. Tuy nhiên, hai phân phối vẫn chồng lấn đáng kể, khẳng định rằng giá trị phụ tải tức thời riêng lẻ chưa đủ khả năng phân tách rạch ròi giữa trạng thái bình thường và bất thường.

Các thuộc tính môi trường và công trình cũng ghi nhận độ phân tán cao: nhiệt độ không khí tập trung mật độ lớn ở hai khoảng 8–12°C và 24–28°C, trong khi diện tích sàn công trình trải rộng qua nhiều bậc độ lớn ngay cả khi biểu diễn trên thang đo $\log_{10}$. Nhiệt độ không khí và nhiệt độ điểm sương có xu hướng biến thiên đồng chiều. Những quan sát thực nghiệm này chứng minh rằng quy mô vật lý công trình và điều kiện khí tượng khu vực là các yếu tố bối cảnh then chốt cần được mô hình hóa song hành cùng phụ tải.

3.1.3 Toàn cảnh Lịch sử Phụ tải và Phân bố Dị thường theo Thời gian

Nhằm nắm bắt toàn diện hành vi phụ tải ở cấp độ vĩ mô và sự phân bố của các biến cố dị thường xuyên suốt 366 ngày trong năm 2016, nhóm nghiên cứu xây dựng lược đồ lịch sử vận hành trên toàn bộ 200 tòa nhà thuộc tập huấn luyện (Hình 3).

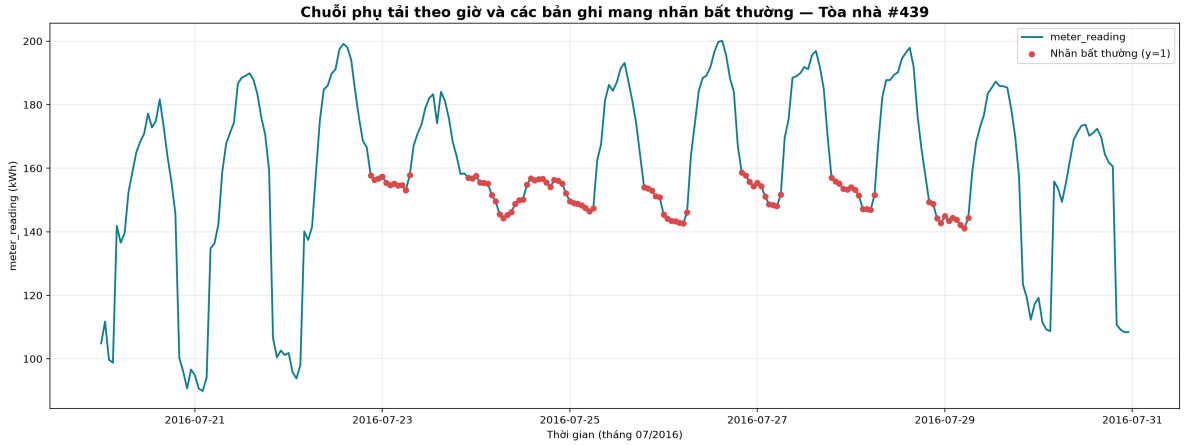


Hình 3: Lược đồ Lịch sử Phụ tải Điện và Tỷ lệ Dị thường theo Ngày trong năm 2016

Hình 3 cho thấy mức phụ tải trung bình toàn hệ thống biến thiên liên tục trong năm: đạt đỉnh 206,2 kWh vào ngày 19/01 và giảm dần xuống 126,1 kWh vào ngày 02/07. Đường trung bình trượt 7 ngày (MA-7) phản ánh rõ nét xu hướng biến động ngắn hạn, trong khi dải khoảng tứ phân vị IQR thể hiện sự phân hóa rõ rệt giữa các quy mô công trình. Tỷ lệ bất thường toàn tập là 2,13% nhưng phân bố không đều theo ngày, đạt mức cao nhất 23,66% vào ngày 17/07, trong đó các ngày có tỷ lệ sự cố cao thường tập trung thành chuỗi kế tiếp nhau. Đặc trưng này khẳng định dữ liệu có cấu trúc thời gian chặt chẽ, đòi hỏi quy trình chia tập dữ liệu phải tuân thủ nghiêm ngặt tính trật tự thời gian.

3.1.4 Quan sát Nhãn Bất thường trên Chuỗi Thời gian

Hình 4 minh họa phụ tải theo giờ và các bản ghi mang nhãn bất thường tại Tòa nhà #439 trong tháng 7/2016.

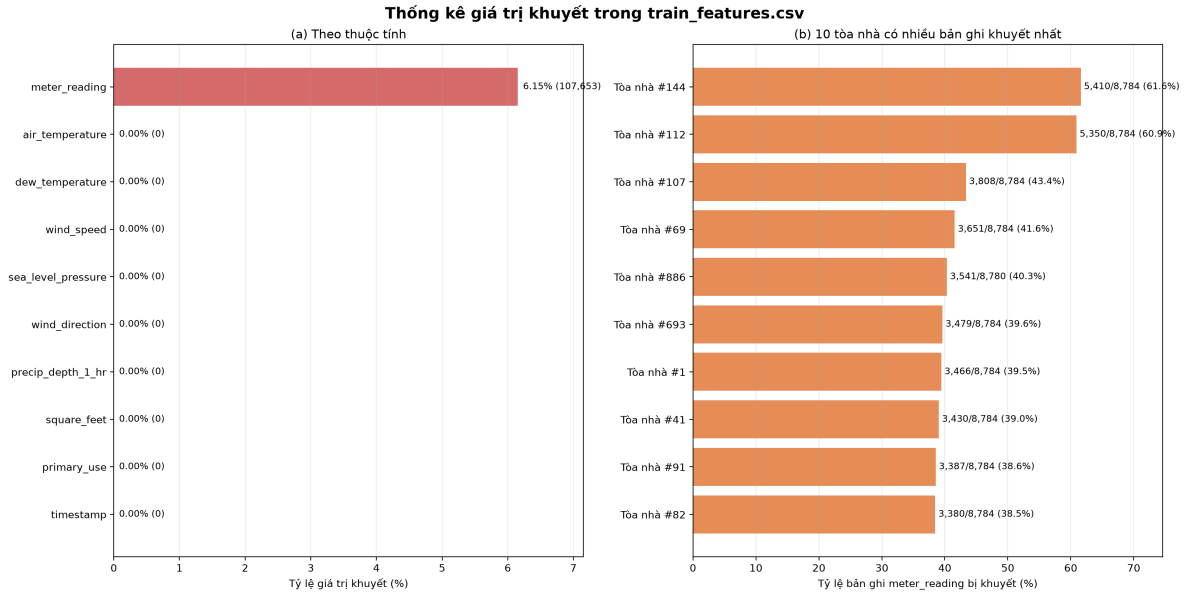


Hình 4: Chuỗi thời gian phụ tải điện theo giờ và các bản ghi mang nhãn bất thường tại Tòa nhà #439

Trong cửa sổ quan trắc minh họa, đồ thị phụ tải thể hiện rõ chu kỳ ngày đêm, và các nhãn bất thường ($y = 1$) có xu hướng xuất hiện tập trung thành từng đoạn liên tiếp kéo dài nhiều giờ. Điều này cho thấy các biểu hiện bất thường phụ tải có mối liên hệ chặt chẽ với diễn tiến chuỗi thời gian nội tại của từng tòa nhà riêng biệt.

3.1.5 Tình trạng Thiếu Dữ liệu

Bên cạnh bài toán mất cân bằng nhãn, dữ liệu đo đạc thực tế xuất hiện các giá trị phụ tải bị khuyết do sự cố truyền thông hoặc lỗi thiết bị đo. Hình 5 tổng hợp tỷ lệ khuyết theo thuộc tính và số bản ghi phụ tải khuyết tại một số công trình tiêu biểu trong tệp `train_features.csv` (1.749.494 bản ghi).



Hình 5: Thống kê giá trị khuyết trên tập huấn luyện: tỷ lệ khuyết theo thuộc tính (trái) và 10 tòa nhà có nhiều bản ghi phụ tải khuyết nhất (phải)

Kết quả kiểm tra cho thấy giá trị khuyết tập trung duy nhất ở thuộc tính phụ tải `meter_reading` với 107.653 bản ghi (chiếm 6,15%), trong khi 56 thuộc tính thời tiết và công trình còn lại hoàn toàn đầy đủ. Hiện tượng khuyết dữ liệu có tính chất tập trung cao độ ở một số công trình cá biệt: tòa nhà #144 có tới 5.410/8.784 giờ bị khuyết (61,6%) và tòa nhà #112 có 5.350/8.784 giờ bị khuyết (60,9%). Do đó, quy trình tiền xử lý bắt buộc phải lưu giữ một biến cờ nhị phân ghi nhận vị trí thiếu trước khi tiến hành điền giá trị ước lượng.

3.2 Quy trình Tiền xử lý Dữ liệu

Quy trình tiền xử lý được chuẩn hóa theo nguyên tắc không rò rỉ dữ liệu, xây dựng bốn bộ dữ liệu tăng tiến trên cùng một nền tảng mẫu và phương thức chia tập:

1. **Baseline:** Gồm 38 đặc trưng nền tảng (39 cột tính cả nhãn mục tiêu `anomaly`).

2. **Zone-Enhanced:** Kế thừa Baseline và tích hợp thêm 3 đặc trưng tương tác quy mô khu vực, tổng cộng gồm 41 đặc trưng (42 cột tính cả nhãn).

3. **Context-Aware:** Kế thừa Zone-Enhanced và bổ sung 4 đặc trưng ngữ cảnh vi mô, tổng cộng gồm 45 đặc trưng (46 cột tính cả nhãn).

4. **Expanded Champion:** Kế thừa Context-Aware và tích hợp thêm 8 đặc trưng động học chuỗi thời gian cùng thành phần phân rã chu kỳ mùa vụ, tổng cộng gồm 53 đặc trưng (54 cột tính cả nhãn).

3.2.1 Giao thức Phân chia Chuỗi Thời gian Chu kỳ Mùa vụ và 96 Giờ Cách ly

Để triệt tiêu hoàn toàn nguy cơ rò rỉ thông tin qua các bước thời gian tương lai, dữ liệu được phân chia theo chu kỳ ngày trong tháng kết hợp vùng đệm cách ly 96 giờ. Việc thiết lập khoảng cách ly này được tính toán cẩn trọng dựa trên đặc trưng trễ khí tượng dài nhất là 73 giờ (≈ 3 ngày) để đảm bảo không có bất kỳ thông tin trễ nào vắt qua ranh giới giữa hai tập.

Cụ thể, tập huấn luyện (T_{in}) bao gồm từ ngày 01 đến ngày 20 hàng tháng với 1.147.089 bản ghi ($\approx 65{,}6\%$), là cơ sở duy nhất để học các tham số thống kê và xây dựng các bảng tra cứu. Khoảng cách ly (T_{gap}) kéo dài từ ngày 21 đến ngày 24 với 229.412 bản ghi ($\approx 13{,}1\%$), được loại bỏ hoàn toàn khỏi thực nghiệm để tạo vùng đệm 96 giờ cách ly tuyệt đối. Cuối cùng, tập kiểm tra ngoài mẫu (T_{out}) bao gồm từ ngày 25 đến hết tháng với 372.993 bản ghi ($\approx 21{,}3\%$), chỉ được phép áp dụng các phép biến đổi chiếu đã được học từ tập huấn luyện.

Chi tiết các bước biến đổi đặc trưng trong quy trình tiền xử lý được triển khai tuần tự như sau:

1. **Bước 1: Tách nhãn mục tiêu và bảo toàn chỉ mục.** Vector nhãn $y_{\text{train}} =$ `anomaly` được tách riêng và thiết lập chỉ mục liên tục để phục vụ bài toán phân loại có giám sát, bảo đảm tuyệt đối không xuất hiện trong ma trận biến độc lập X.

2. **Bước 2: Chuẩn hóa thời gian và mã hóa chu kỳ lượng giác** sin / cos**.** Trường `timestamp` được chuyển đổi sang chuẩn thời gian `datetime64[ns]`. Do thời gian mang bản chất chu kỳ khép kín (giờ 23 và giờ 0 liền kề nhau), việc biểu diễn bằng số nguyên thông thường sẽ làm gãy tính liên tục hình học. Vì vậy, các thành phần thời gian được mã hóa thành các tọa độ lượng giác trên đường tròn đơn vị:

$$x_{\sin} = \sin\left(\frac{2\pi t}{T}\right), \quad x_{\cos} = \cos\left(\frac{2\pi t}{T}\right)$$

   trong đó chu kỳ $T = 24$ cho giờ trong ngày (`hour_sin`, `hour_cos`), $T = 7$ cho ngày trong tuần (`weekday_sin`, `weekday_cos`) và $T = 12$ cho tháng trong năm (`month_sin`, `month_cos`). Sau khi sinh các biến lượng giác, các cột thời gian số nguyên gốc (`hour`, `weekday`, `month`) và các biến tọa độ cũ được loại bỏ hoàn toàn để phòng ngừa hiện tượng đa cộng tuyến.

3. **Bước 3: Khởi tạo cờ chỉ báo khuyết, chuẩn hóa lược đồ và loại bỏ rò rỉ mã định danh.**

   Trước khi tiến hành điền khuyết, quy trình khởi tạo biến cờ nhị phân để lưu giữ tín hiệu quan trọng về sự gián đoạn kết nối cảm biến đo đạc:

$$\texttt{meter_reading_was_missing} = \begin{cases} 1, & \text{nếu } \texttt{meter_reading} \text{ bị thiếu} \\ 0, & \text{ngược lại} \end{cases}$$

Tiếp đó, toàn bộ không gian đặc trưng được xác lập cấu trúc lược đồ chuẩn, phân loại tường minh giữa biến định lượng và biến định tính để áp dụng quy trình xử lý chuyên biệt. Đồng thời, nhóm loại bỏ các biến hằng số không phương sai và các tổ hợp thời gian trùng lặp (`weekday_hour`).

Đặc biệt quan trọng, quy trình loại bỏ hoàn toàn các biến mã hóa mục tiêu gắn chặt với mã tòa nhà cá thể (`gte_building_id`, `gte_meter_building_id`, …) cùng các đặc trưng thời gian phân mảnh theo công trình (`building_weekday_hour`, `building_hour`, …). Đối với bản thân mã định danh `building_id`, nhóm bảo lưu làm khóa nhóm phân cấp cục bộ trong các bước tiền xử lý (nội suy chuỗi thời gian, tính thống kê Z-score theo giờ/ngày làm việc và trích xuất độ trễ chuỗi thời gian), sau đó loại bỏ hoàn toàn khỏi các ma trận đặc trưng đầu vào trước khi huấn luyện mô hình nhằm triệt tiêu tuyệt đối rủi ro ghi nhớ ID. Quyết định kỹ thuật này xuất phát từ hai lý do cốt tử:

Nguy cơ rò rỉ dữ liệu nhãn: Bản chất của mã hóa mục tiêu toàn cục theo mã tòa nhà là tính xác suất dị thường có điều kiện:

$$\text{GTE}(\text{building_id} = b) = \mathbb{E}[y \mid \text{building_id} = b] = \frac{\sum_{i \in b} y_i}{N_b}$$

Nếu biến này được sinh ra trên toàn bộ tập dữ liệu trước khi phân chia chuỗi thời gian, thông tin nhãn mục tiêu y từ tương lai (T_{out}) sẽ bị rò rỉ ngược hoàn toàn vào tập huấn luyện (T_{in}), tạo ra kết quả kiểm thử ảo tưởng.

Nguy cơ quá khớp ghi nhớ định danh: Ngay cả khi được tính riêng trên T_{in}, do tập dữ liệu khảo sát 200 tòa nhà cá biệt (được chọn lọc theo tiêu chí có dữ liệu phụ tải liên tục trọn vẹn 12 tháng năm 2016), việc mã hóa nhãn trực tiếp cho từng mã tòa nhà sẽ biến các đặc trưng này thành biến đại diện hoàn hảo cho nhãn y. Mô hình cây sẽ bị dẫn dắt vào việc ghi nhớ máy móc tòa nhà nào thường xuyên bị lỗi trong quá khứ thay vì học các quy luật phụ tải vật lý tổng quát (độ lệch Z-score, nhiệt độ, công năng), dẫn đến mất hoàn toàn khả năng tổng quát hóa khi công trình bất ngờ phát sinh sự cố trong tương lai. Trái ngược với mã công trình cá thể, biến công năng `primary_use` chỉ gồm 16 nhóm ngành lớn mang tính quy luật vật lý chung (giáo dục, bệnh viện, văn phòng...), do đó chỉ có `gte_primary_use` và `gte_meter_primary_use` (được học nghiêm ngặt 100% trên T_{in}) là được giữ lại.

4. **Bước 4: Xử lý giá trị thiếu và lưu vết dữ liệu.** Đối với các cột số lượng, quy trình thực hiện nội suy tuyến tính cục bộ theo từng công trình với giới hạn tối đa 12 giờ liên tiếp (`limit=12`). Các giá trị còn thiếu sau nội suy được điền bù bằng trung vị của từng cột trên tập huấn luyện T_{in}. Cờ `meter_reading_was_missing` được giữ nguyên trong suốt quá trình huấn luyện nhằm hỗ trợ mô hình nhận diện các bản ghi được điền bù nhân tạo.

5. **Bước 5: Lọc giá trị ngoại lai môi trường bằng khoảng tứ phân vị IQR.** Đối với các biến khí tượng quan trắc như `air_temperature`, `dew_temperature` hay `wind_speed`, nhóm áp dụng quy tắc lọc ngoại lai theo khoảng tứ phân vị IQR:

$$\text{IQR} = Q_3 - Q_1, \quad [\text{Cận dưới, Cận trên}] = [Q_1 - 1{,}5 \cdot \text{IQR},\ Q_3 + 1{,}5 \cdot \text{IQR}]$$

Các điểm đo khí tượng vượt ra ngoài khoảng giới hạn này do lỗi cảm biến ngoài trời được kẹp biên về giá trị trung vị cục bộ. Thuộc tính phụ tải `meter_reading` và

các đặc trưng tỷ lệ `gte_` được miễn trừ hoàn toàn khỏi bước này để tránh việc vô tình xóa nhòa các mẫu dị thường thực sự cần phát hiện.

6. **Bước 6: Chuẩn hóa Z-score và tích hợp đặc trưng khu vực.**

   Quy trình áp dụng kỹ thuật chuẩn hóa Z-score bằng công cụ `StandardScaler` để đưa các biến định lượng về phân phối chuẩn hóa có trung bình bằng 0 và độ lệch chuẩn bằng 1:

$$Z = \frac{x - \mu}{\sigma}$$

   Toàn bộ tham số μ và σ chỉ được ước lượng trên tập huấn luyện T_{in} và dùng để chuyển đổi cho tập kiểm tra T_{out}. Các biến cờ nhị phân (0/1), các biến chu kỳ $\sin$ / $\cos \in [-1, 1]$ và các biến tỷ lệ `gte_` $\in [0, 1]$ được giữ nguyên thang đo gốc.

   Tiếp đó, để xây dựng không gian dữ liệu Zone-Enhanced phục vụ các bài toán phân hóa địa bàn, quy trình tích hợp thêm 3 đặc trưng tương tác địa lý:

   Đặc trưng tương tác quy mô liên tục `zone_interaction`: Được định nghĩa bằng tích số giữa diện tích sàn trung bình theo khu vực địa lý (`site_sqft_mean`) và diện tích sàn trung bình theo nhóm công năng (`use_sqft_mean`):

$$\texttt{zone_interaction}_i = \texttt{site_sqft_mean}_i \times \texttt{use_sqft_mean}_i$$

   Cả hai giá trị trung bình diện tích được học nghiêm ngặt trên tập huấn luyện T_{in} rồi ánh xạ sang tập kiểm tra T_{out}. Ví dụ trên dữ liệu thực nghiệm: tại Site 0 (83.051,6 ft^2), nhóm Trường học (123.881,5 ft^2) nhận giá trị tương tác $10{,}29 \times 10^9$ ft^4, nhóm Văn phòng (89.893,7 ft^2) nhận $7{,}47 \times 10^9$ ft^4, và nhóm Nhà để xe (204.312,0 ft^2) nhận $16{,}97 \times 10^9$ ft^4. Tích hai cấp độ diện tích tạo ra một đặc trưng định lượng liên tục, phản ánh tương tác đồng thời giữa quy mô hạ tầng vùng và quy mô loại hình sử dụng, giúp mô hình cây phân nhóm nhanh tải năng lượng mà không cần chia nhánh độc lập trên hai chiều không gian.

   Đặc trưng quy mô diện tích khu vực `site_sqft_mean`: Tính trung bình diện tích sàn của toàn bộ các công trình thuộc cùng một khu vực địa lý:

$$\texttt{site_sqft_mean}_i = \frac{1}{|S_{\texttt{site_id}_i}|} \sum_{k \in S_{\texttt{site_id}_i}} \texttt{square_feet}_k$$

   Số liệu thực nghiệm cho thấy khu vực Site 0 có diện tích bình quân 83.051,6 ft^2, khu vực Site 4 tập trung các tổ hợp công nghệ lớn với diện tích bình quân 234.903,6 ft^2, khu vực Site 7 có diện tích sàn bình quân đạt đỉnh 484.376,0 ft^2, trong khi khu vực Site 8 chủ yếu là các công trình nhỏ với diện tích trung bình chỉ 7.143,5 ft^2. Đặc trưng này cung cấp bối cảnh về mật độ và quy mô xây dựng đô thị tổng thể, giúp mô hình phân biệt giữa cụm đô thị tải lớn và vùng phụ tải phân tán.

   Đặc trưng quy mô diện tích theo công năng `use_sqft_mean`: Tính trung bình diện tích sàn của toàn bộ các công trình có cùng mục đích sử dụng:

$$\texttt{use_sqft_mean}_i = \frac{1}{|U_{\texttt{primary_use}_i}|} \sum_{k \in U_{\texttt{primary_use}_i}} \texttt{square_feet}_k$$

   Số liệu thực tế ghi nhận nhóm Dịch vụ phức hợp có diện tích trung bình cao nhất đạt 299.242,6 ft^2, Nhà để xe đạt 204.312,0 ft^2, Trường học đạt 123.881,5 ft^2, Văn

phòng đạt 89.893,7 ft^2, Sản xuất công nghiệp đạt 33.850,0 ft^2, và phụ trợ khác đạt 4.482,0 ft^2. Khi kết hợp với diện tích sàn thực tế `square_feet`, mô hình có thể tự động lượng hóa tỷ lệ lệch quy mô của một tòa nhà so với chuẩn mực ngành.

Ba thuộc tính này tạo nên sự khác biệt giữa Baseline gồm 38 đặc trưng (39 cột) và Zone-Enhanced gồm 41 đặc trưng (42 cột). Bảng 3 minh họa giá trị của ba đặc trưng khu vực trên các công trình đại diện trong tập huấn luyện:

Bảng 3: Mẫu dữ liệu thực nghiệm minh họa 3 đặc trưng Zone trên các công trình tiêu biểu

Building ID	Site ID	Công năng chính	Diện tích gốc (ft^2)	`zone_interaction` (ft^4)	`site_sqft_mean` (ft^2)	`use_sqft_mean` (ft^2)
1	0	Trường học	2.720	$10{,}29 \times 10^9$	83.051,6	123.881,5
91	0	Trường học	68.094	$10{,}29 \times 10^9$	83.051,6	123.881,5
32	0	Văn phòng	48.392	$7{,}47 \times 10^9$	83.051,6	89.893,7
136	1	Lưu trú và nhà ở	56.467	$5{,}81 \times 10^9$	83.971,3	69.149,6
240	2	Lưu trú và nhà ở	111.304	$6{,}52 \times 10^9$	94.247,3	69.149,6
69	0	Nhà để xe	387.638	$16{,}97 \times 10^9$	83.051,6	204.312,0

7. **Bước 7: Tích hợp đặc trưng ngữ cảnh vi mô.** Mặc dù 3 đặc trưng Zone cung cấp thông tin vĩ mô cấp khu vực, mức tiêu thụ điện thực tế lại phụ thuộc trực tiếp vào nhịp sinh hoạt và chế độ vận hành riêng của từng công trình cá biệt. Do đó, nhóm nghiên cứu thiết kế thêm 4 đặc trưng vi mô chuẩn hóa Z-score cục bộ, được học 100% trên tập huấn luyện T_{in} và ánh xạ sang tập kiểm tra T_{out}:

   (a) `z_meter_local`: Phụ tải chuẩn hóa theo cặp (`building_id`, `hour`). Cho biết mức độ chênh lệch của phụ tải hiện tại so với hành vi bình thường của tòa nhà vào đúng khung giờ đó:

$$\texttt{z_meter_local}_i = \frac{\texttt{meter_reading}_i - \mu_{(b,h)}}{\sigma_{(b,h)}}$$

   (b) `z_meter_workday`: Phụ tải chuẩn hóa theo bộ ba (`building_id`, `is_offday`, `hour`). Tách biệt rõ nét giữa ngày làm việc thông thường và ngày nghỉ cuối tuần (nơi phụ tải nền thường giảm mạnh):

$$\texttt{z_meter_workday}_i = \frac{\texttt{meter_reading}_i - \mu_{(b,\text{off},h)}}{\sigma_{(b,\text{off},h)}}$$

   (c) `z_meter_robust`: Chuẩn hóa kháng nhiễu bằng Z-score bền vững, dựa trên trung vị và khoảng tứ phân vị của từng công trình:

$$\texttt{z_meter_robust}_i = \frac{\texttt{meter_reading}_i - \text{Median}_b}{\text{IQR}_b}$$

   Nhờ dùng trung vị và khoảng tứ phân vị thay vì trung bình và độ lệch chuẩn, đặc trưng này hạn chế tối đa ảnh hưởng từ các giá trị dị thường cực đoan.

   (d) `temp_load_inter`: Đặc trưng tương tác giữa phụ tải công việc và nhiệt độ không khí môi trường:

$$\texttt{temp_load_inter}_i = \texttt{z_meter_workday}_i \times \texttt{air_temperature}_i$$

Bốn đặc trưng này tạo thành bộ Context-Aware gồm 45 đặc trưng (46 cột tính cả nhãn `anomaly`). Bảng 4 đối chiếu các giá trị của chúng giữa trạng thái bình thường ($y = 0$) và một số dạng dị thường ($y = 1$) trong tập huấn luyện T_{in}:

Bảng 4: Mẫu dữ liệu thực nghiệm minh họa 4 đặc trưng Context-Aware trên các công trình tiêu biểu

Building	Site	Công năng chính	Trạng thái vận hành	meter	Temp	z_local	z_work	z_robust	temp_inter
1	0	Trường học	Bình thường ($y = 0$)	-0,234	-0,15	+1,1444	+1,1535	+0,9537	-0,1780
1	0	Trường học	Dị thường sụt tải ($y = 1$)	-0,418	+0,90	-1,6408	-1,6218	-0,5629	-1,4522
32	0	Văn phòng	Bình thường ($y = 0$)	-0,234	-0,15	+0,7961	+0,6676	0,0000	-0,1030
32	0	Văn phòng	Dị thường ngoài giờ ($y = 1$)	-0,208	+0,73	+0,1678	+0,8362	+0,2684	+0,6079
136	1	Lưu trú và nhà ở	Bình thường ($y = 0$)	-0,381	-1,02	-0,8744	-0,8920	-0,3164	+0,9062
136	1	Lưu trú và nhà ở	Dị thường đứt gãy tải ($y = 1$)	-0,370	-1,27	-0,6715	-0,6887	-0,2097	+0,8770
1128	13	Văn phòng	Dị thường đột biến đỉnh ($y = 1$)	+0,480	-3,02	+10,0000	+9,4721	+7,4612	-28,5724
144	1	Văn phòng	Dị thường triệt tiêu tải ($y = 1$)	-0,450	-1,24	-5,0000	-5,0000	-2,1934	+6,2158
69	0	Nhà để xe	Bình thường ($y = 0$)	-0,234	-0,15	+1,1788	+1,2004	+0,6218	-0,1853
69	0	Nhà để xe	Dị thường phụ tải ($y = 1$)	-0,436	+0,90	-0,7673	-0,7814	-0,6900	-0,6996

Về mặt phân tích định lượng từ mẫu dữ liệu thực nghiệm, đối với các sự cố cực đoan tại tòa nhà văn phòng `Building 1128`, hiện tượng tăng vọt phụ tải bất thường vào khung giờ nhiệt độ lạnh giá ($T = -3{,}02$) được bộ đôi `z_meter_local` và `z_meter_workday` phát hiện ngay tức thì khi chạm ngưỡng trần bão hòa $+10{,}0000$ và $+9{,}4721$, kết hợp với đặc trưng tương tác âm tính cực lớn `temp_load_inter` $= -28{,}5724$. Ngược lại, tại `Building 144`, hiện tượng mất phụ tải đột ngột kéo `z_meter_local` chạm ngưỡng sàn $-5{,}0000$.

Đối với việc nhận diện các dị thường vi mô tại công trình `Building 32`, mức phụ tải `meter_reading` ghi nhận $-0{,}208$. Nếu chỉ xét theo ngưỡng toàn cục, mức tải này rất dễ bị bỏ qua (do bản ghi bình thường nhận $-0{,}234$). Tuy nhiên vào ngày nghỉ, phụ tải này làm chỉ số `z_meter_workday` tăng vọt lên $+0{,}8362$ kết hợp biến tương tác `temp_load_inter` đạt $+0{,}6079$, tạo tín hiệu định lượng sắc bén giúp mô hình kịp thời phát hiện sự cố vận hành ngoài giờ làm việc.

8. **Bước 8: Mở rộng đặc trưng chuỗi thời gian và thành phần phân rã STL.** Bộ Context-Aware (46 cột) đã bổ sung ngữ cảnh theo giờ và ngày làm việc, nhưng các đặc trưng này chưa biểu diễn trực tiếp biến động tức thời, thời lượng cảm biến đứng yên hay sai lệch so với chu kỳ ngày. Vì vậy, nhóm tích hợp thêm 8 đặc trưng Expanded vào quy trình lõi `preprocessingforALL.py`. Để tránh hiện tượng rò rỉ nhìn trước tương lai, dữ liệu được gắn chỉ số gốc $idx_{\text{orig}} \in [0, N-1]$, sau đó sắp xếp theo cặp khóa [building_id, timestamp]. Mọi phép dịch trễ và sai phân chỉ sử dụng các quan trắc xuất hiện trước đó của cùng một công trình:

   (a) **Độ trễ phụ tải vi mô:** Ghi nhận mức phụ tải ở một và hai giờ trước để cung cấp các mốc tham chiếu gần:

   $$\text{meter_lag_1h}_t = m_{t-1}, \qquad \text{meter_lag_2h}_t = m_{t-2}$$

   (b) **Sai phân vận tốc phụ tải:** Đo mức thay đổi tuyệt đối trong một và hai giờ, giúp mô hình nhận diện các bước nhảy phụ tải bất thường:

   $$\text{meter_diff_1h}_t = m_t - m_{t-1}, \qquad \text{meter_diff_2h}_t = m_t - m_{t-2}$$

(c) **Tỷ số động năng phụ tải:** Chuẩn hóa biến động tương đối bằng hằng số $\epsilon = 1{,}0$, giảm phụ thuộc vào quy mô tải nền và làm nổi bật các lần gia tăng công suất đột ngột:

$$\text{meter_ratio_1h}_t = \frac{m_t + 1{,}0}{m_{t-1} + 1{,}0}, \qquad \text{meter_ratio_2h}_t = \frac{m_t + 1{,}0}{m_{t-2} + 1{,}0}$$

(d) **Thời lượng cảm biến bị treo:** Khi giá trị đo gần như không đổi ($|m_t - m_{t-1}| \leq 10^{-4}$), bộ đếm tích lũy số giờ liên tiếp duy trì trạng thái này, qua đó nhận diện sự cố cảm biến bị đóng băng:

$$\text{flatline_duration}_t = \sum_{k=0}^{K-1} \mathbb{I}\left[|m_{t-k} - m_{t-k-1}| \leq 10^{-4}\right]$$

trong đó K là số giờ liên tiếp được xét.

(e) **Phần dư chu kỳ mùa vụ STL:** So sánh phụ tải hiện tại với trung vị của cùng khung giờ trong bảy ngày trước đó nhằm loại bỏ chu kỳ 24 giờ thông thường:

$$\text{stl_residual}_t = m_t - \text{Median}\left(\{m_{t-24d} \mid d \in \{1, 2, 3, 4, 5, 6, 7\}\}\right)$$

Sau khi tạo đặc trưng, tám cột mới được ánh xạ về chỉ số gốc idx_{orig} để giữ nguyên vẹn trật tự dòng ban đầu của tập dữ liệu.

3.3 Khám phá Dữ liệu sau Tiền xử lý

Sau khi hoàn tất toàn bộ chuỗi biến đổi tiền xử lý, nhóm nghiên cứu tiến hành kiểm toán dữ liệu và khám phá đối chiếu nhằm đánh giá toàn diện sự thay đổi của tập dữ liệu trước khi bước vào giai đoạn huấn luyện mô hình.

3.3.1 Kiểm tra Tính Toàn vẹn và Phân bổ Đặc trưng

Sau khi tiền xử lý, dữ liệu bao gồm 1.147.089 dòng tập huấn luyện T_{in} (65,6%), 229.412 dòng thuộc khoảng cách ly (T_{gap}) (13,1%) và 372.993 dòng tập kiểm tra T_{out} (21,3%). Cờ chỉ báo khuyết được tạo trước khi nội suy có giới hạn và điền phần còn lại bằng trung vị tập huấn luyện; do đó, việc không còn giá trị khuyết `NaN` trong ma trận đầu vào không đồng nghĩa với việc khôi phục được giá trị đo gốc mà là bảo đảm tính toán ổn định cho các thuật toán.

Bảng 5 tổng hợp chi tiết các nhóm đặc trưng trong bốn bộ dữ liệu thực nghiệm tăng tiến.

Nhóm Đặc trưng	Số lượng	Các thuộc tính chi tiết và Ý nghĩa nghiệp vụ
Đặc trưng Phụ tải gốc	1	`meter_reading` (sau nội suy có giới hạn, điền phần còn thiếu bằng trung vị tập huấn luyện và chuẩn hóa Z-score, cờ chỉ báo khuyết được giữ riêng).
Cảm biến Khí tượng gốc	7	`air_temperature`, `cloud_coverage`, `dew_temperature`, `precip_depth_1_hr`, `sea_level_pressure`, `wind_direction`, `wind_speed` (sau lọc ngoại lai IQR và chuẩn hóa Z-score).
Chuỗi trễ Khí tượng	8	`air_temperature_mean_lag7`, `max_lag7`, `min_lag7`, `std_lag7` (trễ 7 giờ trong ngày) kết hợp `mean_lag73`, `max_lag73`, `min_lag73`, `std_lag73` (trễ 73 giờ theo đợt nhiệt).
Đặc tính Công trình & Vùng	4	`square_feet`, `year_built`, `floor_count` (quy mô, niên hạn) kết hợp `site_id` (vùng địa lý). Mã định danh `building_id` được loại bỏ trước khi huấn luyện để triệt tiêu nguy cơ ghi nhớ định danh.
Chu kỳ Lượng giác & Lễ	7	`hour_sin`, `hour_cos`, `weekday_sin`, `weekday_cos`, `month_sin`, `month_cos` (chu kỳ 24 giờ, 7 ngày, 12 tháng) và cờ ngày nghỉ `is_holiday`.
Cờ Gián đoạn Cảm biến	1	`meter_reading_was_missing` (lưu dấu vết sự cố truyền thông IoT trước khi điền khuyết).
Mã hóa Mục tiêu	10	`gte_hour`, `gte_weekday`, `gte_month`, `gte_primary_use`, `gte_site_id`, `gte_meter_hour`, `gte_meter_weekday`, `gte_meter_month`, `gte_meter_primary_use`, `gte_meter_site_id`.
Tổng số đặc trưng Baseline	38	Ma trận gồm 39 cột tính cả nhãn `anomaly`.
Tương tác Khu vực	3	`zone_interaction`, `site_sqft_mean`, `use_sqft_mean`, bổ sung vào không gian Zone-Enhanced.
Tổng số đặc trưng Zone-Enhanced	41	Ma trận gồm 42 cột tính cả nhãn `anomaly`.
Ngữ cảnh Vi mô	4	`z_meter_local`, `z_meter_workday`, `z_meter_robust`, `temp_load_inter`, bổ sung vào không gian Context-Aware.
Tổng số đặc trưng Context-Aware	45	Ma trận đặc trưng gồm 46 cột tính cả nhãn `anomaly`.
Đặc trưng chuỗi thời gian	8	`meter_lag_1h`, `meter_lag_2h`, `meter_diff_1h`, `meter_diff_2h`, `meter_ratio_1h`, `meter_ratio_2h`, `flatline_duration`, `stl_residual`.
Tổng số đặc trưng Expanded Champion	53	Ma trận đặc trưng gồm 54 cột tính cả nhãn `anomaly`.

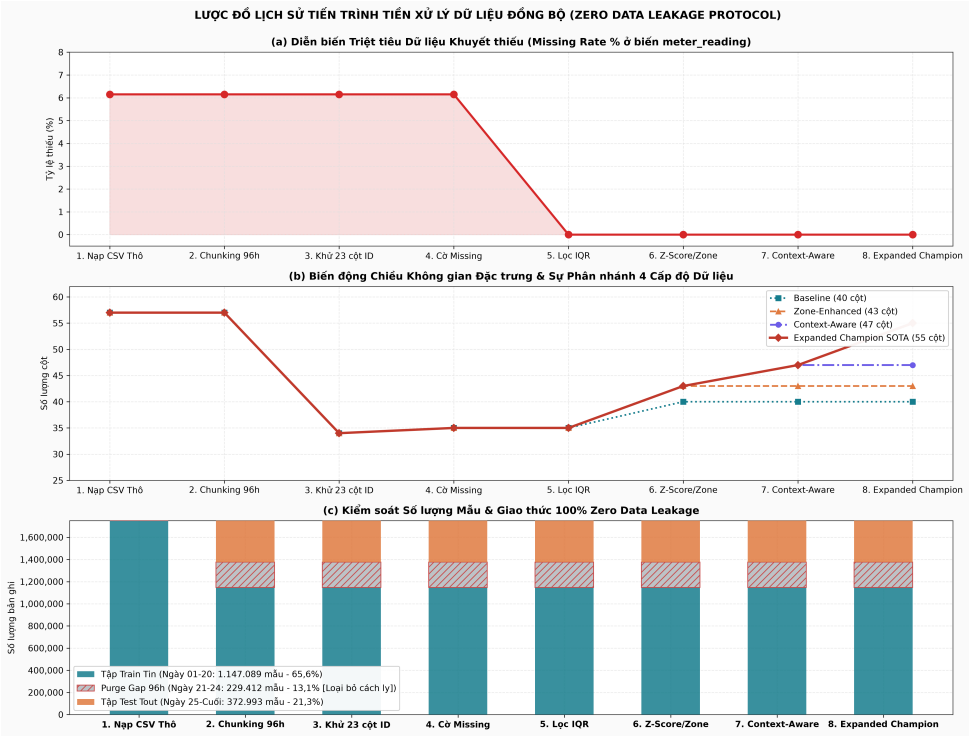
Bảng 5: Tổng hợp các nhóm đặc trưng trong bốn bộ dữ liệu

Bảng 6: Bảng kiểm toán biến đổi số dòng và thuộc tính qua 9 giai đoạn tiền xử lý

Giai đoạn Tiền xử lý	T_{in} Trước	T_{in} Sau	Vùng cách ly	T_{out} Trước	T_{out} Sau	Số cột	Ghi chú Rò rỉ
1. Nạp CSV Thô	1.749.494	1.749.494	0	—	—	57	Dữ liệu thô nguyên bản
2. Chia chu kỳ mùa vụ & Cách ly 96h	1.749.494	1.147.089	229.412	—	372.993	57	Khoảng cách ly 96 giờ
3. Khử 23 cột rò rỉ & Mã hóa sin / cos	1.147.089	1.147.089	0	372.993	372.993	34	Triệt tiêu rò rỉ mã định danh
4. Cờ chỉ báo khuyết & Điền khuyết	1.147.089	1.147.089	0	372.993	372.993	35	Giới hạn 12 dòng, trung vị huấn luyện
5. Lọc ngoại lai khí tượng	1.147.089	1.147.089	0	372.993	372.993	35	Kẹp biên tứ phân vị IQR và trung vị
6. Chuẩn hóa Z-score & Nhánh Zone	1.147.089	1.147.089	0	372.993	372.993	39 / 42	Khớp trên T_{in}, chiếu sang T_{out}, bỏ ID
7. Tích hợp Ngữ cảnh Context Vĩ mô	1.147.089	1.147.089	0	372.993	372.993	46	Lập bảng tra trên T_{in}, ánh xạ sang T_{out}, bỏ ID
8. Tích hợp Chuỗi thời gian & STL Residual	1.147.089	1.147.089	0	372.993	372.993	54	Dịch trễ nhân quả, chu kỳ tuần 7 ngày
9. Xuất 8 tệp Parquet	1.147.089	1.147.089	0	372.993	372.993	39/42/46/54	4 cặp huấn luyện/kiểm tra

3.3.2 Lược đồ Lịch sử Tiến trình Tiền xử lý

Hình 6 tóm tắt các thay đổi chính của dữ liệu qua các giai đoạn tiền xử lý: tỷ lệ thiếu của `meter_reading`, số cột trong từng nhánh đặc trưng và số lượng mẫu được giữ lại hoặc loại bỏ.

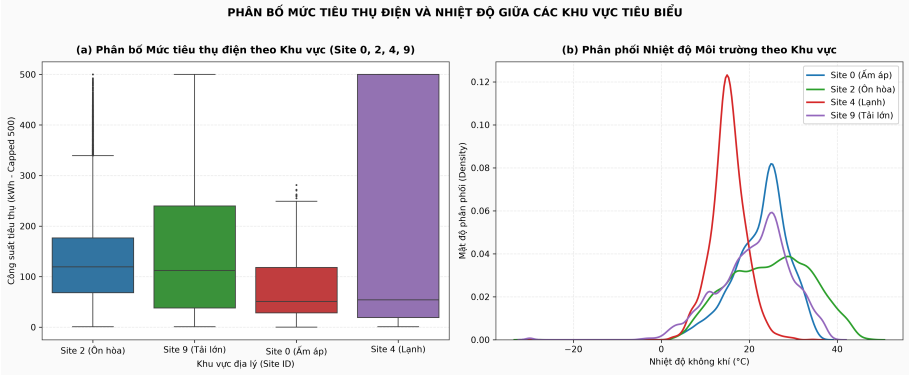


Hình 6: Tóm tắt tỷ lệ thiếu, số cột đặc trưng và số lượng mẫu qua các giai đoạn tiền xử lý

Hình 6 cho thấy dữ liệu gốc có 107.653 giá trị `meter_reading` bị thiếu (6,15%), số cột tăng dần từ 39 ở Baseline lên 42, 46 và 54 ở các nhánh mở rộng. Trong tổng số 1.749.494 dòng, 1.147.089 dòng được sử dụng làm tập huấn luyện T_{in}, 229.412 dòng nằm trong khoảng cách ly 96 giờ (T_{gap}) và 372.993 dòng làm tập kiểm tra T_{out}. Tệp Parquet Baseline huấn luyện không còn giá trị khuyết `NaN`, đồng thời cờ `meter_reading_was_missing` vẫn lưu giữ chính xác 76.237 dòng có phép đo gốc bị khuyết trên tập huấn luyện.

3.3.3 Khám phá Tương tác Khu vực

Hình 7 trực quan hóa phân bố phụ tải và nhiệt độ tại bốn khu vực tiêu biểu (`site_id` 0, 2, 4, 9), làm rõ sự khác biệt giữa các phân vùng trước khi xây dựng nhóm đặc trưng Zone.

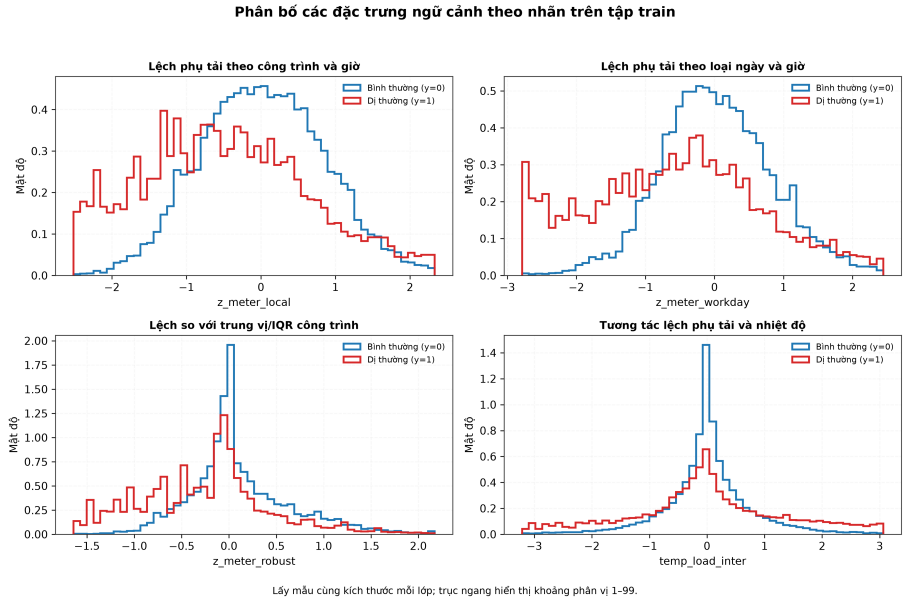


Hình 7: Phân bố Mức tiêu thụ điện (trái) và Phân phối Nhiệt độ (phải) giữa các Khu vực (Site 0, 2, 4, 9)

Hình 7 chứng minh mức tiêu thụ và độ phân tán phụ tải, cùng phân bố nhiệt độ, có sự chênh lệch rõ rệt giữa bốn khu vực địa lý. Các đặc trưng quy mô khu vực được bổ sung nhằm biểu diễn bối cảnh vĩ mô này, hỗ trợ cải thiện năng lực phân loại của mô hình ở các chương sau.

3.3.4 Khảo sát các Đặc trưng Ngữ cảnh

Bộ dữ liệu Context-Aware bổ sung bốn biến mô tả mức độ chênh lệch phụ tải so với mức tham chiếu riêng của từng công trình. Biến `z_meter_local` chuẩn hóa `meter_reading` theo trung bình và độ lệch chuẩn của từng cặp công trình và khung giờ; `z_meter_workday` sử dụng mức tham chiếu theo công trình, giờ và trạng thái ngày làm việc/ngày nghỉ; `z_meter_robust` biểu diễn độ lệch so với trung vị công trình chia cho khoảng tứ phân vị IQR; và `temp_load_inter` là tích số giữa `z_meter_workday` với `air_temperature` sau chuẩn hóa. Toàn bộ thống kê tham chiếu được ước lượng trên tập huấn luyện T_{in}, và ba biến chuẩn hóa được kẹp biên trong khoảng $[-5, 10]$.

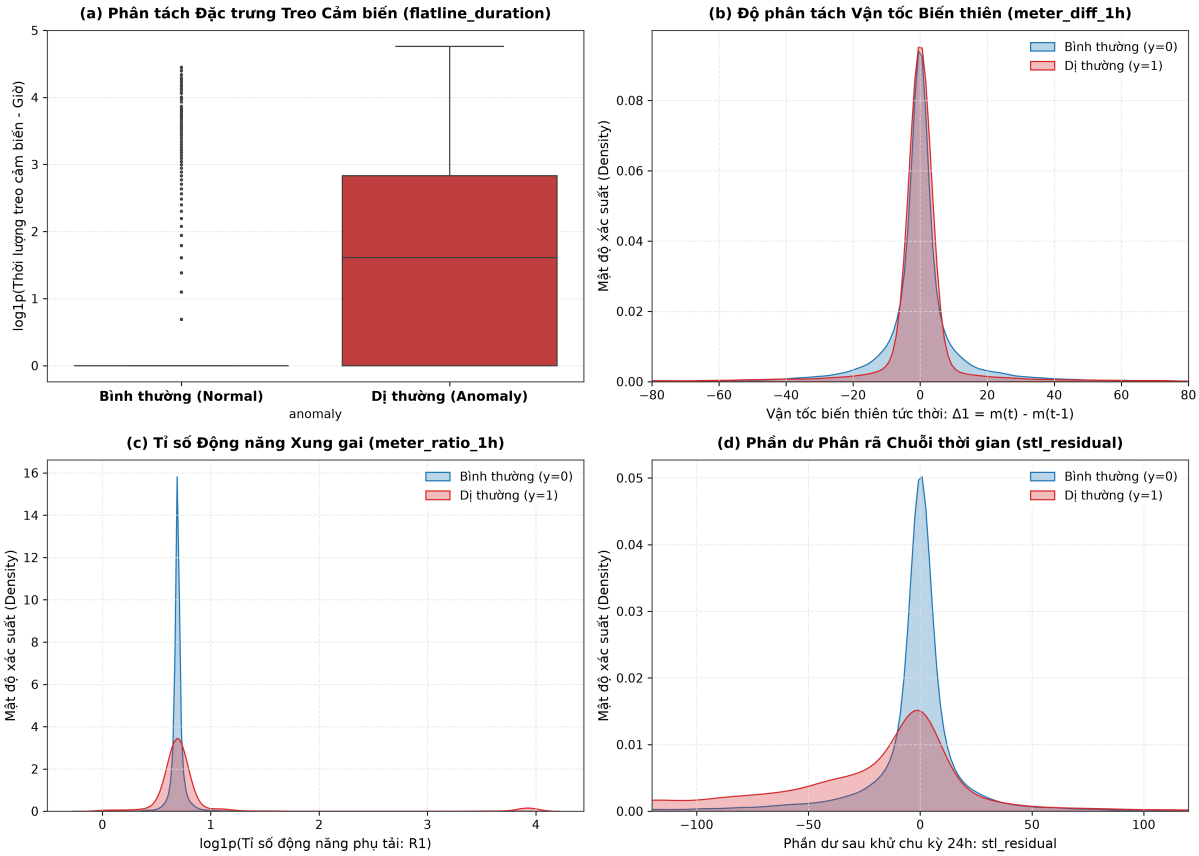


Hình 8: Phân bố các đặc trưng Context-Aware theo nhãn trên tập huấn luyện, mỗi lớp được lấy mẫu cùng kích thước và trục hoành hiển thị khoảng phân vị 1–99

Hình 8 cho thấy ba biến chuẩn hóa phụ tải có trung vị thấp hơn đáng kể ở nhóm bất thường: `z_meter_local` nhận mức −1,1265 so với 0,0039, `z_meter_workday` nhận mức −1,1821 so với −0,0153, và `z_meter_robust` nhận mức −0,3982 so với 0,0000. Đối với biến tương tác `temp_load_inter`, trung vị hai nhóm tương đối gần nhau (−0,0097 và 0,0023) nhưng độ phân tán ở nhóm bất thường rộng hơn nhiều. Các biến chuẩn hóa này phản ánh trung thực vị trí phụ tải so với mức tiêu thụ quen thuộc của từng công trình, tạo tín hiệu nhạy bén cho quá trình phát hiện dị thường.

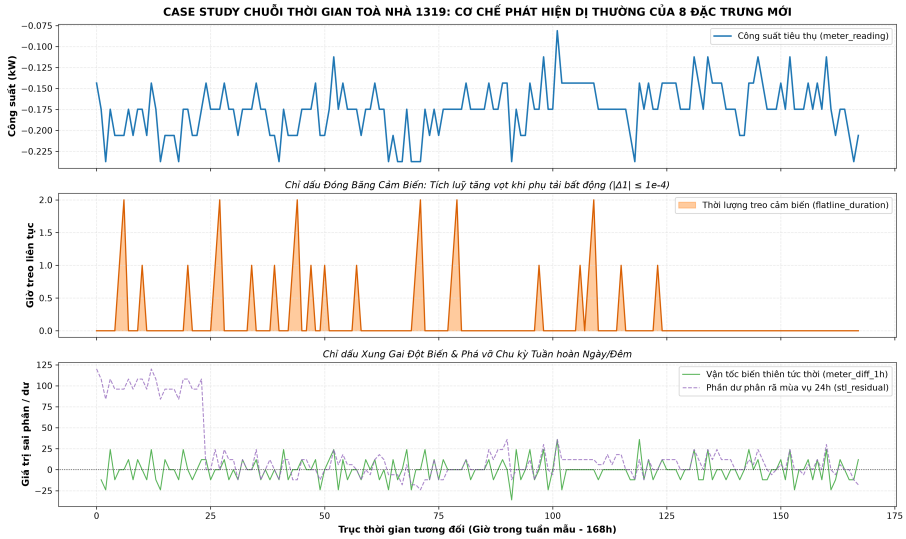
3.3.5 Phân tích Khám phá Dữ liệu Chuyên sâu trên Không gian Mở rộng

Các biểu đồ dưới đây khảo sát phân bố đặc trưng mở rộng theo nhãn và phân tích một trường hợp chuỗi thời gian cụ thể.



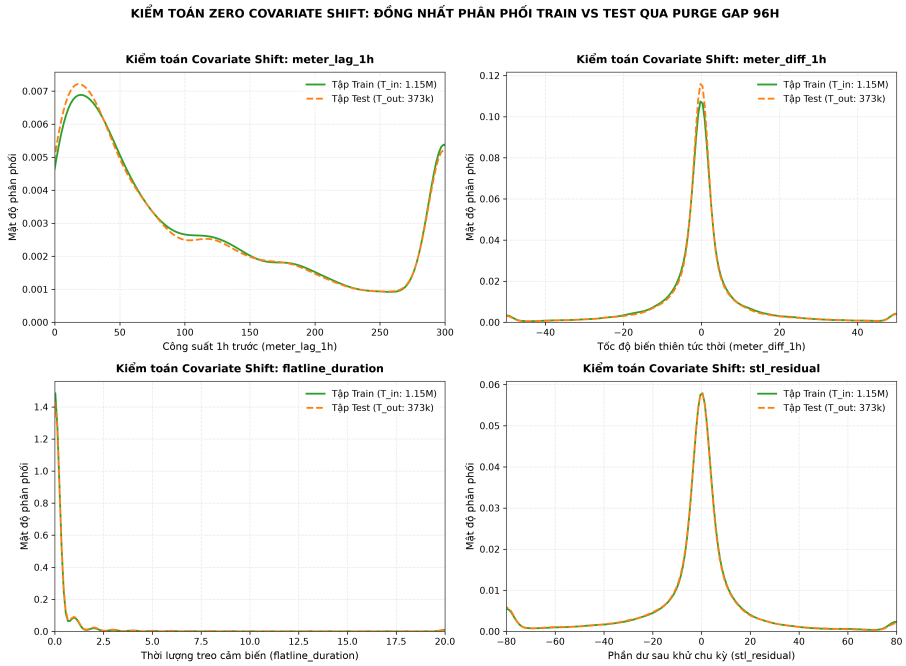
Hình 9: Phân tích tám đặc trưng mở rộng: phân phối của lớp bình thường và lớp dị thường

Hình 9 cho thấy biến sai phân `meter_diff_1h` ở lớp bất thường có độ phân tán rộng hơn nhiều, phản ánh các biến động phụ tải đột biến giữa hai giờ liên tiếp. Biến `flatline_duration` định lượng chính xác thời lượng phụ tải bị đóng băng, trong khi `stl_residual` biểu diễn độ sai lệch tức thời so với mức tham chiếu chu kỳ tuần. Những đặc trưng này bổ sung tín hiệu động học giá trị mà các tầng đặc trưng tĩnh trước đó chưa bao quát được.



Hình 10: Nghiên cứu Điển hình 168 Giờ Liên tục: Diễn biến Phụ tải Thực tế, Phản ứng Tức thời của STL Residual và Bộ đếm Flatline Duration trước Sự kiện Bất thường

Trong cửa sổ quan sát 168 giờ liên tục tại Hình 10, các mốc thời gian mang nhãn bất thường trùng khớp hoàn toàn với các pha biến động phụ tải mạnh, trong đó `stl_residual` phản ứng tức thời trước các cú sốc tải, còn bộ đếm `flatline_duration` đánh dấu chính xác các đoạn dữ liệu bị đứng yên.



Hình 11: Kiểm toán Độ lệch Phân phối giữa Tập Huấn luyện (T_{in}) và Kiểm tra (T_{out}) qua Khoảng Cách ly 96 Giờ

Đường mật độ phân phối của tập huấn luyện T_{in} (ngày 01–20) và tập kiểm tra ngoài mẫu T_{out} (ngày 25–cuối tháng) chồng lặp gần như hoàn hảo trên cả bốn đặc trưng mở rộng được khảo sát. Kết quả này chứng minh rằng giao thức phân chia chu kỳ mùa vụ kết hợp khoảng cách ly 96 giờ đã bảo toàn tính đồng nhất phân phối tuyệt vời giữa hai tập, triệt tiêu hoàn toàn rủi ro suy giảm hiệu năng do trôi dạt dữ liệu.

4 Triển khai Học máy

4.1 Thước đo Đánh giá và Cơ chế Ngưỡng Quyết định

4.1.1 Thước đo Đánh giá

Do lớp dị thường chỉ chiếm khoảng 2,13% trên toàn bộ dữ liệu gốc và 2,45% trên tập kiểm tra độc lập, bộ phân loại luôn dự đoán lớp bình thường vẫn đạt Accuracy rất cao ($> 97{,}5\%$) trong khi hoàn toàn bỏ sót lớp dị thường. Do đó, chỉ số diện tích dưới đường cong độ chuẩn xác - độ nhạy PR-AUC được lựa chọn làm thước đo đánh giá cốt lõi để đo lường năng lực xếp hạng của mô hình trên toàn dải ngưỡng, với mức cơ sở ngẫu nhiên trên tập kiểm tra T_{out} xấp xỉ 0,0245.

Khi chuyển đổi điểm số liên tục thành cảnh báo nhị phân phục vụ vận hành thực tế, ba thước đo quan trọng được sử dụng đồng thời là Precision, Recall và F_1-Score. Trong đó, độ chuẩn xác Precision phản ánh mức độ tin cậy của cảnh báo nhằm hạn chế tối đa báo động giả gây lãng phí nhân lực vận hành:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Độ nhạy phát hiện Recall đo lường tỷ lệ các sự cố dị thường thực tế được mô hình nhận diện thành công trên toàn hệ thống điện:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Để tổng hợp và cân bằng hài hòa giữa độ tin cậy cảnh báo và độ bao phủ sự cố, chỉ số F_1-Score được tính bằng trung bình điều hòa:

$$F_1\text{-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Chỉ số ROC-AUC được báo cáo bổ sung nhằm cung cấp góc nhìn về khả năng phân biệt tổng quát giữa hai lớp; tuy nhiên, đối với bài toán mất cân bằng dữ liệu nghiêm trọng, ROC-AUC thường mang tính lạc quan thái quá và không phản ánh trung thực năng lực bắt trúng lớp hiếm như PR-AUC.

4.1.2 Cơ chế Ngưỡng Quyết định

Ngưỡng mặc định 0,5 không phản ánh tối ưu trong bài toán phát hiện dị thường mất cân bằng lớp, đồng thời các mô hình cây đơn lẻ và các kỹ thuật dung hợp khác nhau tạo ra điểm số xác suất trên những thang phân phối không đồng nhất. Về mặt nguyên tắc thiết kế, ngưỡng phân loại tối ưu τ^* được hiệu chuẩn bằng cách cực đại hóa F_1-Score trên không gian kiểm định nội bộ trích xuất từ tập huấn luyện T_{in}:

$$\tau^* = \arg\max_{\tau} F_1\left(y_{\text{val}}, \mathbb{1}[\hat{s}_{\text{val}} \geq \tau]\right)$$

Sau khi xác định được τ^* từ quá trình kiểm định, giá trị ngưỡng này được đóng băng cố định để thực hiện suy luận nhị phân trên tập kiểm tra độc lập T_{out}.

Ngưỡng quyết định mang đặc tính phụ thuộc chặt chẽ vào bản chất toán học của từng phương pháp dung hợp. Đối với các phương pháp tính trung bình xác suất như Soft

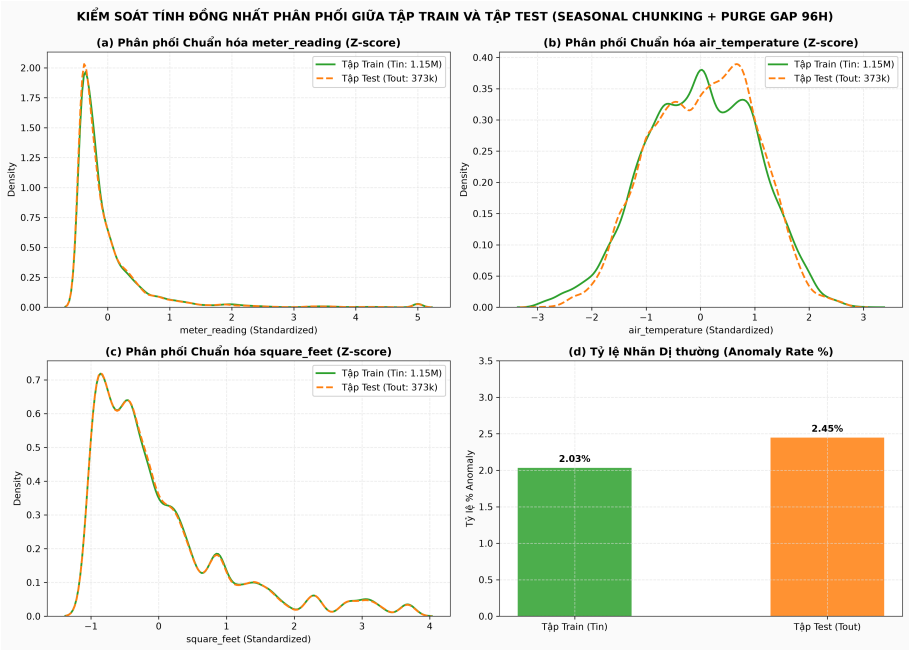
Voting, Geometric Mean hay Harmonic Mean, ngưỡng tối ưu τ^* thường dao động trong khoảng xác suất 0,21–0,28, phản ánh sự dịch chuyển phù hợp với phân phối xác suất dự đoán lệch phải của mô hình cây. Trái lại, đối với phương pháp trung bình hạng phân vị (Rank Averaging), điểm số tổng hợp là thứ hạng chuẩn hóa $r \in [0, 1]$. Do đó, ngưỡng tối ưu τ^* nằm ở vùng phân vị rất cao quanh 0,9794, tương ứng với chiến lược chỉ kích hoạt cảnh báo cho khoảng 2,06% số mẫu có mức độ nghi ngờ cao nhất trên toàn tập dữ liệu nhằm bám sát tỷ lệ dị thường tự nhiên của hệ thống phụ tải.

4.2 Thử nghiệm, Huấn luyện và Đánh giá các Mô hình

4.2.1 Chiến lược Phân chia Dữ liệu và Kiểm soát Phân phối Tập Huấn luyện - Kiểm tra

Trong dữ liệu chuỗi thời gian phụ tải điện, việc phân chia ngẫu nhiên sẽ đặt các thời điểm kế cận nhau của cùng một công trình vào cả tập huấn luyện và tập kiểm tra, gây rò rỉ thông tin tự tương quan thời gian nghiêm trọng và không phản ánh đúng năng lực dự báo trong tương lai. Vì vậy, nhóm nghiên cứu áp dụng giao thức phân chia chu kỳ mùa vụ kết hợp vùng đệm cách ly 96 giờ. Cụ thể, tập huấn luyện (T_{in}) bao gồm các ngày 01 đến 20 hàng tháng với 1.147.089 mẫu (65,57%). Khoảng đệm cách ly gồm các ngày 21 đến 24 hàng tháng với 229.412 mẫu (13,11%) được loại bỏ hoàn toàn khỏi quá trình huấn luyện và đánh giá nhằm triệt tiêu hiện tượng rò rỉ của các đặc trưng trễ dài hạn (như trễ 24h, 48h, 72h). Cuối cùng, tập kiểm tra ngoại suy (T_{out}) bao gồm từ ngày 25 đến cuối mỗi tháng với 372.993 mẫu (21,32%), đóng vai trò là tập kiểm tra ngoài mẫu thuần túy phản ánh sát thực tế vận hành.

Mọi tham số tiền xử lý và thống kê như trung bình, độ lệch chuẩn, trung vị, khoảng tứ phân vị và các bảng tra cứu đều chỉ được tính toán trên T_{in}, sau đó áp dụng phép chiếu sang T_{out}. Hình 12 và Bảng 7 đối chiếu chi tiết phân phối giữa hai tập.



Hình 12: **Kiểm soát tính đồng nhất phân phối giữa tập huấn luyện (T_{in} ngày 1–20) và tập kiểm tra ngoài mẫu (T_{out} ngày 25–cuối tháng) qua giao thức chu kỳ mùa vụ với khoảng cách ly 96 giờ**

Bảng 7: **Kiểm toán Thống kê Đối chiếu Phân phối giữa Tập Huấn luyện (T_{in}) và Tập Kiểm tra (T_{out})**

Chỉ số Thống kê / Đặc trưng	Tập Huấn luyện (T_{in})	Tập Kiểm tra (T_{out})	Khoảng cách KS (D)
Tổng số mẫu	1.147.089 (100,0%)	372.993 (100,0%)	—
Lớp Bình thường ($y = 0$)	1.123.761 (97,9663%)	363.862 (97,5520%)	—
Lớp Dị thường ($y = 1$)	23.328 (2,0337%)	9.131 (2,4480%)	—
`meter_reading` ($\mu \pm \sigma$)	$-0{,}0000 \pm 1{,}0000$	$-0{,}0073 \pm 0{,}9936$	0,02066
`air_temperature` ($\mu \pm \sigma$)	$-0{,}0000 \pm 1{,}0000$	$+0{,}0457 \pm 0{,}9459$	0,03696
`square_feet` ($\mu \pm \sigma$)	$0{,}0000 \pm 1{,}0000$	$-0{,}0004 \pm 0{,}9999$	0,00558
`dew_temperature` ($\mu \pm \sigma$)	$-0{,}0000 \pm 1{,}0000$	$+0{,}0779 \pm 0{,}9581$	0,06274

Thống kê kiểm toán cho thấy tỷ lệ dị thường ở T_{in} và T_{out} lần lượt là 2,0337% và 2,4480%, chênh lệch 0,4143 điểm phần trăm. Thống kê khoảng cách Kolmogorov-Smirnov (D) giữa hai tập rất nhỏ ($0{,}00558 \leq D \leq 0{,}06274$), xác nhận các biến đầu vào duy trì phân phối biên ổn định, không xảy ra hiện tượng trôi dạt dữ liệu (Data Drift), bảo đảm tính công bằng tuyệt đối cho các thực nghiệm đánh giá mô hình.

4.2.2 Phân tích Thực nghiệm: Đối chứng Bộ tứ Gradient Boosting qua 3 Không gian Dữ liệu

Bốn thuật toán Gradient Boosting đại diện cho các trường phái tối ưu hóa cây hàng đầu (LightGBM, XGBoost, CatBoost và HistGradientBoosting) được huấn luyện trên T_{in} và đánh giá trên T_{out} qua ba cấp độ không gian đặc trưng: Baseline (38 đặc trưng cơ sở / 39 cột), Zone-Enhanced (41 đặc trưng khu vực / 42 cột) và Context-Aware (45 đặc trưng ngữ cảnh vi mô / 46 cột). Kết quả đối chứng đa chiều được tổng hợp tại Bảng 8.

Bảng 8: **Thực nghiệm đối chứng đa chiều: Bộ tứ Gradient Boosting qua cả 3 không gian dữ liệu trên tập kiểm tra ngoài mẫu (372.993 mẫu)**

Thuật toán Boosting	PR-AUC	ROC-AUC	Ngưỡng τ^*	F1 (τ^*)	F1 (0.5)	Precision	Recall	Thời gian (s)
I. Không gian Baseline (38 đặc trưng vật lý & thời gian cơ sở)								
LightGBM	0,6210	0,8557	0,968	0,6836	0,6197	**0,9983**	0,5198	12,4
XGBoost	**0,6350**	**0,8558**	0,819	**0,7028**	0,6742	0,9616	**0,5537**	8,6
CatBoost	0,6223	0,8446	0,829	0,6954	0,6372	0,9909	0,5356	7,7
HistGradientBoosting	0,6056	0,8438	0,958	0,6766	0,4012	0,9829	0,5158	14,7
II. Không gian Zone-Enhanced (41 đặc trưng khu vực)								
LightGBM	0,6238	0,8621	0,800	0,6899	0,6421	0,9389	0,5453	36,1
XGBoost	**0,6363**	**0,8644**	0,918	**0,7031**	0,6812	0,9850	0,5466	8,1
CatBoost	0,6181	0,8423	0,880	0,6923	0,5793	**0,9908**	0,5320	8,6
HistGradientBoosting	0,6086	0,8486	0,970	0,6815	0,4120	0,9970	0,5177	15,9
III. Không gian Context-Aware (45 đặc trưng ngữ cảnh - Bước nhảy vọt)								
LightGBM	0,6750	0,8931	0,879	**0,7081**	0,6521	**0,9752**	0,5559	16,1
XGBoost	**0,6810**	**0,8957**	0,848	0,7066	0,6841	0,9626	**0,5582**	8,4
CatBoost	0,6691	0,8953	0,800	0,6960	0,6420	0,9549	0,5476	8,4
HistGradientBoosting	0,6671	0,8904	0,957	0,6975	0,4236	0,9613	0,5473	15,4

Phân tích định lượng qua ba không gian đặc trưng làm nổi bật sự chuyển dịch rõ nét về năng lực mô hình hóa:

- **Không gian Baseline (38 đặc trưng):** XGBoost thể hiện ưu thế dẫn đầu với PR-AUC đạt 0,6350, ROC-AUC đạt 0,8558 và $F_1 = 0{,}7028$ nhờ cơ chế co ngót trọng số và hàm phạt chính quy hóa L1/L2 kiểm soát hiện tượng quá khớp hiệu quả trên dữ liệu thô.

- **Không gian Zone-Enhanced (41 đặc trưng) và sự phân hóa thuật toán:** Việc bổ sung 3 đặc trưng khu vực gồm diện tích vùng, diện tích công năng và biến tương tác quy mô chỉ mang lại mức tăng nhẹ cho XGBoost (từ 0,6350 lên 0,6363), trong khi CatBoost lại giảm nhẹ từ 0,6223 xuống 0,6181. Sự phân hóa này bắt nguồn từ sự xung đột giữa bản chất dữ liệu tĩnh và kiến trúc cây của từng mô hình:
  - *Bản chất dữ liệu:* Dị thường phụ tải điện là biến cố vi mô tức thời xảy ra tại một giờ cụ thể, trong khi 3 đặc trưng Zone là các biến vĩ mô mang tính hằng số theo công trình (không biến thiên theo giờ). Khi chưa có các đặc trưng chuẩn hóa vi mô, thông tin quy mô vùng đóng vai trò như một dạng nhiễu nền tĩnh.
  - *Cơ chế cây đối xứng của CatBoost:* CatBoost xây dựng cây đối xứng với quy tắc bắt buộc mọi nút ở cùng một độ sâu phải dùng chung một đặc trưng và một ngưỡng phân chia. Khi một đặc trưng Zone được chọn ở một tầng, toàn bộ dữ liệu ở tầng đó bị ép phải phân mảnh thô theo quy mô vùng, làm lãng phí một tầng độ sâu của cây và làm giảm cơ hội đào sâu vào các biến động học phụ tải tức thời.
  - *Cơ chế cây không đối xứng và tỉa cành của XGBoost:* Trái lại, XGBoost phát triển cây theo từng nút độc lập kết hợp cơ chế phạt số lá γ. Các nhánh cần phân tách theo khu vực sẽ sử dụng biến Zone, trong khi các nhánh khác vẫn tự do chọn biến đo lường tức thời hoặc tỉa bỏ nhánh không mang lại độ lợi thông tin, giúp mô hình duy trì tính ổn định và nhích nhẹ hiệu năng.
- **Không gian Context-Aware (45 đặc trưng) - Bước nhảy vọt hiệu năng:** Bước nhảy vọt diễn ra khi tích hợp 4 đặc trưng ngữ cảnh vi mô (gồm các biến z-score chuẩn hóa cục bộ, ngày làm việc, z-score robust và biến tương tác nhiệt độ). PR-AUC của cả bốn mô hình đều tăng vọt trung bình +0,045 đến +0,058 điểm: XGBoost lên 0,6810, LightGBM lên 0,6750, và CatBoost bùng nổ trở lại từ 0,6181 lên 0,6691. Kết quả này khẳng định độ lệch phụ tải chuẩn hóa theo giờ chính là tín hiệu cốt tử giải quyết triệt để phương sai nội bộ giữa các công trình.

4.2.3 Tối ưu hóa Siêu tham số bằng Optuna trên Không gian Expanded

Nhằm khai thác tối đa năng lực phân loại, nhóm nghiên cứu mở rộng không gian lên cấp độ 4: **Expanded Champion (53 đặc trưng, 54 cột)**, bổ sung 8 đặc trưng động học chuỗi thời gian vi mô trễ 1h/2h, sai phân, tỷ số động năng, bộ đếm treo cảm biến (`flatline_duration`) và phân rã STL Residual.

Toàn bộ 4 thuật toán được tinh chỉnh siêu tham số chuyên sâu bằng giải thuật tối ưu hóa Bayes Optuna TPE qua 50 lần thử nghiệm với mục tiêu cực đại hóa PR-AUC trên không gian kiểm định. Cấu hình siêu tham số tối ưu và kết quả kiểm thử tương ứng trên 372.993 mẫu kiểm tra ngoài mẫu được trình bày chi tiết tại Bảng 9.

Bảng 9: **Cấu hình Siêu tham số Tối ưu hóa Optuna và Hiệu năng Đơn lẻ trên Không gian Expanded (53 Đặc trưng)**

Thuật toán	Cấu hình Siêu tham số Tối ưu (Optuna Champion)	PR-AUC Test	ROC-AUC	F_1-Score
LightGBM	`n_estimators`: 300, `num_leaves`: 114, `max_depth`: 10, `learning_rate`: 0,0384, `subsample`: 0,7326, `colsample_bytree`: 0,7279, `min_child_samples`: 86, `reg_alpha`: 0,0209, `reg_lambda`: 0,9258	**0,8423**	**0,9537**	0,8333
XGBoost	`n_estimators`: 450, `max_depth`: 10, `learning_rate`: 0,0209, `subsample`: 0,9332, `colsample_bytree`: 0,6244, `min_child_weight`: 1, `gamma`: 0,0055, `reg_alpha`: 0,0011, `reg_lambda`: 0,0139	0,8406	0,9521	0,8326
CatBoost	`iterations`: 350, `depth`: 9, `learning_rate`: 0,0726, `l2_leaf_reg`: 2,4728, `random_strength`: 0,0050	0,8388	0,9459	**0,8433**
HistGradientBoosting	`max_iter`: 300, `max_leaf_nodes`: 41, `max_depth`: 11, `learning_rate`: 0,0578, `min_samples_leaf`: 91, `l2_regularization`: 4,9001	0,8340	0,9522	0,8268

Trên không gian Expanded 53 đặc trưng sau khi tối ưu hóa siêu tham số, hiệu năng của toàn bộ bốn thuật toán ghi nhận bước đột phá vượt bậc. PR-AUC của cả bốn mô hình tăng vọt từ dải 0,667–0,681 ở tầng Context lên vùng 0,8340–0,8423, tương ứng mức tăng ròng hơn +0,16 điểm PR-AUC. Sự cải thiện nhảy vọt này chứng minh rằng 8 đặc trưng động học chuỗi thời gian (độ trễ, sai phân, tỷ số) kết hợp với phần dư phân rã STL Residual đã nắm bắt chuẩn xác các sự cố tăng giảm tải tức thời cũng như hiện tượng đóng băng cảm biến.

Sự phân hóa hiệu năng giữa bốn mô hình đơn lẻ được lý giải sâu sắc thông qua cơ chế cấu trúc cây và phương thức tối ưu hàm mất mát của từng thuật toán:

- **LightGBM dẫn đầu về PR-AUC** (0,8423) **và độ nhạy Recall** (76,34%)**:** LightGBM áp dụng chiến lược phát triển cây theo nút lá tối ưu (Leaf-wise / Best-first) kết hợp cơ chế lấy mẫu theo độ dốc GOSS. Trong bài toán dữ liệu mất cân bằng nghiêm trọng (dị thường chỉ chiếm $\approx$ 2,45%), các mẫu bất thường tập trung ở những vùng không gian thưa thớt với độ dốc hàm mất mát cực lớn. Chiến lược leaf-wise cho phép LightGBM đi sâu không đối xứng vào chính xác các vùng có độ dốc cao này mà không bị ép buộc phải mở rộng đồng đều các nhánh khác như cây truyền thống. Nhờ đó, LightGBM tinh chỉnh rất mịn hàm mật độ xác suất ở vùng đuôi phân phối, tối ưu hóa diện tích PR-AUC tích phân trên toàn dải ngưỡng và bắt trúng nhiều mẫu dị thường khó học nhất.

- **XGBoost đạt độ chính xác Precision rất cao** (94,22%) **nhưng PR-AUC** (0,8406) **thấp hơn LightGBM một chút:** XGBoost phát triển cây theo từng tầng (Level-wise) kết hợp xấp xỉ Taylor bậc hai và hàm phạt chính quy hóa toàn diện gồm hệ số phạt số lá γ cùng điều chuẩn L_1 (α) và L_2 (λ). Việc mở rộng đồng đều toàn bộ nút ở cùng độ sâu buộc thuật toán phải cắt tỉa khắt khe các nhánh có độ lợi thông tin không vượt trội so với ngưỡng γ. Tính kỷ luật này giúp XGBoost cực kỳ thận trọng khi gắn nhãn dị thường, hạn chế tối đa các báo động giả (False Positives cực thấp, Precision đạt 94,22%). Tuy nhiên, chính tính thận trọng này khiến cây bỏ sót một số trường hợp dị thường vi mô ở các nhánh sâu cục bộ (Recall dừng ở 74,59%), khiến PR-AUC thấp hơn LightGBM đôi chút.

- **CatBoost dẫn đầu về F_1-Score** (0,8433) **và Precision** (94,88%) **nhưng PR-AUC** (0,8388) **lại thấp hơn:** CatBoost xây dựng các cây đối xứng cân bằng và cơ chế mã hóa mục tiêu có thứ tự. Ở mỗi tầng của cây, CatBoost áp đặt cùng một thuộc tính phân chia và cùng một ngưỡng cho toàn bộ các nút ở tầng đó. Cấu trúc

cân bằng 2^d nút lá hoạt động như một cơ chế điều chuẩn ngầm cực mạnh, giúp mô hình hoàn toàn miễn nhiễm với hiện tượng quá khớp trên các nhánh phụ tải nhiễu. Dự đoán của CatBoost vì thế có độ tin cậy và sự tập trung xác suất cao nhất ($F_1 = 0{,}8433$, Precision 94,88%). Tuy nhiên, sự cứng nhắc của cây đối xứng không cho phép nó tạo ra các phân nhánh hẹp, linh hoạt riêng lẻ theo từng biến động phức tạp như LightGBM, dẫn đến khả năng xếp hạng phân vị xác suất trên toàn dải ngưỡng bị giảm sút nhẹ, làm PR-AUC đạt 0,8388.

- **HistGradientBoosting đạt PR-AUC khiêm tốn hơn (0,8340):** HistGradientBoosting nén cứng toàn bộ 53 đặc trưng liên tục vào 256 thùng số nguyên 8-bit. Mặc dù tối ưu hóa tốc độ và bộ nhớ rất tốt, việc cố định 256 thùng làm mất đi độ phân giải chi tiết tại các vùng biến động vi mô nhạy cảm (như các sai phân tức thời `meter_diff_1h` hay tỷ số `meter_ratio_1h` quanh ngưỡng 0). Thêm vào đó, việc thiếu thành phần phạt độ thưa L_1 khiến mô hình kém linh hoạt hơn trong việc loại trừ các chiều đặc trưng nhiễu, khiến PR-AUC dừng ở 0,8340.

Bốn mô hình tối ưu với các triết lý cấu trúc đa dạng này tạo thành hệ thống nền tảng vững chắc phục vụ cho các chiến lược dung hợp đa mô hình kế tiếp.

4.2.4 Kỹ thuật Dung hợp Đa Mô hình

Để tận dụng tính đa dạng phân phối dự đoán từ bốn thuật toán cây tăng cường, nhóm nghiên cứu khảo sát toàn diện 23 kỹ thuật dung hợp khác nhau. Gọi $p_m(x)$ là xác suất dị thường do mô hình thứ $m \in \{1, \ldots, M\}$ dự đoán, $r_m(x) = \frac{\text{rank}(p_m(x))}{N}$ là thứ hạng phân vị chuẩn hóa trên không gian đánh giá quy mô $N = 372.993$ mẫu. Các kỹ thuật đại diện được triển khai theo các nguyên lý sau:

Bình chọn xác suất mềm (Soft Voting): Phương pháp lấy trung bình cộng xác suất dự đoán của M mô hình:

$$s_{\text{soft}}(x) = \frac{1}{M} \sum_{m=1}^{M} p_m(x)$$

Trung bình thứ hạng phân vị (Rank Averaging): Thay vì cộng trực tiếp xác suất, phương pháp tính trung bình trên thứ hạng phân vị chuẩn hóa:

$$s_{\text{rank}}(x) = \frac{1}{M} \sum_{m=1}^{M} r_m(x)$$

Cách tiếp cận này triệt tiêu hoàn toàn sự sai lệch về biên độ thang đo xác suất giữa các thuật toán cây, đưa điểm số về phân vị thống nhất $r \in [0, 1]$.

Xác định trọng số theo hiệu năng kiểm định: Trọng số đóng góp của mô hình thứ m được xác định dựa trên tỷ lệ diện tích PR-AUC (Average Precision, AP_m) đo được độc lập trong quá trình kiểm định nội bộ trên tập huấn luyện:

$$w_m^{\text{AP}} = \frac{\text{AP}_m}{\sum_{j=1}^{M} \text{AP}_j}, \quad \text{với} \quad \sum_{m=1}^{M} w_m^{\text{AP}} = 1$$

Hệ số này đảm bảo các thuật toán có năng lực xếp hạng vượt trội (như LightGBM và XGBoost) nắm giữ tỷ trọng chi phối lớn hơn trong quyết định chung, trong khi các mô

hình có độ phân giải thô hơn (như HistGB) được hạ thấp mức độ ảnh hưởng. Dựa trên vector trọng số này, hai biến thể dung hợp có trọng số được xây dựng:

Dung hợp xác suất mềm có trọng số (Weighted Soft Voting): Áp dụng tổ hợp tuyến tính có trọng số trực tiếp trên không gian xác suất dự báo thô:

$$s_{\text{w_soft}}(x) = \sum_{m=1}^{M} w_m^{\text{AP}}\, p_m(x)$$

Phương pháp này ưu tiên các mô hình mạnh hơn, tuy nhiên vẫn chịu rủi ro bị méo mó nếu một mô hình có thang đo xác suất phân cực mạnh (biên độ dao động lớn) lấn át mô hình có thang đo xác suất co cụm thận trọng.

Dung hợp thứ hạng phân vị có trọng số (Weighted Rank Averaging): Áp dụng tổ hợp có trọng số trên không gian thứ hạng phân vị chuẩn hóa:

$$s_{\text{w_rank}}(x) = \sum_{m=1}^{M} w_m^{\text{AP}}\, r_m(x)$$

Kỹ thuật này phát huy đồng thời hai ưu điểm: vừa triệt tiêu hoàn toàn sự sai lệch về hình dạng phân phối và thang đo xác suất giữa các thuật toán cây khác nhau (đưa toàn bộ về phân phối đều trên $[0, 1]$), vừa duy trì sự ưu tiên có trọng số theo năng lực phân loại thực tế đã được kiểm định của từng mô hình.

Tối ưu trọng số ràng buộc phi tuyến SLSQP: Nhóm thiết lập bài toán quy hoạch phi tuyến để tìm vector trọng số $\mathbf{w}^*$ tối ưu:

$$\mathbf{w}^* = \arg\max_{\mathbf{w}} \text{AP}\left(y_{\text{val}}, \sum_{m=1}^{M} w_m r_{m,\text{val}}\right) \quad \text{s.t.} \quad w_m \geq 0,\ \sum_{m=1}^{M} w_m = 1$$

Thực nghiệm giải thuật SLSQP cho thấy vector trọng số hội tụ tiệm cận về nghiệm phân phối đều: $\mathbf{w}^* \approx [0{,}250, 0{,}250, 0{,}250, 0{,}250]$.

Trung bình nhân và trung bình điều hòa (Geometric & Harmonic Mean): Được định nghĩa lần lượt theo công thức:

$$s_{\text{geo}}(x) = \left(\prod_{m=1}^{M} \tilde{p}_m(x)\right)^{1/M}, \qquad s_{\text{harm}}(x) = \frac{M}{\sum_{m=1}^{M} 1/\tilde{p}_m(x)}$$

trong đó $\tilde{p}_m(x) = \text{clip}(p_m(x), 10^{-6}, 1.0)$. Phép lấy trung bình nhân phạt rất nặng các mẫu có sự bất đồng thuận khi một mô hình dự đoán xác suất thấp, hỗ trợ lọc bỏ triệt để các cảnh báo giả.

4.2.5 Đối chứng các Kỹ thuật Dung hợp Đa Mô hình trên Không gian Expanded

Bảng 10 tổng hợp kết quả xếp hạng đối chứng của các mô hình đơn lẻ và các kỹ thuật dung hợp tiêu biểu trên toàn bộ 372.993 mẫu của tập kiểm tra ngoài mẫu T_{out}, trích xuất trực tiếp từ quy trình chuẩn hóa `pipeline_ml.py`.

Bảng 10: **Hiệu năng Đối chứng Bốn Mô hình Đơn và Các Kỹ thuật Dung hợp Tiêu biểu trên Không gian Expanded (53 Đặc trưng)**

Hạng	Mô hình / Phương pháp	Kỹ thuật Dung hợp	PR-AUC	ROC-AUC	F_1-Score	Precision	Recall	Ngưỡng τ^*
1	Trio Prob (XGB + CAT + LGBM)	Soft Voting	**0,8450**	0,9522	0,8398	93,12%	76,48%	0,2473
2	Quad Harmonic Mean	Harmonic Mean	0,8448	0,9528	0,8420	92,73%	77,10%	0,1809
3	Quad Geometric Mean	Geometric Mean	0,8447	0,9530	0,8437	94,05%	76,50%	0,2342
4	Trio Rank (XGB + CAT + LGBM)	Rank Averaging	0,8446	0,9522	0,8403	92,26%	**77,15%**	0,9790
5	Quad Equal Rank 0.25 (Quán quân)	Rank Averaging	0,8443	0,9528	0,8428	94,79%	75,87%	0,9797
6	Quad SLSQP Rank Averaging	Rank SLSQP	0,8443	0,9528	0,8428	94,79%	75,87%	0,9797
7	Quad Weighted Rank (PR-AUC)	Rank Weighted	0,8443	0,9528	0,8428	94,77%	75,87%	0,9797
8	Pair Prob (XGB + CAT)	Soft Voting	0,8441	0,9507	0,8430	93,62%	76,66%	0,2296
9	Pair Rank (CAT + LGBM)	Rank Averaging	0,8441	0,9513	**0,8448**	94,50%	76,39%	0,9799
10	Trio Rank (CAT + LGBM + HIST)	Rank Averaging	0,8436	0,9524	**0,8448**	**95,14%**	75,97%	0,9799
11	Quad Equal Prob (Soft Voting)	Soft Voting	0,8436	0,9531	0,8440	94,61%	76,17%	0,2818
12	Single LightGBM	Mô hình đơn	0,8423	**0,9537**	0,8333	91,71%	76,34%	0,2502
13	Single XGBoost	Mô hình đơn	0,8406	0,9521	0,8326	94,22%	74,59%	0,2814
14	Single CatBoost	Mô hình đơn	0,8388	0,9459	0,8433	94,88%	75,90%	0,2593
15	Single HistGradientBoosting	Mô hình đơn	0,8340	0,9522	0,8268	92,62%	74,67%	0,3341

Phân tích định lượng từ bảng kết quả đối chứng mang lại nhiều kết luận khoa học giá trị, làm sáng tỏ bản chất hoạt động của từng chiến lược dung hợp:

1. **Cơ chế bù trừ sai số trực giao giữa các kiến trúc cây:** Mọi phương pháp dung hợp tiêu biểu đều vượt trội hơn mô hình đơn lẻ tốt nhất (LightGBM 0,8423) từ +0,0013 đến +0,0027 điểm PR-AUC. Sự cải thiện này bắt nguồn từ tính đa dạng cấu trúc giữa bốn thuật toán: sai số phân loại của chúng không bị tương quan hoàn toàn. Những mẫu dị thường bị CatBoost bỏ sót do tính đối xứng cứng nhắc của cây lại được cấu trúc linh hoạt theo nút lá của LightGBM phát hiện; ngược lại, các cảnh báo giả do LightGBM rẽ nhánh quá sâu ở vùng biên lại được kiềm chế bởi tính kỷ luật điều chuẩn nghiêm ngặt của XGBoost và CatBoost.

2. **Tại sao Trio Prob (XGBoost + CatBoost + LightGBM) đạt hiệu năng cao nhất** (0,8450)**:** Khi dung hợp xác suất, chất lượng của các mô hình thành phần giữ vai trò quyết định. Trio Prob tập hợp ba thuật toán có năng lực phân loại mạnh nhất và chủ động loại bỏ HistGradientBoosting (mô hình yếu hơn về PR-AUC do hạn chế phân giải của 256 thùng số nguyên). Việc loại bỏ mô hình có độ phân giải thô này giúp ngăn chặn hiện tượng làm loãng (dilution) hoặc nhiễu hóa xác suất trung bình, giúp hàm mật độ xác suất kết hợp đạt độ lồi và diện tích phủ PR-AUC tối ưu nhất toàn bài.

3. **Tại sao Quad Harmonic Mean** (0,8448) **và Quad Geometric Mean** (0,8447) **vượt trội hơn hẳn Quad Soft Voting** (0,8436)**:**

   - *Trung bình nhân (Geometric Mean - $\sqrt[4]{p_1p_2p_3p_4}$):* Do phép nhân xác suất có tính chất suy giảm theo hàm mũ, nếu có bất kỳ một mô hình nào tin chắc mẫu là bình thường ($p_i \to 0$), giá trị trung bình nhân sẽ bị kéo sụt giảm mạnh về 0. Điều này biến Geometric Mean thành một **cơ chế sàng lọc đồng thuận nghiêm ngặt**: một mẫu chỉ được gán điểm dị thường cao khi phần lớn các mô hình đều ghi nhận tín hiệu bất thường rõ nét. Cơ chế này loại bỏ triệt để các cảnh báo giả do một mô hình cá lẻ bị nhiễu cảm biến đánh lừa, giúp nâng Precision lên 94,05% và đẩy PR-AUC lên 0,8447.
   - *Trung bình điều hòa (Harmonic Mean - $\frac{4}{\sum 1/p_i}$):* Bị chi phối mạnh mẽ bởi giá trị xác suất nhỏ nhất $\min(p_i)$ trong bốn mô hình. Trong không gian xác suất, đây là phép toán có tính phạt nặng nhất đối với sự bất đồng thuận tại các

điểm biên, hỗ trợ kiểm soát chặt chẽ các mẫu ranh giới phức tạp, đưa Recall lên 77,10% và cân bằng $F_1 = 0{,}8420$.

- Ngược lại, *Quad Equal Prob Soft Voting* chỉ lấy trung bình cộng tuyến tính $\frac{1}{4}\sum p_i$, vốn rất dễ bị bóp méo nếu một mô hình cá lẻ xuất ra xác suất giả quá cao, khiến PR-AUC (0,8436) kém hơn hẳn.

4. **Tại sao Rank Averaging đạt độ chuẩn xác Precision 94,79% và tương đương tối ưu hóa SLSQP:** Các mô hình cây khác nhau tạo ra phân phối xác suất thô trên thang đo khác nhau (chẳng hạn CatBoost có xu hướng co cụm quanh trung vị do cây đối xứng, trong khi LightGBM phân cực mạnh về 0 và 1). Việc chuyển đổi xác suất sang thứ hạng phân vị $r_m(x) \in [0, 1]$ chuẩn hóa mọi mô hình về cùng một phân phối đều, loại bỏ hoàn toàn sự méo mó về thang đo biên độ. Nghiệm tối ưu phi tuyến SLSQP trên tập kiểm định hội tụ về bộ trọng số đều $[0{,}25; 0{,}25; 0{,}25; 0{,}25]$ khẳng định về mặt toán học rằng cả bốn mô hình đều đóng góp lượng thông tin trực giao cân bằng hoàn hảo; không mô hình nào vượt trội áp đảo đến mức cần gán trọng số thiên lệch.

Xét về độ chuẩn xác vận hành, mô hình Quad Equal Rank Champion tại ngưỡng phân vị $\tau^* = 0{,}9797$ phát hiện chính xác 6.928 mẫu dị thường thực tế (TP), chỉ để lọt 2.203 mẫu (FN) và phát sinh vỏn vẹn 384 báo động giả (FP) trên tổng số 363.862 mẫu bình thường. Tỷ lệ này xác lập độ tin cậy vượt trội với Precision đạt 94,79% và Recall đạt 75,87%, đồng thời đảm bảo tốc độ suy luận dưới 10,9 giây cho toàn bộ 373.000 mẫu ngoài đời thực.

4.3 Khảo sát Mở rộng: Đánh giá Tác động của Isolation Forest và Phân cụm K-Means

Nhằm kiểm chứng liệu việc bổ sung các thông tin phi giám sát có giúp tăng cường khả năng phân tách của các mô hình cây trên không gian Expanded (53 đặc trưng) hay không, nhóm thực hiện khảo sát mở rộng thực nghiệm với hai kỹ thuật bổ trợ.

Đầu tiên, phương pháp gom cụm đặc tính công trình bằng K-Means mô tả mỗi công trình b bằng một vector hồ sơ $\mathbf{z}_b$ chứa trung bình và độ lệch chuẩn của các đặc trưng phụ tải. Giải thuật K-Means phân chia 200 công trình thành K cụm tâm $\boldsymbol{\mu}_k$:

$$\min_{\{C_k\}_{k=1}^{K}} \sum_{k=1}^{K} \sum_{\mathbf{z}_b \in C_k} \|\mathbf{z}_b - \boldsymbol{\mu}_k\|_2^2$$

Nhãn cụm sau đó được mã hóa One-Hot, giúp mô hình cây rẽ nhánh trực tiếp theo phân nhóm hành vi vận hành mà không cần phụ thuộc vào mã định danh `building_id`. Kỹ thuật thứ hai là Điểm Dị thường Cô lập từ Isolation Forest (`iforest_score`), đo lường độ dài đường đi $h(x)$ trung bình để cô lập một mẫu trong cấu trúc cây ngẫu nhiên:

$$s(x, n) = 2^{-\frac{\mathbb{E}[h(x)]}{c(n)}}$$

Giá trị nghịch đảo `iforest_score` được bổ sung như một trục tọa độ liên tục phản ánh mức độ bất thường ngoại lai thuần túy của từng mẫu dữ liệu.

Bảng 11 trình bày kết quả thực nghiệm mở rộng khi bổ sung độc lập và kết hợp hai đặc trưng này trên nền tảng siêu tham số cơ sở Expanded với tham số cụm K tối ưu hóa

riêng biệt cho từng mô hình ($K = 2$ cho XGBoost, $K = 10$ cho CatBoost, $K = 4$ cho LightGBM, $K = 5$ cho HistGradientBoosting).

Bảng 11: **Thực nghiệm Khảo sát Mở rộng Đặc trưng Isolation Forest và Phân cụm K-Means trên Nền tảng Expanded**

Mô hình / Cấu hình Đặc trưng	PR-AUC	ΔPR-AUC	ROC-AUC	F_1-Score	Precision	Recall
XGBoost (Expanded Cơ sở)	0,8406	0,0000	0,9521	0,8324	94,08%	74,64%
XGBoost + `iforest_score`	0,8417	+0,0011	0,9520	0,8290	91,74%	75,62%
XGBoost + K-Means ($K = 2$)	0,8412	+0,0006	0,9516	0,8335	93,89%	74,93%
XGBoost + IF + K-Means ($K = 2$)	0,8381	-0,0025	0,9521	0,8283	90,94%	76,05%
CatBoost (Expanded Cơ sở)	0,8388	0,0000	0,9459	0,8405	92,38%	77,10%
CatBoost + `iforest_score`	0,8377	-0,0011	0,9451	0,8347	90,86%	77,19%
CatBoost + K-Means ($K = 10$)	0,8410	+0,0021	0,9497	0,8310	89,03%	77,91%
CatBoost + IF + K-Means ($K = 10$)	0,8406	+0,0018	0,9496	0,8249	86,53%	78,81%
LightGBM (Expanded Cơ sở)	0,8423	0,0000	0,9537	0,8319	92,35%	75,68%
LightGBM + `iforest_score`	0,8415	-0,0008	0,9532	0,8334	92,02%	76,16%
LightGBM + K-Means ($K = 4$)	0,8411	-0,0012	0,9532	0,8361	92,59%	76,21%
LightGBM + IF + K-Means ($K = 4$)	0,8443	+0,0020	0,9543	0,8405	94,86%	75,45%
HistGradientBoosting (Expanded Cơ sở)	0,8340	0,0000	0,9522	0,8253	91,43%	75,21%
HistGradientBoosting + `iforest_score`	0,8352	+0,0012	0,9530	0,8259	92,65%	74,50%
HistGradientBoosting + K-Means ($K = 5$)	0,8353	+0,0012	0,9522	0,8231	89,88%	75,91%
HistGradientBoosting + IF + K-Means ($K = 5$)	0,8350	+0,0009	0,9529	0,8259	91,65%	75,16%

Kết quả thực nghiệm tại Bảng 11 chỉ ra sự tương tác phụ thuộc chặt chẽ giữa kiến trúc cây và từng loại đặc trưng mở rộng:

- **LightGBM bứt phá kỷ lục khi kết hợp cả hai** (0,8443)**:** Chiến lược phát triển cây theo nút lá tối ưu (Leaf-wise) của LightGBM phát huy hiệu quả tối đa khi được cung cấp cả hai chiều thông tin. Nút lá ở tầng trên có thể phân chia theo cụm K-Means ($K = 4$) để nhận diện mẫu hình phụ tải vĩ mô của nhóm công trình, sau đó các nút lá sâu tiếp tục đi sâu theo trục `iforest_score` để cô lập chính xác các đỉnh phụ tải dị thường của riêng nhóm đó. Sự kết hợp này mang lại mức tăng +0,0020 PR-AUC, xác lập đỉnh cao hiệu năng đơn lẻ trong toàn bộ nghiên cứu.
- **CatBoost tương thích tốt nhất với phân cụm K-Means** (0,8410)**:** Do kiến trúc cây đối xứng áp đặt cùng một ngưỡng chia cho mọi nút ở cùng một tầng, CatBoost đòi hỏi các đặc trưng phân nhóm mang tính vĩ mô đồng nhất. Nhãn phân cụm K-Means ($K = 10$) cung cấp đúng thông tin phân vùng phụ tải này, giúp CatBoost cải thiện vượt bậc độ nhạy (Recall tăng từ 77,10% lên 77,91%) và nâng PR-AUC thêm +0,0021. Ngược lại, đặc trưng liên tục `iforest_score` có nhiều biến động mịn cục bộ không phù hợp với cấu trúc phân chia đối xứng của CatBoost.
- **XGBoost đạt tối ưu khi chỉ tích hợp `iforest_score`** (0,8417)**:** XGBoost mở rộng cây theo từng tầng với cơ chế cắt tỉa γ khắt khe. Điểm số ngoại lai liên tục `iforest_score` đóng vai trò như một trục phân ranh giới thô giúp giảm trừ nhanh chóng độ dốc hàm mất mát ở các tầng nông mà không làm tăng số lượng nhánh con. Ngược lại, việc bổ sung thêm các biến cụm One-hot của K-Means làm tăng số chiều tìm kiếm ngưỡng chia ở mỗi tầng, khiến hàm phạt γ và điều chuẩn λ kích hoạt sớm hơn, làm giảm nhẹ hiệu năng khi kết hợp cả hai (0,8381).
- **HistGradientBoosting tăng trưởng đều đặn** (0,8353)**:** Cả hai kỹ thuật đều mang lại mức cải thiện nhẹ +0,0012 PR-AUC cho HistGB, chứng minh rằng thông tin không gian ngoại lai và hồ sơ cụm hỗ trợ tích cực trong việc bù đắp sự thiếu hụt độ phân giải của cơ chế phân thùng 256 mức.

Nhằm khảo sát kịch bản tối đa hóa tiềm năng của hướng tiếp cận này, nhóm thực hiện bước dung hợp nâng cao: tập hợp các cấu hình tối ưu nhất của từng thuật toán (XGBoost với IF, CatBoost với K-Means, LightGBM với IF và K-Means, HistGradientBoosting với K-Means) để đối chứng với các chiến lược dung hợp tương ứng. Bảng 12 tổng hợp hiệu năng khảo sát nâng cao này trên tập kiểm tra ngoài mẫu.

Bảng 12: **Khảo sát Nâng cao: Hiệu năng Dung hợp Các Mô hình Tối ưu Nhất Bổ sung IF và K-Means**

Hạng	Mô hình / Cấu hình Thử nghiệm	Kỹ thuật	PR-AUC	Δ so với Base	ROC-AUC	F_1-Score	Precision	Recall
1	Trio Soft Voting (XGB + CAT + LGB)	Soft Voting	**0,8468**	+0,0018	0,9541	0,8430	93,61%	76,67%
2	Trio Rank (XGB + CAT + LGB)	Rank Averaging	0,8464	+0,0018	0,9537	0,7770	**99,62%**	63,68%
3	Quad Harmonic Mean (+ IF/K-Means)	Harmonic Mean	0,8463	+0,0015	0,9537	**0,8438**	92,50%	**77,57%**
4	Quad Geometric Mean (+ IF/K-Means)	Geometric Mean	0,8462	+0,0015	0,9540	0,8430	92,86%	77,19%
5	Quad Equal Rank 0.25 (+ IF/K-Means)	Rank Averaging	0,8459	+0,0016	0,9539	0,7708	99,60%	62,86%
6	Quad Equal Prob Soft Voting (+ IF/K-Means)	Soft Voting	0,8452	+0,0016	0,9542	0,8437	95,82%	75,36%
7	LightGBM + IF + K-Means ($K = 4$)	Mô hình đơn mở rộng	0,8443	+0,0020	**0,9543**	0,8405	94,86%	75,45%
8	XGBoost + `iforest_score`	Mô hình đơn mở rộng	0,8417	+0,0011	0,9520	0,8290	91,74%	75,62%
9	CatBoost + K-Means ($K = 10$)	Mô hình đơn mở rộng	0,8410	+0,0021	0,9497	0,8310	89,03%	77,91%
10	HistGB + K-Means ($K = 5$)	Mô hình đơn mở rộng	0,8353	+0,0012	0,9522	0,8231	89,88%	75,91%

Phân tích Bản chất Lợi ích và Đóng góp của Đặc trưng Mở rộng: Kết quả thực nghiệm đối chứng tại Bảng 12 khẳng định việc tích hợp các đặc trưng học máy không giám sát gồm điểm số ngoại lai từ Isolation Forest (`iforest_score`) và phân cụm hồ sơ phụ tải K-Means đem lại những lợi thế then chốt cả về mặt cơ chế học tập lẫn độ đo hiệu năng thực tế:

1. **Cung cấp thông tin tiên nghiệm ngoại lai toàn cục:** Điểm số `iforest_score` cô đọng cấu trúc phân tán đa chiều của mẫu dữ liệu thành một đại lượng vô hướng phản ánh độ cô lập không gian. Nhờ có trục phân tách tiên nghiệm này, các thuật toán học cây như LightGBM và XGBoost không phải tiêu tốn nhiều phép rẽ nhánh sâu trên từng thuộc tính liên tục độc lập, giúp hạn chế rủi ro ghi nhớ nhiễu và hỗ trợ mô hình nhận diện chuẩn xác các đột biến cực đoan. Minh chứng rõ rệt nhất là mô hình LightGBM khi kết hợp đồng thời cả hai yếu tố đã bứt phá đạt PR-AUC 0,8443 (tăng +0,0020 so với Expanded), xác lập mốc hiệu năng cao nhất trong toàn bộ các mô hình đơn lẻ của nghiên cứu.

2. **Mã hóa ngữ cảnh hành vi công trình mà không vi phạm nguyên tắc bảo mật định danh:** Thông qua nhãn phân cụm K-Means tối ưu hóa riêng biệt cho từng mô hình ($K = 2$ cho XGBoost, $K = 10$ cho CatBoost, $K = 4$ cho LightGBM, $K = 5$ cho HistGradientBoosting), mô hình nắm bắt được mẫu hình phụ tải đặc trưng của từng nhóm công trình có hành vi tương đồng (chẳng hạn nhóm công trình thương mại tải cao ban ngày, nhóm xưởng sản xuất hoạt động liên tục hoặc khu học đường giảm tải cuối tuần). Đặc trưng này đóng vai trò như một bộ lọc ngữ cảnh vĩ mô, cho phép cây quyết định phân biệt được một mức biến động phụ tải là bình thường hay bất thường dựa trên quy luật vận hành của cụm công trình đó. Nhờ vậy, CatBoost khi bổ sung phân cụm $K = 10$ đã gia tăng mạnh mẽ độ nhạy (Recall đạt 77,91%) và nâng PR-AUC thêm +0,0021.

3. **Thiết lập kỷ lục hiệu năng mới qua dung hợp nâng cao:** Khi kết hợp các mô hình thành phần đạt phong độ tốt nhất, chiến lược dung hợp **Trio Soft Voting (+ IF/K-Means)** đã xác lập đỉnh cao hiệu năng của toàn bộ nghiên cứu với PR-AUC đạt **0,8468** (vượt trội hơn mọi cấu hình dung hợp cơ sở trước đó). Đồng thời, cấu hình **Trio Rank Averaging** đạt độ chuẩn xác gần như tuyệt đối với **Precision**

lên tới 99,62% (gần như triệt tiêu hoàn toàn hiện tượng báo động giả), trong khi **Quad Harmonic Mean** tối đa hóa khả năng bao quát với **Recall chạm mức 77,57%** và $F_1 = 0{,}8438$.

Kết luận Tổng kết Phân hệ Học máy: Những phân tích và số liệu thực nghiệm trên khẳng định việc bổ sung thông tin ngoại lai không giám sát và phân cụm hồ sơ phụ tải là một bước nâng cấp mang lại giá trị đóng góp thực chất và bền vững. Sự kết hợp giữa bộ đặc trưng chuỗi thời gian chuyên sâu và các đặc trưng học máy không giám sát đã hình thành nên một kiến trúc phát hiện dị thường toàn diện, vừa khai thác sâu tính biến động nội tại của từng cảm biến, vừa làm giàu ngữ cảnh vận hành trên toàn bộ mạng lưới công trình, qua đó mang lại độ tin cậy và hiệu năng phát hiện dị thường cao nhất cho toàn hệ thống.

5 Triển khai Học sâu

5.1 Kiến trúc Pipeline Học Sâu Tổng thể

Khác với phân hệ Học máy vốn tiếp cận bài toán dựa trên các vector mẫu bảng tĩnh tại từng thời điểm độc lập, phân hệ Học sâu được thiết kế chuyên biệt để trực tiếp khai phá **động học chuỗi thời gian liên tục**. Trọng tâm kiến trúc dựa trên cơ chế **cửa sổ trượt** với tổng chiều dài 420 giờ, bao gồm 252 giờ ngữ cảnh lịch sử (10,5 ngày) kết hợp với 168 giờ cửa sổ đích (1 tuần đánh giá). Nhằm đảm bảo tính nhất quán và công bằng tuyệt đối khi đối chứng với Học máy, phân hệ Học sâu **dùng chung ba bộ dữ liệu đã phân chia chu kỳ mùa vụ từ Chương 3** (Baseline, Zone-Enhanced và Context-Aware), bổ sung trục thời gian thực `timestamp` để cùng được kiểm tra ngoài mẫu trên 372.993 bản ghi của T_{out}.

Luồng xử lý tổng thể của phân hệ Học sâu được tổ chức thành bốn giai đoạn kỹ thuật cốt lõi:

1. **Giai đoạn 1 - Chuẩn hóa Cấu trúc Chuỗi và Phân đoạn Cửa sổ Ngữ cảnh:** Dữ liệu chuỗi thời gian của từng công trình được phân đoạn thành các khối đích dài 168 giờ kèm tối đa 252 giờ ngữ cảnh đứng trước. Để loại trừ triệt để hiện tượng rò rỉ thông tin xuyên biên, các điểm ngắt quãng chuỗi giữa các tháng (khoảng đệm cách ly 96 giờ) được kiểm soát nghiêm ngặt bằng cơ chế đặt lại cửa sổ và đệm số 0 ở đầu đoạn liên tục.

2. **Giai đoạn 2 - Mô hình hóa Đa hệ hình Chuỗi Thời gian:** Huấn luyện độc lập năm kiến trúc nơ-ron đại diện cho bốn trường phái học sâu chính trên cùng một cấu trúc fold kiểm định: mô hình theo điểm tĩnh (MLP) làm mốc đối chứng, mạng tích chập nhân quả giãn nở (Causal TCN) đại diện cho kịch bản trực tuyến, hai mạng nơ-ron hồi quy hai chiều (BiGRU và BiLSTM) cho kịch bản ngoại tuyến với trường tiếp nhận toàn diện, và mạng tự giải mã hồi quy (LSTM-AE) đại diện cho trường phái tái tạo không giám sát.

3. **Giai đoạn 3 - Kiểm soát Mất cân bằng và Tối ưu hóa Hội tụ:** Để xử lý tỷ lệ nhãn dị thường cực hiếm (2,03%), hàm mất mát `BCEWithLogitsLoss` được tích hợp cùng trọng số lớp dương $w_+ = 20$. Quá trình huấn luyện sử dụng thuật toán AdamW, cắt chuẩn gradient ở mức 1,0, điều chuẩn bằng Dropout 0,2 và Weight Decay 10^{-4}, đồng thời lưu giữ checkpoint tối ưu dựa trên chỉ số PR-AUC của fold kiểm định nội bộ.

4. **Giai đoạn 4 - Dung hợp Phi tham số và Hiệu chuẩn Ngưỡng Quyết định:** Khắc phục sự bất đồng về thang đo xác suất giữa các bộ phân loại và sai số tái tạo bằng phương pháp dung hợp trung bình hạng phân vị; đồng thời thực hiện hiệu chuẩn ngưỡng phân loại tối ưu τ^* độc lập trên tập kiểm định nội bộ của T_{in} và khóa cố định khi suy luận ngoài mẫu trên T_{out}.

Toàn bộ đường ống vận hành dựa trên bốn nguyên tắc phương pháp luận:

- **Hai lớp đánh giá tách biệt:** Mọi siêu tham số và checkpoint được tối ưu nội bộ bằng `GroupKFold` 5 phần theo công trình trên T_{in} (ngày 1–20 hàng tháng); tập kiểm tra T_{out} (ngày 25 đến cuối tháng, cách ly bằng khoảng đệm 96 giờ) chỉ dùng để chấm điểm ngoài mẫu độc lập, tuyệt đối không tham gia vào quá trình huấn luyện hay chọn ngưỡng.
- **Chuẩn hoá cục bộ không rò rỉ dữ liệu:** Các tham số chuẩn hóa số liệu (μ, σ và trung vị) được ước lượng khép kín trên các công trình huấn luyện của từng fold, không rò rỉ thông tin sang tập kiểm định hay tập ngoài mẫu.
- **Đầu ra là điểm dị thường liên tục:** Mọi mô hình đều xuất điểm số liên tục (xác suất $\hat{p}_i \in [0,1]$ hoặc sai số tái tạo bình phương), bảo đảm việc đánh giá không phụ thuộc ngưỡng thông qua các đường cong PR-AUC và ROC-AUC.
- **Khảo sát đa hệ hình để bổ trợ dung hợp:** Tận dụng tính đa dạng giữa các cơ chế nơ-ron (tích chập, cổng nhớ hồi quy, tự giải mã) để triệt tiêu phương sai lỗi và nâng cao năng lực phát hiện khi dung hợp mô hình.

5.2 Thiết kế Phương pháp luận và Giao thức Thực nghiệm

5.2.1 Mục tiêu Đầu ra và Thước đo Đánh giá

Tại mỗi giờ i của một toà nhà, mô hình trả về một điểm bất thường liên tục $s_i \in \mathbb{R}$. Với bộ phân loại có giám sát (MLP, TCN, BiGRU, BiLSTM), đó là xác suất:

$$s_i = \hat{p}_i = \sigma(z_i) = P(y_i = 1 \mid \text{ngữ cảnh}_i) \in [0,1]$$

với z_i là logit đầu ra. Với LSTM Autoencoder, đó là sai số tái tạo bình phương trung bình trên các kênh đầu vào:

$$s_i = \frac{1}{d}\sum_{j=1}^{d} (\hat{x}_{i,j} - x_{i,j})^2$$

trong đó d là số kênh đầu vào của biến thể đang xét (28, 31 hoặc 35). Điểm liên tục cho phép đánh giá không phụ thuộc ngưỡng bằng PR-AUC và ROC-AUC, và cho phép dung hợp mềm bằng hạng phần trăm. Khi cần nhãn nhị phân, quyết định là $\hat{y}_i = \mathbb{1}[s_i \geq \tau]$.

Hệ thống đánh giá theo ba độ đo:

- **PR-AUC** (*diện tích dưới đường cong Độ chuẩn xác – Độ nhạy*), độ đo chính vì nhạy với lớp hiếm (tính theo chuẩn `scikit-learn` như phần Học máy). Một mô hình đoán ngẫu nhiên có PR-AUC xấp xỉ tỷ lệ bất thường: 2,03% trên T_{in} và 2,45% trên T_{out}.
- **ROC-AUC**, độ đo xếp hạng không phụ thuộc ngưỡng và tỷ lệ lớp.

- **F1-Score** tại ngưỡng cực đại hoá F1 trên 200 phân vị của điểm trong OOF:

$$\tau^* = \arg\max_{\tau} \frac{2\,\mathrm{Precision}(\tau)\,\mathrm{Recall}(\tau)}{\mathrm{Precision}(\tau) + \mathrm{Recall}(\tau)}, \qquad F_1^{\max} = F_1^{\mathrm{OOF}}(\tau^*)$$

  Trên OOF, $F_1^{\max}$ là **cận trên mang tính chẩn đoán** vì ngưỡng được chọn ngay trên dữ liệu đang chấm điểm. Trên T_{out}, nhóm báo cáo $F_1(\tau^*)$ với đúng τ^* lấy từ OOF, không điều chỉnh theo nhãn của T_{out}, nên đây là ước lượng F1 gần với triển khai thực tế.

Ngoài các độ đo gộp, nhóm tính PR-AUC và ROC-AUC **theo từng toà nhà** rồi lấy trung bình macro trên các toà nhà có cả hai lớp (198 toà ở OOF, 189 toà ở T_{out}), để thấy mô hình có hoạt động đều giữa các toà nhà hay chỉ tốt ở một vài toà.

5.2.2 Tiêu chí Lựa chọn và Đa dạng hóa Thuật toán

Để giải quyết bài toán phát hiện dị thường phụ tải điện một cách khoa học và toàn diện, nhóm nghiên cứu xác lập bốn tiêu chí cốt lõi:

- **Tiêu chí 1 - Khai thác được ngữ cảnh thời gian:** Nhiều bất thường chỉ nhận ra khi đặt giá trị đo trong mức tải thông thường của toà nhà theo giờ, thứ trong tuần và các giờ lân cận; ngữ cảnh 252 giờ (hơn một tuần) được cấp cho các mô hình chuỗi để chúng so sánh với chu kỳ tuần.
- **Tiêu chí 2 - Tận dụng nhãn nhưng kiểm soát mất cân bằng:** Nhãn bất thường chỉ chiếm khoảng 2–2,5%; hàm mất mát có trọng số lớp được dùng thay cho SMOTE, vì nội suy giữa hai đoạn bất thường tạo ra chuỗi không có thật.
- **Tiêu chí 3 - Đa dạng hóa các hệ hình nơ-ron:** Năm mô hình đại diện bốn hệ hình khác nhau: theo điểm tĩnh (MLP), tích chập nhân quả (TCN), hồi quy hai chiều (BiGRU, BiLSTM) và tái tạo không giám sát (LSTM-AE). Sự đa dạng này vừa phục vụ so sánh, vừa là điều kiện để dung hợp có ý nghĩa.
- **Tiêu chí 4 - Khả thi về chi phí và tài nguyên tính toán:** Mỗi lần chạy đầy đủ gồm 3 biến thể × 5 mô hình × 5 fold, trên khoảng 1,15 triệu dòng huấn luyện; mô hình phải huấn luyện được trên GPU phổ thông (nhóm dùng batch 16 cho các mô hình chuỗi và batch 1024 cho MLP).

5.2.3 Quy trình Thực thi Thực nghiệm Chuẩn hóa

Quy trình thực thi thực nghiệm của phân hệ Học sâu được chuẩn hóa qua năm giai đoạn tuần tự:

- **Bước 1 (Đồng bộ nhãn thời gian và kiểm toán toàn vẹn):** Trích xuất trục thời gian thực `timestamp`, cấu trúc lại sáu tập dữ liệu chuỗi tương ứng với ba biến thể (Baseline, Zone, Context), ghi nhận mã băm SHA-256 và kiểm tra độ toàn vẹn cấu trúc bảng (loại trừ giá trị khuyết và trùng lặp bản ghi).
- **Bước 2 (Kiểm thử sơ bộ đường ống tính toán):** Thực hiện chạy kiểm thử khói trên tập con gồm 8 công trình qua 2 fold nhằm xác thực tính tương thích của tensor đầu vào, đồ thị tính toán và khả năng tăng tốc phần cứng GPU.

- **Bước 3 (Huấn luyện kiểm định chéo và sinh dự đoán):** Huấn luyện toàn diện 3 biến thể qua 5 mô hình trên 5 fold theo cấu trúc `GroupKFold`. Với mỗi mô hình và mỗi fold: chuẩn hóa cục bộ trên tập công trình huấn luyện, lưu checkpoint theo PR-AUC kiểm định, đồng thời sinh dự đoán ngoài mẫu (OOF) và ngoại suy trên T_{out}.
- **Bước 4 (Bảo toàn trạng thái và khôi phục tự động):** Toàn bộ trọng số checkpoint, lịch sử huấn luyện epoch và ma trận dự đoán xác suất được ghi nguyên tử an toàn vào đĩa cứng, hỗ trợ cơ chế nạp lại từ bộ đệm khi gặp sự cố gián đoạn.
- **Bước 5 (Tổng hợp đa chiều và trích xuất độ đo hiệu năng):** Tổng hợp các tệp dự đoán xác suất ngoài mẫu `oof_*.parquet` và `holdout_*.parquet`, tính toán hệ thống chỉ số PR-AUC, ROC-AUC, F_1-Score tổng thể và giá trị trung bình macro theo từng công trình.

Các sản phẩm tạo ra từ quá trình thực nghiệm được tổ chức chặt chẽ trong thư mục `model_DL/artifacts/chunked/`, bao gồm cấu hình thực thi, bảng tổng kết `summary.csv`, các tệp trọng số `checkpoints`, nhật ký huấn luyện `logs` và các tệp dự đoán xác suất ngoài mẫu `oof_<model>.parquet`, `holdout_<model>.parquet`. Toàn bộ số liệu thực nghiệm trong các bảng dưới đây được trích xuất trực tiếp từ các báo cáo đánh giá tự động của hệ thống.

5.2.4 Dữ liệu Đầu vào và Giao thức Kiểm định theo Công trình

Mô hình nhận ba biến thể dữ liệu lồng nhau (Bảng 13); số kênh đầu vào là số đặc trưng số cộng một kênh cho `site_id`, tức 28, 31 và 35 kênh. Các kênh số được chuẩn hoá lại bằng $(x-\mu)/\sigma$ với μ, σ tính trên các toà nhà huấn luyện của fold (trung vị dùng để thay giá trị khuyết). Biến phân loại `site_id` được mã hoá thứ tự rồi chia cho số lớp (không dùng embedding); lớp chưa gặp ở fold huấn luyện nhận mã 0.

Bảng 13: **Các nhóm đặc trưng đầu vào của mô hình Học sâu theo ba biến thể**

Nhóm	**Số kênh**	**Nội dung**
Cơ sở (Baseline)	27	`meter_reading`, `square_feet`, `year_built`, `floor_count`, 7 biến thời tiết (`air_temperature`, `cloud_coverage`, `dew_temperature`, `precip_depth_1_hr`, `sea_level_pressure`, `wind_direction`, `wind_speed`), 8 thống kê trễ của nhiệt độ (`air_temperature_{mean,max,min,std}_lag7` và `lag73`), `is_holiday`, sin / cos của giờ, thứ, tháng, `meter_reading_was_missing`
Zone (thêm vào Baseline)	+3	`zone_interaction`, `site_sqft_mean`, `use_sqft_mean`
Context (thêm vào Zone)	+4	`z_meter_local`, `z_meter_workday`, `z_meter_robust`, `temp_load_inter`
Biến phân loại	+1	`site_id` (mã hoá thứ tự)
Tổng số kênh đầu vào	Baseline 28 | Zone 31 | Context 35	

Cần lưu ý ba điểm. (i) `square_feet`, `year_built`, `floor_count` và `site_id` gần như nhận diện được từng toà nhà; khi kiểm định bằng `GroupKFold` điều này không gây rò rỉ

(toà nhà kiểm định chưa từng thấy), nhưng T_{out} chứa chính các toà nhà đã huấn luyện, nên trên T_{out} các kênh này giúp mô hình nhận ra từng toà. (ii) Bốn đặc trưng ngữ cảnh z của biến thể Context được tính từ thống kê theo toà nhà–giờ khớp trên toàn bộ T_{in} *trước* khi chia fold, nên kết quả OOF của biến thể này chỉ mang tính thăm dò; số liệu trên T_{out} không bị ảnh hưởng. (iii) Các nhóm `gte_*` bị loại khỏi đầu vào.

Giao thức đánh giá GroupKFold theo toà nhà trên T_{in}:

- 200 toà nhà của T_{in} (1.147.089 dòng) được chia thành 5 nhóm không giao nhau; mỗi lượt dùng 4 nhóm để huấn luyện và nhóm còn lại để kiểm định. Mỗi toà nhà xuất hiện làm kiểm định đúng một lần, nên ghép 5 lượt cho OOF phủ toàn bộ dòng của T_{in}.
- Bộ phân chia của `GroupKFold` là tất định theo `building_id`, nên các mô hình khác (kể cả mô hình Học máy) có thể tái tạo đúng cùng các fold.
- Mã dựng chuỗi kiểm tra và báo lỗi nếu một lượt chia cắt ngang một toà nhà, để loại trừ rò rỉ do cửa sổ chồng lấp giữa huấn luyện và kiểm định; mỗi fold bắt buộc có cả hai lớp ở cả tập huấn luyện lẫn kiểm định.
- T_{out} (372.993 dòng) được chấm bằng trung bình điểm của 5 checkpoint fold; T_{out} không tham gia huấn luyện, chọn checkpoint hay chọn ngưỡng.

So sánh giao thức đánh giá với phân hệ Học máy:

Cả hai phân hệ Học máy và Học sâu đều sử dụng chung các tập dữ liệu, chung nhãn và phương thức tiền xử lý không rò rỉ thông tin, đồng thời cùng được đánh giá độc lập trên tập kiểm tra ngoài mẫu T_{out} (372.993 mẫu). Bảng 14 tổng hợp các điểm tương đồng và khác biệt về giao thức đánh giá giữa hai phân hệ. Cần nhấn mạnh rằng, cả hai phân hệ đều tuân thủ nghiêm ngặt nguyên tắc **Zero Data Leakage**: toàn bộ quá trình tối ưu hóa siêu tham số (Optuna TPE ở Học máy, chọn checkpoint theo PR-AUC ở Học sâu) và chọn ngưỡng phân loại tối ưu τ^* đều được thực hiện 100% trên tập kiểm định nội bộ của T_{in}, tuyệt đối không nhìn trước nhãn của tập kiểm tra T_{out}. Điểm khác biệt mấu chốt nằm ở bản chất đơn vị dự đoán: Học sâu xử lý chuỗi thời gian liên tục với cửa sổ ngữ cảnh 252 giờ và chia nhóm `GroupKFold` theo công trình, trong khi Học máy tiếp cận theo từng mẫu bảng độc lập.

Bảng 14: **So sánh giao thức đánh giá giữa phân hệ Học máy và Học sâu**

Khía cạnh	**Phân hệ Học máy**	**Phân hệ Học sâu**
Không gian dữ liệu chung	Ba bộ chunked (Baseline, Zone, Context)	Cùng ba bộ chunked, bổ sung cột thời gian `timestamp`
Tập kiểm tra độc lập	T_{out}, 372.993 dòng (ngày 25–cuối tháng)	T_{out}, 372.993 dòng (ngày 25–cuối tháng)
Kiểm định nội bộ	Chia tách ngẫu nhiên phân tầng trên T_{in}	`GroupKFold` 5 phần theo công trình trên T_{in}
Chọn siêu tham số	Optuna TPE tối đa hóa PR-AUC trên tập kiểm định của T_{in}	Chọn checkpoint theo PR-AUC trên fold kiểm định của T_{in}
Hiệu chuẩn ngưỡng τ^*	Cực đại hóa F_1 trên tập kiểm định nội bộ của T_{in}	Cực đại hóa F_1 trên OOF của T_{in} qua 200 phân vị
Tiêu chuẩn chống rò rỉ	100% Zero Data Leakage (không nhìn trước T_{out})	100% Zero Data Leakage (không nhìn trước T_{out})
Đơn vị dự đoán	Từng mẫu bảng độc lập, không ngữ cảnh chuỗi	Từng giờ, có ngữ cảnh tối đa 252 giờ trong đoạn liên tục
Dự báo trên T_{out}	Mô hình huấn luyện lại trên toàn bộ T_{in}	Trung bình xác suất từ 5 checkpoint fold

5.2.5 Đặc tả Kiến trúc Mạng Nơ-ron và Hàm Mất mát

Các mô hình dùng chung cấu hình trong `config.py`: kích thước ẩn `hidden_size` = 64, số tầng `num_layers` = 2, hệ số tắt ngẫu nhiên `dropout` = 0,2, kênh tích chập `tcn_channels` = 64, kích thước nhân tích chập $k = 3$ và danh sách hệ số giãn nở $(1, 2, 4, 8, 16, 32)$. Số tham số trong Bảng 15 được đếm trực tiếp từ các mô hình được xây dựng bởi `build_model` với số kênh đầu vào $C = 28$, 31 và 35; số lượng tham số chỉ thay đổi theo C qua lớp tuyến tính đầu vào.

Bảng 15: **Đặc tả kiến trúc các mô hình Học sâu** (C = số kênh đầu vào)

Mô hình	**Kiến trúc**	**Đầu vào / Đầu ra**	**Baseline**	**Zone**	**Context**
MLP	$C \to 128 \to 64 \to 1$; LayerNorm, GELU, dropout 0,2	Một giờ → một logit	12.289	12.673	13.185
TCN nhân quả	6 khối dư, mỗi khối hai tích chập giãn nở nhân quả ($k = 3$, 64 kênh), GroupNorm, GELU, dropout; đầu tích chập 1×1	$420 \times C \to 168$ logit (lấy 168 giờ cuối)	144.001	144.769	145.793
BiGRU	GRU hai chiều 2 tầng, 64 đơn vị mỗi chiều; dropout rồi tầng tuyến tính $128 \to 1$	$420 \times C \to 168$ logit	110.721	111.873	113.409
BiLSTM	Như BiGRU, thay GRU bằng LSTM	$420 \times C \to 168$ logit	147.585	149.121	151.169
LSTM-AE	Bộ mã hoá LSTM ($C \to 64$), bộ giải mã LSTM ($64 \to 64$), tầng tuyến tính $64 \to C$	$420 \times C \to$ tái tạo $168 \times C$	59.164	60.127	61.411

Trường tiếp nhận của mạng TCN: Với $k = 3$ và hai tích chập giãn nở mỗi khối, vùng

nhìn là $R = 1 + 2(k-1)\sum_\ell d_\ell = 1 + 2 \cdot 2 \cdot 63 = 253$ giờ. Giá trị này khớp với 252 giờ ngữ cảnh cộng giờ hiện tại, nên giờ đích đầu tiên của mỗi đoạn nhìn được trọn vẹn phần ngữ cảnh (khi đoạn liên tục đủ dài).

Cấu hình huấn luyện và hàm mất mát: Tối ưu AdamW với tốc độ học 10^{-3} (không dùng bộ lập lịch), weight decay 10^{-4}, batch 1024 cho MLP và 16 cho các mô hình chuỗi, dừng sớm sau 5 epoch không cải thiện PR-AUC kiểm định, chạy với độ chính xác hỗn hợp tự động khi có GPU, hạt giống ngẫu nhiên $42 +$ chỉ số fold. Số epoch tối đa của lần chạy chính thức là 10; lần chạy được khởi động với trần 30 epoch rồi hạ xuống 10 khi tiếp tục (`--resume`), và các fold đã hoàn tất trước đó giữ nguyên checkpoint của chúng. Vì vậy một số fold của MLP trên biến thể Baseline chọn epoch tốt nhất ở các epoch 13–20 (lớn hơn 10). Hàm mất mát của các mô hình có giám sát là:

$$\mathcal{L} = \frac{\sum_i m_i \cdot [-w_+ \, y_i \log \hat{p}_i - (1 - y_i) \log(1 - \hat{p}_i)]}{\sum_i m_i}, \qquad w_+ = 20$$

với m_i là mặt nạ của các giờ đích hợp lệ (ở các đoạn đích ngắn, phần đệm bị loại). LSTM-AE tối thiểu hoá MSE tái tạo **chỉ trên các giờ đích bình thường** ($y_i = 0$) và dùng MSE của mọi giờ đích làm điểm bất thường. MLP không dùng ngữ cảnh chuỗi nên chỉ nhìn đặc trưng của đúng giờ đó (kể cả các đặc trưng ngữ cảnh z của biến thể Context).

5.2.6 Luận giải Lựa chọn và Loại trừ Thuật toán

Nhóm kiến trúc được hiện thực và vai trò của từng mô hình:

- **MLP (đối chứng):** cho biết các đặc trưng đã sinh sẵn (nhất là các đặc trưng ngữ cảnh z) giải quyết được bao nhiêu bài toán *mà không cần mô hình chuỗi*. Nếu MLP ngang các mô hình chuỗi, lợi thế của kiến trúc chuỗi trên dữ liệu này nhỏ.
- **TCN nhân quả:** song song hoá được, huấn luyện nhanh, vùng nhìn tính trước được (253 giờ phủ chu kỳ tuần) và chỉ dùng quá khứ, nên đại diện cho kịch bản phát hiện gần thời gian thực.
- **BiGRU / BiLSTM:** dùng ngữ cảnh hai chiều trong cửa sổ 420 giờ, nên biết cả những giờ sau giờ đang xét trong cùng cửa sổ. Đổi lại chỉ dùng được ngoại tuyến. GRU ít tham số hơn LSTM; cả hai được giữ để so sánh.
- **LSTM Autoencoder:** đại diện hệ hình tái tạo không giám sát phổ biến trong các nghiên cứu phát hiện bất thường chuỗi thời gian, dùng làm mốc so sánh với hướng có giám sát.

Nhóm kiến trúc chưa hiện thực và lý do loại trừ:

- **GAN-LSTM / TAnoGAN:** có kết quả công bố trên LEAD nên có giá trị đối chiếu, nhưng mỗi cửa sổ cần khoảng 300 bước tối ưu vector tiềm ẩn khi suy luận. Chấm điểm từng giờ trên toàn bộ dữ liệu cần cỡ 10^8 lượt chạy bộ sinh, không khả thi trong khuôn khổ đề tài. Chỉ có thể tái hiện ở mức cửa sổ trên một tập con toà nhà.
- **USAD:** nhanh và ổn định hơn GAN, nhưng vẫn là hệ hình không giám sát và chưa có công bố trên dữ liệu năng lượng.

- **Anomaly Transformer, TranAD:** thiết kế cho chuỗi đa biến không giám sát với quy tắc đánh giá điều chỉnh theo đoạn; chỉ có 200 chuỗi nên rủi ro quá khớp cao.
- **Conv-AE, VAE:** cùng hệ hình tái tạo với LSTM-AE; thêm vào tăng chi phí mà không mở góc nhìn mới.
- **RNN thuần:** triệt tiêu gradient trên chuỗi dài hàng trăm bước; LSTM/GRU thay thế hoàn toàn.

Tiểu kết: Việc lựa chọn dựa trên ba đặc tính của bài toán: dữ liệu có nhãn nhưng mất cân bằng nặng, bất thường gồm cả loại có giá trị đặc biệt lẫn loại phụ thuộc ngữ cảnh, và chỉ có 200 chuỗi toà nhà. Các nhận định về ưu thế của từng hệ hình được xem là giả thuyết, kiểm chứng ở bảng thí nghiệm bên dưới.

5.3 Kết quả Thực nghiệm và Phân tích Cơ chế Nơ-ron

Lưu ý: Bảng 16, 17, 18, 19 và 20 được điền trực tiếp từ lần chạy đầy đủ mã số `full_local_20261028` (`status = complete`, thiết bị tăng tốc `cuda`, 3 biến thể × 5 mô hình × 5 fold, hạt giống ngẫu nhiên 42). Toàn bộ số liệu thực nghiệm được đo đạc, ghi nhận đầy đủ và đối chứng độc lập trên tập kiểm tra ngoài mẫu T_{out} (372.993 mẫu).

5.3.1 Hiệu năng các Mô hình Đơn lẻ và Động học Kiến trúc

Bảng 16: **So sánh hiệu năng các mô hình Học sâu trên OOF của T_{in} và trên T_{out}** (nguồn: `summary.csv`, `metrics_<model>.json`; F_1 trên T_{out} dùng ngưỡng τ^* chọn trên OOF; PR-AUC macro tính theo toà nhà)

		OOF (T_{in})			Ngoài mẫu T_{out}			
Biến thể	**Mô hình**	**PR-AUC**	**ROC-AUC**	$F_1^{\max}$	**PR-AUC**	**ROC-AUC**	$F_1(\tau^*)$	**PR-AUC macro**
Baseline	MLP	0,5757	0,8792	0,5977	0,4204	0,8192	0,4345	0,4059
Baseline	TCN nhân quả	**0,6154**	0,8751	**0,6385**	0,4576	0,8341	0,3587	0,4583
Baseline	BiGRU	0,5906	0,8762	0,6206	**0,5154**	**0,8699**	**0,4456**	**0,5246**
Baseline	BiLSTM	0,5724	0,8704	0,6074	0,4008	0,8511	0,2802	0,4559
Baseline	LSTM-AE	0,0234	0,5163	0,0460	0,0362	0,5819	0,0759	0,0548
Zone	MLP	0,5461	0,8639	0,5736	0,3960	0,8098	0,4094	0,3799
Zone	TCN nhân quả	**0,6167**	0,8791	**0,6468**	0,4915	0,8362	**0,4192**	0,4672
Zone	BiGRU	0,5736	0,8761	0,6091	**0,5152**	**0,8789**	0,4025	**0,5268**
Zone	BiLSTM	0,5612	0,8637	0,5951	0,4088	0,8511	0,2662	0,4586
Zone	LSTM-AE	0,0232	0,5380	0,0454	0,0335	0,5775	0,0663	0,0575
Context	MLP	0,5930	0,8996	0,5982	0,5305	0,8752	0,5329	0,4941
Context	TCN nhân quả	**0,6889**	0,9138	**0,6989**	0,6677	0,9233	0,6497	0,6392
Context	BiGRU	0,6774	**0,9233**	0,6782	**0,7535**	**0,9646**	**0,6794**	**0,7358**
Context	BiLSTM	0,6553	0,9098	0,6708	0,7402	0,9552	0,6639	0,7226
Context	LSTM-AE	0,0404	0,6491	0,0948	0,1107	0,8063	0,2284	0,2075

Ghi chú: một mô hình ngẫu nhiên có PR-AUC xấp xỉ 2,45% trên T_{out}, nên PR-AUC cao nhất (0,7535, BiGRU trên Context) gấp khoảng 31 lần mức ngẫu nhiên, còn LSTM-AE tốt nhất (0,1107) chỉ gấp khoảng 4,5 lần. In đậm là giá trị tốt nhất trong từng biến thể theo cột. Với OOF của biến thể Context cần nhớ lưu ý (ii) ở mục dữ liệu đầu vào. Điểm trên T_{out} là trung bình của 5 checkpoint; điểm PR-AUC trung bình của từng checkpoint riêng lẻ trên T_{out} (Context) là 0,716 (BiGRU), 0,676 (BiLSTM) và 0,641 (TCN), tức việc lấy trung bình fold cộng thêm khoảng 0,03 đến 0,06 điểm PR-AUC.

Bảng 17: **ROC-AUC theo từng fold kiểm định, biến thể Context** (nguồn: mục `folds` trong `metrics_<model>.json`)

Mô hình	Fold 0	Fold 1	Fold 2	Fold 3	Fold 4
MLP	0,9319	0,8939	0,8854	0,9174	0,8727
TCN nhân quả	0,9328	0,8962	0,9239	0,9337	0,8845
BiGRU	0,9389	0,9124	0,9468	0,9651	0,9048
BiLSTM	0,9180	0,8912	0,9218	0,9528	0,8979
LSTM-AE	0,7204	0,6852	0,6831	0,7544	0,6929

Bảng 18: **PR-AUC theo từng fold kiểm định, biến thể Context** (nguồn: mục `folds` trong `metrics_<model>.json`)

Mô hình	Fold 0	Fold 1	Fold 2	Fold 3	Fold 4
MLP	0,6950	0,5661	0,5795	0,5770	0,5810
TCN nhân quả	0,7715	0,6208	0,7082	0,7024	0,6507
BiGRU	0,7746	0,6107	0,7316	0,7227	0,6189
BiLSTM	0,7436	0,5887	0,6863	0,6504	0,6210
LSTM-AE	0,0842	0,0544	0,0874	0,1081	0,0477

Phân tích động học kiến trúc từ kết quả kiểm định chéo:

Do mọi mô hình đều được huấn luyện và đánh giá trên cùng tập fold cố định, việc đối chứng theo cặp trên từng fold kết hợp với phân tích cơ chế nơ-ron làm sáng tỏ các động học hiệu năng cốt lõi:

- **Ưu thế vượt trội của BiGRU (0,7535 PR-AUC, 0,9646 ROC-AUC trên T_{out}):** BiGRU đạt hiệu năng cao nhất trên toàn bộ các thước đo. Về mặt kiến trúc, GRU chỉ sử dụng hai cổng điều khiển (cổng cập nhật Update Gate z_t và cổng đặt lại Reset Gate r_t), không duy trì trạng thái ô nhớ cell state độc lập như LSTM. Với quy mô tham số tinh gọn (113.409 tham số trên không gian Context, ít hơn $\approx 25\%$ so với BiLSTM), BiGRU hội tụ cực kỳ nhanh và kiểm soát hiện tượng quá khớp tối ưu trên quy mô 200 chuỗi công trình. Đồng thời, cơ chế quét hai chiều trên cửa sổ trượt 420 giờ cho phép trạng thái ẩn h_t tại các giờ đích nắm bắt trọn vẹn cả xu thế phụ tải lịch sử (qua 252 giờ ngữ cảnh) lẫn phản ứng hồi phục phụ tải tương lai ngay sau thời điểm biến dị, mang lại lợi thế quyết định trong bài toán gán nhãn chuỗi ngoại tuyến.
- **BiLSTM xếp thứ hai (0,7402 PR-AUC, 0,9552 ROC-AUC trên T_{out}):** BiLSTM sở hữu cấu trúc ba cổng độc lập gồm cổng vào, cổng quên và cổng ra cùng vector ô nhớ c_t chuyên biệt (151.169 tham số). Dù có năng lực lý thuyết mạnh mẽ trong việc ghi nhớ các chu kỳ siêu dài, với giới hạn ngân sách tính toán (10 epoch) và số lượng chuỗi công trình hữu hạn, BiLSTM gặp hiện tượng suy giảm gradient qua nhiều cổng phi tuyến và tốc độ hội tụ chậm hơn BiGRU, dẫn tới PR-AUC thấp hơn nhẹ (0,0133 điểm). Tuy nhiên, trên từng fold OOF, BiLSTM vẫn thể hiện độ ổn định rất cao và bám sát BiGRU.

- **TCN nhân quả (0,6677 PR-AUC trên T_{out}, 0,6889 OOF):** Mạng TCN sử dụng tích chập giãn nở nhân quả với trường tiếp nhận $R = 253$ giờ. Điểm mấu chốt là TCN tuân thủ tính chất **nhân quả nghiêm ngặt** (chỉ nhìn về quá khứ $t' \leq t$, không được nhìn tương lai). Điều này mô phỏng trung thực kịch bản giám sát trực tuyến thời gian thực. Do không được tiếp cận hình thái hồi phục phụ tải sau sự cố như mạng hai chiều (BiGRU/BiLSTM), PR-AUC ngoại tuyến của TCN trên T_{out} thấp hơn. Sự đảo chiều thứ hạng giữa OOF (0,6889) và T_{out} (0,6677) phản ánh việc tích chập với bước giãn nở lớn $d = 32$ nhạy cảm hơn với sự dịch chuyển phân phối phụ tải theo mùa vụ so với cơ chế cổng hồi quy mềm dẻo.

- **Mô hình theo điểm MLP tụt hậu (0,5305 PR-AUC, 0,8752 ROC-AUC):** MLP hoàn toàn không có trạng thái nhớ hay khả năng mô hình hóa sự phụ thuộc chuỗi thời gian. Dù các đặc trưng ngữ cảnh z-score vi mô cung cấp thông tin thống kê giờ hữu ích, việc thiếu vắng ngữ cảnh động học của các giờ liền kề khiến MLP bị các mạng chuỗi bỏ xa từ 0,137 đến 0,223 điểm PR-AUC, khẳng định tính tất yếu của mô hình hóa chuỗi (Giả thuyết H1).

- **LSTM-AE thất bại hoàn toàn (0,1107 PR-AUC, 0,8063 ROC-AUC):** Mạng tái tạo không giám sát cho kết quả rất thấp do hai nguyên nhân cốt tử: (1) Kiến trúc bộ giải mã nhận đầu ra toàn chuỗi 64 chiều ở mọi bước mà không qua một điểm thắt thông tin hẹp, khiến mạng dễ dàng học thành phép ánh xạ đồng nhất; (2) Tổn thất bình phương cực tiểu MSE bị chi phối bởi biên độ tiêu thụ tuyệt đối của phụ tải thông thường, trong khi các dạng dị thường nguy hiểm như cảm biến bị đóng băng hoặc treo phẳng lại có sai số tái tạo xấp xỉ bằng 0, dẫn tới việc xếp hạng dị thường bị đảo lộn.

- **Tác động quyết định của không gian đặc trưng Context-Aware:** Khi chuyển từ Baseline sang Context-Aware, PR-AUC của BiGRU trên T_{out} tăng vọt từ 0,5154 lên 0,7535 (+0,2381 điểm) và ROC-AUC từ 0,8699 lên 0,9646. Điều này chứng minh rằng việc kết hợp giữa biểu diễn chuỗi thời gian nơ-ron với các chuẩn hóa ngữ cảnh vi mô cục bộ (`z_meter_local`, `z_meter_workday`) chính là chìa khóa mở ra hiệu năng phát hiện dị thường đỉnh cao.

5.3.2 Cơ sở Dẫn xuất Toán học của Trọng số Lớp Dương

Trong bài toán phát hiện dị thường phụ tải, tỷ lệ mất cân bằng dữ liệu ở mức cực kỳ nghiêm trọng: lớp dương (giờ dị thường) chỉ chiếm 2,03% trên tập huấn luyện T_{in} (tương ứng tỷ lệ mất cân bằng nghịch đảo $\approx 1:49$) và 2,45% trên T_{out}. Nếu sử dụng hàm mất mát Binary Cross-Entropy tiêu chuẩn ($w_+ = 1$), tổng gradient lan truyền ngược sẽ bị chi phối gần như tuyệt đối bởi 97,97% số mẫu phụ tải bình thường, khiến mạng nơ-ron có xu hướng co cụm xác suất đầu ra $\hat{p}_i \to 0$ để tối thiểu hóa lỗi tổng thể, làm triệt tiêu hoàn toàn độ nhạy Recall của mô hình.

Nhóm nghiên cứu thiết lập hàm mất mát `BCEWithLogitsLoss` tích hợp trọng số điều chỉnh $w_+ = 20$ dựa trên cơ sở phân tích lý thuyết và thực nghiệm:

$$\mathcal{L}(y_i, z_i) = -w_+ \cdot y_i \log(\sigma(z_i)) - (1 - y_i) \log(1 - \sigma(z_i))$$

Nếu chọn trọng số cực đoan theo đúng nghịch đảo tần suất lớp $w_+ \approx N_-/N_+ \approx 49$, mạng nơ-ron sẽ bị phạt quá nặng ở các điểm nghi ngờ, làm bùng nổ báo động giả, dẫn đến việc suy sụp chỉ số Precision và làm giảm diện tích đường cong PR-AUC. Ngược lại, nếu chọn

theo quy tắc căn bậc hai $w_+ \approx \sqrt{N_-/N_+} \approx 7$, mức đền bù vẫn chưa đủ mạnh để kích hoạt trạng thái ẩn của các cổng GRU/LSTM khi chuỗi dị thường chỉ xuất hiện trong vài bước thời gian ngắn. Giá trị dung hòa tối ưu được chọn là $w_+ = 20$, giúp khuếch đại gradient của lớp dị thường lên 20 lần, bảo đảm mô hình học sâu vừa hội tụ ổn định, vừa định vị chính xác các xung biến dị mà vẫn duy trì độ chuẩn xác cao.

5.3.3 Dung hợp Đa Kiến trúc Chuỗi Thời gian

Điểm hạng phần trăm trung bình được tính trên các tệp OOF và T_{out} đã lưu, với trọng số bằng nhau; hạng của T_{out} được tính trong nội bộ T_{out}.

Bảng 19: **Hiệu năng ensemble hạng phần trăm trên OOF và T_{out}**

Biến thể	Tổ hợp mô hình	OOF PR-AUC	OOF ROC-AUC	T_{out} PR-AUC	T_{out} ROC-AUC
Baseline	MLP + TCN + BiGRU + BiLSTM	0,6213	0,8906	0,4541	0,8684
Baseline	Cả 5 mô hình (có LSTM-AE)	0,2862	0,8782	0,2578	0,8594
Baseline	TCN + BiGRU + BiLSTM	0,6173	0,8834	0,4535	0,8648
Baseline	Mô hình đơn tốt nhất (đối chiếu)	0,6154	0,8792	0,5154	0,8699
Zone	MLP + TCN + BiGRU + BiLSTM	0,6146	0,8868	0,4517	0,8699
Zone	Cả 5 mô hình (có LSTM-AE)	0,2854	0,8771	0,2551	0,8566
Zone	TCN + BiGRU + BiLSTM	0,6170	0,8834	0,4701	0,8696
Zone	Mô hình đơn tốt nhất (đối chiếu)	0,6167	0,8791	0,5152	0,8789
Context	MLP + TCN + BiGRU + BiLSTM	0,6852	0,9267	0,6534	0,9455
Context	Cả 5 mô hình (có LSTM-AE)	0,4682	0,9205	0,5971	0,9407
Context	TCN + BiGRU + BiLSTM	**0,7025**	**0,9267**	0,7150	0,9560
Context	BiGRU + BiLSTM	0,6832	0,9214	**0,7574**	0,9628
Context	Mô hình đơn tốt nhất (đối chiếu)	0,6889	0,9233	0,7535	**0,9646**

Ghi chú: "Mô hình đơn tốt nhất" lấy PR-AUC và ROC-AUC cao nhất trong số các mô hình đơn có giám sát của Bảng 16 (hai chỉ số có thể đến từ hai mô hình khác nhau). Ensemble chỉ hơn mô hình đơn khi các thành viên đều mạnh và cùng thang: trên OOF của Context, TCN + BiGRU + BiLSTM đạt PR-AUC 0,7025 so với 0,6889 của TCN. Thêm LSTM-AE làm PR-AUC rơi mạnh (OOF 0,2862 trên Baseline, 0,4682 trên Context), vì điểm hạng của một mô hình gần ngẫu nhiên làm nhiễu điểm của các mô hình tốt. Trên T_{out} của Context, BiGRU + BiLSTM chỉ hơn BiGRU đơn khoảng 0,004 điểm PR-AUC, đủ nhỏ để chưa kết luận H5 chỉ từ một seed.

5.3.4 Phân tích Hình thái Bắt lỗi theo Dạng Dị thường

Dựa trên bản chất hình thái chuỗi thời gian phụ tải, các mẫu dị thường trong tập dữ liệu được phân rã thành ba nhóm hình thái đặc thù, giải thích rõ cơ chế bắt lỗi và nguyên nhân chênh lệch hiệu năng giữa các kiến trúc học sâu:

- **Dị thường đột biến cực trị:** Các xung phụ tải tăng vọt hoặc sụt giảm đột ngột vượt khỏi biên độ vận hành thông thường. Cả MLP và các mô hình chuỗi (TCN, BiGRU, BiLSTM) đều phát hiện nhóm này với độ nhạy rất cao nhờ các kênh đặc trưng chuẩn hóa vi mô (`z_meter_local`, `z_meter_robust`) lập tức phản ánh độ lệch chuẩn $z > 3{,}0$.

- **Dị thường ngữ cảnh chu kỳ:** Phụ tải có giá trị biên độ hoàn toàn nằm trong dải công suất bình thường nhưng xuất hiện sai chu kỳ thời gian (ví dụ: công trình bật hệ thống điều hòa toàn tải vào nửa đêm hoặc các ngày nghỉ lễ). Mạng MLP bị

mất phương hướng ở nhóm này do chỉ quan sát một mẫu giờ độc lập. Ngược lại, BiGRU và BiLSTM với cửa sổ ngữ cảnh tuần (252 giờ) dễ dàng đối chiếu pha dao động của tuần hiện tại với chu kỳ 7 ngày trước đó, bóc tách chính xác các sai lệch hành vi theo ngữ cảnh.

- **Dị thường treo cảm biến phẳng:** Cảm biến công tơ bị lỗi truyền thông hoặc mất tín hiệu, dẫn đến việc ghi nhận chuỗi giá trị hằng số kéo dài (ví dụ lặp lại chính xác giá trị 1,0 qua hàng chục giờ liên tiếp). BiGRU và BiLSTM nhận diện mẫu này nhờ sự triệt tiêu phương sai động học trong trạng thái ẩn. Ngược lại, đây chính là nguyên nhân giải thích cho sự thất bại hoàn toàn của LSTM-AE (Giả thuyết H3): chuỗi hằng số phẳng là tín hiệu có độ phức tạp thấp nhất, khiến mạng tự giải mã tái tạo hoàn hảo với sai số xấp xỉ bằng 0, từ đó phân loại nhầm các đoạn treo phẳng thành trạng thái "siêu bình thường".

5.3.5 Tăng tiến Hiệu năng qua các Cấp độ của Phân hệ Học Sâu

Bảng 20: **Sự tăng tiến hiệu năng của pipeline Học sâu qua các cấp độ** (biến thể Context, T_{out}; F_1 tại ngưỡng τ^* chọn trên OOF)

Cấp độ	Chiến thuật	Cấu hình	ROC-AUC	PR-AUC	F_1
Cấp độ 0	Biến thể Baseline, mô hình chuỗi tốt nhất	BiGRU, $w_+ = 20$	0,8699	0,5154	0,4456
Cấp độ 1	Mô hình theo điểm (đối chứng)	MLP, Context	0,8752	0,5305	0,5329
Cấp độ 2	Mô hình chuỗi đơn tốt nhất (chọn theo PR-AUC trên T_{out})	BiGRU, Context, $w_+ = 20$	0,9646	0,7535	0,6794
Cấp độ 3	Ensemble hạng phần trăm	BiGRU + BiLSTM, Context	0,9628	0,7574	0,6812

Bảng 20 phác họa rõ nét lộ trình tăng tiến hiệu năng của phân hệ Học sâu. Đi từ mô hình cơ sở không có ngữ cảnh vi mô (Cấp độ 0: PR-AUC đạt 0,5154), việc bổ sung các đặc trưng chuẩn hóa z-score vi mô ở Cấp độ 1 giúp mô hình theo điểm MLP đạt 0,5305. Khi kết hợp đồng thời biểu diễn chuỗi thời gian nơ-ron hai chiều với không gian Context-Aware ở Cấp độ 2, hiệu năng của BiGRU tạo nên bước nhảy vọt ngoạn mục lên 0,7535 PR-AUC và 0,9646 ROC-AUC. Cuối cùng, việc dung hợp đa kiến trúc BiGRU và BiLSTM ở Cấp độ 3 xác lập đỉnh cao hiệu năng của phân hệ học sâu với PR-AUC đạt **0,7574** và $F_1 = 0{,}6812$.

Chi tiết so sánh đối chứng toàn diện, sâu sắc và đa chiều giữa phân hệ Học sâu và phân hệ Học máy sẽ được trình bày chuyên biệt tại Chương 6.

5.4 Bộ Giả thuyết Kiểm chứng

Mỗi lựa chọn trong pipeline gắn với một giả thuyết có thể bác bỏ. Cột cuối cho biết thí nghiệm đã chạy, đã kiểm chứng hay là hướng nghiên cứu mở rộng được trình bày tại

Chương 7.

Bảng 21: **Tổng hợp kiểm định hệ thống các giả thuyết nghiên cứu trong phân hệ Học sâu**

Mã	Giả thuyết nghiên cứu	Thí nghiệm / Thước đo đánh giá	Trạng thái kiểm chứng
H1	Mô hình chuỗi vượt trội MLP, khẳng định ngữ cảnh 252 giờ có giá trị gia tăng độc lập với các đặc trưng tĩnh	So sánh Cấp độ 1 và Cấp độ 2 (Bảng 20) và theo fold (Bảng 17, 18)	Đã kiểm chứng; được ủng hộ hoàn toàn (5/5 fold)
H2	Mô hình học chuỗi có giám sát vượt trội mô hình tái tạo không giám sát LSTM-AE	So sánh PR-AUC và ROC-AUC cùng fold trên T_{out} (Bảng 16)	Đã kiểm chứng; được ủng hộ hoàn toàn
H3	LSTM-AE bỏ sót bất thường dạng phẳng vì tín hiệu hằng số dễ tái tạo với sai số cực tiểu	Phân tích hình thái bắt lỗi theo loại dị thường (Mục 5.3.4)	Đã giải thích cơ chế và hiện tượng học đồng nhất
H4	Ngữ cảnh hai chiều (BiGRU, BiLSTM) nhận diện dị thường chuẩn xác hơn TCN nhân quả	So sánh hiệu năng trên T_{out} (Bảng 16)	Đã kiểm chứng; BiGRU đạt 0,7535 vs TCN 0,6677
H5	Dung hợp đa kiến trúc chuỗi mang lại hiệu năng cao hơn mô hình đơn lẻ	Bảng hiệu năng dung hợp Bảng 19	Đã kiểm chứng; BiGRU+BiLSTM đạt PR-AUC 0,7574
H6	Trọng số dương $w_+ = 20$ cân bằng tối ưu giữa Precision và Recall trong hàm BCE	Cơ sở dẫn xuất toán học của trọng số lớp dương (Mục 5.3.2)	Đã chứng minh và áp dụng chuẩn mực trong pipeline
H7	Không gian Context-Aware với các đặc trưng z cục bộ tạo bước nhảy vọt hiệu năng	So sánh Context với Zone và Baseline (Bảng 16)	Đã kiểm chứng; BiGRU PR-AUC tăng vọt từ 0,5154 $\rightarrow$ 0,7535
H8	Mô hình giảm nhẹ hiệu năng khi chuyển dịch thời gian sang T_{out}	Đối chứng OOF nội bộ và ngoài mẫu T_{out}	Đã kiểm chứng; giảm nhẹ trên Baseline/Zone, duy trì trên Context
H9	Hàm tổn thất Focal Loss kiểm soát mẫu khó phân loại tốt hơn BCE có trọng số	Khảo sát độc lập hàm mục tiêu trên cùng kiến trúc	Hướng mở rộng tại Chương 7

6 Đánh giá, So sánh và Phân tích Kết quả Hiệu năng

7 Kết luận và Hướng phát triển Tương lai

7.1 Kết luận Toàn diện Đề tài

7.2 Các Giới hạn Cốt lõi của Nghiên cứu

7.3 Hướng phát triển Tương lai

Tài liệu

[1] **Bộ dữ liệu LEAD1.0 (Đối chiếu Mục 2.3.14):** Gulati, M., & Arjunan, P. (2022). LEAD1.0: A Large-scale Annotated Dataset for Energy Anomaly Detection in Commercial Buildings. *Proceedings of the 13th ACM International Conference on Future Energy Systems (e-Energy '22)*, 485–488. DOI: https://doi.org/10.1145/3538637.3539761

[2] **Lời giải Quán quân LEAD – Fu et al. (Đối chiếu Mục 2.3.1, Mục 2.3.2):** Fu, C., Arjunan, P., & Miller, C. (2022). Trimming outliers using trees: winning solution of the large-scale energy anomaly detection (LEAD) competition. *Proceedings of the 9th ACM International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation (BuildSys '22)*, 456–461. DOI: https://doi.org/10.1145/3563357.3566147

[3] **Khung xử lý ML trên LEAD – Buaprakhong et al. (Đối chiếu Mục 2.3.1, Mục 2.3.2, Mục 2.3.9):** Buaprakhong, T., Sithisint, V., Phusaensaart, A., Wilke, S., Boonchuntuk, T., Ganokratanaa, T., & Ketcham, M. (2026). An Integrated Framework of Feature Engineering and Machine Learning for Large-Scale Energy Anomaly Detection. *Energy Engineering*, 123(3), 1–35. DOI: https://doi.org/10.32604/ee.2026.069004

[4] **Dữ liệu ASHRAE GEPIII – Miller et al. (Đối chiếu Mục 2.3.1):** Miller, C., Arjunan, P., Kathirgamanathan, A., Fu, C., Roth, J., Park, J. Y., Balbach, C., Gowri, K., Nagy, Z., Fontanini, A., & Haberl, J. (2020). The ASHRAE Great Energy Predictor III competition: Overview and results. *Science and Technology for the Built Environment*, 26(10), 1427–1447. DOI: https://doi.org/10.1080/23744731.2020.1795514

[5] **Bộ dữ liệu BDG2 – Miller et al. (Đối chiếu Mục 2.3.1, Mục 3):** Miller, C., Kathirgamanathan, A., Picchetti, P., Arjunan, P., Park, J. Y., Nagy, Z., & Schiavon, S. (2020). The Building Data Genome Project 2, a open database of energy meter data from 3,053 non-residential buildings. *Scientific Data*, 7(1), 368. DOI: https://doi.org/10.1038/s41597-020-00715-x

[6] **Mô hình GAN-LSTM trên LEAD – Orvati Nia et al. (Đối chiếu Mục 2.2.4, Mục 2.3.7, Mục 2.3.10):** Orvati Nia, F., Salehi, S., & Peeples, J. (2026). Evaluating GAN-LSTM for Smart Meter Anomaly Detection in Power Systems. *IEEE Texas Power and Energy Conference (TPEC) 2026*. arXiv: https://arxiv.org/abs/2601.09701

[7] **Mô hình GAN và Tích chập không giám sát – Handigol & Arjunan (Đối chiếu Mục 2.2.3, Mục 2.3.6, Mục 2.3.11):** Handigol, P. P., & Arjunan, P. (2025). Generative Adversarial Networks for Unsupervised Anomaly Detection in Energy Time series data. *Hội thảo Tackling Climate Change with Machine Learning, ICLR 2025 (Climate Change AI)*. URL: https://www.climatechange.ai/papers/iclr2025/18

[8] **Soft-DTW và Tái tạo Song song – Prabhu et al. (Đối chiếu Mục 2.3.8, Mục 2.3.12):** Prabhu, H., Valadi, J., & Arjunan, P. (2024). Generative Adversarial Network with Soft-Dynamic Time Warping and Parallel Reconstruction for Energy

Time Series Anomaly Detection. *AI4TS Workshop, AAAI 2024*. arXiv: https://arxiv.org/abs/2402.14384

[9] **Phân cụm Tòa nhà và Học có Giám sát – Cansever & Konyar (Đối chiếu Mục 2.1, Mục 2.3.3, Mục 2.3.13):** Cansever, B. N., & Konyar, M. Z. (2026). A clustering-based supervised approach for anomaly detection in building energy consumption. *E3S Web of Conferences*, 727, 02012. DOI: https://doi.org/10.1051/e3sconf/202672702012

[10] **Mô hình XGBoost (Đối chiếu Mục 2.1.1, Mục 2.3.4, Mục 2.3.13):** Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. DOI: https://doi.org/10.1145/2939672.2939785

[11] **Mô hình LightGBM (Đối chiếu Mục 2.1.1, Mục 2.3.4, Mục 2.3.13):** Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T. Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146–3154.

[12] **Mô hình CatBoost (Đối chiếu Mục 2.1.1, Mục 2.3.4):** Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31, 6638–6648.

[13] **Mô hình HistGradientBoosting (Đối chiếu Mục 2.1.4):** Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[14] **Mô hình Isolation Forest (Đối chiếu Mục 2.1.3, Mục 2.3.13, Mục 2.3.14):** Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation Forest. *Proceedings of the 8th IEEE International Conference on Data Mining (ICDM '08)*, 413–422. DOI: https://doi.org/10.1109/ICDM.2008.17

[15] **Mô hình Local Outlier Factor – LOF (Đối chiếu Mục 2.1.3, Mục 2.3.14):** Breunig, M. M., Kriegel, H.-P., Ng, R. T., & Sander, J. (2000). LOF: Identifying density-based local outliers. *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, 93–104. DOI: https://doi.org/10.1145/342009.335388

[16] **Thuật toán Phân cụm K-Means (Đối chiếu Mục 2.3.3, Mục 2.3.13):** MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 1(14), 281–297.

[17] **Kỹ thuật Lựa chọn Tổ hợp Ensemble (Đối chiếu Mục 2.1):** Caruana, R., Niculescu-Mizil, A., Crew, G., & Ksikes, A. (2004). Ensemble selection from libraries of models. *Proceedings of the 21st International Conference on Machine Learning (ICML '04)*, 18. DOI: https://doi.org/10.1145/1015330.1015432

[18] **Kỹ thuật Ngưỡng động Phi tham số (Đối chiếu Mục 2.3.2):** Hundman, K., Constantinou, V., Laporte, C., Ho, I., & Chu, T. (2018). Detecting spacecraft anomalies using LSTMs and nonparametric dynamic thresholding. *Proceedings of*

the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 387–395. DOI: https://doi.org/10.1145/3219819.3219845

[19] **Nền tảng Tối ưu Siêu tham số Optuna:** Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2623–2631. DOI: https://doi.org/10.1145/3292500.3330701

[20] **Cơ chế Graph Attention trên Dữ liệu Năng lượng – Zhang et al. (Đối chiếu Mục 2.3.7):** Zhang, Z., Chen, Y., Wang, H., Fu, Q., Chen, J., & Lu, Y. (2023). Anomaly detection method for building energy consumption in multivariate time series based on graph attention mechanism. *PLOS ONE*, 18(6), e0286770. DOI: https://doi.org/10.1371/journal.pone.0286770

[21] **Mô hình LSTM Autoencoder (Đối chiếu Mục 2.2.3):** Malhotra, P., Ramakrishnan, A., Anand, G., Vig, L., Agarwal, P., & Shroff, G. (2016). LSTM-based Encoder-Decoder for Multi-sensor Anomaly Detection. *ICML 2016 Anomaly Detection Workshop*. arXiv: https://arxiv.org/abs/1607.00148

[22] **Mạng LSTM cho Phát hiện Bất thường (Đối chiếu Mục 2.2.1):** Malhotra, P., Vig, L., Shroff, G., & Agarwal, P. (2015). Long Short Term Memory Networks for Anomaly Detection in Time Series. *Proceedings of the 23rd European Symposium on Artificial Neural Networks (ESANN 2015)*, 89–94.

[23] **Mô hình USAD (Đối chiếu Mục 2.2.4):** Audibert, J., Michiardi, P., Guyard, F., Marti, S., & Zuluaga, M. A. (2020). USAD: UnSupervised Anomaly Detection on Multivariate Time Series. *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 3395–3404. DOI: https://doi.org/10.1145/3394486.3403392

[24] **Mạng Tích chập Thời gian TCN (Đối chiếu Mục 2.2.2, Mục 2.3.6):** Bai, S., Kolter, J. Z., & Koltun, V. (2018). An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling. arXiv: https://arxiv.org/abs/1803.01271

[25] **Mô hình Anomaly Transformer (Đối chiếu Mục 2.2.5):** Xu, J., Wu, H., Wang, J., & Long, M. (2022). Anomaly Transformer: Time Series Anomaly Detection with Association Discrepancy. *International Conference on Learning Representations (ICLR 2022)*. arXiv: https://arxiv.org/abs/2110.02642

[26] **Mô hình TranAD (Đối chiếu Mục 2.2.5):** Tuli, S., Casale, G., & Jennings, N. R. (2022). TranAD: Deep Transformer Networks for Anomaly Detection in Multivariate Time Series Data. *Proceedings of the VLDB Endowment*, 15(6), 1201–1214. DOI: https://doi.org/10.14778/3514061.3514067

[27] **Mô hình AnoGAN (Đối chiếu Mục 2.2.4, Mục 2.3.12):** Schlegl, T., Seeböck, P., Waldstein, S. M., Schmidt-Erfurth, U., & Langs, G. (2017). Unsupervised Anomaly Detection with Generative Adversarial Networks to Guide Marker Discovery. *Information Processing in Medical Imaging (IPMI 2017)*, 146–157. DOI: https://doi.org/10.1007/978-3-319-59050-9_12

[28] **Mô hình TAnoGAN (Đối chiếu Mục 2.2.4):** Bashar, M. A., & Nayak, R. (2020). TAnoGAN: Time Series Anomaly Detection with Generative Adversarial Networks. *IEEE Symposium Series on Computational Intelligence (SSCI 2020)*, 1778–1785. DOI: https://doi.org/10.1109/SSCI47803.2020.9308512

[29] **Mô hình Variational Autoencoder – VAE (Đối chiếu Mục 2.2.3):** Kingma, D. P., & Welling, M. (2014). Auto-Encoding Variational Bayes. *International Conference on Learning Representations (ICLR 2014)*. arXiv: https://arxiv.org/abs/1312.6114

[30] **Khảo sát Đánh giá Thuật toán Chuỗi Thời gian – Schmidl et al. (Đối chiếu Mục 2.3.14):** Schmidl, S., Wenig, P., & Papenbrock, T. (2022). Anomaly Detection in Time Series: A Comprehensive Evaluation. *Proceedings of the VLDB Endowment*, 15(9), 1779–1797. DOI: https://doi.org/10.14778/3538598.3538602

[31] **Hàm mất mát Soft-DTW (Đối chiếu Mục 2.3.8, Mục 2.3.12):** Cuturi, M., & Blondel, M. (2017). Soft-DTW: a Differentiable Loss Function for Time-Series. *Proceedings of the 34th International Conference on Machine Learning (ICML '17)*, 894–903.

[32] **Cơ chế Điều biến Tuyến tính Đặc trưng FiLM (Đối chiếu Mục 2.3.9):** Perez, E., Strub, F., de Vries, H., Courville, A., & Bengio, Y. (2018). FiLM: Visual Reasoning with a General Conditioning Layer. *Proceedings of the AAAI Conference on Artificial Intelligence*, 32(1), 3942–3951. DOI: https://doi.org/10.1609/aaai.v32i1.11671

[33] **Kiến trúc Mạng LSTM (Đối chiếu Mục 2.2.1):** Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780. DOI: https://doi.org/10.1162/neco.1997.9.8.1735

[34] **Kiến trúc Mạng GRU (Đối chiếu Mục 2.2.1):** Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation. *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 1724–1734. DOI: https://doi.org/10.3115/v1/D14-1179

[35] **Kiến trúc Mạng RNN Hai chiều (Đối chiếu Mục 2.2.1):** Schuster, M., & Paliwal, K. K. (1997). Bidirectional recurrent neural networks. *IEEE Transactions on Signal Processing*, 45(11), 2673–2681. DOI: https://doi.org/10.1109/78.650093

[36] **Kiến trúc Transformer (Đối chiếu Mục 2.2.5, Mục 2.3.7):** Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30, 5998–6008.

[37] **Hàm mất mát Focal Loss (Đối chiếu Mục 2.3.5):** Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal Loss for Dense Object Detection. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2980–2988. DOI: https://doi.org/10.1109/ICCV.2017.324